

ESTATÍSTICA, 2.^a edição surge agora totalmente adaptado ao novo paradigma da aprendizagem.

De facto, esta edição promove e facilita o processo de aprendizagem, apelando ao trabalho individual do leitor e à capacidade para testar o seu grau de autonomia na aplicação dos métodos de análise estatística a situações próximas das reais.

Estruturado em 14 capítulos, faz a cobertura da matéria de uma forma sistemática e desenvolvida, permitindo que o leitor escolha assuntos que melhor se adaptam ao seu programa.


A abordagem dos temas é feita de uma forma prática, sob perspectiva de aplicação. Cada capítulo contém exemplos e problemas, além de, quando necessário, incluir apêndices explicativos ou suplementares à matéria apresentada.

Esta edição inclui ainda um **CD Resolução dos Problemas** que orienta o leitor na abordagem e resolução dos problemas apresentados no final de cada capítulo. Apresentando informações com diferentes níveis de apoio e de forma interactiva, o CD contém ainda um formulário e uma lista de endereços electrónicos que vale a pena visitar!

Rui Campos Guimarães
José A. Sarsfield Cabral

Estatística

2/e



ESTATÍSTICA

Rui Campos Guimarães

José A. Sarsfield Cabral

Agora com CD

ESTATÍSTICA

Rui Campos Guimarães 2/e
José A. Sarsfield Cabral
Bernardo Almada-Lobo

Resolução
dos Problemas



ISBN-13: 978-969-642-108-3



9 789896 421083



VERLAG
DASHÖFER

Learning & Higher
Education

2.^a edição

HA
GUI/EST ex.2

Sobre os Autores

Rui Campos Guimarães doutorou-se em Investigação Operacional na Universidade de Lancaster, Reino Unido (1981), sendo, desde 1999, professor catedrático da FEUP — Faculdade de Engenharia da Universidade do Porto. Foi presidente da Direcção do ISEE — Instituto Superior de Estudos Empresariais daquela universidade (1996-2000) e presidente do Conselho Académico desta instituição (1988-2000), mantendo ainda a última destas funções na EGP — Escola de Gestão do Porto, instituição que, na Universidade do Porto, veio a suceder ao ISEE. Foi presidente da Direcção do INEGI — Instituto de Engenharia Mecânica e Gestão Industrial (1986-89) e da APDIO — Associação Portuguesa de Investigação Operacional (1991-95) e foi director da Licenciatura em Gestão e Engenharia Industrial da FEUP (1990-95).

Desenvolveu actividades de ensino, investigação e consultadoria nas áreas de Metodologia e Técnicas de Investigação Operacional, Estatística e Métodos de Previsão. É, desde 2003, director geral da COTEC Portugal — Associação Empresarial para a Inovação.

José António Sarsfield Cabral exerceu a sua actividade profissional na indústria entre 1975 e 1984. Iniciou então a sua carreira académica na Faculdade de Engenharia da Universidade do Porto (FEUP), onde se doutorou em 1990. É desde 2006, professor catedrático na FEUP. Foi director da Licenciatura em Gestão e Engenharia Industrial da FEUP (1999-2003) e é Membro do Conselho Académico da Escola de Gestão do Porto (EGP). Foi Vice-Presidente da Associação Portuguesa para a Qualidade (1997-2000) e é *senior member* da American Society for Quality.

Tem orientado a sua carreira de docente, de investigação e de consultadoria para as áreas da Gestão da Qualidade e da Estatística Aplicada. É Pró-Reitor da Universidade do Porto desde 1999.

ÍNDICE GERAL

■ CAPÍTULO 1 INTRODUÇÃO GERAL 1

- 1.1 Objecto da estatística 1
- 1.2 População e amostra 2
- 1.3 Fases do método de análise estatística 4
 - 1.3.1 Estabelecimento do objectivo da análise e definição da(s) população(ões) correspondente(s) 4
 - 1.3.2 Concepção de um procedimento adequado para a selecção de uma ou mais amostras 4
 - 1.3.3 Recolha de dados 6
 - 1.3.4 Análise dos dados 7
 - 1.3.5 Estabelecimento de inferências acerca da(s) população(ões) 8

■ CAPÍTULO 2 ESTATÍSTICA DESCRITIVA 9

- 2.1 Introdução 9
- 2.2 Classificação dos dados segundo a escala em que são expressos 9
 - 2.2.1 Dados qualitativos: escala nominal e escala ordinal 9
 - 2.2.2 Dados quantitativos: escala de intervalo e escala absoluta 10
 - 2.2.3 Comparação entre as diferentes escalas 11
- 2.3 Caracterização de amostras univariadas 11
 - 2.3.1 Dados qualitativos 11
 - 2.3.2 Dados quantitativos 12
 - 2.3.2.1 Formas de representação tabular ou gráfica 12
 - 2.3.2.2 Estatísticas 19
- 2.4 Caracterização de amostras bivariadas 34
 - 2.4.1 Dados qualitativos 35
 - 2.4.2 Dados quantitativos 36
- Apêndice 2.1 Média geométrica e média harmónica 44
- Problemas 46

■ CAPÍTULO 3 TEORIA ELEMENTAR DA PROBABILIDADE 49

- 3.1 Introdução 49
- 3.2 Experiências aleatórias, espaços amostrais e acontecimentos 50
- 3.3 Probabilidade 51
 - 3.3.1 Definição clássica 52
 - 3.3.2 Definição geométrica 53
 - 3.3.3 Definição frequencista 54
 - 3.3.4 Definição subjectiva 54
 - 3.3.5 Definição axiomática 55
- 3.4 Probabilidade condicional 56
- 3.5 Acontecimentos independentes 58
- 3.6 Teorema de Bayes 60
- Apêndice 3.1 Análise combinatória 63
- Problemas 64



CAPÍTULO 4 VARIÁVEIS ALEATÓRIAS. DISTRIBUIÇÕES DE PROBABILIDADE 67

- 4.1 Definição de variável aleatória 67
- 4.2 Variáveis discretas: função de probabilidade e função de distribuição 69
- 4.3 Variáveis contínuas: função densidade de probabilidade e função de distribuição 71
- 4.4 As funções de probabilidade, densidade de probabilidade e de distribuição encaradas como formas de representação de populações 77
- 4.5 Parâmetros das distribuições 79
 - 4.5.1 Parâmetros de localização 79
 - 4.5.2 Parâmetros de dispersão 82
 - 4.5.2 Outros parâmetros 84
- 4.6 Variáveis transformadas 86
 - 4.6.1 Transformação de variáveis aleatórias 86
 - 4.6.2 Os momentos populacionais como valores esperados de variáveis transformadas 86
 - 4.6.3 Distribuição das variáveis transformadas: cálculo do valor esperado e da variância 87
- Apêndice 4.1 Função geradora de momentos 92
- Problemas 93

CAPÍTULO 5 DISTRIBUIÇÕES CONJUNTAS DE PROBABILIDADE 95

- 5.1 Introdução 95
- 5.2 Distribuições conjuntas 95
- 5.3 Distribuições marginais 98
- 5.4 Distribuições condicionais 99
- 5.5 Independência entre variáveis 101
- 5.6 Covariância e correlação 103
- 5.7 Variáveis transformadas 106
 - 5.7.1 Variáveis obtidas por transformação de pares de variáveis aleatórias 106
 - 5.7.2 A covariância definida como valor esperado de uma variável transformada 107
 - 5.7.3 Cálculo do valor esperado e da variância de variáveis transformadas 108
 - 5.7.3.1 Combinação linear de variáveis 108
 - 5.7.3.2 Transformações não-lineares 110
- Apêndice 5.1 Valores limites do coeficiente de correlação, ρ_{HW} 114
- Problemas 116

CAPÍTULO 6 CARACTERIZAÇÃO DE ALGUMAS DISTRIBUIÇÕES DISCRETAS UNIVARIADAS 119

- 6.1 Introdução 119
- 6.2 Distribuição binomial 119
 - 6.2.1 Definição 119
 - 6.2.2 Expressões do valor esperado e da variância 121
- 6.3 Distribuição binomial negativa 122
 - 6.3.1 Definição 122
 - 6.3.2 Expressões do valor esperado e da variância 123

- 6.4 Distribuição hipergeométrica 123
 - 6.4.1 Definição 123
 - 6.4.2 Expressões do valor esperado e da variância 125
 - 6.4.3 Relação entre as distribuições binomial e hipergeométrica 125
- 6.5 Distribuição de Poisson 126
 - 6.5.1 Definição 126
 - 6.5.2 Expressões do valor esperado e da variância 128
 - 6.5.3 Relação entre a distribuição de Poisson e as distribuições binomial e hipergeométrica 128
- Apêndice 6.1 Valor esperado e variância de uma variável aleatória binomial $Y \sim B(N, p)$ 130
- Apêndice 6.2 Valor esperado e variância de uma variável aleatória binomial negativa $Y \sim BN(r, p)$ 131
- Apêndice 6.3 Valor esperado e variância de uma variável aleatória hipergeométrica $Y \sim H(M \cdot p, M \cdot q, N)$ 133
- Apêndice 6.4 Caracterização da função de probabilidade da distribuição de Poisson 135
- Apêndice 6.5 Valor esperado e variância de uma variável aleatória $y \sim \text{Poisson}(\lambda)$ 137
- Apêndice 6.6 Aproximação de uma distribuição binomial (N, p) de uma distribuição de Poisson (λ) 138
- Problemas 139

CAPÍTULO 7 CARACTERIZAÇÃO DE ALGUMAS DISTRIBUIÇÕES CONTÍNUAS UNIVARIADAS 141

- 7.1 Introdução 141
- 7.2 Distribuição uniforme 141
 - 7.2.1 Definição 141
 - 7.2.2 Expressões do valor esperado e da variância 143
- 7.3 Distribuição exponencial negativa 143
 - 7.3.1 Definição 143
 - 7.3.2 Expressões do valor esperado e da variância 144
- 7.4 Distribuição normal 145
 - 7.4.1 Definição 145
 - 7.4.2 Transformação linear de uma variável normal. Distribuição normal padronizada 146
 - 7.4.3 Combinação linear de variáveis normais independentes 148
 - 7.4.4 Relação entre a distribuição normal e a distribuição binomial 149
- 7.5 Distribuição lognormal 150
 - 7.5.1 Definição 150
 - 7.5.2 Expressões do valor esperado e da variância 150
- 7.6 Distribuição do qui-quadrado 152
 - 7.6.1 Definição 152
 - 7.6.2 Expressões do valor esperado e da variância 153
- 7.7 Distribuição t de Student 154
 - 7.7.1 Definição 154
 - 7.7.2 Expressões do valor esperado e da variância 156



7.8	Distribuição F	156
7.8.1	Definição	156
7.8.2	Expressões do valor esperado e da variância	157
Apêndice 7.1	Valor esperado e variância de uma variável exponencial negativa $X \sim EN(\lambda)$	158
Apêndice 7.2	Verificação de que uma função definida pela expressão 7.7 é uma função densidade de probabilidade	159
Apêndice 7.3	Valor esperado e variância de uma variável normal $X \sim N(\mu, \sigma^2)$	160
Apêndice 7.4	Distribuição de uma variável obtida por transformação linear de uma variável normal $X \sim N(\mu, \sigma^2)$	161
Apêndice 7.5	Valor esperado e variância de uma variável lognormal $X \sim LN(\mu, \sigma^2)$	162
Apêndice 7.6	Demonstração da relação 7.21	163
Problemas		164

■ CAPÍTULO 8 AMostragem Aleatória. Distribuições por Amostragem 167

8.1	Introdução	167
8.2	Amostragem aleatória	167
8.3	Distribuições por amostragem	170
8.4	Distribuição da média amostral	171
8.4.1	Valor esperado e variância da média amostral	171
8.4.2	Forma da distribuição da média amostral quando a população é normal	173
8.5	Teorema do limite central	173
8.5.1	Enunciado do teorema. Implicações na caracterização de distribuições por amostragem	173
8.5.2	Justificação da normalidade de certas variáveis	175
8.5.3	Justificação de alguns resultados apresentados anteriormente	176
8.5.3.1	Aproximação da distribuição binomial pela distribuição normal	176
8.5.3.2	Aproximação da distribuição hipergeométrica pela distribuição normal	176
8.5.3.3	Aproximação da distribuição χ^2_{α} pela distribuição normal	176
8.6	Geração de amostras recorrendo à técnica de Monte Carlo	176
8.6.1	Enquadramento	176
8.6.2	Geração de amostras aleatórias provenientes de uma população com uma distribuição $U(0, 1)$	177
8.6.3	Geração de amostras aleatórias provenientes de uma população discreta qualquer	179
8.6.4	Geração de amostras aleatórias provenientes de uma população contínua qualquer	180
Apêndice 8.1	Variância da média amostral (população finita, amostragem sem reposição)	183
Apêndice 8.2	Métodos congruenciais lineares para geração de números pseudo-aleatórios	185
Apêndice 8.3	Geração de amostras aleatórias $N(0, 1)$ pelo método de Box-Muller	186
Problemas		187

■ CAPÍTULO 9 ESTIMAÇÃO PONTUAL 189

9.1	Introdução. Estimadores e estimativas	189
9.2	Propriedades desejáveis dos estimadores pontuais	190
9.2.1	Não-enviesamento	190
9.2.2	Eficiência	191
9.2.3	Consistência	193
9.2.4	Outras características desejáveis	195
9.3	Métodos de estimação	195
9.3.1	Método dos momentos	195
9.3.2	Método de máxima verosimilhança	197
9.3.3	Método de estimação linear com variância mínima	202
9.3.4	Método dos mínimos quadrados	205
9.3.5	Seleção de um estimador	207
Apêndice 9.1	O valor esperado do desvio quadrático médio amostral calculado com base numa amostra aleatória simples	208
Problemas		210



■ CAPÍTULO 10 ESTIMAÇÃO POR INTERVALO 213

10.1	O conceito de intervalo de confiança	213
10.2	Especificação de intervalos de confiança	216
10.2.1	Intervalo de confiança para o valor esperado	217
10.2.1.1	Amostra de grande dimensão, população qualquer	217
10.2.1.2	Amostra de pequena dimensão, população normal	218
10.2.2	Intervalo de confiança da proporção binomial (amostras de grande dimensão)	220
10.2.3	Intervalo de confiança para a variância de uma população normal	222
10.2.4	Intervalo de confiança para a razão entre variâncias de populações normais	223
10.2.5	Intervalo de confiança para a diferença entre os valores esperados de duas populações	225
10.2.5.1	Amostras independentes de grandes dimensões, populações quaisquer	225
10.2.5.2	Amostras independentes de pequenas dimensões, populações normais	227
10.2.6	Intervalo de confiança para a diferença entre proporções binomiais (amostras independentes de grandes dimensões)	229
10.3	Dimensionamento de amostras	230
Apêndice 10.1	Justificação da expressão 10.4	233
Problemas		235

■ CAPÍTULO 11 TESTE DE HIPÓTESES 237

- 11.1 Introdução. Análise do procedimento básico envolvido no teste de hipóteses 237
 - 11.1.1 Definição das hipóteses 237
 - 11.1.2 Identificação da estatística de teste e caracterização da sua distribuição 239
 - 11.1.3 Definição da regra de decisão. Erro do tipo I e especificação do nível de significância 240
 - 11.1.4 Cálculo da estatística de teste e tomada de decisão 241
- 11.2 Valor de prova 242
- 11.3 Erro do tipo II. Potência do teste 243
- 11.4 Relação entre testes de hipóteses e intervalos de confiança 247
- 11.5 Testes mais comuns 249
 - 11.5.1 Testes de dispersão (variância) 250
 - 11.5.1.1 Teste à variância de uma população (teste do χ^2) 250
 - 11.5.1.2 Teste à razão de variâncias entre duas populações normais (teste F) 250
 - 11.5.2 Testes de localização (ao valor esperado) 251
 - 11.5.2.1 Testes ao valor esperado de uma população 251
 - 11.5.2.2 Testes à diferença entre valores esperados de duas populações (amostras independentes) 252
 - 11.5.2.3 Testes à diferença entre valores esperados de duas populações (amostras emparelhadas) 253
 - 11.5.3 Testes de localização (proporção binomial) 256
 - 11.5.3.1 Teste à proporção binomial (uma amostra de grande dimensão) (teste Z) 256
 - 11.5.3.2 Teste à diferença entre duas proporções binomiais (amostras de grandes dimensões) (teste Z) 257
- Problemas 258

■ CAPÍTULO 12 TESTES NÃO-PARAMÉTRICOS 261

- 12.1 Introdução 261
- 12.2 Testes de qualidade de ajuste 262
 - 12.2.1 Ajuste de uma amostra a uma distribuição teórica 262
 - 12.2.1.1 Teste do qui-quadrado 262
 - 12.2.1.2 Teste de Kolmogorov-Smirnov 267
 - 12.2.2 Ajuste entre duas amostras independentes 271
 - 12.2.2.1 Teste do qui-quadrado 271
 - 12.2.2.2 Teste K-S 274
- 12.3 Testes de localização 276
 - 12.3.1 Localização de uma população 276
 - 12.3.1.1 Teste do sinal 276
 - 12.3.1.2 Teste de Wilcoxon 279
 - 12.3.2 Localização relativa de duas populações 281
 - 12.3.2.1 Amostras independentes: teste de Mann-Whitney-Wilcoxon 281
 - 12.3.2.2 Amostras emparelhadas: teste do sinal e teste de Wilcoxon 286


- 12.4 Testes de aleatoriedade 287
 - 12.4.1 Teste das sequências 288
 - 12.4.2 Teste das sequências ascendentes e descendentes 289
- 12.5 Testes de associação 291
 - 12.5.1 Teste de correlação ordinal de Spearman 291
 - 12.5.2 Teste do qui-quadrado baseado na tabela de contingência 294
- Apêndice 12.1 Ilustração do cálculo da função de probabilidade da estatística t (teste de Wilcoxon) 297
- Apêndice 12.2 Ilustração do cálculo da função de probabilidade da estatística W (teste de Mann-Whitney-Wilcoxon) 298
- Problemas 299

■ CAPÍTULO 13 ANÁLISE DE VARIÂNCIA 303

- 13.1 Introdução 303
- 13.2 Análise de variância com um factor 303
 - 13.2.1 Modelo ANOVA de efeitos fixos 303
 - 13.2.2 Definição conjunta de intervalos de confiança pelo método de Tukey 310
 - 13.2.2.1 Amostras equilibradas 310
 - 13.2.2.2 Amostras pouco desequilibradas 310
 - 13.2.3 Definição conjunta de intervalos de confiança pelo método de Scheffé 311
 - 13.2.4 Modelo de efeitos variáveis 312
- 13.3 Análise de variância com dois factores 316
 - 13.3.1 Introdução 316
 - 13.3.2 Modelo de efeitos fixos com duas ou mais observações por célula 316
 - 13.3.3 Modelo de efeitos variáveis com duas ou mais observações por célula 324
 - 13.3.4 Modelos de efeitos fixos e efeitos variáveis com uma observação por célula 327
- 13.4 Implicações da não satisfação das condições impostas aos erros 331
 - 13.4.1 Teste de Kruskal-Wallis 332
 - 13.4.2 Teste de Bartlett 334
- 13.5 Comentário sobre a aplicação da análise de variância à resolução de problemas complexos 335
- Apêndice 13.1 Estimação dos parâmetros do modelo ANOVA com um factor de efeitos fixos recorrendo ao método dos mínimos quadrados 336
- Apêndice 13.2 Modelo ANOVA com um factor: decomposição da variação total (demonstração da expressão 13.3) 338
- Apêndice 13.3 Modelo ANOVA com um factor de efeitos fixos: cálculo dos valores esperados dos desvios quadráticos médios dentro dos grupos e entre os grupos 339
- Apêndice 13.4 Modelo ANOVA com um factor de efeitos fixos: justificação da distribuição da estatística do teste ANOVA quando H_0 é verdadeira 342
- Problemas 343



14.1	Introdução	347
14.2	Regressão linear simples	347
14.2.1	Modelo de regressão linear simples. Hipóteses subjacentes	347
14.2.2	Estimação dos parâmetros de regressão através do método dos mínimos quadrados	349
14.2.3	Intervalos de confiança e testes relativos aos parâmetros de regressão	352
14.2.3.1	Intervalos de confiança	352
14.2.3.2	Testes de hipóteses	354
14.2.4	Previsões efectuadas com base no modelo de regressão linear simples	357
14.2.5	Regressão linear simples e correlação entre variáveis	360
14.3	Regressão linear múltipla	361
14.3.1	Modelo de regressão linear múltipla. Hipóteses subjacentes	361
14.3.2	Estimação dos parâmetros de regressão através do método dos mínimos quadrados	362
14.3.3	Intervalos de confiança e testes relativos aos parâmetros de regressão	366
14.3.3.1	Intervalos de confiança	366
14.3.3.2	Testes de hipóteses	367
14.3.4	Seleção de regressores	371
14.3.4.1	Método exaustivo	372
14.3.4.2	Método progressivo	372
14.3.4.3	Método regressivo	377
14.3.4.4	Métodos de regressão passo a passo	377
14.3.5	Colinearidade	378
14.3.6	Previsões efectuadas com base em modelos de regressão linear múltipla	379
14.3.7	Incorporação de regressores qualitativos num modelo de regressão: variáveis mudas	381
14.3.8	Regressão linear múltipla e correlação	384
14.4	Regressão não-linear	385
14.4.1	Regressão linear simples com transformação de variáveis	385
14.4.2	Regressão linear múltipla com transformação de variáveis	389
14.4.2.1	Regressão polinomial	389
14.4.2.2	Inclusão de produtos cruzados	392
14.4.3	Regressão sem transformação de variáveis	393
Problemas		394
Tabelas		399
Bibliografia		449
Índice Remissivo		451



Introdução Geral




1.1 OBJECTO DA ESTATÍSTICA

A palavra estatística podem atribuir-se diferentes significados. No sentido mais amplo, ela refere-se a uma disciplina cujo objecto fundamental é a recolha, a compilação, a análise e a interpretação de dados.

Para clarificar o que se entende por análise e interpretação de dados, é útil estabelecer, desde já, uma distinção entre estatística descritiva e inferência estatística.

No âmbito da primeira procura-se sintetizar e representar de uma forma compreensível a informação contida num conjunto de dados. Esta tarefa, que adquire importância quando o volume de dados for significativo, materializa-se na construção de tabelas, de gráficos ou no cálculo de medidas que representem convenientemente a informação contida nos dados (ver Figura 1.1).

Figura 1.1
Objectivo da estatística descritiva: síntese da informação contida em dados.



Exemplo 1.1

Um gestor de um banco dispõe de uma lista de 550 saldos de contas à ordem seleccionadas ao acaso, numa determinada data, entre as contas de profissionais liberais clientes das suas agências nacionais. Mais útil do que dispor dos dados em bruto (isto é, da lista de 550 saldos) é ter a informação devidamente classificada (saldos negativos, saldos incluídos nos intervalos 0-100 euros, 100-200 euros, etc.) e representada, por exemplo, num gráfico (como na Figura 1.1).

O objectivo da inferência estatística é mais ambicioso do que o da estatística descritiva e, naturalmente, os métodos e técnicas requeridos são mais sofisticados. Com base na análise de um conjunto limitado de dados (uma **amostra**), pretende-se caracterizar o todo a partir do qual tais dados foram obtidos (a **população**).


Exemplo 1.2

Retomando o Exemplo 1.1, admita-se que o gestor do banco pretende, a partir do conjunto de 550 saldos de que dispõe, retirar conclusões acerca da forma como se distribuem os saldos relativos ao conjunto das contas à ordem de todos os profissionais liberais clientes do banco.

1.2 POPULAÇÃO E AMOSTRA

Para precisar os conceitos de população e de amostra, considere-se uma determinada análise estatística que incide sobre um conjunto de objectos e, em particular, sobre uma característica que, sendo comum a esses objectos, varia em quantidade ou qualidade. Neste contexto, designa-se por população (ou universo) o conjunto dos dados que expressam a característica em causa para todos os objectos sobre os quais a análise incide. Uma amostra corresponde a um subconjunto de dados que pertencem à população. Na Figura 1.2 apresenta-se um diagrama no qual se ilustra a relação entre uma população, P , e um conjunto de amostras nela incluídas, A_i ($i = 1, 2, 3$).

Figura 1.2
Relação entre
população (P)
e amostras (A_i , $i = 1, 2, 3$).



Exemplo 1.3

Retomando o Exemplo 1.2, ter-se-á:

- Objectos sobre os quais incide a análise: contas à ordem de todos os profissionais liberais clientes do banco.
- Característica analisada: saldo registado numa determinada data.
- População: conjunto dos saldos das contas à ordem de todos os profissionais liberais clientes do banco, na data em causa.
- Amostra: conjunto de 550 saldos seleccionados.

Em relação às definições de população e de amostra, vale a pena fazer algumas observações. A primeira tem que ver com o facto de, com muita frequência, aqueles termos serem usados referindo-se indistintamente aos objectos sobre os quais incide a análise estatística e aos dados que medem a característica que é analisada. Como é evidente, desde que o objectivo da análise seja claro, esta imprecisão não acarreta qualquer risco de confusão.

Exemplo 1.4

- No Exemplo 1.2, tal corresponderia a considerar indistintamente como população o conjunto de todas as contas à ordem dos profissionais liberais clientes do banco na data em causa ou os saldos dessas contas.
- Na ficha técnica de uma sondagem de opinião relativa às últimas eleições, referia-se que ela tinha sido efectuada com base numa amostra constituída por 2000 eleitores. De acordo com a definição acima introduzida, cada amostra seria constituída pelo conjunto das intenções de voto dos eleitores inquiridos e não directamente por estes.

A segunda observação tem que ver com o facto de que os conceitos de população e de amostra são definidos em função de uma análise estatística e, em particular, do seu objectivo. Se este se modificar, altera-se também a população e, portanto, o conjunto de amostras que a partir desta podem ser obtidas.

Exemplo 1.5

Voltando ao Exemplo 1.2, se o objectivo da análise for alargado ao conjunto de todos os profissionais liberais portugueses (sejam eles clientes do banco ou não), à população anteriormente definida (ver Exemplo 1.3) devem ser acrescentados os saldos das contas à ordem de todos os profissionais liberais que não são clientes do banco. Repare-se que o conjunto de dados que anteriormente constituía a população passa agora a representar uma amostra.

Em terceiro lugar é importante referir que os conceitos de população e de amostra anteriormente apresentados são susceptíveis de ser generalizados. Quando, em vez de se pretender analisar apenas uma característica dos diferentes objectos em causa, interesse estudar simultaneamente várias características, bem como as relações de associação entre elas, cada elemento da população ou da amostra passa a ser constituído por um **vector de dados** (um par ordenado, um terno ordenado, etc.) que expressa um conjunto de características de um objecto. As populações constituídas por vectores ordenados de dados designam-se por **populações conjuntas**.

Exemplo 1.6

Se o objectivo de uma análise for o estudo da altura e do peso dos portugueses adultos, bem como das relações de associação entre estas características, os elementos que integram a população ou qualquer amostra são vectores (pares ordenados) do tipo (altura de um português, peso desse português). Registe-se que na população conjunta constituída por estes pares ordenados há mais informação do que nas duas populações separadas constituídas pelas alturas de todos os portugueses, por um lado, e pelos pesos de todos os portugueses, por outro (estas populações não permitiriam pôr em evidência a existência de qualquer relação entre as características altura e peso).

A quarta observação tem que ver com as dimensões das populações, que podem ser finitas ou infinitas. É de registar que, frequentemente, as populações finitas têm uma dimensão de tal modo elevada que se torna mais simples analisá-las como infinitas, sem com isso se cometerem erros consideráveis.

Exemplo 1.7

- População finita (susceptível de ser tratada como tal): conjunto das actuais intenções de voto dos eleitores de uma pequena freguesia rural para as próximas eleições autárquicas.
- População finita (susceptível de ser tratada como infinita): conjunto das actuais alturas das portuguesas adultas.
- População infinita: conjunto das pressões atmosféricas que se verificam num determinado momento à superfície da Terra.

O último comentário prende-se com as razões que podem contribuir para não se analisarem todos os elementos de uma população e se procurem inferir as características desta a partir de uma amostra. Entre tais razões figuram as seguintes:

- População infinita (por definição, não pode ser analisada na íntegra);
- Custo excessivo do processo de recolha e tratamento dos dados, como resultado da grande dimensão da população ou da complexidade do processo de caracterização de cada um dos seus elementos;
- Tempo excessivo do processo de recolha e tratamento dos dados, podendo conduzir à obtenção de informação desactualizada (porque a população se altera) ou obsoleta (por levar a que se exceda o prazo dentro do qual a informação é útil);
- Recolha de informação através de métodos destrutivos (que, se aplicada exhaustivamente, conduziria à destruição completa da população);
- Inacessibilidade a alguns dos elementos da população, por exemplo por razões de ordem legal.

Exemplo 1.8

- ♦ Caracterização das intenções de voto de uma população constituída por vários milhões de eleitores.
- ♦ Definição das características geológicas do subsolo no fundo do mar.
- ♦ Controle de qualidade num processo de fabrico com um elevado ritmo de produção e envolvendo riscos de rápida desafinação.
- ♦ Verificação das características mecânicas de um lote de perfis de aço laminado, recorrendo a testes destrutivos.
- ♦ Caracterização dos saldos médios das contas à ordem de todos os médicos portugueses.

1.3 FASES DO MÉTODO DE ANÁLISE ESTATÍSTICA

No âmbito da estatística, o método de abordagem dos problemas pode ser decomposto nas cinco fases que seguidamente se enunciam:

- (i) Estabelecimento do objectivo da análise a efectuar (isto é, das questões que se colocam e que se pretendem ver resolvidas) e definição da(s) população(ões) correspondente(s);
- (ii) Concepção de um procedimento adequado para a selecção de uma ou mais amostras;
- (iii) Recolha de dados;
- (iv) Análise dos dados;
- (v) Estabelecimento de inferências acerca da população (com base na informação amostral).

Existe algum artificialismo na tentativa de decompor um processo integrado de análise num conjunto de fases distintas. No entanto, este procedimento tem a vantagem de permitir apresentar de forma mais clara os seus aspectos essenciais.

As interacções que existem entre as diferentes fases impedem, com frequência, que o processo global de análise seja executado de uma forma meramente sequencial (pode suceder, por exemplo, que, depois de se iniciar a recolha de dados, se detectem dificuldades inesperadas que levem a uma redefinição dos processos de amostragem ou até dos objectivos da análise a efectuar). Em condições normais, a ordem pela qual as fases foram apresentadas e serão seguidamente discutidas corresponde àquela pela qual elas habitualmente são iniciadas.

1.3.1 ESTABELECIMENTO DO OBJECTIVO DA ANÁLISE E DEFINIÇÃO DA(S) POPULAÇÃO(ÕES) CORRESPONDENTE(S)

É óbvia a necessidade de encarar esta fase com o máximo rigor, pois dela dependerá a forma como se desenvolverão todos os passos seguintes e, consequentemente, o maior ou menor esforço neles envolvido e a qualidade das conclusões que deles derivam.

Observe-se que ocorrem com frequência situações nas quais há que identificar mais do que uma população. Tal sucederá sempre que se pretender efectuar um estudo comparativo envolvendo diferentes populações.

Exemplo 1.9

Se o objectivo da análise for o de estabelecer uma comparação entre as alturas dos portugueses adultos e as dos suecos adultos, é óbvio que estarão envolvidas duas populações (o conjunto das alturas de uns e o das alturas dos outros).

1.3.2 CONCEPÇÃO DE UM PROCEDIMENTO ADEQUADO PARA A SELECÇÃO DE UMA OU MAIS AMOSTRAS

O processo de selecção de uma amostra a partir de uma população designa-se por **amostragem**.

Para se poderem fazer inferências a partir de uma amostra e medir o rigor de tais inferências, esta deve ser seleccionada de acordo com um processo de **amostragem proba-**

bilística. Para este tipo de amostragem, cada um dos elementos da população tem hipóteses de ser incluído na amostra, sendo possível medir com rigor qual a possibilidade de tal suceder, através do cálculo da respectiva probabilidade.

De todos os processos de amostragem probabilística, o mais importante é o de **amostragem aleatória**. Este processo garante que todos os elementos da população têm as mesmas hipóteses de ser integrados na amostra. Através dele, consegue evitar-se qualquer **enviesamento de selecção**, isto é, afasta-se qualquer tendência sistemática para sub-representar ou sobre-representar na amostra alguns elementos da população. Seguidamente ilustra-se este tipo de enviesamento, recorrendo a alguns exemplos.

Exemplo 1.10

- ♦ **População:** intenções de voto dos eleitores de uma cidade.
Amostra: intenções de voto de um grupo de eleitores seleccionados ao acaso a partir da lista telefónica correspondente.
Enviesamento de selecção: sub-representação das intenções de voto dos eleitores pertencentes aos estratos económicos mais baixos.
- ♦ **População:** opiniões dos telespectadores sobre um filme erótico exibido num canal de televisão.
Amostra: opiniões expressas por telespectadores que telefonaram para a estação emissora.
Enviesamento de selecção: sobre-representação das opiniões de telespectadores integrados em grupos de pressão autodenominados «defensores dos bons costumes».
- ♦ **População:** atitudes de clientes de supermercados face a um novo detergente.
Amostra: atitudes recolhidas por entrevistadores à porta de supermercados.
Enviesamento de selecção: sobre-representação de pessoas com boa aparência.

Quando não haja preocupações de rigor na representatividade da amostra (por exemplo, na realização de estudos piloto ou de análises preliminares), podem utilizar-se processos de **amostragem não-probabilística**, que não permitem definir com rigor as probabilidades de inclusão dos diferentes elementos da população na amostra. Entre estes processos, que são mais expeditos e mais económicos do que os anteriores, figuram os seguintes:

(i) Amostragem por conveniência

Como o nome sugere, a conveniência para o analista é o critério que essencialmente preside à escolha dos elementos da amostra.

Exemplo 1.11

Teste da aceitabilidade de uma nova cerveja pelos consumidores, efectuado com base nas opiniões recolhidas entre um conjunto de empregados da empresa cervejeira, seleccionados ao acaso.

(ii) Amostragem subjectiva

Os elementos da amostra são seleccionados pelo analista, com base num critério pessoal (eminentemente subjectivo) de representatividade.

Exemplo 1.12

- ♦ Análise da clareza de um texto didático, com base na opinião de um conjunto de alunos que o autor julga serem típicos da população estudantil à qual se dirige.
- ♦ Análise da reacção dos consumidores a um anúncio polémico, envolvendo um padre e uma freira, com base numa amostra constituída por 50 católicos praticantes, 50 católicos não-praticantes, 50 praticantes de outras religiões e 50 elementos noutras condições.

A propósito deste tipo de processos de amostragem, vale a pena referir que existem técnicas híbridas. Assim, se no Exemplo 1.11 os empregados da empresa cervejeira fossem escolhidos pelo analista segundo um critério pessoal de representatividade dos consumidores, a amostragem teria sido efectuada subjectivamente e por conveniência.

1.3.3 RECOLHA DE DADOS

Os dados, que constituem a matéria-prima de qualquer análise estatística, podem ser recolhidos a partir de diferentes fontes.

Se forem obtidos directamente pelo analista ou pela sua organização, os dados dizem-se **primários**. Estão neste caso os dados incluídos nos sistemas de informação das organizações ou aqueles que são obtidos propositadamente para a análise estatística em causa.

Se os dados forem compilados ou publicados por outra organização, dizem-se **secundários**. Incluem-se neste caso os dados obtidos a partir de:

- Agências governamentais (que publicam os mais diversos tipos de estatísticas, por exemplo, relativas a variáveis macroeconómicas relacionadas com a produção, o comércio, o emprego, etc.);
- Associações empresariais ou sindicatos (que frequentemente dispõem de estatísticas relativas ao número e dimensão das empresas do seu sector, à sua rentabilidade, aos níveis salariais por elas praticados ou à distribuição dos empregados por diferentes níveis de qualificação profissional), ou
- Empresas especializadas em estudos de mercado (que vendem, por exemplo, dados obtidos regularmente sobre quotas de mercado de diferentes marcas, para vários tipos de produtos de consumo).

Os sistemas de informação internos das organizações e as publicações que se encontrem disponíveis para utilização pública são, evidentemente, as fontes mais económicas. No caso de se recorrer a tais fontes, há que estar atento ao significado dos dados, à forma como foram recolhidos e aos tipos de erros que potencialmente os afectam. É particularmente importante verificar se, durante o período ao qual os dados se referem, houve alterações na sua definição ou nos métodos utilizados na sua recolha. No caso afirmativo, haverá que verificar se é necessário ou se é possível corrigi-los, antes de os utilizar. Sem estes cuidados, corre-se o risco de cometer erros susceptíveis de pôr em causa toda a análise estatística subsequente.

A recolha de dados pode ser realizada recorrendo a processos que se podem classificar em **experimentais** ou **observacionais**.

Nos processos experimentais exerce-se um controle directo sobre os factores que potencialmente afectam a característica ou o conjunto de características em análise. O objectivo é o de pôr em evidência a influência exercida por aqueles factores, isolada ou conjuntamente.

Exemplo 1.13

- Para estudar o efeito poluente de uma fábrica sobre a água do rio no qual são descarregados os seus efluentes, foram efectuadas medições da quantidade de oxigénio dissolvido na água, para um conjunto de amostras recolhidas a jusante da fábrica. Metade das amostras foi recolhida no fim de um dia em que a fábrica laborou; e a outra metade, no fim de um dia em que a fábrica se encontrou encerrada.
- Para verificar se existem diferenças significativas entre os resultados produzidos pelos medidores-orçamentistas de uma empresa de construção civil, o director do departamento respectivo seleccionou 4 projectos e pediu a todos os medidores que estimassem, independentemente uns dos outros, os custos correspondentes.
- Uma empresa produtora de aglomerados de madeira decidiu analisar o efeito de três tipos de resina e de dois tipos de madeira na resistência de placas de aglomerado de determinadas dimensões. Com esse objectivo, decidiu medir, para cada combinação resina-madeira, a resistência de 15 placas.

Nos processos observacionais, os factores que potencialmente afectam a característica ou o conjunto de características em análise não são controlados.

Exemplo 1.14

- No âmbito de um estudo de tráfego num túnel rodoviário, procurou analisar-se a relação entre a densidade de tráfego no túnel e a velocidade média de circulação. O estudo foi efectuado com base num conjunto de medições simultâneas incidindo sobre valores da densidade e da velocidade observados ao longo de um mês.

- Numa determinada cidade efectuou-se um estudo baseado numa amostra de 1000 pessoas, no qual se obteve informação sobre a frequência com que tomavam café ao longo do dia e sobre certos factores que podiam explicar este hábito (incluindo a idade, o rendimento e o tipo de actividade).

Os processos experimentais são potencialmente mais reveladores da influência que certos factores exercem sobre uma ou mais características que são objecto de análise.

No entanto, a maioria das análises estatísticas efectuadas no âmbito da gestão de empresas, da economia ou das ciências sociais baseia-se em processos observacionais. São duas as razões fundamentais para que tal suceda. Por um lado, a generalidade dos dados mais acessíveis — quer os que provêm dos sistemas de informação internos das organizações, quer os incluídos em fontes que se encontram disponíveis para utilização pública — é de natureza observacional. Por outro lado, quando haja que proceder à recolha de dados propositadamente para uma análise estatística, o facto de se lidar com pessoas ou organizações levanta frequentemente dificuldades de natureza ética ou financeira à adopção de processos experimentais.

Para concluir a análise desta fase do método, serão seguidamente referidos os dois procedimentos que mais frequentemente são utilizados na aquisição de dados primários: **observação** e **questionário**.

No âmbito da observação incluem-se os procedimentos que envolvem um exame directo e o posterior registo de características dos factos ou processos que são objecto de análise.

Exemplo 1.15

- Leitura regular e registo da temperatura ambiente em diferentes divisões de um edifício.
- Contagem e registo do número de veículos que circulam por determinada via pública, a diferentes horas do dia.
- Apuramento diário e registo das vendas de diferentes produtos.

Os processos de observação não podem ser utilizados quando as características que são objecto de análise não sejam passíveis de um exame directo. Tal sucede, por exemplo, quando haja que recolher opiniões ou caracterizar certos comportamentos de pessoas. Neste tipo de situações, a aquisição de dados pode ser efectuada formulando questionários, que frequentemente servem de suporte a entrevistas directas ou por telefone, ou que, em alternativa, são enviados por correio.

Exemplo 1.16

- Recolha de dados relativos aos planos de investimento de empresas de um determinado sector, através da realização de entrevistas aos seus directores-gerais.
- Sondagem de opinião acerca das intenções de voto relativas a uma eleição, realizada por entrevista telefónica a um conjunto de eleitores.
- Recolha de opiniões sobre um plano de actividades proposto pela direcção de um clube, através de um questionário enviado por correio aos sócios.

As entrevistas, sobretudo aquelas que forem efectuadas directamente, permitem colocar questões mais complexas do que as que podem ser incluídas num questionário a enviar pelo correio. Os custos de realização de entrevistas são, no entanto, mais elevados do que a expedição e recolha de questionários por correio. O grande inconveniente destes reside na baixíssima taxa de resposta que geralmente se obtém dos inquiridos.

1.3.4 ANÁLISE DOS DADOS

Nesta fase recorre-se às técnicas de estatística descritiva, com o objectivo fundamental, já enunciado anteriormente, de sintetizar a informação contida nos dados. Tais técnicas serão objecto de análise no próximo capítulo.

Deve referir-se que, com frequência, uma das consequências importantes deste esforço de síntese é a detecção de erros no processo de recolha dos dados.

Exemplo 1.17

Para controlar a eficiência de certos processos químicos, recorre-se ao estabelecimento de balanços mássicos. O objectivo é o de saber, através de leituras efectuadas regularmente, quais as quantidades dos diferentes produtos envolvidos que circulam ou que se acumulam em diferentes locais da instalação. A compatibilidade dos dados recolhidos pode ser analisada tendo em conta que no processo químico global não se cria nem desaparece massa. Frequentemente, tal análise revela inconsistências que permitem detectar erros de leitura em certos instrumentos de medida.

1.3.5 ESTABELECIMENTO DE INFERÊNCIAS ACERCA DA(S) POPULAÇÃO(ÕES)

Esta fase envolve um procedimento de tipo **indutivo**: com base na informação contida numa ou em mais amostras, pretendem retirar-se conclusões relativas a uma ou mais populações.

Exemplo 1.18

- ♦ A partir de uma amostra aleatória constituída pelas alturas de 120 portugueses adultos do sexo masculino, pretende-se estimar qual a proporção de alturas de indivíduos naquelas condições que têm um valor superior a 1.70 m.
- ♦ A partir de duas amostras de dimensão 300, constituídas por peças do mesmo tipo fabricadas por duas máquinas diferentes, pretende-se verificar se a proporção de peças defeituosas produzidas pelas duas máquinas é, a longo prazo, idêntica.
- ♦ A partir das respostas a um inquérito efectuado a 150 consumidores nacionais, procura-se verificar se, entre os portugueses adultos, existe qualquer relação tendencial entre o seu rendimento e os seus hábitos de consumo de certos produtos.



Dada a natureza deste processo, as conclusões que se podem obter relativamente às populações não são passíveis de se classificar dicotomicamente como verdadeiras ou falsas. Em vez disso, a tais conclusões pode associar-se um grau de credibilidade maior ou menor.

Exemplo 1.19

Com base num estudo de mercado, estima-se que um determinado produto atingirá, no próximo ano, uma quota de 35% do mercado nacional. Não faz sentido perguntar se esta estimativa será verdadeira ou falsa. Interessará é saber qual o rigor e a credibilidade que se lhe devem atribuir. Por exemplo, para dimensionar a capacidade de produção para o próximo ano, será razoável admitir como praticamente certo que a quota de mercado se situará entre 33% e 37%? Ou dever-se-á ser mais cauteloso, alargando aquele intervalo?

Talvez o contributo mais importante dado pela estatística para a realização de inferências seja justamente o de permitir medir a confiança nas conclusões relativas às populações, obtidas a partir das amostras.

O processo indutivo «amostra → população» só será realizável nas melhores condições se for precedido por um outro, de natureza **dedutiva**. Este processo dedutivo, que se fundamenta na **teoria das probabilidades**, permite caracterizar o comportamento de amostras a partir do conhecimento das populações de origem. Na Figura 1.3 apresenta-se o ciclo constituído pelos percursos dedutivo e indutivo que têm de ser seguidos por esta ordem na aprendizagem da estatística.



Estatística Descritiva

2.1 INTRODUÇÃO

O objectivo da estatística descritiva, já identificado anteriormente, é o de representar de uma forma compreensível a informação contida em dados. A necessidade de um esforço de classificação destes e de síntese da informação neles contida resulta da incapacidade que, normalmente, a mente humana tem de assimilar e interpretar conjuntos significativos de dados que lhe sejam apresentados de uma forma desorganizada.

O conjunto de dados que interessa analisar raramente corresponde a uma população. Normalmente, não se dispõe senão de uma amostra, na maioria dos casos muito limitada. Ao longo deste capítulo, admitir-se-á que os dados a representar constituem uma amostra (que, no limite, pode coincidir com a população).

A forma de representar a informação contida numa amostra depende, antes do mais, da escala na qual são expressos os dados que a integram. Por esta razão, antes de analisar as técnicas de estatística descritiva mais frequentemente utilizadas, apresentar-se-á uma classificação dos dados segundo a sua escala.

2.2 CLASSIFICAÇÃO DOS DADOS SEGUNDO A ESCALA EM QUE SÃO EXPRESSOS

Os dados podem ser expressos em quatro escalas distintas: **nominal**, **ordinal**, **de intervalo** e **absoluta**. Os dados expressos numa das duas primeiras escalas dizem-se **qualitativos**, enquanto que os que forem expressos numa das duas últimas se dizem **quantitativos**.

2.2.1 DADOS QUALITATIVOS: ESCALA NOMINAL E ESCALA ORDINAL

Os dados dizem-se expressos numa escala **nominal** quando cada um deles for identificado apenas pela atribuição de um nome que designa uma classe. As classes devem ser exaustivas (qualquer dado pertence a uma das classes), mutuamente exclusivas (cada dado pertence a uma só classe) e não ordenáveis (não existe nenhum critério relevante que permita estabelecer preferência por qualquer classe em relação às restantes).

Figura 1.3
Os percursos
dedutivo e indutivo
da estatística.

Exemplo 2.1

Nominal

- ♦ Classificação de pessoas pela cor do cabelo: preto, castanho, branco, loiro, etc.
- ♦ Classificação dos consumidores de bens de primeira necessidade pelo sexo: feminino ou masculino.

Em relação aos dados expressos numa escala nominal, deve observar-se que as classes podem ser designadas, em particular, por números. Neste caso, para que a escala seja nominal, não se poderá estabelecer qualquer relação de ordem entre tais números.

Exemplo 2.2

Nominal

- ♦ Classificação dos consumidores pelo género, no âmbito de um programa de computador: 0 (feminino) ou 1 (masculino).

Aquilo que distingue a **escala ordinal** da escala nominal é a possibilidade de se estabelecer uma ordenação das classes nas quais os dados são classificados, segundo algum critério relevante.

Exemplo 2.3

Ordinal

- ♦ Classificações obtidas pelos alunos num teste de Estatística: mau, medíocre, suficiente, bom ou muito bom.
- ♦ Classificação dos clientes segundo o volume de encomendas que colocam: clientes A (muito importantes), B (importantes) ou C (menos importantes).

■ 2.2.2 DADOS QUANTITATIVOS: ESCALA DE INTERVALO E ESCALA ABSOLUTA

No caso da **escala de intervalo**, os dados são diferenciados e ordenados por números expressos numa escala cuja origem é arbitrária. Neste caso pode-se atribuir um significado à diferença entre esses números, mas não à razão entre eles.

Exemplo 2.4

Temperaturas registadas, em °C, às 8 horas de dias sucessivos. Note-se que, neste caso, se em três dias consecutivos a temperatura atingir 5°C, 10°C e 20°C, não faz sentido dizer-se que no terceiro dia esteve duas vezes mais quente do que no segundo. De facto, se a temperatura fosse expressa noutra escala, a razão entre as temperaturas registadas naqueles dias seria diferente (por exemplo, na escala Fahrenheit, aquela razão seria $68/50 = 1.36$). Já em relação à variação de temperatura entre o segundo e o terceiro dia se pode afirmar, qualquer que seja a escala de temperaturas, que foi dupla da variação de temperatura entre o primeiro e o segundo dia.

Contrariamente ao que sucede com a escala de intervalo, a **escala absoluta** tem uma origem fixa. Nesta escala, zero significa nada (note-se que, anteriormente, dizer que a temperatura era 0°C não significava que não havia temperatura). Como consequência do facto de a origem ser fixa, a razão entre dados expressos numa escala absoluta passa a ter significado, tal como sucede com o intervalo entre tais dados.

Exemplo 2.5

- ♦ Pesos de pessoas, expressos em kg.
- ♦ Volumes de investimento, expressos em milhares de euros.

Entre os dados quantitativos, sejam eles expressos em escalas de intervalo ou absolutas, é conveniente fazer desde já uma distinção relativamente ao conjunto de valores que eles podem tomar. Para o efeito, considerem-se as populações descritas no Exemplo 2.6.

Exemplo 2.6

- ♦ Resultados de 150 lançamentos de um dado.
- ♦ Distâncias a percorrer diariamente por um vendedor no próximo mês, expressas em km.

No primeiro caso, os dados amostrais podem tomar valores pertencentes ao conjunto finito $\{1, 2, \dots, 6\}$. Neste caso, diz-se que os dados são **discretos** ou, melhor ainda, são realizações de uma **variável aleatória discreta** (mais adiante voltar-se-á a esta questão e precisar-se-á o conceito de variável aleatória).

No segundo caso, se se admitir que as distâncias podem ser medidas com precisão absoluta, então entre duas quaisquer distâncias pode sempre definir-se uma outra distância. Nesta situação, diz-se que os dados são **contínuos** ou são realizações de uma **variável aleatória contínua**.

Note-se que, na realidade, as distâncias não podem ser medidas com precisão absoluta: nos automóveis, a distância mínima que é medida é, em geral, o hectómetro. Neste caso, apesar de o conjunto de valores que os dados podem tomar passar a ser discreto, o número de elementos deste conjunto é de tal forma elevado que é mais cómodo considerar os dados como contínuos.

■ 2.2.3 COMPARAÇÃO ENTRE AS DIFERENTES ESCALAS

As diferentes escalas foram apresentadas por uma ordem que traduz um grau crescente de conhecimento dos atributos a que os dados se referem ou, por outras palavras, um crescente «nível de medida». Por este motivo, os dados expressos numa determinada escala podem ser convertidos em dados expressos em qualquer das escalas que a precedam. Como é óbvio, a transformação no sentido inverso não é possível.

Exemplo 2.7


Se se dispuser das temperaturas máximas diárias, em °C, registadas na cidade de Faro ao longo do último ano, é possível reclassificar estes dados, por exemplo, nas classes seguintes:

- ♦ Dias frios (com temperatura máxima inferior a 18°C);
- ♦ Dias amenos (com temperatura máxima entre 18°C e 25°C);
- ♦ Dias quentes (com temperatura máxima acima de 25°C).

Este exemplo ilustra a passagem de uma escala de intervalo para uma escala ordinal. Como é manifesto, se os dados estivessem originalmente expressos na escala ordinal (dias frios, amenos ou quentes) não seria possível exprimi-los na escala de intervalo (°C), por falta de informação.

Na Figura 2.1 comparam-se os níveis de medida das diferentes escalas e resumem-se as suas características fundamentais.

Figura 2.1
Comparação entre
diferentes escalas.



■ 2.3 CARACTERIZAÇÃO DE AMOSTRAS UNIVARIADAS

Uma amostra diz-se **univariada** quando cada um dos dados que a integram mede, numa escala qualquer, apenas um atributo.

Na caracterização de amostras univariadas, considerar-se-á primeiro o caso em que os dados são qualitativos, passando-se depois ao caso dos dados quantitativos.

■ 2.3.1 DADOS QUALITATIVOS

As formas mais comuns de descrever amostras univariadas com dados expressos nas escalas **nominal** ou **ordinal** envolvem o recurso a **tabelas de frequências**, a **diagramas de barras** ou a **diagramas circulares**. Em todos os casos, o objectivo é o de representar a forma como os dados se distribuem por um conjunto de diferentes categorias.

O número de dados contidos numa categoria qualquer k ($k = 1, \dots, K$) designa-se por **frequência absoluta** da categoria k . Denotando por N_k tal frequência e admitindo que as categorias especificadas contêm todos os dados, o número total destes vem dado por

$$N = \sum_{k=1}^K N_k.$$

O número de dados que pertencem a uma categoria qualquer k , quando expresso como uma proporção do número total de dados, designa-se por **frequência relativa** da categoria, e é dada por

Calculo da frequência relativa

$$f_k = \frac{N_k}{N}. \quad (2.1)$$

As frequências relativas são muitas vezes definidas em termos percentuais. Tais frequências serão denotadas por

$$f'_k = 100 \cdot f_k.$$

A descrição de dados qualitativos através de tabelas de frequências, diagramas de barras ou diagramas circulares será ilustrada recorrendo ao exemplo seguinte.

Exemplo 2.8

Numa amostra constituída por 120 peças, constatou-se que 100 não tinham qualquer defeito, 15 tinham defeitos mas eram recuperáveis e 5 eram irreparáveis (isto é, constituíam sucata).

Na Tabela 2.1 representam-se as frequências (absolutas e relativas) dos dados que constituem esta amostra. O diagrama de barras e o diagrama circular, que constituem formas alternativas de representação gráfica dos dados, incluem-se na Figura 2.2.

Tabela 2.1
Representação tabular de amostras univariadas constituídas por dados qualitativos: tabela de frequências relativa ao Exemplo 2.8.

Categorias de peças	Frequência absoluta	Frequência relativa (%)
Sem defeito	100	83.3
Recuperáveis	15	12.5
Sucata	5	4.2
TOTAL	120	100.0

A informação contida na tabela de frequências e nos diagramas — que inclui as diferentes categorias nas quais os dados da amostra foram classificados e as respectivas frequências — designa-se por **distribuição de frequências**, **distribuição empírica** ou **distribuição dos dados amostrais**.

2.3.2 DADOS QUANTITATIVOS

As técnicas utilizadas para descrever amostras univariadas constituídas por dados quantitativos podem ser classificadas em três grupos:

- Formas de representação tabular ou gráfica de dados;
- Estatísticas; e
- Representação gráfica de estatísticas.

Seguidamente analisar-se-á cada um destes tipos de técnicas de representação.


2.3.2.1 FORMAS DE REPRESENTAÇÃO TABULAR OU GRÁFICA

As técnicas utilizadas para representação tabular ou gráfica de dados quantitativos, que são formas alternativas de expressar a mesma informação, serão ilustradas com base no exemplo seguinte.


Figura 2.2

Representação gráfica de amostras univariadas constituídas por dados qualitativos: diagrama de barras e diagrama circular relativos ao Exemplo 2.8.

(i) Diagrama de barras



(ii) Diagrama circular



Exemplo 2.9

Os dados incluídos na Tabela 2.2 representam o peso, expresso em gramas, do conteúdo de uma série de 100 garrafas que, no decurso de um teste, saíram de uma linha de enchimento automático.

Os dados correspondentes a este exemplo encontram-se representados na Tabela 2.3 (**tabela de frequências**) e na Figura 2.3 (**histograma de frequências**, **polígono de frequências** e **polígono de frequências acumuladas**). Em todos os casos, o objectivo é o de representar a forma como os dados se distribuem por um conjunto de diferentes células (ou classes), através da representação das frequências associadas a essas células. Fica assim definida a distribuição de frequências.

Note-se que o histograma e o primeiro polígono de frequências são formas alternativas de representar exactamente a mesma informação: no primeiro caso, a frequência relativa associada a cada célula é representada pela altura da barra correspondente, enquanto que, no segundo, é dada pela ordenada de um ponto cuja abscissa é o ponto médio da célula.

No caso do polígono de frequências acumuladas, representam-se as **frequências relativas acumuladas**, que também foram incluídas na tabela de frequências. Para cada célula k , o valor da frequência relativa acumulada, expressa em termos percentuais (fa'_k) ou como proporção do número total de dados (fa_k), é dado pela expressão seguinte:

$$fa'_k = 100 \cdot fa_k = 100 \cdot \frac{\sum_{i=1}^k N_i}{N} \quad (2.2)$$

onde, de acordo com a notação introduzida na secção anterior, N_i representa o número de dados contidos na célula i e N representa o número total de dados.

Registe-se que, enquanto no diagrama (ii) da Figura 2.3 as frequências relativas (não-acumuladas) se encontram representadas no ponto médio das células respectivas, no dia-

Tabela 2.2
Peso (em gramas)
do conteúdo de
100 garrafas
(Exemplo 2.9).

(1)	302.25	(2)	299.20	(3)	300.24	(4)	297.72
(5)	298.35	(6)	303.76	(7)	298.65	(8)	299.38
(9)	300.36	(10)	299.19	(11)	300.86	(12)	299.83
(13)	302.52	(14)	300.12	(15)	301.81	(16)	297.99
(17)	299.23	(18)	298.73	(19)	303.07	(20)	299.07
(21)	297.83	(22)	299.75	(23)	299.55	(24)	298.76
(25)	301.85	(26)	299.83	(27)	300.52	(28)	298.98
(29)	300.73	(30)	300.14	(31)	298.34	(32)	299.07
(33)	299.62	(34)	299.12	(35)	298.11	(36)	299.48
(37)	302.45	(38)	302.04	(39)	300.83	(40)	298.94
(41)	301.19	(42)	299.70	(43)	302.17	(44)	297.47
(45)	301.11	(46)	298.86	(47)	298.61	(48)	304.22
(49)	299.68	(50)	299.75	(51)	301.99	(52)	302.85
(53)	298.49	(54)	299.60	(55)	299.26	(56)	302.45
(57)	303.66	(58)	302.10	(59)	298.35	(60)	302.83
(61)	299.95	(62)	299.76	(63)	299.13	(64)	299.07
(65)	298.72	(66)	303.49	(67)	298.00	(68)	305.13
(69)	298.56	(70)	301.05	(71)	302.39	(72)	297.84
(73)	299.70	(74)	301.35	(75)	298.85	(76)	300.20
(77)	298.34	(78)	299.70	(79)	298.36	(80)	301.59
(81)	298.07	(82)	298.29	(83)	303.91	(84)	298.16
(85)	297.59	(86)	300.96	(87)	299.08	(88)	300.02
(89)	299.57	(90)	300.84	(91)	299.18	(92)	301.33
(93)	297.87	(94)	301.63	(95)	300.48	(96)	299.16
(97)	298.23	(98)	302.00	(99)	300.86	(100)	300.80

Tabela 2.3
Representação
tabular de amostras
univariadas cons-
tituídas por dados
quantitativos
(contínuos): tabela
de frequências
(Exemplo 2.9).


Célula	Limite inferior	Limite superior	Freq. relativa (%)	Freq. relativa acumulada (%)
1	297.00*	298.00	8	8
2	298.00*	299.00	21	29
3	299.00*	300.00	28	57
4	300.00*	301.00	15	72
5	301.00*	302.00	11	83
6	302.00*	303.00	10	93
7	303.00*	304.00	5	98
8	304.00*	305.00	1	99
9	305.00*	306.00	1	100
TOTAL			100	100

Nota: Na definição de cada célula, convencionou-se excluir o limite inferior (este é o significado que se atribui ao sinal +) e incluir o limite superior.


grama (iii) da mesma figura, as frequências relativas acumuladas são representadas sobre os limites superiores das células. Este procedimento justifica-se pelo facto de tais frequências serem acumuladas justamente até àqueles limites. Ao ligar aquelas frequências relativas acumuladas por segmentos de recta, está-se a fazer uma representação gráfica que presume que, dentro de cada célula, as observações se distribuem com máxima regularidade (isto é, que estão equiespaçadas).

Figura 2.3.
Representação
gráfica de amostras
univariadas
constituídas
por dados quantita-
tivos (contínuos):
histograma
e polígonos de
frequências
(Exemplo 2.9).


(i) Histograma



(ii) Polígono de frequências



(iii) Polígono de frequências acumuladas



Em relação ao processo de construção da tabela e dos diagramas apresentados, é oportuno tecer três comentários.

O primeiro refere-se ao facto de, em cada um deles, todas as células terem sido definidas com igual amplitude. Em condições normais, este procedimento é o mais recomendável, porque é simples e porque facilita a análise dos dados. No entanto, a especificação de células de amplitude variável pode ser vantajosa em situações excepcionais, nas quais as distribuições de frequências apresentem concentrações elevadas em torno de certos valores, apesar de globalmente serem muito dispersas. Nestes casos, a sua representação através de células de amplitude idêntica poderia conduzir ao aparecimento de muitas células contendo poucos ou nenhuns dados e de um número limitado de células contendo muitos dados.

Exemplo 2.10

Com base numa amostra constituída por rendimentos mensais colectáveis de 500 famílias residentes numa determinada cidade, construiu-se a Tabela 2.4.

Tabela 2.4
Tabela de frequências dos rendimentos colectáveis (Exemplo 2.10).


Rendimentos colectáveis (euros · 10 ²)	Frequências relativas (%)
0* - 1500	0.6
1500* - 3000	10.2
3000* - 4500	13.4
4500* - 7500	29.3
7500* - 15000	36.4
15000* - 30000	10.1
TOTAL	100.0

Na Figura 2.4 apresenta-se o histograma construído com células de amplitude variável, iguais às consideradas na Tabela 2.4.

Neste histograma, para se obter uma representação gráfica equivalente à dos histogramas com células de amplitude fixa, a altura de cada barra deixa de ser proporcional à frequência da célula correspondente, passando a ser proporcional à frequência por unidade de amplitude da célula. Por exemplo, a altura da última barra é dada por

$$h = \frac{10.1}{\frac{30\,000 - 15\,000}{1500}} = \frac{10.1}{10} = 1.01.$$

Figura 2.4
Histograma com células de amplitude variável (Exemplo 2.10).



Para ilustrar a razão de ser deste procedimento, considere-se um histograma no qual duas células adjacentes de amplitude idêntica (que se admite ser igual à unidade) têm, tanto uma como a outra, frequências iguais a 10%. As barras correspondentes têm alturas proporcionais às frequências, ou seja a 10%. Se as duas células fossem condensadas numa só, de amplitude igual a duas unidades, esta teria uma frequência de 20%. Para que a representação gráfica não sofresse alterações, haveria que desenhar a barra correspondente com uma altura idêntica às das barras anteriores (proporcional a 10% = 20% ÷ 2) e não proporcional à frequência desta célula agregada (20%).

O segundo comentário relativo à construção da tabela e dos diagramas referentes ao Exemplo 2.9 tem que ver com o número de células neles consideradas. Naturalmente, este número não deve ser tão elevado que se percam os benefícios da síntese: se as células fossem em número excessivo, ocorreriam com frequência casos nos quais o número de observações por célula seria muito escasso ou mesmo nulo, tornando-se difícil perceber a forma como se distribuíam globalmente os dados amostrais. Na situação oposta surgiriam também dificuldades, agora por falta de detalhe na representação.

Uma regra muito utilizada (habitualmente designada por «regra de Sturges») determina que se adopte o número de células (K) de igual amplitude correspondente ao inteiro mais próximo de $1 + 3.3 \cdot \log_{10}(N)$ — em que $\log_{10}(N)$ representa o logaritmo na base 10 do número de observações. Uma regra ainda mais simples (que, no caso de as células terem igual amplitude, conduz a resultados satisfatórios), consiste em cobrir a gama de valores na qual os dados se situam por um número de células próximo da raiz quadrada do número de dados:

$$N.^{\circ} \text{ de células } (K) = \sqrt{N.^{\circ} \text{ de dados } (N)} \quad (\text{células com igual amplitude}) \quad (2.3)$$

Tal como se ilustra seguidamente, esta regra tem um carácter meramente indicativo, devendo ser tomadas em conta as vantagens de ordem prática que advêm da definição de células cujos limites superior e inferior correspondam a números redondos.

Exemplo 2.11

Para o Exemplo 2.9, a amostra contém 100 dados que, quando expressos em gramas, se situam entre os seguintes limites:

$$(\text{Peso})_{\min} = 297.47 \text{ g} \quad \text{e} \quad (\text{Peso})_{\max} = 305.13 \text{ g}.$$

O procedimento adoptado na definição das células consideradas na Tabela 2.3 e na Figura 2.3 foi o seguinte:

- (i) Os limites superior e inferior do intervalo a ser coberto pelo conjunto de células foram fixados em

$$LI = 297.00 \text{ g } (< (\text{Peso})_{\min} = 297.47 \text{ g}) \quad LS = 306.00 \text{ g } (> (\text{Peso})_{\max} = 305.13 \text{ g})$$

A amplitude deste intervalo é

$$LS - LI = 306.00 - 297.00 = 9.00 \text{ g}.$$

- (ii) A regra geral acima enunciada para a definição do número de células conduziria a $\sqrt{100} = 10$ células. No entanto, com o objectivo de definir células com limites superiores e inferiores dados por números redondos, consideraram-se apenas 9 células, todas de igual amplitude ($9.00/9 = 1.00 \text{ g}$).
- (iii) As células foram definidas da forma seguinte:

$$\text{célula 1: } 297.00^* - 298.00 \text{ g}$$

$$\text{célula 2: } 298.00^* - 299.00 \text{ g}$$

(...)

$$\text{célula 9: } 305.00^* - 306.00 \text{ g}.$$

Na definição de cada célula, convencionou-se excluir dela o valor que se apresenta como limite inferior (este é o significado que se atribui ao sinal +) e incluir o limite superior. Numa notação alternativa, as células poderiam ser definidas da forma seguinte: 297.01 – 298.00 g, 298.01 – 299.00 g,...

O último comentário relativo à representação tabular ou gráfica dos dados quantitativos relaciona-se com as implicações que decorrem de eles serem considerados como realizações de variáveis contínuas ou discretas. Para ilustrar tais implicações, considere-se o seguinte exemplo.

Exemplo 2.12

No âmbito de um estudo realizado com o objectivo de caracterizar o comportamento dos clientes de um hipermercado, analisou-se o número de ocupantes por veículo para 1000 veículos que entraram no parque automóvel do referido hipermercado, num sábado. Os resultados encontram-se resumidos na Tabela 2.5.


É óbvio que, neste exemplo, os dados correspondem a realizações de uma variável discreta. Por esta razão e porque é muito limitado o conjunto de valores que os dados

Tabela 2.5
Tabela de frequências
do número de
ocupantes por veículo
(Exemplo 2.12).

N.º de ocupantes por veículo	Frequência absoluta	Frequência relativa (%)
1	103	10.3
2	147	14.7
3	248	24.8
4	197	19.7
5	152	15.2
6	100	10.0
7	53	5.3
TOTAL	1000	100.0

tomam, na tabela de frequências não houve que definir células. A cada valor do número de ocupantes corresponde uma categoria. A forma mais adequada de representar estes dados graficamente é através de um diagrama de barras, tal como o que se representa na Figura 2.5. Repare-se que este diagrama, que é idêntico ao que foi introduzido a propósito de variáveis qualitativas, se distingue de um histograma pelo facto de as barras não se encontrarem justapostas. Pretende-se, deste modo, pôr em evidência a natureza discreta do número de ocupantes por veículo.

Figura 2.5
Diagrama de barras
do número de
ocupantes por
veículo (Exemplo
2.12).



Retome-se agora o Exemplo 2.9, no qual os dados correspondem a pesos expressos em gramas. O facto de cada peso ser expresso por um número com duas casas decimais tem um significado acerca da precisão com que foi medido. Assim, o primeiro dado que figura na Tabela 2.2, 302.25 g, corresponde a um peso que se situa no intervalo situado entre os valores exactos seguintes:

$$302.25 - 0.005 = 302.245 \text{ g} \quad \text{e} \quad 302.25 + 0.005 = 302.255 \text{ g}.$$

Os dados que figuram na Tabela 2.2 podem, tal como os números de ocupantes por veículo, ser considerados como realizações de uma variável discreta, pois só podem tomar valores que constituem um conjunto discreto. De facto, só podem ser iguais a..., 302.23 g, 302.24 g, 302.25 g, 302.26 g, ... e não podem tomar os valores que se situem entre estes (repare-se que os dados podiam ser descritos por números inteiros que resultassem de os multiplicar por 100).

A diferença deste exemplo para o do número de ocupantes por veículo é que o conjunto de valores que os pesos dos conteúdos das garrafas tomam é muito grande. Se se tentassem representar os pesos na forma tabular ou gráfica adoptada para o número de ocupantes/veículo, cada classe (correspondente a um dos pesos..., 302.23 g, 302.24 g, 302.25 g,...) teria uma frequência muito baixa ou mesmo nula. Torna-se assim muito mais claro repre-

sentá-los como se se estes fossem realizações de uma variável contínua, definindo células contínuas justapostas e representando as frequências a elas associadas numa tabela ou num histograma como os apresentados anteriormente.

2.3.2.2 ESTATÍSTICAS

Uma vez discutidos os aspectos essenciais da representação tabular e gráfica de dados quantitativos, passar-se-á à apresentação de uma forma ainda mais sintética de os descrever: através do cálculo de estatísticas.

Tais estatísticas são medidas calculadas com base nos dados, a partir das quais é possível descrever globalmente o conjunto de valores que tais dados tomam. Com o cálculo de estatísticas, pretende-se traduzir em números aquilo que se apreende da observação de uma tabela de frequências ou de um histograma. O objectivo é semelhante ao de descrever a forma de um corpo humano através de um conjunto de quatro medidas: altura, busto, cinta e anca. Dizer, por exemplo, que o corpo de uma mulher tem as medidas 178-86-58-86 (cm) dá uma ideia global, para quem esteja habituado a este tipo de representação, acerca da sua forma (suficientemente segura para se lhe comprar um vestido, por exemplo).

Estatísticas de localização

A mais utilizada das estatísticas de localização é a média aritmética amostral ou, como habitualmente se designa, a **média amostral**. Para uma amostra constituída por N dados x_n ($n = 1, 2, \dots, N$), a média amostral é definida pela expressão

$$\bar{x} = \frac{1}{N} \cdot \sum_{n=1}^N x_n \quad (\text{dados não-agrupados}). \quad (2.4)$$

Exemplo 2.13

Para os dados relativos ao Exemplo 2.9 (incluídos na Tabela 2.2), o valor da média amostral é

$$\bar{x} = \frac{1}{100} \cdot (302.25 + 299.20 + \dots + 300.86 + 300.80) = 300.118 \text{ g}.$$

A média amostral toma um valor que é central em relação aos dados que constituem a amostra. De facto, se se calcularem os desvios dos dados, x_n , em relação à média amostral, verifica-se que os positivos são compensados pelos negativos, sendo nula a sua soma:

$$\sum_{n=1}^N (x_n - \bar{x}) = \sum_{n=1}^N x_n - N \cdot \bar{x} = N \cdot \bar{x} - N \cdot \bar{x} = 0.$$

A média amostral tem uma propriedade que interessa referir desde já. Considere-se a soma dos desvios quadráticos dos dados, x_n , em relação a uma constante qualquer, C :

$$SDQ = \sum_{n=1}^N (x_n - C)^2.$$

O valor de C que minimiza esta soma é justamente a média amostral. Tal pode ser demonstrado muito simplesmente, derivando S em ordem a C e igualando a zero:

$$\frac{dSDQ}{dC} = (-2) \cdot \sum_{n=1}^N (x_n - C) = 0$$

donde

$$N \cdot C = \sum_{n=1}^N x_n$$

ou

$$C = \frac{1}{N} \cdot \sum_{n=1}^N x_n = \bar{x}.$$

Ora, uma vez que, para qualquer valor de C ,

$$\frac{d^2 SDQ}{dC^2} = 2 \cdot N > 0$$

fica demonstrado que $C = \bar{x}$ minimiza a soma dos desvios quadráticos.

Considere-se agora o cálculo da média amostral, tomando o Exemplo 2.12 (Tabela 2.5). Neste caso, em que os 1000 dados que constituem a amostra só tomam os valores 1, 2, ..., 6 ou 7, a média amostral vem dada por

$$\begin{aligned} \bar{x} &= \frac{1}{1000} \cdot (103 \cdot 1 + 147 \cdot 2 + 248 \cdot 3 + 197 \cdot 4 + 152 \cdot 5 + 100 \cdot 6 + 53 \cdot 7) \\ &= 0.103 \cdot 1 + 0.147 \cdot 2 + 0.248 \cdot 3 + 0.197 \cdot 4 + 0.152 \cdot 5 + 0.100 \cdot 6 + 0.053 \cdot 7 \\ &= 3.66. \end{aligned}$$

Note-se que, na expressão que acabou de ser utilizada no cálculo da média amostral, as parcelas correspondem aos produtos dos valores distintos que os dados tomam (x_k , $k = 1, \dots, K$) pelas frequências relativas correspondentes (expressas em proporção do número total de dados). Em geral, quando os dados são agrupados segundo os valores que tomam, a média amostral vem dada por

$$\bar{x} = \sum_{k=1}^K f_k \cdot x_k = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot x_k \quad (\text{dados discretos agrupados}) \quad (2.5)$$

onde f_k e f'_k representam, de acordo com a notação introduzida anteriormente, a frequência relativa de cada valor x_k expressa, respectivamente, como proporção e como percentagem do número total de dados. A média assim calculada é uma **média pesada** dos diferentes valores dos dados (x_k), na qual os pesos são as frequências relativas (expressas como proporções do número total de dados).

Uma variante desta expressão é aplicável ao caso em que os dados são considerados realizações de variáveis contínuas e em que, em vez de serem definidos individualmente, são caracterizados globalmente pelas frequências associadas a diferentes células (de amplitude igual ou variável). Neste caso, a média amostral pode ser calculada aproximadamente, recorrendo à expressão

$$\bar{x} \approx \sum_{k=1}^K f_k \cdot M_k = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot M_k \quad (\text{dados contínuos agrupados}) \quad (2.6)$$

onde f_k e f'_k representam a frequência relativa da célula k , expressa como proporção ou percentagem do número total de dados, e M_k denota o ponto central da célula k .

A aproximação implícita nesta expressão corresponde a admitir que os dados incluídos em cada célula tomam o valor correspondente ao ponto médio dessa célula. Naturalmente, a aproximação será tanto melhor quanto mais pequenas forem as células.

Exemplo 2.14

Cálculo do valor da média amostral com base nos dados relativos ao Exemplo 2.9, agrupados na tabela de frequências (Tabela 2.3):

$$\begin{aligned} \bar{x} &= 0.08 \cdot 297.5 + 0.21 \cdot 298.5 + 0.28 \cdot 299.5 + 0.15 \cdot 300.5 + \\ &\quad + 0.11 \cdot 301.5 + 0.10 \cdot 302.5 + 0.05 \cdot 303.5 + 0.01 \cdot 304.5 + 0.01 \cdot 305.5 \\ &= 300.110 \text{ g.} \end{aligned}$$

Observe-se que este valor é uma excelente aproximação daquele que havia sido obtido a partir dos dados individuais, recorrendo à expressão 2.4 (300.118 g).

Para além da média aritmética amostral, podem definir-se duas outras médias amostrais, de utilização muito mais restrita: a **média geométrica** e a **média harmónica**. A definição e a interpretação do significado destas médias incluem-se no Apêndice 2.1, que se apresenta no final deste capítulo.

Uma medida de localização que constitui uma alternativa à média amostral (aritmética) é a **mediana amostral** (*Med*). Considere-se que os dados que integram uma amostra são colocados por ordem crescente ou decrescente dos seus valores, formando um vector $(x_1, x_2, \dots, x_N)$. A mediana amostral é definida nos seguintes termos:

- (i) se o número (N) de dados que constituem a amostra for ímpar, a mediana toma o valor do dado que, naquele vector, ocupa a posição central (isto é, $Med = x_{(N+1)/2}^*$)
- (ii) se o número de dados for par, a mediana toma o valor médio dos dois termos cujas localizações no vector mais se aproximam da posição central (isto é, $Med = (x_{N/2}^* + x_{N/2+1}^*)/2$).

Exemplo 2.15

Cálculo da mediana da amostra constituída pelos dados relativos ao Exemplo 2.9 (incluídos na Tabela 2.2).

Na Tabela 2.6 apresenta-se o vector constituído pelos dados colocados por ordem crescente.

Dado que o número de dados da amostra é par, a mediana amostral vem dada por

$$Med = (x_{50}^* + x_{51}^*)/2 = (299.70 + 299.70)/2 = 299.70 \text{ g.}$$

Para conjuntos de dados de dimensão significativa e nos quais os seus valores não se repetam frequentemente (como sucede no Exemplo 2.9), a mediana toma um valor tal que cerca de metade dos dados são maiores do que ela e os restantes são menores.

Tabela 2.6
Vector dos dados correspondentes ao Exemplo 2.9 (colocados por ordem crescente).

(1)	297.47	(2)	297.59	(3)	297.72	(4)	297.83
(5)	297.84	(6)	297.87	(7)	297.99	(8)	298.00
(9)	298.07	(10)	298.11	(11)	298.16	(12)	298.23
(13)	298.29	(14)	298.34	(15)	298.34	(16)	298.35
(17)	298.35	(18)	298.36	(19)	298.49	(20)	298.56
(21)	298.61	(22)	298.65	(23)	298.72	(24)	298.73
(25)	298.76	(26)	298.85	(27)	298.86	(28)	298.94
(29)	298.98	(30)	299.07	(31)	299.07	(32)	299.07
(33)	299.08	(34)	299.12	(35)	299.13	(36)	299.16
(37)	299.18	(38)	299.19	(39)	299.20	(40)	299.23
(41)	299.26	(42)	299.38	(43)	299.48	(44)	299.55
(45)	299.57	(46)	299.60	(47)	299.62	(48)	299.68
(49)	299.70	(50)	299.70	(51)	299.70	(52)	299.75
(53)	299.75	(54)	299.76	(55)	299.83	(56)	299.83
(57)	299.95	(58)	300.02	(59)	300.12	(60)	300.14
(61)	300.20	(62)	300.24	(63)	300.36	(64)	300.48
(65)	300.52	(66)	300.73	(67)	300.80	(68)	300.83
(69)	300.84	(70)	300.86	(71)	300.86	(72)	300.96
(73)	301.05	(74)	301.11	(75)	301.19	(76)	301.33
(77)	301.35	(78)	301.59	(79)	301.63	(80)	301.81
(81)	301.85	(82)	301.99	(83)	302.00	(84)	302.04
(85)	302.10	(86)	302.17	(87)	302.25	(88)	302.39
(89)	302.45	(90)	302.45	(91)	302.52	(92)	302.83
(93)	302.85	(94)	303.07	(95)	303.49	(96)	303.66
(97)	303.76	(98)	303.91	(99)	304.22	(100)	305.13

A mediana amostral tem uma propriedade que interessa referir. Considere-se a soma dos desvios absolutos dos dados x_n em relação a uma constante qualquer C :

$$SDA = \sum_{n=1}^N |x_n - C|$$

O valor de C que minimiza esta soma é a mediana amostral (que assim desempenha em relação a esta soma o papel que a média amostral desempenhava em relação à soma dos desvios quadráticos). A razão de ser desta propriedade fica ilustrada através de um exemplo.

Exemplo 2.16

Considere-se a amostra constituída pelos dados que se apresentam seguidamente, já ordenados:

$$\{2.0 \ 3.2 \ 4.5 \ 4.6 \ 5.6\} \quad (Med = 4.5).$$

Na Tabela 2.7 apresenta-se o cálculo da soma SDA para valores de C situados em torno da mediana amostral.

Tabela 2.7
Cálculo da soma dos desvios absolutos em relação a diferentes valores situados em torno da mediana amostral.

C	SDA
(...)	
4.2	$2.2 + 1.0 + 0.3 + 0.4 + 1.4 = 5.3$
4.3	$2.3 + 1.1 + 0.2 + 0.3 + 1.3 = 5.2$
4.4	$2.4 + 1.2 + 0.1 + 0.2 + 1.2 = 5.1$
4.5 (Med)	$2.5 + 1.3 + 0.0 + 0.1 + 1.1 = 5.0$ (min)
4.6	$2.6 + 1.4 + 0.1 + 0.0 + 1.0 = 5.1$
4.7	$2.7 + 1.5 + 0.2 + 0.1 + 0.9 = 5.4$
4.8	$2.8 + 1.6 + 0.3 + 0.2 + 0.8 = 5.7$
(...)	

Finalmente, em relação à mediana amostral, refira-se a forma como pode ser calculada a partir de dados agrupados. Se estes forem considerados realizações de uma variável discreta, todos os dados individuais são conhecidos e o valor da mediana amostral calcula-se como anteriormente.

Exemplo 2.17

Considere-se o cálculo da mediana amostral relativa ao Exemplo 2.12 (Tabela 2.5). Neste caso, em que o número de dados (1000) é par, verifica-se que os dados que ocupam as posições centrais no vector (x_{500}^* e x_{501}^*) pertencem ambos à classe de 4 ocupantes por veículo. A mediana será então $Med = 4$.

Quando os dados amostrais forem considerados realizações de variáveis contínuas e, em vez de serem definidos individualmente, forem caracterizados pelas frequências associadas a diferentes células (de amplitude igual ou variável), a mediana amostral pode ser definida apenas de uma forma aproximada.

Seja LI o limite inferior da célula mediana (aquela onde as frequências acumuladas passam de um valor inferior a 0.5 para um valor superior a 0.5) e seja Δ a amplitude desta célula (ver Figura 2.6). A mediana amostral pode ser obtida aproximadamente através da expressão


$$Med \approx LI + \frac{0.5 - fa^-}{fa^+ - fa^-} \cdot \Delta = LI + \frac{0.5 - fa^-}{f} \cdot \Delta \quad (2.7)$$

onde

- fa^+ : frequência relativa acumulada correspondente à célula mediana
- fa^- : frequência relativa acumulada correspondente à célula que precede a célula mediana
- f : frequência relativa (não-acumulada) correspondente à célula mediana.

A interpretação gráfica deste cálculo apresenta-se na Figura 2.6. Registe-se que este cálculo presume que as observações incluídas na célula mediana (que se admite serem em número N_{Med}) se distribuem com toda a regularidade ao longo desta célula, localizando-se nas posições definidas por $LI + (j/N_{Med}) \cdot \Delta$ onde $j = 1, 2, \dots, N_{Med}$.

Figura 2.6
Interpretação gráfica da expressão 2.7



Exemplo 2.18

Cálculo do valor da mediana amostral com base nos dados relativos ao Exemplo 2.9, agrupados na tabela de frequências (Tabela 2.3).

A célula $299.00^* - 300.00$ g é a célula mediana, visto que contém os dois termos centrais do vector de dados (x_{50} e x_{51}).

O cálculo aproximado da mediana efectua-se recorrendo à expressão 2.7, onde

$$LI = 299.00 \text{ g} \quad \Delta = 1.00 \text{ g} \quad fa^+ = 0.57 \quad fa^- = 0.29$$

A mediana amostral vem então dada aproximadamente por

$$Med \approx 299.00 + \frac{0.5 - 0.29}{0.57 - 0.29} \cdot 1.00 = 299.75.$$

Observe-se que o valor agora obtido é uma boa aproximação daquele que havia sido calculado a partir dos dados individuais (299.70 g).

A última medida de localização que será referida é a **moda** (Mod). Trata-se de uma medida que indica o valor ou a gama de valores nos quais a concentração dos dados amostrais é máxima.

Quando os dados amostrais forem considerados realizações de uma variável discreta, a moda é o valor dos dados que ocorre com maior frequência. Se houver dois ou mais valores adjacentes para os quais a frequência seja máxima, a moda será a média desses valores.

Exemplo 2.19

Para o Exemplo 2.12 (Tabela 2.5), a moda é $Mod = 3$ (valor que ocorre com mais frequência).

Quando os dados amostrais forem considerados realizações de variáveis contínuas, a definição acima apresentada não faz sentido. De facto, a ocorrência de dados com um valor idêntico é excepcional, sendo o resultado de uma coincidência, associada à incapacidade de medir tais dados com suficiente rigor. Neste caso, a moda é definida, a partir das células

nas quais os dados são agrupados, como o ponto central da célula com maior frequência (a **célula ou classe modal**) ou do conjunto das células com maior frequência, se estas forem adjacentes.

Exemplo 2.20

Para a amostra correspondente ao Exemplo 2.9, com os dados agrupados de acordo com a Tabela 2.3, a célula modal é a que corresponde ao intervalo 299.00* – 300.00 g. De acordo com a definição acima apresentada, a moda é $Mod = 299.50$ g.

Esta definição da moda pode ser ligeiramente refinada, tendo em conta as frequências (absolutas ou relativas) da célula modal (N_{Mod} , f_{Mod} ou f'_{Mod}) e das células que lhe são adjacentes (N_1 , f_1 ou f'_1 para a célula à esquerda e N_2 , f_2 ou f'_2 para a célula à direita). A moda pode então ser definida através da expressão

$$Mod = LI + \frac{d_1}{d_1 + d_2} \cdot \Delta \quad (2.8)$$

onde

LI : limite inferior da célula modal Δ : amplitude da célula modal
 d_1 : $N_{Mod} - N_1$, $f_{Mod} - f_1$ ou $f'_{Mod} - f'_1$ d_2 : $N_{Mod} - N_2$, $f_{Mod} - f_2$ ou $f'_{Mod} - f'_2$

Seguidamente, exemplifica-se este cálculo e apresenta-se, na Figura 2.7, a sua interpretação gráfica.

Exemplo 2.21


Voltando ao Exemplo 2.9, com os dados agrupados de acordo com a Tabela 2.3, tem-se

$$\begin{aligned} LI &= 299.00 \text{ g} & \Delta &= 1.00 \text{ g} \\ d_1 &= 28 - 21 = 7 & d_2 &= 28 - 15 = 13 \end{aligned}$$

donde

$$Mod = 299.00 + \frac{7}{7 + 13} \cdot 1.00 = 299.35 \text{ g.}$$

Figura 2.7
Interpretação gráfica
da expressão 2.8.



Deve observar-se que uma amostra, quer ela seja constituída por dados discretos quer por dados contínuos, pode ter mais do que uma moda. Tal sucederá se houver duas ou mais classes cujas frequências sejam maiores do que as das classes suas vizinhas.

Para finalizar a discussão das estatísticas de localização, apresenta-se, na Figura 2.8, uma comparação entre a média, a mediana e a moda.

No diagrama (i), onde se apresenta um histograma simétrico unimodal (isto é, com uma só moda), as três estatísticas coincidem.

Quando o histograma é assimétrico «à direita» (como o que se representa no diagrama (ii)), a mediana situa-se à direita da moda, pois há mais dados à direita do pico do que à esquerda. No que diz respeito à média, esta situa-se à direita da mediana. Para verificar que assim é, comece-se por se notar que a soma dos desvios dos dados em relação à mediana é maior do que zero, pois há tantos desvios positivos como negativos e, dada a forma do histograma, a média dos desvios positivos é superior, em valor absoluto, à dos desvios negativos. Ora, como aquela soma se anula quando os desvios são calculados em relação à média, esta tem de estar situada à direita da mediana.

Exemplo 2.22

Estas posições relativas da média, da mediana e da moda foram as obtidas para a amostra correspondente ao Exemplo 2.9, que, de acordo com o diagrama (i) de Figura 2.3, tem um histograma assimétrico à direita. De facto, os valores anteriormente obtidos para aquelas estatísticas de localização foram os seguintes:

$Mod = 299.35$ g (valor calculado a partir da expressão 2.8, com base nos dados agrupados de acordo com a Tabela 2.3)


$Med = 299.70$ g (valor calculado a partir dos dados individuais)

$\bar{x} = 300.118$ g (valor calculado a partir dos dados individuais).


Naturalmente, quando o histograma é assimétrico à esquerda, as posições relativas das três estatísticas de localização invertem-se.

Figura 2.8
Comparação entre
a média, a mediana
e a moda.

(i) Histograma simétrico



(ii) Histograma assimétrico à direita



Estatísticas de dispersão

A forma mais elementar de caracterizar a variabilidade dos dados que integram uma amostra consiste em calcular a **amplitude da amostra** (A), que se define como a diferença entre o valor máximo e o valor mínimo dos dados.

Exemplo 2.23

Considerando a amostra correspondente ao Exemplo 2.9, a sua amplitude pode ser calculada a partir dos valores máximo e mínimo dos dados, que podem ser obtidos a partir do vector que se apresentou anteriormente na Tabela 2.6:

$$A = (x_n)_{\max} - (x_n)_{\min} = 305.13 - 297.47 = 7.66 \text{ g.}$$

A amplitude da amostra tem o inconveniente de poder ser afectada por valores atípicos dos dados extremos. Uma estatística do mesmo tipo, na qual tal efeito potencial não se faz sentir é o **intervalo interquartis** (IIQ). Para o definir, comece-se por recordar que a mediana separa o vector de dados em dois conjuntos com o mesmo número de dados. Pelo facto de 50% dos dados terem um valor não superior à mediana, esta recebe a designação de **percentil 50**. Ora, tal como se define o percentil 50, podem definir-se os percentis correspondentes a outras percentagens. Os **quartis** são os percentis 25 (primeiro quartil), 50 (segundo quartil) e 75 (terceiro quartil). O **intervalo interquartis** é o intervalo cujos extremos são o primeiro e o terceiro quartis. A amplitude deste intervalo é designada por **amplitude interquartis** (AIQ).

Exemplo 2.24

Calcule-se o intervalo interquartis e a sua amplitude, para a amostra correspondente ao Exemplo 2.9.

Os quartis podem ser calculados a partir do vector de dados que se apresentou na Tabela 2.6:

$$Q_1 = [298.76 \text{ (25.º dado)} + 298.85 \text{ (26.º dado)}] / 2 = 298.805 \text{ g}$$

$$Q_3 = [301.19 \text{ (75.º dado)} + 301.33 \text{ (76.º dado)}] / 2 = 301.260 \text{ g.}$$

O intervalo interquartis é

$$IIQ = [298.805, 301.260] \text{ (gramas)}$$

e a sua amplitude é

$$AIQ = 301.260 - 298.805 = 2.455 \text{ g.}$$

A dispersão de uma amostra pode também ser medida pelo **desvio absoluto médio amostral** (também designado por **desvio médio amostral**). Esta estatística obtém-se calculando a média dos desvios absolutos dos dados em relação à média amostral. Para um conjunto de N dados, x_n ($n = 1, \dots, N$), o desvio absoluto médio amostral é, de acordo com a notação introduzida anteriormente, dado pelas expressões seguintes:

$$DAM = \frac{1}{N} \cdot \sum_{n=1}^N |x_n - \bar{x}| \quad (\text{dados não-agrupados}) \quad (2.9)$$

$$DAM = \sum_{k=1}^K f_k \cdot |x_k - \bar{x}| = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot |x_k - \bar{x}| \quad (2.10)$$

(dados discretos agrupados)

(recorda-se que, nesta expressão, x_k ($k = 1, \dots, K$) denota os diferentes valores que os dados tomam)

$$DAM \approx \sum_{k=1}^K f_k \cdot |M_k - \bar{x}| \approx \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot |M_k - \bar{x}| \quad (2.11)$$

(dados contínuos agrupados)

(recorda-se que, nesta expressão, M_k denota o ponto central da célula k).

Como resultado da sua definição, o desvio absoluto médio amostral tem a dimensão dos dados a partir dos quais for calculado.

Exemplo 2.25

Para a amostra correspondente ao Exemplo 2.9, na qual os dados são expressos em gramas, o desvio absoluto médio, calculado recorrendo à expressão 2.9, é $DAM = 1.424 \text{ g}$.

Observe-se que, na definição apresentada de desvio absoluto médio amostral, a média amostral foi tomada como referência para o cálculo dos desvios absolutos. Embora seja pouco usual, a mediana pode ser utilizada para este fim, em alternativa à média. Se assim se procedesse, o valor do desvio absoluto médio seria menor, tal como se observou anteriormente, no âmbito da caracterização da mediana.

Conquanto o desvio absoluto médio seja uma medida intuitiva de dispersão, a sua manipulação matemática é complicada, como resultado da dificuldade de diferenciação do valor absoluto de cada desvio (mais adiante, noutro capítulo, ver-se-á o interesse desta operação). Uma estatística de dispersão alternativa, que não apresenta a dificuldade referida, é o **desvio quadrático médio amostral** (DQM). Esta estatística obtém-se calculando a média dos quadrados dos desvios dos diferentes dados em relação à média amostral. Recorrendo à notação anterior, o desvio quadrático médio amostral é dado pelas expressões seguintes:

$$DQM = \frac{1}{N} \cdot \sum_{n=1}^N (x_n - \bar{x})^2 \quad (\text{dados não-agrupados}) \quad (2.12)$$

$$DQM = \sum_{k=1}^K f_k \cdot (x_k - \bar{x})^2 = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (x_k - \bar{x})^2 \quad (2.13)$$

(dados discretos agrupados)

$$DQM = \sum_{k=1}^K f_k \cdot (M_k - \bar{x})^2 \approx \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k - \bar{x})^2 \quad (2.14)$$

(dados contínuos agrupados).

Na expressão 2.14, o valor do desvio quadrático médio amostral é calculado como se os dados incluídos em cada célula coincidissem com o valor central desta. Este procedimento tinha já sido adoptado no cálculo da média amostral e do desvio absoluto médio. Mas se o procedimento não introduz qualquer erro sistemático no cálculo destas estatísticas — pois os desvios introduzidos pelos dados que se situam abaixo do ponto central da célula respectiva tendem a ser compensados por desvios de sinal contrário relativos aos dados que se situam acima daquele ponto —, o mesmo não se passa no cálculo do DQM . Na realidade, o facto de se quadrarem os desvios leva a que a expressão 2.14 tenda a sobreavaliar sistematicamente o DQM .

Exemplo 2.26

Para a amostra correspondente ao Exemplo 2.9, o cálculo do desvio quadrático médio com base nos dados individuais (expressão 2.12) conduz a $DQM = 2.969 \text{ g}^2$.

Efectuando o cálculo com base nos dados agrupados segundo a tabela de frequências (Tabela 2.3), a expressão 2.14 conduz a $DQM = 3.058 \text{ g}^2$.

Quando as células tiverem todas a mesma amplitude (Δ) e para amostras cujos histogramas sejam unimodais, tenham a célula modal relativamente afastada dos valores extremos dos dados e tenham células com frequências progressivamente decrescentes nas caudas (esta forma é genericamente designada por forma de sino), a expressão 2.14 pode ser refinada, por inclusão de um termo negativo que recebe o nome de **correção de Sheppard** (para o desvio quadrático médio):

$$DQM = \sum_{k=1}^K f_k \cdot (M_k - \bar{x})^2 - \frac{\Delta^2}{12} = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k - \bar{x})^2 - \frac{\Delta^2}{12} \quad (2.15)$$

(dados contínuos agrupados).

Exemplo 2.27

Para a amostra correspondente ao Exemplo 2.9, cujo histograma tem forma de sino (de acordo com os termos em que esta foi acima definida), o cálculo do desvio quadrático médio com base na expressão 2.15 conduz a $DQM = 2.975 \text{ g}^2$. Este valor é mais próximo de 2.969 g^2 (o verdadeiro DQM , calculado com base nos dados individuais) do que aquele que tinha sido obtido a partir da expressão 2.14 (3.058 g^2).

O desvio quadrático médio é uma medida adequada para descrever a dispersão de uma amostra (ou de uma população, se se dispuser de todos os dados que a compõem). No entanto, se se pretender fazer uma inferência acerca da variabilidade de uma população de grandes dimensões a partir de uma amostra aleatória limitada, então, por razões que serão apresentadas mais adiante, no capítulo onde se aborda o tema de estimação pontual, é preferível recorrer à **variância amostral**. Nesta estatística, habitualmente denotada por s^2 , a soma dos desvios quadráticos é dividida por $N - 1$ (dimensão da amostra menos uma unidade) e não por N , como sucede no desvio quadrático médio.

De acordo com a notação anteriormente utilizada, a variância amostral é dada pelas expressões seguintes:

$$s^2 = \frac{1}{N-1} \cdot \sum_{n=1}^N (x_n - \bar{x})^2 \quad (\text{dados não-agrupados}) \quad (2.16)$$

$$s^2 = \frac{N}{N-1} \cdot \sum_{k=1}^K f_k \cdot (x_k - \bar{x})^2 = \frac{N}{N-1} \cdot \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (x_k - \bar{x})^2 \quad (2.17)$$

(dados discretos agrupados)

$$s^2 \approx \frac{N}{N-1} \cdot \left[\sum_{k=1}^K f_k \cdot (M_k - \bar{x})^2 - \frac{\Delta^2}{12} \right] \approx \frac{N}{N-1} \cdot \left[\frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k - \bar{x})^2 - \frac{\Delta^2}{12} \right] \quad (2.18)$$

(dados contínuos agrupados).

Dada a relação que existe entre a variância e o desvio quadrático médio,

$$s^2 = \frac{N}{N-1} \cdot DQM$$

é óbvio que a primeira destas estatísticas tem um valor superior ao da segunda, tornando-se a diferença entre elas desprezável para amostras de grande dimensão.

Exemplo 2.28

Para a amostra correspondente ao Exemplo 2.9, constituída por 100 dados, a variância amostral ($s^2 = 2.998 \text{ g}^2$) excede o desvio quadrático médio ($DQM = 2.969 \text{ g}^2$) em apenas 1.01%.

O facto de a dimensão destas medidas de dispersão ser o quadrado da dimensão original dos dados, contribui para dificultar a interpretação dos seus valores.

Em vez de se caracterizar a dispersão dos dados através da variância amostral, recorre-se normalmente à sua raiz quadrada, que se designa por **desvio padrão amostral** (e se denota, naturalmente, por s). Esta estatística, expressa nas mesmas unidades que os dados a partir dos quais é calculada, é interpretável como o valor absoluto de um desvio «típico» dos dados em relação à média amostral. O desvio padrão amostral é diferente do desvio absoluto médio amostral, mas é da mesma ordem de grandeza.

Exemplo 2.29

Para a amostra correspondente ao Exemplo 2.9, na qual os dados eram expressos em gramas, o desvio padrão é $s = 1.731 \text{ g}$ e o desvio absoluto médio, anteriormente apresentado, é $DAM = 1.424 \text{ g}$.

■ Outras estatísticas

A média amostral e o desvio quadrático médio amostral pertencem a uma família de estatísticas que se designam por **momentos amostrais**. Neste conjunto de estatísticas, estabelece-se uma distinção entre os **momentos ordinários** (ou em relação à origem) e os **momentos centrados** (também designados por centrais ou em relação à média).

Para uma amostra constituída pelos dados x_n ($n = 1, \dots, N$), os **momentos ordinários de ordem i** ($i = 1, 2, \dots$) são definidos de acordo com as expressões seguintes:

$$m'_i = \frac{1}{N} \cdot \sum_{n=1}^N (x_n)^i \quad (i = 1, 2, \dots) \quad (\text{dados não-agrupados}) \quad (2.19)$$

$$m'_i = \sum_{k=1}^K f_k \cdot (x_k)^i = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (x_k)^i \quad (i = 1, 2, \dots) \quad (2.20)$$

(dados discretos agrupados)

$$m'_i \approx \sum_{k=1}^K f_k \cdot (M_k)^i \approx \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k)^i \quad (i = 1, 2, \dots) \quad (2.21)$$

(dados contínuos agrupados).

A partir destas expressões e da definição da média amostral, é imediato concluir que esta corresponde ao momento ordinário de primeira ordem:

$$m'_1 = \bar{x}.$$

Por sua vez, os **momentos centrados de ordem i** ($i = 1, 2, \dots$) são definidos de acordo com as expressões seguintes:

$$m_i = \frac{1}{N} \cdot \sum_{n=1}^N (x_n - \bar{x})^i \quad (i = 1, 2, \dots) \quad (\text{dados não-agrupados}) \quad (2.22)$$

$$m_i = \sum_{k=1}^K f_k \cdot (x_k - \bar{x})^i = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (x_k - \bar{x})^i \quad (i = 1, 2, \dots) \quad (2.23)$$

(dados discretos agrupados)

$$m_i \approx \sum_{k=1}^K f_k \cdot (M_k - \bar{x})^i = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k - \bar{x})^i \quad (i = 1, 2, \dots) \quad (2.24)$$

(dados contínuos agrupados).

O momento centrado de primeira ordem é sempre nulo (tal como anteriormente foi verificado, a soma dos desvios dos dados de uma amostra em relação à média amostral é nula) e o momento centrado de segunda ordem é o desvio quadrático médio amostral:

$$m_1 = 0 \quad m_2 = DQM.$$

Relativamente aos momentos amostrais, interessa, desde já, chamar a atenção para a interdependência que existe entre os momentos centrados e os momentos ordinários. Na realidade, qualquer momento centrado de ordem i pode ser expresso em função dos momentos ordinários de ordem não superior a i . Por exemplo, desenvolvendo a expressão 2.22 para o segundo momento centrado, obtém-se

$$\begin{aligned} m_2 &= \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^2 = \frac{1}{N} \cdot \sum_{n=1}^N x_n^2 - 2 \cdot \bar{x} \cdot \frac{1}{N} \cdot \sum_{n=1}^N x_n + \bar{x}^2 \\ &= \frac{1}{N} \cdot \sum_{n=1}^N x_n^2 - 2 \cdot \bar{x} \cdot \bar{x} + \bar{x}^2 = \frac{1}{N} \cdot \sum_{n=1}^N x_n^2 - \bar{x}^2 \end{aligned}$$

ou seja,

$$m_2 = m'_2 - (m'_1)^2. \quad (2.25)$$

Para os momentos centrados de ordem 3 e 4, pode mostrar-se que

$$m_3 = m'_3 - 3 \cdot m'_2 \cdot m'_1 + 2 \cdot (m'_1)^3 \quad \text{e} \quad m_4 = m'_4 - 4 \cdot m'_3 \cdot m'_1 + 6 \cdot m'_2 \cdot (m'_1)^2 - 3 \cdot (m'_1)^4.$$

Tendo em conta estas relações, é fácil concluir que os momentos centrados não contêm mais informação do que a traduzida pelos momentos ordinários. O benefício associado à utilização dos primeiros, designadamente para ordens superiores a 1, resulta da maior facilidade de interpretação do seu significado. Por exemplo, é mais fácil interpretar o des-

vio quadrático médio amostral ($DQM = m_2$) directamente a partir da sua definição do que através do segundo membro da expressão 2.25. No entanto, do ponto de vista do cálculo do DQM , é mais prático recorrer ao segundo membro desta expressão do que fazê-lo directamente a partir da sua definição.

Os momentos podem ser calculados para ordens tão elevadas quanto se deseje. No entanto, na prática, raramente se calculam para ordens superiores a 4, por duas ordens de razões:

- (i) as estatísticas, como forma de caracterização de amostras, só têm interesse na medida em que forem utilizadas com parcimónia, e
- (ii) os momentos (mesmo que centrados) de ordem superior a 4 são extremamente difíceis de interpretar.

O momento centrado de terceira ordem — que corresponde ao **desvio cúbico médio** — pode ser utilizado para medir a assimetria com que os dados de uma amostra se distribuem em torno da média amostral. Em notação simbólica, esta estatística pode ser calculada recorrendo às expressões seguintes:

$$m_3 = \frac{1}{N} \cdot \sum_{n=1}^N (x_n - \bar{x})^3 \quad (\text{dados não-agrupados}) \quad (2.26)$$

$$m_3 = \sum_{k=1}^K f_k \cdot (x_k - \bar{x})^3 = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (x_k - \bar{x})^3 \quad (2.27)$$

(dados discretos agrupados)

$$m_3 \approx \sum_{k=1}^K f_k \cdot (M_k - \bar{x})^3 = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k - \bar{x})^3 \quad (2.28)$$

(dados contínuos agrupados).

Note-se que, na última destas expressões, que permite efectuar o cálculo do desvio cúbico médio a partir de dados agrupados, não se torna necessário introduzir qualquer correcção (a correcção de Sheppard só é útil no cálculo de momentos de ordem par).

Quando os dados se localizarem de uma forma simétrica em relação à média amostral (como no histograma anteriormente apresentado na Figura 2.8(i)), cada desvio cúbico positivo será anulado por um desvio cúbico negativo com igual valor absoluto, e m_3 será nulo.

Quando os dados forem assimétricos à direita (como no histograma anteriormente apresentado no diagrama (ii) da Figura 2.8), a soma dos desvios cúbicos positivos excederá, em valor absoluto, a dos desvios cúbicos negativos e m_3 virá positivo. Naturalmente, quando os dados forem assimétricos à esquerda, o valor desta estatística será negativo.

A estatística m_3 é adequada para descrever a assimetria de uma amostra (ou de uma população, se se dispuser de todos os dados que a compõem). No entanto, se se pretender fazer uma inferência acerca da assimetria de uma população de grandes dimensões a partir de uma amostra aleatória limitada, então, pelas mesmas razões por que o desvio quadrático médio amostral deve ser substituído pela variância amostral, também m_3 deve ser substituído por

$$k_3 = \frac{N^2}{(N-1) \cdot (N-2)} \cdot m_3 \quad (2.29)$$

Registe-se que, para amostras de grande dimensão, as estatísticas k_3 e m_3 praticamente não se distinguem.

Em vez de se adoptar directamente a estatística k_3 como medida de assimetria, é preferível padronizá-la, tornando-a adimensional. O **coeficiente de assimetria amostral** (denotado por g_1) obtém-se dividindo k_3 por uma medida de dispersão com dimensões idênticas às suas (s^3):

$$g_1 = \frac{k_3}{s^3} \quad (2.30)$$

Tal como m_3 ou k_3 , o coeficiente de assimetria será nulo, positivo ou negativo, consoante os dados forem simétricos, assimétricos à direita ou assimétricos à esquerda, respectivamente.

Exemplo 2.30

Para a amostra correspondente ao Exemplo 2.9, o coeficiente de assimetria é $g_1 = 0.729$. Como era de esperar, dada a assimetria à direita dos dados, o seu valor é positivo.

O último dos momentos centrados a que habitualmente se recorre para caracterizar amostras é o momento de quarta ordem, que pode ser calculado recorrendo às expressões seguintes:

$$m_4 = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^4 \quad (\text{dados não-agrupados}) \quad (2.31)$$

$$m_4 = \sum_{k=1}^K f_k \cdot (x_k - \bar{x})^4 = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (x_k - \bar{x})^4 \quad (2.32)$$

(dados discretos agrupados)

$$m_4 \approx \sum_{k=1}^K f_k \cdot (M_k - \bar{x})^4 - CS(m_4) = \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k - \bar{x})^4 - CS(m_4) \quad (2.33)$$


(dados contínuos agrupados)

onde $CS(m_4)$ representa a correcção de Sheppard para o quarto momento. Quando as células tiverem todas a mesma amplitude (Δ) e para amostras cujos histogramas tenham forma de sino, aquela correcção é dada pela seguinte expressão:

$$CS(m_4) = \frac{\Delta^2}{2} \cdot \sum_{k=1}^K f_k \cdot (M_k - \bar{x})^2 - \frac{7 \cdot \Delta^4}{240} = \frac{\Delta^2}{2} \cdot \frac{1}{100} \cdot \sum_{k=1}^K f'_k \cdot (M_k - \bar{x})^2 - \frac{7 \cdot \Delta^4}{240} \quad (2.34)$$

O momento centrado de quarta ordem é mais difícil de interpretar do que os anteriores. O seu valor está associado a uma característica designada por **kurtose**. O significado desta característica pode ser ilustrado através de uma comparação entre os histogramas representados na Figura 2.9, que correspondem a duas amostras simétricas de igual dimensão ($N = 89$), que, tendo iguais medidas de localização e de dispersão, diferem justamente na kurtose. Na amostra com mais elevada kurtose (amostra 1) existe uma maior concentração de dados no centro (isto é, próximo da média) e nas caudas e menor concentração nos intervalos que separam aquelas zonas.

Figura 2.9
Interpretação do
conceito de kurtose.



$$\bar{x}_1 = \bar{x}_2 = 0 \quad s_1 = s_2 = 3.90 \quad (g_1)_1 = (g_1)_2 = 0$$

$$(m_4)_1 = 671.24 > (m_4)_2 = 568.70$$

Em vez de se adoptar directamente o momento m_4 como medida de kurtose, pode recorrer-se a uma estatística que se obtém a partir deste por subtracção do termo $3 \cdot m_2^2$. O significado desta medida de kurtose, definida por

$$m_4 - 3 \cdot m_2^2$$

assenta no facto de existir um tipo de população extremamente importante — a população Normal, que mais adiante será caracterizada — para a qual o momento de quarta ordem é igual a três vezes o quadrado do momento de segunda ordem. Nestas condições, a referida medida pode ser interpretada como uma medida relativa de kurtose: conforme for superior, igual ou inferior a zero, assim traduzirá que a kurtose da amostra a que se refere será superior, igual ou inferior à da população normal que é tomada como referência.

Pelas mesmas razões que levaram a que o desvio quadrático médio amostral e o momento centrado de terceira ordem fossem ajustados quando se pretendia fazer inferências em relação a populações de grandes dimensões a partir de amostras aleatórias limitadas, também esta medida relativa de kurtose deve, neste caso, ser substituída por

$$k_4 = \frac{N^2}{(N-1) \cdot (N-2) \cdot (N-3)} \cdot [(N+1) \cdot m_4 - 3 \cdot (N-1) \cdot m_2^2] = \frac{N^2 \cdot (N+1)}{(N-1) \cdot (N-2) \cdot (N-3)} \cdot m_4 - \frac{3 \cdot (N-1)^2}{(N-2) \cdot (N-3)} \cdot s^4 \quad (2.35)$$

Se, tal como se procedeu em relação à estatística k_3 , se reescalar k_4 , dividindo-a agora por s^4 , obtém-se uma medida adimensional de kurtose, designada por **coeficiente de kurtose amostral** (g_2):

$$g_2 = \frac{k_4}{s^4} = \frac{N^2 \cdot (N+1)}{(N-1) \cdot (N-2) \cdot (N-3)} \cdot \frac{m_4}{s^4} - 3 \cdot \frac{(N-1)^2}{(N-2) \cdot (N-3)} \quad (2.36)$$

É imediato verificar que, para um valor de N (dimensão da amostra) suficientemente grande, o coeficiente de kurtose aproxima-se de

$$(m_4 - 3 \cdot m_2^2) / m_2^2 = m_4 / m_2^2 - 3 \approx (m_4 - 3 \cdot m_2^2) / s^4 = m_4 / s^4 - 3.$$

Exemplo 2.31


Para a amostra correspondente ao Exemplo 2.9, as medidas de kurtose definidas tomam os valores $m_4 - 3 \cdot m_2^2 = -2.058$, $k_4 = -1.648$ e $g_2 = -0.183$. Apesar de a amostra ter dimensão 100, o valor de g_2 ainda se afasta algo de $(m_4 - 3 \cdot m_2^2) / m_2^2 = -0.233$ e de $(m_4 - 3 \cdot m_2^2) / s^4 = -0.229$.

2.3.2.3 REPRESENTAÇÃO GRÁFICA DE ESTATÍSTICAS

Existe uma grande variedade de processos de representação gráfica de estatísticas, cujo objectivo é o de simplificar a sua interpretação. O diagrama mais utilizado para este fim é provavelmente o diagrama do tipo caixa (em inglês, este diagrama designa-se por «box plot» ou «box-and-whisker plot»).

Na Figura 2.10 define-se a variante mais simples deste diagrama. Nele se representam graficamente a mediana, o primeiro quartil, o terceiro quartil e os valores máximo e mínimo dos dados.


Figura 2.10
Diagrama do tipo
caixa.



Exemplo 2.32

Na Figura 2.11 comparam-se, para a amostra relativa ao Exemplo 2.9, o histograma e o diagrama do tipo caixa. O segundo pode ser interpretado como uma vista de cima do primeiro, na qual se assinalam as posições da mediana, do intervalo interquartil e dos valores extremos.

Figura 2.11
Comparação entre
um histograma
e o diagrama do
tipo caixa cor-
respondente
(amostra relativa
ao Exemplo 2.9).



2.4 CARACTERIZAÇÃO DE AMOSTRAS BIVARIADAS

Uma amostra diz-se **bivariada** quando é constituída por pares ordenados de dados. Em cada par ordenado, o primeiro elemento mede um atributo de um dos objectos em análise e o segundo mede outro atributo do mesmo objecto.

Na caracterização de uma amostra bivariada, para além de se poderem analisar separadamente os dados relativos a cada atributo, interessa frequentemente verificar se existe uma relação de associação entre eles e, no caso afirmativo, caracterizar esta relação. Nesta secção são referidos processos de conduzir este tipo de análise, começando-se pelo caso em que os dados são qualitativos e tratando-se depois as situações em que os dados são quantitativos.

2.4.1 DADOS QUALITATIVOS

As formas mais comuns de descrever amostras bivariadas com dados expressos nas escalas nominal ou ordinal envolvem o recurso a **tabelas de informação cruzada** e a **diagramas de barras sobrepostas**. A utilização destas formas de representação será ilustrada considerando o seguinte exemplo.

Exemplo 2.33

Uma empresa é abastecida de um determinado produto por três firmas distribuidoras, A, B e C. Das últimas 65 entregas,

- ♦ 39 foram efectuadas pela firma A, das quais: 21 em perfeitas condições (grau de qualidade 1); 10 em condições aceitáveis (grau de qualidade 2); 8 em más condições (grau de qualidade 3);
- ♦ 18 foram efectuadas pela firma B, das quais: 12 em perfeitas condições (grau de qualidade 1); 4 em condições aceitáveis (grau de qualidade 2); 2 em más condições (grau de qualidade 3);
- ♦ 8 foram efectuadas pela firma C, das quais: 3 em perfeitas condições (grau de qualidade 1); 3 em condições aceitáveis (grau de qualidade 2); 2 em más condições (grau de qualidade 3).

A amostra bivariada correspondente a este exemplo encontra-se caracterizada na tabela de informação cruzada que se apresenta seguidamente (Tabela 2.8).

Tabela 2.8
Tabela de infor-
mação cruzada
distribuidor-
-qualidade
(Exemplo 2.33).

Distribuidor	Qualidade das entregas			Total da linha
	1	2	3	
A	21	10	8	39
	32.3%	15.4%	12.3%	60.0%
	53.8%	25.6%	20.5%	100.0%
	58.3%	58.8%	66.7%	—
B	12	4	2	18
	18.5%	6.2%	3.1%	27.7%
	66.7%	22.2%	11.1%	100.0%
	33.3%	23.5%	16.7%	—
C	3.0	3.0	2.0	8.0
	4.6%	4.6%	3.1%	12.3%
	37.5%	37.5%	25.0%	100.0%
	8.3%	17.6%	16.7%	—
TOTAL DA COLUNA	36	17	12	65
	55.4%	26.2%	18.5%	100.0%
	100.0%	100.0%	100.0%	—

Nota: Em cada célula figuram, de cima para baixo:
— número de observações;
— percentagem do número total de observações;
— percentagem do número de observações da linha;
— percentagem do número de observações da coluna.


A informação contida nesta tabela permite pôr simultaneamente em evidência várias características da amostra, designadamente:

- a importância relativa dos distribuidores (ver «Total da linha»),
- a distribuição do número de entregas por grau de qualidade (ver «Total da coluna»), e
- a qualidade relativa dos distribuidores ou, se se preferir, a relação entre distribuidores e qualidade das entregas (ver, para as diferentes células correspondentes a cada distribuidor e ao «Total da coluna», as percentagens do número de observações da linha).

Vale a pena observar que, normalmente, as tabelas de informação cruzada contêm menos informação do que aquela que foi incluída na Tabela 2.8. Ao reduzir a quantidade de informação, retirando-lhe a parte considerada menos relevante, o propósito é o de facilitar a sua leitura.

Em alternativa à representação tabular, os dados de amostras qualitativas bivariadas podem ser caracterizados recorrendo a diagramas de barras sobrepostas (em inglês, «stack diagrams»), tal como aquele que se representa na Figura 2.12.

Figura 2.12
Diagrama de barras sobrepostas (amostra relativa ao Exemplo 2.33).



2.4.2 DADOS QUANTITATIVOS

A forma mais simples de caracterizar uma amostra bivariada com dados quantitativos e, em particular, de pôr em evidência a relação existente entre os dois atributos que tais dados medem envolve a representação destes num sistema de eixos ortogonais, construindo o que habitualmente se designa por **diagrama (x, y)**. A utilização deste tipo de diagrama será ilustrada considerando o exemplo seguinte.

Exemplo 2.34


Uma empresa coligiu dados relativos à produção de 12 lotes de um tipo especial de rolamento. O volume de produção e o custo de produção de cada lote apresentam-se na Tabela 2.9.

Tabela 2.9
Amostra bivariada: volumes e custos de produção de rolamentos (Exemplo 2.34)

Lote	Volume de produção (unidades)	Custo de produção (euros · 10 ³)
1	1500	3100
2	800	1900
3	2600	4200
4	1000	2300
5	600	1200
6	2800	4900
7	1200	2800
8	900	2100
9	400	1400
10	1300	2400
11	1200	2400
12	2000	3800

Na Figura 2.13 apresenta-se o diagrama (x, y) correspondente a este exemplo. Neste diagrama, é patente que existe uma relação entre volumes e custos de produção. Esta relação, embora não seja perfeita, permite concluir que, como seria de esperar, os custos sobem à medida que os volumes de produção aumentam.

Figura 2.13
Diagrama (x, y) (amostra relativa ao Exemplo 2.34).




O facto de se denotar a ordenada na origem por a' e não por a tem apenas que ver com uma convenção que será introduzida no estudo da técnica de regressão, no Capítulo 14.

A localização desta recta em relação aos pontos que representam os dados, (x_n, y_n) ($n = 1, \dots, N$), fica definida, uma vez fixados os valores dos parâmetros a' e b . Tal como se representa na Figura 2.14, o «erro» associado a cada ponto (x_n, y_n) , isto é, o desvio do ponto em relação à recta, medido na direcção do eixo dos yy, é dado por


$$e_n = y_n - (a' + b \cdot x_n).$$

Figura 2.14
Definição de erro.



O grau de ajuste da recta em relação aos dados pode ser medido em função da magnitude dos erros correspondentes aos diferentes dados. A adopção do erro médio ou da soma dos erros como medida do ajuste global da relação linear não é adequada, tal como se ilustra na Figura 2.15. De facto, embora o grau de ajuste das duas rectas nela representadas seja claramente diferente, o valor do erro médio e da soma dos erros é nulo em ambos os casos (no caso da recta R_1 , porque os erros são todos nulos, e no caso da recta R_2 , porque cada erro positivo é anulado por um erro negativo de igual valor absoluto).

Figura 2.15
Insuficiência da soma dos erros ou do erro médio como medidas do grau de ajuste de uma relação linear.



Para superar esta insuficiência, poderia pensar-se em adoptar como medida de ajuste o erro absoluto médio ou a soma dos erros absolutos: quanto menor forem os seus valores, melhor é o ajuste. Estas medidas têm o inconveniente de a sua manipulação matemática ser complicada, como resultado da dificuldade de diferenciação do valor absoluto de cada erro. Por este motivo e por outros que serão referidos mais adiante, no estudo da análise de regressão, é preferível adoptar como medida de ajuste de uma relação linear a um conjunto de dados a soma dos erros quadráticos ou, de forma equivalente, o erro quadrático médio.

Para a recta considerada na Figura 2.14, a soma dos erros quadráticos é dada pela expressão

$$SEQ = \sum_{n=1}^N e_n^2 = \sum_{n=1}^N (y_n - a' - b \cdot x_n)^2.$$

Se a posição da recta se alterar, como consequência de se modificar algum dos parâmetros a' ou b , também o somatório se alterará. Para um conjunto fixo de dados, o valor deste somatório será então função daqueles parâmetros, facto que pode ser expresso, escrevendo

$$SEQ = SEQ(a', b).$$

De acordo com o método dos mínimos quadrados, a recta que melhor se ajusta aos dados amostrais é justamente aquela que minimiza esta soma. Os seus parâmetros podem ser obtidos, fazendo

$$\frac{\partial SEQ(a', b)}{\partial a'} = (-2) \cdot \sum_{n=1}^N (y_n - a' - b \cdot x_n) = 0$$

e

$$\frac{\partial SEQ(a', b)}{\partial b} = (-2) \cdot \sum_{n=1}^N x_n \cdot (y_n - a' - b \cdot x_n) = 0.$$

É fácil verificar que, por um lado, estas equações conduzem a um mínimo de SEQ e, por outro, são satisfeitas pelos valores de a' e b dados pelas expressões seguintes:

$$a' = \frac{1}{N} \cdot \sum_{n=1}^N y_n - b \cdot \frac{1}{N} \cdot \sum_{n=1}^N x_n = \bar{y} - b \cdot \bar{x} \quad (2.37)$$

e

$$b = \frac{s_{xy}}{s_{xx}} \quad (2.38)$$


onde

$$s_{xy} = \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y}) \quad \text{e} \quad s_{xx} = \sum_{n=1}^N (x_n - \bar{x})^2.$$

Exemplo 2.35

Na Figura 2.16 apresenta-se a recta ajustada aos dados correspondentes ao Exemplo 2.34.

Figura 2.16
Diagrama (x, y) e recta ajustada recorrendo ao método dos mínimos quadrados (amostra relativa ao Exemplo 2.34).



Tal como se sugere nesta figura, a recta ajustada passa sempre pelo ponto $(\bar{x}, \bar{y})$, sejam quais forem os dados. Tal pode ser facilmente verificado, calculando o valor de y que corresponde a $\bar{x}$, quando os parâmetros da recta são definidos pelas expressões 2.37 e 2.38:

$$y = a' + b \cdot \bar{x} = \bar{y} - b \cdot \bar{x} + b \cdot \bar{x} = \bar{y}.$$

Atente-se agora na expressão 2.38, na qual o coeficiente angular da recta é dado pela razão entre dois somatórios, s_{xy} e s_{xx} . Desde que os valores de x_n não sejam todos iguais (esta é a situação que, na prática, interessa considerar), o último destes somatórios, que figura em denominador, é sempre positivo. Nestas condições, o sinal do coeficiente angular da recta ajustada é o mesmo que o do somatório s_{xy} .

A interpretação deste facto é relativamente simples. Na situação a que corresponde a Figura 2.16, em que o coeficiente angular da recta é positivo, o somatório s_{xy} é também positivo, uma vez que, para a maioria dos dados, a cada diferença $(x_n - \bar{x})$ corresponde uma diferença $(y_n - \bar{y})$ com o mesmo sinal, sendo portanto predominantemente positivas as parcelas do somatório.

Exemplo 2.36

Para os dados correspondentes ao Exemplo 2.34, as médias amostrais de x_n (volumes de produção) e y_n (custos de produção) são

$$\bar{x} = 1358 \text{ unidades} \quad \bar{y} = 2708 \text{ euros} \cdot 10^3.$$

O somatório s_{xy} é dado por

$$\begin{aligned} s_{xy} &= (1500 - 1358) \cdot (3100 - 2708) & (+) \cdot (+) \\ &+ (800 - 1358) \cdot (1900 - 2708) & (-) \cdot (-) \\ &+ (2600 - 1358) \cdot (4200 - 2708) & (+) \cdot (+) \\ &+ (1000 - 1358) \cdot (2300 - 2708) & (-) \cdot (-) \\ &+ (600 - 1358) \cdot (1200 - 2708) & (-) \cdot (-) \\ &+ (2800 - 1358) \cdot (4900 - 2708) & (+) \cdot (+) \\ &+ (1200 - 1358) \cdot (2800 - 2708) & (-) \cdot (+) \\ &+ (900 - 1358) \cdot (2100 - 2708) & (-) \cdot (-) \\ &+ (400 - 1358) \cdot (1400 - 2708) & (-) \cdot (-) \\ &+ (1300 - 1358) \cdot (2400 - 2708) & (-) \cdot (-) \\ &+ (1200 - 1358) \cdot (2400 - 2708) & (-) \cdot (-) \\ &+ (2000 - 1358) \cdot (3800 - 2708) & (+) \cdot (+) \\ &= 9.094 \cdot 10^6 \end{aligned}$$

Note-se que, dos 12 produtos cruzados (assim se designam habitualmente os termos do somatório), apenas um é negativo e tem um valor absoluto modesto.

Quando a relação linear tiver um coeficiente angular negativo, as diferenças $(x_n - \bar{x})$ e $(y_n - \bar{y})$ serão normalmente de sinal contrário, e o somatório s_{xy} será negativo. Quando não existir qualquer relação (linear) entre os valores de x_n e y_n , os sinais das diferenças $(x_n - \bar{x})$ e $(y_n - \bar{y})$ serão alternadamente iguais ou opostos, tendo o somatório s_{xy} um valor próximo de zero.

Dividindo o somatório s_{xy} pelo número de parcelas que o compõem, obtém-se uma primeira medida do grau de ajustamento da relação linear aos dados. Esta medida, que se pode designar por **produto cruzado médio**, é dada pela expressão seguinte:

$$\frac{1}{N} \cdot \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y}). \quad (2.39)$$

O produto cruzado médio é uma medida adequada para descrever o grau de relacionamento linear dos dados contidos numa amostra bivariada. No entanto, se se pretender fazer uma inferência acerca da população a partir da qual a amostra provém, então, pelas mesmas razões que o desvio quadrático médio amostral deve ser substituído pela variância amostral, também o produto cruzado médio deve ser substituído pela **covariância amostral**. Nesta estatística, habitualmente denotada por c_{xy} , a soma dos produtos cruzados é dividida por $N - 1$ (número de pares de dados menos uma unidade) e não por N , vindo

$$c_{xy} = \frac{1}{N-1} \cdot \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y}). \quad (2.40)$$

Exemplo 2.37

Para os dados correspondentes ao Exemplo 2.34, a covariância amostral é

$$c_{xy} = 9.094 \cdot 10^6 / (12 - 1) = 0.827 \cdot 10^6 \text{ rolamentos} \cdot \text{euros} \cdot 10^3.$$

A covariância amostral tem, como medida do grau de relacionamento linear entre os dados de uma amostra bivariada, a desvantagem de depender das unidades nas quais os dados são expressos. Para ultrapassar esta insuficiência, pode-se padronizar a covariância amostral, dividindo-a pelo produto dos desvios padrão amostrais das duas variáveis em causa. Obtém-se assim uma medida adimensional que se designa por **coeficiente de correlação amostral**, que se denota por r_{xy} (ou simplesmente por r , quando não houver dúvidas acerca de quais são os dados em causa) e que vem dada pela seguinte expressão:

$$\begin{aligned} r_{xy} &= \frac{c_{xy}}{s_x \cdot s_y} \\ &= \frac{\frac{1}{N-1} \cdot \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y})}{\sqrt{\frac{1}{N-1} \cdot \sum_{n=1}^N (x_n - \bar{x})^2} \cdot \sqrt{\frac{1}{N-1} \cdot \sum_{n=1}^N (y_n - \bar{y})^2}} \\ &= \frac{s_{xy}}{\sqrt{s_{xx} \cdot s_{yy}}}. \end{aligned} \quad (2.41)$$


Exemplo 2.38

Para os dados correspondentes ao Exemplo 2.34, o coeficiente de correlação amostral é

$$r_{xy} = 0.981.$$

Na Figura 2.17 caracterizam-se os valores do coeficiente de correlação amostral para diferentes formas de relacionamento linear entre x_n e y_n .

Figura 2.17
O coeficiente de correlação amostral como medida de ajuste da relação linear entre os dados de uma amostra bivariada.



Comece-se por justificar o valor do coeficiente de correlação amostral nos casos (i) e (v), para os quais a relação linear entre os valores x_n e y_n é perfeita, isto é, na qual

$$y_n = a' + b \cdot x_n$$

para todos os valores de n . Neste caso, os somatórios s_{xy} e s_{yy} vêm dados por

$$s_{xy} = \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y}) = \sum_{n=1}^N (x_n - \bar{x}) \cdot b \cdot (x_n - \bar{x}) = b \cdot s_{xx}$$

e

$$s_{YY} = \sum_{n=1}^N (y_n - \bar{y})^2 = b^2 \cdot \sum_{n=1}^N (x_n - \bar{x})^2 = b^2 \cdot s_{XX},$$

donde

$$r_{XY} = \frac{s_{XY}}{\sqrt{s_{XX} \cdot s_{YY}}} = \frac{b \cdot s_{XX}}{\sqrt{s_{XX} \cdot b^2 \cdot s_{XX}}} = \frac{b \cdot s_{XX}}{|b| \cdot s_{XX}} = \frac{b}{|b|}$$

ou seja,

$$r_{XY} = +1, \text{ se } b > 0 \quad r_{XY} = -1, \text{ se } b < 0.$$

A situação (iii) corresponde à inexistência de qualquer relação linear entre os dados x_n e y_n , uma vez que $s_{XY} = 0$ e, portanto,

$$b = \frac{s_{XY}}{s_{XX}} = 0.$$

Neste caso, o coeficiente de correlação amostral é também nulo:

$$r_{XY} = \frac{s_{XY}}{\sqrt{s_{XX} \cdot s_{YY}}} = 0.$$

Nas situações intermédias (ii) e (iv) (note-se que os dados correspondentes ao Exemplo 2.34 se encontravam na situação (ii)) é difícil atribuir directamente um significado ao valor do coeficiente de correlação amostral. No entanto, existe uma interpretação para o quadrado do seu valor. Para se chegar a esta interpretação, desenvolva-se o somatório s_{YY} conforme seguidamente se apresenta

$$s_{YY} = \sum_{n=1}^N (y_n - \bar{y})^2 = \sum_{n=1}^N [(y_n - \hat{y}_n) + (\hat{y}_n - \bar{y})]^2$$

onde $\hat{y}_n = a' + b \cdot x_n$ representa a ordenada que, na recta ajustada segundo o método dos mínimos quadrados, corresponde à abscissa x_n .

O desenvolvimento do somatório s_{YY} conduz a

$$s_{YY} = \sum_{n=1}^N (y_n - \bar{y})^2 = \sum_{n=1}^N (y_n - \hat{y}_n)^2 + \sum_{n=1}^N (\hat{y}_n - \bar{y})^2 + 2 \cdot \sum_{n=1}^N (y_n - \hat{y}_n) \cdot (\hat{y}_n - \bar{y}).$$

A primeira parcela do segundo membro representa a soma dos erros quadráticos:

$$\sum_{n=1}^N (y_n - \hat{y}_n)^2 = \sum_{n=1}^N (y_n - a' - b \cdot x_n)^2 = \sum_{n=1}^N e_n^2.$$

Tendo em conta que a recta ajustada pelo método dos mínimos quadrados passa pelo ponto $(\bar{x}, \bar{y})$ e que, portanto,

$$\hat{y}_n - \bar{y} = b \cdot (x_n - \bar{x})$$

a segunda parcela pode ser reescrita da forma seguinte:

$$\sum_{n=1}^N (\hat{y}_n - \bar{y})^2 = b^2 \cdot \sum_{n=1}^N (x_n - \bar{x})^2.$$

Do desenvolvimento da terceira parcela resulta:

$$\begin{aligned} 2 \cdot \sum_{n=1}^N (y_n - y_n) \cdot (y_n - \bar{y}) &= 2 \cdot \sum_{n=1}^N (y_n - a' - b \cdot x_n) \cdot b \cdot (x_n - \bar{x}) \\ &= 2 \cdot \sum_{n=1}^N [y_n - (\bar{y} - b \cdot \bar{x}) - b \cdot x_n] \cdot b \cdot (x_n - \bar{x}) \\ &= 2 \cdot b \cdot \sum_{n=1}^N [(y_n - \bar{y}) - b \cdot (x_n - \bar{x})] \cdot (x_n - \bar{x}) \\ &= 2 \cdot b \cdot \left[\sum_{n=1}^N (y_n - \bar{y}) \cdot (x_n - \bar{x}) - b \cdot \sum_{n=1}^N (x_n - \bar{x})^2 \right] \\ &= 2 \cdot b \cdot s_{XY} - 2 \cdot b^2 \cdot s_{XX} \\ &= 2 \cdot \frac{s_{XY}}{s_{XX}} \cdot s_{XY} - 2 \cdot \left(\frac{s_{XY}}{s_{XX}} \right)^2 \cdot s_{XX} \\ &= 0. \end{aligned}$$

O somatório s_{YY} , que reflecte a variação dos dados y_n em torno da sua média amostral, pode então ser expresso como a soma de duas parcelas

$$\sum_{n=1}^N (y_n - \bar{y})^2 = \sum_{n=1}^N e_n^2 + b^2 \cdot \sum_{n=1}^N (x_n - \bar{x})^2. \quad (2.42)$$

A segunda parcela representa a parte da variação dos dados y_n que é explicada pela relação linear (a partir da variação dos dados x_n em torno da média amostral destes), e a primeira representa a parte não explicada. Note-se que, se a relação linear entre os dados x_n e y_n for perfeita, os erros são nulos, e toda a variação entre os dados y_n é explicada pela relação linear (a partir da variação dos dados x_n).

Se se calcular a proporção da variação dos dados y_n que é explicada pela relação linear (a partir da variação dos dados x_n), obtém-se

$$\frac{b^2 \cdot \sum_{n=1}^N (x_n - \bar{x})^2}{\sum_{n=1}^N (y_n - \bar{y})^2} = \frac{\left(\frac{s_{XY}}{s_{XX}} \right)^2 \cdot s_{XX}}{s_{YY}} = \frac{s_{XY}^2}{s_{XX} \cdot s_{YY}} = r_{XY}^2.$$

Desta expressão resulta que o quadrado do coeficiente de correlação amostral representa a proporção da variação dos dados y_n que é explicada pela relação linear, a partir da variação dos dados x_n . O valor de r_{XY}^2 (ou r^2) designa-se por **coeficiente de determinação**.

Esta estatística é adequada para descrever a qualidade de ajuste linear entre os dados de uma amostra bivariada (ou de uma população, se se dispuser de todos os dados que a compõem). No entanto, se se pretender fazer uma inferência relativa à população, a partir de uma amostra limitada, o coeficiente de determinação, que pode ser reescrito da forma seguinte

$$r_{XY}^2 = \frac{b^2 \cdot s_{XX}}{s_{YY}} = \frac{s_{YY} - \sum_{n=1}^N e_n^2}{s_{YY}} = 1 - \frac{\sum_{n=1}^N e_n^2}{s_{YY}}, \quad (2.43)$$

deve ser substituído pelo **coeficiente de determinação corrigido** [denotado por r_{XY}^2 (corrigido)], dado pela expressão seguinte:


$$r_{XY}^2 \text{ (corrigido)} = 1 - \frac{\sum_{n=1}^N e_n^2 / (N-2)}{s_{YY} / (N-1)}. \quad (2.44)$$

Exemplo 2.39

Para os dados correspondentes ao Exemplo 2.34, vem

$$r^2 = 0.981^2 = 0.963 = 96.3\% \quad r^2 \text{ (corrigido)} = 0.959 = 95.9\%.$$

A partir das expressões 2.43 e 2.44 é imediato verificar que, para qualquer amostra bivariada, r^2 (corrigido) é menor do que r^2 e que, quando a dimensão da amostra cresce, r^2 (corrigido) tende para r^2 .



APÊNDICE 2.1 MÉDIA GEOMÉTRICA E MÉDIA HARMÔNICA

Considere-se uma amostra constituída por N dados x_n ($n = 1, \dots, N$).

A **média geométrica amostral (MG)** é a raiz de índice N do produto dos dados. Em notação simbólica, vem

$$MG = \sqrt[N]{x_1 \cdot x_2 \cdots x_N} = (x_1 \cdot x_2 \cdots x_N)^{1/N}. \quad (A2.1.1)$$

A utilidade e o significado da média geométrica podem ser ilustrados através de um exemplo.

Exemplo A2.1.1

Admita-se que, nos últimos 4 anos, o produto interno bruto (PIB) de um determinado país cresceu 2.5%, 1.7%, 2.2% e 3.5%. Se se denotar por PIB_0 o valor do PIB no ano anterior a este período, o seu valor no último ano será dado por

$$PIB_4 = (R_1 \cdot R_2 \cdot R_3 \cdot R_4) \cdot PIB_0$$

onde as razões de crescimento, R_n , são

$$\begin{aligned} R_1 &= 1 + 0.025 & R_2 &= 1 + 0.017 \\ R_3 &= 1 + 0.022 & R_4 &= 1 + 0.035. \end{aligned}$$

Se o crescimento fosse constante nos 4 anos e, globalmente, fosse idêntico ao verificado, a razão (R) entre valores sucessivos do PIB deveria satisfazer a seguinte condição:

$$R^4 = R_1 \cdot R_2 \cdot R_3 \cdot R_4$$

ou

$$R = \sqrt[4]{R_1 \cdot R_2 \cdot R_3 \cdot R_4} = \sqrt[4]{1.025 \cdot 1.017 \cdot 1.022 \cdot 1.035} = 1.0247.$$

O valor de R é a média geométrica das razões de crescimento R_1, R_2, R_3 e R_4 . A partir de $R = 1.0247$ obtém-se a taxa média anual de crescimento do PIB, que é de 2.47%.

A **média harmónica amostral (MH)** é o inverso da média aritmética dos inversos dos dados x_n ($n = 1, \dots, N$). Em notação simbólica, vem

$$MH = \frac{1}{\frac{1}{N} \sum_{n=1}^N \frac{1}{x_n}} = \frac{N}{\sum_{n=1}^N \frac{1}{x_n}}. \quad (A2.1.2)$$

A utilidade e o significado da média harmónica serão seguidamente ilustrados através de um exemplo.

Exemplo A2.1.2

Um empreiteiro dispõe de 4 camiões cuja tarefa consiste em transportar pedra desde uma pedreira até um porto. A pedra destina-se a formar o enrocamento de um molhe em construção. Na Tabela A2.1.1 apresenta-se o número de cargas efectuadas por cada camião num determinado turno de 8 horas e o valor correspondente do tempo médio por carga, expresso em minutos.

Se se pretender calcular, relativamente ao conjunto de 4 camiões, o tempo médio por carga, há vários processos equivalentes de o fazer. O primeiro consiste em calcular o número total de cargas efectuadas (53) e dividir o tempo total disponível de camiões ($4 \cdot 8 = 32$ horas = 1920 minutos) por aquele número: o tempo médio global por carga é então de $1920 / 53 = 36.2$ minutos.

O segundo processo corresponde a calcular a média harmónica dos tempos por carga relativos aos diferentes camiões:

$$MH = \frac{4}{\frac{1}{48} + \frac{1}{30} + \frac{1}{40} + \frac{1}{32}} = 36.2 \text{ minutos.}$$

É fácil mostrar porque é que os dois processos de cálculo são equivalentes. De facto, se o numerador e o denominador da média harmónica forem multiplicados por 480 (minutos), obtém-se:

$$MH = \frac{4 \cdot 480}{\frac{480}{48} + \frac{480}{30} + \frac{480}{40} + \frac{480}{32}}.$$

Nesta fracção, o numerador representa o tempo total disponível de camiões ($4 \cdot 480 = 1920$ minutos). Cada parcela do denominador representa o número de cargas efectuadas por cada camião. Globalmente, o denominador representa o número total de cargas efectuadas pelo conjunto de camiões e a fracção é portanto igual àquela que foi definida no primeiro processo de cálculo.

Tabela A2.1.1
Índices de
produtividade dos
camiões (num turno
de 8 horas)


Camião	N.º de cargas	Tempo médio por carga (min)
1	10	48
2	16	30
3	12	40
4	15	32

Note-se que, se se efectuasse o cálculo da média aritmética dos tempos por carga relativos aos diferentes camiões, obter-se-ia o valor $(48 + 30 + 40 + 32) / 4 = 37.5$ minutos. Este valor não representa o tempo médio global por carga, uma vez que os números de cargas efectuadas pelos camiões são diferentes.

Aquele tempo médio pode calcular-se, por um terceiro processo, como uma média pesada dos tempos médios por carga dos diferentes camiões, na qual os pesos são proporcionais ao número de cargas efectuadas pelos camiões:

$$\frac{10 \cdot 48 + 16 \cdot 30 + 12 \cdot 40 + 15 \cdot 32}{10 + 16 + 12 + 15} = 36.2 \text{ minutos.}$$

De novo, esta fracção é equivalente à utilizada no primeiro processo de cálculo, pois o numerador representa o tempo total disponível de camião e o denominador representa o número total de cargas efectuadas pelos 4 camiões.



Problemas

- 2.1. No âmbito de uma campanha de lançamento de um novo modelo automóvel, um fabricante contempla a possibilidade de recorrer a uma série de comparações entre as características do modelo em causa e as de modelos concorrentes situados na mesma gama.

Entre as características que podem ser objecto de comparação figuram as seguintes:

(i) consumo de combustível, (ii) ruído dentro da cabina, e (iii) segurança na travagem.

Para cada uma destas características, poderão ser escolhidos dados expressos em diferentes tipos de escalas. Para cada característica, dê exemplos de dados expressos em escalas distintas, discutindo os seus méritos e limitações.

- 2.2. Num determinado dia, o gabinete de um médico de uma universidade efectuou 73 consultas a alunos, tendo classificado estes segundo a faculdade a que pertenciam:

- ♦ Psicologia (P); ♦ Engenharia (E); ♦ Letras (L);
- ♦ Farmácia (F); ♦ Medicina (M); ♦ Outras (O)

Na tabela seguinte apresentam-se os resultados obtidos.

E	L	F	E	L	E	P	F	L
M	E	E	O	E	P	O	E	F
O	L	O	E	L	F	L	E	L
O	E	O	L	P	E	E	L	E
E	O	E	O	P	P	E	F	E
P	E	L	E	F	O	L	F	P
E	O	E	E	E	M	E	L	E
O	E	L						

Represente adequadamente e interprete a informação contida nestes dados.

- 2.3. Na tabela seguinte apresentam-se os valores (em euros) das compras efectuadas por 64 clientes de uma casa comercial.

649	719	1863	129	3498	1295
2125	6849	938	97	219	4169
465	319	1045	2385	890	1197
444	1388	812	6468	2468	997
367	1493	775	6725	450	3495
749	569	2295	7495	2445	6791
890	3595	126	397	435	599
1197	525	985	650	2997	357
1630	1339	1199	444	6198	692
1185	997	746	1243	2150	168
4987	1383	1956	277		

Represente adequadamente e interprete a informação contida nestes dados.

- 2.4. Considere-se uma amostra constituída por 100 latas de pêssago em calda de uma determinada marca, cujo rótulo indica um peso médio líquido escorrido de 450 gramas. Na tabela seguinte incluem-se os pesos observados na amostra.

452	455	425	453	464	438	457	444	447	454
441	450	457	445	454	450	429	442	454	447
455	436	444	453	421	438	432	452	445	458
440	451	446	436	441	448	435	447	427	450
443	450	432	449	445	436	433	441	449	443
448	449	437	437	449	440	424	453	438	452
447	435	443	451	426	449	441	451	445	454
453	445	449	431	446	437	441	428	450	447
447	440	441	430	439	454	439	444	455	448
459	450	456	440	445	442	430	436	450	454

Represente adequadamente e interprete a informação contida nestes dados.

- 2.5. Na tabela seguinte apresentam-se os resultados relativos à amostra considerada no problema anterior (2.4), agrupados num conjunto de 9 células.

Peso (gramas)	Frequência
420-424	2
425-429	5
430-434	6
435-439	14
440-444	18
445-449	23
450-454	23
455-459	8
460-464	1

Calcule medidas amostrais de localização, dispersão, assimetria e kurtose e compare-as com as que são obtidas directamente a partir dos dados do problema anterior.

- 2.6. Na tabela seguinte apresentam-se os volumes de produção (em toneladas de produtos acabados) registados numa empresa metalomecânica em vinte dias sucessivos.

(1)	9.6	(11)	10.2
(2)	11.5	(12)	12.5
(3)	10.5	(13)	11.8
(4)	11.1	(14)	11.8
(5)	12.0	(15)	10.0
(6)	10.3	(16)	11.8
(7)	9.1	(17)	11.7
(8)	10.7	(18)	11.3
(9)	8.6	(19)	14.4
(10)	10.3	(20)	10.1

Represente e interprete a informação contida nestes dados.

- 2.7. Numa sondagem efectuada recentemente sobre audiências de televisão num país com apenas dois canais, TV1 e TV2, 1973 telespectadores responderam que estavam a ver televisão às 22 horas da última sexta-feira do mês passado.

Dos telespectadores do sexo feminino, 598 responderam que viam o programa da TV1, 212 seguiam a TV2 e 186 sintonizavam uma estação via satélite. As respostas dos telespectadores do sexo masculino foram as seguintes: 528 viam a TV1, 164 a TV2 e 285 uma estação recebida via satélite.

Represente adequadamente e interprete a informação contida nestes dados.

- 2.8. Uma empresa que produz válvulas de um determinado tipo, recolheu informação relativa à dimensão de 30 lotes de fabrico dessas válvulas e ao correspondente custo directo de produção.

Na tabela seguinte apresentam-se os dados recolhidos: 30 pares ordenados (dimensão do lote em unidades, custos directos em euros).

(26, 2300)	(20, 2090)	(5, 1280)
(50, 3410)	(30, 2470)	(10, 1550)
(100, 6290)	(4, 1350)	(10, 1430)
(20, 1870)	(5, 1250)	(6, 1310)
(8, 1590)	(50, 3660)	(20, 2190)
(40, 3270)	(200, 11460)	(15, 1710)
(25, 2060)	(50, 3390)	(30, 2580)
(6, 1240)	(20, 2080)	(65, 4150)
(8, 1550)	(10, 1500)	(22, 2260)
(10, 1470)	(15, 1790)	(10, 1590)

Represente graficamente estes dados, ajuste uma relação linear entre as variáveis dimensão do lote e custo directo de produção, e caracterize o grau de ajuste obtido.



Teoria Elementar da Probabilidade

3.1 INTRODUÇÃO

A representação de dados de uma forma sintética e compreensível, que foi o tema central do capítulo anterior, é um passo necessário, mas limitado, para viabilizar a utilização dos mesmos na análise e interpretação de processos ou na tomada de decisões.

Neste capítulo será apresentado um conjunto de conceitos básicos da Teoria da Probabilidade, que constitui o alicerce fundamental sobre o qual assenta a inferência estatística. Esta razão seria, em si, suficiente para justificar a importância que se atribui à Teoria da Probabilidade. Mas o seu objecto geral, que é o de modelizar os fenómenos ou os processos nos quais interfere o acaso, faz dela um instrumento imprescindível para uma melhor compreensão do mundo que nos rodeia.

Um fenómeno ou processo diz-se **aleatório** quando o acaso interfere na ocorrência de um ou mais dos resultados nos quais tal fenómeno ou processo se podem traduzir. Face à conjugação de um determinado número de condições, um resultado aleatório pode ocorrer ou não.

Exemplo 3.1

Considere-se o lançamento ao ar de uma moeda que numa face tem um Escudo e na outra uma Caravela. Os resultados «sai Escudo» ou «sai Caravela» são aleatórios.

Cada resultado aleatório é a consequência de inúmeras causas fortuitas: no Exemplo 3.1, as causas serão a posição inicial da moeda, a força com que é lançada, a sua forma e muitas outras. Para compreender aquilo que sucede no lançamento da moeda, poder-se-ia tentar relacionar cada um dos resultados possíveis («sai Escudo» ou «sai Caravela») com essas causas. É fácil reconhecer que esta via não será particularmente frutífera quando os fenómenos envolvidos forem muito complexos ou as causas que determinam a ocorrência dos vários resultados possíveis forem em grande número.

Neste tipo de situação é mais pragmática a abordagem da Teoria da Probabilidade, no âmbito da qual se associa o conceito de probabilidade à ocorrência de cada um dos resultados possíveis.

Para precisar este conceito, há que introduzir previamente um conjunto de definições básicas que serão objecto da secção seguinte.

3.2 EXPERIÊNCIAS ALEATÓRIAS, ESPAÇOS AMOSTRAIS E ACONTECIMENTOS

Uma experiência aleatória designa uma situação (ou, como anteriormente se referiu, o cumprimento de um determinado conjunto de condições) à qual estejam associados, de forma não controlada, dois ou mais resultados possíveis.

Exemplo 3.2

- O lançamento de uma moeda E-C ao ar uma vez (com dois resultados possíveis: «sai Escudo» (E) ou «sai Caravela» (C)).
- O lançamento de uma moeda E-C ao ar tantas vezes quantas as necessárias até sair E (com um número infinito de resultados possíveis: 1, 2, 3, ...).
- O atraso de um comboio (com uma infinidade de resultados possíveis, traduzidos pelo conjunto de números reais $[0, +\infty[$; a adopção de um limite inferior igual a zero justifica-se se se admitir que os maquinistas cumprem as instruções de nunca chegarem em avanço em relação ao seu horário; a adopção de um limite superior igual a $+\infty$ é, evidentemente, questionável, podendo ser interpretada como reflectindo o caso no qual o comboio não chega).

Define-se como **espaço amostral** (ou **espaço de resultados**) o conjunto de todos os resultados possíveis de uma experiência aleatória.

Exemplo 3.3

- Experiência: lançamento de uma moeda E-C ao ar uma vez.
Espaço amostral: conjunto $\{E, C\}$, constituído pelos resultados «sai Escudo» (E) ou «sai Caravela» (C).
- Experiência: lançamento de uma moeda E-C ao ar tantas vezes quantas as necessárias até sair E.
Espaço amostral: conjunto $\{1, 2, 3, \dots\}$.
- Experiência: medida do atraso registado na chegada de um determinado comboio.
Espaço amostral (constituído pelos atrasos possíveis, medidos, por exemplo, em minutos): intervalo $[0, +\infty[$.

Os espaços amostrais podem ser **discretos** ou **contínuos**, conforme os seus elementos sejam numeráveis ou não. Os espaços discretos podem ser **finitos** ou **infinitos**.

Exemplo 3.4

No Exemplo 3.3 foram já considerados os três tipos de espaços amostrais:

- Espaço amostral discreto finito: conjunto $\{E, C\}$.
- Espaço amostral discreto infinito: conjunto $\{1, 2, 3, \dots\}$.
- Espaço amostral contínuo: intervalo $[0, +\infty[$ (note-se que o conjunto de atrasos possíveis de um comboio só será contínuo se se admitir que tais atrasos são medidos com precisão absoluta).

O espaço amostral associado a uma experiência aleatória depende naturalmente da forma como a experiência é avaliada (ou medida).

Exemplo 3.5

Considere-se a experiência constituída pelo lançamento da moeda E-C ao ar três vezes. Se o resultado for avaliado pelo número de E's obtidos (vezes nas quais «sai Escudo»), o espaço amostral é constituído pelo conjunto $\{0, 1, 2, 3\}$. Se o resultado for avaliado pela sequência de E's e C's, o espaço amostral é constituído por oito resultados possíveis, tal como se representa na Figura 3.1, através de uma **árvore de resultados** (diagrama utilizado na representação de resultados de experiências sequenciais) e de um **diagrama de Venn**.

Um conjunto de elementos de um espaço amostral — isto é, um conjunto de resultados possíveis associados à realização de uma experiência aleatória — recebe a designação de **acontecimento**. De acordo com esta definição, um acontecimento representa então um subconjunto do espaço amostral.

Figura 3.1
Representação do espaço amostral constituído pelas sequências de E's e C's obtidas em 3 lançamentos da moeda E-C.





Figura 3.2
Os acontecimentos como subconjuntos de espaços amostrais.



Exemplo 3.6

No espaço amostral representado na Figura 3.2, que é constituído pelas sequências de E's e C's obtidas em três lançamentos da moeda E-C,

- A_1 representa o acontecimento «saída de dois e só dois Escudos» e
- A_2 representa o acontecimento «saída de três Caravelas».

Um **acontecimento** designa-se **simples** quando contém apenas um resultado (no exemplo anterior, o acontecimento A_2) e **composto** quando contém mais do que um resultado (no exemplo anterior, o acontecimento A_1).

O acontecimento que contém todos os elementos de um espaço amostral e que, portanto, coincide com este espaço diz-se **acontecimento certo**. Esta designação reflecte o facto de, na realização da experiência aleatória correspondente, um dos resultados nele contidos ocorrer de certeza. O **acontecimento impossível** representa-se através de um conjunto que não contém nenhum elemento do espaço amostral. Tal conjunto, que se designa por **conjunto vazio**, representa-se através do símbolo $\emptyset$.


Dado que os acontecimentos são conjuntos (em particular, subconjuntos do espaço amostral), podem aplicar-se-lhes as operações de **reunião**, **intersecção** e **complementaridade**. Na Figura 3.3 apresenta-se o significado destas operações.

3.3 PROBABILIDADE


O conceito de probabilidade pode ser definido de diferentes maneiras. Apresentar-se-ão seguidamente cinco definições distintas: a clássica, a geométrica, a frequentista, a subjectiva e a axiomática.

Figura 3.3
Reunião, intersecção
e complementariedade de acontecimentos.


Reunião de A com B:
conjunto constituído por todos os elementos contidos em A ou em B



Intersecção de A com B:
conjunto constituído por todos os elementos contidos em A e em B



Complementar de A (em S):
conjunto constituído por todos os elementos do espaço amostral que não pertencem a A



■ 3.3.1 DEFINIÇÃO CLÁSSICA

Na sua origem, a Teoria da Probabilidade esteve associada aos jogos de azar (por exemplo, de dados ou de cartas). Desta associação nasceu a definição clássica de probabilidade: se uma experiência aleatória tiver N resultados mutuamente exclusivos e igualmente prováveis e se um acontecimento A contiver N_A desses resultados ($N_A \leq N$), então a probabilidade do acontecimento A é dada por

$$P(A) = \frac{N_A}{N}, \quad (3.1)$$

ou seja, a probabilidade de um acontecimento A é a razão entre o número de resultados (ou casos) favoráveis (à ocorrência de A, naturalmente) e o número de resultados possíveis.

Exemplo 3.7

- Probabilidade de se obter um resultado não inferior a 3 no lançamento de um dado: o número de casos possíveis é 6 (1, 2, ..., 6) e o número de casos favoráveis é 4 (3, 4, 5 e 6), pelo que a probabilidade do acontecimento em causa é $4/6 = 0.667$.
- Probabilidade de uma carta retirada ao acaso de um baralho ser uma espada: o número de casos possíveis é 52 (13 cartas de cada um dos quatro naipes) e o número de casos favoráveis é 13 (o número de espadas que existem num baralho), pelo que a probabilidade do acontecimento em causa é $13/52 = 0.25$.

Nestes exemplos, o cálculo do número de casos possíveis e do número de casos favoráveis foi trivial. Há, no entanto, situações nas quais o cálculo destes números envolve o recurso à **Análise Combinatória**. No Apêndice 3.1, que se apresenta no final deste capítulo, passam-se em revista alguns conceitos e expressões fundamentais de análise combinatória.

Como resultado da definição acima apresentada, as probabilidades satisfazem algumas propriedades que interessa referir desde já.

- (i) Dado que, para qualquer acontecimento A, $0 \leq N_A \leq N$, então a probabilidade $P(A) = N_A/N$ está compreendida entre zero e a unidade:

$$0 \leq P(A) \leq 1. \quad (3.2)$$

- (ii) O acontecimento certo (que coincide com o espaço amostral, S) inclui todos os resultados possíveis. Daqui que $N_S = N$, e, consequentemente,

$$P(S) = 1 \quad (3.3)$$

(o acontecimento impossível, ϕ , não inclui qualquer dos resultados contidos em S. Por isso, $N_\phi = 0$ e, consequentemente, $P(\phi) = 0$).

- (iii) Se dois acontecimentos A (com N_A resultados) e B (com N_B resultados) forem mutuamente exclusivos (isto é, se não contiverem nenhum resultado comum), ao acontecimento $A \cup B$ associam-se $N_A + N_B$ resultados e $P(A \cup B) = (N_A + N_B)/N = N_A/N + N_B/N$, ou seja,

$$P(A \cup B) = P(A) + P(B). \quad (3.4)$$

■ 3.3.2 DEFINIÇÃO GEOMÉTRICA

A definição clássica de probabilidade tem uma limitação que deriva do pressuposto de que o número de resultados possíveis associados a cada experiência aleatória é finito.

Com base naquela definição, não é possível, por exemplo, calcular a probabilidade de que um ponto seleccionado ao acaso a partir de uma região (por exemplo, de um círculo) se localize numa determinada sub-região incluída nesse círculo (por exemplo, um triângulo). Para o fazer, é necessário estender o conceito de probabilidade ao caso de experiências aleatórias nas quais os resultados possíveis constituam conjuntos contínuos.

Designa-se por «med» uma medida da dimensão (comprimento, área, volume) de uma região qualquer incluída num espaço amostral contínuo (S) de uma experiência aleatória. De acordo com a definição geométrica, a probabilidade de que um ponto seleccionado ao acaso a partir de S se localize na região A nele incluída é dada pela razão


$$P(A) = \frac{\text{med } A}{\text{med } S}. \quad (3.5)$$

Exemplo 3.8

Probabilidade de que um ponto seleccionado ao acaso a partir de um quadrado (Q) se localize no círculo (C) nele inscrito (ver Figura 3.4): admitindo que o círculo tem raio r e que, portanto, o quadrado tem lado $2 \cdot r$, a probabilidade é dada por

$$\frac{\text{área } C}{\text{área } Q} = \frac{\pi \cdot r^2}{(2 \cdot r)^2} = \frac{\pi}{4}.$$

Figura 3.4
Situação considerada no Exemplo 3.8.



É imediato verificar que, de acordo com a nova definição apresentada, as probabilidades ainda satisfazem as propriedades que anteriormente se verificou serem satisfeitas segundo a definição clássica:

$$0 \leq P(A) \leq 1$$

$$P(S) = 1 \quad (\text{e } P(\phi) = 0)$$

$$P(A \cup B) = P(A) + P(B) \quad (A \text{ e } B \text{ mutuamente exclusivos}).$$

3.3.3 DEFINIÇÃO FREQUENCISTA

As definições clássica e geométrica não podem ser utilizadas no cálculo da probabilidade de acontecimentos associados à realização da maioria das experiências com interesse prático, às quais a simetria e a equiprobabilidade dos resultados não se aplica. Seguidamente apresentam-se exemplos deste tipo de experiências e acontecimentos.

Exemplo 3.9

- ♦ No lançamento ao ar de uma moeda E-C que, por ter sido deformada, se sabe que se encontra desequilibrada, qual a probabilidade de sair E?
- ♦ Qual a probabilidade de um português com 18 anos viver pelo menos até aos 70 anos?

Como é evidente, as definições anteriores não são aplicáveis a estes casos. As limitações de tais definições são ultrapassadas na interpretação frequencista de probabilidade que seguidamente se apresenta.

Considere-se que, no decurso de N realizações de uma experiência, um acontecimento qualquer A ocorre N_A vezes ($0 \leq N_A \leq N$). A probabilidade do acontecimento define-se como o limite, quando N tende para infinito, da frequência relativa de ocorrência do acontecimento A (isto é, da ocorrência de qualquer um dos resultados contidos em A). Em notação simbólica, pode escrever-se

$$P(A) = \lim_{N \rightarrow \infty} \frac{N_A}{N}. \quad (3.6)$$

É imediato verificar que, de acordo com a definição frequencista, as probabilidades satisfazem as propriedades que anteriormente se mostrou serem satisfeitas segundo as definições clássica e geométrica:

$$0 \leq P(A) \leq 1$$

$$P(S) = 1 \quad (\text{e } P(\phi) = 0)$$

$$P(A \cup B) = P(A) + P(B) \quad (A \text{ e } B \text{ mutuamente exclusivos}).$$

3.3.4 DEFINIÇÃO SUBJECTIVA

A interpretação frequencista de probabilidade constitui uma base adequada para se conceptualizar e até estimar as probabilidades de acontecimentos associados a experiências que possam ser (ou já tenham sido) repetidas de uma forma estável um número significativo de vezes.

Há, no entanto, experiências que, pela sua própria natureza, nunca se repetirão. Neste caso, a via frequencista não é seguramente útil para estimar as probabilidades associadas a diferentes acontecimentos.

Exemplo 3.10

- ♦ Como estimar, pela via frequencista, a probabilidade de o actual governo se manter inalterado nos próximos seis meses?
- ♦ E a probabilidade de um determinado índice de uma Bolsa de Valores (por exemplo, o PSI 20) duplicar nos próximos 10 anos?

Nestes casos é mais fácil interpretar as probabilidades como expressões do grau de credibilidade que cada pessoa atribui à ocorrência dos acontecimentos em causa.

É claro que se podem imaginar muitas formas de exprimir tais graus de credibilidade. No entanto, para que eles traduzam probabilidades, devem satisfazer o conjunto de propriedades que foram anteriormente identificadas como características destas, de acordo com qualquer das definições apresentadas.

Um argumento em favor da satisfação de tais propriedades é o seguinte: mesmo que haja certas experiências que, na realidade, não se repitam, pode sempre imaginar-se essa possibilidade teórica. Então as propriedades satisfeitas pelas probabilidades interpretadas como limites de frequências devem ser também satisfeitas pelas probabilidades subjectivas.

3.3.5 DEFINIÇÃO AXIOMÁTICA

As definições de probabilidade anteriormente apresentadas sofrem, do ponto de vista filosófico, de uma grande debilidade: a que resulta de incluir o definido nas próprias definições. Consideremos, a título de exemplo, as definições clássica e frequencista de probabilidade.

Tal insuficiência é óbvia no primeiro caso. De facto, na definição clássica refere-se um conjunto de resultados «igualmente prováveis». Utiliza-se assim a expressão «provável» na definição de probabilidade.

Na definição frequencista a insuficiência apresenta-se de uma forma menos evidente. Ao definir-se a probabilidade como o limite de uma frequência, que tipo de limite se estará a contemplar? Por exemplo, em lançamentos sucessivos da moeda E-C, pode suceder que surja sempre o resultado E. De um ponto de vista lógico, pode suceder que a frequência relativa deste resultado se mantenha igual a 1, mesmo no limite. A única forma de rebater este argumento consiste em qualificar esta sucessão de resultados, atribuindo-lhe uma baixíssima probabilidade...

A maneira de romper este raciocínio circular consiste em definir as probabilidades apenas com base num conjunto de regras — ou axiomas — que devem satisfazer. Numa versão simplificada desta abordagem axiomática, consideram-se como axiomas as propriedades que se verificou resultarem das definições anteriormente apresentadas de probabilidade:

AXIOMA 1

Para qualquer acontecimento A (isto é, qualquer subconjunto de um espaço amostral S), a probabilidade desse acontecimento satisfaz a relação

$$0 \leq P(A) \leq 1.$$

AXIOMA 2

A probabilidade associada ao acontecimento certo (S) é

$$P(S) = 1.$$

AXIOMA 3

Se dois acontecimentos A e B forem mutuamente exclusivos, então

$$P(A \cup B) = P(A) + P(B).$$

As probabilidades assim definidas passam a ser meros objectos matemáticos. A garantia de que se trata de objectos com interesse teórico e prático, assenta no facto de que os axiomas são, por um lado, consistentes e, por outro, pragmáticos.

A consistência dos axiomas impõe que os resultados que a partir deles se possam deduzir não sejam contraditórios. O seu pragmatismo está associado à capacidade de permitirem representar de uma forma útil fenómenos ou processos com que a realidade nos confronta.

Com base nos axiomas adoptados, podem deduzir-se as propriedades associadas às probabilidades, cuja validade poderia ser verificada directamente a partir das definições anteriores. Apresentam-se seguidamente três exemplos de tais propriedades:

(i) Para qualquer acontecimento A,

$$P(A) + P(\bar{A}) = 1 \quad (3.7)$$

A e $\bar{A}$ são acontecimentos mutuamente exclusivos.

Do axioma 3 resulta que $P(A \cup \bar{A}) = P(A) + P(\bar{A})$.

Dado que $A \cup \bar{A}$ é o espaço amostral, $P(A \cup \bar{A}) = P(S)$.

Do axioma 2 resulta que $P(A \cup \bar{A}) = P(S) = 1$.

Então $P(A) + P(\bar{A}) = P(A \cup \bar{A}) = 1$.

(ii) $P(\phi) = 0 \quad (3.8)$

ϕ e S são acontecimentos complementares.

Da propriedade anterior resulta $P(\phi) + P(S) = 1$.

Dado que $P(S) = 1$ (axioma 2), $P(\phi) = 1 - P(S) = 0$.

(iii) Para quaisquer acontecimentos A e B,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B). \quad (3.9)$$

Através do segundo diagrama de Venn representado anteriormente na Figura 3.3, é imediato verificar que

$$A \cup B \equiv A \cup (\bar{A} \cap B)$$

e que os acontecimentos A e $\bar{A} \cap B$ são mutuamente exclusivos.

Do axioma 3 resulta que $P(A \cup B) = P(A) + P(\bar{A} \cap B)$.

Ora o acontecimento B pode ser expresso como a reunião de dois acontecimentos mutuamente exclusivos, designadamente

$$B \equiv (A \cap B) \cup (\bar{A} \cap B).$$


Daqui que $P(B) = P(A \cap B) + P(\bar{A} \cap B)$, ou de forma equivalente,

$$P(\bar{A} \cap B) = P(B) - P(A \cap B).$$

Substituindo esta expressão na anteriormente obtida para $P(A \cup B)$, obtém-se

$$P(A \cup B) = P(A) + P(\bar{A} \cap B) = P(A) + P(B) - P(A \cap B).$$

Figura 3.5
Extracção de duas
peças de um lote
(Exemplo 3.11).



A probabilidade incondicional associada ao acontecimento A é dada pela razão entre o número de casos favoráveis (isto é, o número de elementos do conjunto A, #A) e o número de casos possíveis (#S):

$$P(A) = \frac{\#A}{\#S} = \frac{9}{12} = \frac{3}{4}.$$

Ao saber-se que a primeira peça extraída é defeituosa, passam a figurar como resultados possíveis apenas os que pertencem ao acontecimento B (o número de tais resultados é #B = 9). O número de casos favoráveis corresponde ao número de resultados que pertencem simultaneamente a A e a B ($\#(A \cap B) = 6$), vindo então a probabilidade condicional dada por

$$P(A|B) = \frac{\#(A \cap B)}{\#B} = \frac{6}{9} = \frac{2}{3}.$$

Em geral, para quaisquer dois acontecimentos A e B, a probabilidade condicional, $P(A|B)$, é definida pela expressão

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad (\text{com } P(B) > 0). \quad (3.10)$$

No caso de uma experiência aleatória com resultados equiprováveis, como a que corresponde ao exemplo que vem sendo tratado, esta expressão conduz àquela que anteriormente foi apresentada,

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{\#(A \cap B)}{\#S}}{\frac{\#B}{\#S}} = \frac{\#(A \cap B)}{\#B}.$$

A expressão (3.10) pode ser reordenada, vindo

$$P(A \cap B) = P(A|B) \cdot P(B). \quad (3.11)$$

3.4 PROBABILIDADE CONDICIONAL

Na resolução de problemas práticos encontram-se com frequência situações nas quais se pretende conhecer a probabilidade de ocorrência de um acontecimento A quando se admite que ocorreu (ou ocorrerá) um outro acontecimento B.

Exemplo 3.11

De um lote constituído por 1 peça boa e 3 defeituosas, retiraram-se duas peças ao acaso, em sequência e sem reposição da primeira. Sabendo que esta é defeituosa (acontecimento B), qual a probabilidade de a segunda ser também defeituosa (acontecimento A)?

No exemplo seguinte ilustra-se um caso no qual o objectivo é o de obter $P(A \cap B)$ a partir de $P(A|B)$ e de $P(B)$.

Exemplo 3.12

Três lâmpadas defeituosas foram inadvertidamente misturadas com seis lâmpadas boas. Escolhidas duas lâmpadas ao acaso, calcule-se a probabilidade de serem ambas boas.

Imagine-se que as lâmpadas são retiradas uma após a outra e considerem-se os acontecimentos seguintes:

A_1 : a primeira lâmpada é boa

A_2 : a segunda lâmpada é boa.

A probabilidade de as duas lâmpadas serem boas é dada por

$$P(A_1 \cap A_2) = P(A_1) \cdot P(A_2 | A_1) = \frac{6}{9} \cdot \frac{5}{8} = \frac{5}{12}.$$

3.5 ACONTECIMENTOS INDEPENDENTES

Dois acontecimentos quaisquer dizem-se **independentes** quando a ocorrência de um não afecta a probabilidade de ocorrência do outro ou vice-versa, ou seja, quando se verificar algumas das relações seguintes:

$$\begin{cases} P(A|B) = P(A) & (\text{com } P(B) > 0) \\ P(B|A) = P(B) & (\text{com } P(A) > 0). \end{cases} \quad (3.12)$$

É fácil mostrar que uma forma equivalente de expressar a independência entre os acontecimentos A e B se obtém através de

$$P(A \cap B) = P(A) \cdot P(B) \quad (\text{com } P(A) \geq 0 \text{ e } P(B) \geq 0) \quad (3.13)$$

Exemplo 3.13

No lançamento sucessivo de dois dados, considerem-se os seguintes acontecimentos:


A: a pontuação total é ímpar

B: o resultado obtido no primeiro dado é 6

C: a pontuação total é 7.

Estes acontecimentos encontram-se representados na Figura 3.6.

Figura 3.6
Lançamento de dois dados (Exemplo 3.13).



Verifique-se se os diferentes acontecimentos são independentes:

Acontecimentos A e B:

$$P(A) = 18/36 = 1/2$$

$$P(B) = 6/36 = 1/6$$

$$P(A \cap B) = 3/36 = 1/12 = P(A) \cdot P(B) \Rightarrow A \text{ e } B \text{ independentes.}$$

Interpretação: a probabilidade de a pontuação total ser ímpar, $P(A) = 1/2$, não se altera pelo facto de sair um seis no primeiro dado, pois a probabilidade de sair um número ímpar no segundo dado é também $1/2$ (note-se que a independência se manteria, qualquer que fosse o primeiro resultado).

Acontecimentos A e C:

$$P(A) = 18/36 = 1/2$$

$$P(C) = 6/36 = 1/6$$

$$P(A \cap C) = 6/36 = 1/6 \neq P(A) \cdot P(C) \Rightarrow A \text{ e } C \text{ não independentes.}$$

Interpretação: o facto de a pontuação total ser 7 implica que ela é ímpar, ou seja, $P(A|C) = 1$, enquanto que $P(A) = 1/2$.

Acontecimentos B e C:

$$P(B) = 6/36 = 1/6$$

$$P(C) = 6/36 = 1/6$$

$$P(B \cap C) = 1/36 = P(B) \cdot P(C) \Rightarrow B \text{ e } C \text{ independentes.}$$

Interpretação: a probabilidade de a pontuação total ser 7, dado que o 1.º resultado é seis, $P(C|B) = 1/6$, é igual à probabilidade incondicional $P(C) = 1/6$ (note-se que a independência não é generalizável a outros valores da pontuação total).

A definição de independência, introduzida para dois acontecimentos, pode ser generalizada ao caso de um número superior de acontecimentos. Os acontecimentos $A_1, A_2, \dots, A_N$ dizem-se independentes se e só se verificarem as seguintes relações:

$$P(A_i \cap A_j) = P(A_i) \cdot P(A_j) \quad \text{para } i \neq j$$

$$P(A_i \cap A_j \cap A_k) = P(A_i) \cdot P(A_j) \cdot P(A_k) \quad \text{para } i \neq j, i \neq k, j \neq k$$

(...)

$$P\left(\bigcap_{n=1}^N A_n\right) = \prod_{n=1}^N P(A_n). \quad (3.14)$$

Pode questionar-se se todas as relações consideradas na definição anterior são necessárias. Por exemplo, será que

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) \cdot P(A_2) \cdot P(A_3)$$

implica que

$$P(A_1 \cap A_2) = P(A_1) \cdot P(A_2)?$$

A resposta é negativa, pois a primeira relação é satisfeita quando $P(A_3) = 0$, mesmo que $P(A_1 \cap A_2)$ não seja igual a $P(A_1) \cdot P(A_2)$.

Pode também questionar-se se a independência entre os diferentes acontecimentos quando estes forem considerados dois a dois é suficiente para que eles sejam independentes segundo a definição anteriormente apresentada. A resposta volta a ser negativa, como se ilustra no exemplo seguinte.

Exemplo 3.14

No lançamento sucessivo de dois dados, considerem-se os seguintes acontecimentos:

- A: o resultado obtido no primeiro dado é par
- B: o resultado obtido no segundo dado é par
- C: a pontuação total é par.

É imediato verificar que os acontecimentos A, B e C, quando considerados dois a dois, são independentes:

$$P(A \cap B) = 1/4 = P(A) \cdot P(B) = 1/2 \cdot 1/2$$

$$P(A \cap C) = 1/4 = P(A) \cdot P(C) = 1/2 \cdot 1/2$$

$$P(B \cap C) = 1/4 = P(B) \cdot P(C) = 1/2 \cdot 1/2.$$

Tal não implica que, segundo a definição anteriormente apresentada, os três acontecimentos sejam independentes. De facto,

$$P(A \cap B \cap C) = P[C \cap (A \cap B)] = P[C|A \cap B] \cdot P(A \cap B) = 1 \cdot 1/4 = 1/4$$

que é diferente de

$$P(A) \cdot P(B) \cdot P(C) = 1/2 \cdot 1/2 \cdot 1/2 = 1/8.$$

3.6 TEOREMA DE BAYES

O teorema de Bayes é uma consequência relativamente simples do conceito de probabilidade condicional, que será ilustrada recorrendo ao seguinte exemplo.

Exemplo 3.15

Admita-se que, num determinado país, 1% da população tem tuberculose e, ainda, que

- para uma pessoa que tenha, de facto, contraído a doença, uma microrradiografia tem um resultado positivo (isto é, detecta a tuberculose) em 95% dos casos e
- para uma pessoa não tuberculosa, esta percentagem é de apenas 0.5%.

Pretende-se saber qual a probabilidade de uma pessoa a quem a microrradiografia tenha dado resultado positivo estar tuberculosa.

Considerando os seguintes acontecimentos

- T: a pessoa seleccionada está tuberculosa,
- NT: a pessoa seleccionada não está tuberculosa e
- ⊕: a pessoa seleccionada teve um resultado positivo na microrradiografia,

a probabilidade que se pretende calcular é a probabilidade condicional $P(T|\oplus)$.

De acordo com a expressão 3.10, esta probabilidade é dada por

$$P(T|\oplus) = \frac{P(T \cap \oplus)}{P(\oplus)}.$$

Mas, de acordo com a expressão 3.11, a probabilidade que figura no numerador pode ser expressa por

$$P(T \cap \oplus) = P(\oplus \cap T) = P(\oplus|T) \cdot P(T)$$

donde

$$P(T|\oplus) = \frac{P(\oplus|T) \cdot P(T)}{P(\oplus)}. \quad (3.15)$$

Atente-se agora no denominador desta expressão, $P(\oplus)$. Este termo pode ser desenvolvido, tendo em conta que

$$\oplus \equiv \oplus \cap S$$

e que, uma vez que T e NT são acontecimentos que cobrem exaustivamente o espaço amostral,

$$\oplus \equiv \oplus \cap S \equiv \oplus \cap (T \cup NT) \equiv (\oplus \cap T) \cup (\oplus \cap NT).$$

Ora T e NT e, portanto, $(\oplus \cap T)$ e $(\oplus \cap NT)$ são acontecimentos mutuamente exclusivos, pelo que

$$P(\oplus) = P[(\oplus \cap T) \cup (\oplus \cap NT)] = P(\oplus \cap T) + P(\oplus \cap NT).$$

ou, recorrendo à expressão 3.11,

$$P(\oplus) = P(\oplus \cap T) + P(\oplus \cap NT) = P(\oplus|T) \cdot P(T) + P(\oplus|NT) \cdot P(NT).$$

Substituindo $P(\oplus)$ na expressão 3.15, obtém-se

$$P(T|\oplus) = \frac{P(\oplus|T) \cdot P(T)}{P(\oplus|T) \cdot P(T) + P(\oplus|NT) \cdot P(NT)}. \quad (3.16)$$

Todos as probabilidades que figuram no segundo membro desta expressão são conhecidas:

$$P(\oplus|T) = 0.95 \quad P(T) = 0.01$$


$$P(\oplus|NT) = 0.005 \quad P(NT) = 0.99.$$

A partir destes valores pode-se calcular $P(T|\oplus)$:

$$P(T|\oplus) = \frac{0.95 \cdot 0.01}{0.95 \cdot 0.01 + 0.005 \cdot 0.99} = 0.657 = 65.7\%.$$

O significado da expressão 3.16 e os cálculos que lhe estão associados tornam-se mais claros se o problema for representado através de uma árvore de resultados como a que se apresenta na Figura 3.7.

Figura 3.7
Cálculo da probabilidade condicional recorrendo à árvore de resultados (Exemplo 3.15).



Antes de generalizar o procedimento adoptado neste exemplo, é oportuno interpretar a diferença entre a probabilidade condicional $P(T|\oplus)$ e a probabilidade incondicional $P(T)$. O acontecimento T (a pessoa seleccionada está tuberculosa) pode considerar-se como uma causa que tem uma **probabilidade a priori** $P(T)$ de ocorrer e que condiciona, de uma forma probabilística, a ocorrência de um efeito: a pessoa seleccionada tem na microrradiografia um resultado positivo ($\oplus$) ou não. A probabilidade condicional $P(T|\oplus)$ corresponde à probabilidade de a causa ocorrer quando o efeito foi já observado, designando-se por isso por **probabilidade a posteriori**.

No exemplo concreto que vem sendo acompanhado, a diferença entre os valores da probabilidade a priori, $P(T) = 1\%$, e da probabilidade a posteriori, $P(T|\oplus) = 67.5\%$, é uma consequência do acesso ao resultado do teste efectuado, reflectindo o poder deste teste.



A expressão 3.16 e o cálculo da probabilidade a posteriori que lhe está associado são susceptíveis de ser generalizados. Na Figura 3.8, $\{A_n\}$ ($n = 1, \dots, N$) denota um conjunto de acontecimentos mutuamente exclusivos e preenchendo exhaustivamente o espaço amostral (as causas, segundo a designação anterior), e B designa um acontecimento qualquer (anteriormente associado a um efeito).

Nestas condições, a probabilidade a posteriori de cada um dos acontecimentos A_n é dada pela expressão seguinte:

$$P(A_n|B) = \frac{P(B|A_n) \cdot P(A_n)}{P(B|A_1) \cdot P(A_1) + \dots + P(B|A_N) \cdot P(A_N)} \quad (3.17)$$

Esta expressão traduz o resultado do **teorema de Bayes**, podendo ser deduzida de forma idêntica à adoptada para justificar a expressão 3.16.

Figura 3.8
Condições de
definição do
teorema de Bayes
(Expressão 3.17).



■ APÊNDICE 3.1 ANÁLISE COMBINATÓRIA

Chamam-se **permutações** de n elementos distintos os agrupamentos formados por esses elementos que diferem uns dos outros apenas pela ordem pela qual tais elementos estão dispostos. O número destas permutações, denotado por P_n , é dado por

$$P_n = n! = n \cdot (n-1) \cdot \dots \cdot 3 \cdot 2 \cdot 1. \quad (A3.1.1)$$

Exemplo A3.1.1

Considerem-se as permutações dos números 1, 2 e 3.

$$\begin{array}{cccccc} 1-2-3 & 1-3-2 & 2-1-3 & 2-3-1 & 3-1-2 & 3-2-1 \\ P_3 = 3! = 3 \cdot 2 \cdot 1 = 6. \end{array}$$

Designam-se por **arranjos** de n elementos distintos tomados k a k os agrupamentos constituídos por k daqueles elementos que diferem uns dos outros quer pelos elementos que neles figuram quer pela ordem na qual eles se dispõem. O número destes arranjos, denotado por A_k^n , é dado por

$$A_k^n = \frac{n!}{(n-k)!} = n \cdot (n-1) \cdot \dots \cdot (n-k+1). \quad (A3.1.2)$$

Exemplo A3.1.2

Considerem-se os arranjos dos números 1, 2 e 3, tomados dois a dois.

$$\begin{array}{cccccc} 1-2 & 2-1 & 1-3 & 3-1 & 2-3 & 3-2 \\ A_2^3 = \frac{3!}{(3-2)!} = 3 \cdot 2 = 6. \end{array}$$


Designam-se por **combinações** de n elementos distintos tomados k a k os agrupamentos constituídos por k daqueles elementos que diferem uns dos outros apenas pelos elementos que neles figuram, independentemente da ordem pela qual se dispõem. O número destas combinações, denotado por C_k^n ou $\binom{n}{k}$, é dado por

$$C_k^n = \binom{n}{k} = \frac{n!}{(n-k)! k!}. \quad (A3.1.3)$$

Exemplo A3.1.3

Considerem-se as combinações dos números 1, 2 e 3, tomados dois a dois.

$$\begin{array}{ccc} 1-2 & 1-3 & 2-3 \\ C_2^3 = \binom{3}{2} = \frac{3!}{(3-2)! 2!} = \frac{6}{2} = 3. \end{array}$$



3.1. Na tabela seguinte apresenta-se a composição por raça e género da população de um país.

		Género	
		Masculino	Feminino
Raça	Branca	1 726 348	2 110 253
	Negra	628 309	753 125
	Outra	15 239	7 435


Admita que se selecciona ao acaso um indivíduo desta população.

- Qual a probabilidade de o indivíduo seleccionado ser branco?
 - E a de ser negro?
 - E a de ser uma mulher branca?
 - Qual a probabilidade de o indivíduo seleccionado ser de raça branca, admitindo que é uma mulher?
 - Será que os acontecimentos «o indivíduo é mulher» e «o indivíduo é de raça negra» são independentes?
- 3.2. Calcule a probabilidade de, com uma aposta simples, ganhar cada um dos três primeiros prémios do Totoloto.
- 3.3. Calcule a probabilidade de, entre um conjunto de 25 pessoas reunidas numa sala, haver pelo menos duas que façam anos no mesmo dia.
- 3.4. O grupo empresarial Sucesso tem 13 directores, entre os quais figura você. Numa sessão para quadros das empresas do grupo, os directores ocuparão lugares marcados numa mesa colocada sobre um palco. O critério de colocação é desconhecido, presumindo-se que a distribuição dos lugares seja aleatória. Por razões circunstanciais, você não quer ficar ao lado do seu colega da Direcção Financeira. Acha que há uma probabilidade elevada de tal vir a suceder? Calcule essa probabilidade antes de se decidir a telefonar à secretária encarregada da colocação das pessoas na sala.
- 3.5. Um míssil encomendado à firma Joaquim Tiro & Filhos Lda. acerta e destrói determinado tipo de alvo inimigo com uma probabilidade de 30%. Num ataque surpresa, quantos mísseis deverão ser disparados simultaneamente para que a probabilidade de destruir aquele tipo de alvo seja, pelo menos, de 90%?
- 3.6. Admita que dois contentores A e B, cada um com 13 peças, incluem, respectivamente, 3 e 6 peças defeituosas. Considere que, por lapso, se perderam as referências dos contentores. Se se seleccionar ao acaso um dos contentores e se dele se retirarem, também ao acaso, duas peças, qual a probabilidade de ambas serem boas? Calcule também a probabilidade de entre as duas peças haver pelo menos uma boa.

- 3.7. Num determinado país faz sol em 75% dos dias e chove nos restantes 25%. Verificou-se que um tipo de barómetro, que se limita a indicar «sol» ou «chuva», dá frequentemente indicações erradas: prevê sol em 10% dos dias chuvosos e chuva em 30% dos dias com sol.
- Qual a probabilidade de o barómetro errar a previsão?
 - Qual a probabilidade de fazer sol num dia para o qual a previsão seja de chuva?
- 3.8. Três máquinas — A, B e C — produzem, respectivamente, 60%, 30% e 10% do total de peças de um determinado tipo. Para cada uma das máquinas A, B e C, o número de peças defeituosas representa, respectivamente, 2%, 3% e 4% das peças produzidas pela máquina. Admita que, de um contentor no qual se juntaram as peças, foi seleccionada ao acaso uma delas, que se revelou defeituosa. Calcule a probabilidade de esta peça ter sido produzida pela máquina C.
- 3.9. Admita que 42% dos acidentes de aviação são causados por falhas estruturais e que, para este tipo de acidentes, a probabilidade de atribuir (correctamente) a sua ocorrência a uma falha estrutural é de 80%. Admita, ainda, que a probabilidade de um acidente cuja causa não é daquele tipo ser diagnosticado (incorrectamente) como devido a uma falha estrutural é de 15%. Determine a probabilidade de um acidente ao qual foi atribuída como causa uma falha estrutural ter resultado efectivamente de uma falha deste tipo.
- 3.10. Uma dona de casa dispõe de oito chaves, das quais três abrem a porta da sua despensa. Admita que a senhora tenta abrir a porta seleccionando sucessivamente as chaves de uma forma aleatória e pondo de lado as que já tentou (e que não abriam a porta). Calcule a probabilidade de a dona de casa ser bem sucedida na quarta tentativa.
- 3.11. Dois estudantes combinaram encontrar-se à porta da biblioteca entre as 12h00 e as 13h00, de acordo com a seguinte regra: aquele que chegar em primeiro lugar espera pelo outro até ao limite de 15 minutos. Passado este tempo, vai-se embora. Admitindo que cada estudante escolhe ao acaso, dentro do período estipulado, o momento da sua chegada, calcule a probabilidade do encontro se concretizar.
- 3.12. O mercado do serviço de telemóvel reparte-se por três empresas: empresa A com uma quota de 41%, empresa B com 38% e empresa C com 21%. Um estudo levado a cabo por uma associação de consumidores revelou que 17% dos utilizadores do serviço estavam insatisfeitos e que tais utilizadores se distribuíam da seguinte forma: 35% eram clientes de A, 35% de B e 30% de C. Calcule a probabilidade de um cliente satisfeito estar ligado à rede da empresa B.
- 3.13. Dois jogadores, A e B, disputam um jogo na TV. Em cada jogada, cada um dos participantes selecciona ao acaso um de seis temas, lançando um dado. Seguidamente terá de responder a uma pergunta do tema seleccionado. Na tabela seguinte apresenta-se, para cada jogador, as probabilidades de sucesso nas respostas às perguntas de cada tema.

	Desporto	Literatura	Política	Cinema	Telenovela	Música
A	0.90	0.10	0.80	0.10	0.40	0.30
B	0.40	0.50	0.70	0.55	0.20	0.85

Calcule a probabilidade de, numa jogada, sair o tema Desporto a ambos os jogadores, sabendo que, nessa jogada, A acerta e B falha.



Variáveis Aleatórias Distribuições de Probabilidade

4.1 DEFINIÇÃO DE VARIÁVEL ALEATÓRIA

Uma **variável aleatória** utiliza-se para expressar os resultados de uma experiência aleatória. Em algumas situações, o conjunto de valores que uma variável toma confunde-se com o próprio conjunto de resultados, isto é, com o espaço amostral.

Exemplo 4.1

Experiência aleatória: Medição da altura de uma pessoa escolhida ao acaso
Espaço amostral: Conjunto de todas as alturas atribuíveis a uma pessoa
Variável aleatória: Altura (que pode tomar qualquer um dos valores que constituem o espaço amostral).

Existem, no entanto, circunstâncias nas quais os valores que as variáveis aleatórias tomam se podem distinguir claramente dos resultados, correspondendo a uma transformação destes.

Exemplo 4.2

Considere-se de novo o lançamento da moeda E-C três vezes ao ar e admita-se que o espaço amostral S é constituído pelas sequências de E's e C's (ver Figura 3.1).


Se a variável amostral for definida como o número de E's obtidos em cada sequência, os valores que tal variável pode tomar (0, 1, 2 ou 3) são obviamente distintos dos elementos do espaço amostral. Podem, no entanto, ser obtidos a partir destes.

Em geral, uma variável aleatória pode ser definida como uma aplicação do espaço amostral sobre um conjunto de chegada qualquer. Retomando o exemplo anterior, a variável aleatória

$$Y = \text{número de E's}$$

é definida como uma aplicação do espaço amostral S (constituído pelos resultados da experiência lançamento da moeda E-C três vezes ao ar) sobre um conjunto de chegada (CDC) que inclua, pelo menos, os elementos 0, 1, 2 e 3.

Figura 4.1
Variável aleatória
definida como uma
aplicação



Esta aplicação,

$$Y = f(\text{resultado}),$$

encontra-se definida graficamente na Figura 4.1.

O conjunto $S' = \{0, 1, 2, 3\}$, que representa o **contradomínio da aplicação** f , constitui um novo espaço amostral. Na verdade, este conjunto expressa, de uma forma diferente da que originalmente tinha sido estabelecida, os resultados possíveis da experiência lançamento da moeda E-C três vezes ao ar. A cada um dos novos resultados (isto é, a cada um dos valores que a variável aleatória pode tomar) associa-se uma probabilidade, calculável a partir das probabilidades de ocorrência dos resultados originais:

$$P(Y = 0) = P(CCC) = 1/8$$

$$P(Y = 1) = P(ECC) + P(CEC) + P(CCE) = 3/8$$

$$P(Y = 2) = P(EEC) + P(ECE) + P(CEE) = 3/8$$

$$P(Y = 3) = P(EEE) = 1/8.$$

Os elementos do conjunto de chegada que não estão incluídos no contradomínio representam valores impossíveis da variável aleatória (a eles estará associada uma probabilidade nula).


Uma vez que sobre qualquer espaço amostral podem ser definidas diferentes aplicações, então a partir de um mesmo espaço amostral podem especificar-se diferentes variáveis aleatórias.

Exemplo 4.3

Considerando ainda a experiência lançamento da moeda E-C três vezes ao ar, na Figura 4.2 define-se uma nova variável aleatória

$$Y' = \text{número máximo de E's em sequência} = g(\text{resultado}).$$

Figura 4.2
Exemplo de uma
nova variável
aleatória definida a
partir do mesmo
espaço amostral.



Se o conjunto de chegada de uma variável aleatória for constituído por elementos expressos numa escala nominal ou ordinal, a **variável diz-se qualitativa**. Se aqueles elementos forem expressos numa escala de intervalo ou absoluta, a variável é **quantitativa**.

Exemplo 4.4

- As variáveis anteriormente definidas com base na experiência lançamento da moeda E-C três vezes ao ar, $Y = \text{número de E's}$ e $Y' = \text{número máximo de E's em sequência}$, são quantitativas.
- Considerando agora a experiência constituída pelo nascimento de uma criança e admitindo que não foram previamente efectuados testes conclusivos acerca do seu sexo, a variável $Z = \text{sexo da criança}$ (que pode tomar os «valores» feminino ou masculino) é uma variável qualitativa.

Uma **variável quantitativa** classifica-se como **discreta** ou **contínua**, conforme os elementos do contradomínio da aplicação que a define forem numeráveis ou não-numeráveis.

Exemplo 4.5

- A variável resultado do lançamento de um dado é discreta (podendo tomar os valores 1, 2, 3, 4, 5 ou 6).
- A variável distância a percorrer diariamente por um vendedor será contínua, se se admitir que tal distância é medida com precisão absoluta.

No tocante à caracterização das variáveis qualitativas e dos fenómenos aleatórios por elas descritos, pouco mais se pode acrescentar relativamente ao capítulo anterior, no qual foi introduzida a Teoria da Probabilidade. Como se verá ao longo deste capítulo e dos seguintes, as variáveis quantitativas são susceptíveis de uma modelização e de um tratamento muito mais sofisticados.

A partir de agora, este texto concentrar-se-á no estudo de variáveis aleatórias quantitativas. A exemplo do que é comum nos textos de probabilidade e estatística, as variáveis aleatórias quantitativas serão a partir de agora designadas simplesmente por variáveis aleatórias.

4.2 VARIÁVEIS DISCRETAS: FUNÇÃO DE PROBABILIDADE E FUNÇÃO DE DISTRIBUIÇÃO

Seja Y uma variável aleatória discreta. Designa-se por **função de probabilidade** da variável Y , e denota-se por $p(y)$, a função que associa a cada valor particular que a variável pode tomar, y , a probabilidade de Y ser igual a y . Em notação simbólica, a função de probabilidade de Y é definida pela expressão

$$p(y) = \text{Probabilidade}(Y = y) = P(Y = y). \quad (4.1)$$

Exemplo 4.6

Para a variável $Y = \text{número de E's}$, anteriormente definida com base na experiência lançamento da moeda E-C três vezes ao ar, a função de probabilidade é definida por

$$p(0) = 1/8 \quad p(1) = 3/8 \quad p(2) = 3/8 \quad p(3) = 1/8$$

Observa-se que, nesta definição, a variável é denotada por uma letra maiúscula, enquanto que os valores particulares a ela associados (isto é, as suas realizações) são representadas pela letra minúscula.

Dos axiomas da probabilidade, apresentados no capítulo anterior, resultam as seguintes proposições:

- Para qualquer valor y pertencente ao contradomínio da variável aleatória Y , a função de probabilidade de Y toma valores superiores a zero e não superiores à unidade. Em notação simbólica, vem:

$$\forall y \in S': 0 < p(y) \leq 1. \quad (4.2)$$

- (ii) O somatório de $p(y)$ estendido a todos os valores y pertencentes ao contradomínio S' da variável Y é igual à unidade. Em notação simbólica, vem:

$$\sum_{y \in S'} p(y) = 1. \quad (4.3)$$

Designa-se por **função de distribuição** (ou **função de probabilidade acumulada**) da variável aleatória discreta Y , a função $F(y)$ que associa a cada valor particular $y \in \mathbb{R}$ (conjunto dos números reais) a probabilidade de Y ser menor ou igual a y . Em notação simbólica, a função de distribuição de Y é definida pela expressão

$$F(y) = \text{Probabilidade}(Y \leq y). \quad (4.4)$$

Desta definição resulta que a função de distribuição pode ser calculada para qualquer valor real a , de acordo com a expressão

$$F(a) = P(Y \leq a) = \sum_{y \leq a} p(y). \quad (4.5)$$

Como se ilustra no exemplo seguinte, trata-se de uma função «em escada».

Exemplo 4.7

Para a variável definida no exemplo anterior, $Y = \text{número de E's}$, a função distribuição de probabilidade é definida por

$$\begin{aligned} y < 0 & : F(y) = 0 \\ 0 \leq y < 1 & : F(y) = p(0) = 1/8 \\ 1 \leq y < 2 & : F(y) = p(0) + p(1) = 1/2 \\ 2 \leq y < 3 & : F(y) = p(0) + p(1) + p(2) = 7/8 \\ 3 \leq y & : F(y) = p(0) + p(1) + p(2) + p(3) = 1 \end{aligned}$$

Ainda como consequência da definição apresentada, as funções de distribuição têm as seguintes propriedades:

$$\forall y \in]-\infty, +\infty[: 0 \leq F(y) \leq 1 \quad (4.6)$$

$$P(a < Y \leq b) = F(b) - F(a). \quad (4.7)$$

Embora as funções de distribuição de variáveis discretas sejam definidas para quaisquer valores reais, neste livro tais funções serão avaliadas e representadas apenas nos valores particulares que as variáveis podem tomar. Neste caso, aquelas funções podem ser representadas como as funções de probabilidade através de **tabelas** ou de **diagramas de barras**. Tal é ilustrado na Tabela 4.1 e na Figura 4.3, considerando uma vez mais a variável $Y = \text{número de E's}$, anteriormente definida com base na experiência lançamento da moeda E-C três vezes ao ar.


Tabela 4.1
Representação tabular da função de probabilidade e da função de distribuição da variável $Y = \text{número de E's}$.

Variável discreta Y	Função de probabilidade	Função de distribuição
0	1/8	1/8
1	3/8	1/2
2	3/8	7/8
3	1/8	1


Figura 4.3

Diagramas de barras correspondentes à função de probabilidade e à função de distribuição da variável $Y = \text{número de E's}$.

(i) Função de probabilidade



(ii) Função de distribuição



4.3 VARIÁVEIS CONTÍNUAS: FUNÇÃO DENSIDADE DE PROBABILIDADE E FUNÇÃO DE DISTRIBUIÇÃO


Para introduzir o conceito de função densidade de probabilidade, utilizar-se-á uma analogia com o conceito de densidade em Mecânica dos Meios Contínuos. Para o efeito, considere-se uma barra retilínea de secção constante (com área Ω) e de dimensões desprezáveis quando comparadas com o seu comprimento, L (ver Figura 4.4). Admita-se ainda que a barra é constituída por material homogêneo, com massa M .

A densidade (absoluta) do material que constitui a barra é dada por

$$\mu = \frac{M}{\Omega \cdot L} = \frac{M}{V},$$

onde $V = \Omega \cdot L$ representa o volume da barra. A densidade será tanto maior quanto mais concentrada estiver a massa, isto é, quanto menor for o volume pelo qual ela se distribui.

Figura 4.4
Barra retilínea de secção constante.



Admita-se agora que o material que constitui a barra é heterogéneo ao longo da barra. Neste caso, não faz sentido falar em densidade do material, pois esta variará de ponto para ponto. Considere-se, ainda, que, pelo facto de as dimensões da secção da barra serem muito pequenas, as características mecânicas do material (em particular a densidade) são idênticas para todos os pontos que pertencem à mesma secção.

Para os pontos situados na secção S, que, conforme se indica na Figura 4.4, está situada à distância x da extremidade esquerda da barra, a densidade do material pode ser calculada de forma aproximada através da expressão

$$\delta(x) = \frac{\Delta M}{\Delta V} = \frac{\Delta M}{\Delta x \cdot \Omega},$$

onde ΔM , ΔV e Δx representam respectivamente a massa, o volume e o comprimento de um pequeno tramo da barra compreendido entre as secções S e S'.

Para definir com rigor a densidade numa secção é necessário recorrer ao conceito de limite. A densidade nos pontos situados na secção S é dada pelo limite de $\Delta M / \Delta V$ quando o comprimento do tramo, Δx , e portanto o seu volume, ΔV , tendem para zero. Em notação simbólica, vem

$$\delta(x) = \lim_{\Delta V \rightarrow 0} \frac{\Delta M}{\Delta V} = \frac{dM}{dV} = \frac{1}{\Omega} \cdot \frac{dM}{dx}.$$

Nesta expressão, dM , dV e dx representam valores infinitamente pequenos da massa, do volume e do comprimento do tramo, que correspondem aos limites de ΔM , ΔV e Δx .

Se o objectivo for o de definir a forma como a densidade se distribui ao longo da barra, o termo Ω , que se admitiu não variar de secção para secção, pode ser excluído da expressão anterior. Se este procedimento for adoptado, estabelece-se uma definição de densidade linear (em vez da anterior densidade volumétrica):

$$\delta(x) = \frac{dM}{dx}.$$

Esta densidade mede a concentração de massa por unidade de comprimento (e não por unidade de volume, como sucedia anteriormente).

É importante notar que, de acordo com o modelo adoptado na Mecânica dos Meios Contínuos, uma massa não nula (positiva, naturalmente) ocupa um volume não nulo (positivo, também). No caso da barra, uma massa não nula distribui-se por um comprimento não nulo.

A qualquer secção da barra, à qual se associam valores nulos de volume e comprimento, corresponde sempre uma massa nula. No entanto, a essa secção está associado o valor de uma densidade, que pode ser mais elevada ou mais baixa, conforme num mesmo tramo de dimensões infinitamente pequenas que lhe seja adjacente se concentre mais ou menos massa.

Uma vez apresentado o conceito de densidade linear numa barra contínua, pode passar-se à definição de função densidade de probabilidade, tentando estabelecer o paralelo entre os dois.

Denote-se por X uma variável aleatória contínua e admita-se que tal variável pode tomar valores pertencentes ao intervalo $[0, L]$. Qualquer valor particular, x , que a variável tome pode ser associado à localização de uma secção da barra definida na Figura 4.4.

Tal como no modelo físico se admite que é nula a massa que se concentra em qualquer secção, na caracterização do comportamento da variável X admite-se que a probabilidade de esta tomar um valor qualquer particular, x , é nula.

Esta característica do comportamento da variável é consistente com o facto de ela ser considerada contínua. Considere-se, por exemplo, a probabilidade de a variável X tomar o valor $x = 2.567$ (valor este que se admite ser inferior a L). Embora seja de admitir que a variável possa, com alguma probabilidade, tomar um valor próximo de 2.567, admite-se que, se se considerar um número suficientemente elevado de casas decimais, X acabará por tomar sempre um valor diferente daquele (por exemplo, 2.5670000001).

Ao tramo da barra situado entre as secções S e S', distando entre si de Δx , corresponde uma massa ΔM . No modelo probabilístico, o equivalente a ΔM é ΔP , a probabilidade de a variável X tomar um valor situado no intervalo $[x, x + \Delta x]$. Se se dividir esta probabilidade por Δx , obtém-se, de uma forma aproximada, a densidade de probabilidade da variável X em torno do valor x ,

$$f(x) \approx \frac{\Delta P(x < X < x + \Delta x)}{\Delta x}. \quad (4.8)$$

Note-se que no numerador desta expressão os sinais «<» podem ser substituídos por «≤». De facto, dado que as probabilidades $P(X = x)$ e $P(X = x + \Delta x)$ são nulas, as probabilidades $\Delta P(x < X < x + \Delta x)$ e $\Delta P(x \leq X \leq x + \Delta x)$ são iguais.

A exemplo do que sucedia no modelo físico, a definição rigorosa da **função densidade de probabilidade** da variável X obtém-se tomando o limite da expressão anterior quando Δx tende para zero:

$$f(x) = \lim_{\Delta x \rightarrow 0} \frac{\Delta P(x < X < x + \Delta x)}{\Delta x} = \frac{dP(x < X < x + dx)}{dx}. \quad (4.9)$$

Esta função mede, em torno do ponto $X = x$, a concentração de probabilidade por unidade da variável X e daí o facto de ser designada por função densidade de probabilidade. Atente-se ao paralelo que existe com a função de densidade (mássica) linear definida anteriormente para o caso da barra.

A expressão 4.9 pode ser reescrita da forma seguinte:

$$dP(x < X < x + dx) = f(x) \cdot dx.$$

Daqui resulta uma nova interpretação para a função densidade de probabilidade $f(x)$: trata-se de uma função cujo valor numérico, quando multiplicado pela amplitude do intervalo infinitesimal $[x, x + dx]$ dá a probabilidade infinitesimal de a variável X tomar um valor situado dentro do referido intervalo.

Uma vez que as funções densidade de probabilidade medem probabilidades, então, só podem tomar valores não-negativos ou, por outras palavras, satisfazem a condição de não-negatividade.


As funções densidade de probabilidade são habitualmente definidas através de fórmulas, a partir das quais se fixa a sua forma, sendo susceptíveis de ser também representadas pela via gráfica.

Exemplo 4.8

Na Figura 4.5 representa-se graficamente a função densidade de probabilidade da variável T , que representa o tempo de funcionamento sem avarias (ou, se se preferir, entre avarias), expresso em dias, de um determinado equipamento. Aquela função é definida pela expressão seguinte:

$$f(t) = \begin{cases} 0, & \text{se } t < 0 \\ 0.5 \cdot e^{-0.5 \cdot t}, & \text{se } t \geq 0 \end{cases}$$

Figura 4.5
Função densidade de probabilidade da variável T .



Para calcular de uma forma aproximada a probabilidade de a variável X tomar um valor situado dentro do intervalo finito $[a, b]$, divide-se este intervalo num número elevado (N) de intervalos de igual amplitude (Δx), conforme se representa na Figura 4.6 (i):

$$\text{int}_1 = [x_1 = a, x_2 = x_1 + \Delta x[$$

$$\text{int}_2 = [x_2, x_3 = x_2 + \Delta x[$$

(...)

$$\text{int}_n = [x_n, x_{n+1} = x_n + \Delta x[$$

(...)

$$\text{int}_N = [x_N, x_{N+1} = x_N + \Delta x = b].$$

Dado que o acontecimento ($a < X < b$) é a reunião dos N acontecimentos mutuamente exclusivos ($X \in \text{int}_n, n = 1, \dots, N$), vem

$$P(a < X < b) = P\left(\bigcup_{n=1}^N X \in \text{int}_n\right) = \sum_{n=1}^N \Delta P(X \in \text{int}_n). \quad (4.10)$$

Ora, como resulta da expressão 4.8, a probabilidade ΔP de X pertencer ao n -ésimo intervalo de amplitude Δx é dada aproximadamente por

$$\Delta P(X \in [x_n, x_n + \Delta x]) \approx f(x_n) \cdot \Delta x.$$

Substituindo ΔP na expressão 4.10, obtém-se

$$P(a < X < b) \approx \sum_{n=1}^N f(x_n) \cdot \Delta x. \quad (4.11)$$

O segundo membro desta expressão corresponde à área assinalada no diagrama (i) da Figura 4.6. O valor exacto da probabilidade $P(a < X < b)$ obtém-se tomando o limite daquele segundo membro quando Δx tende para zero (ou N tende para infinito):

$$P(a < X < b) = \lim_{\Delta x \rightarrow 0} \sum_{n=1}^N f(x_n) \cdot \Delta x = \int_a^b f(x) \cdot dx. \quad (4.12)$$


O integral definido que figura no segundo membro desta expressão corresponde à área representada no diagrama (ii) da Figura 4.6.

Antes de prosseguir, interessa apresentar uma condição que, para além da de não-negatividade, deve ser satisfeita por todas as funções densidade de probabilidade. Com esse objectivo, substitua-se, na expressão 4.12, o intervalo $[a, b]$ pelo intervalo de amplitude infinita $]-\infty, +\infty[$. A probabilidade de uma variável contínua qualquer tomar um valor situado neste intervalo é igual a um, pois trata-se do acontecimento certo. Daqui resulta que

$$\int_{-\infty}^{+\infty} f(x) \cdot dx = P(-\infty < X < +\infty) = 1. \quad (4.13)$$

Figura 4.6. Cálculo da probabilidade de a variável aleatória X tomar um valor situado no intervalo finito $[a, b]$.

(i) Cálculo aproximado de $P(a < X < b)$, segundo a expressão 4.11



(ii) Cálculo rigoroso de $P(a < X < b)$, segundo a expressão 4.12





Figura 4.7. Representação gráfica da probabilidade $P(1 < T < 3)$.



Exemplo 4.9

Considere-se de novo a variável T definida no Exemplo 4.8 e calcule-se a probabilidade de o equipamento funcionar sem avarias durante um período compreendido entre 1 e 3 dias (tal probabilidade corresponde à área assinalada na Figura 4.7).

Recorrendo à expressão 4.12, obtém-se:

$$\begin{aligned} P(1 < T < 3) &= \int_1^3 f(t) \cdot dt \\ &= \int_1^3 0.5 \cdot e^{-0.5t} \cdot dt \\ &= [-e^{-0.5t}]_1^3 \\ &= e^{-0.5} - e^{-1.5} \\ &= 0.6065 - 0.2231 \\ &= 0.3834 \approx 38\%. \end{aligned}$$

Exemplo 4.10

Verifique-se que a função densidade de probabilidade da variável T definida no Exemplo 4.8 satisfaz esta condição:

$$\begin{aligned}\int_{-\infty}^{+\infty} f(t) \cdot dt &= \int_{-\infty}^0 0 \cdot d(t) + \int_0^{+\infty} 0.5 \cdot e^{-0.5t} \cdot dt \\ &= \int_0^{+\infty} 0.5 \cdot e^{-0.5t} \cdot dt = \left[-e^{-0.5t} \right]_0^{+\infty} \\ &= e^0 - e^{-\infty} = 1 - 0 = 1.\end{aligned}$$

Uma vez definida e interpretada a função densidade de probabilidade, é imediato passar ao conceito de função de distribuição.

A função de distribuição (ou de probabilidade acumulada) da variável aleatória contínua X , $F(x)$, associa a cada valor particular x a probabilidade de X ser menor ou igual a x (ou, o que é absolutamente equivalente, menor do que x). Em notação simbólica, a função de distribuição de X é definida pela expressão

$$F(x) = P(X \leq x) = P(X < x) = \int_{-\infty}^x f(u) \cdot du. \quad (4.14)$$

Note-se que no integral que figura nesta expressão o limite superior de integração é x , pelo que há que considerar uma variável de integração distinta de x , no caso a variável u .

Enquanto no caso das variáveis aleatórias discretas, a função de distribuição era obtida somando termos da função de probabilidade, agora, em domínios contínuos, aquela função é obtida por integração da função densidade.

A partir da definição dada na expressão 4.14 e tendo em conta que, nos pontos em que a função densidade for contínua,

$$\frac{d\left(\int_{-\infty}^{+x} f(u) \cdot du\right)}{dx} = f(x),$$

é imediato estabelecer a relação que existe entre as funções de distribuição e densidade de uma variável aleatória contínua qualquer:

$$\frac{dF(x)}{dx} = f(x), \quad (4.15)$$

ou seja, a derivada da função de distribuição é a função densidade (nos pontos em que esta seja contínua).

Como resultado da sua definição, as funções de distribuição de variáveis contínuas são monótonas crescentes e contínuas, e, tendo em conta a expressão 4.13, satisfazem a condição seguinte:

$$\lim_{x \rightarrow \infty} F(x) = \int_{-\infty}^{+\infty} f(u) \cdot du = 1. \quad (4.16)$$

Exemplo 4.11

Considere-se, de novo, a variável T definida no Exemplo 4.8. A função de distribuição pode ser obtida directamente por integração da função densidade (definida no Exemplo 4.8), obtendo-se:

$$\text{Para } t \leq 0: \quad F(t) = 0$$

Para $t > 0$:


$$F(t) = \int_0^t 0.5 \cdot e^{-0.5u} \cdot du = \left[-e^{-0.5u} \right]_0^t = 1 - e^{-0.5t}.$$

Globalmente, a função de distribuição vem definida então por

$$F(t) = \begin{cases} 0, & \text{se } t \leq 0 \\ 1 - e^{-0.5t}, & \text{se } t > 0. \end{cases}$$

Na Figura 4.8 esta função é apresentada conjuntamente com a função densidade, procurando-se evidenciar a relação que existe entre as duas.

Figura 4.8
Representação conjunta da função densidade de probabilidade e da função de distribuição da variável T (definida no Exemplo 4.8).



4.4 AS FUNÇÕES DE PROBABILIDADE, DENSIDADE DE PROBABILIDADE E DE DISTRIBUIÇÃO ENCARADAS COMO FORMAS DE REPRESENTAÇÃO DE POPULAÇÕES

Nesta secção procura-se, por um lado, mostrar como as funções introduzidas na secção anterior podem ser encaradas como formas de representação de populações e, por outro, relacionar aquelas funções com as distribuições dos dados amostrais. Só será considerado o caso das variáveis e dados discretos, que em nada de substancial difere do caso das variáveis e dados contínuos.

Comece-se por considerar o seguinte exemplo, no qual se define uma população.

Exemplo 4.12

Numa dada urbanização foram aplicadas 1400 lâmpadas incandescentes com três potências diferentes (75, 100 e 150 W). O número de lâmpadas de cada tipo é definido na Tabela 4.2.

Tabela 4.2
Caracterização da população constituída pelas lâmpadas aplicadas numa urbanização.

Tipo de lâmpada (Potência, em W)	Número de lâmpadas
75	350
100	700
150	350

A forma como as lâmpadas que constituem esta população se distribuem pelos três tipos pode ser caracterizada pela função de probabilidade da variável aleatória discreta «potência» (de uma lâmpada seleccionada ao acaso, de entre as 1400 lâmpadas). Tal função toma os valores seguintes:

$$p(75) = 350/1400 = 0.25$$

$$p(100) = 700/1400 = 0.50$$

$$p(150) = 350/1400 = 0.25.$$

Estabelecida a possibilidade de definir, através da função de probabilidade (ou, alternativamente, da função de distribuição), a forma como os elementos de uma população discreta se distribuem, é importante fazer uma observação relativa ao artificialismo deste exemplo.

Nele se admitiu que a população era conhecida *a priori*, ao contrário do que sucede na maioria das vezes, por exemplo por ser demasiado grande para poder ser caracterizada de uma forma completa. Nestas situações, não há possibilidade de caracterizar com rigor absoluto a população. A função de probabilidade assume o carácter de um **modelo** com o qual, de um modo mais ou menos aproximado, se pretende representar a forma como os elementos da população se distribuem.

Um procedimento intuitivo para estabelecer um tal modelo consiste em obter uma amostra aleatória de razoável dimensão e supor que ela é representativa da população (nesta altura, antes de ter sido estudada a inferência estatística, pode considerar-se como razoável a maior dimensão da amostra compatível com os recursos disponíveis para a recolha e tratamento desta). Uma vez obtida a distribuição dos dados amostrais, as frequências relativas desta distribuição são utilizadas como estimativas dos valores da função de probabilidade.

Exemplo 4.13

Admita-se que, relativamente à população definida no Exemplo 4.12, tinha sido recolhida uma amostra aleatória constituída por 280 lâmpadas e que a distribuição de frequências obtida era a que figura na Tabela 4.3.

Com base nesta amostra, a função de probabilidade da variável potência, que caracteriza a distribuição populacional, seria estimada da forma seguinte:

$$p(75) \approx f_{75} = 0.214$$

$$p(100) \approx f_{100} = 0.557$$

$$p(150) \approx f_{150} = 0.229.$$

Tabela 4.3
Distribuição de frequências das lâmpadas.

Tipo de lâmpada (Potência, em W)	Frequência absoluta	Frequência relativa
75	60	0.214
100	156	0.557
150	64	0.229

Neste processo de estimação da função de probabilidade através das frequências relativas amostrais — ou, no caso de variáveis e dados contínuos, no processo de estimação da função densidade de probabilidade pelo histograma — cometem-se, em geral, erros. Tais erros resultam, evidentemente, da variabilidade associada ao carácter aleatório da amostra, e a sua dispersão decrescerá à medida que a dimensão da amostra aumentar (anulando-se quando a amostra coincidir com a população). Uma amostra aleatória diferente da que foi considerada no Exemplo 4.13, da mesma dimensão ou de dimensão diferente, conduziria, em geral a frequências diferentes. Só haveria a garantia de que as frequências observadas fossem iguais aos valores da função de probabilidade, se a amostra coincidissem com a população (isto é, se tivesse a dimensão 1400).

É fundamental notar que, para uma dada população, enquanto a distribuição de probabilidade que lhe está associada é fixa, já as distribuições de frequências variam de amostra para amostra.

4.5 PARÂMETROS DAS DISTRIBUIÇÕES

Tal como as distribuições de frequências são susceptíveis de ser caracterizadas por estatísticas — anteriormente definidas como números que, calculados com base nos dados amostrais, permitiam, de uma forma sintética, identificar a configuração geral de tais distribuições —, também as distribuições associadas às populações (definidas pelas funções de probabilidade e densidade de probabilidade ou pela função de distribuição) podem ser caracterizadas por um conjunto de **parâmetros**.

Para uma dada população, os parâmetros das distribuições de probabilidade são fixos, em contraste com as estatísticas, que variam de amostra para amostra.

Como adiante se verá, para cada uma das estatísticas definidas, existe uma definição paralela do parâmetro correspondente. A designação do parâmetro é, em geral, idêntica à da estatística, podendo a distinção entre eles ser estabelecida, quando necessário, apelidando o parâmetro de «populacional» ou «da população» e a estatística de «amostral» ou «da amostra». Seguindo uma convenção habitual, os parâmetros serão denotados por letras do alfabeto grego (note-se que as estatísticas foram anteriormente denotadas por letras do nosso alfabeto).

4.5.1 PARÂMETROS DE LOCALIZAÇÃO

O parâmetro de localização mais utilizado na caracterização de distribuições populacionais é o **valor esperado** ou, como também é designado, a **média populacional**. A sua definição é a seguinte:

$$\mu_Y = E(Y) = \sum_y y \cdot p(y) \quad (\text{variáveis discretas}) \quad (4.17)$$

onde $p(y)$ representa a função de probabilidade da variável Y e o somatório é estendido a todos os valores que esta variável pode tomar, ou

$$\mu_X = E(X) = \int_{-\infty}^{+\infty} x \cdot f(x) \cdot dx \quad (\text{variáveis contínuas}) \quad (4.18)$$

onde $f(x)$ representa a função densidade de probabilidade da variável X .

É de realçar o paralelismo que existe entre a definição de valor esperado e a de média amostral. Tal paralelismo é particularmente óbvio quando se compara a expressão 4.17 com a expressão 2.5, anteriormente utilizada na definição da média amostral a partir de dados discretos agrupados. Enquanto que na primeira cada valor possível da variável é multiplicado pela respectiva probabilidade, na segunda cada valor que os dados tomam é multiplicado pela frequência observada na amostra. Ora, quando se aumenta a dimensão da amostra e esta tende para a população, as frequências observadas tendem para as probabilidades.

Para ilustrar o significado desta afirmação admita-se que, dos N elementos que constituem uma população finita, há N_y aos quais se associa um resultado comum traduzido pelo valor particular y da variável Y . De acordo com a definição clássica de probabilidade, para um elemento seleccionado ao acaso a partir da população, a probabilidade de a variável Y tomar um valor particular y é dada pelo número de casos favoráveis sobre o número de casos possíveis, ou seja

$$p(y) = \frac{N_y}{N}.$$

É imediato verificar que a probabilidade N_y/N é o limite da frequência observada de y numa amostra quando a dimensão desta tender para a da população.

Exemplo 4.14

- ◆ Considere-se a variável definida com base no Exemplo 4.12, Y = potência de uma lâmpada, e para a qual a função de probabilidade toma os seguintes valores:

$$p(75) = 350/1400 = 0.25$$

$$p(100) = 700/1400 = 0.50$$

$$p(150) = 350/1400 = 0.25.$$

O valor esperado vem dado por

$$\mu_Y = 75 \cdot 0.25 + 100 \cdot 0.50 + 150 \cdot 0.25 = 106.25 \text{ W}.$$

Registe-se que, apesar de o valor esperado representar o «centro de gravidade» em torno do qual a variável se distribui, esta nunca será igual àquele valor (pois apenas pode tomar os valores 75, 100 ou 150 W).

- ◆ Para a variável contínua T = tempo entre avarias, definida no Exemplo 4.8, o valor esperado pode ser obtido recorrendo a uma integração por partes

$$\begin{aligned} \mu_T &= \int_0^{+\infty} t \cdot (0.5 \cdot e^{-0.5 \cdot t}) \cdot dt \\ &= [-e^{-0.5 \cdot t} \cdot t]_0^{+\infty} - \int_0^{+\infty} (-e^{-0.5 \cdot t}) \cdot dt \\ &= 0 - \lim_{t \rightarrow \infty} (-e^{-0.5 \cdot t} \cdot t) - \left[\frac{1}{0.5} \cdot e^{-0.5 \cdot t} \right]_0^{+\infty} \\ &= 0 - 0 - (0 - 2) = 2 \text{ dias.} \end{aligned}$$

Os parâmetros de localização que constituem alternativas ao valor esperado são a **mediana da população** e a **moda da população**. Estes parâmetros são definidos a partir das funções de probabilidade e densidade de probabilidade (ou da função de distribuição), de forma idêntica àquela como a mediana e a moda amostrais foram definidas a partir das distribuições de frequências.

Para o caso de variáveis discretas, a **mediana** (η_Y) define-se nos seguintes termos: denotando por y_0 o valor mínimo que uma variável discreta Y pode tomar e por $F(y)$ a função de distribuição,

- (i) se $F(y_0) \geq 0.5$, a mediana é igual a y_0 , ou seja, $\eta_Y = y_0$;
- (ii) no caso contrário, $\eta_Y = y_1$, onde y_1 denota o valor particular de Y que satisfaz as seguintes condições:

$$F(y_1) \geq 0.5 \quad \text{e} \quad F(y_1^-) < 0.5,$$

onde y_1^- representa o valor particular de Y imediatamente inferior a y_1 .

Para o caso das variáveis contínuas, a definição da mediana é mais simples. Para uma variável contínua X , se, como sucede normalmente, a equação

$$F(x) = 0.5$$

só tiver uma solução, esta corresponde à mediana, η_X . Se existir mais do que uma solução para esta equação, a mediana será definida por

$$\eta_X = \frac{X_{\min} + X_{\max}}{2}$$

onde $X_{\min}$ e $X_{\max}$ representam, respectivamente, o mínimo e o máximo do conjunto de soluções.

Exemplo 4.15

- ◆ Cálculo da mediana para a variável Y = potência de uma lâmpada, definida com base no Exemplo 4.12:

$$F(y_0) = F(75) = 0.25 < 0.5$$

$$F(y_1) = F(100) = 0.75 > 0.5$$

$$\Rightarrow \eta_Y = y_1 = 100 \text{ W}$$

- ◆ Para a variável contínua T = tempo entre avarias, definida no Exemplo 4.8, a mediana é calculada resolvendo a seguinte equação:

$$\int_0^{\eta_T} 0.5 \cdot e^{-0.5 \cdot t} \cdot dt = 0.5$$

$$[-e^{-0.5 \cdot t}]_0^{\eta_T} = 0.5$$

$$-e^{-0.5 \cdot \eta_T} + 1 = 0.5$$

$$-e^{-0.5 \cdot \eta_T} = 0.5$$

$$-0.5 \cdot \eta_T = \ln(0.5)$$

$$\eta_T = -\frac{\ln(0.5)}{0.5} = 1.386.$$

O último parâmetro de localização considerado neste texto, a **moda**, será agora definido.

Para uma variável discreta, Y , a moda (ζ_Y) é o valor da variável para o qual a função de probabilidade toma um valor máximo. Se houver dois ou mais valores adjacentes da variável para os quais a probabilidade correspondente seja máxima, a moda será a média aritmética desses valores.

No caso de uma variável X ser contínua, a sua moda é o valor para o qual a função densidade de probabilidade toma o valor máximo.

Exemplo 4.16

Para as variáveis Y (com a função de probabilidade definida a partir do Exemplo 4.12) e T (com função densidade de probabilidade definida no Exemplo 4.8), os valores da moda são os seguintes:

$$\zeta_Y = 100 \text{ W} \quad \zeta_T = 0 \text{ dias.}$$


As definições apresentadas para a moda são válidas para as situações mais frequentes nas quais este parâmetro toma um só valor. É fácil generalizar as definições aos casos nos quais esta condição não se verifica.

A terminar este ponto respeitante aos parâmetros de localização, refere-se ainda que as suas posições relativas seguem o padrão anteriormente atribuído às estatísticas amostrais que lhe correspondem.

Exemplo 4.17

Na Figura 4.9 apresentam-se as posições relativas do valor esperado, da mediana e da moda para as distribuições das variáveis Y e T que foram objecto dos exemplos anteriores.

Figura 4.9
Posições relativas dos parâmetros de localização das distribuições das variáveis Y (definida com base no Exemplo 4.12) e T (definida no Exemplo 4.8).



4.5.2 PARÂMETROS DE DISPERSÃO

Apresentam-se seguidamente as definições de parâmetros que caracterizam a dispersão de distribuições de probabilidade. Crê-se que a sua interpretação não levanta qualquer dificuldade, uma vez que as definições das estatísticas correspondentes foram amplamente discutidas.

■ **Desvio absoluto médio (ou desvio médio) (δ):**

$$\delta_Y = \sum_y |y - \mu_Y| \cdot p(y) \quad (\text{variáveis discretas}) \quad (4.19)$$

$$\delta_X = \int_{-\infty}^{+\infty} |x - \mu_X| \cdot f(x) \cdot dx \quad (\text{variáveis contínuas}). \quad (4.20)$$

■ **Variância (σ^2):**

$$\sigma_Y^2 = \text{Var}(Y) = \sum_y (y - \mu_Y)^2 \cdot p(y) \quad (\text{variáveis discretas}) \quad (4.21)$$

$$\sigma_X^2 = \text{Var}(X) = \int_{-\infty}^{+\infty} (x - \mu_X)^2 \cdot f(x) \cdot dx \quad (\text{variáveis contínuas}). \quad (4.22)$$

■ **Desvio padrão (σ):**

$$\sigma = \sqrt{\sigma^2}. \quad (4.23)$$

Exemplo 4.18

Apresentam-se a seguir os cálculos dos parâmetros de dispersão para as distribuições das variáveis Y e T que foram objecto dos exemplos anteriores:

♦ Para a variável discreta Y :

$$\begin{aligned} \delta_Y &= |75 - 106.25| \cdot 0.25 + |100 - 106.25| \cdot 0.50 \\ &\quad + |150 - 106.25| \cdot 0.25 = 21.9 \text{ W} \\ \sigma_Y^2 &= (75 - 106.25)^2 \cdot 0.25 + (100 - 106.25)^2 \cdot 0.50 \\ &\quad + (150 - 106.25)^2 \cdot 0.25 = 742.2 \text{ W}^2 \\ \sigma_Y &= \sqrt{\sigma_Y^2} = \sqrt{742.2} = 27.2 \text{ W}. \end{aligned}$$

♦ Para a variável contínua T :

$$\begin{aligned} \delta_T &= \int_0^{+\infty} |t - \mu_T| \cdot f(t) \cdot dt \\ &= \int_0^{+\infty} |t - 2| \cdot f(t) \cdot dt \\ &= \int_0^2 (2 - t) \cdot f(t) \cdot dt + \int_2^{+\infty} (t - 2) \cdot f(t) \cdot dt \\ &= \int_0^2 (2 - t) \cdot (0.5 \cdot e^{-0.5 \cdot t}) \cdot dt + \int_2^{+\infty} (t - 2) \cdot (0.5 \cdot e^{-0.5 \cdot t}) \cdot dt \\ &= 0.736 + 0.736 \\ &= 1.471 \text{ dias}. \end{aligned}$$

$$\begin{aligned} \sigma_T^2 &= \int_{-\infty}^{+\infty} (t - \mu_T)^2 \cdot f(t) \cdot dt \\ &= \int_0^{+\infty} (t - 2)^2 \cdot (0.5 \cdot e^{-0.5 \cdot t}) \cdot dt \\ &= 4 \text{ dias}^2. \end{aligned}$$

$$\sigma_T = \sqrt{\sigma_T^2} = \sqrt{4} = 2 \text{ dias}.$$

Além dos parâmetros de dispersão que foram introduzidos, pode também ser definida, em termos populacionais, a **amplitude interquartil**. A definição desta amplitude, bem como as de percentil e de quartil, é absolutamente paralela às que foram introduzidas na definição das estatísticas de dispersão (ver Secção 2.3.2.2).

4.5.3 OUTROS PARÂMETROS

O valor esperado e a variância pertencem a uma família de parâmetros que se designam por **momentos populacionais**. A exemplo do que sucede no caso dos momentos amostrais, também existem dois tipos de momentos populacionais: os **momentos ordinários** e os **momentos centrados**. As suas definições são seguidamente apresentadas.

■ **Momentos ordinários de ordem i ($i = 1, 2, \dots$) (μ'_i):**

$$\mu'_i = \sum_y y^i \cdot p(y) \quad (\text{variáveis discretas}) \quad (4.24)$$

$$\mu'_i = \int_{-\infty}^{+\infty} x^i \cdot f(x) \cdot dx \quad (\text{variáveis contínuas}). \quad (4.25)$$

A partir destas expressões e da definição do valor esperado, é imediato concluir que este parâmetro corresponde ao momento populacional ordinário de primeira ordem, ou seja,

$$\mu'_1 = \mu.$$

■ **Momentos centrados de ordem i ($i = 1, 2, \dots$) (μ_i):**

$$\mu_i = \sum_y (y - \mu_Y)^i \cdot p(y) \quad (\text{variáveis discretas}) \quad (4.26)$$

$$\mu_i = \int_{-\infty}^{+\infty} (x - \mu_X)^i \cdot f(x) \cdot dx \quad (\text{variáveis contínuas}). \quad (4.27)$$

A partir destas definições é imediato concluir que o momento centrado de primeira ordem é sempre nulo e que o de segunda ordem é a variância populacional:

$$\mu_1 = 0 \quad \mu_2 = \sigma^2.$$

A exemplo do que sucede com os momentos amostrais, também existem relações de interdependência entre os momentos populacionais, centrados e ordinários. De facto, qualquer momento centrado de ordem i pode exprimir-se em função dos momentos ordinários de ordem não superior a i . Para os momentos centrados de ordem 2, 3 e 4, observam-se as seguintes relações:

$$\mu_2 = \mu'_2 - (\mu'_1)^2 \quad (4.28)$$

$$\mu_3 = \mu'_3 - 3 \cdot \mu'_2 \cdot \mu'_1 + 2 \cdot (\mu'_1)^3$$

$$\mu_4 = \mu'_4 - 4 \cdot \mu'_3 \cdot \mu'_1 + 6 \cdot \mu'_2 \cdot (\mu'_1)^2 - 3 \cdot (\mu'_1)^4.$$

Registe-se o paralelismo perfeito que existe entre estas expressões e aquelas que foram apresentadas no Capítulo 2 para os momentos amostrais (por exemplo, entre as expressões 2.25 e 4.28).

A propósito dos momentos populacionais, deve notar-se que existem distribuições para as quais alguns ou mesmo todos os momentos não podem ser definidos.

Exemplo 4.19

Para a distribuição de Cauchy, definida pela função densidade de probabilidade

$$f(x) = \left(\frac{1}{\pi}\right) \cdot \frac{\alpha}{\alpha^2 + x^2} \quad (\text{com } -\infty < x < +\infty \text{ e } \alpha > 0),$$

é possível demonstrar que o valor esperado e a variância não existem (ou, se se preferir, tomam valores infinitos).

Por outro lado, deve observar-se que, uma vez que cada distribuição determina um conjunto de momentos (quando estes existam), é condição necessária, para que duas distribuições sejam iguais, que tenham a mesma sequência de momentos populacionais.

No entanto, em geral, esta condição não é suficiente, pois uma sequência de momentos não determina univocamente uma distribuição. Para que tal suceda, há que garantir a existência de uma função que se designa por **função geradora de momentos**. Esta função encontra-se definida no Apêndice A4.1.

Na prática, raramente se calculam momentos para ordens superiores a 4, pois, por um lado, tais momentos são difíceis de obter e de interpretar e, por outro, a igualdade dos momentos de ordem não superior a quatro é, normalmente, uma condição suficiente para que duas distribuições sejam aproximadamente iguais.

Os momentos de terceira e quarta ordem (o desvio cúbico médio, μ_3 , e o desvio quártico médio, μ_4) medem a assimetria e a kurtose das distribuições populacionais. A partir destes momentos, podem definir-se, a exemplo do que se passa com os momentos amostrais, os **coeficientes populacionais de assimetria e de kurtose**:

$$\gamma_1 = \frac{\mu_3}{\sigma^3} \quad (4.29)$$

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3. \quad (4.30)$$

Exemplo 4.20

Apresentam-se a seguir os valores dos parâmetros de assimetria e kurtose das distribuições das variáveis Y e T que foram objecto dos exemplos anteriores:

◆ Para a variável discreta Y :

$$\begin{aligned} \mu_3 &= \sum_y (y - \mu_Y)^3 \cdot p(y) \\ &= \sum_y (y - 106.25)^3 \cdot p(y) = 1.318 \cdot 10^4 \text{ W}^3 \end{aligned}$$

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{1.318 \cdot 10^4}{27.2^3} = 0.655$$

$$\begin{aligned} \mu_4 &= \sum_y (y - \mu_Y)^4 \cdot p(y) \\ &= \sum_y (y - 106.25)^4 \cdot p(y) = 1.155 \cdot 10^6 \text{ W}^4 \end{aligned}$$

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3 = \frac{1.155 \cdot 10^6}{27.2^4} - 3 = -0.890.$$

◆ Para a variável contínua T :

$$\begin{aligned} \mu_3 &= \int_0^{+\infty} (t - \mu_T)^3 \cdot f(t) \cdot dt \\ &= \int_0^{+\infty} (t - 2)^3 \cdot (0.5 \cdot e^{-0.5 \cdot t}) \cdot dt = 16 \text{ dias}^3 \end{aligned}$$

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{16}{2^3} = 2$$

$$\begin{aligned} \mu_4 &= \int_0^{+\infty} (t - \mu_T)^4 \cdot f(t) \cdot dt \\ &= \int_0^{+\infty} (t - 2)^4 \cdot (0.5 \cdot e^{-0.5 \cdot t}) \cdot dt = 144 \text{ dias}^4 \end{aligned}$$

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3 = \frac{144}{2^4} - 3 = 6.$$

4.6 VARIÁVEIS TRANSFORMADAS

4.6.1 TRANSFORMAÇÃO DE VARIÁVEIS ALEATÓRIAS

Considere-se uma variável aleatória qualquer Z , discreta ou contínua, e admita-se que os seus valores particulares são transformados por aplicação de uma função $\phi(Z)$. Como resultado desta operação, fica definida uma nova variável aleatória:

$$W = \phi(Z).$$

Exemplo 4.21

Considere-se a variável Y = potência de uma lâmpada definida no Exemplo 4.12 e recorde-se que a sua função de probabilidade é

$$p_Y(75) = 350/1400 = 0.25$$

$$p_Y(100) = 700/1400 = 0.50$$

$$p_Y(150) = 350/1400 = 0.25.$$

Admita-se que se pretende operar uma mudança da escala na qual a potência das lâmpadas estava originalmente expressa, por introdução da seguinte transformação:

$$W = \frac{Y - 100}{25} = \frac{1}{25} \cdot Y - 4.$$

A variável transformada, W , pode tomar os valores seguintes, com as probabilidades indicadas:

$$w_1 = \frac{75 - 100}{25} = -1 \quad p_W(-1) = p_Y(75) = 0.25$$

$$w_2 = \frac{100 - 100}{25} = 0 \quad p_W(0) = p_Y(100) = 0.50$$

$$w_3 = \frac{150 - 100}{25} = 2 \quad p_W(2) = p_Y(150) = 0.25.$$

4.6.2 OS MOMENTOS POPULACIONAIS DEFINIDOS COMO VALORES ESPERADOS DE VARIÁVEIS TRANSFORMADAS

Considere-se uma variável aleatória qualquer Z e, a partir dela, definam-se as variáveis transformadas

$$W_1 = Z^i \text{ e } W_2 = (Z - \mu_Z)^i$$

onde i representa um número inteiro qualquer. Admitindo, por exemplo, que a variável Z e, consequentemente, as variáveis W_1 e W_2 são inteiras, os valores esperados destas variáveis são dados pelas expressões seguintes:

$$E(W_1) = E(Z^i) = \sum_{w_1} w_1 \cdot p_{W_1}(w_1) = \sum_z z^i \cdot p_Z(z)$$

$$E(W_2) = E[(Z - \mu_Z)^i] = \sum_{w_2} w_2 \cdot p_{W_2}(w_2) = \sum_z (Z - \mu_Z)^i \cdot p_Z(z).$$

Os últimos termos destas expressões correspondem aos momentos de ordem i (ordinário e centrado) da variável Z . Daí que tais momentos possam ser definidos como os valores esperados das variáveis transformadas W_1 e W_2 , respectivamente. Em notação simbólica, vem

$$\mu'_i(Z) = E(Z^i) \quad (4.31)$$

$$\mu_i(Z) = E[(Z - \mu_Z)^i] \quad (4.32)$$

Estas expressões foram obtidas considerando apenas o caso de variáveis discretas. É imediato verificar que se aplicam também ao caso de variáveis contínuas.

4.6.3 DISTRIBUIÇÃO DAS VARIÁVEIS TRANSFORMADAS: CÁLCULO DO VALOR ESPERADO E DA VARIÂNCIA

Para qualquer transformação de variável $W = \phi(Z)$, é possível definir, a partir de cada valor da variável original, o valor correspondente da variável transformada e, por esta via, especificar a distribuição desta variável (tal foi efectuado no exemplo anterior, no qual se especificou $p_W(w)$ a partir de $p_Y(y)$). Uma vez especificada a distribuição da variável transformada, é possível calcular os parâmetros desta distribuição.

Exemplo 4.22

Para a variável W , definida no exemplo anterior, apresenta-se seguidamente o cálculo do seu valor esperado e da sua variância a partir da distribuição de probabilidade $p_W(w)$:

$$\mu_W = (-1) \cdot 0.25 + 0 \cdot 0.50 + 2 \cdot 0.25 = 0.25$$

$$\sigma_W^2 = (-1 - 0.25)^2 \cdot 0.25 + (0 - 0.25)^2 \cdot 0.50 + (2 - 0.25)^2 \cdot 0.25 = 1.1875.$$

Sucede, no entanto, que o valor esperado e a variância, os dois mais importantes parâmetros da distribuição da variável transformada, podem ser calculados directamente, pelo menos de uma forma aproximada, a partir dos parâmetros correspondentes da distribuição da variável original. Mostrar-se-á seguidamente a forma como este cálculo pode ser efectuado, considerando primeiro o caso das transformações lineares e depois o das transformações não-lineares.

4.6.3.1 TRANSFORMAÇÕES LINEARES

Considere-se a transformação linear

$$W = \phi(Z) = a + b \cdot Z.$$

Tomando, por exemplo, o caso de uma variável transformada discreta, W , da definição de valor esperado resulta:

$$\begin{aligned} E(W) &= \sum_w w \cdot p_W(w) = \sum_z \phi(z) \cdot p_Z(z) \\ &= \sum_z (a + b \cdot z) \cdot p_Z(z) = a \cdot \sum_z p_Z(z) + b \cdot \sum_z z \cdot p_Z(z) \\ &= a \cdot 1 + b \cdot E(Z) \end{aligned}$$

ou seja,

$$E(W) = E[\phi(Z)] = E(a + b \cdot Z) = a + b \cdot E(Z) = \phi[E(Z)]. \quad (4.33)$$



Tomando ainda o caso de uma variável transformada discreta, considere-se agora o desenvolvimento da definição de variância:

$$\begin{aligned}\text{Var}(W) &= \sum_w [w - \mu_w]^2 \cdot p_w(w) = \sum_z [\phi(z) - \phi(\mu_z)]^2 \cdot p_z(z) \\ &= \sum_z [(a + b \cdot z) - (a + b \cdot \mu_z)]^2 \cdot p_z(z) = b^2 \cdot \sum_z (z - \mu_z)^2 \cdot p_z(z)\end{aligned}$$

ou seja,

$$\text{Var}(W) = \text{Var}(a + b \cdot Z) = b^2 \cdot \text{Var}(Z). \quad (4.34)$$

Esta expressão, que se aplica também ao caso das variáveis contínuas, permite então calcular a variância da variável transformada directamente a partir da variância da variável original.

Exemplo 4.23

Cálculo do valor esperado e da variância da variável transformada W (definida no Exemplo 4.21), com base nos parâmetros correspondentes da variável original, Y :

$$\mu_Y = 106.25 \quad (\text{ver Exemplo 4.14})$$

$$\sigma_Y^2 = 742.2 \quad (\text{ver Exemplo 4.18})$$

$$W = \frac{Y - 100}{25} = \frac{1}{25} \cdot Y - 4 \quad (\text{ver Exemplo 4.21})$$

$$E(W) = \frac{\mu_Y - 100}{25} = \frac{106.25 - 100}{25} = 0.25$$

$$\text{Var}(W) = b^2 \cdot \text{Var}(Y) = \left(\frac{1}{25}\right)^2 \cdot 742.2 = 1.1875.$$

Os valores de $E(W)$ e $\text{Var}(W)$ são, naturalmente, idênticos aos obtidos a partir da distribuição de W (ver Exemplo 4.22).

4.6.3.2 TRANSFORMAÇÕES NÃO-LINEARES

Considere-se agora o caso no qual a transformação

$$W = \phi(Z)$$

é não-linear.

Para esta transformação, $E(W)$ e $\text{Var}(W)$ dependerão, em geral, não só do valor esperado e da variância de Z mas também de momentos de ordem superior desta variável.

Exemplo 4.24

Considere-se o caso de uma transformação quadrática,

$$W = a + b \cdot Z + c \cdot Z^2.$$

Admitindo, por exemplo, que as variáveis Z e W são discretas, da definição de valor esperado de W resulta:

$$E(W) = \sum_w w \cdot p_w(w) = \sum_y (a + b \cdot y + c \cdot y^2) \cdot p_Y(y) = a + b \cdot E(Y) + c \cdot (\mu'_2)_Y.$$

Seria fácil de verificar que $\text{Var}(W)$ depende, neste caso da transformação quadrática, dos momentos de ordem 1 a 4 da variável original, Y .

Sucedem frequentemente que as transformações não-lineares de uma variável qualquer Z podem ser aproximadas, em torno de μ_Z , por relações lineares. Nestas condições, e considerando a transformação $W = \phi(Z)$, o desenvolvimento em série de Taylor da função $\phi(Z)$ em torno de μ_Z ,

$$\phi(Z) = \phi(\mu_Z) + (Z - \mu_Z) \cdot \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z} + \frac{(Z - \mu_Z)^2}{2!} \cdot \left[\frac{d^2\phi}{dZ^2} \right]_{Z=\mu_Z} + \dots,$$

pode escrever-se

$$\phi(Z) \approx \phi(\mu_Z) + (Z - \mu_Z) \cdot \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z}. \quad (4.35)$$

Na Figura 4.10 representa-se graficamente o significado desta aproximação linear. Notando que, na expressão 4.35,

$$\mu_Z, \phi(\mu_Z) \text{ e } \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z}$$

representam constantes (dado que o parâmetro μ_Z é fixo), aquela expressão pode escrever-se na forma

$$W = \phi(Z) \approx a + b \cdot Z$$


onde a e b são constantes dadas por

$$a = \phi(\mu_Z) - \mu_Z \cdot \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z} \quad (4.36)$$

e

$$b = \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z}. \quad (4.37)$$

Figura 4.10
Aproximação linear
de $\phi(Z)$ em torno
de μ_Z



As expressões do valor esperado da variável transformada e da sua variância podem ser obtidas a partir das expressões aplicáveis ao caso das transformações lineares (expressões 4.33 e 4.34), nelas substituindo as constantes a e b pelas suas expressões 4.36 e 4.37. Para o valor esperado, obtém-se

$$\begin{aligned} E(W) &= E[\phi(Z)] \approx a + b \cdot E(Z) \\ &\approx a + b \cdot \mu_Z \\ &\approx \left\{ \phi(\mu_Z) - \mu_Z \cdot \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z} \right\} + \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z} \cdot \mu_Z \\ &\approx \phi(\mu_Z) \\ &\approx \phi[E(Z)] \end{aligned}$$

ou, resumindo,

$$E(W) = E[\phi(Z)] \approx \phi[E(Z)]. \quad (4.38)$$

Para a variância, obtém-se

$$\text{Var}(W) = \text{Var}[\phi(Z)] \approx b^2 \cdot \text{Var}(Z) = \left[\frac{d\phi}{dZ} \right]_{Z=\mu_Z}^2 \cdot \text{Var}(Z). \quad (4.39)$$

Exemplo 4.25

Considere-se uma variável Z com os seguintes parâmetros

$$\mu_Z = 4 \quad \sigma_Z^2 = 0.5,$$

e calcule-se o valor esperado e a variância da variável

$$W = f(Z) = 2 \cdot Z^2.$$

Os valores de $E(W)$ e $\text{Var}(W)$ vêm

$$E(W) = E(2 \cdot Z^2) \approx 2 \cdot \mu_Z^2 = 2 \cdot 4^2 = 32$$


$$\frac{dW}{dZ} = \frac{d(2 \cdot Z^2)}{dZ} = 4 \cdot Z \Rightarrow \left[\frac{dW}{dZ} \right]_{Z=4} = 16$$

$$\text{Var}(W) \approx \left[\left[\frac{dW}{dZ} \right]_{Z=4} \right]^2 \cdot \text{Var}(Z) = 16^2 \cdot 0.5 = 128.$$


As expressões 4.38 e 4.39 corresponderão a aproximações tanto melhores quanto menor for a curvatura da função $\phi(Z)$ em torno de μ_Z e quanto menor for a dispersão da distribuição da variável Z . Na Figura 4.11 apresenta-se um caso no qual a aproximação linear é razoável (diagrama (i)) e um outro no qual tal aproximação deve ser evitada (diagrama (ii)).


Figura 4.11
Aproximação de uma transformação não-linear por uma transformação linear.

(i) Aproximação linear mais adequada



(ii) Aproximação linear menos adequada





■ APÊNDICE 4.1 FUNÇÃO GERADORA DE MOMENTOS

- (1) Seja Z uma variável aleatória qualquer (discreta ou contínua). Se existir um número positivo h tal que se possa definir a função

$$G(t) = E[e^{t \cdot Z}] \quad (\text{A4.1.1})$$

para qualquer $t \in]-h, h[$, tal função designa-se por **função geradora de momentos** da variável Z . Pode demonstrar-se que, se esta função existir, então é contínua e diferenciável em torno de $t = 0$.

- (2) Calculem-se as duas primeiras derivadas da função $G(t)$ em ordem a t :

$$G'(t) = \frac{d}{dt} E[e^{t \cdot Z}] = E\left[\frac{d}{dt}(e^{t \cdot Z})\right] = E[Z \cdot e^{t \cdot Z}]$$

$$G''(t) = \frac{d}{dt} G'(t) = \frac{d}{dt} E[Z \cdot e^{t \cdot Z}] = E\left[\frac{d}{dt} Z \cdot e^{t \cdot Z}\right] = E[Z^2 \cdot e^{t \cdot Z}].$$

- (3) Os valores que $G'(t)$ e que $G''(t)$ tomam em $t = 0$ são


$$G'(0) = E[Z], \quad G''(0) = E[Z^2], \quad (\text{A4.1.2})$$

correspondendo portanto aos momentos ordinários de primeira e de segunda ordem (ver expressão 4.31).

- (4) Em geral,

$$G^{(i)}(0) = E[Z^i], \quad (\text{com } i \geq 1) \quad (\text{A4.1.3})$$

- (5) A função $G(t)$ deve a sua designação (e o seu interesse) à propriedade expressa na expressão A4.1.3, pois, a partir dela, é possível gerar todos os momentos ordinários de uma qualquer variável aleatória Z e, com base nestes, calcular os momentos centrados.



- 4.1. Uma empresa de fiscalização de obras de construção civil tem 7 fiscais, dos quais 2 são do sexo feminino. Para visitar as obras de uma ponte ferroviária, foram seleccionados ao acaso dois fiscais. Denote-se por Y o número de mulheres seleccionadas.

- Defina o espaço amostral da experiência, designando os fiscais por A, ..., E (homens) e F, G (mulheres).
- Defina o valor da variável aleatória, Y , para cada elemento do espaço amostral.
- Defina as funções de probabilidade e de distribuição da variável Y . Represente ambas as funções na forma tabular e através de diagramas de barras.
- Calcule o valor esperado, o desvio padrão e o coeficiente de assimetria da variável Y .

- 4.2. Num balcão de uma companhia de aviação, o intervalo de tempo, Δt [minutos], que separa duas quaisquer chamadas consecutivas para reserva de voos, tem a seguinte função densidade de probabilidade:

$$f(\Delta t) = \begin{cases} e^{-\Delta t}, & \text{para } \Delta t \geq 0 \\ 0, & \text{para } \Delta t < 0. \end{cases}$$

- Calcule a probabilidade $P(\Delta t > 2)$.
- Calcule a probabilidade $P(\Delta t > 3)$.
- Calcule a probabilidade condicional de $\Delta t > 3$, dado que $\Delta t > 1$ (compare esta probabilidade com a obtida em (i) e procure generalizar a relação entre elas).

- 4.3. Admita que, para acções de uma determinada empresa cotada na bolsa de Nova Iorque, o lucro anual por acção, depois de impostos, aqui denotado por x [US \$], tem a seguinte função densidade de probabilidade:

$$f(x) = \begin{cases} (4/27) \cdot (9x - 6x^2 + x^3), & \text{para } 0 \leq x \leq 3 \\ 0, & \text{para outros valores de } x \end{cases}$$

- Represente graficamente esta função.
- Calcule as probabilidades seguintes:

$$P(x \leq 1.50), \quad P(x \geq 2) \quad \text{e} \quad P(1.00 \leq x \leq 2.5).$$

- Calcule a função de distribuição $F(x)$ e represente-a graficamente.

- 4.4. Admita que, num determinado processo de fabrico, a temperatura da água registada no início de cada turno no reservatório «R» segue uma distribuição com valor esperado 153°F e desvio padrão 7°F. Calcule estes dois parâmetros da distribuição da temperatura quando esta for expressa em °C.

- 4.5. Numa determinada barragem, a relação entre a cota a montante e o volume de água armazenada na albufeira é a seguinte:

$$N = 75.22 + 0.2511 \cdot V - 0.000481 \cdot V^2 + 0.386 \cdot 10^{-6} \cdot V^3$$

onde

$$N: \text{cota a montante [m]} \quad V: \text{volume de água armazenada [10}^6 \text{ m}^3].$$

No fim do mês de Março, contempla-se a possibilidade de efectuar uma reparação que impede a utilização dos grupos geradores. Durante a reparação, que decorrerá ao longo de um período de 3 meses, o volume de água que afluirá à albufeira, ΔV (expresso em 10^6 m^3), segue uma distribuição com valor esperado $\mu = 20$ e variância $\sigma^2 = 225$.

Admitindo que, no início da reparação, o volume de água armazenada na barragem é $V_0 = 400 \cdot 10^6 \text{ m}^3$, calcule o valor esperado e o desvio padrão da cota a montante no fim da reparação, se no decurso desta não for descarregado qualquer caudal.

- 4.6. No planeamento de um concerto ao ar livre, programado para o dia 6 de Maio, a organização considera que a adesão do público depende do estado do tempo. Na tabela seguinte apresentam-se as estimativas do número de espectadores em função do estado do tempo. Foi ainda pedido ao instituto de meteorologia informação relativa ao estado do tempo no mês de Maio durante os últimos 10 anos.

Estado do tempo	Probabilidade de ocorrência [%]	Estimativa do n.º de espectadores
Húmido e frio	20	5 000
Húmido e quente	20	20 000
Seco e frio	10	30 000
Seco e quente	50	50 000

- (i) Qual o valor esperado do número de espectadores?
- (ii) Considere que os bilhetes vão ser vendidos a 4,5 € cada. Os custos associados à limpeza e à segurança da área do concerto são de 1,0 € por cada bilhete vendido. Sabe-se que o grupo musical cobra 75 000 € e que a organização do concerto custará 30 000 € (valor que inclui os custos de aluguer de espaço). Sabendo que os organizadores do concerto pretendem ter lucro, recomendaria avançar com o concerto? Justifique.
- (iii) Suponha que a organização decidiu avançar com a preparação do concerto. Na semana anterior à realização do concerto a previsão do tempo não é favorável, de tal forma que os quatro tipos de condições meteorológicas têm agora as seguintes probabilidades estimadas:

Estado do tempo	Probabilidade de ocorrência [%]
Húmido e frio	30
Húmido e quente	20
Seco e frio	20
Seco e quente	30

Se o concerto for cancelado, a organização terá de pagar metade dos custos de organização mais 7500 € ao grupo musical devido ao cancelamento do concerto. Nestas condições, recomendaria avançar ou cancelar o concerto?


- 4.7. Uma empresa de veículos de aluguer possui três veículos com idades e estados de conservação diferentes. Considere as seguintes probabilidades associadas à disponibilidade num determinado dia:

Veículo mais novo: 0,95 Veículo mais antigo: 0,85 Terceiro veículo: 0,9

A disponibilidade de um dado veículo não é afectada pelo facto de cada um dos outros estar, ou não, disponível.

- (i) Defina a função de probabilidade e a função de distribuição para a variável «número de veículos disponíveis por dia».
- (ii) Calcule o valor esperado e o desvio padrão da variável definida na alínea anterior.
- (iii) Admitindo que o lucro líquido relativo à utilização de cada veículo é de 50 euros por dia, calcule o valor esperado e o desvio padrão do lucro líquido por dia.

5



Distribuições Conjuntas de Probabilidade

5.1 INTRODUÇÃO

Tal como se observou no capítulo anterior (Secção 4.1, Exemplos 4.2 e 4.3), a partir de um mesmo espaço amostral podem ser definidas diferentes variáveis aleatórias. Ora sucede que no estudo de muitas experiências aleatórias é necessário caracterizar diferentes variáveis, pondo em evidência não só as suas propriedades individuais mas também as propriedades conjuntas (isto é, aquelas que dizem respeito à forma como tais variáveis se encontram associadas).

A caracterização destas propriedades requer a introdução de um conjunto de conceitos que derivam do de **distribuição conjunta de probabilidade**. Embora neste capítulo tais conceitos sejam analisados considerando fundamentalmente o caso de duas variáveis, em algumas situações aqueles conceitos são generalizados ao caso de um número qualquer de variáveis.

5.2 DISTRIBUIÇÕES CONJUNTAS

Para introduzir o conceito de distribuição conjunta, comece-se por considerar o seguinte exemplo.

Exemplo 5.1

Considere-se uma população constituída pelos pares ordenados de alturas e pesos de 7 indivíduos (A, B, ..., G), conforme se representa na Tabela 5.1, e admita-se que a partir desta população é seleccionado um elemento ao acaso.

Tabela 5.1
Alturas e pesos
que constituem
a população
(Exemplo 5.1).

Elementos da população	Altura [m]	Peso [kg]
A	1.73	75
B	1.76	75
C	1.76	75
D	1.78	76
E	1.78	77
F	1.78	79
G	1.82	81

Denotem-se por H e W as variáveis aleatórias que designam a altura e o peso selecionados. De acordo com a definição introduzida no capítulo anterior, as funções (individuais) de probabilidade destas variáveis discretas vêm dadas pelos seguintes valores:

- Variável altura:

$$p_H(1.73) = 1/7 \quad p_H(1.76) = 2/7 \quad p_H(1.78) = 3/7 \quad p_H(1.82) = 1/7$$

- Variável peso:

$$p_W(75) = 3/7 \quad p_W(76) = 1/7 \quad p_W(77) = 1/7 \quad p_W(79) = 1/7 \quad p_W(81) = 1/7.$$

Para as variáveis altura e peso (ou, em geral, para duas quaisquer variáveis discretas H e W), designa-se por **função conjunta de probabilidade**, e denota-se por $p_{H,W}(h,w)$, a função que associa a cada par de valores particulares h e w a probabilidade de, simultaneamente, H ser igual a h e W ser igual a w . Em notação simbólica, aquela função conjunta de probabilidade é definida pela expressão

$$\forall h, w: p_{H,W}(h, w) = \text{Probabilidade } (H = h \wedge W = w) = P(H = h, W = w). \quad (5.1)$$

O somatório dos valores da função de probabilidade estendido a todas as combinações possíveis de H e W é naturalmente igual à unidade, ou seja,

$$\sum_h \sum_w p_{H,W}(h, w) = 1. \quad (5.2)$$

Para o caso particular das variáveis anteriormente definidas, os valores da função conjunta podem obter-se a partir da Tabela 5.1. Por exemplo,

$$p_{H,W}(1.73, 75) = 1/7; \quad p_{H,W}(1.76, 75) = 2/7.$$

A função conjunta de probabilidade de H e W encontra-se globalmente representada na Tabela 5.2.


Tabela 5.2
Representação
tabular da função
conjunta de
probabilidade de H
e W (Exemplo 5.1).

		W [kg]				
		75	76	77	79	81
H [m]	1.73	1/7	0	0	0	0
	1.76	2/7	0	0	0	0
	1.78	0	1/7	1/7	1/7	0
	1.82	0	0	0	0	1/7

No exemplo anterior, as variáveis H e W eram discretas. No entanto, se a população, em vez de ser constituída por 7 elementos, fosse constituída por um número muito elevado de elementos (por exemplo, se se tratasse das alturas e pesos dos portugueses adultos), seria mais conveniente tratar a altura e o peso como variáveis contínuas. Em casos como este, para descrever a distribuição conjunta de duas variáveis contínuas X e Y , haveria que recorrer ao conceito de **função conjunta de densidade de probabilidade**. Tal função, aqui denotada por $f_{X,Y}(x, y)$, é tal que

$$\forall x, y: \text{Probabilidade } \{X \in [x, x + dx] \wedge Y \in [y, y + dy]\} = f_{X,Y}(x, y) \cdot dx \cdot dy. \quad (5.3)$$

Figura 5.1
Representação
gráfica da função
conjunta
de densidade de
probabilidade de X
e Y (Exemplo 5.2).



Exemplo 5.2

Na Figura 5.1 representa-se a função conjunta de densidade de probabilidade das variáveis X e Y , que, para um jogador profissional de golfe, definem a posição final da bola em torno de um buraco, após a pancada de aproximação. A origem do plano (X, Y) representa a posição do buraco (neste caso, o número 13).

A probabilidade de um par ordenado (X, Y) pertencer a um domínio qualquer D (incluído no conjunto $\mathbb{R}^2$ constituído por todos os pares ordenados de números reais) vem dada por

$$\text{Probabilidade } \{(X, Y) \in D\} = \iint_D f_{X,Y}(x, y) \cdot dx \cdot dy. \quad (5.4)$$

O integral duplo que figura nesta expressão representa, no espaço $[X, Y, f_{X,Y}(x, y)]$, o volume de um tronco cilíndrico cuja base é o domínio D definido no plano (X, Y) e que é limitado superiormente pela superfície $f_{X,Y}(x, y)$. O volume total situado entre o plano (X, Y) e a superfície $f_{X,Y}(x, y)$ é igual à unidade, ou seja,

$$\iint_{\mathbb{R}^2} f_{X,Y}(x, y) \cdot dx \cdot dy = 1. \quad (5.5)$$

Até agora foram considerados casos nos quais as variáveis eram ambas discretas ou ambas contínuas. As definições introduzidas anteriormente podem ser facilmente adaptadas ao caso em que uma variável é discreta e a outra contínua. Se se admitir que Z é uma variável contínua e N uma variável discreta, a função conjunta de densidade de probabilidade de Z e N , denotada por $f_{Z,N}(z, n)$, é tal que


$$\forall z, n: \text{Probabilidade } \{Z \in [z, z + dz] \wedge N = n\} = f_{Z,N}(z, n) \cdot dz. \quad (5.6)$$

Exemplo 5.3

Na Figura 5.2 apresenta-se a função conjunta de densidade de probabilidade das variáveis seguintes:

- ♦ Z : energia consumida por um comboio de passageiros na ligação entre duas cidades
- ♦ N : número de carruagens que integram o comboio (que se admite serem 6, 7 ou 8, dependendo da procura e da disponibilidade de material circulante).

Figura 5.2
Representação gráfica da função conjunta de densidade de probabilidade de Z e N (Exemplo 5.3).



A soma das áreas assinaladas a sombreado nesta figura é igual à unidade. Em geral, virá

$$\sum_n \left[\int_{-\infty}^{\infty} f_{Z,N}(z, n) \cdot dz \right] = \sum_n \left[\int_{\mathbb{R}} f_{Z,N}(z, n) \cdot dz \right] = 1. \quad (5.7)$$

5.3 DISTRIBUIÇÕES MARGINAIS

Para introduzir o conceito de distribuição marginal, considere-se de novo o Exemplo 5.1 e a distribuição conjunta das variáveis H e W (a função conjunta de probabilidade, $p_{H,W}(h, w)$, foi definida anteriormente na Tabela 5.2).

Tomando, por exemplo, a variável H , calcule-se a probabilidade de esta tomar o valor 1.78 m:

$$P(H = 1.78) = p_{H,W}(1.78, 75) + p_{H,W}(1.78, 76) + p_{H,W}(1.78, 77) + p_{H,W}(1.78, 79) + p_{H,W}(1.78, 81) = 0 + 1/7 + 1/7 + 1/7 + 0 = 3/7.$$

Este é o valor da função de probabilidade da variável H , calculado para $H = 1.78$, ou seja, é o valor de $p_H(1.78)$. Os restantes valores da função de probabilidade $p_H(h)$ e os da função de probabilidade $p_W(w)$ podem ser obtidos de modo idêntico, através das expressões seguintes:

$$\begin{aligned} \forall h: p_H(h) &= \sum_w p_{H,W}(h, w) \\ \forall w: p_W(w) &= \sum_h p_{H,W}(h, w). \end{aligned} \quad (5.8)$$

Quando a função de probabilidade de cada uma das variáveis é obtida a partir da função conjunta, designa-se por **função marginal de probabilidade**. Note-se que além do procedimento através do qual é obtida, nada distingue esta função marginal de uma variável da função de probabilidade dessa variável, tal como foi definida no capítulo anterior.

Exemplo 5.4

Na Tabela 5.3 encontram-se definidas a função conjunta e as funções marginais de probabilidade das variáveis H e W correspondentes ao Exemplo 5.1.

Tabela 5.3
Representação tabular da função conjunta e das funções marginais de probabilidade de H e W (Exemplo 5.1).

		W [kg]					
		75	76	77	79	81	$P_H(h)$
H (m)	1.73	1/7	0	0	0	0	1/7
	1.76	2/7	0	0	0	0	2/7
	1.78	0	1/7	1/7	1/7	0	3/7
	1.82	0	0	0	0	1/7	1/7
$p_W(w)$		3/7	1/7	1/7	1/7	1/7	

O conceito de distribuição marginal pode ser generalizado aos casos nos quais uma ou as duas variáveis são contínuas.

Se se admitir que duas variáveis aleatórias X e Y são contínuas, as **funções marginais de densidade de probabilidade** são definidas através das expressões seguintes:

$$\begin{aligned} \forall x: f_X(x) &= \int_{\mathbb{R}} f_{X,Y}(x, y) \cdot dy \\ \forall y: f_Y(y) &= \int_{\mathbb{R}} f_{X,Y}(x, y) \cdot dx. \end{aligned} \quad (5.9)$$

Considerando agora o caso em que Z é uma variável contínua e N é uma variável discreta, podem definir-se as seguintes funções:

- Função marginal de densidade de probabilidade de Z :

$$\forall z: f_Z(z) = \sum_n f_{Z,N}(z, n). \quad (5.10)$$

- Função marginal de probabilidade de N :

$$\forall n: p_N(n) = \int_{\mathbb{R}} f_{Z,N}(z, n) \cdot dz. \quad (5.11)$$

Exemplo 5.5

Para interpretar o significado destas funções, atente-se na Figura 5.2, que correspondia ao Exemplo 5.3. A primeira função (que é uma função densidade) obtém-se somando, para cada valor de Z , os valores da função conjunta de densidade definidos para os três valores de N . Cada valor da segunda função (que é uma função de probabilidade) corresponde a uma das áreas representadas a sombreado na referida figura (naturalmente, a soma destas áreas é igual à unidade).

5.4 DISTRIBUIÇÕES CONDICIONAIS

Para introduzir o conceito de distribuição condicional, retome-se o Exemplo 5.1 e, em particular, a Tabela 5.3, na qual se encontram definidas a função conjunta e as funções marginais de probabilidade.

Calcule-se, por exemplo, a probabilidade condicional de a altura ser igual a 1.76 m quando o peso é igual a 75 kg:

$$\begin{aligned} \text{Probabilidade}(H = 1.76 | W = 75) &= \frac{\text{Probabilidade}(H = 1.76 \wedge W = 75)}{\text{Probabilidade}(W = 75)} \\ &= \frac{p_{H,W}(1.76, 75)}{p_W(75)} = \frac{2/7}{3/7} = \frac{2}{3}. \end{aligned}$$

Este cálculo é susceptível de ser generalizado a todas as combinações dos valores de H e W , obtendo-se a função condicional de probabilidade, $p_{H|W}(h|w)$. Em geral, as **funções condicionais de probabilidade** de duas variáveis discretas H e W são definidas através das seguintes expressões:

$$\begin{aligned}\forall h, w: p_{H|W}(h|w) &= \frac{p_{H,W}(h, w)}{p_W(w)} = \frac{p_{H,W}(h, w)}{\sum_h p_{H,W}(h, w)} \\ \forall h, w: p_{H|W}(w|h) &= \frac{p_{H,W}(h, w)}{p_H(h)} = \frac{p_{H,W}(h, w)}{\sum_w p_{H,W}(h, w)}\end{aligned}\quad (5.12)$$

Exemplo 5.6

Na Tabela 5.4 apresenta-se a função condicional $p_{H|W}(h|w)$ correspondente ao Exemplo 5.1 (os valores desta função foram acrescentados aos das funções conjunta e marginais, que tinham sido apresentados anteriormente na Tabela 5.3).

Tabela 5.4
Representação tabular da função condicional $p_{H|W}(h|w)$ (Exemplo 5.1).

		W [kg]					
		75	76	77	79	81	$p_H(h)$
H [m]	1.73	1/7	0	0	0	0	1/7
	1.76	2/7	0	0	0	0	2/7
	1.78	0	1/7	1/7	1/7	0	3/7
	1.82	0	0	0	0	1/7	1/7
	$p_W(w)$	3/7	1/7	1/7	1/7	1/7	
H [m]	1.73	1/3	0	0	0	0	$\leftarrow p_{H W}(h w)$
	1.76	2/3	0	0	0	0	
	1.78	0	1	1	1	0	
	1.82	0	0	0	0	1	

O conceito de distribuição condicional pode ser estendido aos casos nos quais uma ou as duas variáveis são contínuas.

Se se admitir que, tal como sucedia no Exemplo 5.2, duas variáveis aleatórias X e Y são contínuas, as funções condicionais de densidade de probabilidade são definidas através das expressões seguintes:

$$\begin{aligned}\forall x, y: f_{X|Y}(x|y) &= \frac{f_{X,Y}(x, y)}{\int_{\mathbb{R}} f_{X,Y}(x, y) \cdot dx} \quad (\text{com denominador } f_Y(y) = 0) \\ \forall x, y: f_{X|Y}(y|x) &= \frac{f_{X,Y}(x, y)}{\int_{\mathbb{R}} f_{X,Y}(x, y) \cdot dy} \quad (\text{com denominador } f_X(x) = 0)\end{aligned}\quad (5.13)$$

Se, tal como no caso do Exemplo 5.3, se admitir que Z é uma variável contínua e N é uma variável discreta, podem definir-se as seguintes funções:

- Função condicional de densidade de probabilidade de Z :

$$\forall z, n: f_{Z|N}(z|n) = \frac{f_{Z,N}(z, n)}{\int_{\mathbb{R}} f_{Z,N}(z, n) \cdot dz} \quad (5.14)$$

- Função condicional de probabilidade de N :

$$\forall z, n: p_{N|Z}(n|z) = \frac{f_{Z,N}(z, n)}{\sum_n f_{Z,N}(z, n)} \quad (\text{com denominador } f_Z(z) > 0). \quad (5.15)$$

Exemplo 5.7

Para interpretar, por exemplo, o significado da função $f_{Z,N}(z|n)$, atente-se na Figura 5.2, anteriormente apresentada a propósito do Exemplo 5.3. Para cada valor particular $N = n$, a função que limita superiormente a área sombreada — isto é, a função $f_{Z,N}(z, n)$ — não é uma função densidade de probabilidade, uma vez que aquela área não é igual à unidade. A sua conversão numa função densidade de probabilidade — na função $f_{Z,N}(z|n)$ — requer o seu reescalamento, que se obtém dividindo $f_{Z,N}(z, n)$ pelo valor daquela área.

5.5 INDEPENDÊNCIA ENTRE VARIÁVEIS

Para introduzir o conceito de independência, considerem-se duas variáveis discretas H e W . Tais variáveis dizem-se **independentes** se e só se, para quaisquer valores particulares h e w , os acontecimentos

$$\begin{cases} H = h \\ W = w \end{cases}$$

forem independentes. Tal implica que

$$\begin{cases} \text{Probabilidade}(H = h | W = w) = \text{Probabilidade}(H = h) \\ \text{Probabilidade}(W = w | H = h) = \text{Probabilidade}(W = w) \end{cases} \quad (\text{para todos os valores } h \text{ e } w).$$

Atendendo a esta definição, a independência entre duas variáveis implica que entre elas não existe qualquer relação: qualquer que seja o valor particular que uma delas tome, não se altera a distribuição de probabilidade da outra.

Exemplo 5.8

É de esperar que as seguintes variáveis sejam independentes:

- ♦ o QI (quociente de inteligência) das pessoas e a sua altura
- ♦ a temperatura no interior de um forno de uma fundição num determinado momento e o número de empregados administrativos dessa fundição ausentes com baixa
- ♦ a qualidade de um relatório (avaliada numa escala de 0 a 20) e o seu número de páginas.

Da definição de independência acima apresentada para as variáveis discretas H e W resulta que

$$p_{H|W}(h|w) = \frac{p_{H,W}(h, w)}{p_W(w)} = p_H(h) \quad (\text{para todos os valores } h \text{ e } w)$$

$$p_{W|H}(w|h) = \frac{p_{H,W}(h, w)}{p_H(h)} = p_W(w)$$

donde

$$\forall h, w: p_{H,W}(h, w) = p_H(h) \cdot p_W(w). \quad (5.16)$$

Esta relação exprime uma condição necessária e suficiente de independência entre as duas variáveis em causa. Isto significa que, se ela for satisfeita para todos os valores particulares das variáveis, então estas são efectivamente independentes. Inversamente, se para algum par de valores (h, w) a relação não for satisfeita, as variáveis não são independentes.

Exemplo 5.9

Retomando de novo o Exemplo 5.1, a partir da Tabela 5.3 é fácil concluir que as variáveis altura (H) e peso (W) não são independentes. De facto, a relação 5.16 não se verifica, por exemplo, para $H = 1.73$ m e $W = 75$ kg:

$$[p_{H,W}(1.73, 75) = 1/7] \neq [p_H(1.73) \cdot p_W(75) = 1/7 \cdot 3/7].$$

O conceito de independência pode ser estendido aos casos nos quais uma ou as duas variáveis são contínuas.

Se se admitir que, tal como sucedia no Exemplo 5.2, duas variáveis aleatórias X e Y são contínuas, elas serão independentes se e só se, para todos os valores x e y , os acontecimentos

$$\begin{cases} X \in [x, x + dx] \\ Y \in [y, y + dy] \end{cases}$$

forem independentes. É imediato verificar que a condição necessária e suficiente de independência entre as duas variáveis se pode expressar através da função conjunta e das funções marginais de densidade de probabilidade, nos seguintes termos:

$$\forall x, y: f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y). \quad (5.17)$$

Se, tal como no caso do Exemplo 5.3, se admitir que Z é uma variável contínua e N é uma variável discreta, estas variáveis serão independentes se e só se, para quaisquer valores w e n , os acontecimentos

$$\begin{cases} Z \in [z, z + dz] \\ N = n \end{cases}$$

forem independentes. É imediato verificar que, para que as duas variáveis sejam independentes, é necessário e suficiente que se verifique a seguinte condição:

$$\forall z, n: f_{Z,N}(z, n) = f_Z(z) \cdot p_N(n). \quad (5.18)$$

O conceito de independência, que acabou de ser definido para pares de variáveis, é generalizável a qualquer número de variáveis. Apresentam-se seguidamente as condições necessárias e suficientes de independência:

- Para um conjunto qualquer de variáveis discretas $N_1, \dots, N_M$

$$\forall n_1, \dots, n_M: p_{N_1, \dots, N_M}(n_1, \dots, n_M) = p_{N_1}(n_1) \cdot \dots \cdot p_{N_M}(n_M). \quad (5.19)$$

- Para um conjunto qualquer de variáveis contínuas $Z_1, \dots, Z_M$

$$\forall z_1, \dots, z_M: f_{Z_1, \dots, Z_M}(z_1, \dots, z_M) = f_{Z_1}(z_1) \cdot \dots \cdot f_{Z_M}(z_M). \quad (5.20)$$

- Para um conjunto qualquer de variáveis discretas $N_1, \dots, N_{M_1}$ e um conjunto qualquer de variáveis contínuas $Z_1, \dots, Z_{M_2}$

$$\begin{aligned} &\forall n_1, \dots, n_{M_1}, z_1, \dots, z_{M_2}: \\ &f_{N_1, \dots, N_{M_1}, Z_1, \dots, Z_{M_2}}(n_1, \dots, n_{M_1}, z_1, \dots, z_{M_2}) = \\ &= p_{N_1}(n_1) \cdot \dots \cdot p_{N_{M_1}}(n_{M_1}) \cdot f_{Z_1}(z_1) \cdot \dots \cdot f_{Z_{M_2}}(z_{M_2}). \end{aligned} \quad (5.21)$$


5.6 COVARIÂNCIA E CORRELAÇÃO

No Exemplo 5.9, verificou-se que as variáveis altura (H) e peso (W) definidas no Exemplo 5.1 não eram independentes. Este resultado era de esperar, uma vez que, embora possa haver excepções, o peso das pessoas tenderá a ser tanto maior quanto maior for a sua altura. Existem inúmeras formas possíveis de relacionamento entre estas variáveis que satisfazem a condição enunciada, por exemplo, as relações linear, quadrática ou exponencial. De todas elas, a mais simples é a linear, que, em particular, pode ser utilizada como aproximação das restantes.

A covariância e a correlação são medidas do grau de relacionamento linear entre duas variáveis. Estes conceitos serão apresentados considerando de novo as variáveis altura (H) e peso (W) introduzidas no Exemplo 5.1 e cuja função conjunta de probabilidade se representa graficamente na Figura 5.3.

Para qualquer um dos pontos (h, w) a que corresponda uma probabilidade não nula, considerem-se os desvios a partir do ponto (μ_H, μ_W) . Na Figura 5.3 assinalam-se os desvios $(h - \mu_H)$ e $(w - \mu_W)$ correspondentes ao ponto $(h = 1.82$ m, $w = 81$ kg).

Figura 5.3
Representação gráfica da função conjunta de probabilidade de H e W (Exemplo 5.1).



Os pontos situados nos quadrantes NE e SW têm desvios com o mesmo sinal, pelo que os produtos

$$(h - \mu_H) \cdot (w - \mu_W)$$

são positivos. Para os quadrantes NW e SE estes produtos são negativos.

Pode obter-se uma medida do grau de relacionamento linear entre duas variáveis calculando a média pesada daqueles produtos, na qual os pesos são as probabilidades conjuntas $p_{H,W}(h, w)$. Tal medida é a covariância populacional (γ_{HW} ou $\text{Cov}(H, W)$), que vem assim definida:

$$\gamma_{HW} = \sum_h \sum_w (h - \mu_H) \cdot (w - \mu_W) \cdot p_{H,W}(h, w). \quad (5.22)$$

Exemplo 5.10

Retomando de novo o Exemplo 5.1, obtém-se:

$$\begin{aligned} \gamma_{H,W} &= (1.82 - 1.773) \cdot (81 - 76.86) \cdot 1/7 && (\text{NE}) \\ &+ (1.78 - 1.773) \cdot (79 - 76.86) \cdot 1/7 && (\text{NE}) \\ &+ (1.78 - 1.773) \cdot (77 - 76.86) \cdot 1/7 && (\text{NE}) \\ &+ (1.76 - 1.773) \cdot (75 - 76.86) \cdot 2/7 && (\text{SW}) \\ &+ (1.73 - 1.773) \cdot (75 - 76.86) \cdot 1/7 && (\text{SW}) \\ &+ (1.78 - 1.773) \cdot (76 - 76.86) \cdot 1/7 && (\text{SE}) \\ &= 0.0278 + 0.0021 + 0.0001 + 0.0069 + 0.0114 - 0.0009 \\ &= 0.0474 \text{ m} \cdot \text{kg}. \end{aligned}$$

Neste exemplo, $\gamma_{HW} > 0$, pois, predominantemente, H e W crescem e decrescem juntas. Por outras palavras, as probabilidades conjuntas concentram-se mais nos quadrantes NE e SW. Se tais probabilidades se concentrassem mais nos quadrantes NW e SE, γ_{HW} seria negativa e, se se distribuísssem homogeneamente pelos quatro quadrantes, γ_{HW} seria aproximadamente nula, indicando a inexistência de relação linear entre H e W .

Existe um paralelo óbvio entre a definição que acabou de ser introduzida de covariância e aquelas que foram anteriormente apresentadas de produto cruzado médio e de covariância amostral (ver Secção 2.4.2). Deve notar-se, no entanto, que, enquanto a covariância populacional é um parâmetro de uma distribuição conjunta (definido a partir das probabilidades respectivas e, portanto, fixo para uma dada população conjunta), o produto cruzado médio e a covariância amostral são estatísticas (definidas a partir de observações e, portanto, podendo variar de amostra para amostra, para uma dada população conjunta).

A definição de covariância pode ser estendida aos casos em que uma ou as duas variáveis são contínuas:

- X e Y variáveis contínuas, com função conjunta de densidade de probabilidade $f_{X,Y}(x, y)$:

$$\gamma_{XY} = \iint_{\mathbb{R}^2} (x - \mu_X) \cdot (y - \mu_Y) \cdot f_{X,Y}(x, y) \cdot dx \cdot dy. \quad (5.23)$$

- Z variável contínua e N variável discreta, com função conjunta de densidade de probabilidade $f_{Z,N}(z, n)$:

$$\gamma_{ZN} = \sum_n (n - \mu_N) \cdot \int_{\mathbb{R}} (z - \mu_Z) \cdot f_{Z,N}(z, n) \cdot dz. \quad (5.24)$$

A covariância tem o inconveniente de ser afectada pelas unidades nas quais as variáveis em causa são medidas.

Exemplo 5.11

Voltando ao Exemplo 5.10, se as alturas fossem expressas em cm (em vez de m) e se os pesos fossem expressos em g (em vez de kg), a covariância viria dada por:

$$\gamma_{HW} = 4740 \text{ cm} \cdot \text{g (em vez de } 0.0474 \text{ m} \cdot \text{kg)}.$$

Para evitar esta limitação, reescala-se a covariância, dividindo-a pelo produto dos desvios padrões das variáveis em causa. Obtém-se assim o **coeficiente de correlação** (ou, simplesmente, a **correlação**) **populacional**:

$$\rho_{HW} = \frac{\gamma_{HW}}{\sigma_H \cdot \sigma_W}. \quad (5.25)$$

É fácil mostrar que o coeficiente de correlação ρ_{HW} é igual à covariância das seguintes variáveis **padronizadas**:

$$\begin{aligned} H' &= (H - \mu_H) / \sigma_H \\ W' &= (W - \mu_W) / \sigma_W. \end{aligned}$$

De facto, notando que na expressão da covariância

$$\gamma_{H'W'} = \sum_{h'} \sum_{w'} (h' - \mu_{H'}) \cdot (w' - \mu_{W'}) \cdot p_{H',W'}(h', w')$$

os valores esperados $\mu_{H'}$ e $\mu_{W'}$ são

$$\mu_{H'} = E\left(\frac{H - \mu_H}{\sigma_H}\right) = 0 \quad \mu_{W'} = E\left(\frac{W - \mu_W}{\sigma_W}\right) = 0,$$

obtém-se

$$\begin{aligned} \gamma_{H'W'} &= \sum_{h'} \sum_{w'} h' \cdot w' \cdot p_{H',W'}(h', w') \\ &= \sum_h \sum_w \left(\frac{h - \mu_H}{\sigma_H}\right) \cdot \left(\frac{w - \mu_W}{\sigma_W}\right) \cdot p_{H,W}(h, w) \\ &= \frac{1}{\sigma_H \cdot \sigma_W} \cdot \sum_h \sum_w (h - \mu_H) \cdot (w - \mu_W) \cdot p_{H,W}(h, w) \\ &= \frac{1}{\sigma_H \cdot \sigma_W} \cdot \gamma_{HW} = \rho_{HW} \end{aligned}$$

ou seja,

$$\rho_{HW} = \gamma_{H'W'}. \quad (5.26)$$

O coeficiente de correlação pode tomar valores situados entre -1 e 1 . Em notação simbólica, vem

$$-1 \leq \rho_{HW} \leq 1. \quad (5.27)$$

O valor do coeficiente de correlação dependerá do grau de relacionamento linear entre as variáveis em causa, sendo

- (i) igual a 1 : quando, para todos os pares ordenados (H, W) aos quais se associe uma probabilidade não nula, se verificar uma relação $W = \alpha + \beta \cdot H$, com $\beta > 0$ (ou seja, quando o grau de relacionamento linear entre H e W for perfeito e o coeficiente angular da relação for positivo);
- (ii) igual a -1 : quando, para todos os pares ordenados (H, W) aos quais se associe uma probabilidade não nula, se verificar uma relação $W = \alpha + \beta \cdot H$, com $\beta < 0$ (ou seja, quando o grau de relacionamento linear entre H e W for perfeito e o coeficiente angular da relação for negativo);
- (iii) igual a 0 : quando o grau de relacionamento linear entre H e W for nulo.

Destes resultados, os dois primeiros encontram-se demonstrados no Apêndice 5.1. Em relação ao terceiro, vale a pena atentar no seu significado. É evidente que, se as duas variáveis aleatórias em causa forem independentes, então não existirá qualquer relação entre elas, sendo, portanto, nulo o grau de relacionamento linear entre elas. Neste caso, tal como se demonstra no Apêndice 5.1, o coeficiente de correlação é efectivamente nulo. No entanto, se o coeficiente de correlação for nulo, não pode daí depreender-se que as variáveis sejam independentes (uma vez que podem existir relações não-lineares entre elas).

Exemplo 5.12

Considere-se o caso de duas variáveis discretas N e M cuja distribuição conjunta se representa graficamente na Figura 5.4. Note-se que esta distribuição conjunta pode ser interpretada do seguinte modo: a variável M pode tomar, com igual probabilidade ($1/6$), os valores $\{-3, -2, -1, 1, 2, 3\}$ e a variável N encontra-se perfeitamente relacionada com M segundo a relação não-linear $N = |M|$.

Aplicando a definição, a covariância entre as variáveis M e N vem dada por:


$$\gamma_{MN} = \sum_m \sum_n (m - \mu_M) \cdot (n - \mu_N) \cdot p_{M,N}(m, n),$$

mas, atendendo a que $\mu_M = 0$ e $\mu_N = 2$,

$$\begin{aligned}\gamma_{MN} &= \sum_m \sum_n m \cdot (n - 2) \cdot p_{M,N}(m, n) \\ &= (-3) \cdot 1 \cdot 1/6 + (-2) \cdot 0 \cdot 1/6 + (-1) \cdot -1 \cdot 1/6 + \\ &\quad + 3 \cdot 1 \cdot 1/6 + 2 \cdot 0 \cdot 1/6 + 1 \cdot -1 \cdot 1/6 = 0.\end{aligned}$$

Apesar de a covariância e, portanto, a correlação serem nulas, é óbvio que as variáveis em causa não são independentes. De facto, o valor de N depende do de M (ficando, aliás, univocamente definido por este).

Figura 5.4
Representação
gráfica da função
conjunta de
probabilidade de M
e N (Exemplo 5.12).



5.7 VARIÁVEIS TRANSFORMADAS

5.7.1 VARIÁVEIS OBTIDAS POR TRANSFORMAÇÃO DE PARES DE VARIÁVEIS ALEATÓRIAS

A Secção 4.6 do capítulo anterior incidiu sobre o conceito de variável aleatória obtida por transformação de uma outra variável aleatória. Nesta secção estender-se-á a análise ao caso de variáveis obtidas por transformação de pares de variáveis aleatórias.

Considerem-se duas variáveis aleatórias quaisquer H e W e admita-se que os seus valores são transformados por aplicação de uma função $\phi(H, W)$. Como resultado desta operação, fica definida uma nova variável aleatória:

$$V = \phi(H, W).$$

Exemplo 5.13

Retome-se o Exemplo 5.1 e, a partir das variáveis altura (H) e peso (W), defina-se a função

$$V = W/H \quad (\text{peso por unidade de altura}).$$

V é uma variável aleatória cuja função de probabilidade, $p_V(v)$, se encontra definida na Tabela 5.5. Esta função foi calculada a partir da função conjunta, $p_{H,W}(h, w)$, anteriormente apresentada na Tabela 5.2.

Tabela 5.5
Função de probabilidade da variável transformada V (Exemplo 5.13).

$V = W/H$	$p_V(v)$
$42.61 = 75 / 1.76$	$2 / 7$
$42.70 = 76 / 1.78$	$1 / 7$
$43.26 = 77 / 1.78$	$1 / 7$
$43.35 = 75 / 1.73$	$1 / 7$
$44.38 = 79 / 1.78$	$1 / 7$
$44.51 = 81 / 1.82$	$1 / 7$

Os parâmetros da distribuição da variável transformada V podem ser calculados por aplicação das definições introduzidas no capítulo anterior. Se se admitir que, como sucedia no Exemplo 5.13, as variáveis H e W (e, portanto, V) são discretas, os momentos da variável transformada V são calculados recorrendo às expressões seguintes:

$$\mu'_i(V) = E(V^i) = \sum_v v^i \cdot p_V(v) = \sum_{h,w} [\phi(h, w)]^i \cdot p_{H,W}(h, w)$$

$$\mu_i(V) = E[(V - \mu_V)^i] = \sum_v (v - \mu_V)^i \cdot p_V(v) = \sum_{h,w} [\phi(h, w) - \mu_V]^i \cdot p_{H,W}(h, w) \quad (5.28)$$

onde $\mu_V = \mu'_1(V) = E(V)$. Note-se que nestas expressões — que podem ser facilmente adaptadas ao caso em que uma ou as duas variáveis originais são contínuas — estão contempladas duas formas equivalentes de calcular os momentos:

- (i) directamente a partir da distribuição da variável transformada V ou
- (ii) com base nas distribuições das variáveis originais e na função $V = \phi(H, W)$.

Exemplo 5.14

Para a variável V definida no Exemplo 5.13, o valor esperado e a variância, calculados a partir da distribuição definida na Tabela 5.5, vêm dados por:

$$\begin{aligned}\mu_V &= 42.61 \cdot 2/7 + 42.70 \cdot 1/7 + 43.26 \cdot 1/7 + 43.35 \cdot 1/7 + \\ &\quad + 44.38 \cdot 1/7 + 44.51 \cdot 1/7 = 43.346 \\ \sigma_V^2 &= (42.61 - 43.346)^2 \cdot 2/7 + (42.70 - 43.346)^2 \cdot 1/7 + \\ &\quad + (43.26 - 43.346)^2 \cdot 1/7 + (43.35 - 43.346)^2 \cdot 1/7 + \\ &\quad + (44.38 - 43.346)^2 \cdot 1/7 + (44.51 - 43.346)^2 \cdot 1/7 = 0.562\end{aligned}$$

É imediato verificar que o cálculo efectuado a partir das distribuições das variáveis originais H e W é equivalente ao que acabou de se apresentar.

5.7.2 A COVARIÂNCIA DEFINIDA COMO VALOR ESPERADO DE UMA VARIÁVEL TRANSFORMADA

Considerem-se duas variáveis aleatórias discretas H e W , com função conjunta de probabilidade $p_{H,W}(h, w)$, e, a partir delas, defina-se a variável transformada

$$V = (H - \mu_H) \cdot (W - \mu_W).$$

O valor esperado desta variável é dado pela expressão

$$\mu_V = E(V) = \sum_h \sum_w (h - \mu_H) \cdot (w - \mu_W) \cdot p_{H,W}(h, w)$$

onde o segundo membro é exactamente a covariância entre as variáveis H e W . Então, tal como anteriormente se observou que os momentos populacionais podem ser definidos como valores esperados de variáveis transformadas (ver Secção 4.6.2), também a covariância é susceptível de ser interpretada deste modo:

$$\gamma_{H,W} = E[(h - \mu_H) \cdot (w - \mu_W)]. \quad (5.29)$$

O segundo membro desta expressão é susceptível de ser desenvolvido, vindo

$$\begin{aligned} \gamma_{H,W} &= E(h \cdot w - \mu_H \cdot w - h \cdot \mu_W + \mu_H \cdot \mu_W) \\ &= E(h \cdot w) - \mu_H \cdot E(w) - E(h) \cdot \mu_W + \mu_H \cdot \mu_W, \end{aligned}$$

donde

$$\gamma_{H,W} = E(h \cdot w) - \mu_H \cdot \mu_W. \quad (5.30)$$

■ 5.7.3 CÁLCULO DO VALOR ESPERADO E DA VARIÂNCIA DE VARIÁVEIS TRANSFORMADAS

Anteriormente, na Secção 5.7.1, verificou-se como podem ser calculados os momentos populacionais da distribuição de uma qualquer variável transformada $V = \phi(H, W)$. Em particular, no Exemplo 5.14 apresentou-se o cálculo do valor esperado e da variância.

Sucedee, no entanto, que estes dois parâmetros podem ser calculados directamente, pelo menos de uma forma aproximada, a partir dos parâmetros correspondentes das variáveis originais e da covariância entre estas. Mostrar-se-á seguidamente a forma como este cálculo pode ser efectuado, considerando primeiro o caso em que a variável transformada é uma combinação linear das variáveis originais e depois aquele em que a variável transformada é uma função não-linear destas variáveis.

■ 5.7.3.1 COMBINAÇÃO LINEAR DE VARIÁVEIS

Considere-se o caso de a variável V ser obtida combinando linearmente as variáveis H e W :

$$V = \phi(H, W) = a + b \cdot H + c \cdot W,$$

onde a , b e c representam constantes.

Tomando, por exemplo, o caso de as variáveis H e W (e, portanto, V) serem discretas, da definição de valor esperado resulta:

$$\begin{aligned} E(V) &= \sum_v v \cdot p_V(v) = \sum_h \sum_w \phi(h, w) \cdot p_{H,W}(h, w) \\ &= \sum_h \sum_w (a + b \cdot h + c \cdot w) \cdot p_{H,W}(h, w) \\ &= a \cdot \sum_h \sum_w p_{H,W}(h, w) + b \cdot \sum_h \sum_w h \cdot p_{H,W}(h, w) + c \cdot \sum_h \sum_w w \cdot p_{H,W}(h, w) \\ &= a \cdot 1 + b \cdot \sum_h h \left(\sum_w p_{H,W}(h, w) \right) + c \cdot \sum_w w \left(\sum_h p_{H,W}(h, w) \right) \\ &= a + b \cdot \sum_h h \cdot p_H(h) + c \cdot \sum_w w \cdot p_W(w) \\ &= a + b \cdot E(H) + c \cdot E(W) \end{aligned}$$

ou seja,

$$\begin{aligned} E(V) &= E[\phi(H, W)] = E(a + b \cdot H + c \cdot W) \\ &= a + b \cdot E(H) + c \cdot E(W) = \phi[E(H), E(W)]. \end{aligned} \quad (5.31)$$

É imediato verificar que esta expressão, que foi obtida para o caso de H e W serem discretas, é válida também no caso de uma ou duas destas variáveis serem contínuas. O mesmo se verifica com o desenvolvimento que seguidamente se apresenta da definição de variância:

$$\begin{aligned} \text{Var}(V) &= E[(V - \mu_V)^2] \\ &= E\left\{[(a + b \cdot H + c \cdot W) - (a + b \cdot \mu_H + c \cdot \mu_W)]^2\right\} \\ &= E\left\{[b \cdot (H - \mu_H) + c \cdot (W - \mu_W)]^2\right\} \\ &= E\{b^2 \cdot (H - \mu_H)^2 + 2 \cdot b \cdot c \cdot (H - \mu_H) \cdot (W - \mu_W) + c^2 \cdot (W - \mu_W)^2\} \\ &= b^2 \cdot E[(H - \mu_H)^2] + 2 \cdot b \cdot c \cdot E[(H - \mu_H) \cdot (W - \mu_W)] + c^2 \cdot E[(W - \mu_W)^2] \end{aligned}$$

ou seja,

$$\begin{aligned} \text{Var}(V) &= \text{Var}[\phi(H, W)] = \text{Var}(a + b \cdot H + c \cdot W) \\ &= b^2 \cdot \text{Var}(H) + 2 \cdot b \cdot c \cdot \text{Cov}(H, W) + c^2 \cdot \text{Var}(W). \end{aligned} \quad (5.32)$$

A soma de duas variáveis é um caso particular de combinação linear das duas variáveis. Admitindo que a variável S é a soma das variáveis Y_1 e Y_2 , as expressões 5.31 e 5.32 convertem-se nas seguintes:

$$\begin{aligned} \mu_S &= E(S) = E(Y_1 + Y_2) = \mu_{Y_1} + \mu_{Y_2} \\ \sigma_S^2 &= \text{Var}(S) = \text{Var}(Y_1 + Y_2) = \sigma_{Y_1}^2 + 2 \cdot \gamma_{Y_1 Y_2} + \sigma_{Y_2}^2. \end{aligned} \quad (5.33)$$

Exemplo 5.15

Sejam Y_1 e Y_2 duas variáveis aleatórias que representam os resultados do lançamento ao ar de dois dados e denote-se por S a soma daqueles resultados. O valor esperado e a variância das variáveis Y_1 e Y_2 vêm dados por:

$$\begin{aligned} \mu_{Y_1} &= \mu_{Y_2} = (1 + 2 + 3 + 4 + 5 + 6) / 6 = 3.5 \\ \sigma_{Y_1}^2 &= \sigma_{Y_2}^2 = [(1 - 3.5)^2 + (2 - 3.5)^2 + (3 - 3.5)^2 + (4 - 3.5)^2 \\ &\quad + (5 - 3.5)^2 + (6 - 3.5)^2] \cdot (1/6) = 2.9167 \end{aligned}$$

Admitindo que os resultados do lançamento ao ar dos dois dados são independentes, virá

$$\gamma_{Y_1 Y_2} = 0.$$

O valor esperado e a variância de S podem então ser calculados recorrendo às expressões 5.33:

$$\begin{aligned} \mu_S &= E(S) = E(Y_1 + Y_2) = 2 \cdot \mu_{Y_1} = 2 \cdot 3.5 = 7 \\ \sigma_S^2 &= \text{Var}(S) = \text{Var}(Y_1 + Y_2) = \sigma_{Y_1}^2 + 2 \cdot \gamma_{Y_1 Y_2} + \sigma_{Y_2}^2 = 2 \cdot \sigma_{Y_1}^2 \\ &= 2 \cdot 2.9167 = 5.833. \end{aligned}$$

Deve registar-se que estes dois parâmetros foram calculados sem recorrer à distribuição de S .

É imediato demonstrar que a primeira das expressões 5.33 (a que se refere ao valor esperado da soma) é generalizável para qualquer número de variáveis. O valor esperado da soma de N variáveis (independentes ou não), $Y_1, Y_2, \dots, Y_N$, é igual à soma dos valores esperados destas variáveis, ou seja,

$$E(Y_1 + Y_2 + \dots + Y_N) = \mu_{Y_1} + \mu_{Y_2} + \dots + \mu_{Y_N}. \quad (5.34)$$

No tocante à segunda das expressões 5.33 (a que se refere à variância da soma), vale a pena tecer alguns comentários relativos à interpretação do termo que envolve a covariância. Uma covariância positiva implica que, quando uma das variáveis se desvia significativamente do seu valor esperado, a outra tenderá a desviar-se no mesmo sentido. Tal acarretará um aumento da dispersão da soma das variáveis (o que é reflectido pelo facto de aquele termo ser positivo). Este aumento será máximo quando a correlação entre as variáveis for igual à unidade. Neste caso, virá:

$$\begin{aligned} \sigma_S^2 &= \sigma_{Y_1}^2 + 2 \cdot \gamma_{Y_1 Y_2} + \sigma_{Y_2}^2 \\ &= \sigma_{Y_1}^2 + 2 \cdot \sigma_{Y_1} \cdot \sigma_{Y_2} + \sigma_{Y_2}^2 = (\sigma_{Y_1} + \sigma_{Y_2})^2 \quad (\rho_{Y_1 Y_2} = 1). \end{aligned} \quad (5.35)$$

Quando a covariância for negativa, os desvios das duas variáveis tenderão a ser de sentido contrário, implicando uma diminuição da variância da soma (o que é reflectido pelo facto de o termo em causa ser negativo). Tal variância será mínima quando a correlação for igual a -1:

$$\begin{aligned} \sigma_S^2 &= \sigma_{Y_1}^2 + 2 \cdot \gamma_{Y_1 Y_2} + \sigma_{Y_2}^2 = \\ &= \sigma_{Y_1}^2 - 2 \cdot \sigma_{Y_1} \cdot \sigma_{Y_2} + \sigma_{Y_2}^2 = (\sigma_{Y_1} - \sigma_{Y_2})^2 \quad (\rho_{Y_1 Y_2} = -1). \end{aligned} \quad (5.36)$$

Quando a covariância entre as variáveis Y_1 e Y_2 for nula (o que sucederá necessariamente quando elas forem independentes), a variância da soma será igual à soma das variâncias:

$$\sigma_S^2 = \sigma_{Y_1}^2 + 2 \cdot \gamma_{Y_1 Y_2} + \sigma_{Y_2}^2 = \sigma_{Y_1}^2 + \sigma_{Y_2}^2 \quad (\rho_{Y_1 Y_2} = 0). \quad (5.37)$$

Retomando a segunda das expressões 5.33, deve notar-se que, se em vez de duas se considerassem N variáveis ($Y_1, Y_2, \dots, Y_N$), tal expressão redundaria em

$$\text{Var}(Y_1 + \dots + Y_N) = (\sigma_{Y_1}^2 + \dots + \sigma_{Y_N}^2) + 2 \cdot \sum_{i=1}^{N-1} \sum_{j=i+1}^N \gamma_{Y_i Y_j}. \quad (5.38)$$

Quando as variáveis forem independentes (ou não-correlacionadas), esta expressão converter-se-á em

$$\text{Var}(Y_1 + \dots + Y_N) = \sigma_{Y_1}^2 + \dots + \sigma_{Y_N}^2 \quad (\rho_{Y_i Y_j} = 0, \text{ para } i \neq j). \quad (5.39)$$

■ 5.7.3.2 TRANSFORMAÇÕES NÃO-LINEARES

Considere-se agora o caso no qual a transformação

$$V = \phi(H, W)$$

é não-linear.

Para esta transformação, $E(V)$ e $\text{Var}(V)$ dependerão, em geral, não só do valor esperado de H e de W , das suas variâncias e da covariância entre elas, mas também de momentos de ordem superior.

Sucedem frequentemente que as transformações não-lineares $V = \phi(H, W)$ podem ser aproximadas, em torno de μ_H e μ_W , por relações lineares. Considerando apenas os termos lineares do desenvolvimento em série de Taylor da função $\phi(H, W)$ em torno de μ_H e μ_W , vem

$$\phi(H, W) \approx \phi(\mu_H, \mu_W) + (H - \mu_H) \cdot \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W} + (W - \mu_W) \cdot \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W}.$$

Notando que nesta expressão

$$\mu_H, \mu_W, \phi(\mu_H, \mu_W), \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W} \text{ e } \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W}$$

representam constantes (dado que os parâmetros μ_H e μ_W são fixos), pode escrever-se

$$\phi(H, W) \approx a + b \cdot H + c \cdot W$$

onde a, b e c são constantes dadas por

$$a = \phi(\mu_H, \mu_W) - \mu_H \cdot \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W} - \mu_W \cdot \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W} \quad (5.40)$$

$$b = \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W} \quad (5.41)$$

$$c = \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W}. \quad (5.42)$$

As expressões do valor esperado da variável transformada e da sua variância podem ser obtidas a partir das expressões aplicáveis ao caso das transformações lineares (expressões 5.31 e 5.32), nelas substituindo as constantes a, b e c pelas suas expressões 5.40, 5.41 e 5.42. Para o valor esperado obtém-se

$$E(V) = E[\phi(H, W)] \approx a + b \cdot E(H) + c \cdot E(W) \approx a + b \cdot \mu_H + c \cdot \mu_W$$

$$\begin{aligned} &= \left\{ \phi(\mu_H, \mu_W) - \mu_H \cdot \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W} - \mu_W \cdot \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W} \right\} + \\ &+ \mu_H \cdot \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W} + \mu_W \cdot \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W} \\ &\approx \phi(\mu_H, \mu_W) \approx \phi[E(H), E(W)], \end{aligned}$$

ou seja,

$$E(V) = E[\phi(H, W)] \approx \phi[E(H), E(W)]. \quad (5.43)$$

Para a variância, obtém-se

$$\text{Var}[\phi(H, W)] \approx \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W}^2 \cdot \sigma_H^2 + 2 \cdot \left[\frac{\partial \phi}{\partial H} \right]_{H=\mu_H, W=\mu_W} \cdot \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W} \cdot \gamma_{HW} + \left[\frac{\partial \phi}{\partial W} \right]_{H=\mu_H, W=\mu_W}^2 \cdot \sigma_W^2. \quad (5.44)$$

Exemplo 5.16

Considere-se um paralelogramo cujos lados Y e Z são variáveis aleatórias discretas independentes com as distribuições que se definem na Tabela 5.6.

Calcule-se o valor esperado e a variância da área do paralelogramo, $\Omega = Y \cdot Z$, recorrendo às expressões 5.43 e 5.44:

$$E(\Omega) \approx E(Y) \cdot E(Z) = 20.2 \cdot 40.0 = 808$$

$$\text{Var}(\Omega) \approx \left[\frac{\partial \Omega}{\partial Y} \right]_{Y=\mu_Y}^2 \cdot \sigma_Y^2 + \left[\frac{\partial \Omega}{\partial Z} \right]_{Z=\mu_Z}^2 \cdot \sigma_Z^2$$

$$\approx \mu_Z^2 \cdot \sigma_Y^2 + \mu_Y^2 \cdot \sigma_Z^2$$

$$\approx 40.0^2 \cdot 0.36 + 20.2^2 \cdot 2$$

$$\approx 1392.1.$$

Os valores exactos destes parâmetros podem ser calculados recorrendo à distribuição da variável Ω (ver Tabela 5.7).

É de notar que, neste exemplo, os valores obtidos recorrendo às expressões 5.43 e 5.44 são excelentes aproximações dos valores correctos. Tal fica a dever-se ao facto de ser também excelente a aproximação linear da função $\Omega = Y \cdot Z$ na região correspondente aos valores que as variáveis Y e Z tomam:

$$\Omega = Y \cdot Z \approx \mu_Y \cdot \mu_Z + (Y - \mu_Y) \cdot \left[\frac{\partial \Omega}{\partial Y} \right]_{Y=\mu_Y}^{Z=\mu_Z} + (Z - \mu_Z) \cdot \left[\frac{\partial \Omega}{\partial Z} \right]_{Z=\mu_Z}^{Y=\mu_Y}$$

$$\approx 20.2 \cdot 40.0 + (Y - 20.2) \cdot [40.0] + (Z - 40.0) \cdot [20.2]$$

$$\approx 40.0 \cdot Y + 20.2 \cdot Z - 808.$$

A título de exemplo, apresentam-se os valores exactos e aproximados de Ω para duas combinações de Y e Z :

♦ $Y = 21$ e $Z = 38$: $\Omega_{\text{exacto}} = 798$ e $\Omega_{\text{aprox.}} = 799.6$


♦ $Y = 21$ e $Z = 42$: $\Omega_{\text{exacto}} = 882$ e $\Omega_{\text{aprox.}} = 880.4$.

Tabela 5.6
Funções de probabilidade das variáveis Y e Z (Exemplo 5.16).

y	$p_Y(y)$	z	$p_Z(z)$
		38.0	0.20
19.0	0.10	39.0	0.20
20.0	0.60	40.0	0.20
21.0	0.30	41.0	0.20
		42.0	0.20
$\mu_Y = 20.2$		$\mu_Z = 40.0$	
$\sigma_Y^2 = 0.36$		$\sigma_Z^2 = 2$	

Tabela 5.7
Funções de probabilidade da variável Ω (Exemplo 5.16).

y	z	$\omega = y \cdot z$	$P_{\Omega}(\omega)$
19.0	38.0	722	$0.10 \cdot 0.20 = 0.02$
19.0	39.0	741	$0.10 \cdot 0.20 = 0.02$
19.0	40.0	760	$0.10 \cdot 0.20 = 0.02$
19.0	41.0	779	$0.10 \cdot 0.20 = 0.02$
19.0	42.0	798	$0.10 \cdot 0.20 = 0.02$
20.0	38.0	760	$0.60 \cdot 0.20 = 0.12$
20.0	39.0	780	$0.60 \cdot 0.20 = 0.12$
20.0	40.0	800	$0.60 \cdot 0.20 = 0.12$
20.0	41.0	820	$0.60 \cdot 0.20 = 0.12$
20.0	42.0	840	$0.60 \cdot 0.20 = 0.12$
21.0	38.0	798	$0.30 \cdot 0.20 = 0.06$
21.0	39.0	819	$0.30 \cdot 0.20 = 0.06$
21.0	40.0	840	$0.30 \cdot 0.20 = 0.06$
21.0	41.0	861	$0.30 \cdot 0.20 = 0.06$
21.0	42.0	882	$0.30 \cdot 0.20 = 0.06$
			$\mu_{\Omega} = 808$
			$\sigma_{\Omega}^2 = 1392.8$



■ APÊNDICE 5.1 VALORES LÍMITES DO COEFICIENTE DE CORRELAÇÃO, ρ_{HW}

■ Relacionamento linear perfeito entre H e W , com coeficiente angular da relação positivo: $W = \alpha' + \beta \cdot H$ (com $\beta > 0$)

$$(1) \gamma_{HW} = \sum_h \sum_w (h - \mu_H) \cdot (w - \mu_W) \cdot p_{H,W}(h, w)$$

$$(2) W = \alpha' + \beta \cdot H \text{ (com } \beta > 0) \Rightarrow \mu_W = \alpha' + \beta \cdot \mu_H$$

$$\Rightarrow \sigma_W^2 = \beta^2 \cdot \sigma_H^2$$

$$\Rightarrow \sigma_W = \beta \cdot \sigma_H \text{ (dado que } \beta > 0)$$

$$\Rightarrow W - \mu_W = (\alpha' + \beta \cdot H) - (\alpha' + \beta \cdot \mu_H) \\ = \beta \cdot (H - \mu_H)$$

$$(3) \gamma_{HW} = \sum_h \sum_w (h - \mu_H) \cdot \beta \cdot (h - \mu_H) \cdot p_{H,W}(h, w)$$

$$= \sum_h \beta \cdot (h - \mu_H)^2 \cdot \left[\sum_w p_{H,W}(h, w) \right]$$

$$= \beta \cdot \sum_h (h - \mu_H)^2 \cdot p_H(h)$$

$$= \beta \cdot \sigma_H^2$$

$$(4) \rho_{HW} = \frac{\gamma_{HW}}{\sigma_H \cdot \sigma_W} = \frac{\beta \cdot \sigma_H^2}{\sigma_H \cdot (\beta \cdot \sigma_H)} = 1$$

■ Relacionamento linear perfeito entre H e W , com coeficiente angular da relação negativo: $W = \alpha' + \beta \cdot H$ (com $\beta < 0$)

$$(1) \gamma_{HW} = \sum_h \sum_w (h - \mu_H) \cdot (w - \mu_W) \cdot p_{H,W}(h, w)$$

$$(2) W = \alpha' + \beta \cdot H \text{ (com } \beta < 0) \Rightarrow \mu_W = \alpha' + \beta \cdot \mu_H$$

$$\Rightarrow \sigma_W^2 = \beta^2 \cdot \sigma_H^2$$

$$\Rightarrow \sigma_W = -\beta \cdot \sigma_H \text{ (dado que } \beta < 0)$$

$$\Rightarrow W - \mu_W = (\alpha' + \beta \cdot H) - (\alpha' + \beta \cdot \mu_H) \\ = \beta \cdot (H - \mu_H)$$

$$(3) \gamma_{HW} = \sum_h \sum_w (h - \mu_H) \cdot \beta \cdot (h - \mu_H) \cdot p_{H,W}(h, w)$$

$$= \sum_h \beta \cdot (h - \mu_H)^2 \cdot \left[\sum_w p_{H,W}(h, w) \right]$$

$$= \beta \cdot \sum_h (h - \mu_H)^2 \cdot p_H(h)$$

$$= \beta \cdot \sigma_H^2$$

$$(4) \rho_{HW} = \frac{\gamma_{HW}}{\sigma_H \cdot \sigma_W} = \frac{\beta \cdot \sigma_H^2}{\sigma_H \cdot (-\beta \cdot \sigma_H)} = -1$$

■ H e W independentes


$$(1) \gamma_{HW} = \sum_h \sum_w (h - \mu_H) \cdot (w - \mu_W) \cdot p_{H,W}(h, w)$$

$$= \sum_h \sum_w (h - \mu_H) \cdot (w - \mu_W) \cdot p_H(h) \cdot p_W(w)$$

$$= \left[\sum_h (h - \mu_H) \cdot p_H(h) \right] \cdot \left[\sum_w (w - \mu_W) \cdot p_W(w) \right]$$

$$= E(H - \mu_H) \cdot E(W - \mu_W) = 0 \cdot 0 = 0$$

$$(2) \rho_{HW} = \frac{\gamma_{HW}}{\sigma_H \cdot \sigma_W} = \frac{0}{\sigma_H \cdot \sigma_W} = 0$$




5.1. Uma moeda E-C é lançada ao ar três vezes. Seja X o número de E's obtidos nos dois primeiros lançamentos e Y o número de C's obtidos nos dois últimos lançamentos.

- (i) Defina a função conjunta de probabilidade das variáveis X e Y .
- (ii) Defina a função condicional de probabilidade de Y , dado que $X = 1$.
- (iii) Calcule o coeficiente de correlação ρ_{XY} .

5.2. Considere duas variáveis aleatórias X e Y com a seguinte função conjunta de densidade de probabilidade:

$$f(x, y) = \begin{cases} 2, & \text{se } x \text{ e } y \text{ pertencerem ao domínio } D \text{ (ver figura)} \\ 0, & \text{no caso contrário.} \end{cases}$$



Calcule:

- (i) as distribuições marginais das variáveis X e Y ;
- (ii) os valores esperados das variáveis X e Y ;
- (iii) as distribuições condicionais de X , dado que $Y = y$, e de Y , dado que $X = x$;
- (iv) a covariância entre X e Y .

5.3. Numa linha de produção são fabricados osciladores de um certo tipo, que incluem uma resistência R e um condensador com capacidade C .

O período de oscilação depende de R e C , de acordo com a relação seguinte:

$$T = \left(\frac{1}{100} \right) \cdot R^3 \cdot C^3$$

Admita que R e C são variáveis aleatórias com os seguintes parâmetros:

$$R: \mu_R = 10^6, \quad \sigma_R = 0.03 \cdot \mu_R$$

$$C: \mu_C = 10^{-6}, \quad \sigma_C = 0.05 \cdot \mu_C$$

Supondo que a resistência e o condensador incorporados em cada oscilador são seleccionados independentemente um do outro, determine o valor esperado e o desvio padrão do período dos osciladores.

5.4. O teor de humidade de uma remessa de carvão foi estimado em 8%. O erro de estimação deste teor tem valor esperado nulo e desvio padrão de 0.5%. O peso da remessa — 1000 toneladas — foi obtido recorrendo a uma balança que introduz um erro com valor esperado nulo e desvio padrão de 5 toneladas.

Calcule o valor esperado e o desvio padrão do peso de carvão seco existente na referida remessa.

5.5. As variáveis aleatórias $X_1, X_2, \dots, X_N$ representam as alturas de N indivíduos escolhidos ao acaso entre os portugueses adultos do sexo masculino. Cada variável X_i ($i = 1, 2, \dots, N$) tem valor esperado μ e desvio padrão σ .

A variável aleatória

$$\bar{X} = \frac{1}{N} \cdot \sum_{i=1}^N X_i$$

representa a média das alturas dos N indivíduos seleccionados ao acaso.

Calcule as covariâncias seguintes e interprete os resultados obtidos:

- (i) $\text{Cov}(X_i - \bar{X}, \bar{X})$
- (ii) $\text{Cov}(X_i - \bar{X}, X_i)$
- (iii) $\text{Cov}(X_i - \bar{X}, X_j - \bar{X})$ (para $i \neq j$).

5.6. Considere a seguinte população de casais cuja função conjunta de probabilidade do rendimento mensal do marido (X) e da mulher (Y) se encontra representada na tabela seguinte.

		Y [euros]			
		1000	2000	3000	4000
X [euros]	1000	0.20	0.04	0.01	0
	2000	0.10	0.36	0.09	0
	3000	0	0.05	0.10	0
	4000	0	0	0	0.05


- (i) Determine as funções marginais de probabilidade para as variáveis X e Y .
- (ii) Considere apenas as mulheres com um rendimento de 2000 euros mensais. Qual a probabilidade do marido ter um rendimento idêntico?
- (iii) Calcule o valor esperado e o desvio padrão da variável X e da variável Y .
- (iv) Verifique se as variáveis X e Y são independentes.
- (v) Calcule a covariância e a correlação entre X e Y .
- (vi) Calcule o valor esperado e o desvio padrão do:
 - a. Rendimento total (R), considerando $R = X + Y$
 - b. Do imposto sobre o rendimento familiar (I), considerando $I = 0.20X + 0.10Y$.

5.7. Considere que tem uma poupança de 1000 euros e que está a ponderar aplicar este dinheiro em acções e em fundos de investimento geridos pelo seu banco. A taxa de rentabilidade dos dois tipos de investimento é incerta, apresentando a seguinte distribuição conjunta de probabilidade.

		Y: taxa de rentabilidade das acções			
		-10%	0%	10%	20%
X: taxa de rentabilidade dos fundos de investimento	6%	0.10	0.10	0	0
	8%	0	0.10	0.30	0.20
	10%	0	0	0.10	0.10

Se investisse metade da sua poupança (que corresponde a 500 euros) em acções e a outra metade em fundos de investimento, qual seria o valor esperado e o desvio padrão da taxa de rentabilidade da sua poupança (que se denota por R)?

6



Caracterização de Algumas Distribuições Discretas Univariadas

6.1 INTRODUÇÃO

Neste capítulo serão abordadas as seguintes distribuições discretas univariadas:

- Binomial;
- Binomial Negativa (que inclui, como caso particular, a distribuição Geométrica);
- Hipergeométrica;
- Poisson.

Estas distribuições — que são modelos utilizados para descrever populações reais — foram seleccionadas a partir de um vasto conjunto de distribuições descritas na literatura. O critério de selecção privilegiou, por um lado, a frequência com que ocorrem fenómenos aleatórios susceptíveis de ser modelados pelas distribuições escolhidas e, por outro, a simplicidade destas.

6.2 DISTRIBUIÇÃO BINOMIAL

6.2.1 DEFINIÇÃO

Um dos processos mais simples de recolha de dados consiste na contagem do número de vezes que determinado acontecimento ocorre ao longo de uma série de experiências idênticas (por exemplo, a contagem de peças defeituosas num posto de inspecção).

Admita-se que tais experiências possuem as seguintes características:

- a cada experiência corresponde apenas um de dois resultados possíveis: «sucesso» ou «insucesso» (por exemplo, peça boa ou peça defeituosa);
- a probabilidade de ocorrência de cada resultado mantém-se inalterada de experiência para experiência: $P(\text{sucesso}) = p = \text{constante}$ e $P(\text{insucesso}) = 1 - p = q$;
- os resultados associados a cada experiência são independentes.

As experiências que possuem estas propriedades designam-se por experiências de Bernoulli.

Se Y representar o número de vezes que, no decurso de N experiências de Bernoulli, ocorrem sucessos, então Y segue uma **distribuição Binomial** ou, se se preferir, Y é uma variável aleatória Binomial. Em notação simbólica, escreve-se

$$Y \sim B(N, p).$$

Tendo em conta que, entre os dois resultados possíveis associados a cada experiência, é arbitrária a escolha daquele que constitui um sucesso, a variável que representa o número de insucessos é também binomial: trata-se da variável $B(N, q)$. A preceder a definição da função de probabilidade de Y , $p(y)$, considere-se o exemplo seguinte.

Exemplo 6.1

De uma linha de produção em série, retiram-se 5 peças (uma em cada hora). Admitindo que a percentagem de peças defeituosas se mantém inalterada ao longo do tempo com o valor de 10%, calcular a probabilidade de, entre as cinco peças recolhidas, existirem 0 ou 1 peças defeituosas.

Denotando por Y o número de peças defeituosas em amostras de dimensão 5, considerem-se as seguintes situações:

- ♦ Zero peças defeituosas ($Y = 0$)

Este resultado ocorre quando se obtém a sequência BBBBB (onde B representa «peça boa»).

A probabilidade de uma peça ser boa é $q = 1 - p = 0.90$. Admitindo que as cinco experiências são independentes, a probabilidade associada à sequência BBBBB será

$$p(0) = (0.90)^5$$

- ♦ Uma peça defeituosa ($Y = 1$)

Este resultado ocorre quando se obtém qualquer uma das cinco sequências seguintes (onde D representa «peça defeituosa»):

DBBBB, BDBBB, BBDBB, BBBDB, BBBBD.

A probabilidade de ocorrência de cada uma destas sequências será $(0.1)^1 \cdot (0.9)^4$, pelo que

$$p(1) = 5 \cdot (0.1)^1 \cdot (0.9)^4.$$

Em geral, a função de probabilidade da variável $Y \sim B(N, p)$ só toma valores não-nulos para $Y = 0, 1, \dots, N$ e é definida pela expressão

$$p(y) = \binom{N}{y} \cdot p^y \cdot q^{N-y} \quad [Y \sim B(N, p)]. \quad (6.1)$$


O primeiro termo do segundo membro (combinações de N y a y) representa o número de sequências diferentes com y sucessos, vindo naturalmente multiplicado pela probabilidade de ocorrência de cada uma delas.

A partir da expressão 6.1, calcularam-se as funções de probabilidade e de distribuição da variável $Y \sim B(5, 0.1)$ correspondente ao Exemplo 6.1. Tais funções apresentam-se na Figura 6.1. Deve notar-se que, para outros valores dos parâmetros N e p , as formas destas funções podem ser muito diferentes daquelas que se apresentam.

Os valores das funções de probabilidade e de distribuição para quaisquer variáveis Binomiais podem ser facilmente obtidos recorrendo a *software* de estatística de uso generalizado ou mesmo a alguns tipos de calculadoras. O mesmo sucede em relação a outras distribuições que serão objecto de análise neste capítulo e no seguinte.

Figura 6.1

Função de probabilidade e função de distribuição da variável aleatória $B(5, 0.1)$ (Exemplo 6.1).



A Tabela 1 incluída no Anexo «Tabelas» contém os valores de $p(y)$ para variáveis Binomiais $Y \sim B(N, p)$ com

$$N = 1, 2, \dots, 10, 12, \dots, 20, 50, 100$$

e

$$p = 0.05, 0.10, \dots, 0.50.$$

6.2.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

Tal como se demonstra no Apêndice 6.1, o valor esperado e a variância de uma variável $Y \sim B(N, p)$ têm as seguintes expressões:

$$\begin{aligned} \mu &= N \cdot p \\ \sigma^2 &= N \cdot p \cdot q \quad [Y \sim B(N, p)]. \end{aligned} \quad (6.2)$$

Dado que q é inferior à unidade, destas expressões resulta que a variância da distribuição Binomial é menor do que o seu valor esperado.

Exemplo 6.2

Retomando o Exemplo 6.1, o valor esperado e a variância do número de peças defeituosas, $Y \sim B(5, 0.1)$, vêm

$$\begin{aligned} \mu &= N \cdot p = 5 \cdot 0.1 = 0.5 \\ \sigma^2 &= N \cdot p \cdot q = 5 \cdot 0.1 \cdot 0.9 = 0.45. \end{aligned}$$

Note-se que, apesar de y só tomar valores inteiros, tanto μ como σ^2 são não-inteiros.

6.3 DISTRIBUIÇÃO BINOMIAL NEGATIVA

6.3.1 DEFINIÇÃO

A distribuição **Binomial Negativa** permite descrever o comportamento de uma variável aleatória que, embora estando associada à repetição de experiências de Bernoulli, envolve um processo de contagem distinto daquele que era descrito pela distribuição Binomial. Tal como na secção anterior, denotem-se respectivamente por p e q as probabilidades de sucesso e de insucesso associadas a cada experiência de Bernoulli.

Numa sequência infinita de experiências de Bernoulli, a variável aleatória Y seguirá uma distribuição Binomial Negativa se representar o número de insucessos encontrados até ocorrer o r -ésimo sucesso (onde, naturalmente, r é um número inteiro não-negativo). Em notação simbólica, escreve-se

$$Y \sim BN(r, p).$$

A preceder a definição da função de probabilidade de Y , $p(y)$, considere-se o exemplo seguinte.

Exemplo 6.3

Numa sequência de lançamentos da moeda E-C ao ar, pretende-se determinar a probabilidade de sair três vezes Caravela («insucesso») ($Y = 3$) até, pela segunda vez ($r = 2$), ocorrer um resultado Escudo («sucesso»). Note-se que este resultado é equivalente a sair Escudo pela segunda vez no quinto lançamento.

Tal implica que:

- Nos primeiros quatro lançamentos se registre um resultado E e três resultados C, o que, de acordo com a expressão 6.1, ocorre com probabilidade

$$\binom{4}{3} \cdot (0.5)^3 \cdot (0.5)^1$$

- No quinto lançamento ocorra o resultado E (com probabilidade igual a 0.5).

Então a probabilidade de sair três vezes Caravela até, pela segunda vez, ocorrer um resultado Escudo vem dada por

$$p(3) = \binom{4}{3} \cdot (0.5)^3 \cdot (0.5)^1 \cdot (0.5) = 0.125.$$

Em geral, a função de probabilidade da variável $Y \sim BN(r, p)$ é definida pela expressão


$$p(y) = \binom{y+r-1}{y} \cdot p^r \cdot q^y \quad [Y \sim BN(r, p)]. \quad (6.3)$$

No caso particular em que $r = 1$, Y representa o número de experiências de Bernoulli realizadas até à ocorrência, pela primeira vez, de um sucesso, e a distribuição Binomial Negativa converte-se naquela que se designa por **distribuição Geométrica**. Neste caso, a função de probabilidade obtém-se imediatamente fazendo $r = 1$ na expressão 6.3:

$$p(y) = p \cdot q^y \quad [Y \sim G(p)]. \quad (6.4)$$

A partir da expressão 6.3, calcularam-se as funções de probabilidade e de distribuição da variável $Y \sim BN(2, 0.5)$ correspondente ao Exemplo 6.3. Tais funções apresentam-se na Figura 6.2. Deve observar-se que, para outros valores dos parâmetros r e p , as formas destas funções podem ser muito diferentes daquelas que se apresentam.

Figura 6.2
Função de probabilidade e função de distribuição da variável aleatória $BN(2, 0.5)$ (Exemplo 6.3).



6.3.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

No Apêndice 6.2 mostra-se que o valor esperado e a variância de uma distribuição Binomial Negativa são dados pelas seguintes expressões:

$$\begin{aligned} \mu &= \frac{r \cdot q}{p} \\ \sigma^2 &= \frac{r \cdot q}{p^2} \quad [Y \sim BN(r, p)]. \end{aligned} \quad (6.5)$$

Dado que p é inferior à unidade, das expressões 6.5 resulta que a variância da distribuição Binomial Negativa é sempre maior do que o seu valor esperado.

Exemplo 6.4

Retomando o Exemplo 6.3, o valor esperado e a variância da variável $Y \sim BN(2, 0.5)$ vêm

$$\begin{aligned} \mu &= r \cdot q / p = 2 \cdot 0.5 / 0.5 = 2 \\ \sigma^2 &= r \cdot q / p^2 = 2 \cdot 0.5 / 0.5^2 = 4. \end{aligned}$$

6.4 DISTRIBUIÇÃO HIPERGEOMÉTRICA

6.4.1 DEFINIÇÃO

Considere-se uma população finita constituída por M elementos de dois tipos (por exemplo, peças defeituosas e peças boas). Seja $D \leq M$ o número de elementos de um dos referidos tipos (por exemplo, número de peças defeituosas). Nestas condições, as proporções de peças defeituosas e de peças boas são respectivamente $p = D/M$ e $q = (M - D)/M$.

Admita-se que desta população se retiram sucessivamente, sem reposição (ou, o que é equivalente, de uma só vez, em bloco), N elementos. Se Y representar o número de

elementos de um dos tipos (por exemplo, peças defeituosas) que figuram entre os N que foram retirados da população, então Y segue uma **distribuição Hipergeométrica**. Em notação simbólica, escreve-se

$$Y \sim H(M \cdot p, M \cdot q, N).$$

Como é óbvio, Y só poderá tomar valores inteiros não-negativos até ao limite definido pelo menor dos dois valores seguintes: N e, consoante se trate de um tipo de elementos ou do outro, D ou $M - D$.

A diferença fundamental entre a situação que acaba de se descrever e aquela que estava na base das distribuições Binomial e Binomial Negativa, é que agora as experiências não são de Bernoulli. De facto, uma vez que a população é finita e que se retiram elementos sem reposição, a probabilidade de ocorrência de cada um dos resultados possíveis não se mantém constante de experiência para experiência, e os resultados sucessivos passam a não ser independentes.

Para definir a função de probabilidade de Y , $p(y)$, começa-se por calcular o número de diferentes combinações que é possível efectuar com N elementos a partir dos M que constituem a população:

$$\binom{M}{N} \quad (\text{número de casos possíveis}).$$

De entre estas combinações, o número daquelas que contém exactamente y elementos de um dos tipos (por exemplo, peças defeituosas) é

$$\binom{D}{y} \cdot \binom{M-D}{N-y}$$

ou, de outra forma,

$$\binom{M \cdot p}{y} \cdot \binom{M \cdot q}{N-y} \quad (\text{número de casos favoráveis}).$$

Uma vez que as diferentes combinações de elementos da população são equiprováveis, a função de probabilidade $p(y)$ vem dada por

$$p(y) = \frac{\binom{M \cdot p}{y} \cdot \binom{M \cdot q}{N-y}}{\binom{M}{N}} \quad [Y \sim H(M \cdot p, M \cdot q, N)]. \quad (6.6)$$


Exemplo 6.5

Num lote de 8 peças existem 3 defeituosas. Se desse lote forem retiradas aleatoriamente 3 peças, qual a probabilidade de nelas se encontrarem 0, 1, 2 ou 3 peças defeituosas? Representando por Y o número de peças defeituosas incluídas no conjunto de 3 peças retiradas aleatoriamente do lote, então

$$Y \sim H(3, 5, 3).$$

Na Figura 6.3 encontram-se representadas as funções $p(y)$ e $F(y)$, calculadas recorrendo-se à expressão 6.6. Deve notar-se que, para outros valores dos parâmetros $M \cdot p$, $M \cdot q$ e N , as formas destas funções podem ser muito diferentes daquelas que se apresentam.

Figura 6.3
Função de probabilidade e função de distribuição da variável aleatória $H(3, 5, 3)$ (Exemplo 6.5).



6.4.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

O valor esperado e a variância de uma variável $H(M \cdot p, M \cdot q, N)$ são dados pelas expressões seguintes (ver Apêndice 6.3):

$$\begin{aligned} \mu &= N \cdot p \\ \sigma^2 &= N \cdot p \cdot q \cdot \frac{M-N}{M-1} \quad [Y \sim H(M \cdot p, M \cdot q, N)]. \end{aligned} \quad (6.7)$$

Exemplo 6.6

Retomando o Exemplo 6.5, o valor esperado e a variância da variável $Y \sim H(3, 5, 3)$ vêm

$$\begin{aligned} \mu &= N \cdot p = 3 \cdot 3/8 = 1.125 \\ \sigma^2 &= N \cdot p \cdot q \cdot (M-N)/(M-1) = 3 \cdot 3/8 \cdot 5/8 \cdot 5/7 = 0.502. \end{aligned}$$

6.4.3 RELAÇÃO ENTRE AS DISTRIBUIÇÕES BINOMIAL E HIPERGEOMÉTRICA

Comparando as expressões 6.2 e 6.7, verifica-se que as distribuições Binomial $B(N, p)$ e Hipergeométrica $H(M \cdot p, M \cdot q, N)$ têm valores esperados iguais e variâncias que apenas se distinguem pelo factor $(M-N)/(M-1)$. Quando M é muito maior do que N , o facto de não haver reposição dos elementos retirados da população não afecta substancialmente as probabilidades associadas aos resultados das experiências nem tão-pouco gera dependência entre tais resultados. Nesta situação, o termo $(M-N)/(M-1)$ é próximo da unidade e a distribuição Hipergeométrica $H(M \cdot p, M \cdot q, N)$ aproxima-se da distribuição Binomial $B(N, p)$.

Exemplo 6.7

Numa determinada caixa, misturaram-se por engano 10 parafusos defeituosos com 90 em bom estado. Se for retirada daquela caixa uma amostra aleatória de dez parafusos, o número Y de parafusos defeituosos nela incluídos segue uma distribuição $H(10, 90, 10)$. Na Tabela 6.1 apresentam-se os valores das funções de probabilidade desta distribuição e da distribuição $B(10, 0.1)$ para $y \leq 5$, bem como os respectivos valores esperados e variâncias. A comparação entre os valores apresentados revela uma razoável semelhança entre as duas distribuições.

Tabela 6.1
Comparação entre
as funções de
probabilidade
das distribuições
 $H(10, 90, 10)$
e $B(10, 0.1)$
(Exemplo 6.7)

Y	$H(10, 90, 10)$	$B(10, 0.1)$
0	0.330	0.349
1	0.408	0.387
2	0.202	0.194
3	0.052	0.057
4	0.008	0.011
5	0.010	0.002
μ	1.000	1.000
σ^2	0.818	0.900

A aproximação da distribuição Hipergeométrica pela Binomial é útil, uma vez que o cálculo da função de probabilidade da segunda é mais simples. Como regra prática, é habitual indicar-se que a distribuição $H(M \cdot p, M \cdot q, N)$ pode ser aproximada pela distribuição $B(N, p)$ quando se verifica que $M \geq 10 \cdot N$. Note-se que, mesmo nestas condições, a aproximação entre as distribuições é aceitável apenas globalmente. De facto, consultando a Tabela 6.1 e comparando individualmente os valores das funções de probabilidade correspondentes às caudas, verificam-se grandes diferenças entre as duas distribuições. Este comentário é extensível às aproximações que mais adiante serão tratadas noutras secções deste capítulo.

6.5 DISTRIBUIÇÃO DE POISSON


6.5.1 DEFINIÇÃO

A **distribuição de Poisson** (desenvolvida pelo matemático francês S. D. Poisson, nascido em 1781) permite descrever um vasto conjunto de fenómenos aleatórios em que os acontecimentos se repetem no tempo (por exemplo, as entradas de clientes num supermercado) ou no espaço (por exemplo, os defeitos de isolamento registados ao longo de um cabo eléctrico ou os defeitos de acabamento numa placa de vidro).

Para simplificar a exposição, definir-se-á a distribuição de Poisson apenas para o caso em que se admite que as ocorrências do fenómeno aleatório se repetem ao longo do tempo (as modificações que seria necessário introduzir para descrever fenómenos que se repetem no espaço são absolutamente triviais).

Imagine-se que, tal como se representa na Figura 6.4, o tempo se encontra dividido numa partição de intervalos de pequena dimensão, Δt .

Figura 6.4
Partição do tempo
em intervalos de
dimensão Δt .



A variável discreta *número de ocorrências por unidade de tempo* seguirá uma distribuição de Poisson quando se verificarem as quatro condições (ou postulados) seguintes:

- C1. Os números de ocorrências registadas nos intervalos da partição são independentes entre si.
- C2. A distribuição do número de ocorrências em cada intervalo é a mesma para todos os intervalos.
- C3. A probabilidade de se registar uma ocorrência num intervalo qualquer de dimensão Δt , ΔP_1 , é praticamente proporcional à dimensão do intervalo, ou seja,

$$\Delta P_1 \approx \lambda \cdot \Delta t$$

onde λ representa uma constante positiva. No limite, quando a dimensão do intervalo tende para zero, admite-se que

$$\lim_{\Delta t \rightarrow 0} \frac{\Delta P_1}{\Delta t} = \frac{d P_1}{d t} = \lambda.$$

- C4. A probabilidade de se registarem duas, três ou mais ocorrências num intervalo qualquer de dimensão Δt , ΔP_n ($n \geq 2$) é desprezável quando comparada com a probabilidade ΔP_1 . No limite, quando a dimensão do intervalo tende para zero, admite-se que

$$\lim_{\Delta t \rightarrow 0} \frac{\Delta P_n}{\Delta t} = \frac{d P_n}{d t} = 0 \quad (n \geq 2)$$

(note-se que, desta condição, decorre que as ocorrências de fenómenos descritos pela distribuição de Poisson se verificam uma a uma e nunca aos grupos).

A partir destas condições, pode estabelecer-se a forma funcional da distribuição de Poisson. Como se mostra no Apêndice 6.4, a probabilidade de se registarem y ocorrências no intervalo $[0, t]$ é dada por:

$$p_y(t) = e^{-\lambda \cdot t} \cdot \frac{(\lambda \cdot t)^y}{y!}. \quad (6.8)$$

Esta expressão define a função de probabilidade de uma variável aleatória Y ($Y = 0, 1, 2, \dots$) seguindo uma distribuição de Poisson com parâmetro $\lambda \cdot t$. Como se verá na secção seguinte, o parâmetro $\lambda \cdot t$ representa o valor esperado ($\mu_y(t)$) do número de ocorrências num intervalo qualquer de dimensão t . Assim, $\lambda = \mu_y(t)/t$ corresponde ao número médio de ocorrências por unidade de tempo, ou seja, corresponde à **taxa média de ocorrências**.

Interpretado o significado de λ , pode reescrever-se a função de probabilidade de Y expressando-a para um intervalo de tempo ou de espaço de dimensão unitária ($t = 1$) e adoptando uma notação idêntica à que foi utilizada nas secções anteriores:

$$p_y(y) = e^{-\lambda} \cdot \frac{\lambda^y}{y!} \quad [Y \sim \text{Poisson}(\lambda)]. \quad (6.9)$$

Na Tabela 2 do Anexo «Tabelas» apresentam-se os valores da função de distribuição

$$F(y) = \sum_{u=0}^y e^{-\lambda} \cdot \frac{\lambda^u}{u!}$$

para $\lambda = 0.1, 0.2, 0.3, \dots, 5.0, 5.5, 6.0, \dots, 10.0$.

Exemplo 6.8

Durante o horário do almoço (das 12 às 14 horas), o número médio de automóveis que chegam a um parque de estacionamento do centro de uma cidade é de 360. Qual será a probabilidade de, durante um minuto, chegarem $y = 0, 1, 2, \dots$ automóveis?


A taxa média de chegadas (por minuto) é

$$\lambda = 360 / 120 \text{ minutos} = 3 / \text{minuto}.$$

Admitindo que se verificam as condições apresentadas na Secção 6.5.1 e que, portanto, o número de chegadas de automóveis por minuto é uma variável $Y \sim \text{Poisson}(3)$, os valores correspondentes de $p(y)$ podem ser calculados recorrendo à expressão 6.9 ou, alternativamente, podem ser obtidos a partir dos valores de $F(y)$ incluídos na Tabela 2 do Anexo «Tabelas».

Os valores das funções de probabilidade e de distribuição da variável Poisson (3) apresentam-se na Figura 6.5. Deve notar-se que, para outros valores do parâmetro λ , as formas destas funções podem ser muito diferentes daquelas que se apresentam.

Figura 6.5
Função de probabilidade e função de distribuição de uma variável Poisson (3)
(Exemplo 6.8).



6.5.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

Uma das particularidades interessantes da distribuição de Poisson é a de que o valor esperado e variância são iguais. De facto, tal como se demonstra no Apêndice 6.5, os valores destes parâmetros são dados por:

$$\begin{aligned}\mu &= \lambda \\ \sigma^2 &= \lambda.\end{aligned}\quad (6.10)$$

Exemplo 6.9

O número de chamadas telefónicas que, em média, são recebidas por hora na recepção de uma empresa é de 45. Qual será o valor esperado e o desvio padrão do número de chamadas recebidas por minuto?

Assumindo que o número de chamadas recebidas por unidade de tempo segue uma distribuição de Poisson, então

$\lambda = 45 \text{ chamadas} / 60 \text{ minutos} = 0.75 \text{ chamadas} / \text{minuto}$,
resultando

$$\mu = \lambda = 0.75 \quad \text{e} \quad \sigma = \sqrt{\lambda} = 0.866.$$

6.5.3 RELAÇÃO ENTRE A DISTRIBUIÇÃO DE POISSON E AS DISTRIBUIÇÕES BINOMIAL E HIPERGEOMÉTRICA

Considere-se uma distribuição Binomial $B(N, p)$ e tome-se a situação limite na qual $N \rightarrow \infty$ e $N \cdot p = \lambda$.

Nesta situação o número de experiências de Bernoulli cresce para infinito, e a probabilidade de sucesso decresce para zero, por forma a que o número médio de sucessos se mantenha constante em torno do valor λ .

Pode demonstrar-se (ver Apêndice 6.6) que, nestas condições, a distribuição de Poisson com parâmetro λ constitui uma boa aproximação daquela distribuição Binomial. Em termos simbólicos, a relação entre as duas distribuições pode expressar-se através da expressão seguinte:

$$\lim_{\substack{N \rightarrow \infty \\ (N \cdot p = \lambda)}} B(N, p) \equiv \text{Poisson}(\lambda). \quad (6.11)$$

O interesse prático de aproximar uma distribuição Binomial por uma de Poisson resulta de o cálculo da função de probabilidade ser mais simples no segundo caso. Tal aproximação só é razoável quando N for grande ($N \geq 20$) e só tem interesse quando a distribuição Binomial for assimétrica ($N \cdot p \leq 7$ e $N \cdot q \leq 7$). De facto, como se verá no próximo capítulo, se a distribuição Binomial for simétrica (ou quase simétrica), é mais prático aproximá-la por uma outra distribuição (a distribuição Normal).

Exemplo 6.10

Na Tabela 6.2 comparam-se as distribuições binomiais $B(10, 0.1)$, $B(20, 0.05)$, $B(100, 0.01)$ com a distribuição Poisson (1).

Tabela 6.2
Comparação entre as funções de probabilidades das distribuições $B(10, 0.1)$, $B(20, 0.05)$ e $B(100, 0.01)$ e da distribuição Poisson (1)
(Exemplo 6.10).

Y	B (10, 0.1)	B (20, 0.05)	B (100, 0.01)	Poisson (1)
0	0.349	0.359	0.366	0.368
1	0.387	0.377	0.370	0.368
2	0.194	0.189	0.185	0.184
3	0.057	0.060	0.061	0.061
4	0.011	0.013	0.015	0.015
5	0.002	0.002	0.003	0.003
μ	1.000	1.000	1.000	1.000
σ^2	0.900	0.950	0.990	1.000

Como se viu na Secção 6.4.3, há situações em que a distribuição Hipergeométrica se aproxima da distribuição Binomial. Se, por sua vez, esta distribuição estiver em condições de ser aproximada pela distribuição de Poisson, pode recorrer-se a esta última para calcular os valores da função de probabilidade da distribuição Hipergeométrica. Este procedimento encontra-se ilustrado no exemplo seguinte.

Exemplo 6.11


Admita-se que numa caixa se misturaram 35 peças defeituosas com 665 em bom estado e que posteriormente se retira desta caixa (contendo 700 peças) uma amostra aleatória de dimensão 30.

A variável $Y \sim H(35, 665, 30)$ representa o número de peças defeituosas na amostra.

Na Tabela 6.3 comparam-se a função de probabilidade da distribuição $H(35, 665, 30)$ e a da distribuição de Poisson com parâmetro $\lambda = N \cdot p = 30 \cdot 35 / 700 = 1.5$.

Tabela 6.3
Comparação entre as funções de probabilidade das distribuições $H(35, 665, 30)$ e Poisson (1.5)
(Exemplo 6.11).

Y	H (35, 665, 30)	Poisson (1.5)
0	0.2075	0.2231
1	0.3426	0.3347
2	0.2652	0.2510
3	0.1280	0.1256
4	0.0433	0.0470
5	0.0109	0.0141
6	0.0021	0.0036
7	0.0003	0.0007
8	0.0000	0.0002
μ	1.500	1.500
σ^2	1.366	1.500



■ APÊNDICE 6.1. VALOR ESPERADO E VARIÂNCIA DE UMA VARIÁVEL ALEATÓRIA BINOMIAL $Y \sim B(N, p)$

- (1) A função geradora de momentos da variável aleatória $Y \sim B(N, p)$ é

$$\begin{aligned} G(t) &= E[e^{t \cdot Y}] \\ &= \sum_{y=0}^N e^{t \cdot y} \cdot \binom{N}{y} \cdot p^y \cdot q^{N-y} \\ &= \sum_{y=0}^N \binom{N}{y} \cdot (p \cdot e^t)^y \cdot q^{N-y} \quad (\text{desenvolvimento do binômio de Newton}) \\ &= (p \cdot e^t + q)^N. \end{aligned}$$

- (2) Derivando $G(t)$ em ordem a t vem,

$$\begin{aligned} G'(t) &= N \cdot p \cdot e^t \cdot (p \cdot e^t + q)^{N-1} \\ G''(t) &= N \cdot p \cdot e^t \cdot (p \cdot e^t + q)^{N-1} + N \cdot (N-1) \cdot (p \cdot e^t)^2 \cdot (p \cdot e^t + q)^{N-2}. \end{aligned}$$

- (3) Assim,

$$E(Y) = G'(0) = N \cdot p$$

ou seja,

$$\mu = N \cdot p \quad (\text{primeira das expressões 6.2}).$$

- (4) A variância de Y pode ser escrita na forma seguinte:

$$\sigma^2 = E(Y^2) - [E(Y)]^2 \quad (\text{A6.1.1})$$

(note-se que esta é uma forma diferente, mas equivalente, de exprimir a relação 4.28).

- (5) Assim, como

$$E(Y^2) = G''(0) = N \cdot p + N \cdot (N-1) \cdot p^2,$$

a expressão A.6.1.1 vem

$$\sigma^2 = N \cdot p + N \cdot (N-1) \cdot p^2 - (N \cdot p)^2 = N \cdot p - N \cdot p^2 = N \cdot p \cdot (1-p)$$

e, portanto,

$$\sigma^2 = N \cdot p \cdot q \quad (\text{segunda das expressões 6.2}).$$

■ APÊNDICE 6.2. VALOR ESPERADO E VARIÂNCIA DE UMA VARIÁVEL ALEATÓRIA BINOMIAL NEGATIVA $Y \sim BN(r, p)$

- (1) A função geradora de momentos da variável aleatória $Y \sim BN(r, p)$ vem

$$\begin{aligned} G(t) &= E[e^{t \cdot Y}] \\ &= \sum_{y=0}^{\infty} e^{t \cdot y} \cdot \binom{y+r-1}{y} \cdot p^r \cdot q^y \\ &= \sum_{y=0}^{\infty} \binom{y+r-1}{y} \cdot p^r \cdot (q \cdot e^t)^y. \end{aligned} \quad (\text{A6.2.1})$$

- (2) O desenvolvimento em série de Taylor da função

$$f(x) = (1-x)^{-n}$$

conduz a

$$(1-x)^{-n} = \sum_{j=0}^{\infty} \binom{j+n-1}{j} \cdot x^j. \quad (\text{A6.2.2})$$

- (3) Fazendo $j = y$, $n = r$ e $x = q \cdot e^t$ na expressão A6.2.2, obtém-se

$$(1 - q \cdot e^t)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{y} \cdot (q \cdot e^t)^y.$$

donde, por substituição em A6.2.1, resulta

$$G(t) = p^r \cdot (1 - q \cdot e^t)^{-r}. \quad (\text{A6.2.3})$$

- (4) Derivando a expressão A6.2.3 em ordem a t , vem

$$\begin{aligned} G'(t) &= p^r \cdot (-r) \cdot (1 - q \cdot e^t)^{-r-1} \cdot (-q \cdot e^t) = p^r \cdot r \cdot q \cdot [(1 - q \cdot e^t)^{-r-1} \cdot e^t] \\ G''(t) &= p^r \cdot r \cdot q \cdot [(r+1) \cdot q \cdot e^{2t} \cdot (1 - q \cdot e^t)^{-r-2} + 1 \cdot e^t \cdot (1 - q \cdot e^t)^{-r-1}]. \end{aligned}$$

- (5) Assim,

$$E(Y) = G'(0) = p^r \cdot r \cdot q \cdot p^{-r-1} = \frac{r \cdot q}{p},$$

ou seja,

$$\mu = \frac{r \cdot q}{p} \quad (\text{primeira das expressões 6.5}).$$

(6) De forma análoga,

$$E(Y^2) = G''(0) = p^r \cdot r \cdot q \cdot [q \cdot (r+1) \cdot p^{-r-2} + p^{-r-1}] = \frac{r^2 \cdot q^2}{p^2} + \frac{r \cdot q^2}{p^2} + \frac{r \cdot q}{p}.$$

(7) Como

$$\sigma^2 = E(Y^2) - [E(Y)]^2,$$

vem

$$\sigma^2 = \frac{r^2 \cdot q^2}{p^2} + \frac{r \cdot q^2}{p^2} + \frac{r \cdot q}{p} - \left(\frac{r \cdot q}{p}\right)^2 = \frac{r \cdot q}{p^2} \cdot (q + p)$$

ou, finalmente,

$$\sigma^2 = \frac{r \cdot q}{p^2} \quad (\text{segunda das expressões 6.5}).$$

APÊNDICE 6.3 VALOR ESPERADO E VARIÂNCIA DE UMA VARIÁVEL ALEATÓRIA HIPERGEOMÉTRICA $Y \sim H(M \cdot p, M \cdot q, N)$

(1) O valor esperado da variável aleatória $Y \sim H(M \cdot p, M \cdot q, N)$ é dado por

$$\begin{aligned} \mu &= \sum_{y=0}^N y \cdot \frac{\binom{M \cdot p}{y} \cdot \binom{M \cdot q}{N-y}}{\binom{M}{N}} \\ &= \sum_{y=1}^N y \cdot \frac{\frac{M \cdot p}{y} \cdot \binom{M \cdot p - 1}{y-1} \cdot \binom{M \cdot q}{N-y}}{\frac{M}{N} \cdot \binom{M-1}{N-1}} = N \cdot p \cdot \sum_{y=1}^N \frac{\binom{M \cdot p - 1}{y-1} \cdot \binom{M \cdot q}{N-y}}{\binom{M-1}{N-1}}. \end{aligned}$$

(2) Fazendo $k = y - 1$, obtém-se

$$\begin{aligned} \mu &= N \cdot p \cdot \sum_{k=0}^{N-1} \frac{\binom{M \cdot p - 1}{k} \cdot \binom{M \cdot q}{N-1-k}}{\binom{M-1}{N-1}} \\ &= N \cdot p \cdot \frac{\binom{M \cdot p - 1 + M \cdot q}{N-1}}{\binom{M-1}{N-1}} = N \cdot p \cdot \frac{\binom{M-1}{N-1}}{\binom{M-1}{N-1}} \end{aligned}$$

ou, finalmente,

$$\mu = N \cdot p \quad (\text{primeira das expressões 6.7}). \quad (\text{A6.3.1})$$

(3) Para definir a expressão da variância, comece-se por calcular $E[Y \cdot (Y-1)]$:

$$\begin{aligned} E[Y \cdot (Y-1)] &= \sum_{y=0}^N y \cdot (y-1) \cdot \frac{\binom{M \cdot p}{y} \cdot \binom{M \cdot q}{N-y}}{\binom{M}{N}} \\ &= N \cdot (N-1) \cdot p \cdot \frac{M \cdot p - 1}{M-1} \cdot \sum_{y=2}^N \frac{\binom{M \cdot p - 2}{y-2} \cdot \binom{M \cdot q}{N-y}}{\binom{M-2}{N-2}}. \end{aligned} \quad (\text{A6.3.2})$$

(4) Fazendo $k = y - 2$, vem

$$\sum_{y=2}^N \frac{\binom{M \cdot p - 2}{y-2} \cdot \binom{M \cdot q}{N-y}}{\binom{M-2}{N-2}} = \sum_{k=0}^{N-2} \frac{\binom{M \cdot p - 2}{k} \cdot \binom{M \cdot q}{N-2-k}}{\binom{M-2}{N-2}} = \frac{\binom{M \cdot p - 2 + M \cdot q}{k + N - 2 - k}}{\binom{M-2}{N-2}} = 1.$$

(5) Então, a expressão A6.3.2 converte-se em

$$E[Y \cdot (Y-1)] = N \cdot (N-1) \cdot p \cdot \frac{M \cdot p - 1}{M-1}. \quad (\text{A6.3.3})$$

(6) Por outro lado,

$$E[Y \cdot (Y-1)] = E(Y^2) - E(Y)$$

e, portanto,

$$\sigma^2 = E[Y \cdot (Y-1)] + E(Y) - [E(Y)]^2. \quad (\text{A6.3.4})$$

(7) Substituindo A6.3.1 e A6.3.3 em A6.3.4 e desenvolvendo, obtém-se

$$\begin{aligned} \sigma^2 &= N \cdot (N-1) \cdot p \cdot \frac{M \cdot p - 1}{M-1} + N \cdot p - N^2 \cdot p^2 \\ &= N \cdot p \cdot \left[(N-1) \cdot \frac{M \cdot p - 1}{M-1} + 1 - N \cdot p \right] \\ &= N \cdot p \cdot \left[\frac{N \cdot M \cdot p - N - M \cdot p + 1 + M - 1 - N \cdot M \cdot p + N \cdot p}{M-1} \right] \\ &= N \cdot p \cdot \left[\frac{-N - M \cdot p + M + N \cdot p}{M-1} \right] \\ &= N \cdot p \cdot \left[\frac{(M-N) \cdot (1-p)}{M-1} \right] \end{aligned}$$

ou, finalmente,

$$\sigma^2 = N \cdot p \cdot q \cdot \frac{M-N}{M-1} \quad (\text{segunda das expressões 6.7}).$$

■ APÊNDICE 6.4 CARACTERIZAÇÃO DA FUNÇÃO DE PROBABILIDADE DA DISTRIBUIÇÃO DE POISSON

- (1) Denote-se por $p_y(t)$ a probabilidade de se verificarem y ocorrências (com $y = 0, 1, 2, \dots$) no intervalo $[0, t]$.
- (2) Calcule-se $p_y(t + \Delta t)$ (ou seja, a probabilidade de se registarem y ocorrências no intervalo $[0, t + \Delta t]$), considerando separadamente as duas situações seguintes:

$$y = 0$$

e

$$y > 0.$$

- (3) Desenvolvimento de $p_0(t + \Delta t)$

A não ocorrência do fenómeno no intervalo $[0, t + \Delta t]$ é equivalente à não ocorrência do fenómeno tanto no intervalo $[0, t]$ como no intervalo $[t, t + \Delta t]$. Tendo em conta a condição C1, vem

$$p_0(t + \Delta t) = p_0(t) \cdot \Delta P_0 \quad (\text{A6.4.1})$$

onde ΔP_0 , a probabilidade de não se registar qualquer ocorrência no intervalo $[t, t + \Delta t]$, é dada por

$$\begin{aligned} \Delta P_0 &= 1 - \Delta P_1 - \Delta P_2 - \Delta P_3 - \dots \\ &= 1 - \Delta P_1 - \sum_{n=2}^{\infty} \Delta P_n \end{aligned} \quad (\text{A6.4.2})$$

Substituindo A6.4.2 em A6.4.1, obtém-se

$$p_0(t + \Delta t) = p_0(t) \cdot \left(1 - \Delta P_1 - \sum_{n=2}^{\infty} \Delta P_n \right)$$

ou, reordenando os termos,

$$p_0(t + \Delta t) - p_0(t) = -p_0(t) \cdot \left(\Delta P_1 + \sum_{n=2}^{\infty} \Delta P_n \right)$$

Dividindo ambos os membros desta equação por Δt , obtém-se

$$\frac{p_0(t + \Delta t) - p_0(t)}{\Delta t} = -p_0(t) \cdot \left(\frac{\Delta P_1}{\Delta t} + \sum_{n=2}^{\infty} \frac{\Delta P_n}{\Delta t} \right).$$

Tomando o limite desta expressão quando Δt tende para zero e tendo em conta as condições C3 e C4, vem

$$\frac{dp_0(t)}{dt} = -p_0(t) \cdot \left[\frac{dP_1}{dt} + \sum_{n=2}^{\infty} \frac{dP_n}{dt} \right] = -p_0(t) \cdot [\lambda + 0]$$

ou

$$\frac{dp_0(t)}{dt} = -\lambda \cdot p_0(t). \quad (\text{A6.4.3})$$

- (4) Desenvolvimento de $p_y(t + \Delta t)$ (com $y > 0$)

Neste caso, a(s) ocorrência(s) registada(s) no intervalo $[0, t + \Delta t]$ distribuir-se-á(ão) pelos intervalos $[0, t]$ e $[t, t + \Delta t]$. Por exemplo, para $y = 3$, as combinações de ocorrências a considerar são (3, 0), (2, 1), (1, 2) e (0, 3), vindo

$$p_3(t + \Delta t) = p_3(t) \cdot \Delta P_0 + p_2(t) \cdot \Delta P_1 + p_1(t) \cdot \Delta P_2 + p_0(t) \cdot \Delta P_3$$

ou, substituindo ΔP_0 pela sua expressão A6.4.2,

$$p_3(t + \Delta t) = p_3(t) \cdot \left(1 - \Delta P_1 - \sum_{n=2}^{\infty} \Delta P_n\right) + p_2(t) \cdot \Delta P_1 + p_1(t) \cdot \Delta P_2 + p_0(t) \cdot \Delta P_3.$$

Reordenando os termos, obtém-se

$$p_3(t + \Delta t) - p_3(t) = -p_3(t) \cdot \Delta P_1 - p_3(t) \cdot \sum_{n=2}^{\infty} \Delta P_n + p_2(t) \cdot \Delta P_1 + p_1(t) \cdot \Delta P_2 + p_0(t) \cdot \Delta P_3.$$

Dividindo ambos os membros desta equação por Δt e tomando o limite quando Δt tende para zero, obtém-se

$$\begin{aligned} \frac{dp_3(t)}{dt} &= -p_3(t) \cdot \frac{dP_1}{dt} - p_3(t) \cdot \sum_{n=2}^{\infty} \frac{dP_n}{dt} + p_2(t) \cdot \frac{dP_1}{dt} + p_1(t) \cdot \frac{dP_2}{dt} + p_0(t) \cdot \frac{dP_3}{dt} \\ &= \lambda \cdot [p_2(t) - p_3(t)]. \end{aligned}$$

Seria fácil generalizar este resultado ao caso geral em que $y > 0$, obtendo-se

$$\frac{dp_y(t)}{dt} = \lambda \cdot [p_{y-1}(t) - p_y(t)] \quad (y > 0). \quad (\text{A6.4.4})$$

- (5) É imediato verificar que o sistema constituído pelas equações diferenciais A6.4.3 e A6.4.4 admite como solução geral

$$p_y(t) = e^{-\lambda \cdot t} \cdot \frac{(\lambda \cdot t)^y}{y!} \quad (y \geq 0) \quad (\text{expressão 6.8}).$$

De facto, para $y = 0$, obtém-se

$$p_0(t) = e^{-\lambda \cdot t} \cdot \frac{(\lambda \cdot t)^0}{0!} = e^{-\lambda \cdot t}$$

e

$$\frac{dp_0(t)}{dt} = -\lambda \cdot e^{-\lambda \cdot t} = -\lambda \cdot p_0(t),$$

resultado que está de acordo com a expressão A6.4.3.

Para $y > 0$, vem

$$\begin{aligned} \frac{dp_y(t)}{dt} &= \frac{d}{dt} \left[e^{-\lambda \cdot t} \cdot \frac{(\lambda \cdot t)^y}{y!} \right] \\ &= -\lambda \cdot e^{-\lambda \cdot t} \cdot \frac{(\lambda \cdot t)^y}{y!} + e^{-\lambda \cdot t} \cdot y \cdot \frac{(\lambda \cdot t)^{y-1}}{y!} \cdot \lambda \\ &= -\lambda \cdot \left[e^{-\lambda \cdot t} \cdot \frac{(\lambda \cdot t)^y}{y!} \right] + \lambda \cdot \left[e^{-\lambda \cdot t} \cdot \frac{(\lambda \cdot t)^{y-1}}{(y-1)!} \right] \\ &= -\lambda \cdot p_y(t) + \lambda \cdot p_{y-1}(t) \\ &= -\lambda \cdot [p_{y-1}(t) - p_y(t)], \end{aligned}$$

resultado que está de acordo com a expressão A6.4.4.

■ APÊNDICE 6.5 VALOR ESPERADO E VARIÂNCIA DE UMA VARIÁVEL ALEATÓRIA $Y \sim \text{POISSON}(\lambda)$

- (1) A função geradora de momentos da variável aleatória $Y \sim \text{POISSON}(\lambda)$ é

$$G(t) = E[e^{t \cdot Y}] = \sum_{y=0}^{\infty} e^{t \cdot y} \cdot e^{-\lambda} \cdot \frac{\lambda^y}{y!} = e^{-\lambda} \cdot \underbrace{\sum_{y=0}^{\infty} \frac{(\lambda \cdot e^t)^y}{y!}}_{=e^{\lambda \cdot e^t}},$$

donde

$$G(t) = e^{-\lambda} \cdot e^{\lambda \cdot e^t}. \quad (\text{A6.5.1})$$

- (2) Derivando a expressão A6.5.1 em ordem a t , vem

$$G'(t) = e^{-\lambda} \cdot e^{\lambda \cdot e^t} \cdot \lambda \cdot e^t = \lambda \cdot e^{-\lambda} \cdot e^{(\lambda + t) \cdot e^t}$$

$$G''(t) = \lambda \cdot e^{-\lambda} \cdot e^{(\lambda + t) \cdot e^t} \cdot (1 + \lambda \cdot e^t).$$

- (3) Assim,

$$E(Y) = G'(0) = \lambda,$$

ou seja,

$$\mu = \lambda \quad (\text{primeira das expressões 6.13}).$$

- (4) Por outro lado,

$$E(Y^2) = G''(0) = \lambda \cdot (\lambda + 1).$$

- (5) Como

$$\sigma^2 = E(Y^2) - [E(Y)]^2,$$

vem

$$\sigma^2 = E(Y^2) - [E(Y)]^2 = \lambda \cdot (\lambda + 1) - \lambda^2,$$

ou, finalmente,

$$\sigma^2 = \lambda \quad (\text{segunda das expressões 6.13}).$$

■ APÊNDICE 6.6 APROXIMAÇÃO DE UMA DISTRIBUIÇÃO BINOMIAL (N, p) DE UMA DISTRIBUIÇÃO DE POISSON (λ)

(1) A função de probabilidade da variável $Y \sim B(N, p)$ pode ser reescrita na forma seguinte:


$$\begin{aligned} p(y) &= \binom{N}{y} \cdot p^y \cdot q^{N-y} \\ &= \frac{1}{y!} \cdot [N \cdot (N-1) \cdot \dots \cdot (N-y+1)] \cdot p^y \cdot q^{N-y} \\ &= \frac{1}{y!} \cdot \left[\frac{N \cdot (N-1) \cdot \dots \cdot (N-y+1)}{N^y} \right] \cdot (N \cdot p)^y \cdot q^{N-y} \\ &= \frac{1}{y!} \cdot \left[1 \cdot \left(1 - \frac{1}{N}\right) \cdot \left(1 - \frac{2}{N}\right) \cdot \dots \cdot \left(1 - \frac{y-1}{N}\right) \right] \cdot (N \cdot p)^y \cdot q^{N-y}. \end{aligned}$$

(2) Admitindo que $N \cdot p = \lambda$ e tomando o limite de $p(y)$ quando $N \rightarrow \infty$, obtém-se

$$\begin{aligned} \lim_{N \rightarrow \infty} p(y) &= \lim_{N \rightarrow \infty} \left\{ \frac{1}{y!} \cdot \left[1 \cdot \left(1 - \frac{1}{N}\right) \cdot \dots \cdot \left(1 - \frac{y-1}{N}\right) \right] \cdot (N \cdot p)^y \cdot q^{N-y} \right\} \\ &= \lim_{N \rightarrow \infty} \left\{ \frac{1}{y!} \cdot \left[1 \cdot \left(1 - \frac{1}{N}\right) \cdot \dots \cdot \left(1 - \frac{y-1}{N}\right) \right] \cdot \lambda^y \cdot \left(1 - \frac{\lambda}{N}\right)^{N-y} \right\} \\ &= \frac{1}{y!} \cdot \lambda^y \cdot \lim_{N \rightarrow \infty} \left\{ \left[1 \cdot \left(1 - \frac{1}{N}\right) \cdot \dots \cdot \left(1 - \frac{y-1}{N}\right) \right] \cdot \left(1 - \frac{\lambda}{N}\right)^N / \left(1 - \frac{\lambda}{N}\right)^y \right\} \\ &= \frac{1}{y!} \cdot \lambda^y \cdot \left\{ [1] \cdot \frac{e^{-\lambda}}{1} \right\} \\ &= \frac{1}{y!} \cdot \lambda^y \cdot e^{-\lambda} \end{aligned}$$

ou seja,

$$\lim_{\substack{N \rightarrow \infty \\ (N \cdot p = \lambda)}} B(N, p) \equiv \text{Poisson}(\lambda) \quad (\text{expressão 6.11})$$



- 6.1. O patrão da firma patrocinadora RFM estima que a probabilidade de um Fórmula 1 de determinada marca completar um Grande Prémio é de 20%.
- Calcule a probabilidade de, num conjunto de 6 Grandes Prémios, o Fórmula 1 completar
 - exactamente 2 Grandes Prémios
 - pelo menos 3 Grandes Prémios
 - no máximo 2 Grandes Prémios.
 - Se a firma patrocinar 3 carros Fórmulas 1 da marca em questão, calcular a probabilidade de, no conjunto dos 6 Grandes Prémios, haver pelo menos três nos quais haja, no mínimo, 2 carros Fórmula 1 à chegada.
- 6.2. O Conselho de Gerência de uma determinada empresa, constituído por um presidente e 6 vogais, prepara-se para tomar uma decisão polémica. O presidente deseja ver a «sua» proposta aprovada, mas não está certo de conseguir a maioria dos 7 votos do Conselho (maioria essa que é necessária para que consiga a aprovação). Admite-se que os 6 vogais actuarão independentemente e que a probabilidade de que cada um deles vote favoravelmente a proposta é de 35%.
- Calcule a probabilidade de a proposta ser aprovada.
 - Qual será o valor desta probabilidade se o presidente tiver a certeza que dois dos vogais votarão a favor dele?
 - Admita que, em alternativa a (ii), o presidente convoca dois vogais para, antes da votação do Conselho, formarem uma aliança. Os três concordam em fazer uma votação prévia entre si e comprometem-se a formar um bloco no Conselho, votando neste, de acordo com a decisão tomada por maioria entre si. Calcule a probabilidade de, nestas condições, a proposta vir a ser aprovada.
- 6.3. Uma empresa de calços de travões sabe que 5% dos calços por si produzidos são defeituosos. Uma remessa de 10 calços foi enviada a um cliente que usa o seguinte critério de recepção:
- «A remessa é rejeitada se, entre 2 calços seleccionados ao acaso, houver pelo menos um defeituoso».
- Calcule a probabilidade de a remessa ser rejeitada.
- 6.4. Admita que, no final de uma linha de soldadura automática, 7% das peças são retocadas manualmente por um operador. Admita ainda que o ritmo de produção é uma peça por minuto.
- Calcule a probabilidade de o operador permanecer dez minutos sem executar nenhum retoque.
 - Calcule a probabilidade de, numa sequência de seis peças, a última ser a segunda peça a necessitar de retoque.
 - Calcule o tempo que, em média, o operador permanece sem executar nenhum retoque.

- 6.5. Para comemorar o 50.º aniversário de uma revolução, os correios de um país puseram recentemente em circulação um conjunto de seis selos com um valor correspondente à tarifa mínima de expedição de cartas.

Um determinado coleccionador possui já quatro daqueles selos e continuará a recolher os selos de todas as cartas que lhe forem dirigidas. Admitindo que cada carta recebida contém um só selo, defina a distribuição de probabilidade da variável seguinte:

Y : número de cartas com um selo comemorativo da revolução recebidas pelo coleccionador até estar completa a sua colecção.

- 6.6. De um lote de 300 peças retiram-se 5. Admitindo que a percentagem de peças defeituosas no lote é de 1%, calcule a probabilidade de, entre as 5 peças retiradas, haver pelo menos uma que é defeituosa.

- 6.7. Uma máquina que funciona em contínuo tem, em média, duas avarias por cada turno de 8 horas de funcionamento. Para efeitos práticos, pode considerar-se que as avarias são reparadas instantaneamente.

Se numa oficina estiverem a funcionar em simultâneo 20 máquinas daquele tipo, calcule:

- (i) a probabilidade de ocorrerem 3 avarias nos últimos 10 minutos de um turno;
- (ii) o valor esperado e a variância do número global de avarias por hora.

- 6.8. Num processo de fabricação de placas de vidro produzem-se pequenas bolhas que se distribuem aleatoriamente pelas placas, com uma densidade média de 0.4 bolhas/m².

- (i) Calcule a probabilidade de, numa placa de 1.5 · 3.0 m², haver pelo menos uma bolha.
- (ii) Calcule a probabilidade de, num conjunto de 6 placas de 1.5 · 3.0 m², haver pelo menos quatro sem bolhas.

- 6.9. Um entreposto com capacidade para armazenar 80 toneladas de cimento, é abastecido todos os dias por um comboio, que o enche durante a noite.

Ao entreposto dirigem-se diariamente camiões com capacidade para transportar 20 toneladas, de acordo com uma distribuição de Poisson com parâmetro $\lambda = 3/\text{dia}$.

Admita que, se houver cimento, cada camião será carregado até ao limite da sua capacidade.

- (i) Determine o valor esperado da quantidade de cimento que é transferida diariamente do comboio para o entreposto.
- (ii) Calcule o valor esperado da procura não satisfeita diariamente.

- 6.10. Um determinado casino, situado num país exótico, lançou um novo jogo de dados. No início do jogo o jogador escolhe uma face do dado, lançando-o posteriormente de uma forma sucessiva. Uma partida acaba ou quando o jogador consegue obter três vezes a face que escolheu (e ganha 30 moedas de ouro), ou ao fim de seis tentativas se, nesses lançamentos, não obtiver os três resultados com a face seleccionada (e perde 10 moedas de ouro). O Sr. Jo Gador foi de imediato experimentar este novo jogo.

- (i) Calcule a probabilidade de o Sr. Jo Gador ganhar uma partida.
- (ii) O Sr. Jo Gador segue uma regra: depois de ganhar uma partida pára de jogar. Quantas partidas deve ele jogar para que a probabilidade de ganhar uma partida seja de pelo menos 25%?
- (iii) Para além de ter decidido parar de jogar após a primeira partida que venha a ganhar, o Sr. Jo Gador decidiu ainda abandonar o jogo se ao fim de 5 partidas não tiver ganho nenhuma. Calcule o lucro esperado do Sr. Jo Gador se seguir estas regras.



Caracterização de Algumas Distribuições Contínuas Univariadas

7.1 INTRODUÇÃO

Neste capítulo serão analisados dois grupos de distribuições contínuas univariadas. O primeiro grupo é constituído pelas seguintes distribuições:

- Uniforme;
- Exponencial negativa;
- Normal;
- Lognormal.

Tal como no caso das distribuições discretas, o critério que presidiu à selecção destas distribuições privilegiou, por um lado, a frequência com que ocorrem fenómenos aleatórios susceptíveis de ser por elas modelados e, por outro, a sua simplicidade.

O segundo grupo — constituído por distribuições que são indispensáveis para a resolução de muitos problemas de inferência estatística, designadamente os que se referem à estimação por intervalo e ao teste de hipóteses — é formado pelas seguintes distribuições:

- Qui-quadrado;
- t de Student;
- F .

7.2 DISTRIBUIÇÃO UNIFORME

7.2.1 DEFINIÇÃO

Admita-se que a função densidade de probabilidade da variável aleatória contínua X é constante dentro do intervalo finito $[a, b]$ e nula fora desse intervalo. Em termos simbólicos:

$$f(x) = \begin{cases} k, & \text{se } a \leq x \leq b \\ 0, & \text{se } x < a \text{ ou } x > b. \end{cases}$$

Para que $f(x)$ seja efectivamente uma função densidade de probabilidade, deve ser satisfeita a condição

$$\int_{-\infty}^{+\infty} f(x) \cdot dx = \int_a^b k \cdot dx = k \cdot (b-a) = 1$$

donde

$$k = 1 / (b-a).$$

A função densidade de probabilidade da variável X — que segue uma **distribuição Uniforme** $U(a, b)$ — vem então dada por


$$f(x) = \begin{cases} 1/(b-a), & \text{se } a \leq x \leq b \\ 0, & \text{se } x < a \text{ ou se } x > b \end{cases} \quad [X \sim U(a, b)]. \quad (7.1)$$

A função de distribuição de X , $F(x)$, é dada por

$$F(x) = \int_{-\infty}^x f(u) \cdot du = \begin{cases} 0, & \text{se } x < a \\ (x-a)/(b-a), & \text{se } a \leq x \leq b \\ 1, & \text{se } x > b \end{cases} \quad [X \sim U(a, b)]. \quad (7.2)$$

Na Figura 7.1 representam-se a função densidade de probabilidade e a função de distribuição da variável $X \sim U(a, b)$.

Figura 7.1
Função densidade de probabilidade e função de distribuição da variável $X \sim U(a, b)$.



Exemplo 7.1

Admita-se que o atraso (expresso em minutos) dos comboios directos nas chegadas à estação de uma cidade provenientes de outra segue uma distribuição $U(0, 12)$. Pretende-se calcular a probabilidade de ocorrer um atraso compreendido entre os 5 e os 10 minutos. Tal probabilidade é dada por:

$$F(10) - F(5) = 10.0/12.0 - 5.0/12.0 = 0.412.$$

7.2.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

A partir da definição de valor esperado e de variância de uma variável aleatória contínua (ver expressões 4.18 e 4.22) é imediato verificar que, para a distribuição Uniforme, aqueles parâmetros são dados por

$$\begin{aligned} \mu &= \int_{-\infty}^{+\infty} x \cdot f(x) \cdot dx = (a+b)/2 \\ \sigma^2 &= \int_{-\infty}^{+\infty} (x-\mu)^2 \cdot f(x) \cdot dx = \frac{1}{12} \cdot (b-a)^2 \quad [X \sim U(a, b)]. \end{aligned} \quad (7.3)$$

Exemplo 7.2

Retomando o Exemplo 7.1, o valor esperado e a variância da variável $U(0, 12)$ (atraso na chegada a Campanhã) seriam

$$\begin{aligned} \mu &= (0 + 12)/2 = 6 \text{ minutos} \\ \sigma^2 &= (12 - 0)^2/12 = 12.0 \text{ minutos}^2. \end{aligned}$$

7.3 DISTRIBUIÇÃO EXPONENCIAL NEGATIVA

7.3.1 DEFINIÇÃO

Esta distribuição está intimamente relacionada com a distribuição de Poisson, que foi objecto de análise no capítulo anterior. Admitindo que λ é o parâmetro da distribuição de Poisson que descreve o número de ocorrências por unidade de tempo (ou de distância), a variável tempo (ou distância) entre ocorrências sucessivas segue uma distribuição **Exponencial Negativa** com parâmetro λ , habitualmente denotada por $EN(\lambda)$.

Tome-se, por exemplo, a variável X , distância entre defeitos sucessivos no isolamento de um cabo eléctrico. Por definição, esta variável não pode tomar valores negativos. Para $x \leq 0$, a sua função de distribuição, $F(x)$, é nula. Para $x > 0$, esta função vem

$$\begin{aligned} F(x) &= \text{probabilidade de se verificar pelo menos um defeito no intervalo } [0, x] \\ &= 1 - \{\text{probabilidade de não se verificar nenhum defeito no intervalo } [0, x]\}. \end{aligned}$$

Recorrendo à expressão 6.8 (e nela substituindo t por x e fazendo $y = 0$), a função de distribuição da variável X será, para $x > 0$,

$$F(x) = 1 - \frac{e^{-\lambda x} \cdot (\lambda x)^0}{0!} = 1 - e^{-\lambda x}. \quad (7.4)$$

Para valores de x superiores a zero, a função densidade de probabilidade da variável X pode ser obtida por derivação da expressão 7.4, vindo

$$f(x) = \lambda \cdot e^{-\lambda x}.$$


No ponto $x = 0$, $F(x)$ não é derivável. Consequentemente, neste ponto a função densidade de probabilidade não pode ser definida por derivação de $F(x)$. Na prática, o valor atribuído a $f(0)$ é irrelevante, sendo habitualmente fixado em λ . A expressão da função densidade de probabilidade vem então definida por

$$f(x) = \begin{cases} 0, & \text{se } x < 0 \\ \lambda \cdot e^{-\lambda x}, & \text{se } x \geq 0 \end{cases} \quad [X \sim EN(\lambda)]. \quad (7.5)$$

Exemplos 7.3

- A variável T definida no Exemplo 4.8 (e analisada posteriormente nos Exemplos 4.9 a 4.11) — tempo de funcionamento de um equipamento entre avarias sucessivas — segue uma distribuição $EN(0.5)$.
- Retomando o Exemplo 6.8, o tempo entre chegadas sucessivas de automóveis ao parque de estacionamento, entre as 12 e as 14 horas, segue uma distribuição $EN(3)$. As funções densidade de probabilidade e de distribuição desta variável encontram-se representadas na Figura 7.2.

Figura 7.2
Função densidade de probabilidade e função de distribuição da variável $X \sim EN(3)$.



É imediato verificar que a função definida pela expressão 7.5 satisfaz, por um lado, a condição de não-negatividade e, por outro, a condição

$$\int_{-\infty}^{+\infty} f(x) \cdot dx = 1$$

(note-se que esta condição foi verificada, no Exemplo 4.10, para o caso particular da variável $T \sim EN(0.5)$ definida no Exemplo 4.8; a generalização ao caso de uma qualquer variável $EN(\lambda)$ é trivial).

7.3.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

Pode demonstrar-se (ver Apêndice 7.1) que o valor esperado e a variância de uma variável Exponencial Negativa $X \sim EN(\lambda)$ têm as seguintes expressões:

$$\begin{aligned} \mu &= 1/\lambda \\ \sigma^2 &= (1/\lambda)^2 \quad [X \sim EN(\lambda)]. \end{aligned} \quad (7.6)$$

Note-se que, como λ corresponde ao número médio de ocorrências por unidade de tempo (ou de distância), $1/\lambda$ representa o tempo (ou a distância) que, em média, separa ocorrências sucessivas. Registe-se ainda que o valor esperado e o desvio padrão das distribuições Exponenciais Negativas são iguais.

Exemplo 7.4

Para a variável $T \sim EN(0.5)$ considerada no Exemplo 7.3, o valor esperado e a variância vêm

$$\begin{aligned} \mu &= 1/0.5 = 2 \text{ dias} \\ \sigma^2 &= (1/0.5)^2 = 4 \text{ dias}^2. \end{aligned}$$

Note-se que estes valores tinham já sido obtidos, a partir das definições destes parâmetros, nos Exemplos 4.14 e 4.18, respectivamente.

7.4. DISTRIBUIÇÃO NORMAL

7.4.1 DEFINIÇÃO

Em consequência da sua forma e das suas propriedades, a **distribuição Normal** (ou **distribuição de Gauss**, como alguns autores a designam para homenagear o matemático alemão Carl F. Gauss) é a que mais frequentemente se utiliza para descrever fenómenos que se traduzem através de variáveis aleatórias contínuas. Este facto será justificado mais adiante no Capítulo 8, a propósito do teorema do limite central (Secção 8.5). No entanto, pode desde já adiantar-se que, sempre que X é uma variável aleatória resultante da soma de um grande número de efeitos provocados por causas independentes, em que o efeito de cada causa é negligenciável em relação à soma de todos os outros efeitos, então X segue aproximadamente uma distribuição Normal. É frequente encontrarem-se situações nas quais estas condições se verificam.

A distribuição Normal é definida a partir de dois parâmetros: o seu valor esperado, μ (que toma qualquer valor real), e a sua variância, σ^2 (positiva, naturalmente). Simbolicamente, $X \sim N(\mu, \sigma^2)$ representa uma variável aleatória X que segue uma distribuição Normal com aqueles parâmetros.

A função densidade de probabilidade da distribuição Normal é definida, para todo o valor real x , pela expressão

$$f(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot e^{-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2} \quad [X \sim N(\mu, \sigma^2)]. \quad (7.7)$$

Pode demonstrar-se que


- $f(x)$ é uma função densidade de probabilidade (ver Apêndice 7.2) e que,
- para esta função densidade de probabilidade, μ e σ^2 correspondem efectivamente ao valor esperado e à variância da variável X (ver Apêndice 7.3).

A função de distribuição

$$F(x) = \int_{-\infty}^x f(u) \cdot du$$

não é integrável analiticamente, só podendo ser calculada pela via numérica. Na Figura 7.3 representam-se as funções densidade e de distribuição de uma variável $X \sim N(\mu, \sigma^2)$.

Figura 7.3
Função densidade
de probabilidade
e função de distribuição
de uma variável
 $X \sim N(\mu, \sigma^2)$.



A função $f(x)$ é simétrica em torno de $x = \mu$ (sendo nulos todos os seus momentos centrados de ordem ímpar, em particular o de terceira ordem), tem um máximo no ponto $x = \mu$ e pontos de inflexão em $x = \pm\sigma$. A título de exemplo, observe-se que a probabilidade de a variável X tomar valores situados nos intervalos $\mu \pm \sigma$, $\mu \pm 2 \cdot \sigma$ e $\mu \pm 3 \cdot \sigma$ é 0.6826, 0.9544 e 0.9973, respectivamente.

Tal como foi indicado no Capítulo 2 (Secção 2.3.2.2), a kurtose da distribuição Normal é tomada como padrão de referência. Expressa através do coeficiente

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3,$$

a kurtose de uma distribuição Normal toma o valor zero, quaisquer que sejam os seus parâmetros, uma vez que se verifica sempre a relação $\mu_4 = 3 \cdot \sigma^4$.

■ 7.4.2 TRANSFORMAÇÃO LINEAR DE UMA VARIÁVEL NORMAL. DISTRIBUIÇÃO NORMAL PADRONIZADA

Considere-se a variável $V = a + b \cdot X$ (com a e b reais), obtida por transformação linear da variável $X \sim N(\mu, \sigma^2)$. De acordo com as expressões 4.33 e 4.34, o valor esperado e a variância de V são dados por

$$\mu_V = a + b \cdot \mu$$

$$\sigma_V^2 = b^2 \cdot \sigma^2.$$

Pode demonstrar-se (ver Apêndice 7.4) que a variável transformada segue também uma distribuição Normal, isto é,

$$V \sim N(\mu_V, \sigma_V^2) \equiv N(a + b \cdot \mu, b^2 \cdot \sigma^2).$$

Tome-se agora a variável

$$Z = \frac{X - \mu}{\sigma}.$$

Dado que a transformação da variável Normal X é linear, a variável Z é também Normal. Os seus parâmetros são

$$\mu_Z = E\left(\frac{X - \mu}{\sigma}\right) = \frac{E(X) - \mu}{\sigma} = 0$$

$$\sigma_Z^2 = \text{Var}\left(\frac{X - \mu}{\sigma}\right) = \frac{1}{\sigma^2} \cdot \text{Var}(X) = 1.$$

A distribuição $N(0, 1)$ designa-se por **distribuição Normal padronizada** e a variável $Z \sim N(0, 1)$ por **variável Normal padronizada (ou reduzida)**.

Tal como se representa na Figura 7.4, a passagem de uma qualquer variável Normal $X \sim N(\mu, \sigma^2)$ para $Z \sim N(0, 1)$ pode ser entendida com uma dupla transformação, correspondendo à translação da origem de μ para 0 e à mudança de escala executada através do divisor σ .

Substituindo μ e σ por 0 e 1, respectivamente, na expressão 7.7, obtém-se a função densidade de probabilidade da variável $Z \sim N(0, 1)$:

$$f(z) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{z^2}{2}} \quad [Z \sim N(0, 1)]. \quad (7.8)$$

Na Tabela 3 do Anexo «Tabelas» apresentam-se, para a distribuição $N(0, 1)$, valores das probabilidades

$$\alpha = \int_{z(\alpha)}^{+\infty} f(u) \cdot du = 1 - F[z(\alpha)] = \int_{-\infty}^{-z(\alpha)} f(u) \cdot du = F[-z(\alpha)] \quad (\text{ver Figura 7.5})$$

para $z(\alpha) = 0.00, 0.01, 0.02, \dots, 3.07, 3.08, 3.09$.

Figura 7.4
Transformação
da variável Normal
 $X \sim N(\mu, \sigma^2)$
na variável
Normal reduzida
 $Z \sim N(0, 1)$.





Figura 7.5
Definição da probabilidade

$$\alpha = \int_{-\infty}^{+\infty} f(u) \cdot du = \int_{-\infty}^{+\infty} f(u) \cdot du$$



O interesse da tabela resulta de que, a partir dela, é possível calcular a probabilidade de o valor de uma qualquer variável Normal se situar num intervalo qualquer (finito ou infinito).

Exemplo 7.5

A variação relativa diária da cotação de fecho de um determinado fundo transaccionado numa bolsa de valores pode ser razoavelmente aproximada por uma distribuição Normal com valor esperado 0.2% e desvio padrão 1.6%. Denote-se aquela variação por $X \sim N(0.2, 1.6^2)$.

Pretende-se calcular:

- (a) A probabilidade de a próxima variação do preço de fecho ultrapassar 1%:

$$\begin{aligned} P(X > 1) &= P\left(\frac{X - 0.2}{1.6} > \frac{1 - 0.2}{1.6} = 0.5\right) \\ &= P(Z > 0.5) \quad [\text{onde } Z \sim N(0, 1)] \\ &= 0.3085 \quad (\text{ver Tabela 3, do Anexo «Tabelas»}). \end{aligned}$$

- (b) A probabilidade de a próxima variação do preço de fecho se situar entre 1% e 1.16%:

$$\begin{aligned} P(1 < X < 1.16) &= P\left(\frac{1 - 0.2}{1.6} < \frac{X - 0.2}{1.6} < \frac{1.16 - 0.2}{1.6}\right) \\ &= P(0.5 < Z < 0.6) \quad [\text{onde } Z \sim N(0, 1)] \\ &= 1 - [P(Z < 0.5) + P(Z > 0.6)] \\ &= [1 - P(Z < 0.5)] - P(Z > 0.6) \\ &= P(Z > 0.5) - P(Z > 0.6) \\ &= 0.3085 - 0.2743 = 0.0342 \quad (\text{ver Tabela 3, do Anexo «Tabelas»}). \end{aligned}$$

7.4.3 COMBINAÇÃO LINEAR DE VARIÁVEIS NORMAIS INDEPENDENTES

A distribuição Normal tem uma propriedade de enorme importância prática: qualquer combinação linear de variáveis Normais independentes segue ainda uma distribuição Normal.

Exemplo 7.6

Uma empresa desenvolve um conjunto restrito de actividades A_n ($n = 1, \dots, N$). Admite-se que os lucros L_n associados às diferentes actividades A_n são variáveis independentes que seguem distribuições $N(\mu_n, \sigma_n^2)$.

Então, o lucro global da empresa,

$$L = \sum_{n=1}^N L_n,$$

segue uma distribuição Normal cujos parâmetros são dados por

$$\mu = \sum_{n=1}^N \mu_n \quad \sigma^2 = \sum_{n=1}^N \sigma_n^2.$$

7.4.4 RELAÇÃO ENTRE A DISTRIBUIÇÃO NORMAL E A DISTRIBUIÇÃO BINOMIAL

De acordo com o que foi afirmado na Secção 6.5.3, a propósito da aproximação da distribuição Binomial pela de Poisson, nas situações em que N é grande e p não está nem próximo de 1 nem de 0 por forma a que a distribuição Binomial seja aproximadamente simétrica (na prática, $N \geq 20$, $N \cdot p > 7$ e $N \cdot q > 7$), a distribuição Normal com parâmetros

$$\mu = N \cdot p \quad \sigma^2 = N \cdot p \cdot (1 - p)$$

constitui uma boa aproximação da distribuição Binomial (note-se que, se N for grande e se tanto $N \cdot p$ como $N \cdot q$ forem no mínimo 5, a aproximação já será aceitável).

A justificação para a proximidade das distribuições Binomial e Normal será apresentada na Secção 8.5 como uma consequência do teorema do limite central.

A distribuição Normal poderá ser ainda utilizada para aproximar as distribuições Hipergeométrica e de Poisson sempre que estas, por sua vez, sejam aproximáveis por distribuições Binomiais (aproximadamente simétricas).

Exemplo 7.7

Para uma determinada espécie de flores, a proporção de sementes que germinam é de apenas 40%. Plantaram-se 20 sementes dessa espécie. Pretende-se estudar a probabilidade de germinação das sementes plantadas recorrendo à distribuição Normal.

É razoável admitir que o número de sementes que germinam (de entre as 20 que foram plantadas) segue uma distribuição Binomial $B(20, 0.4)$. Nestas condições e dado que $N \geq 20$; $N \cdot p = 8 > 7$ e $N \cdot q = 12 > 7$, poder-se-á aproximar aquela distribuição pela Normal $N(8, 2.19^2)$.

A variável X , denotando o número de sementes que germinam, toma apenas valores inteiros. Para se calcular $P(X = x)$ através da distribuição Normal (que é contínua) recorre-se ao seguinte procedimento:

$$P_{\text{Binomial}}(X = x) \approx P_{\text{Normal}}(x - 0.5 < X < x + 0.5)$$

ou seja,

$$P_{\text{Binomial}}(X = x) \approx P_{\text{Normal}}(X < x + 0.5) - P_{\text{Normal}}(X < x - 0.5).$$


Assim, por exemplo, $P(X = 6)$ virá:

$$\begin{aligned} P_{\text{Binomial}}(X = 6) &\approx P_{\text{Normal}}(X < 6.5) - P_{\text{Normal}}(X < 5.5) \\ &\approx P_{\text{Normal}}(Z < -0.685) - P_{\text{Normal}}(Z < -1.141) \\ &\approx P_{\text{Normal}}(Z > 0.685) - P_{\text{Normal}}(Z > 1.141) \\ &\approx 0.2467 - 0.1269 \\ &\approx 0.1198 \end{aligned}$$

Este valor não se afasta muito daquele que se obtém directamente através da distribuição $B(20, 0.4)$ e que é de 0.1244.

Na Figura 7.6 compara-se globalmente a distribuição $B(20, 0.4)$ com a distribuição $N(8, 2.19^2)$.

Figura 7.6
Aproximação
da distribuição
 $B(20, 0.4)$ pela
distribuição
 $N(8, 2.19^2)$.



7.5 DISTRIBUIÇÃO LOGNORMAL

7.5.1 DEFINIÇÃO

Admita-se que $X > 0$ é uma variável aleatória contínua. Admita-se ainda que $V = \ln X$ segue uma distribuição $N(\mu_V, \sigma_V^2)$. Nestas condições, a variável X segue uma distribuição **Lognormal**, com parâmetros μ_V e σ_V^2 . Normalmente, caracteriza-se esta distribuição recorrendo aos parâmetros da variável transformada V . Assim, denota-se por $X \sim LN(\mu_V, \sigma_V^2)$ uma variável Lognormal X , em que os parâmetros μ_V e σ_V^2 representam o valor esperado e a variância da variável transformada $V = \ln X$.

A função densidade de probabilidade da variável X é dada por

$$f(x) = \frac{1}{x \cdot \sqrt{2\pi} \cdot \sigma_V} \cdot e^{-\frac{1}{2\sigma_V^2} (\ln x - \mu_V)^2} \quad [X \sim LN(\mu_V, \sigma_V^2)]. \quad (7.9)$$

Na Figura 7.7 representam-se a função densidade de probabilidade e a função de distribuição da variável $LN(6, 3^2)$.


Recorde-se que, na secção anterior, se admitiu que uma variável aleatória seguiria uma distribuição Normal se fosse a resultante da soma de um grande número de efeitos provocados por causas independentes. De um modo semelhante, a variável X seguirá uma distribuição Lognormal se for a resultante de um número elevado de efeitos positivos, também provocados por causas independentes, que em vez de se adicionarem se multiplicam (admitindo que cada uma das causas tem um efeito de variabilidade negligenciável quando comparada com a variabilidade do efeito global das restantes). Não é raro verificarem-se fenómenos aleatórios obedecendo a condições próximas das que acabam de ser enunciadas.

7.5.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

No Apêndice 7.5 mostra-se que o valor esperado e a variância de X , expressos em função dos parâmetros de $V = \ln X$, ou seja, em função de μ_V e de σ_V^2 , são

$$\begin{aligned} \mu_X &= e^{\mu_V + \sigma_V^2/2} \\ \sigma_X^2 &= e^{2(\mu_V + \sigma_V^2)} - e^{2\mu_V + \sigma_V^2}. \end{aligned} \quad (7.10)$$

Figura 7.7
Função densidade
de probabilidade e
função de distri-
buição da variável
 $X \sim LN(6, 3^2)$.



Através das expressões 7.10 podem obter-se os parâmetros de $V = \ln X$ a partir de μ_X e de σ_X^2 , vindo

$$\begin{aligned} \mu_V &= \frac{1}{2} \cdot \ln \left(\frac{\mu_X^4}{\sigma_X^2 + \mu_X^2} \right) \\ \sigma_V^2 &= \ln \left(\frac{\sigma_X^2}{\mu_X^2} + 1 \right). \end{aligned} \quad (7.11)$$

Ao contrário da distribuição Normal, a distribuição Lognormal é assimétrica à direita. A mediana e a moda de X expressas em função de μ_V e de σ_V^2 são dadas respectivamente por

$$\begin{aligned} \eta_X &= e^{\mu_V} \\ \zeta_X &= e^{(\mu_V - \sigma_V^2)}. \end{aligned} \quad (7.12)$$

Exemplo 7.8

Para um determinado modelo de automóvel, o custo de manutenção (em euros) no primeiro ano de vida segue uma distribuição lognormal com valor esperado 80 e variância 50^2 , admitindo uma taxa de utilização de 15 000 km/ano. Pretende-se determinar a probabilidade de um veículo novo incorrer num custo de manutenção superior a 125 euros no primeiro ano, admitindo-se que percorrerá 15 000 km. Pretende-se ainda calcular a mediana e a moda do custo de manutenção no primeiro ano.

Uma forma prática de tratar a questão consiste em recorrer à transformação logarítmica da variável «custo de manutenção». De acordo com a definição de distribuição Lognormal, tal variável transformada (V) seguirá uma distribuição Normal com parâmetros

$$\mu_V = \frac{1}{2} \cdot \ln \left(\frac{80^4}{50^2 + 80^2} \right) = 4.217 \quad \text{e} \quad \sigma_V^2 = \ln \left(\frac{50^2}{80^2} + 1 \right) = 0.574^2.$$

A padronização da variável Y no ponto $y = \ln 125 = 4.828$ conduz a $z = (4.828 - 4.217) / 0.574 = 1.064$. Consultando a tabela da distribuição Normal padronizada (Tabela 3 do Anexo «Tabelas»), verifica-se que $P(Z > 1.064) = 0.1436$, pelo que se conclui que a probabilidade de o custo de manutenção ultrapassar 125 euros será de aproximadamente 14%.

De acordo com as expressões 7.12, o cálculo da mediana e da moda da distribuição do custo de manutenção conduz a 67.83 e a 48.79 euros, respectivamente.

7.6 DISTRIBUIÇÃO DO QUI-QUADRADO

7.6.1 DEFINIÇÃO

Considere-se um conjunto de GL variáveis aleatórias Z_i ($i = 1, 2, 3, \dots, GL$) obedecendo às seguintes condições:

- Cada variável Z_i segue uma distribuição Normal padronizada;
- As variáveis Z_i são mutuamente independentes (os valores que cada uma toma não são condicionados pelos valores das restantes).

Simbolicamente, estas condições podem resumir-se do seguinte modo:

$$Z_i \sim N(0, 1) \quad (i = 1, 2, 3, \dots, GL).$$

A variável aleatória X , construída a partir da soma de GL variáveis Z_i elevadas ao quadrado, segue uma distribuição Qui-quadrado com GL graus de liberdade, denotada simbolicamente por χ^2_{GL} :

$$X = \sum_{i=1}^{GL} Z_i^2 = Z_1^2 + Z_2^2 + \dots + Z_{GL}^2 \quad (X \sim \chi^2_{GL}). \quad (7.13)$$

Note-se que o termo «graus de liberdade» corresponde ao número de parcelas incluídas na expressão 7.13.

Pode demonstrar-se que a função densidade de probabilidade de $X \sim \chi^2_{GL}$ é dada por

$$f(x) = \frac{1}{2^{GL/2} \cdot \Gamma(GL/2)} \cdot e^{-x/2} \cdot x^{(GL/2)-1} \quad (x > 0) \quad (7.14)$$

onde Γ (argumento) = $\Gamma(u)$ se designa por **função gama** e representa o integral

$$\Gamma(u) = \int_0^{\infty} x^{u-1} \cdot e^{-x} \cdot dx \quad (\text{com } u > 0).$$

Os valores de $\Gamma(GL/2)$ em 7.14 podem ser obtidos calculando este integral, donde resulta

- $\Gamma(1/2) = \sqrt{\pi}$
- $\Gamma(GL/2) = \frac{1 \cdot 3 \cdot 5 \cdot \dots \cdot (GL-2)}{2^{(GL-1)/2}} \cdot \sqrt{\pi} \quad (\text{para } GL > 1 \text{ e ímpar})$
- $\Gamma(GL/2) = \left(\frac{GL}{2} - 1\right)! \quad (\text{para } GL \text{ par}).$

Na Figura 7.8 representam-se as funções densidade de probabilidade das variáveis Qui-quadrado com 2, 4, 6 e 10 graus de liberdade. Note-se que, tal como será justificado mais adiante no Capítulo 8, à medida que GL cresce, a distribuição da variável χ^2_{GL} tende para uma distribuição Normal.

Na Tabela 4 do Anexo «Tabelas» definem-se valores $\chi^2_{GL}(\alpha)$ (ver Figura 7.9), que, para as variáveis

$$X \sim \chi^2_{GL} \quad (\text{com } GL = 1, 2, \dots, 29, 30, 40, 50, \dots, 100),$$

correspondem a áreas

$$\alpha = \int_{\chi^2_{GL}(\alpha)}^{\infty} f(u) \cdot du$$

iguais a

0.995, 0.99, 0.975, 0.95, 0.90, 0.75, 0.50, 0.25, 0.10, 0.05, 0.025, 0.01 e 0.005.

Figura 7.8
Funções densidade de probabilidade das variáveis Qui-quadrado com 2, 4, 6 e 10 graus de liberdade.





Figura 7.9
Definição de $\chi^2_{GL}(\alpha)$.



7.6.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

É possível demonstrar que o valor esperado e a variância da distribuição de uma variável $X \sim \chi^2_{GL}$ são, respectivamente,

$$\begin{aligned} \mu &= GL \\ \sigma^2 &= 2 \cdot GL \end{aligned} \quad (X \sim \chi^2_{GL}) \quad (7.15)$$

Exemplo 7.9

Admitindo que $X \sim \chi^2_{26}$, pretende determinar-se o primeiro quartil desta distribuição, $\chi^2_{26}(\alpha = 0.75)$, a mediana, $\eta = \chi^2_{26}(\alpha = 0.50)$ e o valor de $\chi^2_{26}(\alpha = 0.05)$. Por consulta da Tabela 4 no Anexo «Tabelas», é imediato verificar que

$$\begin{aligned}\chi^2_{26}(\alpha = 0.75) &= 20.84, \\ \eta = \chi^2_{26}(\alpha = 0.50) &= 25.34, \text{ e} \\ \chi^2_{26}(\alpha = 0.05) &= 38.89.\end{aligned}$$

Repare-se que, para 26 graus de liberdade, a assimetria da distribuição do Qui-quadrado já é pouco pronunciada, sendo a mediana ($\eta = 25.34$) pouco inferior ao valor esperado ($\mu = GL = 26$).

7.7 DISTRIBUIÇÃO DE STUDENT

7.7.1 DEFINIÇÃO

Admita-se que as variáveis

$$Z \sim N(0, 1) \quad \text{e} \quad V \sim \chi^2_{GL}$$

são independentes.

A distribuição da variável aleatória X obtida calculando o quociente $Z/\sqrt{V/GL}$ designa-se por distribuição t de Student com GL graus de liberdade (Student foi o pseudónimo utilizado pelo estatístico inglês W. S. Gosset, que a desenvolveu). A função densidade de probabilidade da variável

$$X = \frac{Z}{\sqrt{V/GL}} \quad (X \sim t_{GL}). \quad (7.16)$$

é definida, para $-\infty < x < \infty$, pela expressão

$$f(x) = \frac{\Gamma[(GL+1)/2]}{\sqrt{GL} \cdot \pi \cdot \Gamma(GL/2)} \cdot \left(1 + \frac{x^2}{GL}\right)^{-(GL+1)/2} \quad (X \sim t_{GL}), \quad (7.17)$$

onde Γ (argumento) representa a função gama anteriormente definida.

Em vez de definir a distribuição t_{GL} como sendo aquela que corresponde à da variável $Z/\sqrt{V/GL}$, esta distribuição pode ser definida directamente a partir da expressão 7.17. Procedendo desta forma, é possível generalizar a definição da distribuição a casos em que GL toma qualquer valor real não-inferior à unidade.

Tal como se pode observar na Figura 7.10, onde se comparam as distribuições $N(0, 1)$, t_{15} e t_3 , a distribuição t de Student é simétrica e unimodal, possuindo uma configuração geral semelhante à da Normal (na realidade tem kurtose superior). É também possível observar que, à medida que o número de graus de liberdade GL cresce, a distribuição t_{GL} se aproxima da distribuição Normal padronizada.

Na Tabela 5 do Anexo «Tabelas» definem-se valores $t_{GL}(\alpha)$ (ver Figura 7.11) que, para as variáveis

$$t_{GL} \quad (\text{com } GL = 1, 2, \dots, 29, 30, 40, 50, \dots, 100, 120 \text{ e } \infty),$$

Figura 7.10
Comparação entre as distribuições t_3 , t_{15} e $N(0, 1)$.





Figura 7.11
Definição de $t_{GL}(\alpha)$ e $-t_{GL}(\alpha)$.



correspondem a áreas

$$\alpha = \int_{t_{GL}(\alpha)}^{\infty} f(u) \cdot du,$$

iguais a

$$0.25, 0.25, 0.10, 0.05, 0.025, 0.01, 0.05 \text{ e } 0.005.$$

Dado que a distribuição t de Student é simétrica em torno de zero, a área situada à esquerda de $-t_{GL}(\alpha)$ é igual à área situada à direita de $t_{GL}(\alpha)$.

Exemplo 7.10

Por consulta da Tabela 5 no Anexo «Tabelas», verifica-se que, para a variável $X \sim t_3$,

$$t_3(0.050) = 2.353 \Rightarrow P[-2.353 < X < 2.353] = 0.90;$$

$$t_3(0.025) = 3.182 \Rightarrow P[-3.182 < X < 3.182] = 0.95.$$

Para a variável $X \sim t_{15}$,

$$t_{15}(0.050) = 1.753 \Rightarrow P[-1.753 < X < 1.753] = 0.90;$$

$$t_{15}(0.025) = 2.131 \Rightarrow P[-2.131 < X < 2.131] = 0.95.$$

Note-se que, à medida que GL aumenta, os valores de $t_{GL}(0.050)$ e de $t_{GL}(0.025)$ se aproximam, respectivamente, dos valores correspondentes à distribuição $N(0, 1)$:

$$z(0.050) = t_{\infty}(0.050) = 1.645$$

$$z(0.025) = t_{\infty}(0.025) = 1.960.$$

7.7.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

É possível demonstrar que o valor esperado e a variância da distribuição da variável $X \sim t_{GL}$ são, respectivamente,

$$\begin{aligned}\mu &= 0 & (\text{para } GL > 1) \\ \sigma^2 &= GL / (GL - 2) & (\text{para } GL > 2).\end{aligned}\quad (7.18)$$

Note-se que, fora das condições indicadas, o valor esperado e a variância não podem ser definidos (por não tomarem valores finitos).

7.8 DISTRIBUIÇÃO F

7.8.1 DEFINIÇÃO

Considerem-se duas variáveis independentes $\chi^2_{GL_1}$ e $\chi^2_{GL_2}$. A distribuição da variável aleatória obtida calculando o quociente

$$\frac{\chi^2_{GL_1} / GL_1}{\chi^2_{GL_2} / GL_2}$$

designa-se por distribuição F com GL_1 e GL_2 graus de liberdade (a designação F foi proposta por G. Snedecor, que a desenvolveu, em homenagem ao estatístico R. Fisher). A função densidade de probabilidade da variável

$$X = \frac{\chi^2_{GL_1} / GL_1}{\chi^2_{GL_2} / GL_2} \quad (X \sim F_{GL_1, GL_2}) \quad (7.19)$$

é dada por

$$f(x) = \frac{\Gamma\{0.5 \cdot (GL_1 + GL_2)\}}{\Gamma(0.5 \cdot GL_1) \cdot \Gamma(0.5 \cdot GL_2)} \cdot \frac{(GL_1 / GL_2)^{0.5 \cdot GL_1} \cdot x^{0.5 \cdot GL_1 - 1}}{(GL_2 + GL_1 \cdot x)^{0.5 \cdot (GL_1 + GL_2)}} \quad (x > 0), \quad (7.20)$$

onde Γ (argumento) representa a função gama anteriormente definida.

Na Figura 7.12 representa-se, a título de exemplo, a função densidade de probabilidade da variável $F_{8,4}$.

Na Tabela 6 do Anexo «Tabelas» definem-se valores $F_{GL_1, GL_2}(\alpha)$ (ver Figura 7.13) que, para variáveis $X \sim F_{GL_1, GL_2}$, correspondem a áreas

$$\alpha = \int_{F_{GL_1, GL_2}(\alpha)}^{\infty} f(u) \cdot du,$$

iguais a

$$0.01, 0.25, 0.05 \text{ e } 0.10.$$

Para se obterem os valores $F_{GL_1, GL_2}(1 - \alpha)$ correspondentes a áreas de dimensão α situadas na cauda esquerda da distribuição de $X \sim F_{GL_1, GL_2}$ (ver Figura 7.13), recorre-se à seguinte relação cuja validade se encontra demonstrada no Apêndice 7.6:

$$F_{GL_1, GL_2}(1 - \alpha) = \frac{1}{F_{GL_2, GL_1}(\alpha)}. \quad (7.21)$$

Note-se que, no denominador do segundo membro, a ordenação dos graus de liberdade — GL_2, GL_1 — é inversa da que figura no primeiro membro.

Figura 7.12
Função densidade de probabilidade da distribuição $F_{8,4}$.





Figura 7.13
Definição de $F_{GL_1, GL_2}(1 - \alpha)$ e $F_{GL_1, GL_2}(\alpha)$.



7.8.2 EXPRESSÕES DO VALOR ESPERADO E DA VARIÂNCIA

Embora sem o demonstrar, indica-se a seguir o valor esperado e a variância da distribuição da variável $X \sim F_{GL_1, GL_2}$:

$$\begin{aligned}\mu &= \frac{GL_2}{GL_2 - 2} & (\text{para } GL_2 > 2) \\ \sigma^2 &= \frac{2 \cdot GL_2 \cdot (GL_1 + GL_2 - 2)}{GL_1 \cdot (GL_2 - 2)^2 \cdot (GL_2 - 4)} & (\text{para } GL_2 > 4).\end{aligned}\quad (7.22)$$

Exemplo 7.11

Pretende-se conhecer o valor esperado e a variância da variável $X \sim F_{8,4}$, bem como os valores de $F_{8,4}(0.05)$ e $F_{8,4}(0.95)$.


De acordo com as expressões 7.22, o valor esperado de X é 2.0 e, dado que $GL_2 = 4$, a variância da distribuição $F_{8,4}$ não é definida (isto é, não toma um valor finito).

Por consulta da Tabela 6 no Anexo «Tabelas», obtém-se directamente

$$F_{8,4}(0.05) = 6.04.$$

O valor de $F_{8,4}(0.95)$ obtém-se recorrendo à expressão 7.21:

$$F_{8,4}(0.95) = 1 / F_{4,8}(0.05) = 1 / 3.84 = 0.26.$$



Apêndices

■ APÊNDICE 7.1 VALOR ESPERADO E VARIÂNCIA DE UMA VARIÁVEL EXPONENCIAL NEGATIVA $X \sim EN(\lambda)$

- (1) A função geradora de momentos da variável aleatória $X \sim EN(\lambda)$ é

$$G(t) = E[e^{t \cdot x}] = \int_0^{+\infty} e^{t \cdot x} \cdot \lambda \cdot e^{-\lambda \cdot x} \cdot dx = \int_0^{+\infty} \lambda \cdot e^{(t-\lambda) \cdot x} \cdot dx = \left[\frac{\lambda}{t-\lambda} \cdot e^{(t-\lambda) \cdot x} \right]_0^{+\infty}$$

donde, para $t < \lambda$,

$$G(t) = -\frac{\lambda}{t-\lambda}.$$

- (2) Derivando $G(t)$ em ordem a t , vem

$$G'(t) = \frac{\lambda}{(t-\lambda)^2} \quad G''(t) = -\frac{2 \cdot \lambda}{(t-\lambda)^3}.$$

- (3) Assim,

$$E(X) = G'(0) = 1/\lambda$$

ou seja,

$$\mu = 1/\lambda \quad (\text{primeira das expressões 7.6}).$$

- (4) Por outro lado,

$$\sigma^2 = E(X^2) - [E(X)]^2 \quad \text{e} \quad E(X^2) = G''(0) = 2/\lambda^2,$$

pelo que

$$\sigma^2 = 2/\lambda^2 - 1/\lambda^2$$

e, portanto,

$$\sigma^2 = \left(\frac{1}{\lambda}\right)^2 \quad (\text{segunda das expressões 7.6}).$$

■ APÊNDICE 7.2 VERIFICAÇÃO DE QUE UMA FUNÇÃO DEFINIDA PELA EXPRESSÃO 7.7 É UMA FUNÇÃO DENSIDADE DE PROBABILIDADE

- (1) De acordo com a expressão 7.7,

$$f(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma^2} \cdot e^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2}$$

e, portanto,

$$\int_{-\infty}^{+\infty} f(x) \cdot dx = \frac{1}{\sqrt{2\pi} \cdot \sigma^2} \cdot \int_{-\infty}^{+\infty} e^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2} \cdot dx. \quad (\text{A7.2.1})$$

- (2) Fazendo $x = \mu + \sigma \cdot u$ na expressão A7.2.1, resulta:

$$\begin{aligned} \int_{-\infty}^{+\infty} f(x) \cdot dx &= \int_{-\infty}^{+\infty} f(\mu + \sigma \cdot u) \cdot \frac{dx}{du} \cdot du \\ &= \frac{1}{\sqrt{2\pi} \cdot \sigma^2} \cdot \int_{-\infty}^{+\infty} e^{-\frac{1}{2} \cdot u^2} \cdot \sigma \cdot du \\ &= \frac{1}{\sqrt{2\pi}} \cdot \underbrace{\int_{-\infty}^{+\infty} e^{-\frac{1}{2} \cdot u^2} \cdot du}_{=A}. \end{aligned} \quad (\text{A7.2.2})$$

- (3) Em vez de tentar calcular directamente A , começa-se por determinar o valor de A^2 (note-se que, a partir de A7.2.2, é imediato concluir que A é sempre positivo e, portanto, $A = +\sqrt{A^2}$). Assim,

$$\begin{aligned} A^2 &= \int_{-\infty}^{+\infty} e^{-\frac{1}{2} \cdot u^2} \cdot du \cdot \int_{-\infty}^{+\infty} e^{-\frac{1}{2} \cdot v^2} \cdot dv \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-\frac{1}{2} \cdot (u^2 + v^2)} \cdot du \cdot dv. \end{aligned} \quad (\text{A7.2.3})$$

- (4) Mudando a expressão A7.2.3 para coordenadas polares, fazendo

$$u = r \cdot \sin \theta \quad \text{e} \quad v = r \cdot \cos \theta,$$

resulta

$$A^2 = \int_0^{2\pi} \int_0^{+\infty} e^{-\frac{1}{2} \cdot r^2} \cdot r \cdot dr \cdot d\theta = \int_0^{2\pi} d\theta = 2\pi$$

e, consequentemente,

$$A = +\sqrt{A^2} = \sqrt{2\pi}.$$

- (5) Substituindo A por $\sqrt{2\pi}$ em A7.2.2, resulta

$$\int_{-\infty}^{+\infty} f(x) \cdot dx = \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1. \quad (\text{A7.2.4})$$

Em consequência deste resultado e tendo em conta que $f(x)$ é uma função que só toma valores positivos, fica demonstrado que $f(x)$ é uma função densidade de probabilidade.

■ APÊNDICE 7.3 VALOR ESPERADO E VARIÂNCIA DE UMA VARIÁVEL NORMAL $X \sim N(\mu, \sigma^2)$

- (1) A função geradora de momentos da variável aleatória $X \sim N(\mu, \sigma^2)$ é

$$G(t) = E[e^{t \cdot X}] = \frac{1}{\sqrt{2\pi \cdot \sigma^2}} \cdot \int_{-\infty}^{+\infty} e^{t \cdot x} \cdot e^{-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2} \cdot dx.$$

- (2) Fazendo $z = (x - \mu) / \sigma$, obtém-se

$$\begin{aligned} G(t) &= \frac{1}{\sqrt{2\pi}} \cdot e^{\mu \cdot t} \cdot \int_{-\infty}^{+\infty} e^{t \cdot z \cdot \sigma} \cdot e^{-\frac{1}{2} z^2} \cdot dz \\ &= \frac{e^{\mu \cdot t}}{\sqrt{2\pi}} \cdot \int_{-\infty}^{+\infty} e^{-\frac{1}{2} (z^2 - 2 \cdot t \cdot \sigma \cdot z)} \cdot dz \\ &= \frac{e^{\mu \cdot t}}{\sqrt{2\pi}} \cdot \int_{-\infty}^{+\infty} e^{-\frac{1}{2} (z - t \cdot \sigma)^2} \cdot dz \\ &= e^{\mu \cdot t + \frac{1}{2} (t \cdot \sigma)^2} \cdot \underbrace{\frac{1}{\sqrt{2\pi}} \cdot \int_{-\infty}^{+\infty} e^{-\frac{1}{2} (z - t \cdot \sigma)^2} \cdot dz}_A \end{aligned} \quad (\text{A7.3.1})$$

- (3) Notando que

$$\frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2} (z - t \cdot \sigma)^2}$$

representa a função densidade de probabilidade de uma variável $N(\sigma \cdot t, 1^2)$, então

$$A = \frac{1}{\sqrt{2\pi}} \cdot \int_{-\infty}^{+\infty} e^{-\frac{1}{2} (z - t \cdot \sigma)^2} = 1,$$

pelo que, finalmente, a expressão A7.3.1 se transforma em

$$G(t) = e^{\mu \cdot t + \frac{1}{2} (t \cdot \sigma)^2}. \quad (\text{A7.3.2})$$

- (4) Derivando esta expressão em ordem a t , obtém-se

$$\begin{aligned} G'(t) &= (\mu + t \cdot \sigma^2) \cdot e^{\mu \cdot t + \frac{1}{2} (t \cdot \sigma)^2} \\ G''(t) &= \sigma^2 \cdot e^{\mu \cdot t + \frac{1}{2} (t \cdot \sigma)^2} + e^{\mu \cdot t + \frac{1}{2} (t \cdot \sigma)^2} \cdot (\mu + t \cdot \sigma^2)^2. \end{aligned}$$

- (5) Ora,

$$E(X) = G'(0) = \mu,$$

ou seja, o parâmetro μ da distribuição Normal corresponde ao seu valor esperado.

- (6) Por outro lado,

$$E(X^2) = G''(0) = \sigma^2 + \mu^2,$$

pelo que

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = \sigma^2 + \mu^2 - \mu^2 = \sigma^2,$$

ou seja, o parâmetro σ^2 da distribuição Normal corresponde à sua variância.

■ APÊNDICE 7.4 DISTRIBUIÇÃO DE UMA VARIÁVEL OBTIDA POR TRANSFORMAÇÃO LINEAR DE UMA VARIÁVEL NORMAL $X \sim N(\mu, \sigma^2)$

- (1) Tal como se admitiu na Secção 7.4.2, considere-se a variável $V = a + b \cdot X$ (com a e b reais), obtida por transformação linear da variável $X \sim N(\mu, \sigma^2)$. A função geradora de momentos de V é:

$$\begin{aligned} G(t) &= E[e^{t \cdot V}] \\ &= E[e^{t \cdot (a + b \cdot X)}] \\ &= e^{t \cdot a} \cdot E[e^{(t \cdot b) \cdot X}]. \end{aligned} \quad (\text{A7.4.1})$$

- (2) O desenvolvimento do termo $E[e^{(t \cdot b) \cdot X}]$ pode ser efectuado de acordo com o procedimento adoptado nos passos (1) a (3) do Apêndice A7.3, conduzindo a

$$E[e^{(t \cdot b) \cdot X}] = e^{\mu \cdot (t \cdot b) + \frac{1}{2} (t \cdot b \cdot \sigma)^2} \quad (\text{A7.4.2})$$

(note-se que o segundo membro desta expressão resulta de substituir t por $(t \cdot b)$ no segundo membro da expressão A7.3.2).

- (3) Substituindo A7.4.2 na expressão A7.4.1, obtém-se

$$\begin{aligned} G(t) &= e^{t \cdot a} \cdot e^{\mu \cdot t \cdot b + \frac{1}{2} (t \cdot b \cdot \sigma)^2} \\ &= e^{t \cdot (a + \mu \cdot b) + \frac{1}{2} (b \cdot \sigma \cdot t)^2} \\ &= e^{(a + \mu \cdot b) \cdot t + \frac{1}{2} (b \cdot \sigma \cdot t)^2}. \end{aligned} \quad (\text{A7.4.3})$$

A expressão A7.4.3 corresponde justamente à função geradora de momentos da distribuição Normal com valor esperado $a + b \cdot \mu$ e variância $b^2 \cdot \sigma^2$ (compare-se A7.4.3 com A7.3.2). Dado que a função geradora de momentos da variável V determina univocamente a sua distribuição, resulta que qualquer variável obtida por transformação linear de uma variável Normal segue também uma distribuição Normal.

■ APÊNDICE 7.5 VALOR ESPERADO E VARIÂNCIA DE UMA VARIÁVEL LOGNORMAL $X \sim LN(\mu, \sigma^2)$

- (1) Calculando directamente os momentos ordinários de ordem r da variável $X \sim LN(\mu, \sigma^2)$, vem:

$$E[X^r] = \int_{-\infty}^{+\infty} x^r \cdot f(x) \cdot dx = \int_{-\infty}^{+\infty} x^r \cdot \frac{1}{x\sqrt{2\pi} \cdot \sigma_V} \cdot e^{-\frac{1}{2\sigma_V^2}(\ln x - \mu_V)^2} \cdot dx. \quad (A7.5.1)$$

- (2) Fazendo

$$u = \frac{\ln x - \mu_V}{\sigma_V},$$

vem

$$x = e^{\mu_V + \sigma_V \cdot u}$$

e, portanto,

$$dx = \sigma_V \cdot e^{\mu_V + \sigma_V \cdot u} \cdot du.$$

- (3) Substituindo em A7.5.1 resulta

$$\begin{aligned} E[X^r] &= \int_{-\infty}^{+\infty} e^{r(\ln x - \mu_V + \sigma_V \cdot u)} \cdot \frac{1}{\sqrt{2\pi} \cdot \sigma_V} \cdot e^{-\frac{u^2}{2}} \cdot \sigma_V \cdot e^{\mu_V + \sigma_V \cdot u} \cdot du \\ &= \int_{-\infty}^{+\infty} e^{r(\mu_V + \sigma_V \cdot u)} \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{u^2}{2}} \cdot du \\ &= e^{r \cdot \mu_V} \cdot \int_{-\infty}^{+\infty} e^{r \cdot \sigma_V \cdot u} \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{u^2}{2}} \cdot du \\ &= e^{r \cdot \mu_V} \cdot \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \cdot e^{r \cdot \sigma_V \cdot u - \frac{u^2}{2}} \cdot du \\ &= e^{r \cdot \mu_V} \cdot \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \cdot e^{r \cdot \sigma_V \cdot u - \frac{u^2}{2}} \cdot \frac{e^{(r \cdot \sigma_V)^2/2}}{e^{(r \cdot \sigma_V)^2/2}} \cdot du \\ &= e^{r \cdot \mu_V + (r \cdot \sigma_V)^2/2} \cdot \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \cdot e^{r \cdot \sigma_V \cdot u - \frac{u^2}{2} - \frac{(r \cdot \sigma_V)^2}{2}} \cdot du \\ &= e^{r \cdot \mu_V + \frac{1}{2} \cdot (r \cdot \sigma_V)^2} \cdot \underbrace{\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2}(u - r \cdot \sigma_V)^2} \cdot du}_{=1} \end{aligned}$$

donde, finalmente,

$$E[X^r] = e^{r \cdot \mu_V + \frac{1}{2} \cdot (r \cdot \sigma_V)^2}. \quad (A7.5.2)$$

- (4) Fazendo $r = 1$ em A7.5.2, resulta

$$E[X] = \mu = e^{\mu_V + \frac{1}{2} \sigma_V^2} \quad (\text{primeira das expressões 7.10}).$$

- (5) Fazendo $r = 2$ em A7.5.2, obtém-se

$$E[X^2] = e^{2 \cdot (\mu_V + \sigma_V^2)},$$

pelo que

$$\sigma^2 = E[X^2] - (E[X])^2 = e^{2 \cdot (\mu_V + \sigma_V^2)} - e^{2 \cdot \mu_V + \sigma_V^2} \quad (\text{segunda das expressões 7.10}).$$

■ APÊNDICE 7.6 DEMONSTRAÇÃO DA RELAÇÃO 7.21

- (1) Sejam $X \sim F_{GL_1, GL_2}$ e $X' \sim F_{GL_1, GL_2}$ e denotem-se por $F_{GL_1, GL_2}(1 - \alpha)$ e $F_{GL_2, GL_1}(\alpha)$ os valores para os quais

$$P[X > F_{GL_1, GL_2}(1 - \alpha)] = 1 - \alpha, \quad (A7.6.1)$$

$$P[X' > F_{GL_2, GL_1}(\alpha)] = \alpha. \quad (A7.6.2)$$

- (2) De A7.6.1 decorre directamente que

$$P[X < F_{GL_1, GL_2}(1 - \alpha)] = \alpha,$$

o que implica que

$$P\left[\frac{1}{X} > \frac{1}{F_{GL_1, GL_2}(1 - \alpha)}\right] = \alpha. \quad (A7.6.3)$$

- (3) Por outro lado, atendendo à definição de $X \sim F_{GL_1, GL_2}$,

$$X = \frac{\chi_{GL_1}^2 / GL_1}{\chi_{GL_2}^2 / GL_2}$$

donde

$$\frac{1}{X} = \frac{\chi_{GL_2}^2 / GL_2}{\chi_{GL_1}^2 / GL_1} = X' \quad (\text{onde } X' \sim F_{GL_2, GL_1}).$$

- (4) A expressão A7.6.3 pode então escrever-se


$$P\left[X' > \frac{1}{F_{GL_1, GL_2}(1 - \alpha)}\right] = \alpha$$

mas, atendendo à expressão A7.6.2, vem

$$\frac{1}{F_{GL_1, GL_2}(1 - \alpha)} = F_{GL_2, GL_1}(\alpha)$$

ou, finalmente,

$$F_{GL_1, GL_2}(1 - \alpha) = \frac{1}{F_{GL_2, GL_1}(\alpha)} \quad (\text{relação 7.21}).$$



- 7.1. O tempo de funcionamento sem avarias de uma determinada máquina de produção contínua segue uma lei Exponencial Negativa com valor esperado igual a 4.5 horas. Imagine que a máquina é recolocada em funcionamento no instante $t = 0$ horas.
- (i) Qual a probabilidade de não ocorrer qualquer avaria antes do instante $t = 6$ horas?
 - (ii) Admitindo que a máquina se encontrava ainda em funcionamento no instante $t = 4$ horas, qual a probabilidade de não ocorrer qualquer avaria antes do instante $t = 6$ horas?
 - (iii) Qual a probabilidade de se verificarem duas avarias durante as primeiras 6 horas de funcionamento da máquina?
- 7.2. A altura dos cidadãos adultos de um determinado país segue uma distribuição Normal com valor esperado igual a 1.70 m e com desvio padrão igual a 0.05 m.
- (i) Qual a probabilidade de a altura de um cidadão ser de 1.80 m?
 - (ii) Qual a probabilidade de a altura de um cidadão ultrapassar 1.80 m?
 - (iii) Sabe-se que um determinado cidadão tem uma altura superior a 1.75 m. Qual a probabilidade de ter uma altura superior a 1.80 m?
 - (iv) Qual a proporção de cidadãos que têm alturas compreendidas entre 1.60 m e 1.80 m?
- 7.3. Admita-se que o rendimento anual (em milhares de euros) dos agricultores numa determinada região tem valor esperado 3.25 e variância 0.25 e segue uma distribuição Lognormal.
- (i) Qual a probabilidade de o rendimento anual de um agricultor ser superior a 3.25 milhares de euros?
 - (ii) Qual o rendimento anual mediano?
 - (iii) Qual a proporção de agricultores cujos rendimentos anuais são inferiores a 0.9 milhares de euros?
- 7.4. Admita que, por engano, se juntaram dois lotes: um incluindo 5000 peças com grau de qualidade A e outro integrando 2000 peças com grau de qualidade B.
- Qual a probabilidade de, numa amostra de dimensão 300 seleccionada aleatoriamente a partir da mistura dos dois lotes, haver mais do que 220 peças com grau de qualidade A?
- 7.5. A variável X segue uma distribuição χ^2 com 19 graus de liberdade.
- (i) Determine o valor x_0 , tal que $P(X < x_0) = 5\%$.
 - (ii) Determine a probabilidade $P(8.91 < X < 22.72)$.

7.6. A variável V segue uma distribuição t com 7 graus de liberdade.

- (i) Determine o valor v_0 , tal que $P(V > v_0) = 1\%$.
- (ii) Determine a probabilidade $P(-1.12 < V < 2.99)$.

7.7. A variável U segue uma distribuição $F_{24, 30}$.


- (i) Determine o valor u_0 , tal que $P(U > u_0) = 5\%$.
- (ii) Determine o valor u_1 , tal que $P(U < u_1) = 1\%$.

7.8. As longevidades de 2 tipos de pilhas — medidas, em horas, de acordo com uma norma europeia — seguem as seguintes distribuições:

- Bateria T: distribuição Normal $N(150, 5^2)$;
- Bateria A: distribuição Normal $N(156, 3^2)$.

Calcule a probabilidade de uma pilha do tipo T ter uma longevidade superior à de uma pilha qualquer do tipo A.

8



Amostragem Aleatória Distribuições por Amostragem

8.1 INTRODUÇÃO

Neste capítulo encerra-se o percurso dedutivo «população → amostra». Partindo do conhecimento da população, caracterizar-se-ão as distribuições de certas estatísticas, ou seja, analisar-se-á a forma como tais estatísticas variam de amostra para amostra.

Para que tal seja possível, é necessário que as amostras sejam seleccionadas de acordo com processos probabilísticos (isto é, processos que tornem possível o cálculo da probabilidade de cada elemento da população ser incluído em cada amostra). Neste capítulo considerar-se-á apenas o processo de **amostragem aleatória**, apresentado anteriormente, no Capítulo 1 (Secção 1.3.2), como o mais importante dos processos probabilísticos.

8.2 AMOSTRAGEM ALEATÓRIA

Tal como anteriormente foi referido no Capítulo 1 (Secção 1.3.2), o processo de amostragem aleatória garante que todos os elementos da população têm a mesma probabilidade de ser incluídos na amostra. Para formalizar esta propriedade, considere-se uma população finita constituída por M elementos e defina-se, com base nessa população, uma variável aleatória Y com função de probabilidade $p_Y(y)$.

Exemplo 8.1

Considere-se uma população constituída pelas alturas de 5 indivíduos, expressas em metros:

{1.70, 1.74, 1.75, 1.75, 1.82}.

Seja Y a variável altura de um dos indivíduos seleccionado ao acaso. A função de probabilidade de Y será a que se encontra definida na Tabela 8.1.

Tabela 8.1
Função de probabilidade da variável altura (Exemplo 8.1).

y	1.70	1.74	1.75	1.82
$p_Y(y)$	1/5	1/5	2/5	1/5

Considerem-se amostras de dimensão N obtidas a partir da população e designem-se por $Y_1, Y_2, \dots, Y_N$ as réplicas da variável Y relativas ao primeiro, segundo, ..., N -ésimo elemento de cada amostra.

Exemplo 8.2

A partir da população definida no Exemplo 8.1, definam-se amostras de dimensão $N = 2$. Cada amostra será constituída por duas observações (isto é, por dois valores partculares) das variáveis altura: $Y_1 = y_1$ e $Y_2 = y_2$.

Admita-se que cada amostra é obtida de acordo com o procedimento constituído pelos passos seguintes:

- numerar de 1 até M todos os elementos da população;
- colocar bolas numeradas de 1 até M numa urna (ou, se se preferir, numa máquina de extracção dos números do Totoloto);
- retirar ao acaso uma bola (de tal forma que a probabilidade de retirar uma bola seja igual à de retirar qualquer outra) e incluir na amostra o elemento da população com o número correspondente;
- repor a bola na urna (ou na máquina); e
- repetir os passos (iii) e (iv) tantas vezes quantas as necessárias para incluir N elementos na amostra (admite-se que extracções sucessivas são independentes).

Para este processo de amostragem, as funções de probabilidade das variáveis $Y_1, Y_2, \dots, Y_N$ são idênticas à da variável original Y . Esta condição pode ser expressa nos seguintes termos:

$$\forall y: p_{Y_1}(y) = p_{Y_2}(y) = \dots = p_{Y_N}(y) = p_Y(y). \quad (8.1)$$

Os processos dizem-se **aleatórios** quando for satisfeita esta condição. As amostras assim obtidas dizem-se também **aleatórias**.

No procedimento descrito, admitiu-se que a amostragem era efectuada **com reposição** (das bolas ou, o que é equivalente, dos elementos da população), o que conduz a que as variáveis $Y_1, Y_2, \dots, Y_N$ sejam independentes, condição que se traduz por

$$\forall y_1, y_2, \dots, y_N: p_{Y_1, Y_2, \dots, Y_N}(y_1, y_2, \dots, y_N) = p_{Y_1}(y_1) \cdot p_{Y_2}(y_2) \cdot \dots \cdot p_{Y_N}(y_N). \quad (8.2)$$

Neste caso, tanto o processo de amostragem como as amostras assim obtidas dizem-se **aleatórios simples**. Note-se que, como resultado da reposição, o que está em causa é retirar N amostras de dimensão unitária a partir de N populações finitas idênticas, de dimensão M . Isto equivale a retirar, sem reposição, uma amostra de dimensão N a partir de uma população infinita constituída por elementos idênticos aos da população original (finita), figurando nas mesmas proporções.

Exemplo 8.3

Admitindo que as amostras de dimensão $N = 2$ consideradas no Exemplo 8.2 eram geradas de acordo com o procedimento descrito (com reposição), as funções de probabilidade $p_{Y_1}(y_1)$, $p_{Y_2}(y_2)$ (ambas idênticas a $p_Y(y)$), e $p_{Y_1, Y_2}(y_1, y_2) = p_{Y_1}(y_1) \cdot p_{Y_2}(y_2)$ são as que se apresentam na Tabela 8.2.

Tabela 8.2
Representação tabular da função conjunta e das funções marginais de probabilidade de Y_1 e Y_2 (população finita, amostragem com reposição).

		$Y_2 [m]$				
		1.70	1.74	1.75	1.82	$p_{Y_1}(y_1)$
$Y_1 [m]$	1.70	1/25	1/25	2/25	1/25	1/5
	1.74	1/25	1/25	2/25	1/25	1/5
	1.75	2/25	2/25	4/25	2/25	2/5
	1.82	1/25	1/25	2/25	1/25	1/5
$p_{Y_2}(y_2)$		1/5	1/5	2/5	1/5	

Considere-se agora que as amostras eram obtidas de acordo com um procedimento que apenas se distinguia do anterior pelo facto de cada bola extraída não ser reposta. Com este procedimento **sem reposição**, as funções de probabilidade das variáveis $Y_1, Y_2, \dots, Y_N$

(com $N \leq M$) deixam de ser independentes, pois, em geral, dado que se admitiu que a população é finita, os valores que os primeiros elementos da amostra tomam condicionam os seguintes. Isto implica que existem valores de $Y_1, Y_2, \dots, Y_N$ para os quais

$$\begin{aligned} p_{Y_2|Y_1}(y_2 | y_1) &\neq p_{Y_2}(y_2) \\ p_{Y_3|Y_1, Y_2}(y_3 | y_1, y_2) &\neq p_{Y_3}(y_3) \\ p_{Y_N|Y_1, Y_2, \dots, Y_{N-1}}(y_N | y_1, y_2, \dots, y_{N-1}) &\neq p_{Y_N}(y_N). \end{aligned} \quad (8.3)$$

No entanto, uma vez que no procedimento considerado nenhum elemento da população recebe um tratamento diferente dos restantes, as probabilidades de os diferentes elementos da população virem a pertencer à amostra são iguais. Daí que seja satisfeita a condição definida pela expressão 8.1, pelo que o processo de amostragem é aleatório (embora não seja aleatório simples, dado que não é satisfeita a condição de independência das distribuições de $Y_1, Y_2, \dots, Y_N$).

Exemplo 8.4

Admitindo que as amostras de dimensão $N = 2$ consideradas no Exemplo 8.2 eram agora geradas de acordo com o procedimento sem reposição, as funções de probabilidade $p_{Y_1}(y_1)$, $p_{Y_2}(y_2)$ (note-se que são ambas idênticas a $p_Y(y)$) e $p_{Y_1, Y_2}(y_1, y_2) \neq p_{Y_1}(y_1) \cdot p_{Y_2}(y_2)$ são as que se apresentam na Tabela 8.3. As diferenças relativamente à Tabela 8.2 verificam-se apenas na função conjunta, como resultado da não reposição. Assim, por exemplo, a função conjunta anula-se agora para $Y_1 = 1.70$ e $Y_2 = 1.70$, pois na população há apenas uma altura igual a 1.70 m. Saída a primeira altura igual a 1.70, a segunda será necessariamente diferente.

Tabela 8.3
Representação tabular da função conjunta e das funções marginais de probabilidade de Y_1 e Y_2 (população finita, amostragem sem reposição).

		$Y_2 [m]$				
		1.70	1.74	1.75	1.82	$p_{Y_1}(y_1)$
$Y_1 [m]$	1.70	0	1/20	2/20	1/20	1/5
	1.74	1/20	0	2/20	1/20	1/5
	1.75	2/20	2/20	2/20	2/20	2/5
	1.82	1/20	1/20	2/20	0	1/5
$p_{Y_2}(y_2)$		1/5	1/5	2/5	1/5	

É fácil compreender que, quando a dimensão da população tende para infinito ($M \rightarrow \infty$) e a dimensão de uma amostra se mantém finita, a dependência entre as variáveis $Y_1, Y_2, \dots, Y_N$ tende a desaparecer. Assim, quando a população for infinita, é indiferente realizar uma amostragem aleatória com ou sem reposição. A amostragem aleatória é simples em qualquer dos casos.

O conceito de amostragem aleatória foi introduzido considerando o caso de variáveis discretas. A generalização ao caso das variáveis contínuas — que presumem populações infinitas ou, na prática, populações finitas de muito grande dimensão — é relativamente simples.

Com base numa população deste tipo, defina-se uma variável aleatória contínua X , com função densidade de probabilidade $f_X(x)$. Considerem-se amostras de dimensão N obtidas a partir da população e designem-se por $X_1, X_2, \dots, X_N$ as réplicas da variável X relativas ao primeiro, segundo, ..., N -ésimo elemento de cada amostra. O processo de amostragem e as amostras dir-se-ão aleatórios (simples) quando forem satisfeitas as duas condições seguintes:

- As funções densidade de probabilidade de $X_1, X_2, \dots, X_N$ são todas idênticas a $f_X(x)$:

$$\forall x: f_{X_1}(x) = f_{X_2}(x) = \dots = f_{X_N}(x) = f_X(x). \quad (8.4)$$

- (ii) As variáveis $X_1, X_2, \dots, X_N$ são mutuamente independentes, ou seja a função conjunta densidade de probabilidade destas variáveis é dada por:

$$\forall x_1, x_2, \dots, x_N : \\ f_{X_1, X_2, \dots, X_N}(x_1, x_2, \dots, x_N) = f_X(x_1) \cdot f_X(x_2) \cdot \dots \cdot f_X(x_N). \quad (8.5)$$

8.3 DISTRIBUIÇÕES POR AMOSTRAGEM

Tal como se observou anteriormente (Capítulo 4, Secção 4.5), existe uma diferença fundamental entre parâmetros e estatísticas: para uma dada população e uma dada variável aleatória sobre ela definida, os parâmetros da distribuição correspondente (valor esperado, variância, etc.) são fixos. Por seu turno, as estatísticas (média amostral, variância amostral, etc.) variam de amostra para amostra.

Dada esta variabilidade das estatísticas, interessará tentar definir a sua distribuição probabilística, através das respectivas funções de probabilidade ou densidade de probabilidade. As distribuições das estatísticas recebem o nome de **distribuições por amostragem**. Este conceito será ilustrado considerando o seguinte exemplo.

Exemplo 8.5

Considere-se uma população com 4 elementos, que correspondem aos seguintes valores da variável aleatória Y : {2, 4, 6, 6}. Na Tabela 8.4 apresenta-se a função de probabilidade desta variável, conjuntamente com o seu valor esperado e a sua variância.

Pretende-se definir a distribuição por amostragem de $\bar{Y}$, a média amostral calculada com base em amostras de dimensão 2 obtidas por um processo aleatório sem reposição. Note-se que a média amostral foi aqui denotada por uma letra maiúscula para significar que se trata de uma variável aleatória (e não de um valor particular dessa variável, que se denotaria por $\bar{y}$, isto é, com uma letra minúscula).

Na Tabela 8.5 definem-se todas as amostras de dimensão 2 obtíveis recorrendo ao processo indicado, bem como as respectivas médias amostrais e as correspondentes probabilidades de ocorrência.

A partir desta informação, definiu-se na Tabela 8.6 a função de probabilidade da média amostral (ou seja, definiu-se a distribuição de $\bar{Y}$).

Tabela 8.4
Função de probabilidade da variável Y (Exemplo 8.5).

y	$p_Y(y)$
2	1/4
4	1/4
6	1/2

$$\mu_Y = 2 \cdot (1/4) + 4 \cdot (1/4) + 6 \cdot (1/2) = 4.5$$

$$\sigma_Y^2 = 2.5^2 \cdot (1/4) + 0.5^2 \cdot (1/4) + 1.5^2 \cdot (1/2) = 2.75$$

Tabela 8.5
Amostras de dimensão $N = 2$, valores correspondentes da média amostral e respectivas probabilidades de ocorrência (Exemplo 8.5).

Amostra	$\bar{y}$	Prob. de ocorrência
2,4	3	$1/4 \cdot 1/3 = 1/12$
2,6	4	$1/4 \cdot 2/3 = 2/12$
4,2	3	$1/4 \cdot 1/3 = 1/12$
4,6	5	$1/4 \cdot 2/3 = 2/12$
6,2	4	$2/4 \cdot 1/3 = 2/12$
6,4	5	$2/4 \cdot 1/3 = 2/12$
6,6	6	$2/4 \cdot 1/3 = 2/12$

Tabela 8.6
Distribuição por amostragem de $\bar{Y}$ (Exemplo 8.5).

$\bar{y}$	$p_{\bar{Y}}(\bar{y})$
3	$1/12 + 1/12 = 1/6$
4	$2/12 + 2/12 = 1/3$
5	$2/12 + 2/12 = 1/3$
6	$2/12 = 1/6$

$$\mu_{\bar{Y}} = 3 \cdot (1/6) + 4 \cdot (1/3) + 5 \cdot (1/3) + 6 \cdot (1/6) = 4.5$$

$$\sigma_{\bar{Y}}^2 = 1.5^2 \cdot (1/6) + 0.5^2 \cdot (1/3) + 0.5^2 \cdot (1/3) + 1.5^2 \cdot (1/6) = 0.917$$

Na Tabela 8.6 apresenta-se o cálculo do valor esperado e da variância da distribuição por amostragem de $\bar{Y}$. O desvio padrão de tal distribuição ($\sigma_{\bar{Y}}$) e, em geral, o desvio padrão da distribuição por amostragem de uma estatística é designado habitualmente por **erro padrão** (da estatística em causa).

No exemplo considerado, a especificação da distribuição por amostragem a partir da distribuição da variável original (com base na qual a estatística foi definida) foi simples, porque a população era muito pequena. Nas secções seguintes apresentar-se-ão métodos que permitem especificar distribuições por amostragem — de uma forma precisa ou aproximada, total ou parcialmente — em situações para as quais o método adoptado no Exemplo 8.5 não resultaria.

8.4 DISTRIBUIÇÃO DA MÉDIA AMOSTRAL

8.4.1 VALOR ESPERADO E VARIÂNCIA DA MÉDIA AMOSTRAL

Para uma variável original X , representativa de uma dada população, e para amostras de dimensão N , a média amostral é definida por

$$\bar{X} = \frac{1}{N} \cdot \sum_{n=1}^N X_n$$

Recordando que o valor esperado de uma soma de variáveis é igual à soma dos valores esperados das variáveis (ver expressão 5.34), obtém-se para o valor esperado da média amostral:

$$E(\bar{X}) = E\left(\frac{1}{N} \cdot \sum_{n=1}^N X_n\right) = \frac{1}{N} \cdot E\left(\sum_{n=1}^N X_n\right) = \frac{1}{N} \cdot \sum_{n=1}^N E(X_n) = \frac{1}{N} \cdot \sum_{n=1}^N E(X) = \frac{1}{N} \cdot [N \cdot E(X)] = E(X),$$

ou seja,

$$\mu_{\bar{X}} = \mu_X \quad (8.6)$$

Fica assim justificado porque é que, relativamente ao Exemplo 8.5, o valor esperado obtido para a média amostral (ver Tabela 8.6) era igual ao valor esperado da variável original (ver Tabela 8.4).

Para definir a variância, é necessário estabelecer a distinção entre amostras aleatórias simples (população finita com reposição ou população infinita) e amostras aleatórias que não sejam simples (população finita, sem reposição).

No primeiro caso, as variáveis X_n são independentes. Recordando que, nesta situação, a variância da soma é igual à soma das variâncias (ver expressão 5.39), obtém-se para a variância da média amostral:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{N} \cdot \sum_{n=1}^N X_n\right) = \frac{1}{N^2} \cdot \text{Var}\left(\sum_{n=1}^N X_n\right) = \frac{1}{N^2} \cdot \sum_{n=1}^N \text{Var}(X_n) \\ = \frac{1}{N^2} \cdot \sum_{n=1}^N \text{Var}(X) = \frac{1}{N^2} \cdot [N \cdot \text{Var}(X)] = \frac{1}{N} \cdot \text{Var}(X),$$

ou seja,

$$\sigma_{\bar{x}}^2 = \frac{1}{N} \cdot \sigma_x^2 \quad (\text{amostras aleatórias simples}). \quad (8.7)$$

Desta expressão resulta que a dispersão da média amostral é inferior à dispersão da variável original e tanto menor quanto maior for a dimensão da amostra. A interpretação deste resultado é simples: no cálculo da média amostral, as observações que se desviem num sentido em relação ao valor esperado tenderão a ser compensadas por observações que se desviem no sentido contrário, e a compensação será tanto mais perfeita quanto maior for o número de termos da média amostral.

No segundo caso (população finita, sem reposição), as variáveis X_n não são independentes. De facto, se uma delas toma um valor acima do valor esperado, as outras tenderão a tomar valores abaixo daquele parâmetro, existindo portanto entre elas uma correlação negativa. Neste caso, como se demonstra no Apêndice 8.1, a variância da média amostral vem dada por

$$\sigma_{\bar{x}}^2 = \left(\frac{M-N}{M-1} \right) \cdot \frac{1}{N} \cdot \sigma_x^2 \quad (\text{população finita, amostragem sem reposição}) \quad (8.8)$$

onde M e N representam as dimensões da população e da amostra, respectivamente. Em relação à expressão 8.7, surge um termo adicional,

$$\left(\frac{M-N}{M-1} \right) \quad (\text{com } N \leq M),$$

que se designa por factor de correcção (ou de redução) para populações finitas.

Em geral (isto é, quando $1 < N < M$), este factor é inferior à unidade, o que significa que, para a mesma variância da variável original, X , a dispersão da média amostral é menor no caso de uma amostragem sem reposição a partir de uma população finita. Este decréscimo da dispersão da média amostral deve-se à correlação negativa entre as variáveis X_n .

Exemplo 8.6

Para o Exemplo 8.5, a variância da média amostral, calculada recorrendo à expressão 8.8, vem

$$\sigma_{\bar{y}}^2 = \left(\frac{M-N}{M-1} \right) \cdot \frac{1}{N} \cdot \sigma_y^2 = \left(\frac{4-2}{4-1} \right) \cdot \frac{1}{2} \cdot 2.75 = 0.917.$$

Note-se que o valor obtido coincide com aquele que tinha sido obtido directamente a partir da distribuição de $\bar{Y}$ (ver Tabela 8.6).

Deve chamar-se a atenção para o valor que o factor de redução toma em algumas situações particulares:

- $M \rightarrow \infty$: Quando a dimensão da população tende para infinito, a amostra (que se admite ter dimensão finita) é aleatória simples, haja ou não reposição, e o factor tende para 1.
- $N = 1$: Neste caso, o factor de redução toma o valor 1, pois, havendo apenas um elemento na amostra, não há qualquer diferença entre os processos com e sem reposição (a média amostral coincide com a variável original, sendo portanto idênticas as suas variâncias).
- $N = M$: Quando a amostra coincide com a população, a média amostral coincide sempre com o valor esperado da variável original, tornando-se portanto uma constante. Neste caso, o factor de redução e, portanto, a variância da média amostral anulam-se.

8.4.2 FORMA DA DISTRIBUIÇÃO DA MÉDIA AMOSTRAL QUANDO A POPULAÇÃO É NORMAL

Considere-se uma população representada por uma variável X Normalmente distribuída, com valor esperado μ_x e variância σ_x^2 . Para amostras aleatórias de dimensão N , a média amostral,

$$\bar{X} = \frac{1}{N} \cdot \sum_{n=1}^N X_n$$

é uma combinação linear das variáveis X_n , todas elas com a distribuição $N(\mu_x, \sigma_x^2)$ e independentes entre si (o facto de a distribuição de X ser Normal presume, em rigor, que a população seja infinita e que, portanto, as amostras aleatórias sejam simples). Dado que, como se referiu no capítulo anterior (Secção 7.4.3), uma combinação linear de variáveis Normais independentes é, ela própria, uma variável Normal, a média amostral $\bar{X}$ segue também uma distribuição Normal. Atendendo a que esta distribuição fica inteiramente especificada através do valor esperado e da variância, e uma vez que estes parâmetros podem ser calculados a partir dos parâmetros correspondentes da população (expressões 8.6 e 8.7), a distribuição da média amostral fica, neste caso, inteiramente especificada:

$$\bar{X} \sim N\left(\mu_x, \frac{1}{N} \cdot \sigma_x^2\right) \quad (\text{população Normal}). \quad (8.9)$$

8.5 TEOREMA DO LIMITE CENTRAL

8.5.1 ENUNCIADO DO TEOREMA. IMPLICAÇÕES NA CARACTERIZAÇÃO DE DISTRIBUIÇÕES POR AMOSTRAGEM

Embora os resultados apresentados na Secção 8.4 sejam de extrema importância, eles são relativamente limitados. Na verdade, referem-se a uma estatística simples (a média amostral é uma combinação linear de variáveis idênticas) e, mesmo para esta estatística, só permitem especificar a forma da sua distribuição por amostragem no caso em que a população segue uma distribuição Normal.

O **teorema do limite central** — que, no domínio da Estatística, constitui um dos desenvolvimentos teóricos mais notáveis, com inúmeras aplicações — permite, em particular, fazer progressos significativos na caracterização de distribuições por amostragem.

De uma forma extremamente simplificada, o teorema pode ser enunciado nos seguintes termos: sejam $X_1, \dots, X_N$ variáveis aleatórias independentes com a mesma distribuição, que se admite ter variância finita (quase todas as distribuições com interesse prático têm variância finita, pelo que esta condição não é particularmente restritiva). Qualquer que seja a forma da distribuição destas variáveis, se o valor N for suficientemente grande, a variável soma

$$S = \sum_{n=1}^N X_n$$

segue aproximadamente uma distribuição Normal.

Esta distribuição é inteiramente especificada através do valor esperado e da variância de S , que são dados por

$$\mu_S = N \cdot \mu_x \quad \sigma_S^2 = N \cdot \sigma_x^2$$

onde μ_x e σ_x^2 representam o valor esperado e a variância das variáveis X_n .

Do teorema assim enunciado resulta imediatamente que, para uma qualquer população com variância finita, a distribuição da média amostral calculada com base numa amostra aleatória simples tende para uma distribuição Normal, à medida que a dimensão da amostra cresce. Na realidade, a média amostral resulta de multiplicar a variável soma pelo coeficiente $1/N$, portanto, se a distribuição da soma se aproxima de uma distribuição Normal, o mesmo sucederá à distribuição da média amostral. No caso da média amostral, a distribuição é a definida através da expressão 8.9.

O que há de mais notável no teorema do limite central é o facto de não se impor nenhuma condição relativa à forma da distribuição original: qualquer que seja esta forma, as variáveis soma ou média amostral têm uma distribuição aproximadamente Normal, se o número de termos for suficientemente elevado.

Exemplo 8.7


Na Figura 8.1 apresenta-se a distribuição da variável Y , tal como se encontra definida na Tabela 8.7, bem como as distribuições da média amostral $\bar{Y}$ (para $N = 5, 10, 20, 50, 100$ e admitindo que as amostras são aleatórias simples).

A Figura 8.1 merece alguns comentários. O primeiro refere-se ao facto de apenas se representarem os contornos dos diagramas de barras, neste caso constituídos por barras justapostas. Por exemplo, no primeiro histograma, a barra correspondente a $Y = 0$ cobre os valores de $Y = -0.5$ até $Y = 0.5$, enquanto que a barra correspondente a $Y = 1$ cobre os valores de $Y = 0.5$ até $Y = 1.5$.

Tabela 8.7
Distribuição
da variável Y
(Exemplo 8.7).

y	$p(y)$
0	0.80
1	0.20

Figura 8.1
Distribuição de Y e de $\bar{Y}$ (Exemplo 8.8).



O segundo comentário diz respeito às ordenadas dos diagramas. Com o objectivo de que as áreas dos diferentes diagramas fossem todas idênticas, à altura de cada barra foi atribuído o valor que resultou de dividir a função de probabilidade pela largura da barra (a justificação para este procedimento foi dada no Capítulo 2, Secção 2.3.2.1, a propósito dos histogramas com células de amplitude variável).

Finalmente, deve notar-se que, dado que a distribuição de Y é discreta, também o é a distribuição da média amostral. Apesar disso, no caso da Figura 8.1, a distribuição Normal é uma boa aproximação da distribuição da média amostral para $N \geq 50$.

Uma questão que se pode colocar em relação ao teorema do limite central, tal como este foi enunciado, é a de saber quando é que N é «suficientemente grande» para que a distribuição Normal seja efectivamente uma boa aproximação da distribuição da variável soma ou da média amostral.

No Exemplo 8.7, a partir da distribuição da variável original, definiu-se a distribuição da média amostral pela via teórica. Tal foi possível porque a distribuição da variável original era extremamente simples. Em casos como este, é possível dar resposta à questão formulada por comparação directa entre as distribuições em causa.

Quando a especificação da distribuição da média amostral (ou da variável soma) não for possível — o que sucede na maioria das situações —, a resposta àquela questão pode ser dada pela via experimental, recorrendo à geração de amostras aleatórias pela técnica de Monte Carlo (este assunto será abordado mais adiante, na Secção 8.6).

Em termos gerais pode afirmar-se que, para um dado valor de N , o rigor da aproximação Normal depende da forma da distribuição original, sendo, em particular, tanto menor quanto maior for a assimetria desta. Como regra prática, é frequente indicar-se que a aproximação Normal é adequada quando $N \geq 10$, se a distribuição original for simétrica, ou quando $N \geq 50$, se a distribuição original for muito assimétrica.

No enunciado anteriormente apresentado do teorema do limite central, considerou-se que as variáveis $X_1, \dots, X_N$ eram independentes e tinham distribuições idênticas. Estas duas condições são suficientes para que se verifique a aproximação Normal, não sendo, no entanto, necessárias. Tais condições podem ser relaxadas:

- (i) as variáveis $X_1, \dots, X_N$ podem ter distribuições distintas, desde que a contribuição da variância de cada uma delas para a variância de S (variável soma) seja pequena, e
- (ii) as variáveis $X_1, \dots, X_N$ podem não ser independentes, desde que as correlações entre elas sejam fracas.

A terminar a apresentação do teorema do limite central, deve acrescentar-se que, no âmbito da caracterização das distribuições por amostragem, o seu alcance ultrapassa largamente as estatísticas até agora consideradas (a soma e média amostral). De facto, existem variantes do teorema que permitem mostrar que as distribuições de muitas outras estatísticas — em particular a da variância amostral — se aproximam da distribuição Normal quando a dimensão das amostras aleatórias for suficientemente grande.

Nas secções seguintes procurar-se-á mostrar que as implicações do teorema do limite central ultrapassam largamente o foro das distribuições por amostragem.

8.5.2 JUSTIFICAÇÃO DA NORMALIDADE DE CERTAS VARIÁVEIS

À luz do teorema do limite central, é possível justificar *a priori* que certas variáveis se distribuam de acordo com distribuições Normais. Tal sucederá, em particular, quando uma variável possa ser considerada, pelo menos aproximadamente, como uma soma de um conjunto significativo de variáveis independentes e idênticamente distribuídas.

Exemplos 8.8

- ♦ Para um sector de uma floresta no qual as árvores tenham sido plantadas há 50 anos, considere-se a variável diâmetro do tronco das árvores. Este diâmetro pode ser interpretado como a soma de um elevado número de termos, cada um deles representando o crescimento anual do tronco. Não parece destituído de sentido considerar que os

crescimentos anuais do diâmetro podem ser descritos, pelo menos aproximadamente, como variáveis independentes com idênticas distribuições. Nestas condições, é de esperar que o diâmetro seja distribuído aproximadamente como uma variável Normal.

- Num aparelho de medida que tenha um número elevado de fontes potenciais de erro, razoavelmente independentes e sem que nenhuma delas seja dominante em termos da amplitude do erro introduzido, é de esperar que o erro global tenha uma distribuição aproximadamente Normal.

8.5.3 JUSTIFICAÇÃO DE ALGUNS RESULTADOS APRESENTADOS ANTERIORMENTE

Para ilustrar o âmbito das implicações do teorema do limite central, apresentam-se seguidamente as justificações de alguns resultados anteriormente apresentados.

8.5.3.1 APROXIMAÇÃO DA DISTRIBUIÇÃO BINOMIAL PELA DISTRIBUIÇÃO NORMAL

Seja Z_n uma variável que toma o valor 1 quando o resultado de uma experiência de Bernoulli for «sucesso» e que toma o valor 0 no caso contrário. Admita-se que a função de probabilidade de Z_n é $p_z(1) = p$ e $p_z(0) = q = 1 - p$.

A variável Binomial $Y \sim B(N, p)$ pode ser interpretada como a soma

$$Y = \sum_{n=1}^N Z_n.$$

Dado que as variáveis Z_n são igualmente distribuídas (com variância finita) e independentes, do teorema do limite central resulta que a distribuição de Y (isto é, a distribuição Binomial) se aproxima da distribuição Normal para valores suficientemente grandes de N .

8.5.3.2 APROXIMAÇÃO DA DISTRIBUIÇÃO HIPERGEOMÉTRICA PELA DISTRIBUIÇÃO NORMAL

A justificação é idêntica à anterior, havendo que relaxar a condição inicial de independência entre as variáveis Z_n . De facto, estas variáveis são agora dependentes, e a aproximação Normal só se verificará quando a dependência for fraca — isto é, quando M for muito superior a N em $H(M \cdot p, M \cdot q, N)$.

8.5.3.3 APROXIMAÇÃO DA DISTRIBUIÇÃO χ^2_{GL} PELA DISTRIBUIÇÃO NORMAL

A variável Qui-quadrado é dada pela soma

$$\chi^2_{GL} = \sum_{n=1}^{GL} Z_n^2$$

onde Z_n são variáveis independentes, todas com a mesma distribuição $N(0, 1)$.

Do teorema do limite central resulta que a distribuição do Qui-quadrado se aproxima da distribuição Normal para valores suficientemente grandes de GL .

8.6 GERAÇÃO DE AMOSTRAS RECORRENDO À TÉCNICA DE MONTE CARLO

8.6.1 ENQUADRAMENTO

Em muitas circunstâncias não é possível derivar pela via teórica, nem sequer de forma aproximada, a forma funcional das distribuições de certas estatísticas. Tal ocorre, por exemplo, quando as populações são infinitas e não-Normais, as amostras são de pequena dimensão e as estatísticas são funções complexas (não-lineares) das observações amostrais.

Exemplo 8.9

Quando a via teórica falha, resta a possibilidade de gerar artificialmente amostras — recorrendo à técnica de Monte Carlo — e, a partir das amostras geradas, estudar experimentalmente o comportamento das estatísticas em causa. Para ilustrar o procedimento geral a seguir nestes casos, considere-se o exemplo seguinte.

Admita-se que uma população infinita é caracterizada por uma variável aleatória X , que segue uma distribuição Exponencial Negativa com parâmetro $\lambda = 2$.

Para amostras de dimensão $N = 10$, pretende-se conhecer a distribuição do coeficiente de assimetria amostral

$$g_1 = \frac{k_3}{s^3} = \frac{N^2}{(N-1) \cdot (N-2)} \cdot \frac{m_3}{s^3}$$

onde m_3 denota o momento amostral centrado de ordem 3 e s denota o desvio padrão amostral.

Para este exemplo, o procedimento experimental envolveria os seguintes passos:

- Gerar uma amostra aleatória constituída por 10 observações da variável X (Exponencial Negativa, com parâmetro $\lambda = 2$).
- Com base em cada amostra gerada, calcular a estatística g_1 e registar o seu valor.
- Repetir os passos (i) e (ii) K vezes.
- Os valores registados $(g_1)_1, \dots, (g_1)_K$ constituem uma amostra que pode ter a dimensão K que se desejar. A partir de tal amostra, caracterizar experimentalmente a distribuição em causa, construindo um histograma ou calculando medidas amostrais de localização, dispersão, assimetria, etc.

O procedimento que acabou de ser enunciado envolve (no passo (i)) a geração de amostras aleatórias, constituídas por observações de uma variável aleatória que segue uma qualquer distribuição pré-especificada. Tal geração pode efectuar-se recorrendo à técnica de Monte Carlo. Deve notar-se que esta técnica — que será objecto da secção seguinte — tem inúmeras aplicações que ultrapassam claramente o âmbito da caracterização das distribuições por amostragem. A mais conhecida das suas áreas de aplicação é provavelmente a da Simulação, uma das técnicas de Investigação Operacional mais utilizadas.

8.6.2 GERAÇÃO DE AMOSTRAS ALEATÓRIAS PROVENIENTES DE UMA POPULAÇÃO COM UMA DISTRIBUIÇÃO $U(0, 1)$

A geração de amostras aleatórias — ou, como frequentemente se diz, a geração de números aleatórios — passa, em geral, por duas fases:

- geração de números aleatórios seguindo uma distribuição uniforme, $U(0, 1)$; e
- transformação daqueles números noutros igualmente aleatórios, mas seguindo uma outra distribuição qualquer pretendida.

Nesta secção serão descritos procedimentos que integram a primeira fase. Um processo possível para se obterem números aleatórios seguindo uma distribuição $U(0, 1)$ consistiria em, a partir de uma urna contendo 10 bolas numeradas de 0 a 9, adoptar os seguintes passos:

- Retirar uma bola ao acaso.
- Registar o seu número e repô-la na urna.
- Repetir sucessivamente os passos (i) e (ii), obtendo uma série de números equiprováveis e independentes

(Exemplo: 0392182746579921 ...)

- (iv) Conforme a precisão desejada para os números $U(0, 1)$ a gerar, constituir sequencialmente a partir da série obtida números com 1, 2, 3, ... algarismos e multiplicá-los respectivamente por 10^{-1} , 10^{-2} , 10^{-3} , ...

(Exemplos: 0.03 0.92 0.18 0.27 0.46 0.57 0.99 0.21 ...
0.039 0.218 0.274 0.657 0.992 ...)

Dado que os números aleatórios gerados no passo (iii) são equiprováveis e independentes, então qualquer das séries geradas no passo (iv) é constituída por números aleatórios independentes seguindo, com a precisão desejada, uma distribuição $U(0, 1)$ (ou seja, cada série constitui uma amostra aleatória de uma população $U(0, 1)$). Deve notar-se que, para qualquer dos números que integram tais séries, a probabilidade de numa casa decimal qualquer figurar um dos algarismos 0 a 9 é igual à probabilidade de figurar qualquer outro desses algarismos e é independente do que sucede noutras casas decimais (desse número ou de outros da mesma série).

É manifesto que o processo descrito, embora sirva como ilustração da forma de gerar números aleatórios $U(0, 1)$, não é facilmente implementável. Na prática, pode-se recorrer a tabelas de números aleatórios já publicadas (na Tabela 7 do Anexo «Tabelas», incluiu-se uma série de números aleatórios equiprováveis independentes) ou, ainda mais fácil, podem utilizar-se rotinas *standard* disponíveis em qualquer linguagem de programação.

Nestas rotinas, os números são obtidos por processos numéricos. Apesar de não serem, de facto, aleatórios, tais números comportam-se como tal, recebendo por isso a designação de **números pseudo-aleatórios**. Seguidamente, apresenta-se um processo que ilustra a forma como tais números podem ser gerados:

- Considere-se um número N_0 com 4 dígitos escolhido arbitrariamente (exemplo: 9218).
- Eleva-se o número definido no passo anterior ao quadrado (para o exemplo considerado, obteve-se 84971524).
- Defina-se um novo número constituído pelos 4 dígitos que, no número obtido no passo anterior, figuram entre a casa das centenas de milhar e a casa das centenas (para o exemplo considerado, obteve-se 9715). Inicie-se a série com este número (ou, se não se estiver a executar este passo pela primeira vez, acrescente-se este número à série a gerar).
- Repitam-se sucessivamente os passos (ii) e (iii) até se obter uma série com a dimensão desejada (no exemplo considerado, a série obtida foi a seguinte: 971538125313 ...).

Com alguma sorte na escolha do número N_0 com o qual se inicia o processo (número esse que recebe o nome de **semente**), o processo que acabou de ser descrito poderia conduzir a uma sequência de números que se assemelhassem a números equiprováveis e independentes.

Deve notar-se que uma característica especialmente útil dos números pseudo-aleatórios é a possibilidade de, ao contrário do que sucede nos números gerados de facto aleatoriamente, se poder repetir uma sequência, sempre que tal for útil ou necessário. Para isso, basta reter a semente do processo de geração pseudo-aleatória.

Na prática, os processos de geração utilizados são muito mais sofisticados do que aquele que foi descrito. O objectivo de tais métodos é o de garantir que, independentemente da semente escolhida,

- a sequência gerada não entre rapidamente em ciclo (no processo anteriormente descrito tal sucederia quando no passo (iii) se gerasse de novo o número 9218);
- ao longo de um ciclo, as proporções de zeros, uns, dois, etc., sejam aproximadamente iguais entre si;
- a ordem pela qual os sucessivos algarismos são gerados os faça parecer independentes (tal não sucederia, por exemplo, se, nas posições seguintes àquelas em que figuram quattros, a proporção de uns fosse maior do que a de setes).

Os métodos mais eficientes e, por isso, mais utilizados na geração de números pseudo-aleatórios são os **métodos congruenciais lineares**. No Apêndice 8.2 apresenta-se uma breve caracterização destes métodos.

8.6.3 GERAÇÃO DE AMOSTRAS ALÉATORIAS PROVENIENTES DE UMA POPULAÇÃO DISCRETA QUALQUER

Tal como se referiu na Secção 8.6.1, os números aleatórios seguindo uma distribuição qualquer obtêm-se por transformação dos números aleatórios $U(0, 1)$. O exemplo seguinte mostra qual o tipo de transformação requerida no caso da geração de amostras provenientes de populações discretas.

Exemplo 8.10


Admita-se que nos veículos ligeiros que circulam numa determinada rua entre as 8h 30 e as 9h 30 dos dias úteis, o número de passageiros por veículo (Y) segue a distribuição que se apresenta na Figura 8.2.

Pretende-se gerar, a partir desta distribuição, uma amostra aleatória com 10 observações.

Para o conseguir, basta gerar 10 números aleatórios $u_n \sim U(0, 1)$, cada um deles com duas casas decimais, transformando-os em números de passageiros, y_n , do seguinte modo:

- ♦ $y_n = 1$, se $0.00 \leq u_n \leq 0.27$
- ♦ $y_n = 2$, se $0.28 \leq u_n \leq 0.60$
- ♦ $y_n = 3$, se $0.61 \leq u_n \leq 0.81$
- ♦ $y_n = 4$, se $0.82 \leq u_n \leq 0.92$
- ♦ $y_n = 5$, se $0.93 \leq u_n \leq 0.97$
- ♦ $y_n = 6$, se $0.98 \leq u_n \leq 0.99$.

Figura 8.2
Função de probabilidade do número de passageiros (Exemplo 8.10).



Na essência, a transformação dos números aleatórios $u_n \sim U(0, 1)$ é efectuada dividindo o intervalo $[0, 1]$ em tantos intervalos quantos os valores que a variável discreta pode tomar, associando a cada valor desta um intervalo com uma amplitude proporcional à probabilidade com que tal valor pode ocorrer.

A propósito ainda desta transformação, valerá a pena fazer duas observações:

- Em vez de associar a cada valor da variável discreta um intervalo de amplitude Δ , poderiam ser-lhe associados vários intervalos, desde que a soma das suas amplitudes fosse igual a Δ . Normalmente associa-se a cada valor da variável discreta um intervalo único, apenas por ser mais simples.
- Em certas situações, pode haver vantagem em adaptar o procedimento descrito, recorrendo directamente às séries originais $\{m_n\}$ de números aleatórios $(0, 1, \dots, 9)$ equiprováveis e independentes, sem passar pelos números $u_n \sim U(0, 1)$. Admita-se, por exemplo, que uma variável discreta Z pode tomar os valores 1, 2 e 3 com probabilidades $3/9$, $5/9$ e $1/9$, respectivamente. Neste caso, a geração de uma amostra aleatória directamente a partir de $\{m_n\}$ poderia ser efectuada do seguinte modo:

- $z_n = 1$, se $m_n = 1, 2$ ou 3
- $z_n = 2$, se $m_n = 4, 5, 6, 7$ ou 8
- $z_n = 3$, se $m_n = 9$
- não gerar qualquer z_n , se $m_n = 0$.

8.6.4 GERAÇÃO DE AMOSTRAS ALEATÓRIAS PROVENIENTES DE UMA POPULAÇÃO CONTÍNUA QUALQUER

Comece-se por considerar uma variável contínua X , com função densidade de probabilidade $f(x)$ e função de distribuição invertível (ver Figura 8.3)


$$F(x) = \int_{-\infty}^x f(v) \cdot dv.$$

Defina-se, por transformação da variável X , uma nova variável,

$$Z = F(X),$$

onde F é a função de distribuição acima definida.

Figura 8.3
Função de distribuição de X e variável transformada $Z = F(X)$.



As funções distribuição, $G(z)$, e densidade, $g(z)$, da nova variável vêm dadas por:

$$G(z) = P(Z < z) = P[X < x = F^{-1}(z)] = F[F^{-1}(z)] = z \quad (\text{no domínio } z \in [0, 1])$$

e

$$g(z) = \frac{dG(z)}{dz} = 1 \quad (\text{no domínio } z \in [0, 1]).$$

Ora a forma destas funções implica que

$$Z \sim U(0, 1).$$

A conclusão a que se chegou é, portanto, a de que, se uma variável X segue uma distribuição com função densidade de probabilidade $f(x)$ e função de distribuição $F(x)$, então a variável transformada $Z = F(X)$ segue uma distribuição $U(0, 1)$.

Inversamente, se uma variável Z segue uma distribuição $U(0, 1)$, então a variável

$$X = F^{-1}(Z)$$

segue uma distribuição com função densidade de probabilidade $f(x)$ e função de distribuição $F(x)$. Este é o resultado no qual se fundamenta a geração de amostras aleatórias provenientes de populações contínuas com funções de distribuição invertíveis e cujo processo será ilustrado no exemplo seguinte.

Exemplo 8.11

Pretende-se gerar uma amostra aleatória de dimensão $N = 3$ a partir de uma população com uma distribuição Exponencial Negativa com parâmetro $\lambda = 0.5$.

A função densidade de probabilidade e a função de distribuição da variável X correspondente a esta população são:

$$f(x) = \begin{cases} 0, & \text{se } x < 0 \\ 0.5 \cdot e^{-0.5 \cdot x}, & \text{se } x \geq 0 \end{cases}$$

$$F(x) = \begin{cases} 0, & \text{se } x < 0 \\ 1 - e^{-0.5 \cdot x}, & \text{se } x \geq 0. \end{cases}$$

Começa por gerar-se uma amostra constituída por 3 observações de $Z \sim U(0, 1)$. Sejam, por exemplo,

$$z_1 = 0.832$$

$$z_2 = 0.325$$

$$z_3 = 0.266.$$

Estes valores são seguidamente transformados recorrendo à função inversa de $F(x)$:

$$z_n = 1 - e^{-0.5 \cdot x_n} = F(x_n) \Rightarrow e^{-0.5 \cdot x_n} = 1 - z_n$$

$$e^{0.5 \cdot x_n} = 1 / (1 - z_n)$$

$$0.5 \cdot x_n = \ln [1 / (1 - z_n)]$$

$$x_n = 2 \cdot \ln [1 / (1 - z_n)] = F^{-1}(z_n).$$

A transformação envolvida está representada na Figura 8.4.


A amostra que se pretendia obter vem então constituída pelas seguintes observações:

$$x_1 = 2 \cdot \ln [1 / (1 - 0.832)] = 2 \cdot \ln (5.952) = 3.568$$

$$x_2 = 2 \cdot \ln [1 / (1 - 0.325)] = 2 \cdot \ln (1.481) = 0.786$$

$$x_3 = 2 \cdot \ln [1 / (1 - 0.266)] = 2 \cdot \ln (1.362) = 0.618.$$

Figura 8.4
Transformação
 $x_n = F^{-1}(z_n)$.



No exemplo que acabou de ser apresentado, a função densidade de probabilidade era integrável analiticamente (e a função de distribuição era invertível). Consequentemente, foi possível definir analiticamente a inversa da função distribuição, $F^{-1}(z)$.



Quando a função densidade de probabilidade não for integrável analiticamente, a função de distribuição pode ser obtida, de forma aproximada, por integração numérica. Para a distribuição Normal, que está nestas condições, Box e Muller desenvolveram um método que permite gerar amostras aleatórias de uma forma exacta e com muito mais eficiência computacional do que os métodos numéricos baseados na inversão da função de distribuição. Dada a importância da distribuição Normal, inclui-se no Apêndice 8.3 uma descrição deste método.

A geração de amostras aleatórias provenientes de populações contínuas com funções de distribuição não-invertíveis pode ser resolvida de forma relativamente simples adaptando ligeiramente o procedimento anteriormente apresentado. Para o ilustrar, considere-se o exemplo seguinte.

Exemplo 8.12

Considere-se a geração de uma amostra aleatória a partir de uma população contínua à qual se associa uma variável aleatória X com a função de distribuição (não-invertível) que se apresenta na Figura 8.5.

Neste caso, poderia adoptar-se o procedimento anteriormente apresentado (para o caso de a função de distribuição ser invertível), excepto quando fosse gerado um número $Z_n \sim U(0, 1)$ igual a 0.3. Nesta situação, ignorar-se-ia tal valor e gerava-se um outro (que fosse diferente de 0.3) em sua substituição.

 Figura 8.5
Exemplo de uma
função distribuição
não-invertível.


APÊNDICE 8.1 VARIÂNCIA DA MÉDIA AMOSTRAL (POPULAÇÃO FINITA, AMOSTRAGEM SEM REPOSIÇÃO)

$$(1) \quad \bar{X} = \frac{1}{N} \cdot \sum_{n=1}^N X_n.$$

$$(2) \quad \text{Var}(\bar{X}) = \left(\frac{1}{N}\right)^2 \cdot \left[\sum_{n=1}^N \text{Var}(X_n) + 2 \cdot \sum_{n=1}^{N-1} \sum_{j=n+1}^N \text{Cov}(X_n, X_j) \right] \quad (\text{ver expressão 5.38})$$

$$= \left(\frac{1}{N}\right)^2 \cdot \left[N \cdot \sigma_X^2 + 2 \sum_{n=1}^{N-1} \sum_{j=n+1}^N \gamma_{X_n X_j} \right] \quad (\text{A8.1.1.})$$

(3) Para uma população constituída por M elementos $(x_1, x_2, \dots, x_M)$, o termo $\gamma_{X_n X_j}$ (no qual $n < j$) vem dado por

$$\gamma_{X_n X_j} = \sum_{k=1}^M \sum_{m=1}^M (x_k - \mu) \cdot (x_m - \mu) \cdot p(x_k, x_m) \quad (\text{A8.1.2})$$

onde

$$\mu = \frac{1}{M} \cdot \sum_{k=1}^M x_k$$

e

$$p(x_k, x_m) = \begin{cases} 1/M \cdot 1/(M-1), & \text{se } m \neq k \\ 0, & \text{se } m = k. \end{cases} \quad (\text{A8.1.3})$$

(4) Substituindo A8.1.3 em A8.1.2 e desenvolvendo, obtém-se

$$\begin{aligned} \sigma_{X_n X_j} &= \frac{1}{M} \cdot \frac{1}{M-1} \cdot \sum_{k=1}^M \sum_{m \neq k}^M (x_k - \mu) \cdot (x_m - \mu) \\ &= \frac{1}{M} \cdot \frac{1}{M-1} \cdot \sum_{k=1}^M (x_k - \mu) \cdot \sum_{m \neq k}^M (x_m - \mu) \\ &= \frac{1}{M} \cdot \frac{1}{M-1} \cdot \sum_{k=1}^M (x_k - \mu) \cdot \left[\sum_{m=1}^M (x_m - \mu) - (x_k - \mu) \right] \\ &= \frac{1}{M} \cdot \frac{1}{M-1} \cdot \sum_{k=1}^M (x_k - \mu) \cdot \{0 - (x_k - \mu)\} \\ &= -\frac{1}{M-1} \cdot \left[\frac{1}{M} \cdot \sum_{k=1}^M (x_k - \mu)^2 \right] \\ &= -\sigma_X^2 / (M-1). \end{aligned}$$

(5) Substituindo A8.1.4 em A8.1.1 e desenvolvendo, obtém-se

$$\text{Var}(\bar{X}) = \left(\frac{1}{N}\right)^2 \cdot \left[N \cdot \sigma_X^2 - 2 \cdot \frac{\sigma_X^2}{N-1} \cdot \sum_{n=1}^{N-1} \sum_{j=n+1}^N 1 \right] \quad (\text{A8.1.5})$$

(6) O duplo somatório que figura na expressão anterior vem

$$\begin{aligned} \sum_{n=1}^{N-1} \sum_{j=n+1}^N 1 &= \sum_{n=1}^{N-1} (N-n) \\ &= (N-1) + (N-2) + \dots + 1 \\ &= (N-1) \cdot \left[\frac{(N-1)+1}{2} \right] \\ &= (N-1) \cdot \frac{N}{2} \end{aligned} \quad (\text{A8.1.6})$$

(7) Substituindo A8.1.6 em A8.1.5 e desenvolvendo, obtém-se

$$\begin{aligned} \text{Var}(\bar{X}) &= \left(\frac{1}{N}\right)^2 \cdot \left[N \cdot \sigma_X^2 - 2 \cdot \frac{\sigma_X^2}{N-1} \cdot (N-1) \cdot \frac{N}{2} \right] \\ &= \frac{\sigma_X^2}{N} \cdot \left(1 - \frac{N-1}{N-1} \right) \\ &= \frac{\sigma_X^2}{N} \cdot \left(\frac{M-N}{M-1} \right) \end{aligned}$$

ou seja,

$$\sigma_{\bar{X}}^2 = \left(\frac{M-N}{M-1} \right) \cdot \frac{1}{N} \cdot \sigma_X^2 \quad (\text{expressão 8.8}).$$

■ APÊNDICE 8.2 MÉTODOS CONGRUENCIAIS LINEARES PARA GERAÇÃO DE NÚMEROS PSEUDO-ALEATÓRIOS

A grande maioria dos geradores de números pseudo-aleatórios recorre aos **métodos congruenciais lineares**. De acordo com estes métodos, começa-se por gerar uma sequência de números inteiros $\{N_i\}$ recorrendo à expressão recursiva

$$N_i = (a \cdot N_{i-1} + b) - \text{INT} \left[\frac{a \cdot N_{i-1} + b}{c} \right] \cdot c,$$

onde a função INT [argumento] representa o maior inteiro contido no argumento, a , b e c são constantes inteiras designadas respectivamente por **multiplicador**, **incremento** e **módulo** e N_0 representa a semente.

A expressão anterior pode ser interpretada do seguinte modo: cada número N_{i-1} sofre uma transformação linear (daí o facto de os métodos serem designados por lineares), e o número seguinte N_i corresponde ao resto da divisão do valor transformado $(a \cdot N_{i-1} + b)$ pela constante c . Uma forma sucinta de descrever a transformação global envolvida é dizer que N_i é «congruente com $(a \cdot N_{i-1} + b)$ módulo c » (daí o facto de os métodos serem designados por congruenciais). Em notação simbólica, escreve-se

$$N_i = (a \cdot N_{i-1} + b) \pmod{c}.$$

Nos métodos congruenciais lineares, é habitual estabelecer-se uma distinção entre os **métodos multiplicativos** (métodos lineares com $b = 0$, o que implica que a transformação linear acima referida se reduz a uma multiplicação) e os **métodos mistos** (métodos lineares com $b \neq 0$).

Em ambos os casos, dada a transformação envolvida, os números N_i estão necessariamente compreendidos entre 0 e $(c-1)$. Dividindo estes números por c (que geralmente é um número elevadíssimo, próximo do limite comportado pelo computador no qual o método for implementado), obtêm-se números u_i pertencentes ao intervalo $[0, 1]$. O processo de geração pode então ser resumido nos seguintes termos:

$$N_i = (a \cdot N_{i-1} + b) \pmod{c}.$$

$$u_i = N_i / c.$$

Para que os números gerados, u_i , se comportem como observações independentes de uma variável aleatória $U(0, 1)$, e para que o processo de geração seja eficiente do ponto de vista computacional, é necessário efectuar uma escolha criteriosa das constantes a , b e c . Esta escolha, que é dependente do computador no qual o método for implementado, está longe de ser trivial. Uma revisão das questões associadas à definição de a , b e c pode encontrar-se em Fishman (1978).

APÊNDICE 8.3 GERAÇÃO DE AMOSTRAS ALEATÓRIAS $N(0, 1)$ PELO MÉTODO DE BOX-MULLER

Sejam U_1 e U_2 duas variáveis independentes seguindo a distribuição $U(0, 1)$. Na base do método proposto por Box e Muller está o facto de que as variáveis transformadas definidas de acordo com as expressões

$$X_1 = \sqrt{-2 \cdot \ln U_1} \cdot \cos 2\pi U_2$$

$$X_2 = \sqrt{-2 \cdot \ln U_1} \cdot \sin 2\pi U_2$$


são independentes e seguem a distribuição $N(0, 1)$.

Assim, recorrendo às transformações apresentadas, é possível converter directamente pares de observações $U(0, 1)$ em pares de observações $N(0, 1)$ sem se recorrer à inversa da função de distribuição.

Se se pretender que as observações geradas sigam uma distribuição Normal qualquer, $N(\mu, \sigma^2)$, apenas haverá que modificar as transformações acima apresentadas para

$$\begin{aligned} X_1 &= \mu + \sigma \cdot \left(\sqrt{-2 \cdot \ln U_1} \cdot \cos 2\pi U_2 \right) \\ X_2 &= \mu + \sigma \cdot \left(\sqrt{-2 \cdot \ln U_1} \cdot \sin 2\pi U_2 \right) \end{aligned} \quad (X_1 \text{ e } X_2 \sim N(\mu, \sigma^2)).$$

Na aplicação da versão do método de Box-Muller que acabou de ser descrita, as observações das variáveis U_1 e U_2 , se forem geradas por um método congruencial linear, devem ser obtidas a partir de duas séries (ou, como também se diz, *correntes*) distintas de números aleatórios. A justificação desta recomendação, bem como a referência a outras versões deste método ou a outros métodos mais eficientes do ponto de vista computacional, pode encontrar-se em Law e Kelton (1991).



- 8.1. O número de computadores pessoais vendidos por semana numa loja segue a seguinte distribuição:

y	$p(y)$
0	0.10
1	0.15
2	0.45
3	0.30

Admita que as vendas registadas em quaisquer duas semanas consecutivas são independentes.

- (i) Calcule o valor esperado e o desvio padrão das vendas quinzenais.
 - (ii) Defina a função de probabilidade das vendas quinzenais e verifique, com base nela, os resultados obtidos na alínea anterior.
 - (iii) Gere duas amostras aleatórias de vendas semanais (cada uma de dimensão 500) e a partir delas construa uma amostra de vendas quinzenais; calcule a média, o erro padrão e o coeficiente de assimetria desta amostra de vendas quinzenais.
- 8.2. Uma empresa fabricante de brinquedos distribui os seus jogos por duas grandes lojas, uma situada no Porto e outra em Lisboa. O número de jogos vendidos por dia na loja do Porto segue uma distribuição $N(150, 25^2)$. Relativamente à loja de Lisboa, o número de jogos vendidos por dia segue uma distribuição $N(200, 30^2)$.
- (i) Qual a probabilidade de num determinado dia serem vendidos mais jogos na loja do Porto que na de Lisboa?
 - (ii) Qual a probabilidade de em 200 dias serem vendidos mais do que 69 000 jogos no conjunto das duas lojas?
- 8.3. Um elevador de acesso a um grupo de galerias de uma mina tem capacidade nominal de 3800 kg. Os mineiros que usam regularmente o elevador são 650 e têm pesos que seguem uma distribuição com valor esperado de 75 kg e desvio padrão de 8 kg. Calcule a probabilidade de ser excedida a capacidade nominal do elevador quando nele se encontrarem 50 mineiros.
- 8.4. Numa recente publicação da União Europeia incluíam-se estatísticas relativas aos salários dos engenheiros recém-formados a trabalhar em países da Comunidade Europeia. O valor esperado do salário horário na Alemanha era estimado em 15.4 euros. Para Portugal, a estatística correspondente era de 11.2 euros. O desvio padrão amostral dos salários horários nos dois países é de 3.0 euros.

Considere que foram seleccionados aleatoriamente 40 engenheiros recém-formados na Alemanha e 50 engenheiros recém-formados em Portugal, sendo-lhes perguntado o valor do seu salário horário.

- (i) Qual a probabilidade da média dos salários dos 40 engenheiros inquiridos na Alemanha estar entre 15 e 16 euros?
- (ii) Qual a probabilidade da diferença entre a média dos salários dos 40 engenheiros inquiridos na Alemanha e dos 50 engenheiros inquiridos em Portugal ser superior a 4.5 euros?

8.5. Os três lados de um determinado tipo de peças paralelepípedicas têm comprimentos que seguem distribuições Normais independentes com parâmetros idênticos: $\mu = 30$ cm e $\sigma^2 = 25$ cm².

- (i) Calcule o valor esperado e o desvio padrão do volume das peças em questão.
- (ii) Determine a probabilidade de o volume das peças exceder 35 litros.
- (iii) Repita os cálculos das alíneas anteriores, admitindo agora que os três lados de cada peça têm o mesmo comprimento, que segue uma distribuição $N(\mu = 30$ cm, $\sigma^2 = 25$ cm²).

8.6. A variável X segue uma distribuição Exponencial Negativa com valor esperado $\mu = 3$. Recorrendo à geração de números aleatórios, caracterize a distribuição desta variável, bem como a da média amostral calculada com base em amostras aleatórias de dimensão $N = 2, 5, 10$ e 15 .

8.7. A partir de duas amostras independentes de dimensão 500 de uma variável $U(0, 1)$, e recorrendo ao método de Box-Muller, gere duas amostras independentes de dimensão 500 de uma variável $N(0, 1)$. Caracterize tais amostras.

8.8. Admita que, em média, chegam 4 navios por hora a um determinado cais (pode admitir-se que as chegadas seguem uma distribuição de Poisson).

- (i) Gere três amostras aleatórias do número de navios que chegam ao cais num período de 3 horas.
- (ii) Supondo que não conhecia a distribuição populacional correspondente ao número de navios que chegam aos cais, estime, com base nas amostras geradas, o número médio de navios que chegam ao cais por hora.



9.1 INTRODUÇÃO. ESTIMADORES E ESTIMATIVAS

Quando, no Capítulo 2, se apresentou a Estatística Descritiva, o objectivo era fundamentalmente o de caracterizar conjuntos restritos de dados. Ao calcular, por exemplo, uma média amostral, pretendia-se apenas definir uma medida de localização dos dados com base nos quais ela era calculada.

No âmbito da Inferência Estatística, que se inicia neste capítulo, ganha-se uma nova dimensão. Ao calcular estatísticas, existe o objectivo adicional de caracterizar a população a partir da qual a amostra foi retirada, procurando designadamente estimar parâmetros desta população.

O problema básico envolvido na estimação pontual pode ser ilustrado recorrendo ao exemplo seguinte.

Exemplo 9.1

Admita-se que uma determinada variável segue uma distribuição Binomial $Y \sim B(N, p)$, cujos parâmetros N e p são desconhecidos.

Com base numa amostra aleatória simples qualquer, $\{Y_1, Y_2, \dots, Y_K\}$, pretende-se estimar o valor de cada um

- daqueles parâmetros, ou
- de outros parâmetros definidos em função daqueles — por exemplo, o valor esperado da distribuição, $\mu = N \cdot p$, ou a variância, $\sigma^2 = N \cdot p \cdot (1 - p)$.

Para o fazer, definem-se estatísticas cujos valores particulares constituam estimativas dos parâmetros em causa. Por exemplo, seria razoável estimar μ a partir da média amostral,

$$\bar{Y} = \frac{1}{K} \cdot \sum_{k=1}^K Y_k.$$

A estatística $\bar{Y}$ é um estimador (pontual) do parâmetro em causa (o valor esperado), e uma realização particular $\bar{y}$ desta estatística (obtida a partir de um conjunto particular de valores observados $\{y_1, y_2, \dots, y_K\}$) constitui uma estimativa daquele parâmetro.

Em termos gerais, designa-se por **estimador (pontual)** de um parâmetro θ uma estatística $\hat{\theta}$ cujos valores particulares $\hat{\theta}$ constituam **estimativas** do parâmetro em causa. Note-se que, de acordo com a convenção introduzida anteriormente, o estimador (que é uma variável) é denotado por uma letra maiúscula ($\hat{\theta}$) enquanto que uma estimativa (que é uma realização particular daquela variável) é representado pela letra minúscula correspondente ($\hat{\theta}$).

Nas secções seguintes começar-se-á por analisar um conjunto de características desejáveis dos estimadores pontuais e posteriormente apresentar-se-ão diferentes métodos de estimação (isto é, métodos com base nos quais tais estimadores podem ser obtidos).

9.2 PROPRIEDADES DESEJÁVEIS DOS ESTIMADORES PONTUAIS

9.2.1 NÃO-ENVIESAMENTO


Seja θ um parâmetro qualquer de uma população e denote-se por $\hat{\theta}$ um estimador desse parâmetro.

O **enviesamento** do estimador $\hat{\theta}$ define-se como a diferença entre o valor esperado do estimador, $E(\hat{\theta}) = \mu_{\hat{\theta}}$, e o valor do parâmetro, θ , isto é,

$$\text{Enviesamento}_{\hat{\theta}} = E(\hat{\theta}) - \theta = \mu_{\hat{\theta}} - \theta. \quad (9.1)$$

Um estimador diz-se **não-enviesado** quando o seu enviesamento for nulo, e **enviesado** no caso contrário. Na Figura 9.1 ilustram-se os conceitos de estimador não-enviesado ($\hat{\theta}_1$) e de estimador enviesado ($\hat{\theta}_2$).

(i) Estimador não-enviesado



(ii) Estimador enviesado




Figura 9.1
Estimadores não-enviesado ($\hat{\theta}_1$) e enviesado ($\hat{\theta}_2$) do parâmetro θ .

Exemplo 9.2

Admita-se que uma determinada população é caracterizada pela variável aleatória X e que as estatísticas que seguidamente se apresentam são calculadas com base em amostras aleatórias simples de dimensão N .

♦ Média amostral

Dado que, como se viu no capítulo anterior (na secção 8.4.1),

$$E(\bar{X}) = E(X) = \mu_X,$$

então a média amostral é um estimador não-enviesado do valor esperado, qualquer que seja a distribuição populacional.

♦ Desvio quadrático médio amostral

Esta estatística foi definida no Capítulo 2 (Secção 2.3.2.2, Estatísticas de Dispersão). Tal como se demonstra no Apêndice 9.1, o seu valor esperado é dado por

$$E(DQM) = \frac{N-1}{N} \cdot \sigma_X^2 = \sigma_X^2 - \frac{1}{N} \cdot \sigma_X^2 \neq \sigma_X^2.$$

Daqui se conclui que, qualquer que seja a distribuição populacional, o desvio quadrático médio amostral é um estimador enviesado da variância populacional, com

$$\text{Enviesamento}_{DQM} = -\frac{1}{N} \cdot \sigma_X^2.$$

♦ Variância amostral

Esta estatística foi igualmente definida no Capítulo 2 (Secção 2.3.2.2, Estatísticas de Dispersão) através da expressão

$$S^2 = \frac{1}{N-1} \cdot \sum_{n=1}^N (X_n - \bar{X})^2 = \frac{N}{N-1} \cdot DQM.$$

O seu valor esperado vem dado por

$$E(S^2) = E\left(\frac{N}{N-1} \cdot DQM\right) = \frac{N}{N-1} \cdot \frac{N-1}{N} \cdot \sigma_X^2 = \sigma_X^2.$$

Daqui se conclui que a variância amostral é um estimador não-enviesado da variância populacional, qualquer que seja a distribuição da população. É por esta razão que, quando se pretende fazer uma inferência acerca da variância de uma população, é preferível recorrer à variância amostral do que ao desvio quadrático médio amostral (este facto havia sido notado, sem justificação, no Capítulo 2, Secção 2.3.2.2, Estatísticas de Dispersão).

9.2.2 EFICIÊNCIA

Para introduzir o conceito de eficiência, começa-se por estabelecer uma comparação entre dois estimadores não-enviesados $\hat{\theta}_1$ e $\hat{\theta}_2$, em relação aos quais se admite que, para amostras da mesma dimensão, N , as suas variâncias são respectivamente $\sigma_{\hat{\theta}_1}^2$ e $\sigma_{\hat{\theta}_2}^2$, com $\sigma_{\hat{\theta}_1}^2 < \sigma_{\hat{\theta}_2}^2$ (ver Figura 9.2).

Neste caso, o estimador $\hat{\theta}_1$ é melhor, mais preciso ou, como habitualmente se diz, **mais eficiente** do que $\hat{\theta}_2$, pois a dispersão dos erros de estimação que podem ser cometidos é menor quando se recorre ao primeiro estimador.

Exemplo 9.3


Admita-se que se pretende estimar o valor esperado de uma população Normal com variância σ^2 . Neste caso, por se tratar de uma população simétrica, a mediana amostral é, tal como a média amostral, um estimador não-enviesado daquele parâmetro. Pode demonstrar-se que a variância da mediana amostral é

$$\sigma_{\text{Med}}^2 = \left(\frac{\pi}{2}\right) \cdot \left(\frac{\sigma^2}{N}\right)$$

onde N representa a dimensão da amostra aleatória a partir da qual se obtém aquele estimador.

Esta variância é então $\pi/2 \approx 1.57$ vezes maior do que a variância da média amostral. Tal é equivalente a afirmar que a mediana amostral só seria um estimador tão preciso como a média amostral se, no primeiro caso, se tomasse uma amostra com uma dimensão 57% maior do que no segundo. A mediana amostral é então um estimador do valor esperado menos eficiente do que a média amostral.


Figura 9.2
Comparação entre
estimadores
não-enviesados
de um parâmetro θ .



Generalize-se a comparação entre a eficiência de estimadores, admitindo agora que estes podem ser enviesados, como sucede com dois dos estimadores cujas funções densidade de probabilidade se representam na Figura 9.3.

Entre os três estimadores representados, aquele que tem menor variância ($\hat{\theta}_3$) parece estar longe de ser o melhor, dado o seu significativo enviesamento. O melhor também não parece ser o que apresenta enviesamento nulo ($\hat{\theta}_1$), pois tem uma variância muito elevada. Restará possivelmente $\hat{\theta}_2$ como o melhor compromisso.

Figura 9.3
Comparação entre
estimadores
enviesados e
não-enviesados de
um parâmetro θ .



Este exemplo sugere a adopção de um critério de eficiência que tome em conta não apenas a variância de cada estimador (que mede a sua dispersão em torno do seu valor

esperado) mas sim uma medida de dispersão do estimador em redor do parâmetro estimado. A eficiência de um estimador $\hat{\theta}$ (que reflecte a sua precisão potencial) pode ser medida através do erro quadrático médio, definido pela expressão seguinte:

$$\begin{aligned} E[(\hat{\theta} - \theta)^2] &= E\left\{\left[(\hat{\theta} - \mu_{\hat{\theta}}) - (\theta - \mu_{\hat{\theta}})\right]^2\right\} \\ &= E[(\hat{\theta} - \mu_{\hat{\theta}})^2] + (\theta - \mu_{\hat{\theta}})^2 - 2 \cdot (\theta - \mu_{\hat{\theta}}) \cdot \underbrace{E(\hat{\theta} - \mu_{\hat{\theta}})}_{=0} \end{aligned}$$

Dado que a primeira parcela do segundo membro representa a variância do estimador e que a segunda é igual ao quadrado do enviesamento (ver expressão 9.1), a eficiência do estimador $\hat{\theta}$ vem dada por

$$\text{Eficiência}_{\hat{\theta}} = E[(\hat{\theta} - \theta)^2] = \sigma_{\hat{\theta}}^2 + (\text{Enviesamento}_{\hat{\theta}})^2. \quad (9.2)$$

Para se comparar a eficiência entre diferentes estimadores recorre-se ao conceito de eficiência relativa. Para dois estimadores quaisquer $\hat{\theta}_1$ e $\hat{\theta}_2$ de um mesmo parâmetro θ , a eficiência do primeiro relativamente ao segundo é dada pela razão

$$\text{Eficiência relativa}_{\hat{\theta}_1/\hat{\theta}_2} = \frac{E[(\hat{\theta}_1 - \theta)^2]}{E[(\hat{\theta}_2 - \theta)^2]}. \quad (9.3)$$

Para um parâmetro qualquer, se existir algum estimador que seja mais eficiente do que qualquer outro, então aquele estimador diz-se eficiente (ou, se se preferir, absolutamente eficiente).

Exemplo 9.4

Pode demonstrar-se que, para o caso de populações Normais, a média amostral é o estimador eficiente (ou absolutamente eficiente) do valor esperado.

9.2.3 CONSISTÊNCIA

Seja $\hat{\theta}$ um estimador do parâmetro θ e N a dimensão da amostra com base na qual $\hat{\theta}$ é calculado. Este estimador diz-se consistente quando, para qualquer valor positivo δ , se verifica a condição seguinte:

$$\lim_{N \rightarrow \infty} \text{Probabilidade}\{|\hat{\theta} - \theta| < \delta\} = 1. \quad (9.4)$$

Esta condição — dita de convergência em probabilidade do estimador para o parâmetro — significa que, quando a dimensão da amostra tende para infinito, o estimador consistente se concentra sobre o seu alvo, isto é, toma o valor do parâmetro estimado.

Exemplo 9.5

Na Figura 9.4 representam-se as funções densidade de probabilidade de um estimador consistente, para diferentes dimensões da amostra com base na qual o estimador é calculado.


É fácil demonstrar que, se o enviesamento e a variância de um estimador tenderem para zero — e, portanto, tender para zero o valor esperado de $(\hat{\theta} - \theta)^2$ — quando a dimensão da amostra tender para infinito, então o estimador será consistente. Em notação simbólica, estas condições suficientes para a consistência de um estimador podem ser expressas nos termos seguintes:

$$\begin{aligned} \lim_{N \rightarrow \infty} (\mu_{\hat{\theta}} - \theta) &= 0 \\ \lim_{N \rightarrow \infty} \sigma_{\hat{\theta}}^2 &= 0. \end{aligned} \quad (9.5)$$

ou

$$\lim_{N \rightarrow \infty} E[(\hat{\theta} - \theta)^2] = 0. \quad (9.6)$$

Figura 9.4
Funções densidade
de probabilidade
de um estimador
consistente, para
diferentes dimen-
sões da amostra.



Exemplo 9.6

É imediato verificar que a média amostral é um estimador consistente do valor esperado, pois as condições 9.5 são satisfeitas:

- o enviesamento é nulo, para qualquer dimensão da amostra, e
- a variância, σ^2/N , tende para zero quando a dimensão da amostra tende para infinito.

Deve observar-se que as condições acima enunciadas não são necessárias para a consistência de um estimador. No exemplo seguinte mostra-se que assim sucede com a condição 9.6.

Exemplo 9.7


Considere-se o estimador $\hat{\theta}$ do parâmetro θ , cuja função de probabilidade toma os seguintes valores não-nulos (ver Figura 9.5):

$$p(\hat{\theta}) = \begin{cases} 1 - 1/N, & \text{para } \hat{\theta} = \theta \\ 1/N, & \text{para } \hat{\theta} = N. \end{cases}$$

O estimador é consistente, pois

$$\lim_{N \rightarrow \infty} \text{Probabilidade}(|\hat{\theta} - \theta| < \delta) = \lim_{N \rightarrow \infty} (1 - 1/N) = 1.$$

Figura 9.5
Função de
probabilidade
do estimador $\hat{\theta}$



No entanto, a condição suficiente 9.6 não é satisfeita, pois

$$E[(\hat{\theta} - \theta)^2] = 0^2 \cdot (1 - 1/N) + (N - \theta)^2 \cdot (1/N) = N - 2 \cdot \theta + \theta^2 / N$$

e, portanto,

$$\lim_{N \rightarrow \infty} E[(\hat{\theta} - \theta)^2] = \infty.$$

9.2.4 OUTRAS CARACTERÍSTICAS DESEJÁVEIS

Para além do não-enviesamento, da eficiência e da consistência, existem outras características desejáveis dos estimadores, que podem ser úteis na sua selecção. Duas delas, embora não sendo aqui analisadas com o detalhe das anteriores, merecem ser referidas.

No âmbito da estimação pontual, a **suficiência** de uma estatística traduz a capacidade que ela tem de condensar toda a informação que, relativamente ao parâmetro estimado, esteja contida no conjunto das observações que integram a amostra. Por outras palavras, uma amostra (constituída por N observações) não contém mais informação relativamente ao parâmetro estimado do que um estimador suficiente calculado a partir dela.

O não-enviesamento e a eficiência de certos estimadores dependem criticamente da validade de certas hipóteses formuladas sobre a forma das distribuições populacionais. Existem, no entanto, estimadores caracterizados por uma considerável **robustez**, propriedade que se traduz pelo facto de tais estimadores se manterem aproximadamente não-enviesados e eficientes para uma vasta gama potencial de distribuições populacionais.

9.3 MÉTODOS DE ESTIMAÇÃO

Definidas algumas das propriedades desejáveis dos estimadores, a questão que se coloca seguidamente é a de saber como os definir. Não existe um método geral único que permita especificar estimadores ideais em todas as circunstâncias. Nas secções seguintes serão analisados quatro métodos alternativos de estimação pontual:

- Método dos Momentos;
- Método de Máxima Verosimilhança;
- Método de Estimação Linear com Variância Mínima;
- Método dos Mínimos Quadrados.

9.3.1 MÉTODO DOS MOMENTOS

Considere-se uma população representada pela variável aleatória Z cuja distribuição é conhecida a menos de R parâmetros, $\theta_1, \theta_2, \dots, \theta_R$. Em geral, os momentos populacionais ordinários (ver Capítulo 4, Secção 4.5, Outros Parâmetros) serão funções conhecidas dos parâmetros a estimar, facto que se pode expressar da forma seguinte:

$$\mu'_i = \mu'_i(\theta_1, \theta_2, \dots, \theta_R).$$

Seja $\{Z_1, Z_2, \dots, Z_N\}$ uma amostra aleatória simples obtida a partir daquela população e denotem-se os momentos amostrais ordinários com base naquela amostra por

$$M'_i = \frac{1}{N} \sum_{n=1}^N (Z_n)^i.$$

Ao denotar os momentos amostrais com letra maiúscula (o que não tinha sucedido no Capítulo de Estatística Descritiva, Secção 2.3.2.2, Outras Estatísticas) pretende-se realçar que tais momentos são agora encarados como variáveis aleatórias (cujos valores particulares são denotados por m'_i).

De acordo com o **método dos momentos**, os estimadores $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_R$ dos parâmetros $\theta_1, \theta_2, \dots, \theta_R$ são obtidos igualando os momentos populacionais aos momentos amostrais, isto é, fazendo

$$M'_i = \mu'_i(\theta_1, \theta_2, \dots, \theta_R) \quad (\text{para } i = 1, 2, \dots, R) \quad (9.7)$$

e resolvendo este sistema de equações em relação a $\theta_1, \theta_2, \dots, \theta_R$. Tais estimadores podem ser designados abreviadamente por **estimadores Mom**.

Exemplo 9.8

- A partir de uma amostra aleatória $\{Y_1, Y_2, \dots, Y_N\}$ proveniente de uma população com distribuição de Poisson, pretende definir-se um estimador Mom para o parâmetro λ . De acordo com o método dos momentos, o estimador é obtido através da equação

$$M'_1 = \bar{Y} = \mu'_1(\lambda) = E(Y|\lambda) = \lambda,$$

ou seja,

$$\hat{\Lambda} = \bar{Y} \quad (\text{note-se que } \Lambda \text{ é a maiúscula de } \lambda).$$

- A partir de uma amostra aleatória $\{X_1, X_2, \dots, X_N\}$ proveniente de uma população Normal, pretendem definir-se estimadores para os parâmetros μ e σ^2 . Tais estimadores serão denotados por $\hat{M}$ e $\hat{\Sigma}^2$ (note-se que M e Σ são as maiúsculas de μ e σ).

De acordo com o método dos momentos, os estimadores são obtidos resolvendo o sistema constituído pelas equações

$$M'_1 = \bar{X} = \mu'_1(\mu, \sigma) = E(X) = \mu$$

$$M'_2 = \frac{1}{N} \cdot \sum_{n=1}^N X_n^2 = \mu'_2(\mu, \sigma) = \sigma^2 + \mu^2 \quad (\text{ver expressão 4.28}),$$

donde,

$$\hat{M} = \bar{X}$$

$$\hat{\Sigma}^2 = M'_2 - \bar{X}^2 = (1/N) \cdot \sum_{n=1}^N X_n^2 - \bar{X}^2 = \sum_{n=1}^N (X_n - \bar{X})^2 / N = DQM.$$

Em relação ao método que acabou de ser apresentado, deve notar-se que ele admite algumas variantes, sendo todas elas incluídas sob a designação genérica de «método dos momentos»:

- Em vez de definir o sistema de equações 9.7 com base nos momentos ordinários, pode recorrer-se aos momentos centrados;
- Em vez de definir o sistema de equações 9.7 com base nos primeiros R momentos (ordinários ou centrados), pode recorrer-se a momentos de outra ordem.

Exemplo 9.9

Considere-se uma amostra aleatória $\{X_1, X_2, \dots, X_N\}$ de uma variável contínua X com função densidade de probabilidade dada por

$$f(x) = \frac{1}{2\beta} e^{-|x|/\beta} \quad (\text{com } \beta > 0).$$

Pode mostrar-se que esta variável tem sempre valor esperado nulo, qualquer que seja o valor do parâmetro β .

Nesta situação, este parâmetro não pode ser estimado a partir da equação

$$M'_1 = \bar{X} = \mu'_1,$$

pois $\mu'_1 = 0$ não é função de β .

Neste caso, o parâmetro pode ser estimado a partir de

$$M'_2 = \frac{1}{n} \cdot \sum_{n=1}^N X_n^2 = \mu'_2 = 2 \cdot \beta^2,$$

obtendo-se

$$\hat{B} = \sqrt{\frac{1}{2N} \cdot \sum_{n=1}^N X_n^2} \quad (\text{note-se que } B \text{ é a maiúscula de } \beta).$$

- Se, em vez de se pretenderem estimar directamente os parâmetros $\theta_1, \theta_2, \dots, \theta_R$, se pretenderem obter estimadores Mom de outros parâmetros transformados a partir destes, por exemplo,

$$\tau_1(\theta_1, \theta_2, \dots, \theta_R), \dots, \tau_R(\theta_1, \theta_2, \dots, \theta_R),$$

tais estimadores podem ser obtidos de diferentes modos. Um deles consiste em obter estimadores dos parâmetros $\theta_1, \theta_2, \dots, \theta_R$, recorrendo ao sistema de equações 9.7, e seguidamente utilizar

$$\tau_1(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_R), \dots, \tau_R(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_R)$$

como estimadores dos parâmetros $\tau_1, \dots, \tau_R$. Alternativamente, estes estimadores poderiam ser obtidos resolvendo o sistema constituído pelas seguintes equações:

$$M'_i = \mu'_i(\tau_1, \tau_2, \dots, \tau_R) \quad (\text{para } i = 1, 2, \dots, R).$$

Observa-se que estas duas variantes do método podem não conduzir aos mesmos estimadores.

Uma característica favorável dos estimadores obtidos segundo o método dos momentos é a sua relativa simplicidade de cálculo. Pode ainda demonstrar-se que, sob condições bastante gerais,

- os estimadores Mom são consistentes e que
- a sua distribuição tende para uma distribuição Normal, quando as dimensões das amostras com base nas quais forem obtidos tenderem para infinito (outra forma de expressar esta propriedade é dizer que os estimadores são assintoticamente Normais).

No entanto, os estimadores obtidos segundo o método dos momentos não são assintoticamente eficientes (para amostras de grandes dimensões são, em geral, menos eficientes do que os estimadores obtidos pelo método de máxima verosimilhança, que será analisado na próxima secção).

9.3.2 MÉTODO DE MÁXIMA VEROSIMILHANÇA


A ideia-base do método pode ser ilustrada recorrendo ao seguinte exemplo.

Exemplo 9.10

Admita-se que, a partir de uma amostra obtida aleatoriamente com base numa população Normal, se pretendem estimar os parâmetros desta população.

Na Figura 9.6 representam-se as observações que constituem a amostra (no eixo horizontal inferior) e três funções densidade de probabilidade Normais, com valores esperados e variâncias distintos.

Figura 9.6
Ideia-base do
método de máxima
verossimilhança.



Dado que as caudas das distribuições normais se estendem indefinidamente, a amostra em causa poderia provir de qualquer uma das distribuições representadas. No entanto, será muito mais verossímil que tenha sido obtida a partir da distribuição $N(\mu_1, \sigma_1^2)$ do que das duas restantes. De facto, a amostra está claramente descentrada em relação à distribuição $N(\mu_2, \sigma_2^2)$ e tem uma dispersão muito superior à da distribuição $N(\mu_3, \sigma_3^2)$. Dos três pares de parâmetros, o primeiro parece ser o mais adequado para representar a população da qual a amostra foi obtida.

A ideia-base do método de máxima verossimilhança consiste em seleccionar, entre todos os valores possíveis dos parâmetros populacionais, aqueles que tornem mais verossímil a ocorrência de uma amostra idêntica àquela que efectivamente se obteve.

Apresentada a ideia-base do **método de máxima verossimilhança**, este pode ser formalizado, começando por considerar o caso de distribuições populacionais discretas.

Considere-se uma população discreta representada pela variável aleatória Y cuja função de probabilidade $p(y)$ é conhecida a menos de R parâmetros, $\theta_1, \theta_2, \dots, \theta_R$ e denote-se por $\{y_1, y_2, \dots, y_N\}$ uma amostra aleatória simples obtida a partir daquela população.

A probabilidade de ocorrência de uma amostra aleatória simples idêntica àquela que efectivamente se obteve a partir da população é dada por

$$L = \text{Probabilidade}(Y_1 = y_1, \dots, Y_N = y_N | \theta_1, \theta_2, \dots, \theta_R) \\ = \prod_{n=1}^N \text{Probabilidade}(Y_n = y_n | \theta_1, \theta_2, \dots, \theta_R) \quad (\text{distribuições discretas}). \quad (9.8)$$

Esta probabilidade, que é função dos parâmetros $\theta_1, \theta_2, \dots, \theta_R$, designa-se por **função de verossimilhança**. Note-se que, quanto maior for o valor da função, mais verossímil se tornará a ocorrência de uma amostra idêntica a $\{y_1, y_2, \dots, y_N\}$.

As **estimativas de máxima verossimilhança (ou estimativas MV)** dos parâmetros $\theta_1, \theta_2, \dots, \theta_R$ são os valores destes parâmetros que maximizam a função de verossimilhança. Por outras palavras, as estimativas MV são os valores dos parâmetros que tornam máxima a probabilidade de ocorrência de uma amostra idêntica àquela que efectivamente ocorreu. Em notação simbólica, as estimativas MV são obtidas através de

$$\text{Max}_{\theta_1, \theta_2, \dots, \theta_R} L(\theta_1, \theta_2, \dots, \theta_R) = \prod_{n=1}^N \text{Probabilidade}(Y_n = y_n | \theta_1, \theta_2, \dots, \theta_R). \quad (9.9)$$

Admitindo que a função de verossimilhança é diferenciável, as estimativas MV podem ser obtidas resolvendo o sistema de equações definido por

$$\frac{\partial L}{\partial \theta_i} = 0 \quad (i = 1, \dots, R). \quad (9.10)$$

Normalmente, as soluções assim obtidas (que correspondem a pontos estacionários das funções de verossimilhança) são máximos destas funções.

Exemplo 9.11

Admita-se que o número de clientes que visitam, em cada dia útil, um determinado antiquário segue uma distribuição de Poisson com parâmetro desconhecido, λ .

Sabendo que, nos dois últimos dias, o antiquário foi visitado por 1 e 5 clientes, pretende-se, com base nesta informação, obter uma estimativa MV do parâmetro λ .

A função de verossimilhança da amostra $\{y_1 = 1, y_2 = 5\}$ é dada por

$$L(\lambda) = \text{Probabilidade}[(Y_1 = 1, Y_2 = 5 | \lambda)] = \left(e^{-\lambda} \cdot \frac{\lambda^1}{1!}\right) \cdot \left(e^{-\lambda} \cdot \frac{\lambda^5}{5!}\right) = e^{-2\lambda} \cdot \frac{\lambda^6}{5!}.$$

A estimativa MV de λ pode obter-se a partir de

$$\frac{dL(\lambda)}{d\lambda} = 0,$$

ou seja,

$$(-2) \cdot e^{-2\lambda} \cdot \frac{\lambda^6}{5!} + e^{-2\lambda} \cdot \frac{6 \cdot \lambda^5}{5!} = \frac{e^{-2\lambda} \cdot \lambda^5}{5!} \cdot (-2 \cdot \lambda + 6) = 0,$$

donde

$$\lambda = 3.$$

Atendendo a que

$$\left. \frac{d^2 L(\lambda)}{d\lambda^2} \right|_{\lambda=3} < 0,$$

então o ponto estacionário da função de verossimilhança é um máximo e

$$\hat{\lambda} = 3$$

é a estimativa MV do parâmetro da distribuição de Poisson.

As estimativas MV, que se obtêm a partir de amostras concretas, correspondem a valores particulares dos correspondentes **estimadores de máxima verossimilhança (estimadores MV)**. Para obter tais estimadores, apenas há que aplicar o método a amostras definidas genericamente como um conjunto de réplicas independentes de uma mesma variável aleatória.

Exemplo 9.12

Para uma situação idêntica à que foi considerada no exemplo anterior, pretende definir-se o estimador MV de λ obtido a partir de amostras $\{Y_1, Y_2, \dots, Y_N\}$.

A função de verosimilhança de uma amostra $\{Y_1, \dots, Y_N\}$ é dada por

$$L(\lambda) = \prod_{n=1}^N \left(e^{-\lambda} \cdot \frac{\lambda^{Y_n}}{Y_n!} \right) = e^{-N \cdot \lambda} \cdot \prod_{n=1}^N \left(\frac{\lambda^{Y_n}}{Y_n!} \right) = e^{-N \cdot \lambda} \cdot \lambda^{\left(\sum_{n=1}^N Y_n \right)} \cdot \frac{1}{\prod_{n=1}^N Y_n!}.$$

Impondo

$$\frac{dL(\lambda)}{d\lambda} = 0,$$

vem

$$(-N) \cdot e^{-N \cdot \lambda} \cdot \lambda^{\left(\sum_{n=1}^N Y_n \right)} \cdot \frac{1}{\prod_{n=1}^N Y_n!} + e^{-N \cdot \lambda} \cdot \sum_{n=1}^N Y_n \cdot \lambda^{\left(\sum_{n=1}^N Y_n - 1 \right)} \cdot \frac{1}{\prod_{n=1}^N Y_n!} = 0$$

ou

$$\left(-N \cdot \lambda + \sum_{n=1}^N Y_n \right) \cdot e^{-N \cdot \lambda} \cdot \lambda^{\left(\sum_{n=1}^N Y_n - 1 \right)} \cdot \frac{1}{\prod_{n=1}^N Y_n!} = 0$$

ou ainda

$$-N \cdot \lambda + \sum_{n=1}^N Y_n = 0.$$

Esta expressão é satisfeita para

$$\lambda = \frac{1}{N} \cdot \sum_{n=1}^N Y_n = \bar{Y},$$

sendo fácil verificar que a função de verosimilhança atinge um máximo para este valor de λ .
O estimador MV do parâmetro λ (denotado pela letra maiúscula correspondente) será então

$$\hat{\lambda} = \bar{Y}.$$

Registe-se que este estimador MV é idêntico ao que se obteria pelo método dos momentos:

$$M'_1 = \bar{Y} = \mu'_1 = E(Y) = \lambda,$$

donde

$$\hat{\lambda} = \bar{Y}.$$

Na prática, em vez de se recorrer directamente à função de verosimilhança $L(\theta_1, \theta_2, \dots, \theta_k)$, maximiza-se a transformada logarítmica desta função, $\ln[L(\theta_1, \theta_2, \dots, \theta_k)]$. Dado que as funções L e $\ln(L)$ têm pontos estacionários comuns, este procedimento conduz aos mesmos resultados. A sua vantagem deriva da simplificação considerável dos cálculos que ele permite atingir (uma vez que, como resultado da transformação logarítmica, o produto que surge na função de verosimilhança se converte num somatório).

Exemplo 9.13

Aplicando este procedimento à obtenção do estimador MV de λ para a situação considerada no exemplo anterior, obtém-se:

$$\begin{aligned} \ln[L(\lambda)] &= \ln \left[\prod_{n=1}^N \left(e^{-\lambda} \cdot \frac{\lambda^{Y_n}}{Y_n!} \right) \right] \\ &= \sum_{n=1}^N \ln \left(e^{-\lambda} \cdot \frac{\lambda^{Y_n}}{Y_n!} \right) \\ &= \sum_{n=1}^N [-\lambda + Y_n \cdot \ln(\lambda) - \ln(Y_n!)] \\ &= -N \cdot \lambda + \ln(\lambda) \cdot \sum_{n=1}^N Y_n - \sum_{n=1}^N \ln(Y_n!). \end{aligned}$$

Anulando a derivada desta função em ordem a λ , obtém-se

$$\frac{d \ln[L(\lambda)]}{d\lambda} = -N + \frac{1}{\lambda} \cdot \sum_{n=1}^N Y_n = 0,$$

resultando

$$\hat{\lambda} = \frac{1}{N} \cdot \sum_{n=1}^N Y_n = \bar{Y}.$$

Na estimação de parâmetros de distribuições contínuas, não faz sentido tentar maximizar a probabilidade de ocorrência de uma amostra idêntica àquela que efectivamente ocorreu, pois tal probabilidade é sempre nula. Nesta situação, procura maximizar-se a densidade de probabilidade definida para os valores observados da variável, actuando sobre os valores dos parâmetros. Por outras palavras, procura maximizar-se a função de verosimilhança que, para uma variável contínua X , com uma distribuição conhecida a menos de R parâmetros, $\theta_1, \theta_2, \dots, \theta_R$, e para uma amostra $\{x_1, \dots, x_N\}$ é definida por

$$\begin{aligned} L(\theta_1, \theta_2, \dots, \theta_R) &= f_{x_1, \dots, x_N | \theta_1, \theta_2, \dots, \theta_R}(x_1, \dots, x_N) \\ &= \prod_{n=1}^N f(x_n | \theta_1, \theta_2, \dots, \theta_R) \quad (\text{distribuições contínuas}). \quad (9.11) \end{aligned}$$

Exemplo 9.14

Para uma variável Normal, X , pretendem definir-se os estimadores MV do valor esperado, μ , e da variância, σ^2 , calculados a partir de uma amostra de dimensão N .

A função de verosimilhança vem, neste caso, dada por

$$L(\mu, \sigma^2) = \prod_{n=1}^N \left[\frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot e^{-\frac{1}{2} (x_n - \mu)^2 / \sigma^2} \right] = \frac{1}{(2\pi)^{N/2} \cdot \sigma^N} \cdot e^{-\frac{1}{2} \sum_{n=1}^N (x_n - \mu)^2 / \sigma^2}$$

e o seu logaritmo vem

$$\ln [L(\mu, \sigma^2)] = C - \frac{1}{2} \cdot N \cdot \ln(\sigma^2) - \frac{1}{2} \cdot \sum_{n=1}^N (X_n - \mu)^2 / \sigma^2,$$

onde C representa um termo constante em relação a μ e a σ^2 .

Anulando as derivadas parciais em ordem a μ e σ^2 , obtém-se

$$\frac{\partial \ln [L(\mu, \sigma^2)]}{\partial \mu} = \sum_{n=1}^N (X_n - \mu) / \sigma^2 = 0$$

$$\Rightarrow \sum_{n=1}^N (X_n - \mu) = 0$$

$$\Rightarrow \sum_{n=1}^N X_n - N \cdot \mu = 0$$

$$\Rightarrow \hat{M} = \frac{1}{N} \sum_{n=1}^N X_n = \bar{X} \quad (\text{relembre-se que } M \text{ é a maiúscula de } \mu)$$

e

$$\frac{\partial \ln [L(\mu, \sigma^2)]}{\partial \sigma^2} = -\frac{N}{2 \cdot \sigma^2} + \frac{\sum_{n=1}^N (X_n - \mu)^2}{2 \cdot \sigma^4} = 0$$

$$\Rightarrow -N \cdot \sigma^2 + \sum_{n=1}^N (X_n - \mu)^2 = 0$$

$$\Rightarrow \hat{\Sigma}^2 = \frac{1}{n} \cdot \sum_{n=1}^N (X_n - \mu)^2 = DQM \quad (\text{relembre-se que } \Sigma \text{ é a maiúscula de } \sigma).$$

Em termos gerais, os estimadores MV têm propriedades que os colocam entre os mais adequados. Salientam-se, em particular as seguintes:

- em geral, são consistentes;
- embora nem sempre sejam não-enviesados e eficientes, tendem a possuir estas propriedades à medida que as dimensões das amostras crescem (veja-se, por exemplo, o caso do estimador da variância no exemplo 9.14); e
- frequentemente, as suas distribuições são assintoticamente Normais.

9.3.3 MÉTODO DE ESTIMAÇÃO LINEAR COM VARIÂNCIA MÍNIMA

Para que o método de máxima verosimilhança possa ser aplicado, há que especificar *a priori* o tipo de distribuição populacional que está em causa. No método de **estimação linear com variância mínima** tal especificação é desnecessária.

Na sua essência, este método consiste em combinar linearmente um conjunto de estimadores não-enviesados, independentes e com variância conhecida, por forma a obter um outro estimador não-enviesado com variância tão pequena quanto possível. O procedimento adoptado pode ser ilustrado considerando inicialmente a combinação linear de apenas dois estimadores.

Relativamente a um parâmetro θ , sejam $\hat{\Theta}_1$ e $\hat{\Theta}_2$ dois estimadores não-enviesados, independentes e com variâncias conhecidas σ_1^2 e σ_2^2 .

Considere-se um novo estimador $\hat{\Theta}$ obtido combinando linearmente $\hat{\Theta}_1$ e $\hat{\Theta}_2$:

$$\hat{\Theta} = k_1 \cdot \hat{\Theta}_1 + k_2 \cdot \hat{\Theta}_2.$$

Para que o estimador $\hat{\Theta}$ seja não-enviesado, é necessário que o seu valor esperado, dado por

$$E(\Theta) = k_1 \cdot E(\Theta_1) + k_2 \cdot E(\Theta_2) = k_1 \cdot \theta + k_2 \cdot \theta = (k_1 + k_2) \cdot \theta,$$

(como decorre de $\hat{\Theta}_1$ e $\hat{\Theta}_2$ serem não-enviesados)

coincida com o valor do parâmetro estimado:

$$E(\Theta) = (k_1 + k_2) \cdot \theta = \theta.$$

Daqui resulta a seguinte condição sobre os coeficientes k_1 e k_2 :

$$k_1 + k_2 = 1. \quad (9.12)$$

Dado que se admitiu que $\hat{\Theta}_1$ e $\hat{\Theta}_2$ são independentes, a variância de $\hat{\Theta}$ vem

$$\text{Var}(\Theta) = k_1^2 \cdot \text{Var}(\Theta_1) + k_2^2 \cdot \text{Var}(\Theta_2) = k_1^2 \cdot \sigma_1^2 + k_2^2 \cdot \sigma_2^2.$$

Substituindo nesta expressão k_2 por $1 - k_1$ (como decorre de 9.12), obtém-se

$$\text{Var}(\Theta) = k_1^2 \cdot \sigma_1^2 + (1 - k_1)^2 \cdot \sigma_2^2.$$

A variância mínima de $\hat{\Theta}$ obtém-se para um valor de k_1 que satisfaça a condição

$$\frac{d \text{Var}(\hat{\Theta})}{d k_1} = 2 \cdot k_1 \cdot \sigma_1^2 - 2 \cdot (1 - k_1) \cdot \sigma_2^2 = 0. \quad (9.13)$$

Embora esta condição seja apenas de estacionaridade, seria imediato verificar que ela conduz, de facto, a um mínimo da variância do estimador.

Das condições 9.12 e 9.13 podem obter-se os valores de k_1 e de k_2 que minimizam a variância do estimador $\hat{\Theta}$:

$$k_1 = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} = \frac{1/\sigma_1^2}{1/\sigma_1^2 + 1/\sigma_2^2} \quad k_2 = 1 - k_1 = \frac{1/\sigma_2^2}{1/\sigma_1^2 + 1/\sigma_2^2}.$$

O **estimador linear não-enviesado com variância mínima** (ou, mais sucintamente, o **estimador LVM**) vem então dado por

$$\hat{\Theta} = \frac{(1/\sigma_1^2) \cdot \hat{\Theta}_1 + (1/\sigma_2^2) \cdot \hat{\Theta}_2}{1/\sigma_1^2 + 1/\sigma_2^2}.$$

De acordo com esta expressão, o estimador LVM obtém-se calculando uma média pesada dos estimadores originais, com pesos inversamente proporcionais às suas variâncias.

No caso geral, em que estejam envolvidos N estimadores originais, $\hat{\Theta}_1, \dots, \hat{\Theta}_N$, o estimador LVM obtém-se através da expressão

$$\hat{\Theta} = \sum_{n=1}^N k_n \cdot \hat{\Theta}_n \quad \text{com} \quad k_n = \frac{1/\sigma_n^2}{\sum_{i=1}^N 1/\sigma_i^2}. \quad (9.14)$$

- ◆ Considere-se uma amostra aleatória simples constituída pelas observações $\{X_1, X_2, \dots, X_N\}$ obtidas a partir de uma população qualquer. Cada uma das observações constitui, em si, um estimador não-enviesado do valor esperado da população, μ . O estimador LVM de μ obtido a partir daquelas observações vem:

$$\hat{M} = \sum_{n=1}^N k_n \cdot X_n \quad \text{com} \quad k_n = \frac{1/\sigma^2}{\sum_{i=1}^N 1/\sigma^2} = \frac{1/\sigma^2}{N/\sigma^2} = \frac{1}{N},$$

donde

$$\hat{M} = \frac{1}{N} \cdot \sum_{n=1}^N X_n = \bar{X}.$$

- ◆ Sejam $S_1^2, S_2^2, \dots, S_R^2$ estimadores não-enviesados e independentes da variância de uma população Normal. Admita-se que aqueles estimadores são variâncias amostrais calculadas a partir de R amostras aleatórias simples (de dimensões $N_1, N_2, \dots, N_R$, respectivamente).

Pretende definir-se o estimador LVM, S^2 , obtido a partir dos R estimadores originais. Designando por V_r a variância de cada estimador S_r^2 , o estimador S^2 vem

$$S^2 = \frac{\sum_{r=1}^R (S_r^2 / V_r)}{\sum_{r=1}^R (1 / V_r)}.$$

Ora, pode-se mostrar que a variância, V_r , é dada pela expressão

$$V_r = \frac{\mu_4 - 3\mu_2^2}{N_r} + \frac{2\mu_2}{N_r - 1}$$

onde μ_4 e μ_2 representam, respectivamente, os momentos populacionais centrados de 4.ª e de 2.ª ordem. Dado que

$$\mu_4 = 3 \cdot \mu_2^2,$$

a expressão de V_r vem

$$V_r = \frac{2\mu_2}{N_r - 1}.$$

Substituindo esta expressão na do estimador S^2 , obtém-se

$$S^2 = \frac{\sum_{r=1}^R \left[\frac{S_r^2 \cdot (N_r - 1)}{2 \cdot \mu_2} \right]}{\sum_{r=1}^R \left[\frac{N_r - 1}{2 \cdot \mu_2} \right]} = \frac{\sum_{r=1}^R (N_r - 1) \cdot S_r^2}{\sum_{r=1}^R (N_r - 1)}. \quad (9.15)$$

Para interpretar este resultado, atente-se na definição de cada um dos estimadores originais, S_r^2 :

$$S_r^2 = \frac{1}{N_r - 1} \cdot \sum_{n=1}^{N_r} (X_{rn} - \bar{X}_r)^2$$

Substituindo esta expressão em 9.15, obtém-se

$$S^2 = \frac{\sum_{r=1}^R \sum_{n=1}^{N_r} (X_{rn} - \bar{X}_r)^2}{\sum_{r=1}^R (N_r - 1)} = \frac{\sum_{r=1}^R \sum_{n=1}^{N_r} (X_{rn} - \bar{X}_r)^2}{\sum_{r=1}^R N_r - R}.$$

O estimador LVM resulta então de dividir a soma dos desvios quadráticos relativos a todas as amostras pela diferença entre o número total de observações contidas no conjunto das amostras e o número de amostras.

9.3.4 MÉTODO DOS MÍNIMOS QUADRADOS

Considere-se uma situação na qual diferentes réplicas de uma variável X se podem exprimir sob a forma

$$X_n = f_n(\theta_1, \dots, \theta_R) + E_n \quad (9.16)$$

onde $f_n(\theta_1, \dots, \theta_R)$ ($n = 1, \dots, N$) representam funções conhecidas de R parâmetros $\theta_1, \dots, \theta_R$ e E_n ($n = 1, \dots, N$) representam réplicas independentes de uma variável aleatória E (habitualmente designada por erro) com valor esperado nulo ($\mu_E = 0$) e variância σ_E^2 .

Admita-se que se dispõe de um conjunto de N ($N > R$) observações de X , $\{X_1, \dots, X_N\}$. Os estimadores dos parâmetros $\theta_1, \theta_2, \dots, \theta_R$ obtidos segundo o **método dos mínimos quadrados** (ou, simplesmente, os **estimadores MQ**) são os valores destes parâmetros que minimizam o somatório dos quadrados dos erros (isto é, das diferenças entre os valores X_n e os valores das funções $f_n(\theta_1, \dots, \theta_R)$). Em notação simbólica, os estimadores $\hat{\theta}_1, \dots, \hat{\theta}_R$ obtêm-se recorrendo a

$$\text{Min}_{\theta_1, \theta_2, \dots, \theta_R} : SEQ(\theta_1, \theta_2, \dots, \theta_R) = \sum_{n=1}^N E_n^2 = \sum_{n=1}^N [X_n - f_n(\theta_1, \theta_2, \dots, \theta_R)]^2. \quad (9.17)$$

Admitindo que a função $SEQ(\theta_1, \theta_2, \dots, \theta_R)$ é diferenciável, os estimadores ou as estimativas MQ podem ser obtidas resolvendo o sistema de equações definido por

$$\frac{\partial SEQ}{\partial \theta_i} = 0 \quad (i = 1, \dots, R). \quad (9.18)$$

Normalmente, as soluções assim obtidas (que correspondem a pontos estacionários dos somatórios dos erros quadráticos) são mínimos destas funções.

Exemplo 9.16

- ◆ Considere-se uma amostra aleatória simples constituída pelas observações $\{X_1, X_2, \dots, X_N\}$ obtidas a partir de uma população com valor esperado μ . Cada uma das observações pode ser expressa através da relação

$$X_n = \mu + E_n.$$

O estimador MQ de μ obtido a partir daquelas observações pode ser obtido do seguinte modo:

$$SEQ(\mu) = \sum_{n=1}^N E_n^2 = \sum_{n=1}^N (X_n - \mu)^2$$

$$\frac{d SEQ}{d \mu} = (-2) \cdot \sum_{n=1}^N (X_n - \mu) = 0$$

$$\Rightarrow \sum_{n=1}^N (X_n - \mu) = 0$$

$$\Rightarrow \sum_{n=1}^N X_n - N \cdot \mu = 0$$

$$\Rightarrow M = \frac{1}{N} \cdot \sum_{n=1}^N X_n = \bar{X}.$$

- ♦ A partir da amostra constituída pelas 3 observações seguintes

$$x_1 = 2 \cdot \alpha + 3 \cdot \beta + e_1 = 10$$

$$x_2 = \alpha - \beta + e_2 = -2$$

$$x_3 = \alpha + 4 \cdot \beta + e_3 = 14$$

calcular as estimativas MQ dos parâmetros α e β .

O somatório dos erros quadráticos observados vem, neste caso, dado por

$$SEQ(\alpha, \beta) = (10 - 2 \cdot \alpha - 3 \cdot \beta)^2 + (-2 - \alpha + \beta)^2 + (14 - \alpha - 4 \cdot \beta)^2.$$

Anulando as derivadas parciais de SEQ em relação aos parâmetros, vem:

$$\frac{\partial SEQ}{\partial \alpha} = (-4) \cdot (10 - 2 \cdot \alpha - 3 \cdot \beta) + (-2) \cdot (-2 - \alpha + \beta) + (-2) \cdot (14 - \alpha - 4 \cdot \beta)$$

$$\frac{\partial SEQ}{\partial \alpha} = 0 \Rightarrow 12 \cdot \alpha + 18 \cdot \beta = 64; \quad (9.19)$$

$$\frac{\partial SEQ}{\partial \beta} = (-6) \cdot (10 - 2 \cdot \alpha - 3 \cdot \beta) + 2 \cdot (-2 - \alpha + \beta) + (-8) \cdot (14 - \alpha - 4 \cdot \beta)$$

$$\frac{\partial SEQ}{\partial \beta} = 0 \Rightarrow 18 \cdot \alpha + 52 \cdot \beta = 176. \quad (9.20)$$

Resolvendo o sistema de equações 9.19 e 9.20, obtêm-se as estimativas MQ de α e β :

$$\hat{\alpha} = 0.5(3) \quad \hat{\beta} = 3.2.$$

9.3.5 SELECÇÃO DE UM ESTIMADOR


Dos exemplos apresentados pode concluir-se que os vários métodos discutidos podem conduzir aos mesmos estimadores. Assim, verificou-se que a média amostral calculada a partir de uma amostra aleatória simples era o estimador do valor esperado, de acordo com qualquer dos métodos discutidos:

- O estimador Mom, para qualquer distribuição (os exemplos 9.8 ilustram este resultado para os casos particulares das distribuições de Poisson e Normal);
- O estimador MV, para as distribuições de Poisson (exemplo 9.12) e Normal (exemplo 9.14);
- O estimador LVM, para qualquer distribuição (ver o primeiro dos exemplos 9.15);
- O estimador MQ, para qualquer distribuição (ver o primeiro dos exemplos 9.16).

No entanto, em geral, os estimadores obtidos pelos diferentes métodos serão diferentes, pois são estabelecidos à luz de critérios distintos.

Na prática, a selecção de um estimador envolve a comparação de propriedades estatísticas de estimadores alternativos e a formulação de um juízo que tome em conta não só aquelas propriedades mas também outros factores de natureza económica, tais como:

- A influência da dimensão da amostra no custo de amostragem;
- O efeito da precisão de cada estimador nos custos do processo que se pretende medir ou controlar;
- O grau de complexidade de cada estimador e o seu reflexo na qualificação exigível — e, portanto, nos custos — do pessoal envolvido na sua obtenção e interpretação, ou
- A maior ou menor propensão de cada estimador para a ocorrência de erros significativos e o reflexo de tais erros nos custos do processo que se pretende medir ou controlar.



■ APÊNDICE 9.1 O VALOR ESPERADO DO DESVIO QUADRÁTICO MÉDIO AMOSTRAL CALCULADO COM BASE NUMA AMOSTRA ALEATÓRIA SIMPLES

- (1) Para uma amostra aleatória simples de dimensão N , $\{X_1, \dots, X_N\}$, o desvio quadrático médio é definido por

$$DQM = \frac{1}{N} \cdot \sum_{n=1}^N (X_n - \bar{X})^2.$$

- (2) O valor esperado de DQM vem dado por

$$\begin{aligned} E(DQM) &= \frac{1}{N} \cdot \sum_{n=1}^N E[(X_n - \bar{X})^2] \\ &= \frac{1}{N} \cdot \sum_{n=1}^N E\left[\left[(X_n - \mu_X) - (\bar{X} - \mu_X)\right]^2\right]. \end{aligned}$$

- (3) Desenvolvendo o segundo membro desta expressão, resulta

$$\begin{aligned} E(DQM) &= \underbrace{\frac{1}{N} \cdot \sum_{n=1}^N E[(X_n - \mu_X)^2]}_{=A} + \underbrace{\frac{1}{N} \cdot \sum_{n=1}^N E[(\bar{X} - \mu_X)^2]}_{=B} - \\ &\quad \underbrace{\frac{2}{N} \cdot \sum_{n=1}^N E[(X_n - \mu_X) \cdot (\bar{X} - \mu_X)]}_{=C}. \end{aligned} \quad (A9.1)$$

- (4) Calculando cada um dos termos A , B e C , obtém-se

$$\begin{aligned} A &= \frac{1}{N} \cdot \sum_{n=1}^N E[(X_n - \mu_X)^2] = \frac{1}{N} \cdot \sum_{n=1}^N \sigma_X^2 = \frac{1}{N} \cdot (N \cdot \sigma_X^2) = \sigma_X^2 \\ B &= \frac{1}{N} \cdot \sum_{n=1}^N E[(\bar{X} - \mu_X)^2] = \frac{1}{N} \cdot \sum_{n=1}^N E[(\bar{X} - \mu_X)^2] \\ &= \frac{1}{N} \cdot \sum_{n=1}^N \sigma_{\bar{X}}^2 = \frac{1}{N} \cdot (N \cdot \sigma_{\bar{X}}^2) = \sigma_{\bar{X}}^2 = \frac{1}{N} \cdot \sigma_X^2 \end{aligned}$$


$$\begin{aligned} C &= -\frac{2}{N} \cdot \sum_{n=1}^N E[(X_n - \mu_X) \cdot (\bar{X} - \mu_X)] \\ &= -\frac{2}{N} \cdot \sum_{n=1}^N E\left[(X_n - \mu_X) \cdot \left(\frac{1}{N} \cdot \sum_{j=1}^N X_j - \mu_X\right)\right] \\ &= -\frac{2}{N^2} \cdot \sum_{n=1}^N E\left[(X_n - \mu_X) \cdot \sum_{j=1}^N (X_j - \mu_X)\right] \\ &= -\frac{2}{N^2} \cdot \sum_{n=1}^N E\left[(X_n - \mu_X)^2 + \sum_{j \neq n} (X_n - \mu_X) \cdot (X_j - \mu_X)\right] \\ &= -\frac{2}{N^2} \cdot \sum_{n=1}^N E\left[\sigma_X^2 + \underbrace{\sum_{j \neq n} \text{cov}(X_n, X_j)}_{=0}\right] \\ &= -\frac{2}{N^2} \cdot (N \cdot \sigma_X^2) \\ &= -\frac{2}{N} \cdot \sigma_X^2. \end{aligned}$$

- (5) Substituindo, em A9.1, cada um dos termos A , B e C pela expressão correspondente obtida no passo anterior, resulta

$$\begin{aligned} E(DQM) &= A + B + C = \sigma_X^2 + \frac{1}{N} \cdot \sigma_X^2 - \frac{2}{N} \cdot \sigma_X^2 \\ &= \left(1 - \frac{1}{N}\right) \cdot \sigma_X^2 = \frac{N-1}{N} \cdot \sigma_X^2. \end{aligned}$$

ou

$$E(DQM) = \frac{N-1}{N} \cdot \sigma_X^2.$$



- 9.1. Duas amostras aleatórias simples são retiradas da mesma população, constituída por peças boas e defeituosas. Sejam

N_1 : dimensão da amostra 1

N_2 : dimensão da amostra 2

X_1 : número de peças defeituosas contidas na amostra 1

X_2 : número de peças defeituosas contidas na amostra 2.

Seguidamente, apresentam-se dois estimadores da proporção de peças defeituosas na população:

$$\hat{p}_a = \frac{X_1 + X_2}{N_1 + N_2} \quad \hat{p}_b = \frac{1}{2} \cdot \left(\frac{X_1}{N_1} + \frac{X_2}{N_2} \right).$$

Verifique qual dos dois estimadores é o mais eficiente.

- 9.2. Admita que os tempos entre avarias de uma certa máquina seguem uma distribuição Exponencial Negativa com parâmetro λ . Com base na amostra aleatória constituída pelos seguintes tempos, expressos em horas,

{24.3, 13.5, 53.0, 17.2, 7.6, 14.9, 8.1, 34.3},

calcule a estimativa de máxima verosimilhança do parâmetro λ .

- 9.3. De um lote de peças com uma proporção desconhecida p de defeituosas, retirou-se uma amostra aleatória simples de dimensão N . Sabendo que, nesta amostra, o número de peças defeituosas é Y , determine o estimador de máxima verosimilhança para a proporção p .

- 9.4. Os valores que se apresentam seguidamente representam os atrasos de comboios, expressos em minutos, verificados numa determinada estação:

{2.23, 7.74, 1.03, 0.08, 11.14, 12.72, 0.42, 5.17}.

Admitindo que os atrasos seguem uma distribuição $U(0, \theta)$ e que a amostra é aleatória, calcule a estimativa de máxima verosimilhança do parâmetro θ .

- 9.5. A variável aleatória X segue uma distribuição com função densidade de probabilidade dada por

$$f(x) = \begin{cases} \frac{(x-\alpha)}{2}, & \text{se } \alpha < x < \alpha + 2 \\ 0, & \text{no caso contrário} \end{cases}$$

onde α é um parâmetro desconhecido.

Recorrendo ao método de máxima verosimilhança, estime o parâmetro α a partir da seguinte amostra aleatória, constituída por 10 observações:

{3.5, 4.3, 2.8, 4.5, 2.9, 3.3, 3.8, 2.9, 4.0, 3.9}.

- 9.6. A variável contínua X segue uma distribuição com a seguinte função densidade de probabilidade:

$$f(x) = \begin{cases} (\theta + 1) \cdot x^\theta, & \text{se } 0 < x < 1 \\ 0, & \text{no caso contrário.} \end{cases}$$

A partir de uma amostra aleatória $\{x_1, x_2, \dots, x_N\}$ (onde $0 < x_n < 1$ para todos os valores $n = 1, \dots, N$) e recorrendo ao método de máxima verosimilhança, defina um estimador do parâmetro θ .

- 9.7. Uma firma produtora de um fármaco procura desenvolver e testar um novo processo de fabrico com rendimento mais elevado.

A partir de cada lote de matéria-prima, a firma pode produzir simultaneamente 3 «fabricos».

Os 3 últimos lotes de matéria-prima foram utilizados para produzir o fármaco segundo o processo convencional e segundo o novo processo, tendo sido obtidos os seguintes rendimentos para os diferentes fabricos:

	Lote de matéria-prima		
	1	2	3
Processo convencional	54; 53	57; 59	53
Processo novo	58	58	57; 58

Admita que, para qualquer fabrico produzido com base no lote i de matéria-prima, o rendimento (X) é dado por

$$X = \begin{cases} (\beta_i - \pi) + \varepsilon, & \text{se for adoptado o processo convencional} \\ (\beta_i + \pi) + \varepsilon, & \text{se for adoptado o novo processo} \end{cases}$$

onde ε é uma variável aleatória com valor esperado nulo e variância constante (para qualquer fabrico, independentemente do lote de matéria-prima ou do processo).

Use o método dos mínimos quadrados para estimar a diferença de rendimento entre os dois processos (2π).

- 9.8. Num processo determinístico, os valores sucessivos de uma variável Y , $\{y_1, y_2, \dots, y_N\}$, estão relacionados na seguinte forma:

$$y_{n+1} = \alpha \cdot y_n$$

onde α é uma constante conhecida que toma o valor 1.1.


Infelizmente os valores de y_n só são observáveis com erro, e as observações $\{x_1, x_2, \dots, x_N\}$, são tais que

$$x_n = y_n + e_n$$

onde os valores de e_n representam erros de observação independentes com valor esperado e nulo e variância constante.

Recorrendo ao método dos mínimos quadrados, calcule estimadores de $y_1, y_2, \dots, y_N$ com base nas seguintes observações:

$x_1 = 3.04$ $x_2 = 3.26$ $x_3 = 3.67$ $x_4 = 4.01$ $x_5 = 4.33$.



Estimação por Intervalo

10.1 O CONCEITO DE INTERVALO DE CONFIANÇA

Cada um dos métodos de estimação pontual analisados no capítulo anterior permite associar a cada parâmetro populacional um estimador. Como se viu, a cada estimador estarão associadas tantas estimativas diferentes quantas as amostras que forem utilizadas para o seu cálculo. Na generalidade dos casos, nenhuma dessas estimativas coincidirá com o valor do parâmetro.

A grande limitação dos métodos de estimação pontual é a de não fornecerem qualquer informação relativa ao rigor ou à confiança das estimativas que através deles são obtidas. Esta dificuldade é ultrapassada recorrendo aos **métodos de estimação por intervalo**. Este conceito será introduzido com base no exemplo seguinte.

Exemplo 10.1

Admita-se que a altura dos alunos do 10.º ano segue uma distribuição Normal cuja variância é conhecida: $\sigma^2 = (0.051 \text{ m})^2$. Admita-se ainda que foi recolhida uma amostra aleatória com dimensão $N = 25$ alunos e calculada a respectiva média amostral, tendo-se obtido $\bar{x} = 1.70 \text{ m}$.


A questão que se coloca é a de como definir um intervalo que, com uma probabilidade de 95%, contenha o valor esperado da altura, μ ?

Como foi visto no Capítulo 8, se a distribuição da variável aleatória X é normal com parâmetros μ e σ^2 , então a média amostral $\bar{X}$ segue também uma distribuição Normal, com parâmetros μ e σ^2/N . Assim,

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{N}} \sim N(0, 1) \quad (\text{ver Secção 7.4.2}).$$

Seja $z(\alpha/2)$ um valor tal que $P[Z > z(\alpha/2)] = \alpha/2$ e seja ainda $-z(\alpha/2)$ o valor simétrico para o qual $P[Z < -z(\alpha/2)] = \alpha/2$ (ver Figura 10.1).

Figura 10.1
Valores simétricos da distribuição $N(0, 1)$ tais que $P[-z(\alpha/2) < Z < z(\alpha/2)] = 1 - \alpha$.



Deste modo

$$P\{-z(\alpha/2) < Z < z(\alpha/2)\} = 1 - \alpha$$

ou

$$P\left[-z(\alpha/2) < \frac{\bar{X} - \mu}{\sigma / \sqrt{N}} < z(\alpha/2)\right] = 1 - \alpha$$

ou ainda

$$P\left[\mu - z(\alpha/2) \cdot \sigma / \sqrt{N} < \bar{X} < \mu + z(\alpha/2) \cdot \sigma / \sqrt{N}\right] = 1 - \alpha. \quad (10.1)$$

Reescrevendo de forma diferente as desigualdades entre parênteses que figuram na expressão 10.1, obtém-se

$$P\left[\bar{X} - z(\alpha/2) \cdot \frac{\sigma}{\sqrt{N}} < \mu < \bar{X} + z(\alpha/2) \cdot \frac{\sigma}{\sqrt{N}}\right] = 1 - \alpha.$$

De acordo com esta última expressão, o intervalo

$$\left[\bar{X} - z(\alpha/2) \cdot \frac{\sigma}{\sqrt{N}}, \bar{X} + z(\alpha/2) \cdot \frac{\sigma}{\sqrt{N}}\right] \quad (10.2)$$

incluirá, com probabilidade $1 - \alpha$, o valor de μ .

Substituindo na expressão 10.2 os valores correspondentes ao Exemplo 10.1 (atente-se a que, de acordo com a Tabela 3, para $\alpha/2 = 2.5\%$ se obtém $z(\alpha/2) = 1.96$), vem

$$1.70 \pm 1.96 \cdot 0.051 / 5$$

ou ainda

$$1.70 \pm 0.02.$$


Resulta, assim, que

$$\mu \in [1.68, 1.72], \text{ com confiança de } 95\%.$$

O intervalo definido pela expressão 10.2 designa-se por **intervalo de confiança** para o valor esperado a $(1 - \alpha) \cdot 100\%$ (para o exemplo considerado, o intervalo foi definido para um nível de confiança de 95%). Os extremos do intervalo definido pela expressão 10.2 designam-se por **limites de confiança** a $(1 - \alpha) \cdot 100\%$ (para o Exemplo 10.1, os limites de confiança a 95% são 1.68 e 1.72). O valor de $z(\alpha/2) \cdot \sigma / \sqrt{N}$ (ver expressão 10.2), ou seja, a semi-amplitude do intervalo de confiança (com o valor 0.02, no exemplo considerado) corresponde ao erro máximo que, com a confiança especificada, se pode cometer na estimativa de μ .

Note-se que, na expressão 10.1, o valor de μ é fixo, uma vez que se trata de um parâmetro da população. O que varia de amostra para amostra é o valor de $\bar{X}$, variando com ele a localização do intervalo de confiança (e não a sua amplitude). Note-se ainda que α representa, em média, a proporção de vezes em que o intervalo de confiança não contém o parâmetro que se pretende estimar (neste caso o valor esperado, μ). Por exemplo, para $\alpha = 5\%$, o parâmetro ficará fora do intervalo uma vez em cada vinte. Estes aspectos são ilustrados na Figura 10.2.

Figura 10.2
Intervalos de confiança para μ .



Uma outra questão importante prende-se com a simetria (que deriva da expressão 10.2) do intervalo de confiança relativamente ao valor do estimador pontual, $\bar{X}$. Para quaisquer valores α_1 e α_2 , não simétricos, que satisfaçam a expressão

$$\alpha_1 + \alpha_2 = \alpha,$$

os intervalos

$$\left[\bar{X} - z(\alpha_1) \cdot \frac{\sigma}{\sqrt{N}}, \bar{X} + z(\alpha_2) \cdot \frac{\sigma}{\sqrt{N}}\right]$$

são todos eles intervalos de confiança de μ a $(1 - \alpha) \cdot 100\%$.

Exemplo 10.2

Utilizando os valores referidos no Exemplo 10.1 ($\bar{x} = 1.70$, $\sigma^2 = 0.051^2$ e $N = 25$), definam-se três intervalos de confiança a 95%:

$$(i) \alpha_1 = \alpha_2 = \alpha / 2 = 0.025$$

$$\bar{x} - z(0.025) \cdot \frac{\sigma}{\sqrt{N}} = 1.70 - 1.96 \cdot \frac{0.051}{\sqrt{25}} = 1.680$$

$$\bar{x} + z(0.025) \cdot \frac{\sigma}{\sqrt{N}} = 1.70 + 1.96 \cdot \frac{0.051}{\sqrt{25}} = 1.720$$

$$\text{Amplitude: } 1.720 - 1.680 = 0.040.$$

(ii) $\alpha_1 = 0.01, \alpha_2 = 0.04$

$$\bar{x} - z(0.01) \cdot \frac{\sigma}{\sqrt{N}} = 1.70 - 2.33 \cdot \frac{0.051}{\sqrt{25}} = 1.676$$

$$\bar{x} + z(0.04) \cdot \frac{\sigma}{\sqrt{N}} = 1.70 + 1.75 \cdot \frac{0.051}{\sqrt{25}} = 1.718$$

$$\text{Amplitude: } 1.718 - 1.676 = 0.042.$$

(iii) $\alpha_1 = 0.005, \alpha_2 = 0.045$

$$\bar{x} - z(0.005) \cdot \frac{\sigma}{\sqrt{N}} = 1.70 - 2.575 \cdot \frac{0.051}{\sqrt{25}} = 1.674$$

$$\bar{x} + z(0.045) \cdot \frac{\sigma}{\sqrt{N}} = 1.70 + 1.695 \cdot \frac{0.051}{\sqrt{25}} = 1.717$$

$$\text{Amplitude: } 1.717 - 1.674 = 0.043.$$

Repare-se que, destes três intervalos de confiança, aquele que tem menor amplitude é o primeiro, precisamente aquele que corresponde a $\alpha_1 = \alpha_2 = \alpha/2$. Sempre que a estatística a partir da qual se definem os intervalos de confiança possuir uma distribuição unimodal simétrica (tal como sucede com $\bar{X}$ quando a população é Normal), o intervalo simétrico em relação à estatística (ou seja, aquele que se obtém com $\alpha_1 = \alpha_2 = \alpha/2$) é o de menor amplitude e, por isso mesmo, aquele que, em geral, deve ser calculado.

Constituem excepções a esta regra situações nas quais se pretendem definir intervalos de confiança unilaterais, isto é, intervalos de confiança ilimitados superiormente (abertos à direita) ou ilimitados inferiormente (abertos à esquerda).

Exemplo 10.3

Retomando o Exemplo 10.1, admita-se que, desta vez, se pretende definir, ainda para μ , o intervalo de confiança aberto à direita, a 95%.

Fazendo $\alpha_1 = 0.05$ e $\alpha_2 = 0.00$, vem:

$$\bar{x} - z(0.05) \cdot \frac{\sigma}{\sqrt{N}} = 1.70 - 1.645 \cdot \frac{0.051}{\sqrt{25}} = 1.683$$

$$\bar{x} + z(0.00) \cdot \frac{\sigma}{\sqrt{N}} = +\infty$$

Assim, o intervalo de confiança aberto à direita a 95% para o valor esperado, μ , será

$$[1.683, +\infty[.$$

ou, de outra forma,

$$\mu \geq 1.683 \quad (\text{com } 95\% \text{ de confiança}).$$

10.2 ESPECIFICAÇÃO DE INTERVALOS DE CONFIANÇA

A partir do conceito de intervalo de confiança para um parâmetro, é imediato concluir que a especificação de um tal intervalo implica o conhecimento simultâneo de:

- (i) um estimador do parâmetro em causa;
- (ii) a sua distribuição, e
- (iii) uma estimativa pontual daquele parâmetro (um valor particular do estimador).

Seguidamente ilustra-se como podem ser especificados intervalos de confiança para parâmetros populacionais em algumas situações comuns. Em todos os casos, serão definidas expressões que permitem especificar directamente intervalos de confiança bilaterais (isto é, intervalos em que ambos os limites são finitos). A construção de intervalos de confiança unilaterais a partir das expressões apresentadas é imediata. Para tal, bastará seguir um procedimento idêntico ao descrito no Exemplo 10.3.

10.2.1 INTERVALO DE CONFIANÇA PARA O VALOR ESPERADO

A especificação dos intervalos de confiança para o valor esperado far-se-á para duas situações distintas: a primeira, na qual se dispõe de uma amostra de grande dimensão proveniente de uma população qualquer e a segunda, na qual a amostra é pequena, mas proveniente de uma população Normal.

10.2.1.1 AMOSTRA DE GRANDE DIMENSÃO, POPULAÇÃO QUALQUER

Neste caso, de acordo com o teorema do limite central (ver Secção 8.5.1), a média amostral segue aproximadamente uma distribuição Normal:

$$\bar{X} \sim N(\mu, \sigma^2/N),$$

onde μ e σ^2 representam o valor esperado e a variância da população e N a dimensão da amostra. Assim,

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{N}} \sim N(0, 1).$$

Em geral, o desvio padrão, σ , é desconhecido, sendo estimado através do desvio padrão amostral,

$$S = \sqrt{\frac{1}{N-1} \cdot \sum_{n=1}^N (X_n - \bar{X})^2}.$$

Note-se que S representa o estimador desvio padrão amostral, cujos valores particulares são as estimativas s .

Uma vez que se admitiu que a amostra é grande, o erro de estimação é desprezável, vindo

$$S \approx \sigma \quad (\text{constante})$$

e, consequentemente,

$$Z = \frac{\bar{X} - \mu}{S / \sqrt{N}} \approx \frac{\bar{X} - \mu}{\sigma / \sqrt{N}} \sim N(0, 1).$$

O intervalo de confiança para o valor esperado, μ , a $(1 - \alpha) \cdot 100\%$ vem então (ver expressão 10.2)

$$\left[\bar{X} - z(\alpha/2) \cdot \frac{S}{\sqrt{N}}, \bar{X} + z(\alpha/2) \cdot \frac{S}{\sqrt{N}} \right]. \quad (10.3)$$

■ 10.2.1.2 AMOSTRA DE PEQUENA DIMENSÃO, POPULAÇÃO NORMAL

Dado que a dimensão, N , da amostra é pequena, já não é válida a aproximação

$$S \approx \sigma \quad (\text{constante}),$$

e, consequentemente, deixa também de ser válida a aproximação

$$\frac{\bar{X} - \mu}{S / \sqrt{N}} \approx \frac{\bar{X} - \mu}{\sigma / \sqrt{N}}.$$

Nestas condições, é necessário verificar qual a distribuição da variável

$$\frac{\bar{X} - \mu}{S / \sqrt{N}}.$$

Para o fazer, reescreva-se esta expressão da forma seguinte:

$$\frac{\bar{X} - \mu}{S / \sqrt{N}} = \frac{\bar{X} - \mu}{\sigma / \sqrt{N}} \cdot \frac{\sigma}{S}.$$

É imediato verificar que a variável em numerador,

$$\frac{\bar{X} - \mu}{\sigma / \sqrt{N}},$$

segue uma distribuição $N(0, 1)$.

Para analisar a distribuição da variável em denominador, S / σ , considere-se a variável

$$V = (N-1) \cdot \left(\frac{S}{\sigma} \right)^2,$$

que pode ser desenvolvida de acordo com a expressão seguinte:

$$V = (N-1) \cdot \frac{S^2}{\sigma^2} = \frac{(N-1)}{\sigma^2} \cdot \left[\frac{1}{(N-1)} \cdot \sum_{n=1}^N (X_n - \bar{X})^2 \right] = \sum_{n=1}^N \left(\frac{X_n - \bar{X}}{\sigma} \right)^2.$$

Ora, é possível demonstrar (ver Apêndice 10.1) que a variável expressa por este somatório segue a distribuição Qui-quadrado com $N-1$ graus de liberdade, ou seja, que

$$V = (N-1) \cdot \frac{S^2}{\sigma^2} \sim \chi_{N-1}^2, \quad (10.4)$$

donde S / σ segue a distribuição da variável transformada $\sqrt{V / (N-1)}$ (com $V \sim \chi_{N-1}^2$), facto que pode ser simbolizado por

$$\frac{S}{\sigma} \sim \sqrt{\frac{\chi_{N-1}^2}{(N-1)}}.$$

Assim, e mantendo esta notação,

$$\frac{\bar{X} - \mu}{S / \sqrt{N}} = \frac{\bar{X} - \mu}{\sigma / \sqrt{N}} \cdot \frac{\sigma}{S} \sim \frac{N(0, 1)}{\sqrt{\chi_{N-1}^2 / (N-1)}}.$$

Como as variáveis

$$\frac{\bar{X} - \mu}{\sigma / \sqrt{N}} \quad \text{e} \quad S / \sigma$$

são independentes (facto que aqui não se demonstra), de acordo com a definição da distribuição t de Student apresentada na Secção 7.7.1, resulta que

$$\frac{\bar{X} - \mu}{S / \sqrt{N}} \sim t_{N-1}.$$

Seguindo um procedimento idêntico ao adoptado anteriormente, o intervalo de confiança para o valor esperado, μ , a $(1 - \alpha) \cdot 100\%$ virá então

$$\left[\bar{X} - t_{N-1}(\alpha/2) \cdot \frac{S}{\sqrt{N}}, \quad \bar{X} + t_{N-1}(\alpha/2) \cdot \frac{S}{\sqrt{N}} \right]. \quad (10.5)$$

Exemplo 10.4

A quantidade de oxigénio dissolvido na água constitui um indicador do grau de poluição dos rios. Tal quantidade pode ser avaliada através de análises efectuadas aos tecidos dos seres que neles vivem. Com o objectivo de verificar a qualidade da água junto a uma captação para abastecimento urbano, recolheram-se, de forma aleatória, seis trutas perto daquele local, durante o mês de Agosto. As análises efectuadas a órgãos desses peixes revelaram taxas de oxigénio dissolvido na água de, respectivamente, 5.4, 5.2, 5.1, 5.0, 4.9 e 4.9 partes por milhão (ppm). Pretende estimar-se o intervalo que, com 95% de confiança, inclui o valor esperado da quantidade de oxigénio dissolvido na água em Agosto.

Executando os cálculos a partir dos dados fornecidos, a média e o desvio padrão amostrais da variável X — quantidade de oxigénio dissolvido na água durante o mês de Agosto — vêm dados, respectivamente, por 5.083 ppm e 0.194 ppm. Admitindo-se que X segue uma distribuição Normal, o intervalo de confiança pretendido vem dado por

$$\left[5.083 - 2.571 \cdot \frac{0.194}{\sqrt{6}}, \quad 5.083 + 2.571 \cdot \frac{0.194}{\sqrt{6}} \right].$$

Neste intervalo, o termo $t_5(0.025) = 2.571$ foi obtido a partir da Tabela 5 do Anexo «Tabelas». Efectuando os cálculos, obtém-se o intervalo

$$[4.879, 5.287],$$

que contém, com 95% de confiança, o valor esperado de X , expresso em ppm.

Note-se que, para um dado α , à medida que a dimensão da amostra vai aumentando, o correspondente valor $t_{N-1}(\alpha/2)$ vai diminuindo, decrescendo também a amplitude do intervalo de confiança. Na Tabela 10.1 ilustra-se este facto para $\alpha = 0.05$ (ver Tabela 5 do Anexo «Tabelas»).

Tabela 10.1
Valores críticos
da distribuição
 $t_{N-1}(0.025)$.

N	$t_{N-1}(0.025)$
7	2.447
14	2.160
21	2.086
∞	1.960

A interpretação da redução progressiva do intervalo de confiança para o valor esperado é simples: à medida que a dimensão da amostra aumenta, o erro de estimação de σ diminui. De outra forma, com o aumento de N , a distribuição da variável

$$t_{N-1} = \frac{\bar{X} - \mu}{S / \sqrt{N}}$$

vai-se aproximando progressivamente da distribuição Normal padronizada, cuja kurtose é inferior à de qualquer distribuição t de Student com um número de graus de liberdade finito. Não existe nenhum critério objectivo que permita fixar o valor de N a partir do qual se pode considerar uma amostra grande, pois tal depende da precisão exigida no cálculo dos limites do intervalo de confiança e da forma da distribuição da variável X . Em relação à normalidade de $\bar{X}$, é frequente indicar-se como regra prática que, no caso de distribuições muito assimétricas, a distribuição de $\bar{X}$ é suficientemente próxima da Normal para $N \geq 50$ e que, para distribuições simétricas, tal aproximação é razoável a partir de $N = 10$ (ver Secção 8.5.1).

10.2.2 INTERVALO DE CONFIANÇA DA PROPORÇÃO BINOMIAL (AMOSTRAS DE GRANDE DIMENSÃO)

Considere-se uma população dicotómica, constituída apenas por elementos de dois tipos (por exemplo, por peças defeituosas e peças boas). O valor p , que corresponde à proporção de elementos de um dos dois tipos na população (por exemplo, peças defeituosas), designa-se por **proporção Binomial**. Se desta população for retirada uma amostra de dimensão N contendo y elementos de um dos tipos (por exemplo, peças defeituosas) então $\hat{p} = y/N$ será uma proporção amostral. Esta estimativa de p corresponde a um valor particular do estimador $\hat{P} = Y/N$.

Se o processo de amostragem for aleatório simples (o que de acordo com o definido na Secção 8.2 pressupõe que a população é infinita, ou, no caso contrário, que a amostragem é efectuada com reposição), o número Y de elementos de um dado tipo contidos na amostra (por exemplo, número de peças defeituosas) pode ser interpretado como o número de «sucessos» em N experiências de Bernoulli. Nestas condições, a variável Y segue uma distribuição Binomial $B(N, p)$ (ver a Secção 6.2.1).

De acordo com o teorema do limite central, para N suficientemente grande, a distribuição de Y (número de elementos de um dado tipo contidos na amostra) aproximar-se-á de uma distribuição Normal (ver Secções 7.4.4 e 8.5.3) com parâmetros

$$\mu = N \cdot p \quad \text{e} \quad \sigma^2 = N \cdot p \cdot (1 - p).$$

Recorde-se que tal aproximação será tanto mais precisa quanto maior for a dimensão da amostra e menos assimétrica for a distribuição de Y (na prática, exige-se, como mínimo, que $N \geq 20$, $N \cdot p > 5$ e $N \cdot q > 5$, sendo desejável que $N \cdot p > 7$ e $N \cdot q > 7$). É imediato verificar que, nestas condições, a proporção amostral, $\hat{P} = Y/N$, seguirá também uma distribuição Normal, com parâmetros

$$\mu = \frac{1}{N} \cdot N \cdot p = p \quad \text{e} \quad \sigma^2 = \frac{1}{N^2} \cdot N \cdot p \cdot (1 - p) = \frac{p \cdot (1 - p)}{N},$$

ou seja,

$$\hat{P} = \frac{Y}{N} \sim N[p, p \cdot (1 - p)/N]. \quad (10.6)$$

Assim, os limites do intervalo de confiança para p a $(1 - \alpha) \cdot 100\%$ serão

$$(Y/N) \pm z(\alpha/2) \cdot \sigma.$$

Para amostras de grandes dimensões, o valor de σ (que depende do parâmetro desconhecido p) pode ser substituído por um qualquer valor do seu estimador (calculado com base em $\hat{P} = Y/N$):

$$S = \sqrt{\frac{\hat{P} \cdot (1 - \hat{P})}{N}} = \sqrt{\frac{Y/N \cdot (1 - Y/N)}{N}} = \sqrt{\frac{Y \cdot (N - Y)}{N^3}}.$$

Nestas condições, vem

$$\frac{\frac{Y}{N} - p}{\sqrt{\frac{Y \cdot (N - Y)}{N^3}}} \sim N(0, 1),$$

e, finalmente, o intervalo de confiança para a proporção binomial, p , a $(1 - \alpha) \cdot 100\%$ é

$$\left[\frac{Y}{N} - z(\alpha/2) \cdot \sqrt{\frac{Y \cdot (N - Y)}{N^3}}, \quad \frac{Y}{N} + z(\alpha/2) \cdot \sqrt{\frac{Y \cdot (N - Y)}{N^3}} \right]. \quad (10.7)$$

Exemplo 10.5

Num lote de 150 peças fabricadas numa determinada máquina-ferramenta encontraram-se 12 defeituosas. Defina-se o intervalo de confiança a 95% para a proporção de peças defeituosas que aquela máquina produz.

Tal intervalo será calculado no pressuposto de que a produção de uma peça defeituosa (ou boa) tem uma probabilidade constante e de que qualquer resultado não é influenciado por resultados anteriores nem condiciona resultados futuros.

$$\frac{y}{N} = \frac{12}{150} = 0.08$$

$$z(0.025) = 1.96$$

$$\frac{y}{N} \pm z(\alpha/2) \cdot \sqrt{\frac{y \cdot (N - y)}{N^3}} = 0.08 \pm 1.96 \cdot \sqrt{\frac{12 \cdot 138}{150^3}}$$

$$= 0.08 \pm 1.96 \cdot 0.0221$$

$$= 0.08 \pm 0.043.$$

Intervalo de confiança pretendido: [0.037, 0.123].

Note-se que até agora só se consideraram populações infinitas ou, no caso contrário, amostragens com reposição. No caso de a população ser finita e de a amostragem ser efectuada sem reposição, a aproximação da distribuição da variável Y (número de «sucessos») pela Normal pode ser efectuada desde que se verifiquem as condições já enunciadas ($N \geq 20$, $N \cdot p > 7$ e $N \cdot q > 7$) e desde que a dimensão da população, M , seja grande e a dimensão da amostra, N , muito menor do que M . Esta última condição assegura que a

dependência entre os sucessivos resultados do processo de amostragem é fraca e, que, portanto, é ainda válida a aplicação do teorema do limite central (ver Secção 8.5.1). Em rigor, nesta situação, a estimativa da variância de Y/N deveria ser multiplicada pelo factor de redução $(M - N)/(M - 1)$ (ver Secção 8.4.1).

10.2.3 INTERVALO DE CONFIANÇA PARA A VARIÂNCIA DE UMA POPULAÇÃO NORMAL

Tal como foi referido na Secção 10.2.1, se de uma população $N(\mu, \sigma^2)$ forem obtidas amostras aleatórias de dimensão N com variância amostral S^2 , então (ver expressão 10.4)

$$(N-1) \cdot \frac{S^2}{\sigma^2} \sim \chi^2_{N-1}.$$

Sejam $(\chi^2_{N-1})_A$ e $(\chi^2_{N-1})_B$ dois valores tais que

$$P[(\chi^2_{N-1})_A < \chi^2_{N-1} < (\chi^2_{N-1})_B] = 1 - \alpha.$$

Substituindo na expressão anterior χ^2_{N-1} por $(N-1) \cdot \frac{S^2}{\sigma^2}$, vem

$$P\left[(\chi^2_{N-1})_A < (N-1) \cdot \frac{S^2}{\sigma^2} < (\chi^2_{N-1})_B\right] = 1 - \alpha,$$

ou

$$P\left[\frac{1}{(\chi^2_{N-1})_A} > \frac{\sigma^2}{(N-1) \cdot S^2} > \frac{1}{(\chi^2_{N-1})_B}\right] = 1 - \alpha,$$

ou ainda

$$P\left[\frac{(N-1) \cdot S^2}{(\chi^2_{N-1})_A} > \sigma^2 > \frac{(N-1) \cdot S^2}{(\chi^2_{N-1})_B}\right] = 1 - \alpha,$$

ou, finalmente,

$$P\left[\frac{(N-1) \cdot S^2}{(\chi^2_{N-1})_B} < \sigma^2 < \frac{(N-1) \cdot S^2}{(\chi^2_{N-1})_A}\right] = 1 - \alpha.$$

O intervalo de confiança para a variância, σ^2 , a $(1 - \alpha) \cdot 100\%$, é então

$$\left[\frac{(N-1) \cdot S^2}{(\chi^2_{N-1})_B}, \frac{(N-1) \cdot S^2}{(\chi^2_{N-1})_A} \right].$$

Note-se que a distribuição do χ^2 não é simétrica. Existe assim a dificuldade de definir os valores

$$(\chi^2_{N-1})_B \text{ e } (\chi^2_{N-1})_A$$

que conduzem ao intervalo de confiança de menor amplitude. Por uma questão de simplicidade, é habitual utilizarem-se, respectivamente, $\chi^2_{N-1}(\alpha/2)$ e $\chi^2_{N-1}(1-\alpha/2)$. À medida que N cresce, estes valores aproximam-se dos óptimos, já que a distribuição do χ^2 tende

para uma distribuição Normal (ver Secção 8.5.3). Assim, em geral, adopta-se a seguinte expressão para definir os limites do intervalo de confiança a $(1 - \alpha) \cdot 100\%$ para a variância de uma população Normal:

$$\left[\frac{(N-1) \cdot S^2}{\chi^2_{N-1}(\alpha/2)}, \frac{(N-1) \cdot S^2}{\chi^2_{N-1}(1-\alpha/2)} \right]. \quad (10.8)$$

Exemplo 10.6

Pretende avaliar-se a variabilidade associada ao resultado de um determinado método de análise química. Com esse objectivo, efectuaram-se 17 análises a uma determinada substância em que se seguiu o referido método, em condições perfeitamente estabilizadas. A variância amostral dos resultados (expressos numa determinada unidade) foi de 2.70. Admitindo que o resultado das análises segue uma distribuição Normal, defina-se o intervalo de confiança a 95% para a variância.

De acordo com a Tabela 4 do Anexo «Tabelas», para 16 graus de liberdade, vem

$$\chi^2_{16}(0.975) = 6.91, \text{ e}$$

$$\chi^2_{16}(0.025) = 28.85.$$

Assim, o intervalo a 95% de confiança para σ^2 virá

$$\left[\frac{(17-1) \cdot 2.7}{28.85}, \frac{(17-1) \cdot 2.7}{6.91} \right]$$

ou, finalmente,

$$[1.50, 6.25].$$



10.2.4 INTERVALO DE CONFIANÇA PARA A RAZÃO ENTRE VARIÂNCIAS DE POPULAÇÕES NORMAIS

Admita-se que σ_A^2 e σ_B^2 correspondem às variâncias de duas populações normais, A e B. Admita-se ainda que, com base em amostras independentes de dimensões N_A e N_B , se obtêm os estimadores para aquelas variâncias, S_A^2 e S_B^2 , respectivamente.

Recorrendo, de novo, à expressão 10.4, vem

$$(N_A - 1) \cdot \frac{S_A^2}{\sigma_A^2} \sim \chi^2_{N_A-1} \quad \text{e} \quad (N_B - 1) \cdot \frac{S_B^2}{\sigma_B^2} \sim \chi^2_{N_B-1}.$$

Assim, e de acordo com notação anteriormente introduzida,

$$S_A^2 / \sigma_A^2 \sim \chi^2_{N_A-1} / (N_A - 1) \quad \text{e} \quad S_B^2 / \sigma_B^2 \sim \chi^2_{N_B-1} / (N_B - 1),$$

ou, ainda

$$\frac{S_A^2 / \sigma_A^2}{S_B^2 / \sigma_B^2} \sim \frac{\chi^2_{N_A-1} / (N_A - 1)}{\chi^2_{N_B-1} / (N_B - 1)}.$$

De acordo com a definição de distribuição F apresentada na Secção 7.8.1 (ver expressão 7.19), vem então

$$\frac{S_A^2 / \sigma_A^2}{S_B^2 / \sigma_B^2} \sim F_{N_A-1, N_B-1},$$

uma vez que se admite que as variáveis S_A^2 e S_B^2 são independentes (pois são obtidas a partir de amostras independentes).

Tomem-se dois valores desta distribuição, $F_{N_A-1, N_B-1}(\alpha/2)$ e $F_{N_A-1, N_B-1}(1-\alpha/2)$ tais que

$$P[F_{N_A-1, N_B-1}(1-\alpha/2) < F_{N_A-1, N_B-1} < F_{N_A-1, N_B-1}(\alpha/2)] = 1-\alpha.$$

Virá então

$$P\left[F_{N_A-1, N_B-1}(1-\alpha/2) < \frac{S_A^2 / \sigma_A^2}{S_B^2 / \sigma_B^2} < F_{N_A-1, N_B-1}(\alpha/2)\right] = 1-\alpha,$$

ou

$$P\left[\frac{1}{F_{N_A-1, N_B-1}(1-\alpha/2)} > \frac{\sigma_A^2 / \sigma_B^2}{S_A^2 / S_B^2} > \frac{1}{F_{N_A-1, N_B-1}(\alpha/2)}\right] = 1-\alpha$$

ou, ainda,

$$P\left[\frac{1}{F_{N_A-1, N_B-1}(1-\alpha/2)} \cdot \frac{S_A^2}{S_B^2} > \frac{\sigma_A^2}{\sigma_B^2} > \frac{1}{F_{N_A-1, N_B-1}(\alpha/2)} \cdot \frac{S_A^2}{S_B^2}\right] = 1-\alpha$$

ou, finalmente,

$$P\left[\frac{1}{F_{N_A-1, N_B-1}(\alpha/2)} \cdot \frac{S_A^2}{S_B^2} < \frac{\sigma_A^2}{\sigma_B^2} < \frac{1}{F_{N_A-1, N_B-1}(1-\alpha/2)} \cdot \frac{S_A^2}{S_B^2}\right] = 1-\alpha.$$

O intervalo de confiança, a $(1-\alpha) \cdot 100\%$, para a razão entre as variâncias das duas populações normais, σ_A^2 / σ_B^2 , é então

$$\left[\frac{1}{F_{N_A-1, N_B-1}(\alpha/2)} \cdot \frac{S_A^2}{S_B^2}, \frac{1}{F_{N_A-1, N_B-1}(1-\alpha/2)} \cdot \frac{S_A^2}{S_B^2} \right] \quad (10.9)$$

Note-se que a distribuição F não é simétrica e, assim, os valores $F_{N_A-1, N_B-1}(\alpha/2)$ e $F_{N_A-1, N_B-1}(1-\alpha/2)$ não são os que conduzem ao intervalo de menor amplitude. No entanto, à semelhança do procedimento que foi adoptado em 10.2.3, a prática habitual corresponde a adoptar os valores incluídos na expressão 10.9.

Exemplo 10.7

Pretende-se comparar o desempenho de duas máquinas, A e B, no que diz respeito à precisão de fabrico de uma peça. A partir de 13 peças produzidas na máquina A e de 17 na máquina B, obtiveram-se os seguintes resultados para a variância amostral de uma determinada dimensão cotada no respectivo desenho:

$$s_A^2 = 6.32 \text{ mm}^2 \quad \text{e} \quad s_B^2 = 4.80 \text{ mm}^2.$$

Admitindo que quer em peças fabricadas na máquina A, quer em peças fabricadas na máquina B a distribuição da referida dimensão é Normal, defina-se o intervalo de confiança a 90% para a razão entre as variâncias σ_A^2 e σ_B^2 .

Recorrendo à Tabela 6 do Anexo «Tabelas», para 12 e 16 graus de liberdade e para $\alpha = 10\%$, obtém-se

$$\frac{1}{F_{12, 16}(0.05)} \cdot \frac{s_A^2}{s_B^2} = \frac{1}{2.42} \cdot \frac{6.32}{4.80} = 0.544.$$

A Tabela 6 não permite obter directamente o valor de $F_{N_A-1, N_B-1}(1-\alpha/2)$, ou seja, o valor de $F_{12, 16}(0.95)$. Recorrendo à expressão 7.21 (ver Secção 7.8.1), vem:

$$F_{12, 16}(0.95) = \frac{1}{F_{16, 12}(0.05)} = \frac{1}{2.60}.$$

Assim,

$$\frac{1}{F_{N_A-1, N_B-1}(1-\alpha/2)} \cdot \frac{s_A^2}{s_B^2} = 2.60 \cdot \frac{6.32}{4.80} = 3.423.$$

O intervalo de confiança a 90% para σ_A^2 / σ_B^2 será então

$$[0.544, 3.423].$$

10.2.5 INTERVALO DE CONFIANÇA PARA A DIFERENÇA ENTRE OS VALORES ESPERADOS DE DUAS POPULAÇÕES

Em paralelo com o procedimento adoptado na Secção 10.2.1 a propósito da definição do intervalo de confiança para o valor esperado, também agora se estabelece a distinção entre a situação na qual se dispõe de amostras grandes provenientes de populações quaisquer e a situação na qual as amostras são pequenas mas provêm de populações Normais.

10.2.5.1 AMOSTRAS INDEPENDENTES DE GRANDES DIMENSÕES, POPULAÇÕES QUAISQUER

Sejam μ_A e μ_B os valores esperados das populações A e B e σ_A^2 e σ_B^2 as suas variâncias. Admita-se que a partir destas populações se obtiveram amostras independentes de dimensões N_A e N_B , com base nas quais se calcularam os estimadores dos valores esperados, $\bar{X}_A$ e $\bar{X}_B$, e das variâncias, S_A^2 e S_B^2 .

Tratando-se de amostras de grandes dimensões, quaisquer valores dos estimadores S_A^2 e S_B^2 serão muito próximos de σ_A^2 e de σ_B^2 . De acordo com o teorema do limite central, quaisquer que sejam as formas das distribuições A e B, poderá afirmar-se que

$$\bar{X}_A \sim N(\mu_A, \sigma_A^2 / N_A) \approx N(\mu_A, S_A^2 / N_A)$$

e que

$$\bar{X}_B \sim N(\mu_B, \sigma_B^2 / N_B) \approx N(\mu_B, S_B^2 / N_B).$$

Dado que se admitiu que as amostras são obtidas independentemente uma da outra, a diferença $\bar{X}_A - \bar{X}_B$ é ainda uma variável aleatória Normal (ver Secção 7.4.3) e assim

$$\bar{X}_A - \bar{X}_B \sim N\left(\mu_A - \mu_B, \frac{\sigma_A^2}{N_A} + \frac{\sigma_B^2}{N_B}\right) \approx N\left(\mu_A - \mu_B, \frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}\right),$$

ou ainda

$$Z = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}} \sim N(0, 1).$$

O intervalo de confiança a $(1 - \alpha) \cdot 100\%$ para a diferença de valores esperados, $\mu_A - \mu_B$, vem então (ver expressão 10.2)

$$\left[(\bar{X}_A - \bar{X}_B) - z(\alpha/2) \cdot \sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}, (\bar{X}_A - \bar{X}_B) + z(\alpha/2) \cdot \sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}} \right]. \quad (10.10)$$

Se se admitir que as variâncias das duas populações são iguais, ou seja, que

$$\sigma_A^2 = \sigma_B^2 = \sigma^2,$$

então

$$\bar{X}_A - \bar{X}_B \sim N \left[\mu_A - \mu_B, \left(\frac{\sigma^2}{N_A} + \frac{\sigma^2}{N_B} \right) \right] = N \left[\mu_A - \mu_B, \sigma^2 \cdot \left(\frac{1}{N_A} + \frac{1}{N_B} \right) \right].$$

Neste caso, a expressão 10.10 pode ser refinada. De facto, a variância comum das populações A e B , σ^2 , pode ser estimada por

$$S^2 = \frac{(N_A - 1) \cdot S_A^2 + (N_B - 1) \cdot S_B^2}{N_A + N_B - 2}. \quad (10.11)$$

Como se viu na Secção 9.3.3, este estimador é não-enviesado e, de entre todos aqueles que podem ser obtidos por combinação linear de S_A^2 e S_B^2 , é o que possui variância mínima.

Substituindo S_A^2 e S_B^2 por S^2 na expressão 10.10, o intervalo de confiança a $(1 - \alpha) \cdot 100\%$ para a diferença entre os valores esperados, $\mu_A - \mu_B$, quando as variâncias das populações A e B são iguais, vem

$$\left[(\bar{X}_A - \bar{X}_B) - z(\alpha/2) \cdot S \cdot \sqrt{\frac{1}{N_A} + \frac{1}{N_B}}, (\bar{X}_A - \bar{X}_B) + z(\alpha/2) \cdot S \cdot \sqrt{\frac{1}{N_A} + \frac{1}{N_B}} \right]. \quad (10.12)$$

No capítulo seguinte serão apresentados métodos que permitem verificar formalmente a hipótese da igualdade entre σ_A^2 e σ_B^2 .

Exemplo 10.8

Um campo experimental foi utilizado para testar o crescimento de duas espécies florestais, A e B . Analisaram-se 200 árvores da espécie A com 20 anos de idade, obtendo-se uma altura média de 165 cm e um desvio padrão amostral de 15 cm. Uma amostra de 150 árvores da espécie B , com a mesma idade, conduziu a uma altura média de 161 cm e a um desvio padrão amostral de 12 cm. Pretende-se determinar o intervalo de confiança a 95% para a diferença entre os valores esperados das alturas das duas espécies ao fim de 20 anos, $\mu_A - \mu_B$.

Recorrendo à expressão 10.10, vem:

$$(165 - 161) \pm 1.96 \cdot \sqrt{\frac{15^2}{200} + \frac{12^2}{150}}, \quad \text{ou seja,} \quad 4.0 \pm 2.8.$$

Assim, o intervalo que contém $\mu_A - \mu_B$ com 95% confiança será

$$[1.2, 6.8]$$

(note-se que as hipóteses de as variâncias serem iguais ou diferentes deveriam ter sido testadas. Tal verificação foi, no entanto, omitida, uma vez que este assunto só será abordado no capítulo seguinte).

10.2.5.2 AMOSTRAS INDEPENDENTES DE PEQUENAS DIMENSÕES, POPULAÇÕES NORMAIS

Considerem-se duas populações Normais A e B com valores esperados μ_A e μ_B e variâncias σ_A^2 e σ_B^2 . Admita-se que a partir destas populações se obtiveram amostras independentes de pequenas dimensões N_A e N_B . Neste caso não são válidas as aproximações

$$S_A^2 \approx \sigma_A^2, \quad \text{e} \quad S_B^2 \approx \sigma_B^2,$$

e, nestas condições, a variável

$$\frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}}$$

não segue uma distribuição Normal padronizada.

Seguindo um procedimento paralelo ao adoptado na Secção 10.2.1.2, é possível provar que

$$\frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}} = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\sigma_A^2/N_A + \sigma_B^2/N_B}} \cdot \frac{\sqrt{\sigma_A^2/N_A + \sigma_B^2/N_B}}{\sqrt{S_A^2/N_A + S_B^2/N_B}} \sim \frac{N(0, 1)}{\sqrt{\chi_{GL}^2/GL}} = t_{GL},$$

ou seja, que aquela variável segue uma distribuição t de Student com GL graus de liberdade.

Para definir GL , admita-se, em primeiro lugar, que as variâncias das populações A e B são iguais ($\sigma_A^2 = \sigma_B^2 = \sigma^2$). Neste caso, a variância comum σ^2 pode, tal como anteriormente, ser estimada recorrendo à expressão 10.11, resultando

$$\frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{S \cdot \sqrt{\frac{1}{N_A} + \frac{1}{N_B}}} \sim t_{GL} = t_{N_A + N_B - 2}$$

(note-se que GL representa o número de graus de liberdade com que a variância comum das duas populações, σ^2 , é estimada).

Consequentemente, os limites do intervalo de confiança para $\mu_A - \mu_B$ a $(1 - \alpha) \cdot 100\%$ vêm dados por

$$(\bar{X}_A - \bar{X}_B) \pm t_{N_A + N_B - 2}(\alpha/2) \cdot S \cdot \sqrt{\frac{1}{N_A} + \frac{1}{N_B}}. \quad (10.13)$$

Se a hipótese da igualdade das variâncias não puder ser admitida, a variável

$$t_{GL} = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}}$$

segue *aproximadamente* uma distribuição t de Student com um número de graus de liberdade calculado de acordo com a expressão:

$$GL = \frac{\left(\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B} \right)^2}{\frac{(S_A^2/N_A)^2}{N_A - 1} + \frac{(S_B^2/N_B)^2}{N_B - 1}} \quad (10.14)$$

Quando GL não for um número inteiro, recomenda-se que se adopte o inteiro imediatamente inferior (este procedimento é prudente, já que conduz à definição de um intervalo com uma confiança maior do que a especificada inicialmente).

Note-se que, de acordo com a expressão 10.14, se os valores de S_A^2 e S_B^2 forem muito diferentes e se as amostras possuírem dimensões semelhantes, então o número de graus de liberdade aproximar-se-á de N_A ou de N_B , consoante for maior o valor de S_A^2 ou o de S_B^2 . Se, pelo contrário, as estimativas das variâncias não diferirem muito, GL será próximo de $N_A + N_B - 2$.

Neste caso, o intervalo de confiança para $\mu_A - \mu_B$ a $(1 - \alpha) \cdot 100\%$ vem dado por

$$\left[(\bar{X}_A - \bar{X}_B) - t_{GL}(\alpha/2) \cdot \sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}, (\bar{X}_A - \bar{X}_B) + t_{GL}(\alpha/2) \cdot \sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}} \right] \quad (10.15)$$

Exemplo 10.9

Um determinado método de análise permite determinar o conteúdo de enxofre no petróleo bruto. Os ensaios efectuados em 10 amostras de 1 kg de petróleo bruto, provenientes de furos pertencentes a um determinado campo, revelaram os seguintes resultados (em gramas):

{105, 111, 114, 112, 106, 110, 109, 107, 112, 110}.

As análises efectuadas em 8 amostras de 1 kg de petróleo bruto extraído de furos localizados noutra campo conduziram aos seguintes valores (igualmente em gramas):

{101, 106, 104, 105, 103, 110, 108, 109}.

Qual será o intervalo que inclui, com 95% de confiança, a diferença entre os valores esperados da quantidade de enxofre por quilograma de petróleo proveniente de cada campo? Designe-se o primeiro campo por A e o segundo por B. Assim,

$$\bar{x}_A = 109.60, s_A^2 = 8.267;$$

$$\bar{x}_B = 105.75, s_B^2 = 9.643.$$

Assumindo que as variâncias são iguais, σ^2 é estimada por

$$s^2 = \frac{(N_A - 1) \cdot s_A^2 + (N_B - 1) \cdot s_B^2}{N_A + N_B - 2} = \frac{9 \cdot 8.267 + 7 \cdot 9.643}{10 + 8 - 2} = 8.869.$$

Assumindo ainda a Normalidade das populações e a independência das amostras e recorrendo à expressão 10.13, obtém-se

$$(109.60 - 105.75) \pm t_{16}(0.025) \cdot \sqrt{8.869 \cdot \left(\frac{1}{10} + \frac{1}{8} \right)}$$

Como

$$t_{16}(0.025) = 2.120 \quad (\text{ver Tabela 5 do Anexo «Tabelas»),$$

resulta

$$3.85 \pm 3.00.$$

Assim, pode afirmar-se com 95% de confiança que $\mu_A - \mu_B$ pertence ao intervalo

$$[0.85, 6.85].$$

Em alternativa, se não se admitir que as variâncias são iguais, recorre-se à expressão 10.15, obtendo-se:

$$3.85 \pm t_{GL}(0.025) \cdot \sqrt{\frac{8.267}{10} + \frac{9.643}{8}}.$$

Como

$$GL = \frac{\left(\frac{8.267}{10} + \frac{9.643}{8} \right)^2}{\frac{(8.267/10)^2}{9} + \frac{(9.643/8)^2}{7}} = 14.56 \approx 14$$

e como

$$t_{14}(0.025) = 2.145,$$

resulta

$$3.85 \pm 2.145 \cdot \sqrt{\frac{8.267}{10} + \frac{9.643}{8}}, \quad \text{ou} \quad 3.85 \pm 3.06,$$

ou, finalmente, $\mu_A - \mu_B$ pertence ao intervalo

$$[0.79, 6.91]$$

com *aproximadamente* 95% de confiança (repare-se que, tal como se poderia esperar, este intervalo tem uma amplitude superior à do calculado anteriormente).

10.2.6 INTERVALO DE CONFIANÇA PARA A DIFERENÇA ENTRE PROPORÇÕES BINOMIAIS (AMOSTRAS INDEPENDENTES DE GRANDES DIMENSÕES)

Considerem-se duas populações A e B constituídas por elementos de dois tipos (por exemplo, por peças defeituosas e peças boas). Seja p_A a proporção de elementos de um dos dois tipos na população A (por exemplo, peças defeituosas) e p_B a correspondente proporção na população B. Seja ainda $\hat{P}_A = Y_A / N_A$ um estimador de p_A baseado numa amostra de dimensão N_A e $\hat{P}_B = Y_B / N_B$ um estimador de p_B baseado numa amostra de dimensão N_B . Admita-se ainda que as amostras em causa são independentes.

Como já se viu na Secção 10.2.2, para que as distribuições de $\hat{P}_A$ e de $\hat{P}_B$ possam ser aproximadas por distribuições Normais é necessário que, no caso de populações infinitas ou de amostragens com reposição, se verifique que $N \geq 20$, $N \cdot p > 7$ e $N \cdot q > 7$ (para ambas as populações A e B), e, no caso de populações finitas e de amostragens sem reposição, que as populações possuam, adicionalmente, dimensões grandes em comparação com as das amostras. Dado que se admite que as amostras são independentes, pode afirmar-se que a variável aleatória $\hat{P}_A - \hat{P}_B$ segue também uma distribuição Normal, cujos parâmetros são

$$\mu = p_A - p_B \quad \text{e} \quad \sigma^2 = \frac{p_A \cdot (1 - p_A)}{N_A} + \frac{p_B \cdot (1 - p_B)}{N_B}.$$

Utilizando um procedimento idêntico ao seguido em 10.2.2, os limites do intervalo de confiança para $p_A - p_B$ a $(1 - \alpha) \cdot 100\%$ vêm definidos por

$$\left(\frac{Y_A}{N_A} - \frac{Y_B}{N_B} \right) \pm z(\alpha/2) \cdot \sqrt{\frac{Y_A \cdot (N_A - Y_A)}{N_A^3} + \frac{Y_B \cdot (N_B - Y_B)}{N_B^3}} \quad (10.16)$$

Exemplo 10.10

Uma grande cadeia de venda a retalho pretende comparar os hábitos de compra de homens e mulheres. Uma das variáveis em estudo consiste na proporção de vezes que uma compra é concretizada após a entrada numa loja. Em 45 observações seleccionadas aleatoriamente, os homens realizaram compras 27 vezes. No caso das mulheres, em 74 observações a compra concretizou-se 32 vezes. Com base nestes dados, construa-se o intervalo de confiança a 95% para a diferença entre as proporções de concretização de compras entre homens e mulheres.

Assim,

$$\hat{p}_H = \frac{y_H}{N_H} = \frac{27}{45} \quad \text{e} \quad \hat{p}_M = \frac{y_M}{N_M} = \frac{32}{74}.$$

Substituindo estes valores na expressão 10.16 e atendendo a que $z(0.025) = 1.96$, obtém-se

$$\left(\frac{27}{45} - \frac{32}{74} \right) \pm 1.96 \cdot \sqrt{\frac{27 \cdot (45 - 27)}{45^3} + \frac{32 \cdot (74 - 32)}{74^3}},$$

ou seja, $p_H - p_M$ pertence ao intervalo

$$[-1.47\%, 34.99\%]$$

com 95% de confiança.

10.3 DIMENSIONAMENTO DE AMOSTRAS

Até este momento, sempre se assumiu que as dimensões das amostras utilizadas no cálculo das estimativas pontuais são conhecidas à partida. De facto, ainda não foi referido de forma explícita o problema da determinação de tais dimensões. No entanto, a resolução deste problema tem um enorme interesse prático, já que:

- recolher e tratar uma amostra grande de mais para os resultados que se pretendem obter, constitui um evidente desperdício de recursos, e
- recolher uma amostra cuja dimensão não é suficiente para se poderem tirar conclusões, constitui um erro.

A dimensão requerida para as amostras aumentará naturalmente, à medida que aumentem os seguintes parâmetros (um a um ou simultaneamente):

- a precisão do intervalo de confiança (que varia na razão inversa da sua amplitude) e
- o grau de confiança do intervalo (isto é a probabilidade de este vir a incluir o parâmetro).

A forma de dimensionar amostras será introduzida com base no seguinte exemplo.

Exemplo 10.11

A proporção de peças defeituosas à saída de uma linha de fabrico será estimada a partir de um lote de peças constituído para esse efeito. Qual deverá ser a dimensão do lote para que a amplitude do intervalo de confiança a 95% para a proporção de peças defeituosas não ultrapasse 0.02?

De acordo com a expressão 10.7, os limites do intervalo de confiança da proporção Binomial são

$$\frac{Y}{N} \pm z(\alpha/2) \cdot \sqrt{\frac{Y \cdot (N - Y)}{N^3}}.$$

Como se pretende uma estimativa com 95% de confiança e um intervalo de confiança com uma amplitude máxima de 2%, vem:

$$z(\alpha/2) = z(0.025) = 1.96 \quad \text{e} \quad 1.96 \cdot \sqrt{\frac{Y \cdot (N - Y)}{N^3}} < 0.01.$$

Para resolver esta inequação e determinar N , é necessário dispor de uma estimativa de p . Uma solução consiste em recolher uma amostra piloto cuja dimensão é fixada arbitrariamente. Admita-se que, a partir de uma amostra de dimensão $N = 300$, se obteve $y = 30$, ou $\hat{p} = y/N = 0.1$. Substituindo y por $\hat{p} \cdot N = 0.1 \cdot N$, vem

$$1.96^2 \cdot \frac{0.1 \cdot N \cdot (N - 0.1 \cdot N)}{N^3} < 0.01^2$$

$$\frac{0.1 \cdot 0.9}{N} < \left(\frac{0.01}{1.96} \right)^2$$

$$N > \frac{0.1 \cdot 0.9}{\left(\frac{0.01}{1.96} \right)^2} = 3457.4$$

ou, finalmente,

$$N \geq 3458.$$

Em relação à forma como N foi determinado, é oportuno fazer os seguintes comentários:

- a amostra piloto de 300 peças poderia (e deveria) ser integrada na amostra final;
- seria mais razoável que, à medida que a amostra final fosse sendo constituída, a proporção p fosse progressivamente reestimada e o valor de N fosse sucessivamente corrigido.

Note-se que o método que acaba de se expor tem uma limitação: em certas circunstâncias, não é prático ou é mesmo inexequível constituir uma amostra piloto para estimar p .

Exemplo 10.12

Uma estação de rádio pretende efectuar, no mesmo dia em que se realizam as eleições, uma previsão da votação num novo candidato à presidência da Câmara de uma cidade. As intenções de voto serão recolhidas «à boca da urna», ou seja, imediatamente após os eleitores terem efectivamente votado. Quantos eleitores deverão ser inquiridos se se pretender obter um intervalo de confiança para a proporção de votantes no candidato com uma semi-amplitude de 0.01 e um grau de confiança de 95%?

Recorde-se que de acordo com os pressupostos definidos na Secção 10.2.2, a distribuição da proporção amostral, $\hat{P}$, segue uma distribuição Normal com valor esperado p e variância $[p \cdot (1 - p)]/N$. É imediato verificar que a variância de $\hat{P}$ apresenta o seu valor


máximo quando $p = 0.5$. Então, quando p não puder ser estimada *a priori*, a dimensão da amostra deve ser especificada para $\hat{P} = Y/N = 0.5$ (que induz uma amplitude máxima para o intervalo ou, para uma amplitude pré-fixada, induz uma dimensão máxima da amostra). Recorrendo à expressão 10.6, e fazendo $z(0.025) = 1.96$, vem

$$1.96 \cdot \sqrt{\frac{Y \cdot (N - Y)}{N^3}} = 1.96 \cdot \sqrt{\frac{0.5 \cdot N \cdot (N - 0.5 \cdot N)}{N^3}} < 0.01,$$

ou seja,

$$n \geq 9604.$$

Note-se que este procedimento conduz a uma dimensão amostral eventualmente superior àquela que seria necessária se se dispusesse de mais informação sobre a população em causa. No entanto, esta dimensão da amostra garante que se cumpre a condição imposta relativamente à precisão da estimativa e ainda que a confiança a depositar no resultado não seja inferior à especificada.



Apêndice

APÊNDICE 10.1 JUSTIFICAÇÃO DA EXPRESSÃO 10.4

A expressão em causa,

$$(N-1) \cdot \frac{S^2}{\sigma^2} \sim \chi_{N-1}^2,$$

não será demonstrada de uma forma completa, por se considerar que tal ultrapassaria o âmbito deste texto. No entanto, os aspectos fundamentais dessa demonstração são apresentados em seguida.

(1) Seja

$$\bar{X} = \sum_{n=1}^N \frac{X_n}{N}$$

e seja μ uma constante qualquer. Então,

$$\begin{aligned} \sum_{n=1}^N (X_n - \mu)^2 &= \sum_{n=1}^N [(X_n - \bar{X}) + (\bar{X} - \mu)]^2 \\ &= \sum_{n=1}^N (X_n - \bar{X})^2 + 2 \cdot \sum_{n=1}^N (X_n - \bar{X}) \cdot (\bar{X} - \mu) + \sum_{n=1}^N (\bar{X} - \mu)^2 \\ &= \sum_{n=1}^N (X_n - \bar{X})^2 + 2 \cdot (\bar{X} - \mu) \cdot \sum_{n=1}^N (X_n - \bar{X}) + N \cdot (\bar{X} - \mu)^2. \end{aligned}$$

Mas, como

$$\sum_{n=1}^N (X_n - \bar{X}) = 0,$$

vem

$$\sum_{n=1}^N (X_n - \mu)^2 = \sum_{n=1}^N (X_n - \bar{X})^2 + N \cdot (\bar{X} - \mu)^2. \quad (\text{A10.1.1})$$

(2) Seja $X_1, X_2, \dots, X_N$ uma amostra de dimensão N , proveniente de uma população $N(0, \sigma^2)$. Da expressão A10.1.1 decorre directamente que

$$\frac{\sum_{n=1}^N (X_n - \mu)^2}{\sigma^2} = \frac{\sum_{n=1}^N (X_n - \bar{X})^2}{\sigma^2} + \frac{N \cdot (\bar{X} - \mu)^2}{\sigma^2}$$

ou, equivalentemente, que

$$\sum_{n=1}^N \left(\frac{X_n - \mu}{\sigma} \right)^2 = \sum_{n=1}^N \left(\frac{X_n - \bar{X}}{\sigma} \right)^2 + \left[\frac{\sqrt{N} \cdot (\bar{X} - \mu)}{\sigma} \right]^2. \quad (\text{A10.1.2})$$

(3) Uma vez que as variáveis

$$\frac{X_n - \mu}{\sigma} \quad (n = 1, \dots, N)$$

são Normais padronizadas e independentes, e atendendo à definição da distribuição do Qui-quadrado (ver Secção 7.6), é imediato verificar que

$$\sum_{n=1}^N \left(\frac{X_n - \mu}{\sigma} \right)^2 \sim \chi_N^2. \quad (\text{A10.1.3})$$

(4) Por outro lado,

$$\frac{\sqrt{N} \cdot (\bar{X} - \mu)}{\sigma}$$

é também uma variável Normal padronizada, o que implica que

$$\left[\frac{\sqrt{N} \cdot (\bar{X} - \mu)}{\sigma} \right]^2 \sim \chi_1^2.$$

(5) A expressão A10.1.2 é então do seguinte tipo:

$$\chi_N^2 = \sum_{n=1}^N \left(\frac{X_n - \bar{X}}{\sigma} \right)^2 + \chi_1^2.$$

(6) Da definição das variáveis Qui-quadrado decorre directamente (ver expressão 7.13) que a soma de duas variáveis $\chi_{GL_1}^2$ e $\chi_{GL_2}^2$ independentes é também uma variável Qui-quadrado, com $GL_1 + GL_2$ graus de liberdade. É ainda possível demonstrar que os dois termos do segundo membro da expressão A10.1.2 são independentes. Nestas condições, o termo representado pelo somatório


$$\sum_{n=1}^N \left(\frac{X_n - \bar{X}}{\sigma} \right)^2$$

segue uma distribuição Qui-quadrado com $N - 1$ graus de liberdade. Mas, como

$$(N - 1) \cdot \frac{S^2}{\sigma^2} = \sum_{n=1}^N \left(\frac{X_n - \bar{X}}{\sigma} \right)^2 \quad (\text{ver 10.2.1.2}),$$

vem, finalmente,

$$(N - 1) \cdot \frac{S^2}{\sigma^2} \sim \chi_{N-1}^2 \quad (\text{expressão 10.4}).$$



Problemas

10.1. Um conjunto de 140 condutores de camião, escolhidos aleatoriamente nas estradas nacionais, dispôs-se a participar numa experiência que tinha por objectivo medir os seus tempos de reacção depois do almoço. A média e o desvio padrão dos tempos observados foram, respectivamente, 0.85 e 0.20 segundos.

Determine o intervalo de confiança a 95% para o valor esperado do tempo de reacção dos condutores em causa, após o almoço.

10.2. A empresa SCB controla regularmente a resistência à rotura dos cabos por si produzidos. Recentemente, foram analisadas as tensões de rotura de 10 cabos SCB-33R seleccionados aleatoriamente a partir de um lote de grandes dimensões, tendo sido obtidos os seguintes resultados:

$$\begin{cases} \bar{x} = 4537 \text{ kg/cm}^2 \\ s = 112 \text{ kg/cm}^2. \end{cases}$$

O director comercial pretende saber qual o intervalo de confiança (aberto à direita), a 95%, para o valor esperado da tensão de rotura dos cabos do lote em causa. Defina esse intervalo.

10.3. No âmbito do estudo de uma determinada operação de montagem, recolheram-se 25 observações do tempo necessário para a sua realização. A variância amostral obtida foi de $(0.3 \text{ horas})^2$.

Construa os intervalos de confiança a 90, 95 e 99% para a variância dos tempos de montagem, indicando as hipóteses subjacentes à construção destes intervalos.

10.4. O director fabril de uma empresa industrial que emprega 4000 operários emitiu um novo conjunto de normas internas de segurança. Passada uma semana, seleccionou aleatoriamente 300 operários e verificou que apenas 75 deles conheciam suficientemente bem as normas em causa.

Construa um intervalo de confiança a 95% para a proporção dos operários que conheciam adequadamente o conjunto de normas, uma semana após a sua emissão.

10.5. O gerente de um banco está interessado em analisar a diferença entre os valores esperados dos saldos das contas à ordem de duas das suas agências. De cada uma delas foi recolhida uma amostra aleatória de saldos, tendo-se registado os seguintes resultados:

Agência A: Dimensão da amostra: $N_A = 17$

$$\begin{cases} \bar{x}_A = 48.2 \text{ euros} \\ s_A = 2.74 \text{ euros} \end{cases}$$

Agência B: Dimensão da amostra: $N_B = 13$

$$\begin{cases} \bar{x}_B = 41.5 \text{ euros} \\ s_B = 3.91 \text{ euros.} \end{cases}$$

Calcule os intervalos de confiança a 90% e a 95% para a diferença entre os valores esperados dos saldos à ordem das agências A e B.

- 10.6. No âmbito de um inquérito efectuado com o objectivo de medir a audiência de um semanário, foram inquiridos 350 quadros superiores da função pública e 325 gestores de empresas. Uns e outros foram seleccionados aleatoriamente.

De entre os primeiros, 105 declararam que tinham lido a última edição. Para os segundos, aquele número foi de 130.

Defina um intervalo de confiança a 99% para a diferença entre as proporções reais de gestores e de quadros da função pública que leram a última edição do semanário em causa.

- 10.7. O gabinete de projecto de uma empresa de material de construção civil pretende estimar a tensão de rotura do material utilizado num determinado tipo de tubos.

Com base num vasto conjunto de ensaios realizados no passado, estima-se que o desvio padrão da tensão de rotura do material em causa é de 70 psi.

Deseja-se definir um intervalo de confiança a 99% para o valor esperado da tensão de rotura, pretendendo-se que a sua amplitude não exceda 60 psi. Qual o número de ensaios necessário para definir este intervalo?

- 10.8. A direcção de uma Faculdade dispõe-se a oferecer aos seus 3800 alunos a possibilidade de estes frequentarem aulas ao sábado de manhã, se a procura para este horário for suficientemente alta.

Qual a dimensão apropriada da amostra de alunos a inquirir, para que a amplitude do intervalo de confiança a 95% para a proporção de alunos com interesse por aquele horário não exceda 0.1?

Admita que não existe qualquer estimativa desta proporção e que não há tempo para recolher uma amostra piloto.



Teste de Hipóteses

11.1 INTRODUÇÃO. ANÁLISE DO PROCEDIMENTO BÁSICO ENVOLVIDO NO TESTE DE HIPÓTESES

Os procedimentos apresentados nos dois capítulos anteriores permitem definir estimativas (pontuais ou por intervalo) de parâmetros populacionais. Será agora apresentado um outro procedimento de Inferência Estatística — o teste de hipóteses — cujo objectivo fundamental é o de verificar se dados amostrais (ou estimativas obtidas a partir deles) são ou não compatíveis com determinadas populações (ou com valores previamente fixados dos correspondentes parâmetros populacionais). O resultado do teste corresponde inevitavelmente a uma das duas respostas possíveis para aquela questão: afirmativa ou negativa. Em ambos os casos corre-se o risco de errar. Uma das características do teste de hipóteses é, justamente, a de permitir controlar ou minimizar tal risco.

Para facilitar a compreensão da metodologia utilizada no teste de hipóteses, o procedimento básico nela envolvido será decomposto em quatro fases, designadamente:

- (i) Definição das hipóteses.
- (ii) Identificação da estatística de teste e caracterização da sua distribuição.
- (iii) Definição da regra de decisão, com especificação do nível de significância do teste.
- (iv) Cálculo da estatística de teste e tomada de decisão.

Nos pontos seguintes apresenta-se em detalhe cada uma destas fases.

11.1.1 DEFINIÇÃO DAS HIPÓTESES

Uma hipótese pode ser definida neste contexto como uma *conjectura* acerca de uma ou mais populações. Neste capítulo apenas serão considerados testes envolvendo hipóteses relativas ao valor de um parâmetro populacional ou à comparação entre parâmetros pertencentes a duas populações. No capítulo seguinte — Testes Não-Paramétricos — o teste de hipóteses será alargado a hipóteses que não envolvam parâmetros populacionais. No Capítulo 13 — Análise de Variância — apresentar-se-á uma técnica que permite testar hipóteses relativas a parâmetros pertencentes a mais do que duas populações.

Para ilustrar o conceito de hipótese em Estatística, considere-se o seguinte exemplo.

Exemplo 11.1

Numa determinada empresa industrial, uma peça é fabricada automaticamente, em grandes quantidades, por duas máquinas A e B, que se distinguem apenas pelo facto de a máquina A ser mais velha (e mais usada) do que a máquina B. Coloca-se a questão de saber se as proporções de peças defeituosas produzidas em A e B são ou não idênticas.

Tendo por base este exemplo, enunciam-se seguidamente algumas das hipóteses que poderiam ser colocadas envolvendo os parâmetros «proporções de peças defeituosas» das quantidades produzidas em A e B:

$$p_A = p_B \quad p_A \neq p_B \quad p_A < p_B \quad p_A > p_B.$$

No Exemplo 11.1 está implícita a vontade de verificar se o «cansaço» da máquina A se reflecte num aumento de peças defeituosas. Isto é, pretende-se verificar se é válida a hipótese colocada em último lugar, $p_A > p_B$. Esta hipótese será designada por **hipótese alternativa** ou H_1 , escrevendo-se

$$H_1: p_A > p_B.$$

Uma vez especificada a hipótese que se pretende verificar (neste caso, se a afirmação contida em H_1 é ou não válida), define-se a hipótese complementar de H_1 que se designa por **hipótese nula** ou H_0 . Continuando a seguir o Exemplo 11.1, no qual se considerou que apenas a idade permitia distinguir as duas máquinas, se se admitir que o envelhecimento de uma máquina só pode contribuir para o aumento da proporção de defeituosas, então a hipótese nula (complementar de H_1 , recorde-se) seria a de que a proporção de defeituosas não viria afectada pelo envelhecimento:

$$H_0: p_A = p_B$$

(note-se que, neste caso, seria destituída de sentido incluir na hipótese nula a possibilidade de ser $p_A < p_B$).

A estratégia básica seguida no método do teste de hipóteses consiste em tentar suportar a validade de H_1 , uma vez provada a inverosimilhança de H_0 . Por outras palavras, conseguindo-se mostrar que, com uma elevada probabilidade, a hipótese nula é falsa, fica assim corroborada a validade da hipótese alternativa. Se, pelo contrário, não se puder rejeitar H_0 , a hipótese H_1 não será reforçada pelo teste.

Em relação à formulação das hipóteses, é importante notar os pontos seguintes:

- A hipótese alternativa contém sempre uma desigualdade (que se traduz pelos sinais $>$ ou $<$) ou uma não-igualdade (sinal $\neq$), mas *nunca* uma igualdade (sinal $=$). No Exemplo 11.1 fez-se $H_1: p_A > p_B$ e não $p_A \neq p_B$ ou mesmo $p_A < p_B$, porque se considerou que o efeito da idade só poderia ser o de deteriorar as máquinas, aumentando a proporção de defeituosas.
- A hipótese nula é considerada verdadeira ao longo do procedimento de teste até ao momento em que haja evidência estatística clara apontando em sentido contrário. Neste caso (isto é, quando se rejeitar H_0), aceita-se como válida a hipótese alternativa (visto que se admite que esta é a hipótese complementar de H_0).
- A hipótese nula contém *sempre* uma igualdade. Note-se que em relação ao Exemplo 11.1, se se tivesse admitido que existiam outros factores capazes de influenciar a proporção de defeituosas no sentido contrário ao da idade (ou seja, capazes de diminuir a proporção de defeituosas), seria razoável definir H_0 como $p_A \leq p_B$. No entanto, mesmo quando na hipótese nula faz sentido figurar o sinal $\geq$ ou o sinal $\leq$, o teste é efectuado considerando apenas a situação em que H_0 mais se aproxima de H_1 , ou seja, supondo que é verdadeira a afirmação de H_0 que corresponde à igualdade. No Exemplo 11.1, mesmo que a hipótese nula fosse formulada como $H_0: p_A \leq p_B$, só se consideraria a hipótese $p_A = p_B$. Se fosse possível concluir que esta hipótese era falsa, por maioria de razão concluir-se-ia que todas as outras, que se afastam mais de H_1 , seriam também falsas.
- Quando a hipótese alternativa contiver uma desigualdade (sinal $>$ ou sinal $<$), o teste diz-se **unilateral** (à direita, para o sinal $>$, à esquerda para o sinal $<$). Quando H_1 envolver uma não igualdade (sinal $\neq$), o teste diz-se **bilateral**. No caso do Exemplo 11.1, dado que H_1 é $p_A > p_B$, o teste é unilateral à direita.

11.1.2 IDENTIFICAÇÃO DA ESTATÍSTICA DE TESTE E CARACTERIZAÇÃO DA SUA DISTRIBUIÇÃO

A estatística que é utilizada para verificar a plausibilidade da hipótese nula designa-se por **estatística de teste** (sendo aqui denotada por ET). Para que tal estatística possa cumprir a sua função, é necessário conhecer a sua distribuição quando se admitir que é verdadeira a hipótese nula.

Exemplo 11.2

Retorne-se o Exemplo 11.1, para o qual foram formuladas as seguintes hipóteses:

$$H_0: p_A = p_B$$

$$H_1: p_A > p_B.$$

A estatística que corresponde ao parâmetro «proporção populacional» é a «proporção amostral». Assim, é apropriada a adopção de uma estatística de teste baseada na «diferença entre proporções amostrais»,

$$\frac{Y_A}{N_A} - \frac{Y_B}{N_B},$$

onde

N_A : dimensão de uma amostra de peças produzidas na máquina A;

Y_A : número de peças defeituosas incluídas na amostra anterior (de dimensão N_A);

N_B : dimensão de uma amostra de peças produzidas na máquina B;

Y_B : número de peças defeituosas incluídas na amostra anterior (de dimensão N_B).

Se se admitir que as amostras são de grandes dimensões e que foram constituídas independentemente uma do outra, então

$$\frac{Y_A}{N_A} - \frac{Y_B}{N_B} \sim N(\mu, \sigma^2),$$

em que

$$\mu = p_A - p_B \quad \text{e} \quad \sigma^2 = \frac{p_A \cdot (1 - p_A)}{N_A} + \frac{p_B \cdot (1 - p_B)}{N_B}.$$

No caso particular de a hipótese nula ser $H_0: p_A = p_B$ (ou $H_0: p_A - p_B = 0$), o que corresponde à situação em apreço, a expressão de σ^2 pode ser refinada. De facto, se H_0 for verdadeira, então $p_A = p_B = p_0$. Nestas condições, substituindo p_A e p_B por p_0 , a variância de $Y_A/N_A - Y_B/N_B$ resulta:

$$\sigma^2 = \frac{p_0 \cdot (1 - p_0)}{N_A} + \frac{p_0 \cdot (1 - p_0)}{N_B}.$$

Assim, se a hipótese nula $H_0: p_A - p_B = 0$ for verdadeira, virá

$$\frac{Y_A}{N_A} - \frac{Y_B}{N_B} \sim N\left(0, \sigma^2 = \frac{p_0 \cdot (1 - p_0)}{N_A} + \frac{p_0 \cdot (1 - p_0)}{N_B}\right).$$

Embora a «diferença entre proporções amostrais» pudesse servir como estatística de teste, é mais cómodo recorrer à diferença padronizada. A expressão da estatística de teste será então

$$ET = \frac{\left(\frac{Y_A}{N_A} - \frac{Y_B}{N_B}\right) - 0}{\sqrt{\frac{p_0 \cdot (1 - p_0)}{N_A} + \frac{p_0 \cdot (1 - p_0)}{N_B}}} \sim N(0, 1).$$

Ora, sendo H_0 verdadeira, Y_A e Y_B serão provenientes de distribuições binomiais com o mesmo parâmetro p_0 , cujo valor é estimado por:

$$\hat{p}_0 = \frac{Y_A + Y_B}{N_A + N_B}.$$

Como as dimensões das amostras são grandes, a expressão da estatística de teste pode ser reescrita, resultando finalmente

$$ET = \frac{\left(\frac{Y_A}{N_A} - \frac{Y_B}{N_B}\right) - 0}{\sqrt{\hat{p}_0 \cdot (1 - \hat{p}_0) \cdot \left(\frac{1}{N_A} + \frac{1}{N_B}\right)}} \sim N(0, 1). \quad (11.1)$$

Identificada a distribuição da estatística de teste quando se admite que H_0 é verdadeira, é fácil compreender o modo como tal estatística será utilizada para verificar a plausibilidade daquela hipótese.

Admita-se, por exemplo, que a estatística definida na expressão 11.1 tomava o valor 5.5. Embora tal pudesse suceder, o valor da estatística de teste (que nestas condições seria absolutamente extremo, dado que se trata de uma variável $N(0, 1)$) indicia que é mais razoável admitir que H_1 é verdadeira. A formalização do procedimento que conduz à rejeição ou à não-rejeição de H_0 será apresentada nas secções seguintes.

11.1.3 DEFINIÇÃO DA REGRA DE DECISÃO. ERRO DO TIPO I E ESPECIFICAÇÃO DO NÍVEL DE SIGNIFICÂNCIA

A decisão de rejeitar ou não a hipótese nula fundamenta-se no valor que a estatística de teste toma (recorde-se que a distribuição da estatística de teste é especificada na suposição de que H_0 é verdadeira). Se, no caso de a hipótese nula ser válida, o valor da ET for muito improvável e, pelo contrário, aquele valor for razoavelmente provável quando se verificar a hipótese alternativa, então H_0 deverá ser rejeitada em favor de H_1 . Para que esta decisão possa ser tomada de uma forma controlada, é conveniente que, à partida, se fixe o valor a partir do qual se considera improvável a validade da hipótese nula. Tal fixação corresponde à definição da **regra de decisão** para o teste.

A formalização desta regra passa pela especificação de uma **região de rejeição**. O modo de definir a região de rejeição e o seu significado serão ilustrados considerando o seguinte exemplo.

Exemplo 11.3

Retomando o Exemplo 11.1 e de acordo com o que foi já referido, se a hipótese nula $H_0: p_A = p_B$ for verdadeira, a estatística de teste, ET , segue uma distribuição Normal padronizada. A região assinalada na Figura 11.1 corresponde a valores de ET que, se H_0 for verdadeira, ocorrem com baixa probabilidade (são valores extremos). Simultaneamente, tais valores de ET são mais plausíveis se a hipótese alternativa $H_1: p_A > p_B$ for verdadeira. A região assinalada corresponderá à **região de rejeição**, desde que seja adoptada a seguinte **regra de decisão**:

- se o valor calculado para a estatística de teste pertencer à região de rejeição — isto é, se $ET > ET(\alpha)$ (ver Figura 11.1) — então a hipótese nula será rejeitada (note-se que $ET(\alpha)$ se designa habitualmente por **valor crítico** da estatística de teste);
- se a estatística de teste não se situar dentro da região de rejeição, então a hipótese nula não será rejeitada (e o resultado do teste dir-se-á **inconclusivo**).

A probabilidade α de, no caso de H_0 ser verdadeira, a ET pertencer à região de rejeição designa-se por **nível de significância** do teste. O nível de significância representa, então, a probabilidade (ou o risco) de se incorrer no erro de rejeitar H_0 quando esta hipótese é, de facto, verdadeira. Esse erro é o que se designa por **erro do tipo I**.

Retomando o exemplo anterior, cometer um erro do tipo I significaria admitir que a máquina A seria pior do que a máquina B, quando as proporções de peças rejeitadas produzidas por ambas as máquinas fossem, de facto, idênticas.

A região de rejeição que se representa na Figura 11.1 concentra-se na cauda direita da distribuição da estatística de teste. Este facto resulta de o teste considerado ser unilateral à direita (recorde-se que $H_1: p_A > p_B$). Se o teste fosse bilateral, ou seja, se a hipótese alternativa fosse $H_1: p_A \neq p_B$, a região de rejeição deveria cobrir as duas caudas da distribuição de ET , tal como se representa na Figura 11.2, para o nível de significância α .

Embora se possa atribuir ao nível de significância um valor qualquer situado entre 0 e 1, os valores mais frequentes são $\alpha = 0.05$ (5%) e $\alpha = 0.01$ (1%).

Figura 11.1
Região de rejeição de H_0 (teste unilateral à direita).





Figura 11.2
Região de rejeição de H_0 para um teste bilateral.



11.1.4 CÁLCULO DA ESTATÍSTICA DE TESTE E TOMADA DE DECISÃO

A última fase do teste de hipóteses corresponde ao cálculo da estatística de teste e, face ao valor obtido, à aplicação da regra de decisão.

Exemplo 11.4

Voltando ao exemplo anterior e admitindo que se tinha fixado para o nível de significância o valor 5% (que corresponde a $ET(\alpha) = 1.645$), a regra de decisão seria:

- rejeitar H_0 e aceitar H_1 se $ET > 1.645$;
- não rejeitar H_0 se $ET \leq 1.645$ (na prática considera-se nula a probabilidade de $ET = 1.645$, pelo que bastará escrever $ET < 1.645$).

Suponha-se agora que se recolheram duas amostras, sendo cada uma delas constituída por 100 peças produzidas em cada uma das máquinas, e que se encontraram nove peças defeituosas na amostra proveniente de A e duas na proveniente de B. Substituindo estes valores na expressão 11.1, resulta

$$ET = \frac{0.09 - 0.02}{\sqrt{0.055 \cdot 0.945 \cdot \frac{2}{100}}} = 2.171.$$

Como este valor é superior ao valor crítico (1.645), a hipótese nula é rejeitada.

Perante o resultado obtido no teste, haveria que desencadear as acções correspondentes. Tais acções dependerão, naturalmente, das características particulares de cada problema. Por exemplo, tomando por referência o caso que vem sendo analisado, se a hipótese nula fosse rejeitada (ou seja, se se admitisse que $p_A > p_B$) faria sentido estudar a viabilidade da substituição da máquina A por uma nova. Note-se, no entanto, que se H_0 não fosse rejeitada com base nas amostras recolhidas, isso não significaria que a máquina A produzisse necessariamente a mesma proporção de peças defeituosas que a máquina B. Neste caso, a acção correcta poderia ser a de recolher mais informação (em vez de, simplesmente, manter a máquina A em serviço).

11.2 VALOR DE PROVA

De acordo com o procedimento anteriormente descrito para o teste de hipóteses, no final toma-se uma decisão de *rejeição* ou de *não-rejeição* da hipótese nula. Esta dicotomia é, na realidade, artificial. De facto

- (i) a fixação de um nível de significância é francamente arbitrária, e
- (ii) os dados amostrais podem contradizer a hipótese nula em maior ou menor grau.

O **valor de prova** (ou **valor P**) constitui uma medida do grau com que os dados amostrais contradizem a hipótese nula. A sua definição é a seguinte: o valor de prova corresponde à probabilidade de a estatística de teste tomar um valor igual ou mais extremo do que aquele que, de facto, é observado. Note-se que, tal como a estatística de teste, o valor de prova é calculado admitindo que H_0 é verdadeira.


Exemplo 11.5

No Exemplo 11.4, a estatística de teste tomou o valor $ET = 2.171$ (recorde-se que o nível de significância do teste era $\alpha = 5\%$ e o correspondente valor crítico $ET(\alpha) = 1.645$). De acordo com a definição apresentada, o valor de prova é

$$P[ET \geq 2.171 | H_0] \approx 0.0150 \quad (\text{ver Tabela 3 do Anexo «Tabelas»}).$$

O significado do valor de prova é ilustrado na Figura 11.3.

Figura 11.3
Valor de prova
(Exemplo 11.5).



Como é evidente, quanto menor for o valor de prova maior será o grau com que a hipótese nula é contradita. Dada a relevância da informação contida no valor de prova, é recomendável a sua inclusão explícita nos resultados de qualquer teste de hipóteses. Por exemplo, muito mais esclarecedor do que dizer que uma hipótese nula foi rejeitada ao nível de significância de 5% é afirmar que isso sucedeu e que o valor de prova foi, suponha-se, de 0.3%.

Quando o teste é bilateral, no cálculo do valor de prova devem tomar-se em consideração ambas as caudas da distribuição da estatística de teste.

Exemplo 11.6

Se, ao contrário da situação contemplada no exemplo anterior (em que o teste era unilateral à direita), as hipóteses configurassem o seguinte teste bilateral


$$\begin{aligned} H_0: p_A &= p_B \\ H_1: p_A &\neq p_B, \end{aligned}$$

e admitindo ainda que $ET = 1.965$, então o valor de prova seria

$$P[ET \leq -2.171 | H_0 \text{ ou } ET \geq 2.171 | H_0] \approx 2 \cdot 0.015 = 0.03.$$

O significado do valor de prova para este teste bilateral (em que $\alpha = 5\%$) é ilustrado na Figura 11.4.

Figura 11.4
Valor de prova num
teste bilateral
(Exemplo 11.6).



11.3 ERRO DO TIPO II. POTÊNCIA DO TESTE

Foi anteriormente referida a possibilidade de, no teste de hipóteses, se cometer um erro do tipo I: ou seja, de se *rejeitar H_0 quando esta hipótese é, de facto, verdadeira*. O risco de se incorrer neste tipo de erro foi designado por nível de significância e denotado por α .

Existe ainda a possibilidade de se cometer um outro tipo de erro no teste de hipóteses: o que corresponde a *não se rejeitar H_0 quando a hipótese alternativa, H_1 , é verdadeira*. Este erro é designado por **erro do tipo II** e a probabilidade de nele se incorrer é denotada por β .

Na Tabela 11.1 apresentam-se os resultados possíveis associados a um teste de hipóteses.

Tabela 11.1
Resultados
possíveis de um
teste de hipóteses.

	H_0 verdadeira	H_0 falsa
H_0 rejeitada	Erro do Tipo I (probabilidade α)	Decisão Correcta (probabilidade $1 - \beta$)
H_0 não rejeitada	Decisão Correcta (probabilidade $1 - \alpha$)	Erro do Tipo II (probabilidade β)

A diferença $1 - \beta$ traduz a probabilidade de rejeitar H_0 quando ela é falsa. Atendendo ao seu significado — a probabilidade de, correctamente, rejeitar uma hipótese nula falsa —, tal diferença designa-se por **potência do teste**.

Exemplo 11.7

Retome-se o caso tratado nos exemplos anteriores. Admita-se que, ao nível de significância de 5%, se pretende efectuar um teste a partir de amostras de grandes dimensões, envolvendo as seguintes hipóteses:

$$\begin{aligned} H_0: p_A - p_B &= 0 \\ H_1: p_A - p_B &> 0. \end{aligned}$$

O teste é unilateral à direita e a região de rejeição de H_0 é definida por

$$ET > 1.645 \quad (\text{ver expressão 11.1 e Exemplo 11.4}).$$

Consequentemente, a região de não rejeição de H_0 é

$$ET < 1.645.$$

Admita-se agora que $H_0: p_A - p_B = 0$ é falsa e que, em particular, a hipótese alternativa toma o seguinte valor

$$H_1: p_A - p_B = \sigma,$$

com σ representando o desvio padrão da variável «diferença entre proporções amostrais».

Nestas condições, faz todo o sentido determinar a probabilidade de se incorrer num erro do tipo II (β), ou seja, de não se rejeitar H_0 que é falsa. Esta questão é complementar à determinação da potência do teste ($1 - \beta$), que corresponde à probabilidade de se rejeitar H_0 admitindo como verdadeira a H_1 que foi especificada.

Denote-se por X a variável aleatória «diferença entre proporções amostrais». Como se viu no Exemplo 11.2, esta variável segue uma distribuição Normal. Trata-se então de calcular a probabilidade de X tomar valores pertencentes à região de rejeição de H_0 . O valor crítico da distribuição de X (que se denotará por $X_{\text{crítico}}$) que corresponde a $ET(\alpha = 5\%) = 1.645$, determina-se muito facilmente:

$$ET(\alpha = 5\%) = 1.645 = Z = \frac{X - \mu_X | H_0}{\sigma_X} = \frac{X_{\text{crítico}} - 0}{\sigma}$$

(recorde-se que quando H_0 é verdadeira $\mu_X = 0$ e $\sigma_X = \sigma$), pelo que

$$X_{\text{crítico}} = 1.645 \cdot \sigma.$$

No caso particular de prevalecer $H_1: p_A - p_B = \sigma$, a potência do teste ($1 - \beta$) traduz a probabilidade de X ser maior (ou igual) a $X_{\text{crítico}} = 1.645 \cdot \sigma$. Dado que, nestas circunstâncias, os parâmetros da distribuição de X são $\mu_X = \sigma$ e $\sigma_X = \sigma$, a potência é então:

$$1 - \beta = P \left[Z = \frac{X - \mu_X | H_1}{\sigma_X} \geq \frac{(1.645 \cdot \sigma - \sigma)}{\sigma} \right] = P[Z \geq 0.645] = 0.26.$$

Ou seja, a probabilidade de se incorrer num erro do tipo II é

$$\beta = 1 - 0.26 = 0.74.$$

Esta situação encontra-se ilustrada no diagrama (i) da Figura 11.5.

Suponha-se agora que se reduzira o nível de significância de 5% para 1%. A região de não rejeição de H_0 seria então

$$ET < 2.33 \quad (\text{ver Tabela 3 do «Anexo Tabelas»}).$$

Mantendo o pressuposto de que $p_A = p_B + \sigma$, a probabilidade de se incorrer num erro de tipo II seria, neste caso, de:

$$\beta = P \left[Z = \frac{X - \mu_X | H_1}{\sigma_X} < \frac{(2.33 \cdot \sigma - \sigma)}{\sigma} \right] = P[Z < 1.33] = 0.908.$$

O diagrama (ii) da Figura 11.5 ilustra esta última situação.

Figura 11.5
Riscos α e β
(Exemplo 11.7).

(i) Teste com nível de significância 5%:





Figura 11.5
(continuação).

(ii) Teste com nível de significância 1%:



O exemplo anterior ilustra claramente que quando se diminui α se aumenta β (e vice-versa). Por outro lado, a probabilidade de se cometer um erro do tipo II e, portanto, a potência do teste, ($1 - \beta$), dependem da forma como a hipótese alternativa se afasta da hipótese nula. Recorrendo ao Exemplo 11.7, na Figura 11.6 ilustra-se a evolução de β para diferentes valores do parâmetro $p_A - p_B$ quando α se mantém constante, no valor de 5%.

Figura 11.6
Evolução de β para
diferentes valores
de $p_A - p_B$ (Exemplo
11.7).





Figura 11.7
Potência de um teste
unilateral para
 $\alpha = 5\%$ e $\alpha = 1\%$
(Exemplo 11.7).



Na Figura 11.7 representa-se a potência do teste proposto no Exemplo 11.7, para $\alpha = 5\%$ e para $\alpha = 1\%$, em função de $(p_A - p_B) / \sigma$.

É importante notar que só existe uma forma de diminuir um dos riscos α ou β sem aumentar o outro: para o conseguir, há que dilatar o número de dados amostrais com base nos quais é calculada a estatística de teste.

Exemplo 11.8

Recorde-se que a estatística de teste utilizada nos exemplos anteriores foi

$$ET = \frac{\left(\frac{Y_A}{N_A} - \frac{Y_B}{N_B} \right)}{\sigma}$$

com

$$\sigma \approx S = \sqrt{\hat{p}_0 \cdot (1 - \hat{p}_0) \cdot \left[\frac{1}{N_A} + \frac{1}{N_B} \right]}$$

É imediato verificar que o aumento de N_A ou de N_B implica uma diminuição de σ . Ora, para um dado valor não nulo da diferença entre proporções $p_A - p_B$, tal diminuição implica um aumento de $(p_A - p_B) / \sigma$. Ou seja, não se alterando α , utilizar amostras de maiores dimensões tem como consequência o aumento da potência do teste (ver Figura 11.7).

Registe-se ainda que amostras exageradamente grandes podem, no extremo, conduzir à rejeição, por excesso de potência, de uma hipótese nula que, embora não sendo exactamente verdadeira, seja aproximadamente verdadeira. Por outras palavras, com amostras de dimensões exageradas, o desvio padrão da estatística de teste é tão reduzido que qualquer diferença insignificante entre H_0 e H_1 será detectada, implicando a rejeição de H_0 .

Exemplo 11.9

Admita-se que a cada uma das máquinas A e B anteriormente referidas se adaptou um dispositivo capaz de detectar e separar peças defeituosas. Ao fim de uma longa série de 100 000 unidades produzidas em cada uma das máquinas, verificou-se que se produziram 8000 defeituosas na máquina A e 7800 defeituosas na máquina B. Com base nestes números, pretende-se efectuar o seguinte teste ao nível de significância de 5%:

$$\begin{aligned} H_0: p_A &= p_B \\ H_1: p_A &> p_B \end{aligned}$$

A estatística de teste é

$$ET = \frac{\left(\frac{Y_A}{N_A} - \frac{Y_B}{N_B} \right)}{\sqrt{\hat{p}_0 \cdot (1 - \hat{p}_0) \cdot \left(\frac{1}{N_A} + \frac{1}{N_B} \right)}}$$

e a hipótese nula será rejeitada se $ET > ET(\alpha = 0.05) = 1.645$.

Como

$$\hat{p}_0 = \frac{8000 + 7800}{100000 + 100000} = 0.079,$$

resulta:

$$ET = \frac{0.080 - 0.078}{\sqrt{0.079 \cdot 0.921 \cdot (2/100000)}} = 1.658.$$

Sendo $ET > ET(\alpha = 0.05)$, a hipótese nula é rejeitada, apesar de a diferença entre as proporções de defeituosas provenientes de cada máquina ser de apenas 0.2%. Ou seja, embora, na prática, as máquinas pudessem, eventualmente, ser consideradas idênticas no que diz respeito à produção de peças defeituosas, o teste permite sustentar que a máquina A é pior do que a B.

11.4 RELAÇÃO ENTRE TESTES DE HIPÓTESES E INTERVALOS DE CONFIANÇA

A relação fundamental que existe entre os testes de hipóteses e os intervalos de confiança pode ser enunciada nos termos seguintes: uma hipótese nula

$$H_0: \theta = \theta_0$$

pode ser rejeitada a um nível de significância α se, e só se, o intervalo de confiança de θ a $(1 - \alpha) \cdot 100\%$ não incluir o valor de θ_0 . Note-se que esta condição impõe que o intervalo de confiança seja compatível com a natureza de H_1 , ou seja, que para testes bilaterais se construam intervalos de confiança bilaterais e para testes unilaterais (num sentido) se construam intervalos de confiança unilaterais (no mesmo sentido).

A implicação essencial desta relação é que se pode proceder ao teste de hipóteses recorrendo a intervalos de confiança. Tal será ilustrado a partir de dois exemplos, um envolvendo um teste bilateral e outro um teste unilateral.

Exemplo 11.10

Considere-se o caso de uma população Normal com variância conhecida $\sigma^2 = 1$. Com base numa amostra de dimensão $N = 25$, obteve-se a média amostral de $\bar{x} = 1.4$. Pretende-se testar, ao nível de significância $\alpha = 5\%$, a hipótese $H_0: \mu = 1$, admitindo como hipótese alternativa $H_1: \mu \neq 1$.

Dada a natureza da hipótese alternativa, o intervalo de confiança deve ser bilateral (contemplando a possibilidade de μ se situar tanto à esquerda como à direita do intervalo). Os limites do intervalo de confiança bilateral a $(1 - \alpha) \cdot 100\%$ para μ são:

$$\bar{x} \pm z(\alpha/2) \cdot \frac{\sigma}{\sqrt{N}}.$$

Note-se que a probabilidade de o intervalo não conter o valor especificado em H_0 quando tal hipótese é verdadeira (ou seja, quando $\mu = 1$) é justamente α , ou seja, é igual ao nível de significância do teste.

Como $\alpha = 5\%$, vem $z(0.05/2) = 1.96$. Assim, o intervalo de confiança de μ resulta:

$$\bar{x} \pm z(\alpha/2) \cdot \frac{\sigma}{\sqrt{N}} = 1.4 \pm 1.96 \cdot \frac{1}{\sqrt{25}} = [1.01, 1.79].$$

Neste intervalo de confiança não está incluída a unidade, pelo que a hipótese nula, $H_0: \mu = 1$, deverá ser rejeitada.

Tal como sucedia no procedimento «convencional» do teste de hipóteses proposto em 11.1, é também possível calcular o valor de prova a partir de intervalos de confiança. No exemplo seguinte, mostra-se como se pode efectuar tal cálculo.

Exemplo 11.11

A partir dos dados referidos no exemplo anterior, determine-se o valor de prova do teste efectuado.

No exemplo anterior verificou-se que o intervalo de confiança a 95% para μ , estabelecido com base em $\bar{X} = 1.4$ (com $N = 25$), não incluía o valor $\mu = 1$. Se se aumentar progressivamente o grau de confiança do intervalo, a sua amplitude aumentará e atingir-se-á uma situação na qual o limite inferior do intervalo toma o valor $\mu = 1$. Esta situação ocorrerá quando

$$\bar{x} - z(\alpha/2) \cdot \frac{\sigma}{\sqrt{N}} = 1.0,$$

resultando

$$z(\alpha/2) = (1.4 - 1.0) \cdot \sqrt{25} = 2.0.$$

A partir da Tabela 3 do Anexo «Tabelas» é fácil verificar que para $z(\alpha/2) = 2.0$ vem

$$\alpha/2 = 0.0228,$$

pelo que

$$\alpha = 4.56\%.$$

Este resultado corresponde ao valor de prova. O menor grau de confiança que permite que o intervalo inclua o valor 1 é então:

$$100\% - 4.56\% = 95.44\%.$$

A encerrar o tema da relação entre teste de hipóteses e intervalos de confiança, apresenta-se em seguida um exemplo no qual se efectua um teste unilateral recorrendo a um intervalo de confiança.

Exemplo 11.12

Dois amostras de dimensões $N_A = 16$ e $N_B = 21$ foram retiradas de duas populações Normais A e B. A partir dessas amostras, obtiveram-se as seguintes estimativas das variâncias: $s_A^2 = 4.60$ e $s_B^2 = 1.12$. Pretende-se testar ao nível de significância de 5% se $H_0: \sigma_A^2 = \sigma_B^2$, admitindo-se em alternativa que $H_1: \sigma_A^2 > \sigma_B^2$.

O intervalo de confiança unilateral para a razão das variâncias de populações Normais é dado por:

$$\left[\frac{1}{F_{N_A-1, N_B-1}(\alpha)} \cdot \frac{s_A^2}{s_B^2}, +\infty \right] \quad (\text{ver Secção 10.2.4}).$$

Note-se que o intervalo é unilateral e aberto à direita, uma vez que a hipótese alternativa é $H_1: \sigma_A^2 > \sigma_B^2$ ou, o que é equivalente, $H_1: \sigma_A^2 / \sigma_B^2 > 1$. Este intervalo contém a razão entre as variâncias das populações A e B com uma probabilidade $(1 - \alpha) \cdot 100\%$, ou seja, 95%. Consequentemente, a probabilidade de σ_A^2 / σ_B^2 tomar um valor inferior ao limite esquerdo do intervalo é $\alpha = 5\%$.

O intervalo de confiança é então o seguinte:

$$\left[\frac{1}{F_{15, 20}(\alpha = 0.05)} \cdot \frac{4.60}{1.12}, +\infty \right]$$

$$\left[\frac{1}{2.20} \cdot \frac{4.60}{1.12}, +\infty \right]$$

$$[1.87, +\infty[.$$

Este intervalo não inclui o valor 1, o que implica a rejeição de H_0 ao nível de significância de 5%.

Adoptando o procedimento ilustrado no exemplo anterior, determina-se em seguida o valor de prova do teste. O intervalo que com o menor grau de confiança contém a unidade é $[1, +\infty[$, pelo que

$$\frac{1}{F_{15, 20}(\alpha)} \cdot \frac{s_A^2}{s_B^2} = 1$$

$$F_{15, 20}(\alpha) \cdot \frac{s_A^2}{s_B^2} = \frac{4.60}{1.12} = 4.11.$$

Consultando a Tabela 6 do Anexo «Tabelas» verifica-se que $F_{15, 20}(\alpha = 0.01) = 3.09$, pelo que se pode concluir que o valor de prova é inferior a 1%. O recurso, por exemplo, ao Microsoft Excel permite calcular este valor de prova, que é 0.19%.

Note-se que as conclusões obtidas nestes exemplos, em que se recorreu a intervalos de confiança para testar hipóteses, são rigorosamente as mesmas que se encontrariam se se tivesse utilizado o procedimento «convencional» apresentado na Secção 11.1.

11.5 TESTES MAIS COMUNS

Na Tabela 11.2 apresenta-se uma série de testes que, por serem de utilização muito comum, são discutidos nas secções seguintes deste capítulo.

Chama-se a atenção para a relação estreita que existe entre as estatísticas de teste e as expressões propostas no Capítulo 10 para os intervalos de confiança correspondentes.

Tabela 11.2
Testes mais comuns abordados neste capítulo.

Dispersão (Variância)	Uma Amostra	População normal Amostra de qualquer dimensão	Teste do χ^2
	Duas Amostras Independentes	Populações normais Amostras de quaisquer dimensões	Teste F
	Uma Amostra	População qualquer Amostra de grande dimensão	Teste Z
		População normal Amostra de pequena dimensão	Teste t
Localização (Valor Esperado)	Duas Amostras Independentes	Populações quaisquer Amostras de grandes dimensões	Teste Z
		Populações normais Amostras de pequenas dimensões	Teste t
	Duas Amostras Emparelhadas	Populações quaisquer Amostras de grandes dimensões	Teste Z
		Populações normais Amostras de pequenas dimensões	Teste t
Localização (Proporção Binomial)	Uma Amostra	População dicotómica Amostra de grande dimensão	Teste Z
	Duas Amostras Independentes	Populações dicotómicas Amostras de grandes dimensões	Teste Z

11.5.1 TESTES DE DISPERSÃO (VARIÂNCIA)

11.5.1.1 TESTE À VARIÂNCIA DE UMA POPULAÇÃO NORMAL (TESTE DO χ^2)

Um teste à variância de uma população normal pode incluir as seguintes hipóteses:

$$H_0: \sigma^2 = \sigma_0^2$$

$$H_1: \sigma^2 \neq \sigma_0^2, \sigma^2 < \sigma_0^2 \text{ ou } \sigma^2 > \sigma_0^2.$$

A estatística de teste é:

$$ET = (N-1) \cdot \frac{S^2}{\sigma_0^2}, \quad (11.2)$$

onde N representa a dimensão de uma amostra aleatória com base na qual se obtém a variância amostral S^2 .

Quando H_0 é verdadeira, a estatística de teste segue uma distribuição χ^2_{N-1} (ver Secção 10.2.3).

Exemplo 11.13

O fabricante de um determinado tipo de paquímetro afirma que as medições efectuadas com este tipo de instrumento são afectadas por um erro cujo desvio padrão é $\sigma = 0.01$ mm. Admite-se que este valor é comum a toda a escala do aparelho. Com o objectivo de verificar se um paquímetro daquele tipo, em serviço há já muito tempo, ainda possuía as características indicadas pelo fabricante, o responsável de um laboratório de controlo da qualidade repetiu, em condições estabilizadas, 20 medições sobre uma determinada dimensão padrão. O desvio padrão amostral das leituras obtido nesta experiência foi de $s = 0.013$ mm. Poder-se-á concluir, ao nível de significância de 5%, que o paquímetro se degradou com o uso?

As hipóteses subjacentes a esta experiência são as seguintes:

$$H_0: \sigma^2 = 0.01^2$$

$$H_1: \sigma^2 > 0.01^2.$$

Se se admitir que os valores referentes às leituras repetidas seguem uma distribuição Normal, a estatística de teste será

$$ET = (N-1) \cdot \frac{S^2}{\sigma_0^2} = 19 \cdot \frac{0.013^2}{0.01^2} = 32.11.$$

O valor crítico da distribuição χ^2_{19} para o nível de significância especificado (5%) é (ver Tabela 4 do Anexo «Tabelas»):

$$\chi^2_{19} (\alpha = 5\%) = 30.1.$$

Como $32.11 > 30.1$, H_0 é rejeitada ao nível de significância de 5% (com um valor de prova de 3.04%), podendo concluir-se que o paquímetro se degradou.

11.5.1.2 TESTE À RAZÃO DE VARIÂNCIAS ENTRE DUAS POPULAÇÕES NORMAIS (TESTE F)

Os testes à razão entre as variâncias σ_A^2 e σ_B^2 de duas populações Normais A e B podem ser dos seguintes tipos:

$$H_0: \frac{\sigma_A^2}{\sigma_B^2} = r_0$$

$$H_1: \frac{\sigma_A^2}{\sigma_B^2} \neq r_0, \quad H_1: \frac{\sigma_A^2}{\sigma_B^2} < r_0, \quad H_1: \frac{\sigma_A^2}{\sigma_B^2} > r_0.$$

A estatística de teste é:

$$ET = \frac{S_A^2}{r_0 \cdot S_B^2} \quad (11.3)$$

No caso particular de $r_0 = 1$, as hipóteses em causa serão:

$$H_0: \sigma_A^2 = \sigma_B^2$$

$$H_1: \sigma_A^2 \neq \sigma_B^2, \sigma_A^2 < \sigma_B^2 \text{ ou } \sigma_A^2 > \sigma_B^2.$$

A estatística de teste é:

$$ET = \frac{S_A^2}{S_B^2} \quad (11.4)$$

onde S_A^2 e S_B^2 são variâncias amostrais calculadas com base em amostras aleatórias independentes retiradas das populações A e B , com dimensões N_A e N_B , respectivamente.

Quando H_0 é verdadeira (e são Normais as populações a partir das quais se obtêm as amostras), a estatística de teste tem a seguinte distribuição (ver Secção 10.2.4):

$$ET \sim F_{N_A-1, N_B-1}.$$

11.5.2 TESTES DE LOCALIZAÇÃO (AO VALOR ESPERADO)

11.5.2.1 TESTES AO VALOR ESPERADO DE UMA POPULAÇÃO

Nestes testes, efectuados com base numa amostra aleatória simples, são considerados dois casos: amostra de grande dimensão proveniente de uma população qualquer e amostra de pequena dimensão proveniente de uma população Normal.

Amostra de grande dimensão, população qualquer (teste Z)

$$H_0: \mu = \mu_0$$

$$H_1: \mu \neq \mu_0, \mu < \mu_0 \text{ ou } \mu > \mu_0$$

A estatística de teste é:

$$ET = \frac{\bar{X} - \mu_0}{S / \sqrt{N}}, \quad (11.5)$$

onde N representa a dimensão da amostra com base na qual são calculadas a média amostral $\bar{X}$ e a variância amostral S^2 .

Quando H_0 é verdadeira, a estatística de teste segue uma distribuição $N(0, 1)$ (ver a justificação na Secção 10.2.1).

Amostra de pequena dimensão, população Normal (teste t)

$$H_0: \mu = \mu_0$$

$$H_1: \mu \neq \mu_0, \mu < \mu_0 \text{ ou } \mu > \mu_0$$

A estatística de teste é idêntica à que foi considerada no teste anterior:

$$ET = \frac{\bar{X} - \mu_0}{S / \sqrt{N}}, \quad (11.6)$$

Quando H_0 é verdadeira, a estatística de teste segue uma distribuição t_{N-1} (ver a justificação na Secção 10.2.1).

11.5.2.2 TESTES À DIFERENÇA ENTRE VALORES ESPERADOS DE DUAS POPULAÇÕES (AMOSTRAS INDEPENDENTES)

Nestes testes, efectuados com base em duas amostras independentes provenientes de duas populações A e B , serão também consideradas duas situações distintas: amostras de grandes dimensões provenientes de duas populações quaisquer e amostras de pequenas dimensões provenientes de duas populações Normais.

Amostras de grandes dimensões, populações quaisquer (teste Z)

Se os valores esperados das populações se denotarem por μ_A e μ_B , as hipóteses do teste são:

$$\begin{aligned} H_0: \mu_A - \mu_B &= \delta_0 \\ H_1: \mu_A - \mu_B &\neq \delta_0, \mu_A - \mu_B > \delta_0 \text{ ou } \mu_A - \mu_B < \delta_0 \end{aligned}$$

A estatística de teste é:

$$ET = \frac{(\bar{X}_A - \bar{X}_B) - \delta_0}{\sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}}, \quad (11.7)$$

onde S_A^2 e S_B^2 representam as variâncias amostrais e N_A e N_B as dimensões das amostras.

Quando H_0 é verdadeira, a estatística de teste segue uma distribuição $N(0, 1)$ (ver a justificação na Secção 10.2.5).

Se se admitir que as variâncias das populações A e B são iguais, ou seja, que $\sigma_A^2 = \sigma_B^2 = \sigma^2$ (o que, para populações Normais, pode ser verificado recorrendo ao teste da razão de variâncias apresentado na Secção 11.5.1), então σ^2 pode ser estimado por

$$S^2 = \frac{(N_A - 1) \cdot S_A^2 + (N_B - 1) \cdot S_B^2}{N_A + N_B - 2}.$$

Nestas condições, a estatística de teste é

$$ET = \frac{(\bar{X}_A - \bar{X}_B) - \delta_0}{S \cdot \sqrt{\frac{1}{N_A} + \frac{1}{N_B}}}, \quad (11.8)$$

que, no caso de H_0 ser verdadeira, segue uma distribuição $N(0, 1)$.

Amostras de pequenas dimensões, populações Normais (teste t)

As hipóteses são, neste caso, as mesmas:

$$\begin{aligned} H_0: \mu_A - \mu_B &= \delta_0 \\ H_1: \mu_A - \mu_B &\neq \delta_0, \mu_A - \mu_B > \delta_0 \text{ ou } \mu_A - \mu_B < \delta_0 \end{aligned}$$

Se se admitir que as variâncias σ_A^2 e σ_B^2 são diferentes, a estatística de teste será:

$$ET = \frac{(\bar{X}_A - \bar{X}_B) - \delta_0}{\sqrt{\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B}}}, \quad (11.9)$$

Quando H_0 é verdadeira, a estatística de teste segue uma distribuição t_{GL} (ver a justificação na Secção 10.2.5), na qual o número de graus de liberdade da distribuição é dado por (expressão 10.14):

$$GL = \frac{\left(\frac{S_A^2}{N_A} + \frac{S_B^2}{N_B} \right)^2}{\frac{(S_A^2 / N_A)^2}{N_A - 1} + \frac{(S_B^2 / N_B)^2}{N_B - 1}}.$$

Se se admitir que as variâncias das duas populações são iguais, então a estatística de teste será

$$ET = \frac{(\bar{X}_A - \bar{X}_B) - \delta_0}{S \cdot \sqrt{\frac{1}{N_A} + \frac{1}{N_B}}}, \quad (11.10)$$

com

$$S^2 = \frac{(N_A - 1) \cdot S_A^2 + (N_B - 1) \cdot S_B^2}{N_A + N_B - 2}.$$

No caso de H_0 ser verdadeira, a estatística de teste segue uma distribuição t_{GL} com o número de graus de liberdade dado por

$$GL = N_A + N_B - 2.$$

11.5.2.3 TESTES À DIFERENÇA ENTRE VALORES ESPERADOS DE DUAS POPULAÇÕES (AMOSTRAS EMPARELHADAS)

Suponha-se que as duas amostras de que se dispõe, cada uma proveniente da sua população, em vez de serem independentes são **emparelhadas**. Este termo designa um tipo particular de amostras bivariadas, constituídas por pares ordenados cujos termos medem ambos a mesma grandeza.

Exemplo 11.14

Considerem-se as amostras emparelhadas constituídas pelas idades do marido e da mulher de seis casais seleccionados aleatoriamente:

$$\{(31, 27), (82, 76), (21, 22), (47, 47), (53, 50), (67, 62)\}.$$

Note-se que, neste exemplo, os objectos em análise são os casais (cuja idade podem ser encaradas como elementos de uma população bivariada). Relativamente a este exemplo, é oportuno observar o seguinte:

- as idades dos dois elementos do casal não parecem independentes, como seria de esperar (o marido de uma senhora de oitenta anos terá maior probabilidade de ser um idoso do que um jovem trintão);
- pode interessar saber se o valor esperado da idade dos maridos é superior ao valor esperado da idade das mulheres. Para o investigar, interessará analisar o comportamento da amostra univariada constituída pelas diferenças de idade entre maridos e mulheres.

Em situações deste tipo, os dados amostrais podem ser classificados de uma forma análoga à que é adoptada na Tabela 11.3 (que se refere ao caso definido no Exemplo 11.14, com a variável X_A representando a idade dos maridos e a variável X_B a das mulheres).

Tabela 11.3
Registo de dados
referentes a
amostras empare-
lhadas (com
referência ao
Exemplo 11.4).

Objectos da análise (casais)	Elementos da amostra emparelhada (idade dos maridos, idade das mulheres)	Diferença (de idades entre os elementos dos casais)
1	(x_1^A, x_1^B)	$\Delta_1 = x_1^A - x_1^B$
2	(x_2^A, x_2^B)	$\Delta_2 = x_2^A - x_2^B$
3	(x_3^A, x_3^B)	$\Delta_3 = x_3^A - x_3^B$
4	(x_4^A, x_4^B)	$\Delta_4 = x_4^A - x_4^B$
.	.	.
N	(x_N^A, x_N^B)	$\Delta_N = x_N^A - x_N^B$
	$\bar{x}_A, \bar{x}_B$	$\bar{\Delta} = \sum_{n=1}^N (\Delta_n / N)$

Tal como nos casos precedentes, estabelecer-se-á uma distinção entre situações nas quais se dispõe de amostras emparelhadas de grandes dimensões provenientes de populações quaisquer e situações nas quais as amostras emparelhadas são de pequenas dimensões e provêm de populações Normais.

■ **Amostras de grandes dimensões, populações quaisquer (teste Z)**

Admita-se que de duas populações A e B se dispõe de N observações emparelhadas $(x_n^A - x_n^B)$ ($n = 1, \dots, N$) e que, a partir delas, se obtêm N observações da variável «diferença entre observações emparelhadas», $\Delta_n = x_n^A - x_n^B$ ($n = 1, \dots, N$) (tal como se representa na Tabela 11.3). Sejam:

- μ_A, μ_B e μ_Δ : valores esperados das populações A, B e Δ ;
 $\sigma_A^2, \sigma_B^2, \sigma_\Delta^2$: variâncias das populações A, B e Δ ;
 $\bar{x}_A, \bar{x}_B, \bar{\Delta}$: médias amostrais obtidas a partir de amostras de dimensão N provenientes das populações A, B e Δ ;
 S_A^2, S_B^2, S_Δ^2 : variâncias amostrais obtidas a partir de amostras de dimensão N provenientes das populações A, B e Δ .

Aparentemente, o teste à diferença entre valores esperados μ_A e μ_B poderia ser formulado como anteriormente, isto é:

$$H_0: \mu_A - \mu_B = \delta_0$$

$$H_1: \mu_A - \mu_B \neq \delta_0, \mu_A - \mu_B > \delta_0 \text{ ou } \mu_A - \mu_B < \delta_0$$

No entanto, a estatística

$$\frac{(\bar{x}_A - \bar{x}_B) - \delta_0}{\sqrt{\frac{S_A^2}{N} + \frac{S_B^2}{N}}}$$

não seria útil, na medida em que a sua distribuição é difícil de caracterizar. De facto, uma vez que as amostras não são independentes,

$$\text{Var}(\bar{x}_A - \bar{x}_B) \neq \frac{\sigma_A^2}{N} + \frac{\sigma_B^2}{N},$$

faltando contabilizar a parcela correspondente à componente γ_{AB} , (ver expressão 5.33). Nestas condições, a estatística acima considerada não seguirá uma distribuição N (0, 1).

Em alternativa, tomando a variável $\Delta = X_A - X_B$, é possível definir o teste seguinte

$$H_0: \mu_\Delta = \Delta_0$$

$$H_1: \mu_\Delta \neq \Delta_0, \mu_\Delta > \Delta_0 \text{ ou } \mu_\Delta < \Delta_0,$$

cujas hipóteses têm o mesmo significado das que foram especificadas na formulação anterior (de facto, se se verificar que $\mu_\Delta = \Delta_0$, também $\mu_A - \mu_B = \Delta_0$; se $\mu_\Delta > \Delta_0$, também $\mu_A - \mu_B > \Delta_0$, etc.).

A estatística de teste pode então ser definida como

$$ET = \frac{\bar{\Delta} - \Delta_0}{S_\Delta / \sqrt{N}} \quad (11.11)$$

Se H_0 for verdadeira, dado que a amostra constituída pelas diferenças é de grande dimensão, esta estatística segue uma distribuição Normal padronizada (ver justificação na Secção 10.2.1).

■ **Amostras de pequenas dimensões, populações normais (teste t)**

Neste caso, as hipóteses são também

$$H_0: \mu_\Delta = \Delta_0$$

$$H_1: \mu_\Delta \neq \Delta_0, \mu_\Delta > \Delta_0 \text{ ou } \mu_\Delta < \Delta_0,$$

Atendendo a que as diferenças seguem uma distribuição Normal e que a amostra constituída por tais diferenças é pequena (e que portanto $S_\Delta \neq \sigma_\Delta$), então a estatística de teste pode ser definida por

$$ET = \frac{\bar{\Delta} - \Delta_0}{S_\Delta / \sqrt{N}} \quad (11.12)$$

Quando H_0 é verdadeira, esta estatística segue uma distribuição t_{N-1} (ver Secção 10.2.1).

Exemplo 11.15

Retomando o Exemplo 11.14, pretende-se testar, ao nível de significância de 5%, se o valor esperado das idades dos maridos é ou não superior ao das mulheres. Os dados representam-se na Tabela 11.4.

As hipóteses deste teste são as seguintes:

$$H_0: \mu_\Delta = 0$$

$$H_1: \mu_\Delta > 0.$$

Tabela 11.4
Idades dos cônjuges
(Exemplos 11.14
e 11.5).

Casal	x_A (idade do marido)	x_B (idade da mulher)	Diferença ($\Delta = x_A - x_B$)
1	31	27	4
2	82	76	6
3	21	22	-1
4	47	47	0
5	53	50	3
6	67	62	5
			$\bar{\Delta} = 2.83$ $s_\Delta^2 = 2.787$

Substituindo $\bar{\Delta} = 2.83$, $s_{\Delta} = 2.787$ e $N = 6$ na expressão da estatística de teste, resulta

$$ET = \frac{2.83}{2.787 / \sqrt{6}} = 2.490.$$

Como este valor é superior ao valor crítico t_5 ($\alpha = 0.05$) = 2.015 (ver Tabela 5 do Anexo «Tabelas»), H_0 seria rejeitada ao nível de significância de 5%, concluindo-se que, em média, os maridos têm idade superior à das mulheres. O recurso a *software* de estatística permite calcular o valor de prova do teste, que é de 2.76%.

Ao longo de toda esta secção, sugeriu-se que a diferença entre os valores esperados de duas populações pode ser testada com base nas «diferenças entre observações emparelhadas». No entanto, há situações nas quais poderá fazer sentido efectuar testes com base nas diferenças relativas (em vez das diferenças absolutas) entre as observações emparelhadas.

Exemplo 11.16

Se se pretender testar a eficiência de um revestimento anticorrosivo, podem sujeitar-se diferentes placas possuindo áreas distintas, com metade da sua superfície revestida e a outra metade não revestida, a diferentes ambientes corrosivos. A eficiência do revestimento pode ser avaliada com base nas diferenças relativas

$$\frac{x_c - x_s}{x_s},$$

onde x_c e x_s correspondem a medidas da corrosão observada, com e sem revestimento.

11.5.3 TESTES DE LOCALIZAÇÃO (PROPORÇÃO BINOMIAL)

11.5.3.1 TESTE À PROPORÇÃO BINOMIAL

(UMA AMOSTRA DE GRANDE DIMENSÃO) (TESTE Z)

Considere-se que a população em causa é constituída por elementos de dois tipos (peças boas e más, homens gordos e magros, cidadãos com olhos claros e escuros, etc.). Admita-se também que se dispõe de uma amostra de grande dimensão. Se Y representar o número de elementos de um dos dois tipos incluídos em amostras de dimensão N , então $\hat{P} = Y/N$, que representa a proporção amostral dos elementos do tipo considerado, distribui-se de uma forma aproximadamente Normal (no caso de $N \cdot p > 7$ e de $N \cdot q > 7$, ver Secção 10.2.2), com valor esperado p e variância $[p \cdot (1 - p)/N]$. As hipóteses a considerar num teste relativo à proporção binomial, p , são as seguintes:

$$H_0: p = p_0$$

$$H_1: p \neq p_0, p < p_0 \text{ ou } p > p_0.$$

A estatística que se utiliza no teste é

$$ET = \frac{\frac{Y}{N} - p_0}{\sqrt{\frac{p_0 \cdot (1 - p_0)}{N}}} \quad (11.13)$$

Quando H_0 é verdadeira, esta estatística segue uma distribuição $N(0, 1)$ (repare-se que, no denominador, figura o desvio padrão da proporção binomial, quando H_0 é verdadeira).

11.5.3.2 TESTE À DIFERENÇA ENTRE DUAS PROPORÇÕES BINOMIAIS (AMOSTRAS DE GRANDES DIMENSÕES) (TESTE Z)

Este teste foi já tratado neste capítulo, na Secção 11.1. Recorde-se que, considerando duas populações A e B , as hipóteses podem ser formuladas como segue:

$$H_0: p_A - p_B = p_0$$

$$H_1: p_A - p_B \neq p_0, p_A - p_B < p_0 \text{ ou } p_A - p_B > p_0.$$

A estatística de teste, dada por

$$ET = \frac{\left(\frac{Y_A}{N_A} - \frac{Y_B}{N_B} \right) - p_0}{\sqrt{\frac{Y_A \cdot (N_A - Y_A)}{N_A^3} + \frac{Y_B \cdot (N_B - Y_B)}{N_B^3}}}, \quad (11.14)$$


segue, quando H_0 for verdadeira, uma distribuição $N(0, 1)$.

Recorde-se que no caso particular de $p_0 = 0$, ou seja de $H_0: p_A - p_B = 0$, a estatística de teste é:

$$ET = \frac{\left(\frac{Y_A}{N_A} - \frac{Y_B}{N_B} \right)}{\sqrt{\hat{p}_0 \cdot (1 - \hat{p}_0) \cdot \left(\frac{1}{N_A} + \frac{1}{N_B} \right)}}, \quad (11.15)$$

com

$$\hat{p}_0 = \frac{Y_A + Y_B}{N_A + N_B}.$$



- 11.1. A empresa MQL garante que, se os seus pneus forem utilizados em «condições normais», têm uma vida esperada superior a 40 000 km.

Uma amostra constituída por 30 pneus utilizados nas condições acima referidas proporcionou os seguintes resultados:

$$\bar{x} = 43\,200 \text{ km} \quad e \quad s = 8000 \text{ km}.$$

Teste, ao nível de significância de 5%, se os pneus têm a vida esperada que o fabricante reivindica.

- 11.2. Duas máquinas são utilizadas no fabrico de anéis de metal. O director de produção pretende saber se o valor esperado dos diâmetros dos anéis produzidos na máquina 1 é maior do que o dos anéis produzidos na máquina 2.

Para o efeito foram recolhidos os seguintes dados:

Máq. 1 (amostra de dimensão 10): $\bar{x}_1 = 1.051 \text{ cm}$ e $s_1 = 0.021 \text{ cm}$;

Máq. 2 (amostra de dimensão 15): $\bar{x}_2 = 1.036 \text{ cm}$ e $s_2 = 0.015 \text{ cm}$.

Admitindo que os diâmetros dos anéis seguem distribuições Normais, teste se $\mu_1 > \mu_2$, ao nível de significância de 5%.

- 11.3. Uma empresa construtora de equipamento para a indústria alimentar pretende adquirir termóstatos para comandar a abertura de um certo tipo de fornos, contemplando a possibilidade de os adquirir a um dos fornecedores A ou B.

O fornecedor B vende os termóstatos mais caros, invocando que são os mais fiáveis do mercado.

Num ensaio de 9 termóstatos do fornecedor A e 11 do fornecedor B, todos regulados para actuarem à mesma temperatura, as temperaturas observadas de abertura dos fornos foram as seguintes:

Fornecedor A: 423 425 401 430 417 425 416 421 419;

Fornecedor B: 419 414 422 435 418 421 420 410 406 418 421.

Verifique, ao nível de significância de 5%, se os resultados confirmam a maior fiabilidade dos termóstatos fornecidos por B.

- 11.4. Num processo de fabricação de placas de vidro, produzem-se bolhas que se distribuem aleatoriamente pelas placas. Com base na abundante informação recolhida pelo Departamento de Qualidade, a densidade média das bolhas estimava-se, até há pouco tempo, em 0.4 bolhas/m².

Recentemente fez-se uma tentativa para melhorar o processo produtivo, em particular no tocante ao aparecimento daqueles defeitos. Depois de serem introduzidas as alterações

no processo, recolheu-se uma amostra constituída por 15 placas de 1.5 · 3.0 m² e registou-se o número de bolhas em cada uma delas. Os resultados foram os seguintes:

{1, 0, 3, 0, 2, 3, 1, 0, 1, 1, 2, 0, 1, 2, 1}.

Verifique, ao nível de significância de 5%, se a densidade esperada de bolhas diminuiu.

- 11.5. Uma empresa de aluguer de automóveis que opera numa cidade resolveu publicar um anúncio num jornal diário. Nas duas semanas anteriores à publicação do anúncio, os números de contratos de aluguer celebrados por dia foram os seguintes:

Dia	1	2	3	4	5	6	7	8	9	10	11	12	13	14
N.º de contratos	22	19	19	24	21	25	22	21	19	24	22	23	24	19

Nos três dias seguintes à publicação do anúncio, o número de contratos celebrados foi de 25, 24 e 27, respectivamente.

- (i) Poder-se-ia concluir, após se ter conhecimento do primeiro destes resultados (25), que o anúncio teve um efeito positivo sobre o número de contratos? Admita, embora a aproximação se possa considerar algo grosseira, que a variável «número de contratos celebrados diariamente» antes e depois do anúncio segue, aproximadamente, uma distribuição Normal. Efectue o teste adequado, ao nível de significância de 5%.
- (ii) Com base nos três resultados observados após a publicação do anúncio, a conclusão seria a mesma?
- 11.6. Sete indivíduos saudáveis ofereceram-se para realizar uma experiência envolvendo uma nova droga para combater a insónia. Os sete indivíduos submeteram-se, antes e depois de ingerir a tal droga, a um exame em que foi medido (em centésimos de segundo) o tempo de resposta a um sinal sonoro (admite-se que, em ambas as situações, o tempo de resposta se distribui Normalmente). Os resultados desse exame apresentam-se na seguinte tabela:

	Indivíduo						
	A	B	C	D	E	F	G
Tempo de reacção com droga	17	27	39	27	30	21	36
Tempo de reacção sem droga	19	22	34	21	27	24	29

Teste, ao nível de significância de 5%, se a tal droga provoca, como efeito secundário, o aumento do tempo de resposta a estímulos auditivos.

- 11.7. No laboratório DMC foi recentemente desenvolvido um método mais barato e mais rápido do que o convencional para efectuar certas análises de rotina.

Em testes realizados com o objectivo de comparar a fiabilidade do novo método com a do convencional, repetiu-se sucessivamente a mesma análise, tendo-se obtido os seguintes resultados:

	N.º de observações	$\sum (x_n - \bar{x})^2$
Método convencional	24	30.5
Método novo	30	55.7

- (i) Poder-se-á concluir que o novo método é menos fiável do que o método convencional?
 (ii) Será que a média de 3 observações obtidas com o novo método é mais precisa do que uma observação recolhida com base no método convencional?

Efectue os testes adequados, ao nível de significância de 5%.

- 11.8. Um molde de injeção tem produzido peças de um determinado material isolante térmico com uma resistência à compressão com valor esperado de 5.18 kg/cm^2 e variância de $0.0625 \text{ (kg/cm}^2\text{)}^2$.

As últimas 12 peças produzidas nesse molde foram recolhidas e ensaiadas, tendo-se obtido para a resistência média à compressão o valor 4.95 kg/cm^2 . Admite-se que a resistência à compressão segue uma distribuição Normal.

- (i) Poder-se-á afirmar, ao nível de significância de 5%, que as peças produzidas recentemente são menos resistentes do que o habitual?
 (ii) Qual a potência do teste efectuado em (i), admitindo que o valor esperado da resistência à compressão das peças produzidas recentemente é de 4.90 kg/cm^2 ?

- 11.9. Uma empresa produz veios de um determinado tipo em duas máquinas, A e B, do mesmo modelo. Os diâmetros dos veios devem obedecer a tolerâncias relativamente apertadas. Num teste recentemente efectuado com as duas máquinas (devidamente reguladas pelo mesmo operário), obtiveram-se os resultados que se apresentam na tabela seguinte.

Máquina	N.º de veios produzidos	Diâmetro médio [mm]	Variância amostral do diâmetro [mm^2]	N.º de veios defeituosos
A	132	30.1	12.7	15
B	120	29.8	4.7	7


Teste ao nível de significância de 5%, se as máquinas diferem,

- (i) Na precisão.
 (ii) Na proporção de veios defeituosos.

- 11.10. Para controlar o peso da castanha de cajú incluída em embalagens de 200 gramas com origem num determinado fornecedor, o departamento de controlo de qualidade de um hipermercado recolheu uma amostra constituída por 35 embalagens, a partir da qual foram calculadas as seguintes estatísticas:

$$\bar{x} = 196g \quad \text{e} \quad s^2 = 20,47g^2.$$

- (i) Construa um intervalo de confiança bilateral, a 95%, para o valor esperado do peso da castanha de cajú incluída em cada embalagem.
 (ii) Admita que o departamento de controlo de qualidade do hipermercado desconfiava, *a priori*, da honestidade do fornecedor em causa. Recorrendo a um intervalo de confiança a 95%, efectue o teste de hipóteses apropriado.



Testes Não-Paramétricos

12.1 INTRODUÇÃO

Os testes de hipóteses recebem a designação de **paramétricos** se satisfizerem simultaneamente as duas condições seguintes:

- os testes incidem explicitamente sobre um parâmetro de uma ou mais populações (por exemplo, o valor esperado ou a variância de uma ou mais populações).
- a distribuição da estatística de teste pressupõe uma forma particular da(s) distribuição(ões) populacional(ais) envolvida(s) (por exemplo, a Normalidade de tal(ais) distribuição(ões)).

Neste capítulo será estudado um conjunto de testes que, violando pelo menos uma das condições referidas, se denominam **testes não-paramétricos**. Deve notar-se, desde já, que a fronteira entre este tipo de testes e os testes paramétricos não é muito rigorosa. Para o ilustrar, considere-se o teste ao valor esperado de uma população (Secção 11.5.2.1). Tal teste poderá ser classificado ora como paramétrico — se a amostra for de pequena dimensão, porque se exige a Normalidade da população de onde foi extraída — ora como não-paramétrico — se a amostra for de grande dimensão, já que à luz do teorema do limite central se assume que a estatística de teste se distribui Normalmente. No entanto, não existe nenhum critério que permita definir com rigor a fronteira entre amostra «pequena» e amostra «grande».

Em alguns dos testes apresentados no Capítulo 11 presume-se que a população a partir da qual a amostra é obtida possui uma distribuição particular. Neste capítulo são propostos testes não-paramétricos que permitem verificar hipóteses acerca da *forma* da distribuição da população de onde provém uma qualquer amostra ou avaliar se diferentes amostras são provenientes de uma população comum: são os testes de qualidade de ajuste, tratados na Secção 12.2.

A Secção 12.3 ocupa-se de testes não-paramétricos de localização de uma população e de localização relativa de duas populações, que correspondem aos testes ao valor esperado discutidos no Capítulo 11. Note-se que a adopção de testes não-paramétricos em alternativa aos equivalentes paramétricos exige alguma cautela — os primeiros são, por regra, menos potentes quando prevalecem as condições nas quais os segundos são válidos.

Outra condição habitualmente requerida no teste de hipóteses é a de que as amostras a partir das quais se obtêm as estatísticas de teste sejam aleatórias. Na Secção 12.4 apresentam-se testes relativos à aleatoriedade das observações de uma variável. Na Secção 12.5

propõem-se testes que permitem analisar se duas variáveis se relacionam entre si, ou, de outra forma, se estão associadas. A existência de associação entre as variáveis significa que elas não são independentes. Assim, os testes de associação são de facto testes de independência.

De entre a vasta gama de testes não-paramétricos disponíveis, foi seleccionado, para análise neste capítulo, um conjunto de testes de utilização frequente ou que constituem uma alternativa aos testes paramétricos discutidos no Capítulo 11. Na Tabela 12.1 apresentam-se os testes discutidos nas secções seguintes, classificados pelo seu tipo (qualidade de ajuste, localização, aleatoriedade e associação), indicando-se, ainda que muito resumidamente, os pressupostos referentes às populações a que os testes dizem respeito e às respectivas amostras.

12.2 TESTES DE QUALIDADE DE AJUSTE

12.2.1 AJUSTE DE UMA AMOSTRA A UMA DISTRIBUIÇÃO TEÓRICA

12.2.1.1 TESTE DO QUI-QUADRADO

O teste do Qui-quadrado permite avaliar a aderência entre uma distribuição de frequências associada a uma amostra constituída por observações expressas numa qualquer escala e uma distribuição teórica. Os requisitos exigidos para a realização do teste são apenas os de que a amostra seja aleatória e tenha uma dimensão mínima adequada (esta questão será discutida mais tarde). Para ilustrar uma situação típica de aplicação do teste do Qui-quadrado, considere-se o exemplo seguinte.

Exemplo 12.1

No posto de inspecção final de uma fábrica de fogões, os aparelhos são submetidos a um conjunto de verificações e ensaios. Quando se detecta qualquer defeito, o aparelho é corrigido imediatamente ou, quando tal se justifica, é retirado da linha de montagem para posterior reparação. O número de defeitos por aparelho manteve um comportamento estável ao longo dos anos em que o processo de fabrico e montagem não se alterou. Com base em muitos milhares de observações, pôde concluir-se que o número de defeitos (Y) por aparelho submetido à inspecção final seguia uma distribuição de Poisson com o valor esperado de 2 defeitos/fogão.

Com o objectivo de melhorar a produtividade, foram recentemente introduzidas alterações no processo de montagem dos fogões. Os resultados obtidos para cem aparelhos retirados aleatoriamente do último lote apontam para que o número médio de defeitos por aparelho ensaiado não tenha sido afectado por tais alterações ($\bar{y} = 2.05$). Tais resultados são apresentados na Tabela 12.2. Por outro lado, a comparação visual entre a função de probabilidade da distribuição Poisson (2) e o histograma de frequências relativas dos dados amostrais (Figura 12.1) não permite concluir se o novo processo teve, ou não, consequências na distribuição do número de erros de montagem. Esta questão será respondida recorrendo ao teste do Qui-quadrado.

Figura 12.1
Comparação entre a função de probabilidade da distribuição Poisson (2) e a distribuição de frequências correspondente aos dados da Tabela 12.2.




Tabela 12.1
Testes abordados neste capítulo.

Qualidade de ajuste	Uma amostra	População qualquer	Teste do Qui-quadrado
		Frequências observadas	
		População contínua conhecida	
		Observações quantitativas	
Qualidade de ajuste	Duas amostras independentes	População Normal (parâmetros estimados)	Teste K-S
		Observações quantitativas	
		Populações quaisquer	
		Frequências observadas	
Localização	Uma amostra	População contínua	Teste K-S
		Observações quantitativas	
		População contínua qualquer	
		Frequência de observações acima ou abaixo de η_0	
Localização	Duas amostras independentes	População contínua e simétrica	Teste de Wilcoxon
		Observações quantitativas	
		Populações contínuas com forma igual	
		Observações quantitativas	
Localização	Duas amostras emparelhadas	População (Δ) contínua	Teste M-W-W
		Diferença entre as observações e η_0	
		População (Δ) contínua e simétrica	
		Diferença entre as observações e η_0	
Aleatoriedade	Uma amostra	População qualquer	Teste do Sinal
		Observações numa escala qualquer	
		População qualquer	
		Observações numa escala pelo menos ordinal	
Aleatoriedade	Duas amostras	Populações quaisquer	Teste de Wilcoxon
		Observações numa escala pelo menos ordinal	
		Populações quaisquer	
		Frequências observadas	
Associação	Duas amostras	Populações contínuas	Teste das Sequências
		Observações numa escala pelo menos ordinal	
		Populações quaisquer	
		Frequências observadas	
Associação	Duas amostras	Populações contínuas	Teste das Sequências Ascend. e Descendentes
		Observações numa escala pelo menos ordinal	
		Populações quaisquer	
		Frequências observadas	
Associação	Duas amostras	Populações contínuas	Teste da Correlação Ordinal de Spearman
		Observações numa escala pelo menos ordinal	
		Populações quaisquer	
		Frequências observadas	
Associação	Duas amostras	Populações contínuas	Teste do Qui-quadrado
		Observações numa escala pelo menos ordinal	
		Populações quaisquer	
		Frequências observadas	

Tabela 12.2
Número de defeitos por fogão (Exemplo 12.1).

Fogão n.º	Número de defeitos por fogão									
1 a 010	2	1	1	5	1	2	1	1	0	4
11 a 020	1	2	3	2	0	1	6	1	3	7
21 a 030	1	3	1	3	1	1	0	1	2	4
31 a 040	4	2	1	2	4	0	1	1	3	1
41 a 050	6	5	1	0	3	1	0	5	0	2
51 a 060	2	1	3	4	4	1	2	0	5	4
61 a 070	2	0	2	0	5	0	0	3	2	1
71 a 080	2	1	0	1	3	2	7	5	0	1
81 a 090	1	0	2	1	1	1	0	3	2	1
91 a 100	3	2	3	2	1	3	2	1	4	6

O teste do Qui-quadrado para a avaliação da qualidade de ajuste baseia-se na comparação da distribuição dos dados amostrais com a distribuição teórica à qual se supõe pertencer a amostra. A metodologia que se adopta no teste inclui os passos que se descrevem em seguida.

- (i) As hipóteses nula e alternativa são formuladas nos seguintes termos:

H_0 : A população possui uma determinada distribuição de probabilidade (Poisson (2), por exemplo)

H_1 : A população não possui tal distribuição de probabilidade.

- (ii) As N observações que constituem a amostra são agrupadas em K classes (ou categorias) não sobreponíveis (com $K \geq 2$). Neste passo devem ser contempladas duas situações possíveis:

- A amostra é constituída por dados qualitativos ou por dados quantitativos discretos — as classes a considerar corresponderão, naturalmente, às categorias nas quais os dados se encontram classificados ou aos valores particulares que podem tomar.
- A amostra é constituída por dados quantitativos contínuos — os dados serão agrupados em classes (células) que, a exemplo do que sucede na construção de histogramas, são de definição relativamente arbitrária.

Em ambas as situações dever-se-ão respeitar regras que serão apresentadas mais adiante.

- (iii) Calculam-se as frequências (absolutas) de observações amostrais nas diferentes classes k ($k = 1, 2, \dots, K$). Tais frequências, que se designam por *frequências observadas*, denotam-se por N_k e satisfazem a condição

$$\sum_{k=1}^K N_k = N.$$

- (iv) Determina-se a frequência de observações que se esperaria obter em cada classe k se a hipótese nula fosse verdadeira, isto é, se os dados fossem provenientes de uma determinada distribuição conhecida. Tais *frequências esperadas*, que se denotam por e_k , são dadas por

$$e_k = N \cdot p_k,$$

onde p_k representa a probabilidade de, sendo H_0 verdadeira, a variável aleatória tomar valores pertencentes à categoria k . Note-se que, tal como as frequências observadas, também as frequências esperadas satisfazem a condição

$$\sum_{k=1}^K e_k = N.$$

- (v) A estatística de teste é construída com base numa medida global de «ajuste» entre as frequências observadas na amostra, N_k , e as frequências esperadas, e_k . Essa medida é dada por

$$ET = Q = \sum_{k=1}^K \frac{(N_k - e_k)^2}{e_k}. \quad (12.1)$$

Se H_0 for verdadeira, devem registar-se pequenas diferenças entre as frequências observadas e as esperadas e, consequentemente, Q deve tomar valores baixos. Pelo contrário, um valor de Q elevado constitui um indício de que há um desajuste entre a distribuição de frequências na amostra e a teórica.

Pode demonstrar-se que, quando H_0 é verdadeira e a dimensão da amostra é grande, a estatística Q segue uma distribuição χ^2_{GL} com

$$GL = (K - 1) - R$$

graus de liberdade, onde K representa o número de classes e R representa o número de parâmetros da distribuição populacional estimados a partir da amostra.

- (vi) Uma vez fixado o nível de significância α , a rejeição ou não rejeição de H_0 será feita com base na comparação entre o valor que a estatística de teste toma e $\chi^2_{K-1-R}(\alpha)$. Dada a natureza da estatística Q — tomando valores próximos de zero, se H_0 for verdadeira, e valores tanto mais positivos quanto mais H_0 se afastar de H_1 —, o teste será unilateral à direita e, consequentemente, o valor crítico, $\chi^2_{K-1-R}(\alpha)$, deverá ser procurado na cauda direita da distribuição do Qui-quadrado.

Sendo H_0 verdadeira, a estatística Q terá uma distribuição tanto mais próxima da distribuição χ^2_{K-1-R} quanto maior for a dimensão da amostra e maiores forem os números de observações esperadas nas diferentes classes (e_k). A título indicativo, apresenta-se em seguida uma regra prática que permite utilizar este teste com confiança:

- dimensão da amostra não inferior a 30 ($N \geq 30$);
- frequência esperada em cada classe não inferior a 5 ($e_k \geq 5$).

Se esta última condição não prevalecer, o teste pode ainda ser utilizado, embora com moderada confiança, se não mais de 20% dos valores de e_k forem inferiores a 5 e nenhum for inferior a 1. Quando tal não se verificar, procuram agregar-se classes adjacentes, por forma a obter novas categorias que satisfaçam esta condição.

Exemplo 12.2

Retome-se o Exemplo 12.1 para ilustrar a metodologia de teste do Qui-quadrado, que acaba de ser apresentada.

- *Formulação das hipóteses:*

H_0 : A variável Y (número de defeitos por aparelho) segue uma distribuição de Poisson (2)

H_1 : A variável Y não segue uma distribuição de Poisson (2).

- *Nível de significância do teste:*

O nível de significância, α , é fixado arbitrariamente em 5%.

- *Cálculo da estatística de teste:*

Na Tabela 12.3 ilustra-se o cálculo de Q . Note-se que a divisão dos dados nas classes $y = 0, 1, \dots, \geq 8$ é uma consequência de a variável aleatória em causa ser discreta e de se admitir que possui uma distribuição de Poisson (2).

Tabela 12.3
Cálculo da estatística Q (Exemplo 12.2)

Classe k	Frequência observada N_k	Probabilidade		Frequência esperada $e_k = N \cdot p_k$	Frequência esperada $(N_k - e_k)^2 / e_k$
		de $Y = y$ (H_0 verdadeira) p_k			
1: $y = 0$	16	0.135335		13.5335	0.45
2: $y = 1$	32	0.270671		27.0671	0.90
3: $y = 2$	20	0.270670		27.0670	1.85
4: $y = 3$	13	0.180447		18.0447	1.41
5: $y = 4$	8	0.090224		9.0224	0.12
6: $y = 5$	6	0.036089		3.6089	5.2653
7: $y = 6$	3	0.012030	11	1.2030	
8: $y = 7$	2	0.003437		0.3437	
9: $y \geq 8$	0	0.001097		0.1097	
					$Q = 10.98$

De acordo com as regras atrás enunciadas (não mais do que 20% dos valores de e_k inferiores a 5 e nenhum inferior a 1), as classes $y = 5$, $y = 6$, $y = 7$ e $y \geq 8$ foram agrupadas numa só.

♦ **Decisão estatística:**

Por consulta da Tabela 4 do Anexo «Tabelas», verifica-se que, para 5 graus de liberdade ($GL = 6 - 1 - 0 = 5$), $\chi^2_5(0.05) = 11.07$. Como $Q = 10.98 < 11.07$, não se rejeita H_0 ao nível de significância de 5%.

Nas situações em que a distribuição considerada em H_0 é contínua e em que não exista nenhuma razão que aconselhe alguma forma especial de agrupamento dos dados, pode considerar-se o maior número possível de classes com frequências esperadas iguais. Em consonância com a regra prática apresentada anteriormente, sempre que a dimensão da amostra o permitir, procura-se que as frequências esperadas tomem em todas as classes o valor 5.

Exemplo 12.3

Pretende construir-se um modelo de simulação das operações de um determinado terminal cerealheiro de um porto situado na Europa. Uma das variáveis a considerar no modelo corresponde à diferença entre a data de chegada dos navios provenientes dos Estados Unidos e a respectiva data planeada. Dado que tal diferença é influenciada por muitos factores aditivos independentes, há razões para supor que se distribui Normalmente. Uma amostra de 50 navios revelou os resultados que se apresentam na Tabela 12.4.

Definida a variável X como a diferença, em dias, entre a data efectiva de chegada e a respectiva data planeada de chegada, a sua média ($\bar{x} = 0.1$) e o seu desvio padrão amostral ($s = 7.2$) foram calculados a partir dos dados da Tabela 12.4. Com base nestes resultados, efectuou-se o seguinte teste do Qui-quadrado.

♦ **Formulação das hipóteses:**

H_0 : X segue uma distribuição $N(0.1, 7.2^2)$

H_1 : X não segue uma distribuição $N(0.1, 7.2^2)$.

♦ **Nível de significância de teste:**

Adoptou-se $\alpha = 5\%$.

♦ **Cálculo da estatística de teste:**

Foram utilizadas 10 classes em que $p_k = 10\%$ (ver Figura 12.2). Como a dimensão da amostra é 50, este procedimento conduz a

$$e_k = N \cdot p_k = 50 \cdot 0.1 = 5.$$

Na Tabela 12.5 apresenta-se o cálculo da estatística de teste.

♦ **Decisão estatística:**

Os parâmetros da distribuição Normal foram estimados a partir dos dados amostrais. Assim,

$$GL = 10 - 1 - 2 = 7.$$

Tabela 12.4
Diferença entre a data de chegada e a data planeada para uma amostra de 50 navios (Exemplo 12.3).

Diferença entre a data de chegada e a data planeada (dias)										
1.8	-6.6	-7.4	4.4	-9.0	-2.0	2.4	-2.8	-6.0	15.2	
-11.6	-5.8	2.2	4.0	5.0	20.6	-1.8	12.4	-8.9	-2.4	
8.2	2.2	-5.6	13.2	-0.3	-1.8	-0.6	2.6	-7.6	-3.4	
7.6	-4.2	-6.0	5.0	18.8	0.0	1.4	-10.0	3.6	-8.4	
1.0	1.4	-3.8	0.4	-1.8	-4.0	-9.2	3.2	0.2	-1.8	

Figura 12.2
Definição de 10 classes equiprováveis para a distribuição $N(0.1, 7.2^2)$.




Tabela 12.5
Cálculo da estatística Q (dados do Exemplo 12.3).

Classe k	Frequência observada N_k	Probabilidade de y em classe k (H_0 verdadeira) p_k	Frequência esperada $e_k = N \cdot p_k$	$(N_k - e_k)^2 / e_k$
1: $]-\infty, -9.12]$	3	0.1	5	0.8
2: $]-9.12, -5.95]$	8	0.1	5	1.8
3: $]-5.95, -3.67]$	5	0.1	5	0.0
4: $]-3.67, -1.72]$	8	0.1	5	1.8
5: $]-1.72, 0.10]$	3	0.1	5	0.8
6: $]0.10, 1.92]$	6	0.1	5	0.2
7: $]1.92, 3.87]$	6	0.1	5	0.2
8: $]3.87, 6.15]$	4	0.1	5	0.2
9: $]6.15, 9.32]$	2	0.1	5	1.8
10: $]9.32, +\infty[$	5	0.1	5	0.0
				$Q = 7.6$

Por consulta da Tabela 4 do Anexo «Tabelas» verifica-se que $\chi^2_7(0.05) = 14.07$. Como $Q = 7.6 < 14.07$, H_0 não é rejeitada ao nível de significância de 5%. O valor de prova é 37%.

Com base neste resultado e face à convicção de que a diferença entre a data de chegada dos navios provenientes dos Estados Unidos e a respectiva data planeada seguia uma distribuição Normal, decidiu-se modelizar esta variável recorrendo à distribuição $N(0.1, 7.2^2)$.

12.2.1.2 TESTE DE KOLMOGOROV-SMIRNOV

Este teste de qualidade de ajuste (que se designa abreviadamente por K-S) deve o seu nome aos matemáticos russos A. Kolmogorov e N. Smirnov, seus autores. Podem ser apontadas duas vantagens do teste K-S sobre o do Qui-quadrado, que acaba de ser apresentado. Em primeiro lugar, quando a distribuição populacional é contínua e se conhecem a forma e os parâmetros da sua função densidade de probabilidade, a distribuição da estatística do teste é definida rigorosamente (ao contrário do que sucede com a estatística Q , cuja distribuição é aproximada). Esta vantagem é tanto mais nítida quanto menor for a dimensão da amostra. Em segundo lugar, o teste K-S é, na maioria das situações, mais

potente do que o teste do Qui-quadrado. Em contrapartida, o teste K-S exige distribuições populacionais contínuas e completamente especificadas (o que não sucede com o teste do Qui-quadrado), bem como um maior esforço computacional.

Para uma variável X , o teste K-S tem por base a análise da proximidade ou, se se preferir, do ajuste entre a função de distribuição populacional, $F_0(x)$, que é admitida em H_0 e a função de distribuição empírica ou da amostra, $S(x)$ (para qualquer valor particular x da variável X , esta função expressa a soma das frequências relativas dos dados com valores menores ou iguais a x). A estatística de teste, que se denota por D , corresponde ao supremo da diferença em valor absoluto entre $S(x)$ e $F_0(x)$, quando são considerados todos os valores possíveis de X . Em notação simbólica,

$$ET = D = \sup_x |S(x) - F_0(x)|. \quad (12.2)$$

É possível demonstrar que se, a amostra é aleatória e provém de uma distribuição contínua conhecida, a estatística D só depende da dimensão da amostra (N), sendo irrelevante a forma da função distribuição $F_0(x)$. Na Tabela 8 do Anexo «Tabelas» apresentam-se os valores da cauda direita da distribuição da estatística D , para

$$\alpha = 0.20, 0.10, 0.05, 0.02 \text{ e } 0.01, \text{ com } N = 1, 2, \dots, 40.$$

Para $N > 40$, a Tabela 8 do Anexo «Tabelas» apresenta as fórmulas que permitem determinar aproximações dos valores críticos de D para aqueles níveis de significância.

No teste K-S de qualidade de ajuste adopta-se o procedimento que se descreve em seguida.

(i) As hipóteses nula e alternativa são formuladas nos seguintes termos:

H_0 : $F(x) = F_0(x)$ para todos os valores de X (ou seja, a função de distribuição da população da qual provém a amostra é idêntica a uma função de distribuição que se assume conhecida)

H_1 : $F(x) \neq F_0(x)$ para algum valor de X .

(ii) Uma vez determinada a função de distribuição empírica, $S(x)$, calcula-se D . O supremo de $|S(x) - F_0(x)|$ não é necessariamente o maior valor que $|S(x) - F_0(x)|$ toma quando se consideram apenas os valores observados de X . De facto, dado que a função $F_0(x)$ é contínua e $S(x)$ é uma função em escada, o valor máximo daquela diferença absoluta deve ser procurado na vizinhança de cada valor observado de X .

(iii) Uma vez especificado o nível de significância do teste, o valor D é comparado com o respectivo valor crítico e, em função do resultado, H_0 é ou não rejeitada. Note-se que, como a estatística D é calculada com base no módulo da diferença entre $S(x)$ e $F_0(x)$, não distinguindo entre valores positivos e negativos, os valores críticos de D devem ser procurados na cauda direita da sua distribuição.

Exemplo 12.4

Os enólogos de uma grande adega cooperativa admitem que, em média, o álcool provável (expresso em graus) das uvas anualmente entregues para vinificação pelo conjunto dos seus sócios, segue uma distribuição Normal com valor esperado 10° e desvio padrão 1° . Pretende-se testar a validade desta conjectura a partir dos dados obtidos nos últimos vinte anos, que se apresentam na Tabela 12.6.

Na resposta a esta questão será utilizado o teste K-S.

Tabela 12.6
Grau médio de álcool provável das uvas entregues nos últimos 20 anos.

Grau médio anual									
11.9	10.6	13.3	11.6	12.9	10.4	11.3	13.5	9.1	8.2
11.6	10.0	11.3	10.3	8.4	9.9	11.0	10.3	13.2	9.9

♦ Formulação das hipóteses:

H_0 : $F(x) = F_0(x)$, ou seja, a variável aleatória X «grau médio anual de álcool provável» segue a distribuição $N(10, 1)$.

H_1 : $F(x) \neq F_0(x)$.

♦ Nível de significância do teste:

Adopta-se $\alpha = 5\%$.

♦ Cálculo da estatística de teste:

A Figura 12.3 representa graficamente o cálculo da estatística D que se detalha na Tabela 12.7. Note-se que, na figura, apenas se representa o perfil da função $S(x)$, através de uma linha quebrada (não se assinalando o valor da função nos pontos de descontinuidade).

Os valores $F_0(x_n)$ que figuram na Tabela 12.7 foram obtidos recorrendo a *software* de estatística. No entanto eles podem ser facilmente calculados a partir da Tabela 3 do Anexo «Tabelas». Por exemplo, para $x = 8.2$ vem

$$(x - \mu) / \sigma = (8.2 - 10) / 1 = -1.8.$$

Mas, como, para a distribuição $N(0, 1)$, $F(-1.8) = 0.0359$ (ver Tabela 3 no Anexo «Tabelas»), vem

$$F_0(8.2) = 0.0359.$$

Os valores de $|S(x) - F_0(x)|$ assinalados com sinal $-$ e sinal $+$ foram calculados na vizinhança, respectivamente à esquerda e à direita, de cada x_n . O supremo daquela diferença (D) observa-se na vizinhança de $x = 11.3$ (à esquerda), sendo $D = 0.3532$.

♦ Decisão estatística:

O valor crítico que a estatística D toma para $\alpha = 5\%$ e $N = 20$ é $D_{20}(\alpha = 0.05) = 0.294$ (ver Tabela 8 do Anexo «Tabelas»).

Como

$$D = 0.3532 > D_{20}(\alpha = 0.05) = 0.294,$$

H_0 é rejeitada, ficando estabelecido, ao nível de significância de 5%, que X não segue uma distribuição $N(10, 1)$. O valor de prova do teste é inferior a 1%.

Este resultado não surpreende. De facto, os intervalos de confiança a 95% para o valor esperado de X , $[10.21, 11.65]$, e para a sua variância, $[1.36, 5.01]$, calculados a partir dos valores amostrais ($\bar{x} = 10.93$ e $s^2 = 2.35$), permitiriam rejeitar imediatamente as hipóteses de que o valor esperado e a variância seriam 10 e 1, respectivamente. No entanto, aqueles testes não permitem tirar conclusões sobre a Normalidade (ou, se se preferir, sobre a forma) da distribuição de X .

Figura 12.3
Teste K-S
(Exemplo 12.4).




Tabela 12.7
Cálculo da estatística
 D (dados do
Exemplo 12.4).

x_n	$S(x_n)$	$F_0(x_n)$	$ S(x_n) - F_0(x_n) $
8.2	0.0500	0.0359	0.0359-
			0.0141+
8.4	0.1000	0.0548	0.0048-
			0.0452+
9.1	0.1500	0.1841	0.0841-
			0.0341+
9.9	0.2500	0.4602	0.3102-
			0.2102+
10.0	0.3000	0.5000	0.2500-
			0.2000+
10.3	0.4000	0.6179	0.3179-
			0.2179+
10.4	0.4500	0.6554	0.2564-
			0.2054+
10.6	0.5000	0.7257	0.2757-
			0.2257+
11.0	0.5500	0.8413	0.3413-
			0.2913+
11.3	0.6500	0.9032	0.3532-
			0.2532+
11.6	0.7500	0.9452	0.2932-
			0.1952+
11.9	0.8000	0.9713	0.2213-
			0.1713+
12.9	0.8500	0.9981	0.1981-
			0.1481+
13.2	0.9000	0.9993	0.1493-
			0.0993+
13.3	0.9500	0.9995	0.0995-
			0.0495+
13.5	1.0000	0.9998	0.0498-
			0.0002+

Tal como já se afirmou atrás, o teste K-S é exacto (ou seja, o risco α está definido rigorosamente) quando a função $F_0(x)$ se encontra perfeitamente especificada e, em particular, se conhecem os seus parâmetros. O teste pode, no entanto, ser ainda utilizado quando os parâmetros de $F_0(x)$ são estimados a partir da amostra. Porém, nestas circunstâncias, deverá ter-se em conta que o nível de significância com que se realiza o teste é menor do que aquele que é especificado e que a potência do teste também diminui de uma quantidade não conhecida.

Para ultrapassar esta limitação do teste K-S, H. Lilliefors estudou o comportamento da estatística D nas situações em que a distribuição populacional é Normal ou Exponencial Negativa, mas em que os seus parâmetros são estimados a partir dos dados amostrais. Na Tabela 9 do Anexo «Tabelas» apresentam-se os valores críticos da estatística D para o caso da distribuição Normal, considerando níveis de significância de 20%, 15%, 10%, 5% e 1% e amostras de dimensão $N \geq 4$.

Exemplo 12.5

Retomando os dados do Exemplo 12.4, admita-se que se pretende testar se o valor médio do álcool provável segue uma distribuição Normal, mas agora com valor esperado e desvio padrão iguais às estimativas obtidas a partir da amostra que se apresentou na Tabela 12.6 ($\hat{\mu} = \bar{x} = 10.93^\circ$ e $\hat{\sigma} = s = 1.53^\circ$).

Seguindo um procedimento análogo ao adoptado no Exemplo 12.4, determina-se D , que toma o valor 0.1 (ver Figura 12.4).


Consultando a Tabela 9 do Anexo «Tabelas» (para $\alpha = 5\%$ e $N = 20$) verifica-se que, nestas circunstâncias, o valor crítico é $D_{20}(\alpha = 0.05) = 0.19$.

Como

$$D = 0.1 < D_{20}(0.05) = 0.19,$$

a hipótese de que o grau médio de álcool provável segue uma distribuição Normal com valor esperado 10.93° e desvio padrão 1.53° não é rejeitada ao nível de significância de 5%.

Figura 12.4
Teste K-S
(Exemplo 12.5).



12.2.2 AJUSTE ENTRE DUAS AMOSTRAS INDEPENDENTES

12.2.2.1 TESTE DO QUI-QUADRADO

O teste do Qui-quadrado utilizado na comparação de duas amostras independentes pode ser considerado como uma extensão do teste do Qui-quadrado da qualidade do ajuste de uma amostra a uma distribuição teórica. A situação que será abordada nesta secção difere da que foi estudada anteriormente pelo facto de o objectivo ser agora o da comparação entre duas populações a partir das quais se obtêm amostras independentes. Tal como anteriormente, apenas se requer que as amostras sejam aleatórias e tenham dimensões adequadas.

A metodologia deste teste do Qui-quadrado, que se descreve em seguida, é muito semelhante à que foi apresentada anteriormente.

- (i) Denotando por A e B as populações a partir das quais se obtêm as amostras, as hipóteses nula e alternativa são formuladas nos seguintes termos:

H_0 : As populações A e B são idênticas

H_1 : As populações A e B não são idênticas.

Estas hipóteses podem tomar a seguinte forma equivalente:

H_0 : $F_A(x) = F_B(x)$, para todo o x

H_1 : $F_A(x) \neq F_B(x)$, para algum x ,

com $F_A(x)$ e $F_B(x)$ representando as funções de distribuição das populações A e B .

- (ii) As N_A e N_B observações que constituem as amostras retiradas das populações A e B , são agrupadas em K classes (ou categorias) não sobreponíveis (com $K \geq 2$).
- (iii) Para cada amostra, determinam-se as frequências observadas nas K categorias, N_{kA} e N_{kB} (com $k = 1, 2, \dots, K$).

- (iv) As frequências esperadas, e_{kA} e e_{kB} são calculadas no pressuposto de que H_0 é verdadeira, do modo que se segue:

- Denote-se por N o número total de observações ($N = N_A + N_B$) e por $N_{k\cdot}$ a frequência das observações na categoria k ($N_{k\cdot} = N_{kA} + N_{kB}$).
- Como se admite que H_0 é verdadeira, a probabilidade de uma observação ser classificada na categoria k pode ser estimada por

$$\frac{N_{k\cdot}}{N}$$

- Consequentemente, a frequência esperada de observações referente à população A na categoria k será

$$e_{kA} = N_A \cdot \frac{N_{k\cdot}}{N}$$

- As frequências esperadas, e_{kB} , são obtidas de forma análoga ou, mais simplesmente, pela subtração $N_{k\cdot} - e_{kA}$, já que

$$e_{kB} = (N - N_A) \cdot N_{k\cdot} / N = N_{k\cdot} - e_{kA}$$

Estes cálculos encontram-se representados na Tabela 12.8.

Poderia verificar-se facilmente que das $2 \cdot K$ frequências esperadas apenas $K - 1$ são independentes. Isto é, a partir de $K - 1$ frequências esperadas quaisquer, as restantes frequências esperadas podem ser obtidas por subtração, já que

$$\sum_k e_{kA} = N_A \quad \text{e} \quad \sum_k e_{kB} = N_B$$

- (v) A estatística de teste é uma medida global do ajuste entre as frequências observadas nas amostras e as respectivas frequências esperadas. Tal medida é dada por

$$ET = Q' = \sum_{k=1}^K \frac{(N_{kA} - e_{kA})^2}{e_{kA}} + \sum_{k=1}^K \frac{(N_{kB} - e_{kB})^2}{e_{kB}} \quad (12.3)$$

Se H_0 for verdadeira, pode demonstrar-se que, para amostras grandes, a estatística Q' segue a distribuição Qui-quadrado com $GL = K - 1$ graus de liberdade (uma vez que só existem $K - 1$ termos independentes nos somatórios da expressão 12.3).

- (vi) Fixado o nível de significância, α , H_0 será rejeitada ou não com base na comparação entre o valor de Q' e o valor crítico $\chi^2_{K-1}(\alpha)$. Tal como no teste do Qui-quadrado apresentado anteriormente, este teste é unilateral à direita, pelo que o valor crítico deverá ser procurado na cauda direita da distribuição do Qui-quadrado.

Tabela 12.8
Cálculo das frequências esperadas e_k ($k = 1, \dots, K$).

Categoria	Frequências observadas			Frequências esperadas	
	A	B	Total	e_A	e_B
1	N_{1A}	N_{1B}	$N_{1\cdot}$	$N_A \cdot N_{1\cdot} / N$	$N_{1\cdot} - e_{1A}$
2	N_{2A}	N_{2B}	$N_{2\cdot}$	$N_A \cdot N_{2\cdot} / N$	$N_{2\cdot} - e_{2A}$
...	...	...	...	...	...
K	N_{KA}	N_{KB}	$N_{K\cdot}$	$N_A \cdot N_{K\cdot} / N$	$N_{K\cdot} - e_{KA}$
TOTAL	N_A	N_B	N	N_A	N_B

Exemplo 12.6

Como a estatística Q' terá uma distribuição tanto mais próxima da distribuição χ^2_{K-1} quanto maior forem as dimensões das amostras, o teste deve ser conduzido seguindo as mesmas recomendações que foram apresentadas a propósito do teste do Qui-quadrado discutido na Secção 12.2.1.1. Note-se apenas que, quando houver necessidade de agregar classes adjacentes numa das amostras, tal operação deve ser igualmente executada na outra.

Um fabricante de automóveis pretende verificar se o modo como se repartem as vendas da sua marca ao longo da gama é idêntico nos países A e B . Na Tabela 12.9 apresenta-se a composição das vendas nestes mercados ao longo do último ano.

Denotando por A e por B as populações referentes à composição das vendas dos automóveis daquela marca no país A e no país B , ilustra-se em seguida o procedimento do teste do Qui-quadrado.

- *Formulação das hipóteses:*

H_0 : As populações A e B têm composições idênticas

H_1 : As populações A e B não têm composições idênticas.

- *Nível de significância do teste:*

Seja $\alpha = 5\%$.

- *Cálculo da estatística de teste:*

Na Tabela 12.10 apresentam-se os cálculos a partir dos quais se obteve o valor de Q' .

- *Decisão estatística:*

A Tabela 4 do Anexo «Tabelas» indica que $\chi^2_3(\alpha = 0.05) = 11.07$. Como $Q' = 11.317 > 11.07$, rejeita-se H_0 ao nível de significância de 5%. O valor de prova é, neste caso, 4.5%.

Tabela 12.9
Composição das vendas de automóveis de uma determinada marca nos países A e B .

Gama	País A	País B	Total
Baixa	1034	2225	3259
Média-Baixa	892	2103	2995
Média	734	1754	2488
Média-Alta	280	685	965
Alta	80	202	282
Luxo	26	32	58
TOTAL	3046	7001	10047

Tabela 12.10
Cálculo da estatística Q' (Exemplo 12.6).

k	N_A	N_B	Total	e_A	e_B	$(N_A - e_A)^2 / e_A$	$(N_B - e_B)^2 / e_B$
1	1034	2225	3259	988.0	2271.0	2.137	0.930
2	892	2103	2995	908.0	2087.0	0.282	0.123
3	734	1754	2488	754.3	1733.7	0.540	0.238
4	280	685	965	292.6	672.4	0.540	0.235
5	80	202	282	85.5	196.5	0.353	0.154
6	26	32	58	17.6	40.4	4.028	1.752
TOTAL	3046	7001	10047	3046.0	7001.0	7.886	3.431
							$Q' = 7.886 + 3.431 = 11.317$

12.2.2.2 TESTE K-S

Admita-se agora que se pretende avaliar se duas amostras aleatórias independentes provêm de uma única população contínua ou, equivalentemente, se provêm de duas populações contínuas idênticas.

Denotem-se por $F_A(x)$ e $F_B(x)$ as funções de distribuição associadas às populações A e B , respectivamente. A estrutura do novo teste K-S, que é semelhante à do teste K-S discutido anteriormente, é a seguinte:

- (i) As hipóteses nula e alternativa são formuladas nos seguintes termos:

$$H_0: F_A(x) = F_B(x) \text{ para todo o } x$$

$$H_1: F_A(x) \neq F_B(x) \text{ para algum } x \text{ (teste bilateral).}$$

No caso de fazer sentido efectuar um teste unilateral, a hipótese alternativa virá:

$$H_1: F_A(x) > F_B(x) \text{ ou } F_A(x) < F_B(x) \text{ para algum } x.$$

- (ii) Uma vez determinadas as funções de distribuição das amostras, $S_A(x)$ e $S_B(x)$, calcula-se a estatística de teste, D' , tal que:

$$ET = D' = \max_x |S_A(x) - S_B(x)|. \quad (12.4)$$

Note-se que se recorre à estatística D' tanto no caso de o teste ser bilateral como no de o teste ser unilateral.

- (iii) Uma vez especificado o nível de significância do teste, o valor obtido para D' é comparado com o respectivo valor crítico e, em função do resultado, H_0 é ou não rejeitada.

A distribuição de D' é conhecida de forma exacta quando H_0 é verdadeira e ambas as distribuições consideradas são contínuas. Na Tabela 10 do Anexo «Tabelas» apresentam-se valores da distribuição da estatística $N_A \cdot N_B \cdot D'$ (onde N_A e N_B representam as dimensões das amostras) para $2 \leq N_A \leq N_B \leq 12$ e $N_A + N_B \leq 16$ e ainda para $9 \leq N_A = N_B \leq 20$. Para amostras cujas dimensões não são contempladas nas situações anteriores, a Tabela 10 apresenta expressões que permitem determinar, de forma aproximada, os valores críticos de D' para $\alpha = 0.20, 0.10, 0.05, 0.02$ e 0.01 (testes bilaterais) ou $\alpha = 0.10, 0.05, 0.025, 0.01$ e 0.005 (testes unilaterais).

Exemplo 12.7

Uma grande repartição de finanças foi seleccionada para uma experiência piloto na qual se pretendem testar novos procedimentos. Na Tabela 12.11 apresentam-se valores do tempo despendido no processamento de uma determinada operação, antes e depois de terem sido introduzidos novos procedimentos.

Estes valores foram obtidos a partir de cronometragens seleccionadas aleatoriamente. Será que os dados sustentam a hipótese de que a distribuição do tempo de processamento se modificou com a introdução dos novos procedimentos? Na resposta a esta questão utilizar-se-á o teste K-S do ajuste entre duas amostras independentes.

Formulação das hipóteses:

$$H_0: F_A(x) = F_B(x) \text{ para todo o } x \text{ (em que } A \text{ e } B \text{ denotam, respectivamente, as situações anterior e posterior à adopção dos novos procedimentos)}$$

$$H_1: F_A(x) \neq F_B(x) \text{ para algum } x.$$

Nível de significância do teste:

É adoptado $\alpha = 5\%$.

Tabela 12.11
Tempos de processamento, em minutos
(Exemplo 12.7).

ANTES:	4.1	4.4	4.7	4.8	4.9	5.7	7.4	7.6	9.7	10.3	12.4	15.5
DEPOIS:	3.8	5.0	6.3	6.6	6.7	6.9	8.5	8.6	8.9	9.5	9.8	10.2

Cálculo da estatística de teste:

A estatística de teste, $D' = 0.333$, é calculada como se indica na Tabela 12.12. Note-se que, ao contrário do que sucedia no teste K-S discutido anteriormente na Secção 12.2.1.2, agora basta calcular as diferenças absolutas para valores observados de X numa ou outra amostra e escolher o valor máximo de tais diferenças absolutas. Na Figura 12.3 representa-se graficamente o significado de D' .

Decisão estatística:


De acordo com a Tabela 10, com $\alpha = 5\%$ e $N_A = N_B = 12$, vem $N_A \cdot N_B \cdot D' = 84$, donde resulta $D'(\alpha = 0.05) = 84 / 144 = 0.583$.

Como $D' = 0.333 < D'(\alpha = 0.05) = 0.583$, H_0 não é rejeitada.

Tabela 12.12
Teste K-S para duas amostras: cálculo de D' (Exemplo 12.7).

x	$S_A(x)$	$S_B(x)$	$ S_A(x) - S_B(x) $
3.8	0	1/12	1/12
4.1	1/12	1/12	0
4.4	2/12	1/12	1/12
4.7	3/12	1/12	2/12
4.8	4/12	1/12	3/12
4.9	5/12	1/12	4/12
5.0	5/12	2/12	3/12
5.7	6/12	2/12	4/12
6.3	6/12	3/12	3/12
6.6	6/12	4/12	2/12
6.7	6/12	5/12	1/12
6.9	6/12	6/12	0
7.4	7/12	6/12	1/12
7.6	8/12	6/12	2/12
8.5	8/12	7/12	1/12
8.6	8/12	8/12	0
8.9	8/12	9/12	1/12
9.5	8/12	10/12	2/12
9.7	9/12	10/12	1/12
9.8	9/12	11/12	2/12
10.2	9/12	1	3/12
10.3	10/12	1	2/12
12.4	11/12	1	1/12
15.5	1	1	0

Figura 12.5
Teste K-S para duas amostras: representação gráfica de D' (Exemplo 12.7).



12.3 TESTES DE LOCALIZAÇÃO

12.3.1 LOCALIZAÇÃO DE UMA POPULAÇÃO

O valor esperado, μ , é o parâmetro de localização mais frequentemente utilizado em inferência estatística. No entanto, a mediana populacional, η , (ver Secção 4.5), correspondendo igualmente a um valor «central» das distribuições, pode constituir uma alternativa ao valor esperado, uma vez que:

- ♦ é menos influenciada por valores extremos;
- ♦ quando as distribuições são assimétricas, a mediana situa-se numa posição mais próxima do valor mais observado, podendo por isso ter mais sentido como medida de tendência central;
- ♦ quando as distribuições são simétricas, a mediana populacional e o valor esperado coincidem, possuindo assim o mesmo mérito como medida de tendência central.

Nos pontos seguintes (bem como na Secção 12.3.2) apresentam-se testes de localização não-paramétricos em que o parâmetro envolvido é, justamente, a mediana populacional. Tais testes constituem uma alternativa aos testes ao valor esperado apresentados no Capítulo 11.

12.3.1.1 TESTE DO SINAL

O teste do sinal desenvolve-se com base em amostras aleatórias provenientes de populações contínuas.

Na hipótese nula admite-se que a mediana populacional possui um determinado valor particular, η_0 , em alternativa à hipótese de que a mediana da população é diferente, superior ou inferior a η_0 . Simbolicamente, vem:

$$\begin{aligned} H_0: \eta &= \eta_0 \\ H_1: \eta &\neq \eta_0, \text{ ou} \\ &\eta > \eta_0, \text{ ou ainda,} \\ &\eta < \eta_0. \end{aligned}$$

Se H_0 for verdadeira e a amostra for aleatória simples, o número Y de observações com valor inferior (ou superior) a η_0 é uma variável aleatória Binomial com parâmetro $p = 0.5$. A estatística de teste é então

$$ET = Y \text{ [número de observações abaixo (ou acima) da mediana]}. \quad (12.5)$$

As hipóteses que integram o teste do sinal podem, alternativamente, ser formuladas nos seguintes termos:

$$\begin{aligned} H_0: p &= 0.5 \\ H_1: p &\neq 0.5, \text{ ou} \\ &p > 0.5, \text{ ou ainda,} \\ &p < 0.5. \end{aligned}$$

Exemplo 12.8

Admita-se que o rendimento familiar mediano numa determinada região é de 600 euros/mês. Admita-se ainda que uma amostra aleatória constituída por doze famílias que habitam numa vila da referida região revelou os seguintes rendimentos (em euros/mês):

{440, 466, 482, 518, 603, 617, 636, 727, 774, 824, 961 e 1056}.

Será que, perante estes dados, se poderia concluir que o rendimento mensal mediano na vila em causa seria diferente do correspondente à região?

Formulação das hipóteses:

A hipótese nula é a de que a mediana do rendimento familiar mensal é de 600 euros/mês. Se esta hipótese for verdadeira, 50% das famílias terão um rendimento inferior a 600 euros/mês (e 50% um rendimento superior a 600 euros/mês). Será então:

$$H_0: p = 0.5$$

$$H_1: p \neq 0.5.$$

Admita-se que o número de famílias que compõem a população é muito grande em relação à dimensão da amostra, que foi recolhida de forma aleatória. Nestas condições e se H_0 for verdadeira, a variável Y , representando, por exemplo, o número de famílias com rendimento inferior a η_0 numa amostra de dimensão 12, segue uma distribuição $B(12, 0.5)$ (note-se que o teste teria o mesmo resultado se se adoptasse a variável «número de famílias com rendimento superior a η_0 »).

Nível de significância do teste:

É adoptado $\alpha = 5\%$.

Regra de decisão:

Consultando a Tabela 1 do Anexo «Tabelas» para $N = 12$ e $p = 0.5$, verifica-se que $P(Y \leq 2) + P(Y \geq 10) = 0.0384$ e que $P(Y \leq 3) + P(Y \geq 9) = 0.1458$, pelo que H_0 será rejeitada ao nível de significância de 5% se na amostra ocorrerem menos do que 3 ou mais do que 9 observações inferiores a η_0 (ver Figura 12.6).


Cálculo da estatística de teste:

Como existem 4 observações com valor inferior a 600 euros/mês, a estatística Y toma o valor 4.

Decisão estatística:

Dado que $Y = 4$, não é possível concluir, ao nível de significância de 5%, que o rendimento familiar mensal mediano da vila em causa é diferente do da região.

Figura 12.6
Regra de decisão de um teste do sinal bilateral ($\alpha = 5\%$ e $N = 12$).



Sempre que na amostra se observarem valores iguais a η_0 , tais observações não deverão ser consideradas, e a dimensão da amostra deverá ser diminuída em concordância.

Suponha-se agora que se dispõe de uma amostra de grandes dimensões, de tal modo que a distribuição $N(N \cdot p, N \cdot p \cdot q)$ constitui uma boa aproximação da distribuição $B(N, p)$. De acordo com a regra prática apresentada na secção 7.4.4 e dado que, neste caso, $p = 0.5$,

bastará que $N \geq 20$ para que tal aproximação seja aceitável. Nessas condições, a estatística utilizada no teste do sinal será (ver Secção 10.2.2)

$$ET = \frac{\hat{P} - 0.5}{\sqrt{\frac{0.25}{N}}}, \quad (12.6)$$

onde N representa a dimensão da amostra, e $\hat{P}$ a proporção amostral de observações abaixo (ou acima) de η_0 . Se H_0 for verdadeira, então $ET \sim N(0, 1)$.

Exemplo 12.9

Um estudo envolvendo um determinado modelo automóvel da gama média-alta permitiu concluir que o custo de manutenção mediano no terceiro ano de vida de um veículo que percorre 15 000 km/ano é de 300 euros. Numa amostra constituída por 130 automóveis da mesma gama que se encontravam nas condições referidas, mas pertencentes a outra marca, verificaram-se 53 situações nas quais o custo foi superior a 300 euros. Será possível concluir, ao nível de significância de 5%, que a mediana do custo de manutenção (no terceiro ano de vida e para uma quilometragem anual de 15 000 km) é, nesta marca, inferior à do modelo que foi objecto do estudo?

♦ Formulação das hipóteses:

$$H_0: \eta = 300$$

$$H_1: \eta < 300,$$

ou

$$H_0: p = 0.5$$

$$H_1: p < 0.5.$$

♦ Nível de significância de teste:

De acordo com a formulação do problema, $\alpha = 5\%$.

♦ Regra de decisão:

Como a amostra é de grande dimensão, adopta-se a estatística apresentada na expressão 12.6. O teste é unilateral à esquerda, pelo que H_0 será rejeitada (ao nível de significância de 5%) se $ET \leq 1.645$ (ver Tabela 3 do Anexo «Tabelas»).

♦ Cálculo da estatística de teste:

$$ET = \frac{\frac{53}{130} - 0.5}{\sqrt{\frac{0.25}{130}}} = -2.105.$$

♦ Decisão estatística:

Como $ET = -2.105 < -1.645$, H_0 é rejeitada (com o valor de prova de 1.76%).

Quando estão em causa amostras de grande dimensão, coloca-se a questão da escolha entre o teste do sinal e o teste Z do valor esperado. Recorde-se que, para grandes amostras, o teste Z é sempre válido, independentemente da forma da distribuição da população em causa.

Se forem satisfeitas as respectivas condições de aplicação, o teste Z é mais potente do que o teste do sinal. Assim, só quando existirem razões objectivas que levem a preferir a mediana populacional como medida de tendência central (por exemplo, no caso de testes unilaterais sobre populações muito assimétricas) é que será razoável efectuar o teste do sinal em alternativa ao teste Z.

O raciocínio que está na base do teste do sinal poderia igualmente ser utilizado para construir intervalos de confiança para a mediana. Tal questão, cuja análise é muito simples, não será aqui discutida.

12.3.1.2 TESTE DE WILCOXON

Tal como já foi indicado, no teste do sinal os dados são transformados em contagens de uma variável dicotómica (observações acima ou abaixo da mediana). Ao proceder desta forma, perde-se a informação relativa às diferenças de valor entre as observações e a mediana. Por exemplo, se $\eta_0 = 0$, tanto faz que uma observação tenha o valor 5 como o valor 15: no cálculo da estatística de teste, será contabilizada, em ambos os casos, como uma observação acima de η_0 . No teste de Wilcoxon, a magnitude das diferenças é tida em conta, exigindo-se, em contrapartida, que a população, para além de ser contínua, seja também simétrica. Nestas condições, este teste é mais potente do que o teste do sinal.

Tal como no teste do sinal, considerem-se então as seguintes hipóteses:

$$H_0: \eta = \eta_0$$

$$H_1: \eta \neq \eta_0, \text{ ou}$$

$$\eta > \eta_0, \text{ ou ainda,}$$

$$\eta < \eta_0.$$

Se a população for contínua e simétrica, a amostra for aleatória e H_0 for verdadeira, as diferenças

$$d_n = x_n - \eta_0$$

deverão distribuir-se em torno de zero também de forma simétrica (com x_n representando cada uma das $n = 1, 2, \dots, N$ observações amostrais). Ou seja, observar-se-ão diferenças positivas e negativas com valores absolutos da mesma ordem de grandeza em número aproximadamente igual.

A avaliação relativa da magnitude das diferenças d_n pode ser efectuada ordenando de forma crescente os seus valores absolutos, $|d_n|$, e atribuindo a cada um destes o respectivo número de ordem (começando por 1, no menor valor absoluto, e acabando em N , no maior). Assim, se a população for simétrica em torno de η_0 e, por sua vez, H_0 for verdadeira, a soma dos números de ordem referentes às diferenças d_n negativas deverá ser aproximadamente igual à soma dos números de ordem das diferenças positivas. Uma situação contrária a esta favorece uma das hipóteses alternativas. Por exemplo, se a soma dos números de ordem relativos às diferenças positivas for muito maior do que a soma dos números relativos às diferenças negativas, então a hipótese $H_1: \eta > \eta_0$ tornar-se-á plausível. A estatística de teste de Wilcoxon é baseada, justamente, na propriedade que acaba de ser enunciada. Os passos que integram o cálculo da estatística de teste de Wilcoxon são definidos em seguida.

- Calculam-se as diferenças $d_n = x_n - \eta_0$ e ordenam-se de forma crescente os respectivos valores absolutos $|d_n|$.
- Atribui-se um número de ordem a cada $|d_n|$ e coloca-se o sinal «+» nos números de ordem referentes a valores d_n positivos e o sinal «-» nos que resultam de diferenças d_n negativas.
- Calcula-se o valor da estatística que resulta da soma dos números de ordem «positivos» ou «negativos». Esta estatística denota-se por T_+ , no primeiro caso, por T_- , no segundo, e por T se se referir genericamente aos dois casos anteriores. Note-se que o valor que a estatística toma é sempre um número inteiro não negativo e que, para uma amostra de dimensão N , a soma de todos os números de ordem é constante e igual a $N \cdot (N + 1) / 2$.

Se a hipótese nula for verdadeira, as distribuições de T_+ e T_- são idênticas e simétricas em torno do valor esperado, $N \cdot (N + 1) / 4$. Pode assim ser indiferentemente tomada tanto a estatística T_+ como T_- .

- (iv) Se a estatística T (T_+ ou T_-) tomar um valor muito alto ou muito baixo (note-se que ele pode variar entre o mínimo 0 e o máximo $N \cdot (N + 1) / 2$), tal significa que a hipótese nula deve ser questionada. Na Tabela 11 do Anexo «Tabelas» apresentam-se, para $N \leq 15$, os valores P referentes à probabilidade de a estatística tomar valores menores ou iguais aos valores tabelados t_e (na cauda esquerda) ou maiores ou iguais aos valores tabelados t_d (na cauda direita). No caso de testes unilaterais, o valor de prova será o valor de P correspondente a T (à esquerda ou à direita). Em testes bilaterais, o valor de prova é calculado por duplicação daquele valor de P . No Apêndice 12.1 descreve-se a forma com a função de distribuição da estatística de teste é calculada.
- (v) Se H_0 for verdadeira, a distribuição de T tende para a distribuição Normal quando N aumenta. Para valores de N superiores a 15, a aproximação pela Normal é já suficientemente precisa. Nesta situação, a estatística de teste pode ser substituída pela variável que resulta da transformação de T ,

$$ET = \frac{T - N \cdot (N + 1) / 4}{\sqrt{N \cdot (N + 1) \cdot (2 \cdot N + 1) / 24}} \quad (12.7)$$

Quando H_0 é verdadeira, ET segue aproximadamente uma distribuição $N(0, 1)$.

- (vi) Embora se assuma que a população é contínua, na prática, em consequência da limitada precisão com que a variável aleatória correspondente é medida, ocorrem diferenças absolutas $|d_n|$ de igual valor («empates») ou nulas («zeros»). No que diz respeito aos «zeros», recomenda-se que se ignorem tais valores e que, consequentemente, se diminua a dimensão da amostra. Caso se verifiquem «empates», o número de ordem que se atribui a cada uma das diferenças absolutas $|d_n|$ com o mesmo valor corresponde à média aritmética dos números de ordem que tais observações receberiam se não estivessem empatadas. Por exemplo, no caso da sequência {1, 3, 3, 5, 7, 7, 7, 8} seriam atribuídos os números de ordem 1, 2.5, 2.5, 4, 6, 6, 6, 8. Este procedimento tem a vantagem de manter o valor da soma dos números de ordem em $N \cdot (N + 1) / 2$. A menos que se verifiquem muitos empates, a distribuição da estatística T assim calculada é muito próxima daquela que se obtém quando tais empates não ocorrem. Nestas condições, os valores indicados na Tabela 11 do Anexo «Tabelas» mantêm-se válidos.
- (vii) Quando se aproxima a distribuição de T pela Normal (ponto v), se existirem observações empatadas, o desvio padrão da estatística de teste deve ser corrigido, vindo:

$$\sigma_T = \sqrt{\frac{N \cdot (N + 1) \cdot (2 \cdot N + 1)}{24} - \frac{\left(\sum_i u_i^3 - \sum_i u_i\right)}{48}}$$

onde u_i representa o número de empates no i -ésimo grupo de observações iguais (com $i = 1, 2, \dots$). Por exemplo, no caso da já referida sequência {1, 3, 3, 5, 7, 7, 7, 8}, virá

$$u_1 = 2, \quad u_2 = 3$$

e, portanto,

$$\frac{\left(\sum_i u_i^3 - \sum_i u_i\right)}{48} = \frac{(2^3 + 3^3) - (2 + 3)}{48} = \frac{30}{48} = 0.625.$$

Neste caso (em que $N = 8$), o valor de σ_T não corrigido (que corresponde ao denominador da expressão 12.7) seria 7.141 e o corrigido é 7.097. Embora a correcção seja muito pequena, se ela não fosse introduzida, o teste seria ligeiramente conservador, isto é, o nível de significância seria ligeiramente inferior ao especificado.

Exemplo 12.10

Um médico pediatra pretende avaliar se o peso mediano dos bebés recém-nascidos do sexo feminino numa pequena vila de província é inferior ao da mediana nacional, que se admite ser de 3.3 kg. Tal avaliação será baseada nos pesos das nove meninas nascidas no último ano, que foram os seguintes (em quilogramas): {1.9, 2.0, 2.2, 2.8, 3.1, 3.1, 3.3, 3.4, e 3.7}.

◆ Formulação das hipóteses:

$$H_0: \eta = 3.3 \text{ kg}$$

$$H_1: \eta < 3.3 \text{ kg.}$$

◆ Nível de significância do teste:

Arbitrariamente, α é fixado em 5%.

◆ Cálculo da estatística de teste:

O teste é unilateral à esquerda. Optando-se por T_- , no caso de H_1 ser verdadeira tal estatística deverá tomar valores elevados. Alternativamente, se se optar por T_+ , a hipótese H_1 é compatível com valores baixos. Na Tabela 12.13 apresenta-se o cálculo da estatística de teste (T_+ e T_-).

◆ Decisão estatística:

Uma vez que ocorre um «zero» em $x_n = 3.3$, a dimensão da amostra é reduzida de uma unidade, ficando em $N = 8$. De acordo com a Tabela 11 do Anexo «Tabelas», para $N = 8$, a probabilidade de T_- ser maior ou igual a 31 é de 0.039 (ou, alternativamente, a probabilidade de T_+ ser menor ou igual a 5 é também de 0.039). Assim, H_0 é rejeitada ao nível de significância de 5%, com o valor de prova de 3.9%.

Tabela 12.13
Cálculo da estatística
de teste de Wilcoxon
(Exemplo 12.10).

x_n	$d_n = x_n - 3.3$	$ d_n $	Ordem (+)	Ordem (-)
1.9	-1.4	1.4		8
2.0	-1.3	1.3		7
2.2	-1.1	1.1		6
2.8	-0.5	0.5		5
3.1	-0.2	0.2		2.5
3.1	-0.2	0.2		2.5
3.3	0.0	—	—	—
3.4	0.1	0.1	1	
3.7	0.4	0.4	4	
			$T_+ = 5$	$T_- = 31$

12.3.2 LOCALIZAÇÃO RELATIVA DE DUAS POPULAÇÕES

12.3.2.1 AMOSTRAS INDEPENDENTES: TESTE DE MANN-WHITNEY-WILCOXON

O objectivo deste teste (por vezes designado por teste M-W-W) é o de avaliar se as medianas de duas populações contínuas A e B, com a mesma forma, se localizam no mesmo

ponto. Na hipótese nula, admite-se que as medianas de ambas as populações coincidem, e na hipótese alternativa postula-se que a diferença entre as medianas é não nula, é positiva ou é negativa:

$$\begin{aligned} H_0: \eta_A &= \eta_B \\ H_1: \eta_A &\neq \eta_B, \text{ ou} \\ \eta_A &> \eta_B, \text{ ou ainda,} \\ \eta_A &< \eta_B. \end{aligned}$$

Admita-se que de cada população se retira uma amostra. Admita-se ainda que as duas amostras são independentes e se denotam as suas dimensões por N_A e N_B (sendo $N_B \leq N_A$). O cálculo da estatística de teste compreende os seguintes passos:

- Ordenam-se de forma crescente e em conjunto as $N = N_A + N_B$ observações.
- Atribui-se um número de ordem a cada observação, começando por 1, na que se encontra em primeiro lugar no vector ordenado, e terminando em N , na que se encontra em último.
- A estatística de teste, W , corresponde à soma dos números de ordem relativos à amostra de menor dimensão:

$$ET = W \text{ (soma dos números de ordem da menor amostra).} \quad (12.8)$$

Note-se que, tal como sucede no teste de Wilcoxon, a soma de todos os números de ordem é uma constante igual a $N \cdot (N + 1) / 2$.

- Se a estatística W tomar um valor w muito baixo (ou muito alto), tal significa que as observações referentes à menor amostra são predominantemente inferiores (ou superiores) às observações da outra amostra. Tal facto contraria a hipótese nula, isto é, contraria a hipótese de que ambas as populações (com a mesma forma) têm a mesma localização, favorecendo uma das hipóteses alternativas.

Quando H_0 é verdadeira, a estatística W possui uma distribuição simétrica centrada em

$$E(W) = N_B \cdot (N + 1) / 2,$$

com valores que se situam entre o mínimo $N_B \cdot (N_B + 1) / 2$ e o máximo $N_B \cdot (2 \cdot N - N_B + 1) / 2$. A variância de W é dada por

$$\text{Var}(W) = N_A \cdot N_B \cdot (N + 1) / 12.$$

No Apêndice 12.2, ilustra-se a forma como a função de probabilidade de W é especificada.

- Na Tabela 12 do Anexo «Tabelas», é caracterizada a distribuição de W (quando H_0 é verdadeira). Para diferentes valores w_e e w_d , são apresentadas as probabilidades $\text{Probabilidade}(W \leq w_e) = \text{Probabilidade}(W \geq w_d) = P$. A tabela é construída para N_A e N_B não superiores a 10. No caso de testes unilaterais, o valor de prova será determinado pelo valor de P correspondente a W (à esquerda ou à direita). Em testes bilaterais, o valor de prova é calculado por duplicação daquele valor de P .
- Quando H_0 é verdadeira e as amostras têm dimensões (N_A e N_B) que não estão contempladas na Tabela 12 do Anexo «Tabelas», a distribuição de W pode ser aproximada pela distribuição Normal (tanto mais perfeita será a aproximação quanto maiores forem N_A e N_B). Nestas condições, a estatística do teste é

$$ET = \frac{W - N_B \cdot (N + 1) / 2}{\sqrt{N_A \cdot N_B \cdot (N + 1) / 12}}. \quad (12.9)$$

Quando H_0 for verdadeira, ET segue aproximadamente uma distribuição $N(0, 1)$.

- No caso de existirem observações «empatadas» (dentro da mesma amostra ou entre amostras) e quando as amostras forem pequenas (N_A e $N_B \leq 10$), a atribuição do número de ordem a cada observação empatada segue o procedimento descrito a propósito do teste de Wilcoxon. A menos que o número de empates seja elevado, estes não afectam significativamente a distribuição da estatística W , e os valores apresentados na Tabela 12 podem ser utilizados com confiança.
- Quando se aproxima a distribuição de W pela Normal, se existirem observações empatadas, o desvio padrão da estatística de teste deve ser corrigido, calculando-se através da expressão:

$$\sigma_W = \sqrt{\frac{N_A \cdot N_B \cdot (N + 1)}{12} - \frac{N_A \cdot N_B}{12 \cdot N \cdot (N - 1)} \left(\sum_i u_i^3 - \sum_i u_i \right)},$$

com u_i representando, tal como no teste de Wilcoxon, o número de empates no i -ésimo grupo de observações iguais (com $i = 1, 2, \dots$).

Exemplo 12.11

Pretende avaliar-se se as distribuições dos consumos domésticos de energia eléctrica por habitante em duas regiões relativamente pobres têm a mesma mediana. Na Tabela 12.14 apresentam-se os dados referentes a consumos anuais por habitante, expressos em milhares de kwh (baixa tensão), para duas amostras aleatórias independentes, uma correspondendo a 10 concelhos de uma região A, e a outra a 8 concelhos de outra região B.

◆ Formulação das hipóteses:

$$\begin{aligned} H_0: \eta_A &= \eta_B \\ H_1: \eta_A &\neq \eta_B. \end{aligned}$$

◆ Nível de significância do teste:

Arbitra-se $\alpha = 5\%$.

◆ Regra de decisão:

De acordo com os valores apresentados na Tabela 12 para $N_A = 10$ e $N_B = 8$, H_0 será rejeitada se W for inferior a 54 ou exceder 98 (note-se que, sendo o teste bilateral, $P \leq \alpha/2 = 0.025$).

◆ Cálculo da estatística de teste:

Na Tabela 12.15 apresenta-se o cálculo da estatística W .

Tabela 12.14
Consumos anuais de energia eléctrica de baixa tensão (milhares de kwh/habitante) em diferentes concelhos das Regiões A e B.

Região A	Região B
0.237	0.341
0.235	0.482
0.423	0.464
0.398	0.256
0.241	0.908
0.237	0.286
0.344	0.518
0.449	0.326
0.741	
0.405	

♦ **Decisão estatística:**

De acordo com os valores apresentados na Tabela 12 para $N_A = 10$ e $N_B = 8$, $P(W \geq 89) = 0.137$. Como o teste é bilateral, o valor de prova será então de $2 \cdot 13.7\% = 27.4\%$, pelo que não se rejeita H_0 .

Tabela 12.15
Cálculo da estatística W (Exemplo 12.11).

A ($N_A = 10$)	N.º de ordem	B ($N_B = 8$)	N.º de ordem
0.235	1	—	—
0.237	2,5	—	—
0.237	2,5	—	—
0.241	4	—	—
—	—	0.256	5
—	—	0.286	6
—	—	0.341	7
—	—	0.326	8
0.344	9	—	—
0.398	10	—	—
0.405	11	—	—
0.423	12	—	—
0.449	13	—	—
—	—	0.464	14
—	—	0.482	15
—	—	0.518	16
0.741	17	—	—
—	—	0.908	18
w = 89			

Uma extensão simples do teste M-W-W consiste na avaliação de hipóteses envolvendo diferenças na localização de populações A e B (com forma idêntica, recorde-se), ou seja:

$$\begin{aligned}
 H_0: \eta_A - \eta_B &= \delta \\
 H_1: \eta_A - \eta_B &\neq \delta, \text{ ou} \\
 &\eta_A - \eta_B > \delta, \text{ ou ainda,} \\
 &\eta_A - \eta_B < \delta.
 \end{aligned}$$

Se a hipótese nula for verdadeira, $(\eta_A - \delta) - \eta_B = 0$, pelo que bastará subtrair δ às observações referentes à população A para que o procedimento de teste anteriormente apresentado seja aplicável directamente.

Exemplo 12.12

Pretende avaliar-se se, na capital de um determinado país, a remuneração mediana das secretárias de Direcção é superior, em pelo menos 100 euros/mês, à remuneração mediana numa determinada cidade periférica. Admite-se que as distribuições das remunerações em ambas as cidades apenas diferem na sua localização.

Para o efeito, foram recolhidas duas amostras aleatórias de 20 vencimentos mensais, tendo-se obtido os seguintes resultados (em euros/mês, ordenados por ordem crescente):

Periferia: {1266, 1337, 1366, 1420, 1464, 1471, 1475, 1483, 1488, 1527, 1551, 1552, 1590, 1645, 1673, 1736, 1754, 1758, 1795, 1854}.

Capital: {1380, 1479, 1557, 1580, 1700, 1720, 1731, 1733, 1768, 1779, 1781, 1784, 1793, 1794, 1837, 1898, 1910, 1957, 1959, 2215}.

♦ **Formulação das hipóteses:**

$$\begin{aligned}
 H_0: (\eta_C - 100) - \eta_P &= 0 \\
 H_1: (\eta_C - 100) - \eta_P &> 0.
 \end{aligned}$$

♦ **Nível de significância do teste:**

O teste será efectuado ao nível de significância de 5%.

♦ **Regra de decisão:**

Como $N_A = N_B > 10$, será adoptada a distribuição Normal como aproximação da distribuição de W . Assim, dado que o teste é unilateral à direita, H_0 será rejeitada se $Z > 1.645$.

♦ **Cálculo da estatística de teste:**

Seja X_C a variável que representa a remuneração mensal na capital subtraída de $\delta = 100$ euros e X_P a que representa a remuneração mensal na cidade periférica. Na Tabela 12.16 apresenta-se o cálculo de W , efectuado a partir dos números de ordem referentes à variável X_C (note-se que, como as amostras são de igual dimensão, se H_1 for verdadeira, devem prevalecer observações da variável X_C com números de ordem superiores aos das observações de X_P).

Substituindo $W = 480$, $N_A = N_B = 20$ e $N = 40$ na expressão 12.9, a estatística de teste resulta

$$ET = Z = \frac{480 - 410}{36.97} = 1.89.$$

♦ **Decisão estatística:**

Sendo a estatística do teste superior ao valor crítico, 1.645, H_0 é rejeitada ao nível de significância de 5% (com o valor de prova 2.94%).

Registe-se que, quando o teste Mann-Whitney-Wilcoxon é utilizado na avaliação da localização relativa de duas populações Normais, é quase tão potente como o teste t . De facto, nessas circunstâncias e para o mesmo nível de significância, a potência do teste t é praticamente igual (apenas ligeiramente superior) à do teste M-W-W.

Tabela 12.16
Cálculo da estatística W (Exemplo 12.12).

Variável X_P :	1266	—	1337	1366	—	1420	—	1464	1471	1475
Variável X_C :	—	1280	—	—	1379	—	1457	—	—	—
Ordem i (X_C):	—	2	—	—	5	—	7	—	—	—
Variável X_P :	—	1483	1488	1527	1551	1552	1590	—	—	—
Variável X_C :	1480	—	—	—	—	—	—	1600	1620	1631
Ordem i (X_C):	11	—	—	—	—	—	—	18	19	20
Variável X_P :	—	1645	—	1673	—	—	—	—	—	1736
Variável X_C :	1633	—	—	—	1679	1681	1684	1693	1694	—
Ordem i (X_C):	21	—	23	—	25	26	27	28	29	—
Variável X_P :	—	1754	1758	1795	—	—	1854	—	—	—
Variável X_C :	1737	—	—	—	1798	1810	—	1857	1859	2115
Ordem i (X_C):	31	—	—	—	35	36	—	38	39	40
$\Sigma i = w = 480$										

12.3.2.2 AMOSTRAS EMPARELHADAS: TESTE DO SINAL E TESTE DE WILCOXON

Suponha-se que se pretende analisar o efeito de um determinado factor sobre a localização de uma distribuição populacional. Admita-se que, em vez de amostras independentes, se dispõe de observações emparelhadas. Nestas condições, a variável aleatória diferença (ou diferença relativa) entre pares de observações pode servir de base à realização de um teste de localização (paramétrico ou não-paramétrico) que se considere pertinente. No que, em particular, diz respeito aos testes de localização não-paramétricos, a escolha entre o teste do sinal e o teste de Wilcoxon basear-se-á nos critérios apresentados anteriormente.

Exemplo 12.13

Mediu-se a capacidade torácica de 7 indivíduos seleccionados aleatoriamente. Esse grupo de indivíduos submeteu-se voluntariamente, durante um mês, a um treino especial que tinha por objectivo o aumento daquela capacidade. No final do mês de treino, foi medida, de novo, a capacidade torácica. Os resultados de ambas as medições estão representados na Tabela 12.17 (em litros). Na tabela apresentam-se também observações da variação relativa da capacidade torácica, tida como mais adequada do que a variação absoluta, para se avaliar o impacto do treino.

Com base nos dados apresentados, poder-se-á concluir, ao nível de significância de 5%, que o treino é eficaz?

◆ Teste do sinal

Denotando por p a proporção de indivíduos para os quais a capacidade torácica aumentou, o teste do sinal é conduzido com base nas hipóteses:

$$H_0: p = 0.5$$

$$H_1: p > 0.5.$$

No caso de a hipótese nula ser verdadeira, a estatística de teste,

Y (número de vezes em que a capacidade torácica aumentou),

segue uma distribuição $B(7, 0.5)$.

Consultando a Tabela 1 do Anexo «Tabelas», verifica-se que, para $N = 7$ e $p = 0.5$, $P(Y \geq 5) = 0.2266$, valor que é superior ao nível de significância especificado. Deste modo, H_0 não pode ser rejeitada.

◆ Teste de Wilcoxon

Admita-se agora que a variação relativa da capacidade torácica se distribui de forma simétrica em torno da mediana η_0 . É assim possível executar o teste de Wilcoxon, de acordo as seguintes hipóteses:

$$H_0: \eta_0 = 0;$$

$$H_1: \eta_0 > 0.$$

O cálculo da estatística de teste é apresentado na Tabela 12.18.

Tabela 12.17
Capacidades torácicas (em litros) antes e depois de um treino específico (Exemplo 12.13).

Indivíduo	Antes do treino C_A	Depois do treino C_B	Diferença relativa $\Delta_C/C_A = (C_B - C_A)/C_A$
A	3.5	3.4	-0.029
B	3.6	3.9	0.083
C	4.1	4.5	0.098
D	2.9	3.1	0.069
E	3.4	3.9	0.147
F	4.2	4.4	0.048
G	3.9	3.8	-0.026

Tabela 12.18
Teste de Wilcoxon (Exemplo 12.13).

(Δ_C/C_A)	$ \Delta_C/C_A $	Ordem (+)	Ordem (-)
-0.029	0.029	—	2
0.083	0.083	5	—
0.098	0.098	6	—
0.069	0.069	4	—
0.147	0.147	7	—
0.048	0.048	3	—
-0.026	0.026	—	1
		$T_+ = 25$	$T_- = 3$

Consultando a Tabela 11 do Anexo «Tabelas», para $N = 7$ verifica-se que $P(T_+ \geq 25) = 0.039$, pelo que H_0 é rejeitada ao nível de significância de 5%. Se os pressupostos admitidos forem válidos (simetria da distribuição de Δ_C/C_A), este resultado significa que o treino é eficaz, na medida em que contribui para o aumento da capacidade torácica mediana.

12.4 TESTES DE ALEATORIEDADE

Admita-se que em vinte lançamentos da moeda E-C ao ar se observa uma sequência de resultados alternados Escudo-Caravela-Escudo-Caravela Percebe-se imediatamente que a amostra constituída por tais observações não é aleatória. De facto, o que é insólito nesta experiência não é a ocorrência de dez Escudos e de dez Caravelas, mas sim a ordem pela qual estes resultados aparecem.


Em geral, a não-aleatoriedade pode ocorrer de muitas formas: mistura de populações com diferentes médias ou diferentes variâncias, correlação positiva ou negativa entre observações sucessivas, periodicidade, etc. Na Figura 12.7 ilustram-se algumas destas situações, para o caso de uma variável contínua. Repare-se que, quando a amostra é aleatória, a linha que une as observações sucessivas cruza frequentemente a mediana amostral (ver Figura 12.7 (a)). Se o número de cruzamentos é muito baixo (ver Figura 12.7 (b) e (d)), há fortes razões para supor que as observações não estão ordenadas «ao acaso». Do mesmo modo, se o número de cruzamentos da linha mediana for muito elevado (ver Figura 12.7 (c)) tal significa que a seguir a uma observação acima da mediana se segue uma outra abaixo e vice-versa, situação que não é compatível com a hipótese da aleatoriedade. O mesmo raciocínio poderia ser aplicado ao número de vezes que é inflectido o sentido ascendente ou descendente da sucessão de observações. Um número muito baixo ou muito alto de inflexões constitui igualmente uma indicação de não-aleatoriedade.

Figura 12.7
Sequências de observações aleatórias e não-aleatórias.


(a) Observações aleatórias



(b) Observações correlacionadas (positivamente)



(c) Observações correlacionadas (negativamente)



(d) Observações provenientes de duas populações



Nesta secção serão apresentados dois testes: o teste das sequências e o teste das sequências ascendentes e descendentes.

O teste das sequências incide sobre um conjunto de observações classificadas dicotomicamente: Escudo-Caravela, homem-mulher, grande-pequeno, etc. No caso de variáveis expressas em escalas de nível superior ao nominal, o teste das sequências poderá ser utilizado se as observações forem transformadas artificialmente em símbolos de dois tipos: por exemplo, cada observação cujo valor se situe acima da mediana amostral é substituída pela letra A e cada observação cujo valor lhe seja inferior é substituída por B. Porém, neste processo perde-se informação. Por essa razão, quando se dispõe de observações expressas numa escala ordinal, de intervalo ou absoluta, é geralmente preferível efectuar o teste das sequências ascendentes e descendentes.

12.4.1 TESTE DAS SEQUÊNCIAS

Define-se por **sequência** um conjunto de observações idênticas (por exemplo A, A, A, ...) que é precedido ou seguido por uma observação do outro tipo (por exemplo, B). A definição comporta sequências constituídas por uma só observação. Por exemplo, o conjunto de observações A, B, A, A, A, inclui três sequências. Em geral, uma amostra de dimensão N , constituída por N_A observações de um tipo e N_B observações do outro, apresentará $r \leq N$ sequências (por convenção, admitir-se-á que $N_B \leq N_A$).

A estatística do teste baseia-se na variável R — número de sequências numa amostra de dimensão N (representando-se por r qualquer valor particular que esta variável aleatória tome). Na Tabela 13 do Anexo «Tabelas» apresentam-se valores P correspondentes a áreas das caudas direita e esquerda da distribuição de R quando a amostra for aleatória (isto é, quando a hipótese nula for verdadeira). Tais áreas são dadas para todos os valores possíveis de N_A e N_B , tais que $N \leq 20$ e ainda para algumas situações nas quais $20 < N \leq 24$.

Se a hipótese nula for verdadeira e se os valores de N_A ou de N_B não se encontrarem na Tabela 13 do Anexo «Tabelas», a distribuição de R pode ser aproximada pela distribuição Normal com parâmetros

$$\mu_R = \frac{2 \cdot N_A \cdot N_B}{N} + 1 \quad \text{e} \quad \sigma_R = \sqrt{\frac{2 \cdot N_A \cdot N_B \cdot (2 \cdot N_A \cdot N_B - N)}{N^2 \cdot (N - 1)}}.$$

Nestas condições, a estatística utilizada no teste das sequências é então

$$ET = Z = \frac{R - \mu_R}{\sigma_R}. \quad (12.10)$$

Quando H_0 for verdadeira, ET segue aproximadamente uma distribuição $N(0, 1)$.

Em testes bilaterais, as hipóteses nula e alternativa são formuladas nos seguintes termos:

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória.

Quando a hipótese nula for falsa, as observações tenderão ora a agrupar-se (ver Figura 12.7 (b)) ora a misturar-se excessivamente (ver Figura 12.7 (c)). Assim, pode construir-se o teste unilateral à esquerda

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória, pois as observações têm tendência para se agrupar (o valor que R toma, r , deverá ser muito baixo),

ou o teste unilateral à direita

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória, pois as observações têm tendência para se misturar (o valor r deverá ser muito alto).

Quando o teste for unilateral à direita (ou à esquerda), os valores críticos de R deverão ser procurados na cauda direita (ou esquerda) da sua distribuição.

Exemplo 12.14

Recorrendo ao teste das sequências, pretende-se verificar a aleatoriedade da amostra seguinte constituída pelos resultados de 25 lançamentos da moeda E-C:

[E, E, C, C, E, C, E, E, C, E, C, C, E, E, C, E, E, C, E, E, C, C, E, C]

Neste caso, $N_A = 14$, $N_B = 11$ e $r = 16$.

• Formulação das hipóteses:

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória.

• Nível de significância:

O nível de significância será fixado em 5%.

• Cálculo da estatística de teste:

Dado que $N = 25$ (valor não contemplado na Tabela 13 do Anexo «Tabelas»), admitir-se-á que R segue uma distribuição Normal. Como

$$\mu_R = \frac{2 \cdot 14 \cdot 11}{25} + 1 = 13.32 \quad \text{e} \quad \sigma_R = \sqrt{\frac{2 \cdot 14 \cdot 11 \cdot (2 \cdot 14 \cdot 11 - 25)}{25^2 \cdot (25 - 1)}} = 2.41,$$

vem

$$z = \frac{r - \mu_R}{\sigma_R} = \frac{16 - 13.32}{2.41} = 1.11.$$

• Decisão estatística:

Uma vez que o teste é bilateral e $\alpha = 0.05$, H_0 seria rejeitada se a estatística do teste fosse superior a 1.96 ou inferior a -1.96. Atendendo a que $z = 1.11$, H_0 não pode ser rejeitada ao nível de significância de 5% (com valor de prova de $2 \cdot 13.35\% = 26.7\%$).

Admita-se que se pretende conduzir o mesmo teste, mas, agora, sem dispor das três primeiras observações, E, E, C. Ter-se-ia, então, $N = 22$, $N_A = 12$, $N_B = 10$ e $r = 15$. Nestas condições, o teste seria efectuado recorrendo à Tabela 13 do Anexo «Tabelas». Para $N_A = 12$, $N_B = 10$ e $r = 15$, só existe o valor tabelado da cauda direita, $P = 12.5\%$. Assim, H_0 não seria rejeitada, com o valor de prova de $2 \cdot 12.5\% = 25\%$.

12.4.2 TESTE DAS SEQUÊNCIAS ASCENDENTES E DESCENDENTES

Este teste aplica-se a observações expressas numa escala pelo menos ordinal. Uma **sequência** (ascendente ou descendente) consiste numa sucessão de observações ordenadas de forma crescente ou decrescente. Nestas condições, sempre que a ordenação altera o seu sentido, inicia-se uma nova sequência.

Tome-se como exemplo o conjunto de observações

{8.3, 5.6, 5.8, 6.1, 6.0, 6.9, 7.5, 7.7, 7.0}.

Se se substituir pelo símbolo «+» cada observação precedida por uma outra de valor inferior, e pelo símbolo «-» cada observação precedida por uma outra de valor superior, vem

{-, -, +, +, -, +, +, +, -}.

Cada conjunto de sinais «mais» representa uma sequência ascendente, e cada conjunto de sinais «menos» representa uma sequência descendente. Assim, nas nove observações existem cinco sequências: três descendentes e duas ascendentes. A dimensão da amostra será, como habitualmente, designada por N , enquanto que o número de sequências será representado pela variável aleatória V . Note-se que esta variável, que constitui a estatística de teste, só pode tomar valores inteiros entre 1 e $N - 1$. Compreende-se intuitivamente que, num conjunto de N observações aleatórias, o valor que V toma quando a amostra for aleatória não deverá ser nem muito próximo de 1 nem muito próximo de $N - 1$.

No caso de testes bilaterais, as hipóteses nula e alternativa são formuladas nos seguintes termos:

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória.

Se hipótese alternativa corresponder à existência de tendências (ver Figura 12.7 (b)) ou à alternância excessiva de valores altos e baixos (ver Figura 12.7 (c)), podem construir-se dois tipos de testes unilaterais. O teste unilateral à esquerda

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória, pois existem tendências nas observações amostrais (V tomará um valor muito baixo),

ou o teste unilateral à direita

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória, pois as observações da amostra têm propensão para alternar excessivamente (V tomará um valor muito alto).

Na Tabela 14 do Anexo «Tabelas» apresentam-se valores das caudas direita e esquerda da distribuição de V quando H_0 é verdadeira, para amostras com $N \leq 25$.

É possível demonstrar que, quando a hipótese nula é verdadeira, a distribuição de V tende assintoticamente para a distribuição Normal com N . A partir de $N = 26$, a aproximação da distribuição de V pela Normal já se pode considerar suficientemente precisa. O valor esperado e o desvio padrão de V são calculados recorrendo às expressões seguintes:

$$\mu_V = \frac{2 \cdot N - 1}{3} \quad \text{e} \quad \sigma_V = \sqrt{\frac{(16 \cdot N - 29)}{90}}.$$

Nestas condições, a estatística do teste é

$$ET = Z = \frac{V - \mu_V}{\sigma_V}. \quad (12.11)$$

Quando H_0 for verdadeira, ET segue aproximadamente uma distribuição $N(0, 1)$. Frequentemente, ocorrem situações nas quais há observações adjacentes idênticas. Nestas situações, recomenda-se que se registre o símbolo «0» naquelas que forem precedidas por outras de igual valor. Quando o número de «zeros» for pequeno face a N , tais «zeros» são ignorados no cálculo da estatística, e a dimensão da amostra é reduzida em conformidade.

Exemplo 12.15

Na Tabela 12.19 apresenta-se o número de jornais diários vendidos nos últimos quinze domingos por um quiosque no centro de uma cidade. Teste-se ao nível de significância de 5%, se a amostra permite corroborar a hipótese de que existe uma tendência nas vendas ao domingo.

◆ Formulação das hipóteses:

Se se pretende verificar a existência de uma tendência, o teste deverá ser unilateral à esquerda:

H_0 : A amostra é aleatória

H_1 : A amostra não é aleatória, pois existem tendências nas observações amostrais.

◆ Cálculo da estatística de teste:

Substituindo os valores amostrais por sinais «mais» e «menos», vem:

{-, +, -, +, +, 0, -, -, +, +, +, +, -, -},

pelo que $V = 6$.

◆ Decisão estatística:

De acordo com a Tabela 14 do Anexo «Tabelas», para $N = 14$ e $V = 6$ a probabilidade acumulada na cauda esquerda da correspondente distribuição de V é 4.41%. Assim, H_0 é rejeitada ao nível de significância de 5%.

Tabela 12.19
Vendas de jornais diários nos últimos quinze domingos (Exemplo 12.15).

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
27	68	45	53	61	61	32	19	64	65	67	69	71	37	35

A terminar, e uma vez esclarecida a natureza do teste das sequências ascendentes e descendentes, observa-se que ele não seria apropriado para detectar a situação de não-aleatoriedade ilustrada na Figura 12.7 (d). Neste caso, o teste apropriado seria, evidentemente, o teste das sequências.

12.5 TESTES DE ASSOCIAÇÃO

12.5.1 TESTE DE CORRELAÇÃO ORDINAL DE SPEARMAN

Considere-se que, de uma população contínua bivariada, se retira uma amostra aleatória constituída por N pares de observações das variáveis aleatórias X e Y , que se exprimem numa escala pelo menos ordinal: $\{(X_1, Y_1), \dots, (X_N, Y_N)\}$.

Considere-se ainda que as observações da variável X são ordenadas de forma crescente e lhes é atribuído um número de ordem, de acordo com a seguinte regra: à menor o número 1, à seguinte o número 2 e assim sucessivamente até N . Admita-se que se procede da mesma forma com os valores de Y . Os pares de observações podem assim ser substituídos por pares de números de ordem: por exemplo, (3, 2), (1, 4), etc.

Tabela 12.20
Exemplos de
associação perfeita
entre números
de ordem.

(i)		(ii)	
Variável X N.º de ordem	Variável Y N.º de ordem	Variável X N.º de ordem	Variável Y N.º de ordem
1	1	1	N
2	2	2	N - 1
.	.	.	.
N - 1	N - 1	N - 1	2
N	N	N	1

Se as variáveis X e Y estiverem perfeitamente associadas, deverá observar-se uma das duas situações representadas na Tabela 12.20. A situação representada em (i) corresponde a uma associação directa perfeita (na qual ao menor valor de X corresponde o menor de Y). A situação representada em (ii) ilustra o mesmo grau de associação mas, agora, do tipo inverso (agora ao menor valor de X corresponde o maior de Y).

Seja d_n (com $n = 1, 2, \dots, N$) a diferença entre os números de ordem de cada par de observações x_n e y_n . É fácil provar que o somatório

$$\sum_{n=1}^N d_n^2$$

é nulo numa situação de associação directa perfeita e toma o valor $N \cdot (N^2 - 1)/3$ no caso de uma associação inversa perfeita.

O psicólogo inglês Charles Spearman construiu uma medida de associação relativa (denominada **coeficiente de correlação ordinal de Spearman**), que se define com base naquele somatório, de acordo com a expressão

$$R_s = 1 - \frac{6 \cdot \sum_{n=1}^N d_n^2}{N \cdot (N^2 - 1)}. \quad (12.12)$$

O coeficiente R_s toma o valor 1 quando entre o conjunto das observações existe uma associação directa perfeita, e toma o valor -1 no caso de associação inversa perfeita. Quando não existir associação entre as variáveis X e Y , o coeficiente R_s situa-se próximo de zero.

Note-se que o coeficiente de correlação ordinal de Spearman tem um significado diferente do coeficiente de correlação ρ , estudado na Secção 5.6. De facto, o coeficiente de correlação de Pearson, ρ , que também pode tomar valores entre -1 e 1 , mede apenas o grau de relacionamento linear entre duas variáveis. O coeficiente R_s traduz formas mais gerais de relacionamento que se incluem na designação «grau de associação». Note-se que duas variáveis exibindo um grau de associação elevado podem ser ou não correlacionadas linearmente.

Com base no coeficiente R_s , pode construir-se o seguinte teste bilateral:

- H_0 : As variáveis não estão associadas
- H_1 : As variáveis estão associadas.

Podem ainda conceber-se as seguintes hipóteses alternativas:

- H_1 : Associação directa (teste unilateral à direita)
- H_1 : Associação inversa (teste unilateral à esquerda).

O coeficiente de correlação ordinal de Spearman constitui a estatística para testar H_0 . Na Tabela 15 do Anexo «Tabelas» apresentam-se os valores críticos da cauda direita da distribuição do coeficiente R_s (admitindo que H_0 é verdadeira), para $5 \leq N \leq 30$ e para os

níveis de significância $\alpha = 0.05, 0.025, 0.01$ e 0.005 . Atendendo à simetria da distribuição de R_s , os valores críticos correspondentes na cauda esquerda são obtidos trocando-se o sinal aos valores tabelados. Para dimensões de amostras superiores a 30, a estatística de teste pode ser substituída por

$$ET = \frac{R_s}{\sqrt{(1 - R_s^2)/(N - 2)}}, \quad (12.13)$$

que, quando H_0 é verdadeira, segue uma distribuição t de Student com $N - 2$ graus de liberdade.

Sempre que se verifiquem «empates», o procedimento a adoptar é análogo ao apresentado na Secção 12.3.1, a propósito do teste de Wilcoxon: atribui-se às observações naquela situação o número de ordem que corresponde à média aritmética dos números de ordem que as observações receberiam se não estivessem empatadas. Se existir um número pequeno de «empates» o valor da estatística R_s calculado através da expressão 12.12 não é significativamente afectado. No caso contrário, a estatística R_s tenderá a ser subestimada. Assim, quando se verificarem muitos «empates» é conveniente calcular R_s através da expressão

$$R_s = \frac{N \cdot (N^2 - 1) - 6 \cdot \sum_{n=1}^N d_n^2 - 6 \cdot (u' + v')}{\sqrt{N \cdot (N^2 - 1) - 12 \cdot u'} \cdot \sqrt{N \cdot (N^2 - 1) - 12 \cdot v'}}$$

com

$$u' = \left(\sum_i u_i^3 - \sum_i u_i \right) / 12 \quad \text{e} \quad v' = \left(\sum_i v_i^3 - \sum_i v_i \right) / 12,$$

em que u_i e v_i representam o número de empates no i -ésimo grupo de observações iguais pertencentes, respectivamente, à variável X e à variável Y (ver Secção 12.3.1).

Exemplo 12.16

Na Tabela 12.21 apresentam-se os resultados obtidos por 12 atletas em duas provas: corrida de 100 metros planos (em segundos) e salto em comprimento (em metros). Os atletas foram seleccionados aleatoriamente entre praticantes das classes júnior e sénior, inscritos há pelo menos dois anos num determinado clube desportivo. Será que os resultados permitem corroborar, ao nível de significância de 5%, a hipótese de que os bons velocistas são também bons saltadores em comprimento?

♦ Formulação das hipóteses:

O teste unilateral à direita é formulado como se segue:

H_0 : Os resultados no salto em comprimento não estão associados aos resultados nos 100 metros

H_1 : Os resultados no salto em comprimento estão directamente associados aos resultados nos 100 metros (isto é, os bons velocistas tendem a ser bons saltadores).

Tabela 12.21
Resultados obtidos
por 12 atletas nos
100 metros planos
(em segundos)
e no salto em
comprimento
(em metros).

Atleta	A	B	C	D	E	F	G	H	I	J	K	L
100 m	12.1	12.4	13.0	11.9	14.2	13.6	12.7	14.2	13.7	13.3	12.8	13.4
Salto	6.93	6.76	5.94	7.70	5.61	6.32	7.08	5.30	5.86	6.04	7.13	6.76

Tabela 12.22
Cálculos
referentes ao
coeficiente de
correlação
ordinal de
Spearman
(Exemplo
12.16).

Atleta	A	B	C	D	E	F	G	H	I	J	K	L
N.º de ordem (100 metros)	2	3	6	1	11.5	9	4	11.5	10	7	5	8
N.º de ordem (Salto em comp.)	4	5.5	9	1	11	7	3	12	10	8	2	5.5
d_i^2	4	6.25	9	0	0.25	4	1	0.25	0	1	9	6.25
$\Sigma d_i^2 = 41$												

♦ *Cálculo da estatística de teste:*

Na Tabela 12.22 apresentam-se os cálculos referentes a Σd_i^2 (note-se que, na definição dos números de ordem, se adoptou, tanto para a prova de 100 metros como para o salto em comprimento, o critério de associar números de ordem mais baixos a resultados melhores).

Como o número de observações empatadas é pequeno, o cálculo de R_s é efectuado recorrendo à expressão 12.12. Assim,

$$R_s = 1 - \frac{6 \cdot \sum_{i=1}^N d_i^2}{N \cdot (N^2 - 1)} = 1 - \frac{6 \cdot 41}{12 \cdot (12^2 - 1)} = 0.857.$$

♦ *Decisão estatística:*

De acordo com a Tabela 15 do Anexo «Tabelas», para $N = 12$ e $\alpha = 5\%$, o valor crítico de R_s é 0.497. Nestas condições, H_0 é rejeitada ao nível de significância de 5%, aceitando-se a hipótese de que os bons velocistas são igualmente bons saltadores em comprimento (a hipótese nula é rejeitada com um valor de prova inferior a 0.5%).

12.5.2 TESTE DO QUI-QUADRADO BASEADO NA TABELA DE CONTINGÊNCIA

Este teste permite verificar a independência entre duas variáveis que, sendo expressas em qualquer escala, se apresentam agrupadas em classes mutuamente exclusivas e exaustivas. Para ilustrar a estrutura do teste, considere-se o seguinte exemplo.

Exemplo 12.17

Admita-se que foi conduzida uma experiência no âmbito da qual se procurou testar se existe alguma relação entre a qualidade da secagem de máquinas de lavar roupa de um certo tipo e a velocidade de rotação a que se eleva o tambor da roupa na fase de centrifugação. Os resultados desta experiência, efectuada com base no comportamento de 90 máquinas, estão representados na Tabela 12.23.

As tabelas como aquela na qual se apresentam os resultados referentes ao Exemplo 12.17 são habitualmente designadas por **tabelas de contingência**. Admita-se que os resultados que nelas figuram resultam de amostras aleatórias. Tais resultados representam o número de observações incluídas nas diferentes combinações das classes nas quais as duas variáveis em estudo se exprimem.

O objectivo do teste é o de verificar se as duas variáveis em questão são ou não relacionadas. As hipóteses nula e alternativa são então as seguintes:

H_0 : As variáveis são independentes

H_1 : As variáveis não são independentes.

Note-se que na hipótese alternativa nada se diz quanto ao tipo de relacionamento das variáveis em estudo.

Suponha-se então que a variável X pode ser observada em I categorias não sobreponíveis (X_i , com $i = 1, 2, \dots, I$ e $I \geq 2$) e a variável Y em J categorias igualmente não sobreponíveis (Y_j , com $j = 1, 2, \dots, J$ e $J \geq 2$). Sejam (ver Tabela 12.24):

Tabela 12.23
Teste da qualidade
da secagem para 90
máquinas de lavar
(Exemplo 12.17).

		Qualidade da secagem				Total
		Mediocre	Suficiente	Boa	Muito boa	
Velocidade de rotação	600 rpm	12	8	7	3	30
	900 rpm	9	10	7	4	30
	1200 rpm	2	9	8	11	30
TOTAL		23	27	22	18	90

Tabela 12.24
Tabela de contin-
gência referente ao
teste de indepen-
dência do Qui-
quadrado.

	Y_1	Y_2	...	Y_J	Total
X_1	N_{11}	N_{12}	...	N_{1J}	$N_{1.}$
X_2	N_{21}	N_{22}	...	N_{2J}	$N_{2.}$
...	...	...	...	...	...
X_I	N_{I1}	N_{I2}	...	N_{IJ}	$N_{I.}$
Total	$N_{.1}$	$N_{.2}$	...	$N_{.J}$	N

N_{ij} : frequência observada na célula ij

$N_{i.} = \sum_{j=1}^J N_{ij}$: frequência marginal observada na categoria X_i

$N_{.j} = \sum_{i=1}^I N_{ij}$: frequência marginal observada na categoria Y_j

$N = \sum_{i=1}^I \sum_{j=1}^J N_{ij}$: dimensão da amostra.

Recorde-se que a função de probabilidade conjunta de duas variáveis independentes é igual ao produto das respectivas funções marginais de probabilidade (ver Secção 5.5 e expressão 5.16). Admitindo que H_0 é verdadeira, as frequências esperadas nas células ij , e_{ij} , podem assim ser calculadas recorrendo-se à relação

$$\frac{e_{ij}}{N} = \frac{N_{i.}}{N} \cdot \frac{N_{.j}}{N},$$

vindo

$$e_{ij} = \frac{N_{i.} \cdot N_{.j}}{N}.$$

À semelhança do teste da qualidade de ajuste, a estatística do teste de independência do Qui-quadrado (ver expressão 12.1) é

$$ET = Q'' = \sum_{i=1}^I \sum_{j=1}^J \frac{(N_{ij} - e_{ij})^2}{e_{ij}}. \quad (12.14)$$

No caso de a hipótese nula ser verdadeira, ET segue aproximadamente uma distribuição do Qui-quadrado com $(I-1) \cdot (J-1)$ graus de liberdade. Valores baixos de Q'' suportam a hipótese nula, pelo que os valores críticos do teste devem ser fixados na cauda direita da distribuição $\chi^2_{(I-1) \cdot (J-1)}$.

Tal como foi recomendado a propósito do teste de qualidade de ajuste (Secção 12.1.1), o teste de independência não deve ser utilizado se mais do que 20% das frequências e_{ij} forem inferiores a 5 ou se alguma das frequências e_{ij} for menor do que 1. Em geral,

a agregação de classes adjacentes em tabelas de contingência não faz qualquer sentido. No entanto, se tal for possível, poderão ser agregadas classes adjacentes até que aquelas condições se encontrem preenchidas.

No caso de $I = J = 2$, a estatística de teste deverá ser modificada de acordo com a correcção de Yates:

$$ET \text{ (corrigida)} = \sum_{i=1}^2 \sum_{j=1}^2 \frac{(|N_{ij} - e_{ij}| - 0.5)^2}{e_{ij}}$$

Esta correcção permite uma melhor aproximação da estatística de teste à distribuição χ^2 .

Exemplo 12.18

A partir dos dados relativos ao Exemplo 12.17 (ver Tabela 12.23) pretende-se testar a hipótese de a qualidade da secagem estar relacionada com a velocidade de centrifugação.

◆ Formulação das hipóteses:

H_0 : A qualidade da lavagem e a velocidade de centrifugação são independentes

H_1 : A qualidade da lavagem e a velocidade de centrifugação não são independentes.

◆ Nível de significância do teste:

O teste será efectuado ao nível de significância de 5%.

◆ Regra de decisão:

Como $I = 3$ (três velocidades) e $J = 4$ (quatro classificações de qualidade), o número de graus de liberdade da distribuição do Qui-quadrado é de 6. Assim (ver Tabela 4 do Anexo «Tabelas») o valor crítico da distribuição $\chi^2_6(0.05)$ é 12.59.

◆ Cálculo da estatística de teste:

Na Tabela 12.25 representam-se entre parênteses curvos os valores de cada frequência esperada, calculados através da expressão

$$\frac{e_{ij}}{N} = \frac{N_{i.}}{N} \cdot \frac{N_{.j}}{N}$$

Em cada célula e entre parênteses rectos, representam-se ainda os valores de

$$\frac{(N_{ij} - e_{ij})^2}{e_{ij}}$$


A estatística Q'' , que corresponde à soma destas parcelas, toma o valor 13.516.

◆ Decisão estatística:

Como $Q'' = 13.516 > \chi^2_6(0.05) = 12.59$, H_0 é rejeitada. Fica estabelecido (ao nível de significância de 5%) que as variáveis «qualidade da secagem» e «velocidade de rotação» não são independentes.

Tabela 12.25
Cálculo da estatística Q''
(Exemplo 12.18).

		Qualidade da secagem				
		Medíocre	Suficiente	Boa	Muito boa	Total
Velocidade de rotação	600 rpm	12 (7.67) [2.449]	8 (9.0) [0.111]	7 (7.33) [0.015]	3 (6.0) [1.500]	30
	900 rpm	9 (7.67) [0.232]	10 (9.0) [0.111]	7 (7.33) [0.015]	4 (6.0) [0.667]	30
	1200 rpm	2 (7.67) [4.188]	9 (9.0) [0.0]	8 (7.33) [0.061]	11 (6.0) [4.167]	30
	TOTAL	23	27	22	18	90
						$Q'' = 13.516$



■ APÊNDICE 12.1 ILUSTRAÇÃO DO CÁLCULO DA FUNÇÃO DE PROBABILIDADE DA ESTATÍSTICA T (TESTE DE WILCOXON)

(1) Admita-se que uma população contínua e simétrica em torno de η_0 se obtém de uma amostra aleatória de dimensão $N = 3$, por exemplo. Nestas circunstâncias, os números de ordem associados às diferenças $|d_n|$ ($n = 1, 2, 3$) são 1, 2 e 3.

(2) Na Tabela A12.1.1 indicam-se as possíveis sequências de números de ordem (para $N = 3$) e os respectivos valores de T_+ e T_- .

Tabela A12.1.1
Sequências possíveis de números de ordem para $N = 3$ e respectivos valores de T_+ e T_- .

T_-	Números de ordem ($d_n < 0$)	Números de ordem ($d_n > 0$)	T_+
6	1, 2, 3	nenhum	0
5	2, 3	1	1
4	1, 3	2	2
3	1, 2	3	3
3	3	1, 2	3
2	2	1, 3	4
1	1	2, 3	5
0	nenhum	1, 2, 3	6

(3) Cada uma das sequências apresentadas na Tabela A12.1.1 tem probabilidade de ocorrência de $1/2^3 = 1/8$. Assim, para $N = 3$, é imediato determinar a função de probabilidade de T_+ e de T_- . Tal função está representada na tabela seguinte:

Tabela A12.1.2
Função de probabilidade de T_+ e T_- (para $N = 3$).

T_-	T_+	Probabilidade
6	0	1/8
5	1	1/8
4	2	1/8
3	3	2/8
2	4	1/8
1	5	1/8
0	6	1/8

APÊNDICE 12.2 ILUSTRAÇÃO DO CÁLCULO DA FUNÇÃO DE PROBABILIDADE DA ESTATÍSTICA W (TESTE DE MANN-WHITNEY-WILCOXON)

- (1) Seja N_A a dimensão da amostra da variável Z (associada à população A) e N_B a dimensão da amostra da variável X (associada à população B), com $N_B \leq N_A$ e $N_A + N_B = N$. Se H_0 for verdadeira, isto é, se as distribuições de Z e X forem idênticas, podem ocorrer

$$\binom{N}{N_A} = \frac{N!}{N_A! N_B!}$$

diferentes seqüências de observações de Z e X com igual probabilidade.

- (2) Seja, por exemplo, $N_A = 3$ e $N_B = 2$. Na tabela A12.2.1 representam-se as

$$\binom{5}{3} = 10$$

possíveis seqüências de observações de Z e de X e os respectivos valores de W .


- (3) De acordo com os resultados apresentados na Tabela A12.2.1, é imediato determinar a função probabilidade de W para $N_A = 3$ e $N_B = 2$. Tal função é apresentada na Tabela A12.2.2.

Tabela A12.2.1
Seqüências possíveis de observações de X e de Y em amostras de dimensões $N_A = 3$ e $N_B = 2$ e respectivo valor de W .

Seqüência	W
$x x z z z$	3
$x z x z z$	4
$x z z x z$	5
$z x x z z$	5
$z x z x z$	6
$x z z z x$	6
$z z x x z$	7
$z x z z x$	7
$z z x z x$	8
$z z z x x$	9

Tabela A12.2.2
Função de probabilidade de W (para $N_A = 3$ e $N_B = 2$).

w	$P(W = w)$
3	1/10
4	1/10
5	2/10
6	2/10
7	2/10
8	1/10
9	1/10



Problemas

- 12.1. Um fabricante de margarina deseja testar se o comportamento de compra das donas-de-casa é influenciável pela embalagem na qual a margarina é vendida. Com esse objectivo, levou a efeito uma experiência que consistiu em colocar num hipermercado, em iguais condições de preço e visibilidade/exposição, a margarina embalada de 5 formas diferentes. As vendas atribuíveis a donas-de-casa foram as seguintes

Embalagem	Vendas
A	132
B	74
C	120
D	131
E	162

Teste, ao nível de significância de 5%, se a embalagem teve influência na preferência das donas-de-casa.

- 12.2. Uma companhia aérea registou qual o número de passageiros que, tendo efectuado reserva para um determinado destino, acabava por não fazer o *check in*. Para cem voos escolhidos aleatoriamente, os resultados foram os seguintes:

N.º de ausências	N.º de voos
0	21
1	36
2	23
3	13
4	4
5	2
6	1

Teste, ao nível de significância de 5%, se a distribuição do número de ausências por voo segue uma distribuição de Poisson.

- 12.3. Na tabela seguinte apresentam-se os desvios entre o tempo planeado para uma determinada operação de montagem numa linha de produção e o tempo efectivamente gasto (em segundos). Admite-se que as 20 observações foram recolhidas de forma aleatória.

Observação	Desvio	Observação	Desvio
1	50	11	165
2	53	12	47
3	102	13	22
4	-39	14	-46
5	112	15	91
6	64	16	140
7	-122	17	-38
8	104	18	109
9	37	19	41
10	32	20	-33

Teste, ao nível de significância de 5%, se os desvios seguem uma distribuição Normal.

- 12.4. Num relatório recentemente publicado num determinado país, afirma-se que 50% das PME's que consomem propano, pagam as suas contas de gás no prazo de 14 ou menos dias úteis após a recepção da factura correspondente.

Uma das empresas que distribui propano para fins industriais recolheu uma amostra aleatória constituída pelos números de dias que 10 dos seus clientes demoraram a pagar as contas. Os resultados são os que se apresentam na tabela seguinte.

Prazos de pagamento (dias)	34	3	4	44	29	17	32	14	28	16
----------------------------	----	---	---	----	----	----	----	----	----	----

Teste, ao nível de significância de 5%, se a afirmação produzida no relatório é válida.

- 12.5. A empresa produtora do creme protector solar MORENAÇA deseja testar se uma nova fórmula, recentemente proposta pelo departamento de desenvolvimento, é mais eficaz do que a actualmente adoptada. De entre os colaboradores que se ofereceram para participar no teste, 10 deles foram seleccionados aleatoriamente. Os cremes baseados nas duas fórmulas foram aplicados nas costas destes voluntários (um de cada lado, direito e esquerdo) que, posteriormente, foram submetidas a radiações solares controladas. Os resultados do teste — que exprimem o grau de queimadura solar da pele — apresentam-se na tabela seguinte.

Colaborador	Fórmula actual	Nova fórmula
A	41	37
B	42	39
C	48	31
D	38	39
E	38	34
F	45	47
G	21	19
H	28	30
I	29	25
J	14	8

Teste ao nível de significância de 5%, se o creme baseado na nova fórmula é um protector mais eficaz do que o actual. De entre os testes não-paramétricos aplicáveis a esta situação, escolha o mais potente.

- 12.6. Uma empresa de construção civil e imobiliária colocou à venda uma série de andares de luxo. O seu gerente deseja confirmar se o facto de os seus potenciais clientes verem um andar modelo melhora a sua predisposição para a compra.

A 15 clientes, que apenas tiveram acesso a um folheto que descreve o andar, perguntou quanto estariam dispostos a pagar por ele. As respostas, expressas em milhares de euros, foram as seguintes:

[315, 165, 220, 235, 275, 195, 300, 225, 120, 155, 265, 150, 180, 345, 270].

A mesma pergunta foi feita a outros 12 potenciais clientes que, além de terem visto o folheto, puderam inspecionar o andar modelo. As respostas, expressas em milhares de contos, foram, neste caso, as seguintes:

[325, 225, 215, 355, 260, 255, 320, 175, 295, 375, 335, 240].

Teste ao nível de significância de 5%, se a inspecção do andar modelo conduziu a uma maior valorização do andar por parte dos potenciais clientes.

- 12.7. Para testar o efeito de um tratamento de superfície anticorrosivo, foi efectuada uma experiência que consistiu em enterrar 20 tubos, nos quais metade da sua superfície tinha sido tratada, e verificar, um ano depois, qual o grau de corrosão das superfícies tratadas e não-tratadas. Os resultados, traduzindo o grau de corrosão, incluem-se na tabela seguinte:

Tubo n.º	1	2	3	4	5	6	7	8	9	10
Grau de corrosão (superfície não tratada)	42	37	61	74	55	57	44	55	37	70
Grau de corrosão (superfície tratada)	40	44	54	65	53	59	41	46	48	63
Tubo n.º	11	12	13	14	15	16	17	18	19	20
Grau de corrosão (superfície não tratada)	52	55	60	48	52	44	56	4	39	47
Grau de corrosão (superfície tratada)	41	45	51	38	56	37	54	33	38	41

Admitindo que, em média, o tratamento não pode fazer subir o grau de corrosão das superfícies, teste, ao nível de significância de 5%, se ele tem, de facto, algum efeito anticorrosivo.

- 12.8. Na tabela seguinte representa-se o peso (em toneladas) de uvas produzidas num hectare de vinha localizada numa determinada região demarcada, nos últimos 20 anos.

Ano	77	78	79	80	81	82	83	84	85	86
Peso (toneladas)	3.56	4.40	5.42	6.51	8.30	5.78	5.22	4.67	7.68	8.34
Ano	87	88	89	90	91	92	93	94	95	96
Peso (toneladas)	9.89	7.35	5.15	3.80	5.62	7.73	7.93	6.35	8.92	9.77

Teste, ao nível de significância de 5%, se se verificam tendências (períodos de aumento ou de diminuição persistentes) na produção de uvas naquela parcela, ao longo dos últimos 20 anos.

- 12.9. Na tabela seguinte apresentam-se registos relativos à percentagem de frequência às aulas verificada em 12 turmas práticas de um curso de Estatística e à percentagem de sucessos dos alunos nelas matriculados.


Presença nas aulas práticas [%]	Sucessos [%]
95.2	60.5
94.7	72.8
84.6	71.3
83.1	64.7
79.7	66.2
72.6	56.5
70.8	56.0
70.8	60.8
64.1	52.4
62.9	45.7
49.2	33.2
41.8	33.2

Teste, ao nível de significância de 5%, se existe associação directa entre as variáveis em causa.

- 12.10. Para testar a atitude relativamente ao novo detergente BMB, foi distribuído um pacote a cada uma de 350 donas-de-casa seleccionadas aleatoriamente em 3 cidades (*F*, *P* e *L*) de um país. A cada uma delas foi perguntado qual a sua opinião (favorável/indiferente/desfavorável) sobre o novo detergente. Os números de respostas obtidas apresentam-se na tabela seguinte.

		Cidade		
		<i>F</i>	<i>P</i>	<i>L</i>
Opinião	Favorável	49	25	34
	Indiferente	27	68	38
	Desfavorável	17	44	48

Verifique, ao nível de significância de 5%, se a cidade de origem das donas-de-casa afecta a atitude destas relativamente ao novo detergente.



13.1 INTRODUÇÃO

Nos Capítulos 10 e 11 foram abordados os conceitos fundamentais de inferência estatística que permitem construir intervalos de confiança ou testar hipóteses envolvendo um parâmetro de uma população ou, alternativamente, envolvendo a razão ou a diferença entre parâmetros de duas populações.

Com a análise de variância pode ir-se mais além, uma vez que esta técnica possibilita a comparação entre parâmetros de mais do que duas populações. A partir da análise da dispersão total presente num conjunto de dados, a análise de variância permite identificar os factores que deram origem a essa dispersão e avaliar a contribuição de cada um deles.

No âmbito deste capítulo, apenas serão estudados casos envolvendo a comparação entre valores esperados. No entanto, é igualmente possível utilizar a análise de variância para testar hipóteses envolvendo outros parâmetros, por exemplo, variâncias.

A análise de variância é mais potente quando incide sobre dados provenientes de experiências especialmente concebidas para a aplicação desta técnica. Não obstante, pode também ser aplicada a dados obtidos a partir de processos menos «orientados» de recolha de informação.

Ao longo deste capítulo, a técnica de análise de variância será, em muitos casos, designada sinteticamente por ANOVA (esta designação, de utilização muito frequente, resulta da contracção do nome que a técnica recebe em inglês: *analysis of variance*).

13.2 ANÁLISE DE VARIÂNCIA COM UM FACTOR

13.2.1 MODELO ANOVA DE EFEITOS FIXOS

O objectivo e os conceitos envolvidos na aplicação da análise de variância às situações mais simples serão ilustrados recorrendo ao exemplo seguinte.

Exemplo 13.1

Um determinado departamento governamental está preocupado com os aumentos dos custos verificados no decurso de projectos de I&D (investigação e desenvolvimento) encomendados aos institutos *A*, *B*, *C* e *D*. Por esse motivo, decidiu analisar os custos associados

a diferentes projectos, calculando, para cada um deles, a razão entre o custo final incorrido e o custo inicialmente previsto (na altura da adjudicação). Para cada projecto, ambos os custos foram expressos numa base constante. Os resultados apresentam-se na Tabela 13.1.

A questão que se coloca é a de saber se os quatro institutos têm um comportamento global distinto em relação ao agravamento de custos. Ou, por outras palavras, pretende saber-se se o factor «instituto» tem efeito significativo sobre o agravamento do custo dos projectos.

Tabela 13.1
Relação custos incorridos/custos previstos em projectos realizados pelos institutos A, B, C e D (Exemplo 13.1).

Instituto	Custo incorrido/Custo previsto					
A	1.0	0.8	1.9	1.1	2.7	
B	1.7	2.5	3.0	2.2	3.7	1.9
C	1.0	1.3	3.2	1.4	1.3	2.0
D	3.8	2.8	1.9	3.0	2.5	

Para descrever situações como a que foi apresentada neste exemplo, adopta-se um modelo do tipo

$$X_{ij} = \underbrace{\mu_i}_{\text{valor esperado do grupo}} + \underbrace{E_{ij}}_{\text{erro}} = \underbrace{\mu}_{\text{parâmetro global}} + \underbrace{\alpha_i}_{\text{efeito do grupo}} + \underbrace{E_{ij}}_{\text{erro}} \quad (13.1)$$

onde

i : índice que designa o grupo de observações para os quais o factor se mantém inalterado ($i = 1, 2, \dots, I$)

j : índice que denota uma observação dentro de cada grupo ($j = 1, 2, \dots, J_i$)

X_{ij} : j -ésima observação do i -ésimo grupo

μ_i : valor esperado do i -ésimo grupo de observações

μ : parâmetro global fixo

α_i : parâmetro que corresponde ao efeito do i -ésimo grupo

E_{ij} : erro associado à j -ésima observação do i -ésimo grupo.

Este modelo designa-se por **modelo ANOVA com um factor** (aquele que permite diferenciar as observações de grupo para grupo) de **efeitos fixos** (mais adiante neste capítulo tornar-se-á evidente o conceito de *efeitos fixos* por contraposição ao de *efeitos variáveis*).

Neste modelo, admite-se que os erros E_{ij} satisfazem as seguintes condições:

- (i) têm valor esperado nulo e variância constante, σ^2 ,
- (ii) são mutuamente independentes, e
- (iii) são Normalmente distribuídos.

Simbolicamente, estas três condições traduzem-se por

$$E_{ij} \sim IN(0, \sigma^2)$$

onde as letras *IN* denotam erros *I*ndependentes e *N*ormalmente distribuídos.

Nas situações descritas por este tipo de modelo, interessa, por um lado, estimar os valores esperados μ_i associados aos diferentes grupos e, por outro, testar se são significativamente diferentes uns dos outros (isto é, testar se os efeitos α_i são significativamente diferentes de zero). Relativamente ao Exemplo 13.1, haveria então que, em primeiro lugar, estimar os valores esperados dos agravamentos de custo dos projectos de I&D realizados pelos diferentes institutos. Adicionalmente, haveria que testar se há diferenças significativas entre tais valores esperados.

O teste fundamental da análise de variância pode então ser especificado do seguinte modo:


$$H_0: \mu_1 = \mu_2 = \dots = \mu_I = \mu \quad (\text{ou, equivalentemente, } \alpha_1 = \dots = \alpha_I = 0)$$

$$H_1: \text{Nem todos os } \mu_i \text{ são iguais} \quad (\text{ou, equivalentemente, algum } \alpha_i \neq 0).$$


Na Figura 13.1 representa-se graficamente o significado destas hipóteses para a situação descrita no Exemplo 13.1.

Figura 13.1
Hipóteses nula e alternativa na análise de variância com um factor de efeitos fixos (Exemplo 13.1).

H_0 : Todos os μ_i são iguais (todos os $\alpha_i = 0$)



H_1 : Nem todos os μ_i são iguais (algum $\alpha_i \neq 0$)



Se forem verdadeiras as duas primeiras condições que se admitiu serem satisfeitas pelos erros E_{ij} , está-se nas condições ideais de aplicação do método dos mínimos quadrados à estimação dos parâmetros do modelo ANOVA apresentado na expressão 13.1. Nesta situação, estimadores eficientes de tais parâmetros podem ser obtidos minimizando o somatório

$$SEQ = \sum_{i=1}^I \sum_{j=1}^{J_i} E_{ij}^2.$$

No Apêndice 13.1 mostra-se que tal minimização conduz às estimativas seguintes:

$$\begin{aligned} \hat{\mu}_i &= \bar{x}_i & (i = 1, \dots, I) \\ \hat{\mu} &= \bar{x} \\ \hat{\alpha}_i &= \hat{\mu}_i - \hat{\mu} & (i = 1, \dots, I), \end{aligned} \quad (13.2)$$

onde $\bar{x}_i$ representa, para cada grupo i ($i = 1, \dots, I$), a média das observações nele incluídas e $\bar{x}$ representa a média global de todas as observações.

Exemplo 13.2

Retomando o Exemplo 13.1, calculem-se as estimativas dos parâmetros em causa:

$$\hat{\mu}_A = \bar{x}_A = (1.0 + 0.8 + 1.9 + 1.1 + 2.7)/5 = 1.5$$

$$\hat{\mu}_B = \bar{x}_B = (1.7 + 2.5 + 3.0 + 2.2 + 3.7 + 1.9)/6 = 2.5$$

$$\hat{\mu}_C = \bar{x}_C = (1.0 + 1.3 + 3.2 + 1.4 + 1.3 + 2.0)/6 = 1.7$$

$$\hat{\mu}_D = \bar{x}_D = (3.8 + 2.8 + 1.9 + 3.0 + 2.5)/5 = 2.8$$

$$\hat{\mu} = \bar{x} = 2.12$$

$$\hat{\alpha}_A = 1.5 - 2.12 = -0.62$$

$$\hat{\alpha}_B = 2.5 - 2.12 = +0.38$$

$$\hat{\alpha}_C = 1.7 - 2.12 = -0.42$$

$$\hat{\alpha}_D = 2.8 - 2.12 = +0.68$$

Considerem-se agora os desvios das várias observações X_{ij} em relação à média global $\bar{X}$, encarando as observações, a sua média e, portanto os desvios, como variáveis aleatórias. No Apêndice 13.2 demonstra-se que a soma dos quadrados de tais desvios,

$$\sum_i \sum_j (X_{ij} - \bar{X})^2,$$

pode ser expressa através da seguinte relação:

$$\underbrace{\sum_i \sum_j (X_{ij} - \bar{X})^2}_{VT} = \underbrace{\sum_i \sum_j (X_{ij} - \bar{x}_i)^2}_{VDG} + \underbrace{\sum_i J_i \cdot (\bar{x}_i - \bar{X})^2}_{VEG} \quad (13.3)$$

onde:

- VT:** Variação (ou, Soma de Quadrados) Total das observações X_{ij} em relação a $\bar{X}$;
VDG: Variação Dentro dos Grupos, que corresponde à soma das variações das observações X_{ij} dentro de cada um dos diferentes grupos (para cada grupo i , a variação das observações é calculada relativamente a $\bar{x}_i$);
VEG: Variação Entre Grupos, que corresponde à soma ponderada das variações das médias de cada grupo, $\bar{x}_i$, em torno da média global, $\bar{X}$ (com pesos proporcionais ao número de observações em cada grupo, J_i).

Note-se que a variação dentro dos grupos (VDG) é calculada com base nos desvios quadráticos de todas as observações, num total de $\sum J_i$. No entanto, como a partir das observações foram previamente calculadas I médias, $\bar{x}_i$, só restam $\sum J_i - I$ desvios independentes.

Define-se o **Desvio Quadrático Médio** (ou, a **Média de Quadrados**) **Dentro dos Grupos** ($DQMDG$) como o quociente entre a variação dentro dos grupos e o número de termos independentes que tal variação comporta (ou, como também se diz, o correspondente número de graus de liberdade):

$$DQMDG = \frac{VDG}{\sum_i J_i - I} = \frac{1}{\sum_i J_i - I} \cdot \sum_i \sum_j (X_{ij} - \bar{x}_i)^2. \quad (13.4)$$

Por sua vez, a variação entre grupos (VEG) é calculada com base em I desvios das médias dos grupos em relação à média global, $\bar{X}$. Desses I desvios, só $I - 1$ são independentes, uma vez que qualquer um deles pode ser calculado a partir dos $I - 1$ restantes e de $\bar{X}$.

Define-se o **Desvio Quadrático Médio Entre Grupos** ($DQMEG$) como o quociente

$$DQMEG = \frac{VEG}{I - 1} = \frac{1}{I - 1} \cdot \sum_i J_i \cdot (\bar{x}_i - \bar{X})^2. \quad (13.5)$$

Com base nas duas primeiras hipóteses formuladas anteriormente acerca dos erros E_{ij} , é possível demonstrar (ver Apêndice 13.3) que os valores esperados dos desvios quadráticos médios (dentro e entre grupos) são dados por

$$E(DQMDG) = \sigma^2$$

e por

$$E(DQMEG) = \sigma^2 + \frac{1}{I - 1} \cdot \sum_i J_i \cdot (\alpha_i - \bar{\alpha})^2,$$

respectivamente.

Os resultados até agora obtidos são habitualmente resumidos numa tabela ANOVA para o modelo com um factor de efeitos fixos (ver Tabela 13.2).

Com base nos desvios quadráticos médios ($DQMEG$ e $DQMDG$) é então possível realizar o teste fundamental da análise de variância, que permite verificar se os efeitos α_i são significativamente diferentes de zero. No entanto, a realização deste teste requer que às duas primeiras hipóteses relativas aos erros E_{ij} se junte a terceira: a de que os erros seguem uma distribuição Normal.

Se a hipótese nula $H_0: \mu_1 = \mu_2 = \dots = \mu$ (ou, equivalentemente, $\alpha_1 = \alpha_2 = \dots = 0$) for verdadeira, então tanto o desvio quadrático médio entre grupos ($DQMEG$) como o desvio quadrático médio dentro dos grupos ($DQMDG$) constituem estimativas da variância dos erros E_{ij} , σ^2 (ver Tabela 13.2).

O teste ANOVA tem assim a seguinte estrutura:

$$H_0: \mu_1 = \mu_2 = \dots = \mu_i = \mu \quad (\text{ou } \alpha_1 = \dots = \alpha_i = 0)$$

$$H_1: \text{Nem todos os } \mu_i \text{ são iguais} \quad (\text{ou algum } \alpha_i \neq 0)$$

$$ET = \frac{DQMEG}{DQMDG}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_1, GL_2}$$

No Apêndice 13.4 justifica-se a distribuição da estatística deste teste quando a hipótese nula é verdadeira. É nesta justificação que se invoca a condição de Normalidade dos erros E_{ij} .

Note-se que este teste é sempre unilateral à direita. De facto, se prevalecer a hipótese alternativa, isto é, se pelo menos um dos α_i for diferente de zero, o valor esperado do $DQMEG$ é superior a σ^2 enquanto que o valor esperado de $DQMDG$ se mantém igual a σ^2 (ver Tabela 13.2).

Exemplo 13.3

Teste-se a hipótese nula de os quatro institutos referidos no Exemplo 13.1 terem um comportamento idêntico em relação ao agravamento dos custos dos projectos.

Para os dados fornecidos no Exemplo 13.1, vem:

$$VT = \sum_i \sum_j (x_{ij} - \bar{x})^2 = 16.619$$

$$VDG = \sum_i \sum_j (x_{ij} - \bar{x}_i)^2 = 10.460$$

$$VEG = \sum_i J_i \cdot (\bar{x}_i - \bar{x})^2 = 6.159$$

Tabela 13.2. Tabela ANOVA para o modelo com um factor de efeitos fixos.

Fontes de Variação	Variações (Somadas de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Entre grupos (EG)	(Variação «explicada» pelas diferenças entre médias) $VEG = \sum_i J_i \cdot (\bar{X}_i - \bar{X})^2$	$GL_1 = I - 1$	$DQMEG = VEG / GL_1$	$E[DQMEG] = \sigma^2 + \frac{1}{I-1} \cdot \sum_i J_i \cdot (\alpha_i - \bar{\alpha})^2$
Dentro dos grupos (DG)	(Variação residual «não explicada») $VDC = \sum_i \sum_j (X_{ij} - \bar{X}_i)^2$	$GL_2 = \left(\sum_i J_i \right) - I$	$DQMDG = VDC / GL_2$	$E[DQMDG] = \sigma^2$
Total (T)	(Variação total) $VT = \sum_i \sum_j (X_{ij} - \bar{X})^2$	$GL = GL_1 + GL_2 = \left(\sum_i J_i \right) - I$		

Na Tabela 13.3 apresenta-se a tabela ANOVA relativa a este exemplo. Ao nível de significância de 5%, o teste ANOVA conduz ao seguinte resultado:

$$ET = \frac{DQMEG}{DQMDG} = \frac{2.053}{0.581} = 3.533 > F_{3,18} (\alpha = 0.05) = 3.16,$$

pelo que a hipótese nula $H_0: \mu_1 = \mu_2 = \dots = \mu_I = \mu$ deverá ser rejeitada. Conclui-se assim (com um valor de prova de aproximadamente 3.6%) que os institutos têm comportamentos distintos no que diz respeito ao agravamento dos custos de execução de projectos de I&D.

Tabela 13.3
Tabela ANOVA
para os dados
do Exemplo 13.1.

Fontes de variação	Variações	Graus de liberdade	Desvios quadráticos médios
Entre grupos (EG) (entre institutos)	6.159	3	2.053
Dentro dos grupos (DG) (nos institutos)	10.460	18	0.581
TOTAL (T)	16.619	21	

No exemplo que acabou de se apresentar, concluiu-se que a hipótese nula era falsa. Ficou no entanto por esclarecer qual ou quais os valores esperados que eram, de facto, diferentes.

Uma abordagem possível desta questão consistiria em construir intervalos de confiança para as diferenças entre dois quaisquer valores esperados: $\mu_1 - \mu_2$, $\mu_1 - \mu_3$, ou, em geral, $\mu_{i_1} - \mu_{i_2}$ (com $i_1 \neq i_2$). Admitindo que $E_{ij} \sim IN(0, \sigma^2)$, a expressão 10.13 apresentada no Capítulo 10 permite definir tais intervalos. Assim, para a diferença $\mu_{i_1} - \mu_{i_2}$, os limites do intervalo de confiança a $(1 - \alpha) \cdot 100\%$ são:

$$(\bar{X}_{i_1} - \bar{X}_{i_2}) \pm t_{GL_2}(\alpha/2) \cdot S \cdot \sqrt{\frac{1}{J_{i_1}} + \frac{1}{J_{i_2}}}$$

onde

$$S = \hat{\sigma} = \sqrt{DQMDG} = \sqrt{\frac{1}{\sum_i J_i - I} \cdot \sum_i \sum_j (\bar{X}_{ij} - \bar{X}_i)^2}$$

e

$$GL_2 = \left(\sum_i J_i \right) - I.$$

Exemplo 13.4

Voltando ao Exemplo 13.1, o intervalo de confiança para a diferença entre os valores esperados das razões «custos incorridos/custos previstos» correspondentes aos institutos B e A é:

$$\begin{aligned} & (\bar{x}_2 - \bar{x}_1) \pm t_{18}(0.025) \cdot \sqrt{DQMDG} \cdot \sqrt{\frac{1}{J_2} + \frac{1}{J_1}} \\ & = (2.5 - 1.5) \pm 2.101 \cdot \sqrt{0.581} \cdot \sqrt{\frac{1}{6} + \frac{1}{5}} \\ & = 1.0 \pm 0.97, \end{aligned}$$

donde o intervalo de confiança é

$$[0.03, 1.97].$$

Como este intervalo só contém valores positivos, pode concluir-se, ao nível de significância de 5%, que o agravamento de custos no instituto B é superior ao que se verifica no instituto A.

No entanto, o cálculo de intervalos de confiança considerando os valores esperados dois a dois acarreta um inconveniente sério: embora seja verdade que cada um dos intervalos tem um nível de confiança de $(1 - \alpha) \cdot 100\%$, o mesmo não se pode dizer para o conjunto dos intervalos. No Exemplo 13.3, que envolve 4 grupos de dados correspondentes a outros tantos institutos, seria possível construir $C_2^4 = 6$ intervalos a 95%. Se se pudesse admitir a independência das variáveis com base nas quais os intervalos são definidos, o nível de confiança para o conjunto dos intervalos seria de $(0.95)^6 = 0.735$. Este valor representaria a probabilidade de todos os intervalos definidos incluírem as diferenças entre os valores esperados em causa.

Uma solução para este problema seria a de fixar o nível de confiança de cada um dos intervalos em função da confiança pretendida para o conjunto dos intervalos. Este procedimento seria extremamente simples se a hipótese de independência acima referida fosse aceitável. No entanto, sucede que tal hipótese está longe de ser realista.

Definir-se-ão em seguida dois métodos que, tomando em conta esse facto, permitem definir intervalos de confiança para o conjunto das diferenças entre valores esperados, $\mu_{i_1} - \mu_{i_2}$ ($i_1 \neq i_2$).

13.2.2 DEFINIÇÃO CONJUNTA DE INTERVALOS DE CONFIANÇA PELO MÉTODO DE TUKEY

Serão consideradas duas situações: aquela em que as amostras relativas aos diferentes grupos têm todas a mesma dimensão e uma outra em que as dimensões das amostras relativas aos diferentes grupos são «moderadamente» diferentes.

13.2.2.1 AMOSTRAS EQUILIBRADAS

Neste caso admite-se que as amostras têm todas a mesma dimensão, isto é, $J_1 = J_2 = \dots = J_I = J$.

Os limites do intervalo de confiança para $\mu_{i_1} - \mu_{i_2}$ ($i_1 \neq i_2$) a $(1 - \alpha) \cdot 100\%$ são dados por

$$(\bar{X}_{i_1} - \bar{X}_{i_2}) \pm q_{I, GL_2}(\alpha) \cdot \sqrt{DQMDG / J}, \quad (13.6)$$

onde

I : número de grupos

J : número de observações em cada grupo

$$DQMDG: \frac{1}{I \cdot (J - 1)} \cdot \sum_i \sum_j (X_{ij} - \bar{X}_i)^2$$

$$GL_2: I \cdot (J - 1)$$

$q_{I, GL_2}(\alpha)$: parâmetro definido na Tabela 16 do Anexo «Tabelas»

13.2.2.2 AMOSTRAS POUCO DESEQUILIBRADAS

Neste caso incluem-se situações para as quais $(J_i)_{\text{máximo}} \leq 2 \cdot (J_i)_{\text{mínimo}}$. Os intervalos de confiança definidos pela expressão 13.6 podem ainda ser utilizados, depois de introduzidas as seguintes adaptações:

$$(i) \quad J = \frac{I}{\frac{1}{J_1} + \frac{1}{J_2} + \dots + \frac{1}{J_I}}$$

(recorde-se que J se designa por média harmónica dos valores J_i)

$$(ii) \quad DQMDG = \frac{1}{\sum_i J_i - I} \cdot \sum_i \sum_j (X_{ij} - \bar{X}_i)^2$$

$$(iii) \quad GL_2 = \sum_i J_i - I.$$

Exemplo 13.5

Retomando o Exemplo 13.1, calculem-se os intervalos de confiança a 95% para $\mu_{i_1} - \mu_{i_2}$ ($i_1 \neq i_2$).

O Exemplo 13.1 envolve quatro amostras pouco desequilibradas. Assim, os intervalos de confiança podem ser definidos pelo método de Tukey nos termos seguintes:

$$I = 4$$

$$J = \frac{4}{\frac{1}{5} + \frac{1}{6} + \frac{1}{6} + \frac{1}{5}} = 5.45$$

$$DQMDG = 0.581 \quad (\text{ver Tabela 13.3})$$

$$GL_2 = 22 - 4 = 18$$

$$q_{4, 18}(0.05) = 4.00 \quad (\text{ver Tabela 16 do Anexo «Tabelas»}).$$

A amplitude dos intervalos de confiança é então dada por

$$2 \cdot q_{4, 18}(0.05) \cdot \sqrt{DQMDG / J} = 2 \cdot 4.00 \cdot \sqrt{0.581 / 5.45} = 2.62.$$

Na Tabela 13.4 apresenta-se o conjunto dos intervalos ao qual se associa a confiança de 95% (ou seja, existe 95% de confiança de os intervalos referidos na tabela conterem, todos, as respectivas diferenças $(\mu_{i_1} - \mu_{i_2})$).

Tabela 13.4
Intervalos de confiança definidos pelo método de Tukey (Exemplo 13.1).

i_1	i_2	$\bar{X}_{i_1} - \bar{X}_{i_2}$	Int. de conf. a 95%
1	2	1.50 - 2.50 = -1.00	[-2.31, 0.31]
1	3	1.50 - 1.70 = -0.20	[-1.51, 1.11]
1	4	1.50 - 2.80 = -1.30	[-2.61, 0.01]
2	3	2.50 - 1.70 = 0.80	[-0.51, 2.11]
2	4	2.50 - 2.80 = -0.30	[-1.61, 1.01]
3	4	1.70 - 2.80 = -1.10	[-2.41, 0.21]

Registe-se que, apesar de no teste ANOVA ter sido possível rejeitar a hipótese nula ($H_0: \mu_1 = \mu_2 = \dots = \mu_I = \mu$) ao nível de significância de 5%, tal não ocorreu na comparação dos valores esperados dois a dois (de facto, nenhum dos intervalos de confiança apresentados na Tabela 13.4 exclui o zero). Isto é, foi possível concluir-se que havia diferenças significativas entre os valores esperados mas não se conseguiu identificar entre quais deles.

13.2.3 DEFINIÇÃO CONJUNTA DE INTERVALOS DE CONFIANÇA PELO MÉTODO DE SCHEFFÉ

Quando as dimensões das amostras correspondentes aos diferentes grupos são muito diferentes — isto é, quando $(J_i)_{\text{máximo}} > 2 \cdot (J_i)_{\text{mínimo}}$ — os intervalos de confiança não podem ser definidos através do método de Tukey. Neste caso pode recorrer-se ao proposto por Scheffé, que não exige a satisfação de nenhuma condição no que diz respeito ao equilíbrio dimensional das amostras. De acordo com este método, os limites dos intervalos de confiança para $\mu_{i_1} - \mu_{i_2}$ ($i_1 \neq i_2$) a $(1 - \alpha) \cdot 100\%$ são dados por

$$(\bar{X}_{i_1} - \bar{X}_{i_2}) \pm \sqrt{(I - 1) \cdot F_{GL_1, GL_2}(\alpha) \cdot DQMDG \cdot \left(\frac{1}{J_{i_1}} + \frac{1}{J_{i_2}} \right)}, \quad (13.7)$$

onde

I : número de grupos

$$F_{GL, GL_2}(\alpha): F_{(I-1), (\sum_j J_j - I)}(\alpha) \quad (\text{Tabela 6 do Anexo «Tabelas»})$$

$$DQMDG: \frac{1}{\sum_j J_j - I} \cdot \sum_i \sum_j (X_{ij} - \bar{X}_i)^2.$$

Exemplo 13.6

Considerando, de novo, o Exemplo 13.1, calcule-se a amplitude dos intervalos de confiança a 95% para $\mu_{i_1} - \mu_{i_2}$ ($i_1 \neq i_2$), utilizando o método de Scheffé.

Dado que

$$I - 1 = 3,$$

$$F_{3, 18}(\alpha = 0.05) = 3.16 \quad (\text{ver Tabela 6 do Anexo «Tabelas»}),$$

$$DQMDG = 0.581 \quad (\text{ver Tabela 13.3})$$

e que

$$\frac{1}{J_1} + \frac{1}{J_2} = \frac{1}{5} + \frac{1}{6} = 0.366,$$

resulta

$$\sqrt{3 \cdot (3.16) \cdot (0.581) \cdot (0.366)} = 1.42.$$

A amplitude dos intervalos de confiança é então de

$$2 \cdot 1.42 = 2.84.$$

Chama-se a atenção para o facto de a amplitude dos intervalos calculados segundo o método de Scheffé (ver exemplo anterior) ser maior do que a dos intervalos definidos de acordo com o método de Tukey (ver Exemplo 13.5). A explicação para este facto é simples: dado que o método de Scheffé é mais geral do que o de Tukey (pois este só é aplicável a amostras equilibradas ou pouco desequilibradas), então os intervalos de confiança especificados pelo método de Scheffé têm de ser mais conservadores e, portanto, têm de ter uma amplitude maior.

13.2.4 MODELO DE EFEITOS VARIÁVEIS

No Exemplo 13.1, que serviu de introdução ao modelo de efeitos fixos, admitiu-se que o objectivo da análise era o de verificar se existiam diferenças entre os comportamentos dos 4 institutos A, B, C, e D (e só esses). Suponha-se agora que se está perante a situação descrita no exemplo seguinte.

Exemplo 13.7

Um departamento governamental tem projectos de I&D encomendados a um número elevado de institutos. Por razões ligadas ao controlo de custos, está interessado em saber se, na generalidade dos casos, os institutos a quem adjudica projectos têm ou não comportamentos idênticos no tocante ao agravamento dos custos inicialmente orçamentados. Com este objectivo, o departamento decide recolher uma amostra aleatória de quatro institutos e, em relação a cada um deles, analisar o agravamento de custos relativos a um conjunto de projectos seleccionados ao acaso.

Admita-se que os institutos e os resultados associados às amostras de projectos são os que foram considerados no Exemplo 13.1 (ver Tabela 13.1).

A diferença essencial entre a situação descrita neste exemplo e a que se dava conta no Exemplo 13.1 é a de que, agora, os quatro institutos seleccionados (A, B, C, e D) são uma *amostra aleatória* dos institutos aos quais são encomendados projectos de I&D. Assim, o valor esperado das observações, por exemplo do instituto A, é um valor seleccionado aleatoriamente entre muitos valores equivalentes possíveis (valores esperados das observações dos institutos E, F, G, etc.). Contrariamente, no Exemplo 13.1 os institutos A, B, C e D constituíam a totalidade da população em apreço.

Nestas circunstâncias, os elementos μ_i e α_i que integravam o modelo representado pela expressão 13.1 já não são constantes, mas sim *variáveis aleatórias*, sendo substituídos por M_i e A_i , respectivamente. O modelo ANOVA com **um factor de efeitos variáveis** (ou **aleatórios**) toma então a forma seguinte:

$$X_{ij} = \underbrace{M_i}_{\text{valor esperado}} + \underbrace{E_{ij}}_{\text{erro}} = \underbrace{\mu}_{\text{parâmetro}} + \underbrace{A_i}_{\text{efeito variável}} + \underbrace{E_{ij}}_{\text{erro}}, \quad (13.8)$$

onde se admite que

$$A_i \sim IN(0, \sigma_A^2) \quad \text{e} \quad E_{ij} \sim IN(0, \sigma^2)$$

e que as variáveis A_i e $E_{i,j}$ (onde i_1 e i_2 denotam quaisquer valores particulares, iguais ou diferentes, do índice i) são independentes.

Na Figura 13.2 ilustra-se o modelo consagrado na expressão 13.8.

Note-se que, como se admite que os valores esperados de A_i e E_{ij} são nulos, o parâmetro μ representa neste modelo o valor esperado do conjunto das observações (sem especificação do grupo a que pertencem).

A tabela ANOVA correspondente ao modelo de efeitos variáveis apresenta-se na página seguinte. Repare-se que a única diferença em relação à tabela respeitante ao modelo de efeitos fixos reside no valor esperado do desvio quadrático médio entre grupos. Tudo o resto é idêntico nas Tabelas 13.2 e 13.5.

Figura 13.2
Modelo ANOVA com
um factor de efeitos
variáveis.




Tabela 13.5. Tabela ANOVA para o modelo com um factor de efeitos variáveis.

Fontes de Variação	Variações (Somadas de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Entre grupos (EG)	(Variação «explicada» pelas diferenças entre médias) $VEG = \sum_i J_i \cdot (\bar{X}_i - \bar{X})^2$	$GL_1 = I - 1$	$DQMEG = VEG / GL_1$	$E[DQMEG] = \sigma^2 + h \cdot \sigma_A^2$ com $h = \frac{\left(\sum_i J_i\right)^2 - \sum_i J_i^2}{\left(\sum_i J_i\right) \cdot (I - 1)}$
Dentro dos grupos (DG)	(Variação residual «não explicada») $VDG = \sum_i \sum_j (X_{ij} - \bar{X}_i)^2$	$GL_2 = \left(\sum_i J_i\right) - I$	$DQMDG = VDG / GL_2$	$E[DQMDG] = \sigma^2$
Total (T)	(Variação total) $VT = \sum_i \sum_j (X_{ij} - \bar{X})^2$	$GL = GL_1 + GL_2 = \left(\sum_i J_i\right) - 1$		

No caso de efeitos variáveis, o teste ANOVA consiste em verificar se a variância σ_A^2 das variáveis A_i (que reflectem os efeitos dos grupos) é significativamente maior do que zero. De facto, se $\sigma_A^2 = 0$, resulta que todos os A_i serão nulos ou, equivalentemente, que todos os M_i serão iguais a μ . O teste ANOVA tem, neste caso, a seguinte estrutura:

$$H_0: \sigma_A^2 = 0 \quad (\text{ou } M_1 = M_2 = \dots = \mu \text{ ou, ainda, } A_1 = A_2 = \dots = 0)$$

$$H_1: \sigma_A^2 > 0$$

$$ET = \frac{DQMEG}{DQMDG}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_1, GL_2}$$

Observe-se que os cálculos envolvidos neste teste e o seu resultado (rejeição ou não de H_0) são iguais aos correspondentes na situação descrita pelo modelo de efeitos fixos.

Quando H_0 é rejeitada, faz sentido estimar a variância dos efeitos, σ_A^2 . Dado que, como se regista na coluna da direita da Tabela 13.5,

$$E(DQMEG) = \sigma^2 + h \cdot \sigma_A^2, \text{ com } h = \frac{\left(\sum_i J_i\right)^2 - \sum_i J_i^2}{\left(\sum_i J_i\right) \cdot (I - 1)},$$

e que

$$E(DQMDG) = \sigma^2,$$

o estimador de σ_A^2 vem

$$\hat{\sigma}_A^2 = \frac{DQMEG - DQMDG}{h}.$$

Exemplo 13.8

Pretende-se dar resposta à questão colocada no Exemplo 13.7, ou seja, a de saber se, na generalidade, os institutos aos quais o departamento governamental adjudica projectos têm comportamentos idênticos ou não. Recorde-se que se dispõe de dados relativos a quatro institutos seleccionados aleatoriamente e que tais dados são os representados na Tabela 13.1.

A hipótese nula $H_0: \sigma_A^2 = 0$ é rejeitada ao nível de significância de 5%, já que os cálculos e os resultados para este teste ANOVA com efeitos variáveis são exactamente iguais aos que foram efectuados no Exemplo 13.2 (efeitos fixos).

Uma vez que se rejeita $H_0: \sigma_A^2 = 0$ e que se aceita $H_1: \sigma_A^2 > 0$, será interessante estimar o valor de σ_A^2 . Assim,

$$h = \frac{22^2 - (5^2 + 6^2 + 6^2 + 5^2)}{22 \cdot (4 - 1)} = 5.48$$

e (ver Tabela 13.3)

$$\hat{\sigma}_A^2 = \frac{DQMEG - DQMDG}{h} = \frac{2.053 - 0.581}{5.48} = 0.27.$$

13.3 ANÁLISE DE VARIÂNCIA COM DOIS FACTORES

13.3.1 INTRODUÇÃO

No âmbito desta secção só será contemplada a organização de dados amostrais de acordo com o esquema designado por **classificação cruzada**. Neste tipo de organização de dados, cada nível de um factor é cruzado com cada um dos níveis do outro factor. Na Tabela 13.6 ilustra-se a classificação cruzada de dados, considerando uma situação na qual se dispõe de duas observações para cada combinação de cada nível de um factor com cada nível do outro (isto é, duas observações por célula).

Além desta restrição relativa à organização dos dados, só será considerado o caso em que as amostras correspondentes a cada célula são equilibradas, isto é, têm todas a mesma dimensão. Dada a complexidade da análise de variância com dois factores e com amostras desequilibradas, é geralmente reconhecido que o esforço envolvido na constituição de amostras de igual dimensão é amplamente compensado pela simplificação introduzida na análise e interpretação dos resultados.

Tabela 13.6
Classificação
cruzada de dados
(duas observações
por célula).

Factor A Nível	Factor B / Nível				
	1	2	3	4	5
1	x_{111}, x_{112}	x_{121}, x_{122}	x_{131}, x_{132}	x_{141}, x_{142}	x_{151}, x_{152}
2	x_{211}, x_{212}	x_{221}, x_{222}	x_{231}, x_{232}	x_{241}, x_{242}	x_{251}, x_{252}
3	x_{311}, x_{312}	x_{321}, x_{322}	x_{331}, x_{332}	x_{341}, x_{342}	x_{351}, x_{352}

13.3.2 MODELO DE EFEITOS FIXOS COM DUAS OU MAIS OBSERVAÇÕES POR CÉLULA

Para ilustrar a aplicação da técnica de análise de variância ao caso de dois factores com efeitos fixos, considere-se o seguinte exemplo.

Exemplo 13.9

Para caracterizar o consumo de um determinado modelo, o director de uma revista de automóveis solicitou a três jornalistas (X, Y e Z) que efectuassem testes de consumo em estrada (E) e em cidade (C), pedindo-lhes que conduzissem «normalmente». Ao formular o pedido desta maneira procurava, para além de testar o modelo em causa, caracterizar o comportamento dos jornalistas.

Os resultados obtidos nos testes resumem-se na Tabela 13.7, sendo expressos em litros/100 km.

Tabela 13.7
Dados relativos aos
testes de consumo
(Exemplo 13.9).

	E				C			
X	6.6	8.0	6.2	7.6	9.1	7.8	10.2	8.9
Y	7.8	8.5	9.2	8.9	12.6	11.6	10.9	13.3
Z	10.1	10.9	9.7	8.9	12.6	8.4	10.7	10.3

Para descrever situações correspondentes a este exemplo, adopta-se um **modelo com dois factores de efeitos fixos**. Se os efeitos dos dois factores fossem aditivos, tal modelo poderia escrever-se da seguinte forma:

$$X_{ijk} = \underbrace{\mu_{ij}}_{\text{valor esperado da célula}} + \underbrace{E_{ijk}}_{\text{erro}} = \underbrace{\mu}_{\text{parâmetro global}} + \underbrace{\alpha_i}_{\text{efeito do 1.º factor (linha)}} + \underbrace{\beta_j}_{\text{efeito do 2.º factor (coluna)}} + \underbrace{E_{ijk}}_{\text{erro}} \quad (13.9)$$

onde

i : índice que denota diferentes níveis de um dos factores (numa tabela de duas entradas, tal como a Tabela 13.6, o índice i designará as linhas) ($i = 1, 2, \dots, I$)

j : índice relativo ao nível do segundo factor (numa tabela de duas entradas o índice j designará as colunas) ($j = 1, 2, \dots, J$)

k : índice relativo a cada observação dentro de cada célula (i, j) ($k = 1, \dots, K$ com $K \geq 2$)

X_{ijk} : k -ésima observação da célula (i, j)

μ_{ij} : valor esperado das observações incluídas na célula (i, j).

Este modelo descreveria adequadamente situações do tipo da que é ilustrada na Figura 13.3 (na qual o primeiro factor tem três níveis e o segundo dois).

Frequentemente os efeitos não são aditivos, havendo lugar a interacção entre eles. Para descrever estas situações, o modelo com dois factores de efeitos fixos deverá ser escrito na sua forma mais geral:

$$X_{ijk} = \underbrace{\mu_{ij}}_{\text{valor esperado da célula}} + \underbrace{E_{ijk}}_{\text{erro}} = \underbrace{\mu}_{\text{parâmetro global}} + \underbrace{\alpha_i}_{\text{efeito do 1.º factor (linha)}} + \underbrace{\beta_j}_{\text{efeito do 2.º factor (coluna)}} + \underbrace{\gamma_{ij}}_{\text{interacção}} + \underbrace{E_{ijk}}_{\text{erro}} \quad (13.10)$$

Quando $\gamma_{ij} = 0$ (interacção nula) este modelo coincide com aquele que foi anteriormente apresentado. Quando $\gamma_{ij} \neq 0$ ele representará situações como a que se apresenta na Figura 13.4 (compare-se a situação que é ilustrada nesta figura com aquela que se representa na Figura 13.3).

Figura 13.3
Modelo com dois
factores de efeitos
fixos aditivos.





Figura 13.4
Modelo com dois
factores com
interacção entre
os efeitos.



Para estimar e testar a interação e os efeitos linha e coluna, admitem-se, relativamente aos erros, hipóteses idênticas às aquelas que foram consideradas no âmbito do modelo com um factor de efeitos fixos (ver 13.2.1):

$$E_{ijk} \sim IN(0, \sigma^2)$$

Se os erros forem independentes entre si e tiverem valor esperado nulo e variância constante, os estimadores obtidos via método dos mínimos quadrados são eficientes. As estimativas correspondentes (isto é, os valores particulares de tais estimadores) vêm dados por:

$$\hat{\mu}_{ij} = \bar{x}_{ij} = \frac{1}{K} \cdot \sum_k x_{ijk} \quad (13.11)$$

Impondo as restrições

$$\begin{aligned} \sum_i \alpha_i &= 0 & \sum_j \gamma_j &= 0 \quad (j=1, 2, \dots, J) \\ \sum_j \beta_j &= 0 & \sum_i \gamma_i &= 0 \quad (i=1, 2, \dots, I) \end{aligned}$$

obtêm-se as estimativas seguintes:

$$\begin{aligned} \hat{\mu} &= \bar{x}_{..} = \frac{1}{I \cdot J \cdot K} \cdot \sum_i \sum_j \sum_k x_{ijk} \\ \hat{\alpha}_i &= \bar{x}_{i.} - \hat{\mu} = \frac{1}{J \cdot K} \cdot \sum_j \sum_k x_{ijk} - \bar{x}_{..} \quad (i=1, \dots, I) \\ \hat{\beta}_j &= \bar{x}_{.j} - \hat{\mu} = \frac{1}{I \cdot K} \cdot \sum_i \sum_k x_{ijk} - \bar{x}_{..} \quad (j=1, \dots, J) \\ \hat{\gamma}_{ij} &= \bar{x}_{ij} - \bar{x}_{i.} - \bar{x}_{.j} + \bar{x}_{..} \quad (i=1, \dots, I; j=1, \dots, J), \end{aligned} \quad (13.12)$$

onde

$\bar{x}_{..}$: média global de todas as observações

$\bar{x}_{i.}$: média amostral das observações incluídas na linha i

$\bar{x}_{.j}$: média amostral das observações incluídas na coluna j .

Exemplo 13.10

Retomando o Exemplo 13.9, calculem-se as estimativas referidas nas expressões 13.12, recorrendo aos resultados que se apresentam na Tabela 13.8.

Tabela 13.8
Cálculos das
médias relativas
ao Exemplo 13.9.

		(j = 1)	(j = 2)	
		E	C	
(i = 1)	X	$\bar{x}_{11} = 7.10$	$\bar{x}_{12} = 9.00$	$\bar{x}_{1.} = 8.05$
(i = 2)	Y	$\bar{x}_{21} = 8.60$	$\bar{x}_{22} = 12.10$	$\bar{x}_{2.} = 10.35$
(i = 3)	Z	$\bar{x}_{31} = 9.90$	$\bar{x}_{32} = 10.50$	$\bar{x}_{3.} = 10.20$
		$\bar{x}_{.1} = 8.53$	$\bar{x}_{.2} = 10.53$	$\bar{x}_{..} = 9.53$

Assim:

$$\hat{\mu} = \bar{x}_{..} = 9.53$$

$$\hat{\alpha}_1 = \bar{x}_{1.} - \hat{\mu} = 8.05 - 9.53 = -1.48$$

$$\hat{\alpha}_2 = \bar{x}_{2.} - \hat{\mu} = 10.35 - 9.53 = 0.82$$

$$\hat{\alpha}_3 = \bar{x}_{3.} - \hat{\mu} = 10.20 - 9.53 = 0.67$$

$$\hat{\beta}_1 = \bar{x}_{.1} - \hat{\mu} = 8.53 - 9.53 = -1.00$$

$$\hat{\beta}_2 = \bar{x}_{.2} - \hat{\mu} = 10.53 - 9.53 = 1.00$$

$$\hat{\gamma}_{11} = \bar{x}_{11} - \bar{x}_{1.} - \bar{x}_{.1} + \bar{x}_{..} = 7.1 - 8.05 - 8.53 + 9.53 = 0.05$$

$$\hat{\gamma}_{12} = \bar{x}_{12} - \bar{x}_{1.} - \bar{x}_{.2} + \bar{x}_{..} = 9.0 - 8.05 - 10.53 + 9.53 = -0.05$$

$$\hat{\gamma}_{21} = \bar{x}_{21} - \bar{x}_{2.} - \bar{x}_{.1} + \bar{x}_{..} = 8.6 - 10.35 - 8.53 + 9.53 = -0.75$$

$$\hat{\gamma}_{22} = \bar{x}_{22} - \bar{x}_{2.} - \bar{x}_{.2} + \bar{x}_{..} = 12.1 - 10.35 - 10.53 + 9.53 = 0.75$$

$$\hat{\gamma}_{31} = \bar{x}_{31} - \bar{x}_{3.} - \bar{x}_{.1} + \bar{x}_{..} = 9.9 - 10.20 - 8.53 + 9.53 = 0.70$$

$$\hat{\gamma}_{32} = \bar{x}_{32} - \bar{x}_{3.} - \bar{x}_{.2} + \bar{x}_{..} = 10.5 - 10.20 - 10.53 + 9.53 = -0.70$$

A variação total (VT)

$$VT = \sum_i \sum_j \sum_k (x_{ijk} - \bar{x}_{..})^2 \quad (13.13)$$

é decomponível nos termos:

$$\begin{aligned} VT &= \text{Variação Devida ao Factor Linha (VDFL)} \\ &+ \text{Variação Devida ao Factor Coluna (VDFC)} \\ &+ \text{Variação Devida à Interação (VDI)} \\ &+ \text{Variação Residual (VR)} \end{aligned}$$

onde

$$VDFL = K \cdot J \cdot \sum_i (\bar{x}_{i.} - \bar{x}_{..})^2; \quad (13.14)$$

$$VDFC = K \cdot I \cdot \sum_j (\bar{x}_{.j} - \bar{x}_{..})^2; \quad (13.15)$$

$$VDI = K \cdot \sum_i \sum_j (\bar{x}_{ij} - \bar{x}_{i.} - \bar{x}_{.j} + \bar{x}_{..})^2; \quad (13.16)$$

$$VR = \sum_i \sum_j \sum_k (x_{ijk} - \bar{x}_{ij})^2. \quad (13.17)$$

Os Desvios Quadráticos Médios, que são obtidos dividindo as variações apresentadas anteriormente pelos respectivos graus de liberdade, têm os valores esperados que se apresentam na última coluna da tabela ANOVA correspondente a este caso (Tabela 13.9).

Tabela 13.9. Tabela ANOVA para o modelo com dois factores de efeitos fixos com interacção.

Fontes de variação	Variações (Somas de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Factor linha (FL)	$VDL = K \cdot J \cdot \sum_i (\bar{X}_{i.} - \bar{X}_{..})^2$	$GL_1 = I - 1$	$DQMDFL = VDL / GL_1$	$E[DQMDFL] = \sigma^2 + \frac{J \cdot K}{I - 1} \cdot \sum_i \alpha_i^2$
Factor coluna (FC)	$VDFC = K \cdot I \cdot \sum_j (\bar{X}_{.j} - \bar{X}_{..})^2$	$GL_2 = J - 1$	$DQMDFC = VDFC / GL_2$	$E[DQMDFC] = \sigma^2 + \frac{I \cdot K}{J - 1} \cdot \sum_j \beta_j^2$
Interacção (I)	$VDI = K \cdot \sum_i \sum_j (\bar{X}_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2$	$GL_3 = (I - 1) \cdot (J - 1)$	$DQMDI = VDI / GL_3$	$E[DQMDI] = \sigma^2 + \frac{K}{(I - 1) \cdot (J - 1)} \cdot \sum_i \sum_j \gamma_{ij}^2$
Residual (Dentro das células) (R)	$VR = \sum_i \sum_j \sum_k (X_{ijk} - \bar{X}_{ij})^2$	$GL_4 = I \cdot J \cdot (K - 1)$	$DQMR = VR / GL_4$	$E[DQMR] = \sigma^2$
Total (T)	$VT = \sum_i \sum_j \sum_k (X_{ijk} - \bar{X}_{..})^2$	$GL = GL_1 + GL_2 + GL_3 + GL_4 = I \cdot J \cdot K - 1$		

Para testar se a interacção entre os factores, γ_{ij} , é significativa, pode recorrer-se ao seguinte teste ANOVA:

$$H_0: \gamma_{ij} = 0 \quad (\text{para todo o } i \text{ e todo o } j)$$

$$H_1: \text{Algum } \gamma_{ij} \neq 0$$

$$ET = \frac{DQMDI}{DQMR}$$

Uma vez que se admite que os erros E_{ijk} seguem distribuições Normais, então, quando H_0 é verdadeira, tanto o numerador como o denominador de ET são estimadores da mesma variância (σ^2) e, portanto, $ET \sim F_{GL_3, GL_4}$.

Para testar se os efeitos do factor linha, α_i , são significativamente diferentes de zero, pode utilizar-se o teste ANOVA com a seguinte estrutura:

$$H_0: \alpha_i = 0 \quad (\text{para todo o } i)$$

$$H_1: \text{Algum } \alpha_i \neq 0$$

$$ET = \frac{DQMDFL}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_1, GL_4}$$

Para testar se os efeitos do factor coluna, β_j , são significativamente diferentes de zero, aplica-se o seguinte teste ANOVA:

$$H_0: \beta_j = 0 \quad (\text{para todo o } j)$$


$$H_1: \text{Algum } \beta_j \neq 0$$

$$ET = \frac{DQMDFC}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_2, GL_4}$$

É importante notar que, quando as interacções são significativas do ponto de vista estatístico e, simultaneamente, são grandes quando comparadas com os efeitos α_i e β_j , os testes relativos a estes efeitos podem tornar-se destituídos de significado. Esta situação, ilustrada na Figura 13.5 (i), ocorre quando, do ponto de vista conceptual, não for possível isolar o impacto individual dos factores linha e coluna (que fica escondido na interacção). A situação oposta (na qual as interacções são significativas e o teste dos efeitos α_i e β_j ainda tem significado) representa-se na Figura 13.5 (ii).

Figura 13.5 Interpretação dos factores linha e coluna quando existe interacção.



Exemplo 13.11

Na Tabela 13.10 apresenta-se a tabela ANOVA correspondente ao Exemplo 13.9. Note-se que, neste caso, o factor linha corresponde ao condutor (X, Y ou Z), e o factor coluna corresponde ao trajecto (estrada ou cidade).

O teste relativo à interacção entre os factores conduz ao seguinte resultado:

$$ET = \frac{DQMDFC}{DQMR} = \frac{4.220}{1.138} = 3.708 > F_{2,18}(\alpha = 0.05) = 3.55,$$

pelo que a hipótese nula $H_0: \gamma_{ij} = 0$ é rejeitada ao nível de significância de 5% (com um valor de prova de 4.5%).

Uma vez que se verificou haver interacção significativa entre os factores, é necessário analisar a sua influência e verificar se, face a ela, fará sentido testar o significado dos factores linha e coluna. Na Figura 13.6 representam-se graficamente as estimativas $\hat{\mu}_{ij}$ em função do factor linha e do factor coluna (esta figura foi construída com base nos valores da Tabela 13.8).

Neste caso, apesar de a interacção ser considerável, nota-se que

- (i) o consumo aumenta sempre da estrada para a cidade e que
- (ii) o condutor X consegue melhores consumos do que os outros dois, tanto em estrada como na cidade.

Faz assim sentido verificar se as diferenças registadas são significativas do ponto de vista estatístico ou se, pelo contrário, resultam de variações aleatórias.

O teste que permite verificar se os efeitos α_i são significativamente diferentes de zero conduz ao seguinte resultado


$$ET = \frac{DQMDFL}{DQMR} = \frac{13.247}{1.138} = 11.64 > F_{2,18}(\alpha = 0.05) = 3.55,$$

pelo que a hipótese nula $H_0: \alpha_i = 0$ é rejeitada ao nível de significância de 5% (com um valor de prova muito baixo).

Tabela 13.10
Tabela ANOVA para
o Exemplo 13.9.

Fontes de variação	Variações	Graus de liberdade	Desvios quadráticos médios
Factor Linha (FL)	26.494	2	13.247
Factor Coluna (FC)	24.000	1	24.000
Interacção (I)	8.440	2	4.220
Residual (R)	20.480	18	1.138
TOTAL (T)	79.414	23	

Figura 13.6
Estimativas de μ_{ij}
(Exemplo 13.9).



Por sua vez, o cálculo da estatística do teste ANOVA aos efeitos β_j conduz a

$$ET = \frac{DQMDFC}{DQMR} = \frac{24.000}{1.138} = 21.09 > F_{1,18}(\alpha = 0.05) = 4.41,$$

pelo que a hipótese nula $H_0: \beta_j = 0$ é rejeitada ao nível de significância de 5% (com um valor de prova muito baixo).

Os resultados obtidos podem ser globalmente interpretados da seguinte maneira:

- (i) À cidade associa-se um aumento significativo de consumo relativamente à estrada. Esse aumento (que, em média, se estima em $\bar{x}_{.2} - \bar{x}_{.1} = 10.53 - 8.53 = 2$ litros/100 km) depende do tipo de condutor e do seu comportamento em estrada ou em cidade.
- (ii) Os consumos parecem sugerir os seguintes tipos de comportamento dos diferentes jornalistas:

X — «pé leve», com uma condução calma e, consequentemente, consumos baixos tanto na estrada como na cidade;

Y — «pé pesado», com um consumo elevado na cidade e um consumo moderado em estrada (provavelmente como resultado de uma condução a baixa velocidade);

Z — «Fangio», com um consumo moderado na cidade (provavelmente por não poder acelerar) e um consumo elevado em estrada (provavelmente como resultado de uma condução a alta velocidade).

Até agora considerou-se a situação na qual o teste ANOVA relativo à interacção revela que esta é significativa do ponto de vista estatístico. Passemos agora a considerar uma situação na qual, por um lado, seja razoável admitir que a interacção é nula e, por outro, o correspondente teste ANOVA não o desminta. Neste caso, os desvios $DQMR$ e $DQMDFL$ são ambos estimadores independentes da mesma variância σ^2 (ver última coluna da Tabela 13.9). A partir deles, pode ser obtido um novo estimador de σ^2 ,

$$\hat{\sigma}^2 = \frac{GL_3 \cdot DQMDFL + GL_4 \cdot DQMR}{GL_3 + GL_4},$$

com $GL_3 + GL_4$ graus de liberdade.

Este estimador pode ser usado, em vez de $DQMR$, como denominador das estatísticas dos testes ANOVA relativos ao factor linha e ao factor coluna:

- Factor linha: H_0 verdadeira $\Rightarrow ET = \frac{DQMDFL}{\hat{\sigma}^2} \sim F_{GL_1, GL_3+GL_4}$

- Factor coluna: H_0 verdadeira $\Rightarrow ET = \frac{DQMDFC}{\hat{\sigma}^2} \sim F_{GL_2, GL_3+GL_4}$

O recurso às novas estatísticas confere maior potência a estes testes ANOVA, como resultado do aumento do número de graus de liberdade do denominador.

Considere-se agora a definição de intervalos de confiança para as diferenças entre os valores esperados das células, linhas ou colunas diferentes. Para a situação considerada — na qual as amostras são equilibradas — pode recorrer-se ao método de Tukey. Os limites dos intervalos de confiança para as diferenças entre os valores esperados de duas quaisquer células, $\mu_{i_1j_1} - \mu_{i_2j_2}$ a $(1 - \alpha) \cdot 100\%$ vêm definidos por:

$$(\bar{x}_{i_1j_1} - \bar{x}_{i_2j_2}) \pm q_{I,J,GL_4}(\alpha) \cdot \sqrt{DQMR / K}, \quad (13.18)$$

onde

I : número de linhas
 J : número de colunas
 K : número de observações por célula

$$DQMR: \sum_i \sum_j \sum_k (X_{ijk} - \bar{X}_{ij})^2 / GL_4$$

$$GL_4: I \cdot J \cdot (K - 1)$$

$q_{I, J, GL_4}(\alpha)$: factor definido na Tabela 16 do Anexo «Tabelas».

Exemplo 13.12

Para a situação contemplada no Exemplo 13.9, calcule-se a amplitude dos intervalos de confiança a 95% para as diferenças $\mu_{i1} - \mu_{i2}$.

Para $I = 3, J = 2, K = 4, GL_4 = 3 \cdot 2 \cdot 3 = 18, q_{6, 18}(\alpha = 0.05) = 4.49$ e $DQMR = 1.138$, a amplitude dos intervalos de confiança vem

$$2 \cdot 4.49 \cdot \sqrt{1.138 / 4} = 4.79.$$

Ainda segundo o método de Tukey, os limites dos intervalos de confiança de $\mu_{i1} - \mu_{i2}$ ou de $\mu_{j1} - \mu_{j2}$ a $(1 - \alpha) \cdot 100\%$ são os seguintes:

(i) $\mu_{i1} - \mu_{i2}$ (diferenças entre valores esperados de linhas):

$$(\bar{X}_{i\cdot} - \bar{X}_{i\cdot}) \pm q_{I, GL_4}(\alpha) \cdot \sqrt{DQMR / J \cdot K} \quad (13.19)$$

(ii) $\mu_{j1} - \mu_{j2}$ (diferenças entre valores esperados de colunas):

$$(\bar{X}_{\cdot j_1} - \bar{X}_{\cdot j_2}) \pm q_{J, GL_4}(\alpha) \cdot \sqrt{DQMR / I \cdot K} \quad (13.20)$$

onde os símbolos têm o mesmo significado que anteriormente lhes foi atribuído.

Exemplo 13.13

Recorrendo de novo ao Exemplo 13.9, calcule-se a amplitude dos intervalos de confiança a 95% para as diferenças $\mu_{j1} - \mu_{j2}$.

Para $I = 3, J = 2, K = 4, GL_4 = 3 \cdot 2 \cdot 3 = 18, q_{2, 18}(\alpha = 0.05) = 2.97$ e $DQMR = 1.138$, a amplitude dos intervalos de confiança vem

$$2 \cdot 2.97 \cdot \sqrt{1.138 / 12} = 1.83.$$

13.3.3 MODELO DE EFEITOS VARIÁVEIS COM DUAS OU MAIS OBSERVAÇÕES POR CÉLULA

O modelo com dois factores de efeitos variáveis (no qual ambos os factores se consideram variáveis) é definido por

$$\begin{aligned} X_{ijk} &= \underbrace{M_{ij}}_{\text{v. esperado variável da célula}} + \underbrace{E_{ijk}}_{\text{erro}} = \\ &= \underbrace{\mu}_{\text{v. esperado da célula}} + \underbrace{A_i}_{\text{ef. variável do 1.º factor (linha)}} + \underbrace{B_j}_{\text{ef. variável do 2.º factor (coluna)}} + \underbrace{C_{ij}}_{\text{interacção variável}} + \underbrace{E_{ijk}}_{\text{erro}}. \end{aligned} \quad (13.21)$$

onde se admite que

$$A_i \sim IN(0, \sigma_A^2) \quad C_{ij} \sim IN(0, \sigma_C^2)$$

$$B_j \sim IN(0, \sigma_B^2) \quad E_{ijk} \sim IN(0, \sigma^2)$$

e ainda que as variáveis $A_i, B_j, C_{ij}, (i_1 = 1, \dots, I; j_1 = 1, \dots, J)$ e $E_{i_1 j_2 k}$ ($i_2 = 1, \dots, I; j_2 = 1, \dots, J$) são mutuamente independentes.

Na Tabela 13.11 apresenta-se a tabela ANOVA referente a este modelo. Note-se que a única diferença entre esta tabela e a Tabela 13.9 (dois factores efeitos fixos) reside nos valores esperados dos desvios quadráticos médios.

Estimativas não-enviesadas das variâncias $\sigma^2, \sigma_A^2, \sigma_B^2, \sigma_C^2$ podem ser obtidas a partir das expressões dos valores esperados que figuram na última coluna da Tabela (ANOVA) 13.11:

$$\hat{\sigma}^2 = DQMR$$

$$\hat{\sigma}_C^2 = \frac{1}{K} \cdot (DQMDI - DQMR)$$

$$\hat{\sigma}_A^2 = \frac{1}{K \cdot J} \cdot (DQMDFL - DQMI)$$

$$\hat{\sigma}_B^2 = \frac{1}{K \cdot I} \cdot (DQMDFC - DQMDI).$$

Para testar se estas variâncias são significativamente diferentes de zero, deve adoptar-se o procedimento que se apresenta em seguida.

(i) Testar se é significativa a variância da interacção, recorrendo ao teste ANOVA com a seguinte estrutura:

$$H_0: \sigma_C^2 = 0$$

$$H_1: \sigma_C^2 > 0$$

$$ET = \frac{DQMDI}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_2, GL_4}$$

(ii) Se a hipótese nula do teste anterior for rejeitada, isto é, se se admitir que $\sigma_C^2 > 0$, testar se são significativamente diferentes de zero as variâncias dos factores linha e coluna recorrendo aos seguintes testes ANOVA:

$$H_0: \sigma_A^2 = 0$$

$$H_1: \sigma_A^2 > 0$$

$$ET = \frac{DQMDFL}{DQMDI}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_1, GL_3}$$

Tabela 13.11. Tabela ANOVA para o modelo com dois factores de efeitos variáveis com interacção.

Fontes de variação	Variações (Somadas de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Factor linha (FL)	$VDFL$ $= K \cdot J \cdot \sum_i (\bar{X}_{i.} - \bar{X}_{..})^2$	$GL_1 = I - 1$	$DQMDFL = VDFL / GL_1$	$E(DQMDFL)$ $= \sigma^2 + K \cdot \sigma_c^2 + K \cdot J \cdot \sigma_a^2$
Factor coluna (FC)	$VDFC$ $= K \cdot I \cdot \sum_j (\bar{X}_{.j} - \bar{X}_{..})^2$	$GL_2 = J - 1$	$DQMDFC = VDFC / GL_2$	$E(DQMDFC)$ $= \sigma^2 + K \cdot \sigma_c^2 + K \cdot I \cdot \sigma_b^2$
Interação (I)	VDI $= K \cdot \sum_i \sum_j (\bar{X}_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2$	$GL_3 = (I - 1) \cdot (J - 1)$	$DQMDI = VDI / GL_3$	$E(DQMDI) = \sigma^2 + K + \sigma_c^2$
Residual (Dentro das células) (R)	$VR = \sum_i \sum_j \sum_k (X_{ijk} - \bar{X}_{ij})^2$	$GL_4 = I \cdot J \cdot (K - 1)$	$DQMR = VR / GL_4$	$E(DQMR) = \sigma^2$
Total (T)	$VT = \sum_i \sum_j \sum_k (X_{ijk} - \bar{X}_{..})^2$	$GL = GL_1 + GL_2 + GL_3 + GL_4$ $= I \cdot J \cdot K - 1$		

e

$$H_0: \sigma_b^2 = 0$$

$$H_1: \sigma_b^2 > 0$$

$$ET = \frac{DQMDFC}{DQMDI}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_2, GL_3}$$

(iii) Se se admitir que $\sigma_c^2 = 0$ e esta hipótese não for rejeitada no teste inicial relativo à interacção, então $E(DQMDI) = \sigma^2$ e também $E(DQMR) = \sigma^2$. Neste caso, pode obter-se um melhor estimador de σ^2 juntando estes dois desvios quadráticos médios:

$$\sum^2 = \frac{GL_3 \cdot DQMDI + GL_4 \cdot DQMR}{GL_3 + GL_4}$$

Nestas condições, os testes ANOVA que permitem verificar se são significativos os factores linha e coluna têm uma nova estatística de teste:

$$H_0: \sigma_a^2 = 0$$

$$H_1: \sigma_a^2 > 0$$

$$ET = \frac{DQMDFL}{\sum^2}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_1, GL_3 + GL_4}$$

e

$$H_0: \sigma_b^2 = 0$$

$$H_1: \sigma_b^2 > 0$$

$$ET = \frac{DQMDFC}{\sum^2}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_2, GL_3 + GL_4}$$

13.3.4 MODELOS DE EFEITOS FIXOS E EFEITOS VARIÁVEIS COM UMA OBSERVAÇÃO POR CÉLULA

Nos modelos com dois factores definidos anteriormente, a variação residual foi estimada a partir da variação dentro das células, através da expressão

$$VR = \sum_i \sum_j \sum_k (X_{ijk} - \bar{X}_{ij})^2$$

No caso de só se dispor de uma observação por célula, tal estimativa não faz sentido. No entanto, se se admitir que o modelo é aditivo (isto é, se se considerar que não há interacção entre os factores), ainda se pode utilizar a técnica de análise de variância. De facto, tratando-se de efeitos fixos, o modelo é semelhante ao definido na expressão 13.9, ou seja:

$$\begin{aligned}
 X_{ij} &= \underbrace{\mu_{ij}}_{\text{v. esperado da célula}} + \underbrace{E_{ij}}_{\text{erro}} \\
 &= \underbrace{\mu}_{\text{parâmetro global}} + \underbrace{\alpha_i}_{\text{efeito do 1.º factor (linha)}} + \underbrace{\beta_j}_{\text{efeito do 2.º factor (coluna)}} + \underbrace{E_{ij}}_{\text{erro}}
 \end{aligned} \quad (13.22)$$

Tratando-se de efeitos variáveis, o modelo com dois factores e com uma observação por célula vem:

$$X_{ij} = \underbrace{M_{ij}}_{\substack{\text{v. esperado variável} \\ \text{da célula}}} + \underbrace{E_{ij}}_{\text{erro}} \\ = \underbrace{\mu}_{\substack{\text{parâmetro} \\ \text{global}}} + \underbrace{A_i}_{\substack{\text{ef. variável} \\ \text{do 1.º factor} \\ \text{(linha)}}} + \underbrace{B_j}_{\substack{\text{ef. variável} \\ \text{do 1.º factor} \\ \text{(coluna)}}} + \underbrace{E_{ij}}_{\text{erro}} \quad (13.23)$$

As tabelas ANOVA para estes modelos (efeitos fixos e efeitos variáveis) apresentam-se nas Tabelas 13.12 e 13.13, respectivamente. Note-se que em ambos os casos a variação residual é estimada por

$$VR = \sum_i \sum_j (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2.$$

Os resultados que é possível obter a partir destas tabelas serão ilustrados considerando apenas o modelo de efeitos fixos. Para este modelo, os testes ANOVA que permitem verificar se os factores linha e coluna induzem efeitos significativos têm a seguinte estrutura:

$$H_0: \alpha_i = 0 \quad (\text{para todo o } i)$$

$$H_1: \text{Algum } \alpha_i \neq 0$$

$$ET = \frac{DQMDFL}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_1, GL_3}$$

$$H_0: \beta_j = 0 \quad (\text{para todo o } j)$$

$$H_1: \text{Algum } \beta_j \neq 0$$

$$ET = \frac{DQMDFC}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{GL_2, GL_3}$$

Exemplo 13.14

Foram experimentadas cinco matérias-primas (1, 2, 3, 4 e 5) em três máquinas (A, B e C) no fabrico de um determinado componente para sapatos. Em cada máquina foi produzido um componente utilizando cada uma das matérias-primas. Ensaiou-se a longevidade desses componentes com os resultados que se apresentam na Tabela 13.14.

Coloca-se a questão de saber se a longevidade dos componentes é influenciada pelo tipo de máquina e pelas matérias-primas. Admite-se que não há interacção entre o factor máquina e o factor matéria-prima.

Tabela 13.14
Resultados de um
teste de longevidade
(Exemplo 13.14).

Máquina	Matéria-prima					$\bar{X}_{.j}$
	1	2	3	4	5	
A	56.7	45.7	48.3	54.6	37.7	48.6
B	64.5	53.4	54.3	57.5	52.3	56.4
C	56.7	50.6	49.5	56.5	44.7	51.6
$\bar{X}_{.j}$	59.3	49.9	50.7	56.2	44.9	$\bar{X}_{..} = 52.2$

Tabela 13.12. Tabela ANOVA para o modelo aditivo com dois factores de efeitos fixos (uma observação por célula).

Fontes de variação	Variações (Somar de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Factor linha (FL)	$VDFL = J \cdot \sum_i (\bar{X}_{i.} - \bar{X}_{..})^2$	$GL_1 = I - 1$	$DQMDFL = VDFL/GL_1$	$E(DQMDFL) = \sigma^2 + \frac{J}{I-1} \cdot \sum_i \alpha_i^2$
Factor coluna (FC)	$VDFC = I \cdot \sum_j (\bar{X}_{.j} - \bar{X}_{..})^2$	$GL_2 = J - 1$	$DQMDFC = VDFC/GL_2$	$E(DQMDFC) = \sigma^2 + \frac{I}{J-1} \cdot \sum_j \beta_j^2$
Residual (Dentro das células) (R)	$VR = \sum_i \sum_j (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2$	$GL_3 = (I-1) \cdot (J-1)$	$DQMR = VR/GL_3$	$E(DQMR) = \sigma^2$
Total (T)	$VT = \sum_i \sum_j (X_{ij} - \bar{X}_{..})^2$	$GL = GL_1 + GL_2 + GL_3 = I \cdot J - 1$		

Tabela 13.13. Tabela ANOVA para o modelo aditivo com dois factores de efeitos variáveis (uma observação por célula).

Fontes de variação	Variáveis (Somas de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Factor linha (FL)	$VDFL = J \cdot \sum_i (\bar{X}_{i.} - \bar{X}_{..})^2$	$GL_1 = I - 1$	$DQMDFL = VDFL / GL_1$	$E[DQMDFL] = \sigma^2 + J \cdot \sigma_A^2$
Factor coluna (FC)	$VDFC = I \cdot \sum_j (\bar{X}_{.j} - \bar{X}_{..})^2$	$GL_2 = J - 1$	$DQMDFC = VDFC / GL_2$	$E[DQMDFC] = \sigma^2 + I \cdot \sigma_B^2$
Residual (Dentro das células) (R)	$VR = \sum_{i,j} (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2$	$GL_3 = (I - 1) \cdot (J - 1)$	$DQMR = VR / GL_3$	$E[DQMR] = \sigma^2$
Total (T)	$VT = \sum_{i,j} (X_{ij} - \bar{X}_{..})^2$	$GL = GL_1 + GL_2 + GL_3 = I \cdot J - 1$		

Tabela 13.15
Tabela ANOVA
relativa ao Exemplo
13.14.

Fontes de variação	Variações	Graus de liberdade	Desvios quadráticos médios
Factor Linha (FL)	154.8	2	77.4
Factor Coluna (FC)	381.7	4	95.4
Residual (R)	47.3	8	5.9
TOTAL (T)	583.8	14	

Na Tabela 13.5 apresenta-se a correspondente tabela ANOVA (modelo com dois factores aditivos de efeitos fixos).

Como

$$ET = \frac{DQMDFL}{DQMR} = \frac{77.4}{5.9} = 13.1 > F_{2,8}(\alpha = 0.05) = 4.46,$$

a hipótese nula de que o factor máquina (factor linha) não tem efeito sobre a longevidade é rejeitada ao nível de significância de 5%.

O teste relativo ao factor matéria-prima (factor coluna) conduz ao seguinte resultado:

$$ET = \frac{DQMDFC}{DQMR} = \frac{95.4}{5.9} = 16.17 > F_{4,8}(\alpha = 0.05) = 3.84,$$

pelo que a hipótese nula correspondente é também rejeitada ao nível de significância de 5%.

Os limites dos intervalos de confiança a $(1 - \alpha) \cdot 100\%$ (obtidos pelo método de Tukey) para as diferenças entre os valores esperados entre linhas ou colunas são calculados usando expressões semelhantes às 13.19 e 13.20:

(i) $\mu_{i.} - \mu_{i'.$ (diferenças entre linhas):

$$(\bar{X}_{i.} - \bar{X}_{i'.}) \pm q_{I, GL_1}(\alpha) \cdot \sqrt{DQMR / J} \quad (13.24)$$

(ii) $\mu_{.j} - \mu_{.j'}$ (diferenças entre colunas):

$$(\bar{X}_{.j} - \bar{X}_{.j'}) \pm q_{J, GL_2}(\alpha) \cdot \sqrt{DQMR / I}. \quad (13.25)$$

Exemplo 13.15

Voltando ao Exemplo 13.14, calcule-se a amplitude dos intervalos de confiança a 95% para as diferenças entre os valores esperados das matérias-primas.

Tal amplitude é dada por

$$2 \cdot q_{I, GL_1}(\alpha) \cdot \sqrt{DQMR / J} = 2 \cdot q_{5,8}(0.05) \cdot \sqrt{5.9 / 3} = 2 \cdot 4.89 \cdot 1.40 = 13.7.$$

13.4 IMPLICAÇÕES DA NÃO SATISFAÇÃO DAS CONDIÇÕES IMPOSTAS AOS ERROS

Tal como foi atrás referido, a análise de variância tem a sua aplicação restringida, pelo menos em teoria, aos casos em que sejam satisfeitas as seguintes três condições relativas aos erros:

- Normalidade da sua distribuição
- homogeneidade da sua variância (σ^2 constante)
- independência mútua.

A primeira das condições — necessária para a realização de testes e para a especificação de intervalos de confiança — é, porventura, a menos crítica. De facto, os testes e os intervalos de confiança incidem sobre médias ou diferenças entre médias. A menos que

as amostras sejam de pequenas dimensões e a distribuição dos erros seja francamente assimétrica, o teorema do limite central acaba por garantir que os intervalos de confiança anteriormente definidos e as distribuições admitidas para as estatísticas de teste são razoáveis aproximações da realidade. Recorde-se que, para verificar a Normalidade dos erros, se pode recorrer aos testes de qualidade de ajuste referidos no Capítulo 12. Se a hipótese de Normalidade for rejeitada e se se estiver a lidar com amostras de pequenas dimensões, existe um teste não paramétrico alternativo ao teste ANOVA para verificar se existem diferenças significativas entre os valores médios de vários grupos de dados. Trata-se do teste de Kruskal-Wallis (que se apresenta a seguir na Secção 13.4.1), que não envolve qualquer hipótese relativa à forma da distribuição dos erros.

A segunda condição de aplicabilidade da técnica de análise da variância é a da homogeneidade da variância dos erros. Os erros associados às observações incluídas num grupo ou numa célula devem ter a mesma variância que os erros das observações incluídas noutro grupo ou noutra célula qualquer. Na prática, a homogeneidade da variância só se torna importante quando as dimensões das amostras (grupos ou células) forem muito diferentes, isto é, quando a maior amostra tiver uma dimensão pelo menos dupla da dimensão da menor amostra. Quando as amostras não são fortemente desequilibradas, o efeito da heterogeneidade da variância, mesmo se acentuada, é pouco significativo.

Se se admitir que os erros têm uma distribuição Normal, a homogeneidade da sua variância pode ser verificada recorrendo ao teste de Bartlett, que será tratado na Secção 13.4.2.

Caso os dados sugiram que a variância dos erros depende de forma mais ou menos sistemática do valor médio das observações, pode conseguir-se uma homogeneização da variância dos erros, recorrendo a transformações dos dados originais. A título de exemplo, sugerem-se em seguida algumas transformações:

- S^2 proporcional a $\bar{X}_i$: $Z_{ij} = \sqrt{\bar{X}_{ij}}$.
- S^2 proporcional a $\bar{X}_i^2$: $Z_{ij} = \ln \bar{X}_{ij}$.
- S^2 proporcional a $\bar{X}_i^4$: $Z_{ij} = 1 / \bar{X}_{ij}$.

A terceira e última condição de aplicabilidade da análise da variância é a da independência dos erros. A violação desta condição pode causar muitos problemas na aplicação da técnica.

Registe-se que, quando os dados são recolhidos convenientemente num determinado momento (ou, na prática, ao longo de um intervalo de tempo curto), a independência das observações e, portanto, dos erros é frequentemente assegurada. Se, pelo contrário, os dados são recolhidos a partir de registos ou de medições repetidas no decurso de um intervalo de tempo significativo, há a possibilidade de ser introduzida uma dependência estatística entre cada erro e aqueles que o precedem e lhe sucedem, através de um qualquer factor associado ao tempo.

13.4.1 TESTE DE KRUSKAL-WALLIS

Considere-se a seguinte notação:

- I : número total de grupos de observações
- i : índice relativo a cada grupo ($i = 1, 2, \dots, I$)
- J_i : dimensão do grupo i
- J : número total de observações ($J = \sum_i J_i$)
- j : índice relativo a cada observação dentro de cada grupo ($j = 1, 2, \dots, J_i$).

Para realizar o teste de Kruskal-Wallis é necessário combinar a totalidade das J observações e ordená-las, da mais baixa para a mais elevada. No caso de duas ou mais observações serem iguais, atribui-se-lhes um número de ordem correspondente à média aritmética dos

números de ordem que tais observações receberiam se não fossem, de facto, iguais. Em seguida, define-se para cada grupo i o valor T_i , que corresponde à soma dos números de ordem das observações contidas nesse grupo.

Formalmente, a hipótese nula deste teste é a de que as distribuições dos dados contidos nos diferentes grupos são idênticas. O teste não é particularmente afectado por diferenças na variabilidade de grupo para grupo, pelo que, na prática, a hipótese nula se converte efectivamente na igualdade dos valores esperados das distribuições. Nestas condições, a estrutura do teste de Kruskal-Wallis é a seguinte:

H_0 : As distribuições dos diferentes grupos são idênticas
(ou, mais simplesmente, as populações dos diferentes grupos têm valores esperados idênticos)

H_1 : As distribuições dos grupos diferem em localização

$$ET = \frac{12}{J \cdot (J+1)} \cdot \sum_i \frac{T_i^2}{J_i} - 3 \cdot (J+1)$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim \chi^2_{I-1}$$

(registre-se que este teste é unilateral à direita)

Exemplo 13.16

Aplique-se o teste de Kruskal-Wallis ao Exemplo 13.1.

A ordenação das observações conduz ao resultado que se apresenta na Tabela 13.16.

A partir dos valores incluídos nesta tabela, é fácil calcular as estatísticas T_i :

$$T_1 (A): 1 + 2.5 + 4 + 10.0 + 16 = 33.5$$

$$T_2 (B): 8 + 10.0 + 13 + 14.5 + 18.5 + 21 = 85.0$$

$$T_3 (C): 2.5 + 5.5 + 5.5 + 7 + 12 + 20 = 52.5$$

$$T_4 (D): 10.0 + 14.5 + 17 + 18.5 + 22 = 82.0$$

Entrando com estes valores no cálculo da estatística de teste, vem:

$$ET = \frac{12}{22 \cdot 23} \cdot \left(\frac{33.5^2}{5} + \frac{85^2}{6} + \frac{52.5^2}{6} + \frac{82^2}{5} \right) - 3 \cdot 23 = 7.7.$$

Como $\chi^2_3 (\alpha = 0.05) = 7.81$ (ver Tabela 4 do Anexo «Tabelas»), resulta

$$ET < \chi^2_3 (\alpha = 0.05),$$

pelo que a hipótese nula não pode ser rejeitada ao nível de significância de 5%.

Tabela 13.16
Ordenação das observações do Exemplo 13.1.

Observação	Grupo	Número de ordem	Observação	Grupo	Número de ordem
0.8	A	1	2.0	C	12.0
1.0	A	2.5	2.2	B	13.0
1.0	C	2.5	2.5	B	14.5
1.1	A	4	2.5	D	14.5
1.3	C	5.5	2.7	A	16.0
1.3	C	5.5	2.8	D	17.0
1.4	C	7	3.0	B	18.5
1.7	B	8	3.0	D	18.5
1.9	A	10	3.2	C	20.0
1.9	B	10	3.7	B	21.0
1.9	D	10	3.8	D	22.0

Note-se que, enquanto o resultado do teste que acaba de se apresentar é inconclusivo, o teste ANOVA realizado no Exemplo 13.1 tinha conduzido à rejeição da mesma hipótese nula. Este resultado não é surpreendente, já que é de esperar que, quando se verificarem as condições nas quais se fundamenta o teste ANOVA, ele seja mais potente do que o teste de Kruskal-Wallis.

13.4.2 TESTE DE BARTLETT

Tal como já foi indicado, este teste de homogeneidade da variância só é válido quando os erros seguem distribuições Normais. De facto, o teste depende criticamente da verificação desta condição, sendo muito sensível a desvios da Normalidade.

Adopte-se a seguinte notação:

I : número de amostras distintas obtidas a partir de populações Normais

i : índice relativo a cada amostra ($i = 1, 2, \dots, I$)

J_i : dimensão da amostra i

GL_i : $J_i - 1$

X_{ij} : j -ésima observação na i -ésima amostra

$\bar{X}_i$: média amostral das observações incluída na amostra i

$$S_i^2: \frac{1}{GL_i} \sum_j (X_{ij} - \bar{X}_i)^2$$

$$GL: \sum_i GL_i$$

$$S^2: \frac{1}{GL} \sum_i GL_i \cdot S_i^2$$

O teste de Bartlett é aplicável quando as diferentes amostras envolvidas tenham dimensões não inferiores a 4 (isto é, quando $J_i \geq 4$, para todo o i). A estrutura do teste é a seguinte:

$$H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_I^2$$

$$H_1: \text{Os } \sigma_i^2 \text{ não são todos iguais}$$

$$ET = \frac{1}{C} \left[GL \cdot \ln(S^2) - \sum_i GL_i \cdot \ln(S_i^2) \right]$$

$$\text{com } C = 1 + \left\{ \frac{1}{3} \cdot (I - 1) \right\} \cdot \left[\left(\sum_{i=1}^I 1/GL_i \right) - 1/GL \right]$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim \chi_{I-1}^2$$

(registre-se que este teste é unilateral à direita)

Exemplo 13.17

Recorrendo ao teste de Bartlett, verifique-se se os erros referentes ao Exemplo 13.1 têm variância homogênea.

Na Tabela 13.17 apresentam-se alguns dos cálculos intermédios.

Instituto	i	GL_i	$\bar{X}_i$	s_i^2
A	1	4	1.5	0.625
B	2	5	2.5	0.556
C	3	5	1.7	0.648
D	4	4	2.8	0.485
		$GL = 18$		$s^2 = 0.581$

Tabela 13.17
Teste de Bartlett.
Cálculos referentes
ao Exemplo 13.1.

Assim,

$$C = 1 + \frac{1}{3 \cdot (4 - 1)} \cdot \left(\frac{1}{4} + \frac{1}{5} + \frac{1}{5} + \frac{1}{4} - \frac{1}{18} \right) = 1.094,$$

donde

$$ET = \frac{1}{1.094} \cdot [18 \cdot \ln(0.581) - 4 \cdot \ln(0.625) - 5 \cdot \ln(0.556) - 5 \cdot \ln(0.648) - 4 \cdot \ln(0.485)] = 0.0956.$$

Como $\chi_3^2(\alpha = 0.05) = 7.81$ (ver Tabela 4 do Anexo «Tabelas»), resulta

$$ET < \chi_3^2(\alpha = 0.05),$$

não se podendo rejeitar (ao nível de significância de 5%) a hipótese nula da homogeneidade da variância dos erros.

13.5 COMENTÁRIO SOBRE A APLICAÇÃO DA ANÁLISE DE VARIÂNCIA À RESOLUÇÃO DE PROBLEMAS COMPLEXOS

Ao conceber uma experiência que se destine a pôr em evidência os factores que afectam, por exemplo, a eficiência de um processo ou a receptividade de um produto no mercado, coloca-se frequentemente uma dificuldade: o elevado número de factores que potencialmente afectam a resposta.


Considere-se, por exemplo, a aceitação de um novo sabonete no mercado. Inúmeros factores podem afectar potencialmente a resposta dos consumidores: o poder de lavagem, a forma, a cor, a embalagem, a marca, o preço, etc. Seria completamente inviável pretender analisar o impacto destes factores conduzindo uma análise de variância multifactor que fosse uma mera extensão das que foram anteriormente apresentadas (com um e dois factores).

De facto, se se isolassem, por exemplo, cinco factores, sendo definidos cinco níveis para três deles e quatro níveis para os dois restantes, haveria que considerar $5 \cdot 5 \cdot 5 \cdot 4 \cdot 4 = 2000$ combinações dos diferentes factores. Se, para se obter uma ideia da variação envolvida em cada experiência, se recolhessem três observações por cada combinação, no total haveria que recolher 6000 observações!

Para além do problema da dimensão, a análise de variância multifactor coloca graves dificuldades de interpretação. Antes de se efectuarem testes relativos aos efeitos principais (α , β , etc.), há que testar as interações, considerando os factores dois a dois, três a três, etc. A interpretação das interações de ordem superior a dois é, em geral, muito complicada.

Na tentativa de contornar estas dificuldades, desenvolveu-se um conjunto de métodos que, globalmente, constituem a teoria de concepção de experiências (na linguagem anglo-saxónica, *theory of experimental design*). Em geral, nestes métodos parte-se do princípio que não existem interações de ordem superior a dois ou a três e procura apenas estimar-se os efeitos relativos aos factores principais e a algumas das interações entre eles. O sucesso da aplicação destes métodos assenta no facto de, admitidas certas hipóteses simplificadoras, se poder obter uma notável quantidade de informação a partir de um conjunto relativamente limitado de dados bem seleccionados.





■ APÊNDICE 13.1 ESTIMAÇÃO DOS PARÂMETROS DO MODELO ANOVA COM UM FACTOR DE EFEITOS FIXOS RECORRENDO AO MÉTODO DOS MÍNIMOS QUADRADOS

- (1) O modelo ANOVA apresentado na expressão 13.1 contempla duas versões equivalentes, a primeira das quais se traduz por

$$X_{ij} = \mu_i + E_{ij}.$$

Os parâmetros μ_i ($i = 1, \dots, I$) podem ser estimados minimizando o somatório

$$SEQ = \sum_{i=1}^I \sum_{j=1}^{J_i} E_{ij}^2 = \sum_{i=1}^I \sum_{j=1}^{J_i} (X_{ij} - \mu_i)^2.$$

As estimativas *MQ* daqueles parâmetros podem ser obtidos resolvendo as equações

$$\frac{\partial SEQ}{\partial \mu_i} = (-2) \cdot \sum_{j=1}^{J_i} (x_{ij} - \mu_i) = 0 \quad (i = 1, \dots, I)$$

Destas relações obtém-se

$$J_i \cdot \mu_i = \sum_{j=1}^{J_i} x_{ij} \quad (i = 1, \dots, I)$$

ou, finalmente

$$\hat{\mu}_i = \frac{1}{J_i} \cdot \sum_{j=1}^{J_i} x_{ij} = \bar{x}_i \quad (i = 1, \dots, I)$$

onde $\bar{x}_i$ ($i = 1, \dots, I$) representam as médias das observações contidas em cada um dos diferentes grupos.

- (2) A segunda versão do modelo ANOVA apresentada na expressão 13.1 corresponde a

$$X_{ij} = \mu + \alpha_i + E_{ij}.$$

Os parâmetros μ e α_i ($i = 1, \dots, I$) podem ser estimados minimizando o somatório

$$SEQ = \sum_{i=1}^I \sum_{j=1}^{J_i} E_{ij}^2 = \sum_{i=1}^I \sum_{j=1}^{J_i} (X_{ij} - \mu - \alpha_i)^2.$$

Para se obterem estimativas MQ de tais parâmetros considere-se a equação

$$\frac{\partial SEQ}{\partial \mu} = (-2) \cdot \sum_{i=1}^I \sum_{j=1}^{J_i} (x_{ij} - \mu - \alpha_i) = 0.$$

Desta equação resulta

$$\sum_{i=1}^I \sum_{j=1}^{J_i} x_{ij} = \mu \cdot \sum_{i=1}^I J_i + \alpha_i \cdot \sum_{i=1}^I J_i. \quad (A13.1.1)$$

Por outro lado, das equações

$$\frac{\partial SEQ}{\partial \alpha_i} = (-2) \cdot \sum_{j=1}^{J_i} (x_{ij} - \mu - \alpha_i) = 0 \quad (i = 1, \dots, I)$$

obtem-se

$$\sum_{j=1}^{J_i} x_{ij} = \mu \cdot J_i + \alpha_i \cdot J_i \quad (i = 1, \dots, I). \quad (A13.1.2)$$

É óbvio que a equação A13.1.1 é igual à soma das equações A13.1.2. Não existe portanto uma solução única para o sistema de equações. Habitualmente acrescenta-se às equações A13.1.2 a seguinte restrição adicional:

$$\sum_{i=1}^I J_i \cdot \alpha_i = 0.$$

Esta restrição tem uma interpretação particularmente simples quando as observações incluídas nos diferentes grupos são em número idêntico (isto é, quando $J_1 = J_2 = \dots = J_I$). Neste caso, a restrição equivale a impor que o valor médio dos efeitos é nulo:

$$\bar{\alpha} = \frac{1}{I} \cdot \sum_{i=1}^I \alpha_i = 0.$$

Nestas condições, a solução do sistema de equações vem:

$$\begin{aligned} \hat{\mu} &= \bar{x} = \frac{1}{I} \cdot \sum_{i=1}^I \sum_{j=1}^{J_i} x_{ij} \\ \hat{\alpha}_i &= \bar{x}_i - \bar{x} \quad (i = 1, \dots, I) \end{aligned}$$

onde $\bar{x}$ representa a média de todas as observações e $\bar{x}_i$ ($i = 1, \dots, I$) têm o significado que anteriormente lhes foi atribuído.

A aparente arbitrariedade que envolve a adição da restrição suplementar não tem qualquer consequência prática, pois, na realidade, o que interessa são as diferenças entre os efeitos α_i e não os seus valores.

APÊNDICE 13.2 MODELO ANOVA COM UM FACTOR: DECOMPOSIÇÃO DA VARIAÇÃO TOTAL (DEMONSTRAÇÃO DA EXPRESSÃO 13.3)

(1) A soma dos desvios quadrados $(X_{ij} - \bar{X})^2$ é dada por

$$\begin{aligned} \sum_i \sum_j (X_{ij} - \bar{X})^2 &= \sum_i \sum_j [(X_{ij} - \bar{X}_i) + (\bar{X}_i - \bar{X})]^2 \\ &= \sum_i \sum_j (X_{ij} - \bar{X}_i)^2 + \sum_i \sum_j (\bar{X}_i - \bar{X})^2 + \\ &\quad + 2 \cdot \underbrace{\sum_i \sum_j (X_{ij} - \bar{X}_i) \cdot (\bar{X}_i - \bar{X})}_A \end{aligned} \quad (\text{A13.2.1})$$

(2) O termo A pode ser decomposto nas seguintes parcelas:

$$A = \underbrace{\sum_i \sum_j X_{ij} \cdot \bar{X}_i}_{A_1} - \underbrace{\sum_i \sum_j X_{ij} \cdot \bar{X}}_{A_2} - \underbrace{\sum_i \sum_j \bar{X}_i^2}_{A_3} + \underbrace{\sum_i \sum_j \bar{X}_i \cdot \bar{X}}_{A_4} \quad (\text{A13.2.2})$$

onde,

$$A_1 = \sum_i \bar{X}_i \cdot \left(\sum_j X_{ij} \right) = \sum_i \bar{X}_i \cdot (J_i \cdot \bar{X}_i) = \sum_i J_i \cdot \bar{X}_i^2,$$

$$A_2 = \bar{X} \cdot \sum_i \sum_j X_{ij} = \bar{X} \cdot \left(\sum_i J_i \cdot \bar{X} \right) = \left(\sum_i J_i \right) \cdot \bar{X}^2,$$

$$A_3 = \sum_i J_i \cdot \bar{X}_i^2$$

e

$$A_4 = \bar{X} \cdot \sum_i \sum_j \bar{X}_i = \bar{X} \cdot \sum_i J_i \cdot \bar{X}_i = \bar{X} \cdot \left(\sum_i J_i \right) \cdot \bar{X} = \left(\sum_i J_i \right) \cdot \bar{X}^2.$$

(3) Substituindo estes termos em A13.2.2 obtém-se

$$A = \sum_i J_i \cdot \bar{X}_i^2 - \left(\sum_i J_i \right) \cdot \bar{X}^2 - \sum_i J_i \cdot \bar{X}_i^2 + \left(\sum_i J_i \right) \cdot \bar{X}^2 = 0.$$

(4) Deste resultado e de A13.2.1 obtém-se, finalmente,

$$\underbrace{\sum_i \sum_j (X_{ij} - \bar{X})^2}_{VT} = \underbrace{\sum_i \sum_j (X_{ij} - \bar{X}_i)^2}_{VDG} + \underbrace{\sum_i J_i \cdot (\bar{X}_i - \bar{X})^2}_{VEG} \quad (\text{expressão 13.3}).$$

APÊNDICE 13.3 MODELO ANOVA COM UM FACTOR DE EFEITOS FIXOS: CÁLCULO DOS VALORES ESPERADOS DOS DESVIOS QUADRÁTICOS MÉDIOS DENTRO DOS GRUPOS E ENTRE OS GRUPOS

(1) Dado que se admite que os erros E_{ij} possuem as seguintes propriedades

$$E(E_{ij}) = 0;$$

$$\text{Var}(E_{ij}) = \sigma^2;$$

$$\text{Cov}(E_{ij}, E_{ik}) = 0, \text{ para todo } j \neq k;$$

$$\text{Cov}(E_{ij}, E_{ky}) = 0, \text{ para todo } i \neq k;$$

e dado, ainda, que

$$X_{ij} = \mu_i + E_{ij} = \mu + \alpha_i + E_{ij},$$

vem

$$E(X_{ij}) = \mu + \alpha_i;$$

$$\text{Var}(X_{ij}) = \sigma^2;$$

$$\text{Cov}(X_{ij}, X_{ik}) = 0, \text{ para todo } j \neq k;$$

$$\text{Cov}(X_{ij}, X_{ky}) = 0, \text{ para todo } i \neq k.$$

(2) A variação dentro dos grupos (VDG) é dada por

$$\begin{aligned} VDG &= \sum_i \sum_j (X_{ij} - \bar{X}_i)^2 \\ &= \sum_i \sum_j [(X_{ij} - \mu_i) - (\bar{X}_i - \mu_i)]^2 \\ &= \underbrace{\sum_i \sum_j (X_{ij} - \mu_i)^2}_A + \underbrace{\sum_i \sum_j (\bar{X}_i - \mu_i)^2}_B - 2 \cdot \underbrace{\sum_i \sum_j (X_{ij} - \mu_i) \cdot (\bar{X}_i - \mu_i)}_C \end{aligned}$$

(3) O valor esperado de VDG vem então

$$E(VDG) = E(A) + E(B) + E(C), \quad (\text{A13.3.1})$$

onde:

$$E(A) = \sum_i \sum_j E[(X_{ij} - \mu_i)^2] = \sum_i \sum_j \sigma^2 = \left(\sum_i J_i \right) \cdot \sigma^2$$

$$E(B) = \sum_i \sum_j E[(\bar{X}_i - \mu_i)^2] = \sum_i \sum_j \sigma_{\bar{X}_i}^2 = \sum_i \sum_j \frac{1}{J_i} \cdot \sigma^2 = \sum_i \sigma^2 = I \cdot \sigma^2$$

$$\begin{aligned}
E(C) &= -2 \cdot \sum_i \sum_j E \left\{ (X_{ij} - \mu_i) \cdot \left[(1/J_i) \cdot \sum_{k=1}^{J_i} X_{ik} - \mu_i \right] \right\} \\
&= -2 \cdot \sum_i \sum_j E \left\{ (X_{ij} - \mu_i) \cdot (1/J_i) \cdot \sum_{k=1}^{J_i} (X_{ik} - \mu_i) \right\} \\
&= -\frac{2}{J_i} \cdot \sum_i \sum_j E \left\{ (X_{ij} - \mu_i) \cdot \sum_k (X_{ik} - \mu_i) \right\} \\
&= -\frac{2}{J_i} \cdot \sum_i \sum_j \left\{ E[(X_{ij} - \mu_i)^2] + \sum_{j \neq k} E[(X_{ij} - \mu_i) \cdot (X_{ik} - \mu_i)] \right\} \\
&= -\frac{2}{J_i} \cdot \sum_i \sum_j [\sigma^2 + \underbrace{\sum_{j \neq k} \text{Cov}(X_{ij}, X_{ik})}_{=0}] \\
&= -\frac{2}{J_i} \cdot \sum_i \sum_j \sigma^2 = -2 \cdot \sum_i \sigma^2 = -2 \cdot I \cdot \sigma^2.
\end{aligned}$$

Substituindo estes termos em A13.3.1, obtém-se

$$E(VDG) = \left[\left(\sum_i J_i \right) + I - 2 \cdot I \right] \cdot \sigma^2 = \left(\sum_i J_i - I \right) \cdot \sigma^2,$$

onde

$$E(DQMDG) = E \left(\frac{1}{\left(\sum_i J_i - I \right)} \cdot VDG \right) = \sigma^2.$$

(4) Passe-se agora ao cálculo do valor esperado da variação entre grupos (VEG). De

$$X_{ij} = \mu + \alpha_i + E_{ij}$$

obtem-se

$$\bar{X}_i = \frac{1}{J_i} \cdot \sum_j (\mu + \alpha_i + E_{ij}) = \mu + \alpha_i + \frac{1}{J_i} \cdot \sum_j E_{ij} = \mu + \alpha_i + \bar{E}_i$$

e

$$\begin{aligned}
\bar{X} &= \frac{1}{\sum_i J_i} \cdot \sum_i \sum_j (\mu + \alpha_i + E_{ij}) \\
&= \mu + \frac{1}{\sum_i J_i} \cdot \sum_i J_i \cdot \alpha_i + \frac{1}{\sum_i J_i} \cdot \sum_i \sum_j E_{ij} = \mu + \bar{\alpha} + \bar{E}.
\end{aligned}$$

A variação entre grupos vem

$$\begin{aligned}
VEG &= \sum_i J_i \cdot (\bar{X}_i - \bar{X})^2 \\
&= \sum_i J_i \cdot [(\mu + \alpha_i + \bar{E}_i) - (\mu + \bar{\alpha} + \bar{E})]^2 \\
&= \sum_i J_i \cdot [(\alpha_i - \bar{\alpha}) + (\bar{E}_i - \bar{E})]^2 \\
&= \underbrace{\sum_i J_i \cdot (\alpha_i - \bar{\alpha})^2}_A + \underbrace{\sum_i J_i \cdot (\bar{E}_i - \bar{E})^2}_B + 2 \cdot \underbrace{\sum_i J_i \cdot [(\alpha_i - \bar{\alpha}) \cdot (\bar{E}_i - \bar{E})]}_C,
\end{aligned}$$

onde

$$\begin{aligned}
B &= \sum_i J_i \cdot \bar{E}_i^2 + \sum_i J_i \cdot \bar{E}^2 - 2 \cdot \sum_i \left[J_i \cdot \left(\frac{1}{J_i} \sum_j E_{ij} \right) \cdot \left(\frac{1}{\sum_k J_k} \sum_k \sum_j E_{kj} \right) \right] \\
&= \sum_i J_i \cdot \bar{E}_i^2 + \sum_i J_i \cdot \bar{E}^2 - \frac{2}{\sum_k J_k} \cdot \sum_i \left[\left(\sum_j E_{ij} \right) \cdot \left(\sum_k \sum_j E_{kj} \right) \right].
\end{aligned}$$

O valor esperado de VEG é então

$$E(VEG) = E(A) + E(B) + E(C),$$

onde

$$\begin{aligned}
E(A) &= \sum_i J_i \cdot (\alpha_i - \bar{\alpha})^2, \\
E(B) &= \sum_i J_i \cdot \frac{1}{J_i} \cdot \sigma^2 + \sum_i J_i \cdot \frac{1}{\sum_k J_k} \cdot \sigma^2 - \frac{2}{\sum_k J_k} \cdot \sum_i (J_i \cdot \sigma^2) \\
&= I \cdot \sigma^2 + \sigma^2 - 2 \cdot \sigma^2 \\
&= (I - 1) \cdot \sigma^2
\end{aligned}$$

e

$$E(C) = 2 \cdot \sum_i J_i \cdot (\alpha_i - \bar{\alpha}) \cdot \underbrace{E[(\bar{E}_i - \bar{E})]}_{=0} = 0.$$

Adicionando estes termos, obtém-se

$$E(VEG) = \sum_i J_i \cdot (\alpha_i - \bar{\alpha})^2 + (I - 1) \cdot \sigma^2,$$

onde, finalmente, resulta

$$E(DQMEG) = E \left(\frac{1}{I - 1} \cdot VEG \right) = \sigma^2 + \frac{1}{I - 1} \cdot \sum_i J_i \cdot (\alpha_i - \bar{\alpha})^2.$$

**APÊNDICE 13.4 MODELO ANOVA COM UM FACTOR DE EFEITOS FIXOS:
JUSTIFICAÇÃO DA DISTRIBUIÇÃO DA ESTATÍSTICA
DO TESTE ANOVA QUANDO H_0 É VERDADEIRA**

- (1) Admitido que $E_{ij} \sim IN(0, \sigma^2)$ e ainda que é verdadeira a hipótese nula $H_0: \mu_1 = \mu_2 = \dots = \mu_I = \mu$, vem

$$\frac{VEG}{\sigma^2} = \frac{\sum_i J_i \cdot (\bar{X}_i - \bar{X})^2}{\sigma^2} \sim \chi^2_{I-1}$$

e


$$\frac{VDG}{\sigma^2} = \frac{\sum_i \sum_j (X_{ij} - \bar{X}_i)^2}{\sigma^2} \sim \chi^2_{\sum_i J_i - I}$$

- (2) Por outro lado, é fácil demonstrar que, nas condições acima enunciadas, as variáveis VEG / σ^2 e VDG / σ^2 são independentes.
- (3) Assim,

$$ET = \frac{DQMEG}{DQMDG} = \frac{VEG / (I-1)}{VDG / \left(\sum_i J_i - I\right)} = \frac{\frac{VEG / \sigma^2}{(I-1)}}{\frac{VDG / \sigma^2}{\left(\sum_i J_i - I\right)}} \sim \frac{\chi^2_{I-1} / (I-1)}{\chi^2_{\sum_i J_i - I} / \left(\sum_i J_i - I\right)}$$

onde o numerador e o denominador são independentes, resultando

$$ET = \frac{DQMEG}{DQMDG} \sim F_{I-1, \sum_i J_i - I} = F_{GL_1, GL_2}$$



- 13.1. Uma empresa distribuidora de butano decidiu testar qual o conteúdo de isobutano no gás que distribuía. Os testes foram realizados recorrendo à técnica de cromatografia em três laboratórios distintos, que dispunham de equipamentos diferentes. Os resultados expressos em percentagem de butano, foram os seguintes:

Laboratório		
I	II	III
27.64	28.40	28.01
27.48	28.24	27.86
26.82	28.54	28.44
27.42	28.61	28.69
27.20	27.82	28.32
27.91	27.93	27.75
28.20	28.45	28.21
26.45		28.43
27.63		
28.14		

Interprete os resultados obtidos. Verifique a condição de homogeneidade dos erros.

- 13.2. Na tabela seguinte apresentam-se índices de qualidade de 4 amostras retiradas de cada um de seis fabricos de um determinado processo químico.

Fabrico					
I	II	III	IV	V	VI
33	39	30	19	37	26
22	26	28	18	35	36
27	20	36	20	37	16
27	37	33	5	44	20

Caracterize a variação de qualidade de amostra para amostra e de fabrico para fabrico.

- 13.3. Para estudar o efeito que os quatro tipos de óleos disponíveis no mercado podem ter na vida de determinado componente, um laboratório efectuou os testes de longevidade cujos resultados figuram na tabela seguinte.

Óleo			
W	X	Y	Z
20	28	17	21
27	26	15	23
26	21	18	19
22	29	20	17

- (i) Teste, ao nível de significância de 5%, se há diferenças significativas entre as longevidades médias associadas aos diferentes óleos.
- (ii) Calcule a probabilidade de um componente lubrificado com o óleo W ter uma longevidade inferior a um outro lubrificado com o óleo Z.
- 13.4. Na tabela seguinte apresentam-se números de avarias semanais registadas em máquinas seleccionadas a partir de um parque de 100 máquinas do mesmo tipo. Note que as semanas durante as quais os números de avarias foram registados não são necessariamente as mesmas, de máquina para máquina.

Máquina	Número de avarias por semana				
1	22	15	9	16	10
2	8	4	2	10	8
3	7	16	15	8	10
4	11	6	1	12	7

- (i) Caracterize o comportamento das máquinas que integram o parque.
- (ii) Para a máquina 3, qual a probabilidade de, numa semana futura qualquer, o número de avarias ultrapassar as 20?
- 13.5. O director do Departamento de Marketing de uma empresa produtora de cervejas efectuou um teste para comparar a eficácia de dois anúncios, L e M. O teste foi conduzido em cafés de grandes cidades, pequenas cidades e vilas. Em cada um dos cafés seleccionados para realizar o teste, foi exibido, durante o mês de Maio, um cartaz ou com o anúncio L ou o anúncio M e foi registado o aumento das vendas em causa. Analise os resultados, que se apresentam na tabela seguinte, e tire conclusões acerca da eficácia relativa dos anúncios. Que recomendações faria ao director de Marketing, que tem que tomar decisões urgentes relativamente à campanha de Verão?

Anúncio	Tipo de aglomerado	N.º de observações (K)	Média*	Soma dos desvios quadráticos**
L	Pequena cidade	6	4.4	7.0
L	Grande cidade	6	4.1	4.0
L	Vila	6	3.5	5.0
M	Pequena cidade	6	3.0	8.0
M	Grande cidade	6	2.5	5.0
M	Vila	6	4.1	7.0

$$(*) \bar{x} = \frac{1}{K} \sum_{k=1}^K x_k \quad (**) \sum_{k=1}^K (x_k - \bar{x})^2$$

- 13.6. Para estudar o efeito de três tipos de resina e de dois tipos de madeira na resistência de placas de aglomerado de determinadas dimensões, um laboratório efectuou um conjunto de ensaios. Os resultados obtidos, que expressam uma medida de resistência das placas testadas, são os que figuram na tabela seguinte.

		Tipo de madeira					
		X			Y		
Tipo de resina	A	9	12	12	12	15	18
	B	15	12	12	14	15	16
	C	20	17	17	10	12	14

- (i) Interprete os resultados.
- (ii) Defina os intervalos de confiança a 95% para as diferenças entre os valores médios de resistências associadas às diferentes combinações resina-madeira.
- 13.7. O director de uma escola decidiu investigar se as classificações obtidas pelos alunos de um determinado ano variavam significativamente de turma para turma e de disciplina para disciplina. Para o efeito, escolheu ao acaso duas turmas e três disciplinas e recolheu, para as diferentes combinações turma-disciplina, amostras independentes de quatro classificações. Os resultados obtidos apresentam-se na tabela seguinte.

	Disciplina X	Disciplina Y	Disciplina Z
Turma A	14, 11, 12, 14	16, 15, 13, 13	10, 12, 14, 10
Turma B	10, 13, 12, 14	14, 16, 17, 12	11, 12, 14, 10

- (i) Recorrendo à técnica de análise de variância, interprete os resultados.
- (ii) Calcule a probabilidade de um aluno da turma A ter na disciplina X uma classificação superior à de um aluno da turma B na disciplina Y.
- 13.8. Os gestores de uma das casas comerciais mais requintadas de uma cidade cosmopolita observam, com preocupação, uma progressiva dificuldade em persuadir certos clientes a saldar as suas contas.
- Na tentativa de estudar uma política eficaz de gestão de clientes difíceis, o responsável por esta área decidiu realizar uma experiência que envolvia três procedimentos distintos:

- A: Enviar a habitual carta de «Último Aviso» (procedimento já adoptado há vários anos)
- B: Tal como em A, mas com a mensagem «Último Aviso» impressa a vermelho
- C: Tal como em B, mas fazendo preceder o envio da carta por um telefonema efectuado pelo gestor de clientes difíceis.

Na experiência efectuada, a escolha do procedimento a adoptar para cada cliente foi aleatória. A experiência foi realizada em dois meses consecutivos, tendo-se registado, para cada mês e para cada um de três grupos de montantes em dívida, a percentagem de clientes que saldaram as suas contas no período de quinze dias após a expedição da carta.

Os resultados obtidos apresentam-se na tabela seguinte.

		Procedimento		
		A	B	C
Montante em dívida [euros]	< 150	37%	45%	45%
		33%	47%	51%
	150-250	31%	40%	48%
		29%	44%	48%
	> 250	28%	38%	44%
		34%	38%	40%

Analise e interprete os resultados. Quais seriam as suas recomendações?

- 13.9. Os técnicos do ramo automóvel de uma seguradora procederam ao estudo da sinistralidade numa dada região. Tal região foi dividida em três zonas e os veículos foram classificados em comerciais e não-comerciais.

Para cada uma das combinações zona/tipo de veículo, foram analisadas as indemnizações pagas nos últimos 12 meses aos proprietários de 50 veículos seguros contra terceiros (estes veículos foram seleccionados aleatoriamente a partir dos registos da empresa seguradora). Na tabela seguinte apresentam-se, para cada uma daquelas combinações, a indemnização média anual paga por veículo (em milhares de euros).

	Zona X	Zona Y	Zona Z
Veículos comerciais	42.1	45.2	39.8
Veículos não-comerciais	41.0	42.5	39.7


Para os dados em causa, calcularam-se as seguintes variações:

Factor linha (FL)	VDFL	126.75
Factor coluna (FC)	VDFC	844.67
Interacção (I)	VDI	86.00
Residual (R)	VR	10945.62

- (i) Analise e interprete os resultados (nos testes que efectuar adopte o nível de significância de 5%).
- (ii) Estime a probabilidade de a indemnização anual paga a um veículo comercial seguro contra terceiros operando na zona Z exceder 34 mil euros.
- 13.10. Um fabricante de iogurtes está a ensaiar um novo tipo de conservante (inócuo para a saúde) que adicionado em certas proporções permitirá prolongar o prazo de validade. Numa experiência em que se ensaiaram três diferentes concentrações do referido conservante em seis diferentes iogurtes, observaram-se os seguintes resultados (medidos pelo número de dias adicionais com validade relativamente ao limite actualmente a ser praticado):

	Número adicional de dias com validade					
	2	7	4	0	2	3
Concentração A	2	7	4	0	2	3
Concentração B	4	3	8	5	5	6
Concentração C	1	2	0	3	1	4

Verifique se o valor esperado do número adicional de dias com validade é significativamente influenciado pelos níveis de concentração ensaiados.



14.1 INTRODUÇÃO

No capítulo dedicado à Estatística Descritiva, em particular na Secção 2.4.2, foram estudadas formas de descrever o relacionamento entre dados quantitativos integrados em amostras bivariadas.

Este tema será retomado neste capítulo, mas agora com uma ambição que, pelas razões que seguidamente se indicam, ultrapassa claramente a do estudo anteriormente desenvolvido:

- a postura meramente descritiva que foi adoptada anteriormente será agora substituída por uma outra que tem um objectivo de inferência estatística, e
- enquanto anteriormente a análise se tinha circunscrito ao relacionamento linear entre dois conjuntos de dados, neste capítulo serão analisadas relações lineares e não-lineares envolvendo duas ou mais variáveis.

Estes aspectos serão debatidos no âmbito do estudo da **regressão**, uma das técnicas estatísticas mais potentes e de utilização mais frequente. Esta técnica será apresentada começando pelo caso da regressão linear simples e progredindo depois para modelos mais complexos de regressão linear múltipla e de regressão não-linear.

14.2 REGRESSÃO LINEAR SIMPLES

14.2.1 MODELO DE REGRESSÃO LINEAR SIMPLES. HIPÓTESES SUBJACENTES

Um modelo de regressão linear simples descreve uma relação entre uma variável quantitativa independente, X , e uma variável quantitativa dependente, Y , nos termos seguintes:

$$Y_n = \alpha + \beta \cdot (X_n - \bar{X}) + E_n \quad (14.1)$$

onde

- n : índice denotando as observações do par de variáveis X e Y ($n = 1, \dots, N$)
- (X_n, Y_n) : n -ésima observação do par (X, Y)
- $\bar{X}$: média aritmética das observações X_n ($\bar{X} = 1/N \cdot \sum X_n$)
- α, β : parâmetros fixos (ambos desconhecidos, a estimar) da relação linear entre X e Y
- E_n : erro aleatório associado ao valor observado Y_n .

Neste modelo, admite-se que aos valores observados da variável independente, X_n ($n = 1, \dots, N$), não se encontram associados quaisquer erros. Tais valores devem então ser encarados como constantes pre-determinadas (e não como observações de uma variável aleatória).

Como se mostra na expressão 14.1, os erros considerados no modelo de regressão linear simples incidem directamente sobre os valores observados de Y . A teoria da regressão assenta no seguinte conjunto de hipóteses sobre tais erros, E_n ($n = 1, \dots, N$):

- (i) têm valor esperado nulo e variância constante, σ^2 ,
- (ii) são mutuamente independentes, e
- (iii) são Normalmente distribuídos.

Estas três hipóteses, que são idênticas àquelas sobre as quais se fundamenta a técnica de análise de variância, podem ser simbolicamente traduzidas pela expressão

$$E_n \sim IN(0, \sigma^2). \quad (14.2)$$


Se estas hipóteses se verificarem, atendendo à relação expressa na expressão 14.1, os valores da variável dependente, Y_n , também são independentes e seguem uma distribuição Normal com variância σ^2 e valor esperado μ_{Y_n} . Simbolicamente (ver Figura 14.1), vem

$$Y_n \sim IN(\mu_{Y_n}, \sigma^2), \quad \text{com} \quad \mu_{Y_n} = \alpha + \beta \cdot (X_n - \bar{X}).$$

Registe-se que o modelo apresentado na expressão 14.1,

$$Y_n = \alpha + \beta \cdot (X_n - \bar{X}) + E_n,$$

Figura 14.1
O modelo de regressão linear simples.



é equivalente ao modelo


$$Y_n = \alpha' + \beta \cdot X_n + E_n,$$

onde o parâmetro α' tem o seguinte significado:

$$\alpha' = \alpha - \beta \cdot \bar{X}.$$

Uma vez que se admitiu que os valores X_n são constantes, $\bar{X}$ é também uma constante, o mesmo sucedendo a α' . Esta constante (ou parâmetro) corresponde à ordenada da recta na origem dos XX e a constante (ou parâmetro) α à ordenada da recta em $\bar{X}$. O significado de α e de α' encontra-se ilustrado graficamente na Figura 14.2. Em ambos os modelos, o parâmetro β representa o coeficiente angular da recta.

Figura 14.2
Interpretação do significado dos parâmetros α e α' .



Registe-se ainda que, nas expressões até agora apresentadas, as observações da variável dependente e dos erros figuraram sempre em maiúsculas: Y_n e E_n . De acordo com a convenção anteriormente introduzida, estes símbolos designam variáveis aleatórias genéricas, que podem tomar valores particulares y_n e e_n .

14.2.2 ESTIMAÇÃO DOS PARÂMETROS DE REGRESSÃO ATRAVÉS DO MÉTODO DOS MÍNIMOS QUADRADOS

Adoptando o modelo consagrado na expressão 14.1, os parâmetros α e β podem ser estimados a partir de um conjunto de observações (X_n, Y_n) ($n = 1, \dots, N$, com $N > 2$) recorrendo ao método dos mínimos quadrados (de forma análoga à que se utilizou em 2.4.2). A minimização da função

$$SEQ = \sum_n E_n^2 = \sum_n \{Y_n - [\alpha + \beta \cdot (X_n - \bar{X})]\}^2$$

conduz aos seguintes estimadores

$$A = \frac{1}{N} \cdot \sum_n Y_n = \bar{Y} \quad (\text{estimador de } \alpha) \quad (14.3)$$

e

$$B = \frac{S_{XY}}{S_{XX}} \quad (\text{estimador de } \beta). \quad (14.4)$$

onde

$$S_{XY} = \sum_n [(X_n - \bar{X}) \cdot (Y_n - \bar{Y})] \quad \text{e} \quad S_{XX} = \sum_n (X_n - \bar{X})^2.$$

Se se considerarem os valores particulares destes estimadores, obtidos a partir de um conjunto particular de observações (x_n, y_n) , obtêm-se as estimativas seguintes:

$$a = \hat{\alpha} = \frac{1}{N} \cdot \sum_n y_n = \bar{y} \quad (14.5)$$


e

$$b = \hat{\beta} = \frac{S_{XY}}{S_{XX}}. \quad (14.6)$$

(estas expressões coincidem com as expressões 2.37 e 2.38, apresentadas anteriormente na Secção 2.4.2).

Registe-se que, uma vez que a ordenada da recta estimada no ponto $\bar{X}$ é $A = \bar{Y}$, aquela recta passa sempre pelo ponto $(\bar{X}, \bar{Y})$ (ver Figura 14.3).

Figura 14.3
Ponto $(\bar{X}, \bar{Y})$ na recta
estimada de
regressão.



Se a relação entre X_n e μ_{Y_n} for efectivamente linear e se forem verdadeiras as duas primeiras hipóteses formuladas em 14.2.1 relativamente aos erros (as que correspondem a admitir que estes são independentes, têm valor esperado nulo e variância constante), então pode demonstrar-se que:

- Os estimadores A e B (de que a e b são valores particulares) são não-enviesados, eficientes e consistentes.
- A matriz de variância-covariância dos estimadores A e B é

$$\begin{bmatrix} \text{Var}(A) & \text{Cov}(A, B) \\ \text{Cov}(B, A) & \text{Var}(B) \end{bmatrix} = \begin{bmatrix} \sigma^2 / N & 0 \\ 0 & \sigma^2 / S_{XX} \end{bmatrix},$$

onde N representa, como anteriormente foi referido, o número de observações e

$$\sigma^2 = \text{Var}(E_n) \quad S_{XX} = \sum_n (X_n - \bar{X})^2.$$

Como $\text{Cov}(A, B) = 0$, conclui-se que os estimadores A e B não são correlacionados. Deste facto resulta uma vantagem do modelo $Y_n = \alpha + \beta \cdot (X_n - \bar{X}) + E_n$ em relação ao modelo $Y_n = \alpha' + \beta \cdot X_n + E_n$, já que neste os estimadores A' e B são correlacionados. Esta correlação tem origem no facto de que α' é função de α e β pois, como se viu anteriormente, $\alpha' = \alpha - \beta \cdot \bar{X}$.

(iii) Um estimador não-enviesado de σ^2 é dado por

$$S^2 = \frac{1}{N-2} \cdot \sum_n \hat{E}_n^2 = \frac{1}{N-2} \cdot \sum_n [Y_n - A - B \cdot (X_n - \bar{X})]^2. \quad (14.7)$$

Note-se que, na expressão deste estimador, o divisor é $N-2$, ou seja, é igual ao número total de observações menos o número de parâmetros estimados (α e β).

As estimativas da variância dos erros, que correspondem a valores particulares deste estimador, denotam-se, como é habitual, por s^2 .

Exemplo 14.1

Considerem-se os pares de observações (x_n, y_n) que constam da Tabela 14.1. Admitindo que a relação entre as variáveis X e Y é linear, estimem-se os parâmetros do modelo de regressão correspondente.

Neste caso,

$$N = 5$$

$$\bar{x} = \frac{1}{5} \cdot (12 + 8 + 14 + 10 + 6) = 10$$

$$\bar{y} = \frac{1}{5} \cdot (33 + 24 + 39 + 31 + 23) = 30$$

$$S_{XX} = \sum_n (x_n - \bar{x})^2 = 2^2 + 2^2 + 4^2 + 0 + 4^2 = 40$$

$$S_{XY} = \sum_n (x_n - \bar{x}) \cdot (y_n - \bar{y}) = 2 \cdot 3 + (-2) \cdot (-6) + 4 \cdot 9 + 0 \cdot 1 + (-4) \cdot (-7) = 82.$$

Resulta assim que

$$a = \bar{y} = 30$$

$$b = S_{XY} / S_{XX} = 2.05.$$

Na Tabela 14.2 apresentam-se os cálculos que conduzem às diferenças entre as observações de Y e os valores correspondentes da recta estimada de regressão.

Tabela 14.1
Observações (x_n, y_n)
(Exemplo 14.1).

n	x_n	y_n
1	12	33
2	8	24
3	14	39
4	10	31
5	6	23

Cálculo dos
erros estimados
(Exemplo 14.1).

n	y_n	$\hat{\mu}_{y_n} = a + b \cdot (x_n - \bar{x})$	$\hat{e}_n = y_n - \hat{\mu}_{y_n}$
1	33	$30 + 2.05 \cdot 2 = 34.1$	$33 - 34.1 = -1.1$
2	24	$30 + 2.05 \cdot (-2) = 25.9$	$24 - 25.9 = -1.9$
3	39	$30 + 2.05 \cdot 4 = 38.2$	$39 - 38.2 = 0.8$
4	31	$30 + 2.05 \cdot 0 = 30.0$	$31 - 30.0 = 1.0$
5	23	$30 + 2.05 \cdot (-4) = 21.8$	$23 - 21.8 = 1.2$

A partir dos valores da última coluna desta tabela, pode-se estimar a variância dos erros E_n (ver expressão 14.7):

$$s^2 = \hat{\sigma}^2 = \frac{1}{N-2} \cdot \sum_n \hat{e}_n^2 = \frac{1}{3} \cdot (1.1^2 + 1.9^2 + 0.8^2 + 1.0^2 + 1.2^2) = 2.63.$$

As estimativas das variâncias dos estimadores A e B vêm:

$$\hat{\sigma}_A^2 = s^2 / N = 2.63 / 5 = 0.527 \quad (\text{ou seja, } \hat{\sigma}_A = 0.726),$$

$$\hat{\sigma}_B^2 = s^2 / s_{xx} = 2.63 / 40 = 0.0658 \quad (\text{ou seja, } \hat{\sigma}_B = 0.257).$$

■ 14.2.3 INTERVALOS DE CONFIANÇA E TESTES RELATIVOS AOS PARÂMETROS DE REGRESSÃO

Se os erros E_n , além de serem independentes com valor esperado nulo e variância constante, seguirem uma distribuição Normal, ou seja, se satisfizerem todas as condições referidas na Secção 14.2.1 (que se traduzem na expressão 14.2), então é possível especificar as distribuições dos estimadores de α , β e σ^2 bem como das estatísticas utilizadas na realização de testes de hipóteses relativas àqueles parâmetros. Em particular, verifica-se que

$$\begin{aligned} A &\sim N(\alpha, \sigma^2 / N) \\ B &\sim N(\beta, \sigma^2 / s_{xx}) \\ (N-2) \cdot \frac{S^2}{\sigma^2} &\sim \chi^2_{N-2}, \end{aligned} \quad (14.8)$$

donde resulta que

$$\begin{aligned} \frac{A - \alpha}{S / \sqrt{N}} &\sim t_{N-2} \\ \frac{B - \beta}{S / \sqrt{s_{xx}}} &\sim t_{N-2}. \end{aligned} \quad (14.9)$$

A partir destas expressões, é possível definir intervalos de confiança e testes de hipóteses envolvendo os parâmetros de regressão α (ou α') e β .

■ 14.2.3.1 INTERVALOS DE CONFIANÇA

A definição dos intervalos de confiança para o parâmetro α decorre directamente da primeira expressão 14.9. Por exemplo, os limites do intervalo de confiança bilateral a $(1 - \gamma) \cdot 100\%$ são dados por

$$A \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{1/N}. \quad (14.10)$$

Frequentemente, é mais útil definir intervalos de confiança para o parâmetro α' do que para o parâmetro α (recorde-se que α' representa a ordenada na origem do eixo dos XX). Para definir tais intervalos, há que tomar em conta que

- o estimador de α' , $A' = A - \bar{X} \cdot B$, segue uma distribuição Normal, pois A e B são variáveis independentes que seguem distribuições normais e $\bar{X}$ é uma constante e
- o valor esperado e a variância de A' são dados por

$$E(A') = E(A) - \bar{X} \cdot E(B) = \alpha - \bar{X} \cdot \beta$$

$$\text{Var}(A') = \text{Var}(A) + \bar{X}^2 \cdot \text{Var}(B) = \frac{\sigma^2}{N} + \bar{X}^2 \cdot \frac{\sigma^2}{s_{xx}} = \left(\frac{1}{N} + \frac{\bar{X}^2}{s_{xx}} \right) \cdot \sigma^2.$$

Destas condições decorre a definição dos intervalos de confiança para o parâmetro α' . Por exemplo, os limites do intervalo de confiança bilateral a $(1 - \gamma) \cdot 100\%$ são dados por

$$(A - \bar{X} \cdot B) \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{\frac{1}{N} + \frac{\bar{X}^2}{s_{xx}}}. \quad (14.11)$$

Exemplo 14.2

Para o Exemplo 14.1, o intervalo de confiança bilateral a 95% para α' é calculado a partir dos seguintes valores:

$$a - \bar{x} \cdot b = 30 - 10 \cdot 2.05 = 9.50$$

$$N = 5$$

$$t_3(0.025) = 3.18 \quad (\text{ver Tabela 5 do Anexo «Tabelas»})$$

$$s = \sqrt{2.63} = 1.62$$

$$\sqrt{\frac{1}{N} + \frac{\bar{x}^2}{s_{xx}}} = \sqrt{\frac{1}{5} + \frac{10^2}{40}} = 1.64.$$

Substituindo estes valores em 14.11, os limites do intervalo de confiança vêm

$$9.50 \pm 3.18 \cdot 1.62 \cdot 1.64 \quad 9.50 \pm 8.45$$

donde resulta que o intervalo de confiança a 95% para α' é

$$[1.05, 17.95].$$

A definição dos intervalos de confiança para o parâmetro β resulta da segunda expressão 14.9. Por exemplo, os limites do intervalo de confiança bilateral a $(1 - \gamma) \cdot 100\%$ são dados por

$$B \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{1/s_{xx}}. \quad (14.12)$$

Exemplo 14.3

Para o Exemplo 14.1, o intervalo de confiança bilateral a 95% para β é calculado a partir dos valores seguintes:

$$b = 2.05$$

$$N = 5$$

$$t_3(0.025) = 3.18$$

$$s = \sqrt{2.63} = 1.62$$

$$s_{xx} = 40.$$

Substituindo estes valores em 14.12, os limites do intervalo de confiança vêm

$$2.05 \pm 3.18 \cdot 1.62 \cdot \sqrt{1/40}$$

$$2.05 \pm 0.82$$

donde resulta que o intervalo de confiança é

$$[1.23, 2.87].$$

14.2.3.2 TESTES DE HIPÓTESES

Os testes de hipóteses relativos aos parâmetros α (ou α') e β podem ser realizados recorrendo aos intervalos de confiança. Assim, com base no intervalo calculado no Exemplo 14.2, a hipótese $\alpha' = 0$ deve ser rejeitada, ao nível de significância de 5%, em favor de $\alpha' \neq 0$. De modo análogo, o intervalo de confiança calculado no Exemplo 14.3 conduz, ao mesmo nível de significância, à rejeição da hipótese $\beta = 0$, aceitando-se $\beta \neq 0$.

Alternativamente, os testes podem ser conduzidos recorrendo ao procedimento clássico. Para α , a estrutura do teste, que decorre da primeira das expressões 14.9, é a seguinte:

$$H_0: \alpha = \alpha_0$$

$$H_1: \alpha \neq \alpha_0, \alpha > \alpha_0 \text{ ou } \alpha < \alpha_0$$

$$ET = \frac{A - \alpha_0}{S / \sqrt{N}}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim t_{N-2}.$$

Para α' , o teste, cuja estrutura é fácil de justificar a partir das considerações que conduziram à expressão 14.11, vem:

$$H_0: \alpha' = \alpha'_0$$

$$H_1: \alpha' \neq \alpha'_0, \alpha' > \alpha'_0 \text{ ou } \alpha' < \alpha'_0$$

$$ET = \frac{(A - \bar{X} \cdot B) - \alpha'_0}{S \cdot \sqrt{\frac{1}{N} + \frac{\bar{X}^2}{S_{XX}}}}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim t_{N-2}.$$

Exemplo 14.4

Retomando o Exemplo 14.1, teste-se, ao nível de significância de 5%, a hipótese $H_0: \alpha' = 0$ contra $H_1: \alpha' \neq 0$.

Como

$$ET = \frac{30 - 10 \cdot 2.05}{\sqrt{2.63} \cdot \sqrt{\frac{1}{5} + \frac{10^2}{40}}} = \frac{9.50}{1.62 \cdot 1.64} = 3.58 > t_3 (\alpha = 0.025) = 3.18,$$

a hipótese nula é rejeitada ao nível de significância de 5% (com um valor de prova aproximado de 3.73%), resultado que é consistente com o obtido no Exemplo 14.2.

Para β , a estrutura do teste resulta da segunda das expressões 14.9, vindo:

$$H_0: \beta = \beta_0$$

$$H_1: \beta \neq \beta_0, \beta > \beta_0 \text{ ou } \beta < \beta_0$$

$$ET = \frac{B - \beta_0}{S / \sqrt{S_{XX}}}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim t_{N-2}.$$

Exemplo 14.5

Retomando o Exemplo 14.1, teste-se, ao nível de significância de 5%, a hipótese $H_0: \beta = 0$ contra $H_1: \beta \neq 0$.

Como

$$ET = \frac{2.05}{1.62 / \sqrt{40}} = 7.99 > t_3 (\alpha = 0.025) = 3.18,$$

a hipótese nula é rejeitada ao nível de significância de 5% (com um valor de prova aproximado de 0.41%), resultado que é consistente com o obtido no Exemplo 14.3.

Quando se pretenda realizar um teste *bilateral* à hipótese nula $H_0: \beta = 0$, pode ainda recorrer-se a um terceiro procedimento, baseado na análise de variância. No contexto da regressão linear simples, a aplicação daquela técnica fundamenta-se na decomposição seguinte (ver Figura 14.4):

$$\sum_{n=1}^n (Y_n - \bar{Y})^2 = \underbrace{\sum_{n=1}^n \{[A + B \cdot (X_n - \bar{X})] - \bar{Y}\}^2}_{VT = S_{YY}} + \underbrace{\sum_{n=1}^n \{Y_n - [A + B \cdot (X_n - \bar{X})]\}^2}_{VDR = B^2 \cdot S_{XX}} \quad (14.13)$$

onde:

VT: Variação Total das observações Y_n em torno da sua média $\bar{Y}$

VDR: Variação Devida à Regressão (para este termo contribuem os desvios entre os pontos que, na recta estimada, correspondem às observações X_n e a média $\bar{Y}$)

VR: Variação Residual ou inexplicada (para este termo contribuem os desvios entre as observações Y_n e os pontos que, na recta estimada, lhes correspondem).

Na Tabela 14.3 representa-se a tabela ANOVA correspondente ao modelo de regressão linear simples.

Figura 14.4
Desvios que, para uma observação particular (x_0, y_0), contribuem para as diferentes componentes de variação.




Tabela 14.3. Tabela ANOVA para o modelo de regressão linear simples

Fontes de variação	Variações (Somas de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Devida à regressão (DR)	(Variação «explicada» pela regressão) $VDR = B^2 \cdot S_{xx} = B \cdot S_{xy}$	$GL_1 = 1$	$DQMDR = VDR$	$E[DQMDR] = \sigma^2 + \beta^2 \cdot S_{xx}$
Residual (R)	(Variação residual «não explicada») $VR = S_{yy} - B \cdot S_{xy}$	$GL_1 = N - 2$	$DQMR = VR / GL_2$	$E[DQMR] = \sigma^2$
Total (T)	(Variação total) $VT = S_{yy}$	$GL = GL_1 + GL_2 = N - 1$		

O procedimento de teste ANOVA tem a seguinte estrutura:

$$H_0: \beta = 0$$

$$H_1: \beta \neq 0$$

$$ET = \frac{DQMDR}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{1, N-2}$$

Exemplo 14.6

Repita-se o teste efectuado no Exemplo 14.5, recorrendo à técnica de análise de variância. A tabela ANOVA correspondente a este caso apresenta-se na Tabela 14.4. O teste conduz então ao seguinte resultado:

$$ET = \frac{168.1}{2.633} = 63.84 > F_{1,3}(0.05) = 10.13,$$

pelo que H_0 é rejeitada ao nível de significância de 5% (com um valor de prova aproximado de 0.41%, ou seja, um valor igual àquele que já tinha sido obtido no teste apresentado no Exemplo 14.5).

Tabela 14.4
Tabela ANOVA
(Exemplo 14.1).

Fontes	Variações	GL	DQM
DR	168.1	1	168.1
RD	7.9	3	2.633
TD	176.0	4	

Relativamente a este teste ANOVA deve salientar-se o seu carácter estritamente bilateral. De facto, atendendo à expressão do valor esperado do desvio quadrático médio devido à regressão (ver Tabela 14.3), a estatística de teste só depende do quadrado de β , não tendo portanto em conta o sinal deste parâmetro (quando ele for diferente de zero).

14.2.4 PREVISÕES EFECTUADAS COM BASE NO MODELO DE REGRESSÃO LINEAR SIMPLES

Uma das aplicações mais correntes dos modelos de regressão linear simples consiste na previsão do valor da variável dependente, Y , para um novo valor da variável independente, X .

Para cada valor X , a melhor previsão de Y obtém-se recorrendo à recta estimada, ou seja, fazendo

$$\hat{Y} = \hat{\mu}_Y = A + B \cdot (X - \bar{X}). \quad (14.14)$$

O erro que se comete na previsão é dado pela diferença

$$\delta = Y - \hat{Y} = [\alpha + \beta \cdot (X - \bar{X}) + E] - [A + B \cdot (X - \bar{X})].$$

Uma vez que se admite que cada nova observação, Y , é independente das observações anteriores (a partir das quais se obteve $\hat{Y}$), tal observação será, também, independente de $\hat{Y}$. Assim, a variância do erro de previsão vem dada por

$$\text{Var}(\delta) = \text{Var}(Y) + \text{Var}(\hat{Y}).$$

Ora, uma vez que α , β , X e $\bar{X}$ são constantes, vem

$$\text{Var}(Y) = \text{Var}[\alpha + \beta \cdot (X - \bar{X}) + E] = \text{Var}(E) = \sigma^2. \quad (14.15)$$

Por outro lado, dado que A e B são independentes e que $(X - \bar{X})$ é uma constante, resulta

$$\begin{aligned}\text{Var}(\hat{Y}) &= \text{Var}[A + B \cdot (X - \bar{X})] \\ &= \text{Var}(A) + (X - \bar{X})^2 \cdot \text{Var}(B) \\ &= \frac{\sigma^2}{N} + (X - \bar{X})^2 \cdot \frac{\sigma^2}{S_{XX}} \\ &= \left[\frac{1}{N} + \frac{(X - \bar{X})^2}{S_{XX}} \right] \cdot \sigma^2.\end{aligned}\quad (14.16)$$

Finalmente, somando as expressões 14.15 e 14.16, a variância do erro de previsão vem:

$$\text{Var}(\delta) = \left[1 + \frac{1}{N} + \frac{(X - \bar{X})^2}{S_{XX}} \right] \cdot \sigma^2.\quad (14.17)$$

onde, recorde-se, σ^2 pode ser estimado através da expressão 14.7 ou, o que é equivalente, mas mais prático, através da expressão do desvio quadrático médio residual que se apresenta na Tabela 14.3 ($DQMR = VR/GL_2$).

Admitindo como válida a hipótese da Normalidade dos erros E_n , é óbvio que tanto Y como $\hat{Y}$ e, por consequência, δ , seguem também distribuições Normais. Nestas condições, para cada estimativa particular da posição da recta de regressão e para cada valor particular de X , os limites do intervalo de previsão a $(1 - \gamma) \cdot 100\%$ — isto é, os limites do intervalo que incluirá o valor observado, Y , com probabilidade $(1 - \gamma)$ — vêm dados por:

$$\hat{Y} \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{1 + \frac{1}{N} + \frac{(X - \bar{X})^2}{S_{XX}}}.\quad (14.18)$$


Quando se considera o conjunto de todos os valores possíveis de X , os intervalos formam uma **banda de previsão**.

Na Figura 14.5, a banda exterior (C) é definida por

$$\hat{Y} \pm S \cdot \sqrt{1 + \frac{1}{N} + \frac{(X - \bar{X})^2}{S_{XX}}},$$

correspondendo, portanto, a uma banda de previsão a $(1 - \gamma) \cdot 100\%$ onde γ é tal que $t_{N-2}(\gamma/2) = 1$.

Figura 14.5
Banda de previsão
para os valores de Y .



Para facilitar a interpretação do significado daquela banda, foram definidas duas outras, A e B, nos seguintes termos:

Banda A: $\hat{Y} \pm S$

Se a posição da recta de regressão fosse conhecida correctamente (isto é, se os parâmetros α e β fossem estimados a partir de uma infinidade de observações e, portanto, fossem conhecidos sem erro), o valor de Y seria ainda afectado pelo erro E , como se presumiu desde início no modelo de regressão linear simples. Metade da largura da banda A representa uma estimativa do desvio padrão desse erro E . Como se admitiu que os erros que afectam as observações da variável dependente são homogêneos (isto é, têm variância constante, independentemente de X), a banda tem largura constante.

Banda B: $\hat{Y} \pm S \cdot \sqrt{1 + \frac{1}{N}}$

Na definição desta banda, acrescenta-se, relativamente à anterior, o termo correspondente ao erro de estimação de α . A largura adicional é constante, reflectindo o facto de este erro de estimação se traduzir na colocação da recta estimada acima ou abaixo da posição correcta, paralelamente a esta.


Na definição da banda C,

$$\hat{Y} \pm S \cdot \sqrt{1 + \frac{1}{N} + \frac{(X - \bar{X})^2}{S_{XX}}},$$

acrescenta-se, relativamente a B, o termo correspondente ao erro de estimação de β . A largura adicional é nula quando a variável independente toma o valor $\bar{X}$ (isto é, no ponto que, relativamente ao eixo dos XX , corresponde ao centro das observações) e aumenta à medida que X se afasta daquele valor, reflectindo o facto de o erro de estimação de β se traduzir numa maior ou menor inclinação da recta estimada relativamente à posição correcta.

Deve observar-se que, apesar de a banda de previsão alargar à medida que as observações se afastam de $\bar{X}$, sempre que se efectuam extrapolações corre-se o risco de se subestimar o desvio padrão do erro de previsão. Na verdade, uma relação que pareça linear dentro da gama de valores observados X_n pode ter, como se ilustra na Figura 14.6, um comportamento não-linear numa gama mais alargada. A banda de previsão C, acima definida, não contempla a ocorrência deste tipo de situações, pois a sua especificação assenta no pressuposto de que a relação é efectivamente linear.

Figura 14.6
Efeito da não-linearidade da
relação entre X e m_Y
na previsões
efectuadas com base
em extrapolações.



14.2.5 REGRESSÃO LINEAR SIMPLES E CORRELAÇÃO ENTRE VARIÁVEIS

Nos Capítulos 2 (Estatística Descritiva) e 5 (Distribuições Conjuntas de Probabilidades) foi feita referência à correlação amostral e populacional. Embora a análise de correlação (entre duas variáveis) seja uma técnica menos potente do que a de regressão linear (simples) — já que a primeira revela apenas o grau de relacionamento linear entre variáveis, enquanto a segunda especifica a forma como tal relacionamento se processa —, as duas técnicas estão intimamente ligadas.

No modelo de regressão linear simples, os valores observados de X são encarados como constantes predeterminadas (podendo não ser representativos de uma qualquer distribuição populacional de X). Na análise de correlação, para que a partir do coeficiente de correlação amostral,

$$R_{XY} = \frac{\sum_n [(X_n - \bar{X}) \cdot (Y_n - \bar{Y})]}{\sqrt{\sum_n (X_n - \bar{X})^2} \cdot \sqrt{\sum_n (Y_n - \bar{Y})^2}} = \frac{S_{XY}}{\sqrt{S_{XX}} \cdot \sqrt{S_{YY}}} \quad (\text{ver expressão 2.41}),$$

se possam fazer inferências relativas ao coeficiente de correlação populacional,

$$\rho_{XY} = \frac{E[(X - \mu_X) \cdot (Y - \mu_Y)]}{\sqrt{E[(X - \mu_X)^2] \cdot E[(Y - \mu_Y)^2]}} \quad (\text{ver expressões 5.25 e 5.29}),$$

é preciso que as observações (X_n, Y_n) sejam representativas da população conjunta de X e Y (o que implica que as observações X_n sejam representativas da distribuição populacional de X). Para se entender esta exigência, observe-se a Figura 14.7 onde se admite estar representada toda a população conjunta de X e Y . Se os valores de X pudessem ser predeterminados (como se admite na regressão), então podiam ser escolhidas, por exemplo, apenas as observações contidas na “zona central” da população de X . O coeficiente de correlação amostral obtido a partir delas seria claramente enviesado: o seu valor esperado seria muito mais baixo do que o coeficiente de correlação populacional.

Na análise da correlação entre duas variáveis não se faz qualquer distinção entre variável dependente e variável independente (ao contrário do que sucede na regressão, no âmbito da qual se presume existir uma relação causa-efeito entre a variável independente e a variável dependente). No contexto da análise da correlação, que, como se viu, requer que as observações (X_n, Y_n) sejam representativas da população conjunta de X e Y , tanto se poderia ajustar uma recta minimizando o somatório

$$SEQ = \sum_n [Y_n - \alpha - \beta \cdot (X_n - \bar{X})]^2$$




Figura 14.7
Enviesamento
do coeficiente
de correlação
amostral calculado
a partir de obser-
vações pertencentes
à zona central da
população de X .

como uma outra recta minimizando

$$SEQ^* = \sum_n [X_n - \alpha^* - \beta^* \cdot (Y_n - \bar{Y})]^2.$$

Em geral, as rectas seriam diferentes, mas o coeficiente de correlação amostral seria o mesmo.

A existência de correlação populacional entre duas variáveis X e Y implica a ocorrência de uma das seguintes situações:

- (i) X é causa de Y , ou
- (ii) Y é causa de X , ou ainda
- (iii) uma terceira variável é causa simultânea de X e Y .

A fechar esta breve análise da interligação entre regressão e correlação, far-se-á um comentário relativo à questão do sentido que fará, no contexto de uma análise de regressão em que X seja claramente assumida como variável predeterminada (escolhida de forma não aleatória), calcular o coeficiente de correlação amostral, R_{XY} . Neste caso, o interesse estará no cálculo do seu quadrado, ou seja, o coeficiente de determinação, R_{XY}^2 , definido anteriormente, na Secção 2.4.2. Como então se observou, R_{XY}^2 tem um significado importante, que é útil na interpretação dos resultados da regressão: este coeficiente representa a proporção da variação de Y que é explicada pela regressão, pois (ver expressão 2.43)

$$R_{XY}^2 = \frac{B^2 \cdot S_{XX}}{S_{YY}} = \frac{B^2 \cdot \sum_n (X_n - \bar{X})^2}{\sum_n (Y_n - \bar{Y})^2} = \frac{\text{variação de } Y \text{ explicada pela regressão}}{\text{variação total de } Y}.$$

14.3 REGRESSÃO LINEAR MÚLTIPLA

14.3.1 MODELO DE REGRESSÃO LINEAR MÚLTIPLA. HIPÓTESES SUBJACENTES

Um modelo de regressão linear múltipla descreve uma relação entre um conjunto de variáveis quantitativas independentes, X_j ($j = 1, 2, \dots, J$), e uma variável dependente também quantitativa, Y , através da expressão

$$Y_n = \alpha + \beta_1 \cdot (X_{1n} - \bar{X}_1) + \dots + \beta_J \cdot (X_{Jn} - \bar{X}_J) + E_n \quad (14.19)$$

onde, adoptando uma notação na linha da anterior,

- n : índice denotando as observações das variáveis $X_1, \dots, X_J$ e Y ($n = 1, \dots, N$)
- $(X_{1n}, \dots, X_{Jn}, Y_n)$: n -ésima observação das variáveis $X_1, \dots, X_J$ e Y
- $\bar{X}_j$: média aritmética das observações da variável X_j ($\bar{X}_j = 1/N \cdot \sum_n X_{jn}$)
- $\alpha, \beta_1, \dots, \beta_J$: parâmetros fixos (desconhecidos, a estimar) da relação linear entre $X_1, \dots, X_J$ e Y
- E_n : erro aleatório associado ao valor observado Y_n .

As hipóteses subjacentes a este modelo são idênticas àquelas que foram consideradas no caso do modelo de regressão linear simples:

- (i) os valores X_{jn} e, portanto, os valores $\bar{X}_j$ são encarados como constantes predeterminadas, sem erro e
- (ii) os erros E_n são mutuamente independentes, têm valor esperado nulo, variância constante, σ^2 , e são Normalmente distribuídos, isto é, $E_n \sim IN(0, \sigma^2)$.

14.3.2 ESTIMAÇÃO DOS PARÂMETROS DE REGRESSÃO ATRAVÉS DO MÉTODO DOS MÍNIMOS QUADRADOS

Os parâmetros α e $\beta_1, \dots, \beta_J$ do modelo considerado na expressão 14.19 podem ser estimados a partir de um conjunto de observações $(X_{1n}, \dots, X_{Jn}, Y_n)$ ($n = 1, \dots, N$, com $N > J + 1$) recorrendo ao método dos mínimos quadrados. O mínimo da função

$$SEQ = \sum_n E_n^2 = \sum_n \{Y_n - [\alpha + \beta_1 \cdot (X_{1n} - \bar{X}_1) + \dots + \beta_J \cdot (X_{Jn} - \bar{X}_J)]\}^2$$

$$= \sum_n [Y_n - \alpha - \beta_1 \cdot (X_{1n} - \bar{X}_1) - \dots - \beta_J \cdot (X_{Jn} - \bar{X}_J)]^2$$

atinge-se para

$$\frac{\partial SEQ}{\partial \alpha} = (-2) \cdot \sum_n [Y_n - \alpha - \beta_1 \cdot (X_{1n} - \bar{X}_1) - \dots - \beta_J \cdot (X_{Jn} - \bar{X}_J)] = 0$$

$$\frac{\partial SEQ}{\partial \beta_1} = (-2) \cdot \sum_n \{(X_{1n} - \bar{X}_1) \cdot [Y_n - \alpha - \beta_1 \cdot (X_{1n} - \bar{X}_1) - \dots - \beta_J \cdot (X_{Jn} - \bar{X}_J)]\} = 0$$

(...)

$$\frac{\partial SEQ}{\partial \beta_J} = (-2) \cdot \sum_n \{(X_{Jn} - \bar{X}_J) \cdot [Y_n - \alpha - \beta_1 \cdot (X_{1n} - \bar{X}_1) - \dots - \beta_J \cdot (X_{Jn} - \bar{X}_J)]\} = 0.$$

A partir da primeira destas equações, obtém-se para α um estimador idêntico ao que havia sido definido para o modelo de regressão linear simples:

$$A = \frac{1}{N} \cdot \sum_n Y_n = \bar{Y} \quad (\text{expressão 14.3}).$$

Desenvolvendo as restantes equações, obtém-se o seguinte sistema, a partir do qual se podem obter os estimadores $B_1, \dots, B_J$ dos parâmetros $\beta_1, \dots, \beta_J$:

$$\begin{aligned} B_1 \cdot S_{X_1 X_1} + B_2 \cdot S_{X_1 X_2} + \dots + B_J \cdot S_{X_1 X_J} &= S_{X_1 Y} \\ B_1 \cdot S_{X_2 X_1} + B_2 \cdot S_{X_2 X_2} + \dots + B_J \cdot S_{X_2 X_J} &= S_{X_2 Y} \\ (\dots) \\ B_1 \cdot S_{X_J X_1} + B_2 \cdot S_{X_J X_2} + \dots + B_J \cdot S_{X_J X_J} &= S_{X_J Y}, \end{aligned} \quad (14.20)$$

onde

$$S_{X_n X_n} = \sum_n (X_{1n} - \bar{X}_1) \cdot (X_{1n} - \bar{X}_1)$$

e

$$S_{X_J Y} = \sum_n (X_{Jn} - \bar{X}_J) \cdot (Y_n - \bar{Y}).$$

Se a relação entre as variáveis X_j e μ_Y for efectivamente linear e se os erros E_n forem independentes, tiverem valor esperado nulo e variância constante, σ^2 , então pode demonstrar-se que:

- (i) Os estimadores A e $B_1, \dots, B_J$ são não-enviesados, eficientes e consistentes.
- (ii) A matriz de variância-covariância dos estimadores A e $B_1, \dots, B_J$ é

$$\begin{bmatrix} \text{Var}(A) & \text{Cov}(A, B_1) & \dots & \text{Cov}(A, B_J) \\ \text{Cov}(B_1, A) & \text{Var}(B_1) & \dots & \text{Cov}(B_1, B_J) \\ \dots & \dots & \dots & \dots \\ \text{Cov}(B_J, A) & \text{Cov}(B_J, B_1) & \dots & \text{Var}(B_J) \end{bmatrix} =$$

$$= \sigma^2 \cdot \begin{bmatrix} N & 0 & \dots & 0 \\ 0 & S_{X_1 X_1} & \dots & S_{X_1 X_J} \\ \dots & \dots & \dots & \dots \\ 0 & S_{X_J X_1} & \dots & S_{X_J X_J} \end{bmatrix}^{-1}$$

donde se pode concluir que

$$\text{Var}(A) = \sigma^2 / N$$

$$\text{Cov}(A, B_j) = 0 \quad (\text{para } j = 1, \dots, J) \quad \text{e}$$

$$\begin{bmatrix} \text{Var}(B_1) & \text{Cov}(B_1, B_2) & \dots & \text{Cov}(B_1, B_J) \\ \dots & \dots & \dots & \dots \\ \text{Cov}(B_J, B_1) & \text{Cov}(B_J, B_2) & \dots & \text{Var}(B_J) \end{bmatrix}$$

$$= \sigma^2 \cdot \begin{bmatrix} S_{X_1 X_1} & \dots & S_{X_1 X_J} \\ \dots & \dots & \dots \\ S_{X_J X_1} & \dots & S_{X_J X_J} \end{bmatrix}^{-1}.$$

A inexistência de correlação entre o estimador A e os estimadores $B_1, \dots, B_J$ resulta de o primeiro ser obtido (através da equação 14.3) por um processo independente dos segundos (calculados recorrendo ao sistema de equações 14.20). Já entre os estimadores $B_1, \dots, B_J$ existe correlação, como resultado de tais estimadores serem obtidos resolvendo o sistema de equações 14.20 (daí que um erro de estimação incorrido num deles tenha influência nos erros de estimação dos outros).

- (iii) O estimador de σ^2 definido pela expressão

$$\begin{aligned} S^2 &= \frac{1}{N - J - 1} \cdot \sum_n \hat{E}_n^2 \\ &= \frac{1}{N - J - 1} \cdot \sum_n [Y_n - A - B_1 \cdot (X_{1n} - \bar{X}_1) - \dots - B_J \cdot (X_{Jn} - \bar{X}_J)]^2 \end{aligned} \quad (14.21)$$

é não-enviesado. Note-se que o divisor deste estimador é igual ao número total de observações, N , menos o número de parâmetros estimados, $J + 1$.

Tabela 14.5
Observações
(x_{1n}, x_{2n}, y_n)
(Exemplo 14.7).

n	x_{1n}	x_{2n}	y_n
1	5.0	7.2	51.7
2	5.8	7.8	56.4
3	4.2	8.1	49.3
4	6.0	8.7	60.7
5	4.8	6.6	48.9
6	5.6	7.5	54.1
7	4.4	9.0	54.9
8	5.2	6.3	49.8
9	5.4	8.4	57.9
10	4.6	6.9	50.4

Exemplo 14.7

Considerem-se as observações das variáveis X_1 , X_2 e Y que constam da Tabela 14.5. Admitindo que o valor esperado de Y é uma função linear de X_1 e X_2 , estimem-se os parâmetros do modelo de regressão correspondente.

Neste caso,

$$N = 10$$

$$\bar{x}_1 = \frac{1}{10} \cdot (5.0 + 5.8 + \dots + 4.6) = 5.10$$

$$\bar{x}_2 = \frac{1}{10} \cdot (7.2 + 7.8 + \dots + 6.9) = 7.65$$

$$\bar{y} = \frac{1}{10} \cdot (51.7 + 56.4 + \dots + 50.4) = 53.41$$

$$s_{x_1 x_1} = \sum_n (x_{1n} - \bar{x}_1)^2 = (5.0 - 5.1)^2 + \dots + (4.6 - 5.1)^2 = 3.30$$

$$s_{x_2 x_2} = \sum_n (x_{2n} - \bar{x}_2)^2 = (7.2 - 7.65)^2 + \dots + (6.9 - 7.65)^2 = 7.42$$

$$\begin{aligned} s_{x_1 x_2} &= s_{x_2 x_1} = \sum_n (x_{1n} - \bar{x}_1) \cdot (x_{2n} - \bar{x}_2) \\ &= (5.0 - 5.1) \cdot (7.2 - 7.65) + \dots + (4.6 - 5.1) \cdot (6.9 - 7.65) = 0.45 \end{aligned}$$

$$\begin{aligned} s_{x_1 y} &= \sum_n (x_{1n} - \bar{x}_1) \cdot (y_n - \bar{y}) \\ &= (5.0 - 5.1) \cdot (51.7 - 53.41) + \dots + (4.6 - 5.1) \cdot (50.4 - 53.41) = 15.67 \end{aligned}$$

$$\begin{aligned} s_{x_2 y} &= \sum_n (x_{2n} - \bar{x}_2) \cdot (y_n - \bar{y}) \\ &= (7.2 - 7.65) \cdot (51.7 - 53.41) + \dots + (6.9 - 7.65) \cdot (50.4 - 53.41) = 24.16 \end{aligned}$$

$$s_{yy} = \sum_n (y_n - \bar{y})^2 = (51.7 - 53.41)^2 + \dots + (50.4 - 53.41)^2 = 147.19.$$

Tabela 14.6
Estimativas dos
valores esperados
de Y_n e dos erros e_n
(Exemplo 14.7)

n	y_n	$\hat{\mu}_{y_n}$	$\hat{e}_n = y_n - \hat{\mu}_{y_n}$
1	51.7	51.630	0.070
2	56.4	56.897	-0.497
3	49.3	50.850	-1.550
4	60.7	60.458	0.242
5	48.9	48.967	-0.067
6	54.1	55.132	-1.032
7	54.9	54.410	0.490
8	49.8	49.306	-0.006
9	57.9	56.956	0.944
10	50.4	48.996	1.404

As estimativas dos parâmetros de regressão podem então obter-se nos seguintes termos:

$$a = \hat{\alpha} = \bar{y} = 53.41$$

$$\begin{cases} 3.30 \cdot b_1 + 0.45 \cdot b_2 = 15.67 \\ 0.45 \cdot b_1 + 7.42 \cdot b_2 = 24.16 \end{cases} \Rightarrow \begin{cases} b_1 = \hat{\beta}_1 = 4.34 \\ b_2 = \hat{\beta}_2 = 2.99. \end{cases}$$

Na Tabela 14.6 apresentam-se os valores de $\hat{\mu}_{y_n}$ calculados a partir de

$$\hat{\mu}_{y_n} = a + b_1 \cdot (x_{1n} - \bar{x}_1) + b_2 \cdot (x_{2n} - \bar{x}_2)$$

e ainda os valores de $\hat{e}_n = y_n - \hat{\mu}_{y_n}$.

Estimam-se em seguida a variância dos erros, σ^2 , e a matriz de variância-covariância dos estimadores B_1 e B_2 .

$$s^2 = \hat{\sigma}^2 = \frac{1}{N - J - 1} \cdot \sum_n \hat{e}_n^2 = \frac{1}{10 - 2 - 1} \cdot [0.07^2 + \dots + 1.404^2] = 0.983.$$

$$\begin{aligned} \begin{bmatrix} \text{Vâr}(B_1) & \text{Côv}(B_1, B_2) \\ \text{Côv}(B_2, B_1) & \text{Vâr}(B_2) \end{bmatrix} &= \hat{\sigma}^2 \cdot \begin{bmatrix} s_{x_1 x_1} & s_{x_1 x_2} \\ s_{x_2 x_1} & s_{x_2 x_2} \end{bmatrix}^{-1} \\ &= 0.983 \cdot \begin{bmatrix} 3.30 & 0.45 \\ 0.45 & 7.42 \end{bmatrix}^{-1} = \frac{0.983}{3.30 \cdot 7.42 - (0.45)^2} \cdot \begin{bmatrix} 7.42 & -0.45 \\ -0.45 & 3.30 \end{bmatrix}^T \\ &= 0.0405 \cdot \begin{bmatrix} 7.42 & -0.45 \\ -0.45 & 3.30 \end{bmatrix} = \begin{bmatrix} 0.300 & -0.018 \\ -0.018 & 0.133 \end{bmatrix}, \end{aligned}$$

ou seja,

$$\text{Vâr}(B_1) = 0.300 \quad (\Rightarrow \hat{\sigma}_{B_1} = 0.548)$$

$$\text{Vâr}(B_2) = 0.133 \quad (\Rightarrow \hat{\sigma}_{B_2} = 0.365)$$

$$\text{Côv}(B_1, B_2) = -0.018 \quad (\Rightarrow \hat{\rho}_{B_1, B_2} = -\frac{0.018}{0.548 \cdot 0.365} = -0.090).$$

14.3.3 INTERVALOS DE CONFIANÇA E TESTES RELATIVOS AOS PARÂMETROS DE REGRESSÃO

Se, às hipóteses consideradas na secção anterior, se acrescentar a de que os erros são normalmente distribuídos, então é possível especificar as distribuições dos estimadores A e B_j ($j = 1, \dots, J$):

$$\begin{aligned} A &\sim N(\alpha, \sigma^2/N) \\ B_1 &\sim N[\beta_1, \text{Var}(B_1)] \\ &\dots\dots\dots \\ B_J &\sim N[\beta_J, \text{Var}(B_J)] \end{aligned} \quad (14.22)$$

onde $\text{Var}(B_1), \dots, \text{Var}(B_J)$ são definidas a partir da matriz de variância-covariância apresentada na secção anterior. Por outro lado, pode demonstrar-se que

$$(N - J - 1) \cdot \frac{S^2}{\sigma^2} \quad (14.23)$$

segue uma distribuição χ^2_{N-J-1} .

Nestas condições, verificam-se as distribuições seguintes

$$\begin{aligned} \frac{A - \alpha}{S / \sqrt{N}} &\sim t_{N-J-1} \\ \frac{B_1 - \beta_1}{\sqrt{\text{Var}(B_1)}} &\sim t_{N-J-1} \\ \frac{B_J - \beta_J}{\sqrt{\text{Var}(B_J)}} &\sim t_{N-J-1} \end{aligned} \quad (14.24)$$

onde as estimativas de $\text{Var}(B_1), \dots, \text{Var}(B_J)$ são obtidas, como no Exemplo 14.7, substituindo σ^2 por s^2 nas respectivas expressões.

A partir destas expressões é possível definir intervalos de confiança e testes de hipóteses envolvendo os parâmetros de regressão α (ou α') e β_j ($j = 1, \dots, J$).

14.3.3.1 INTERVALOS DE CONFIANÇA

Os procedimentos envolvidos na definição de intervalos de confiança para os parâmetros do modelo de regressão linear múltipla são semelhantes aos considerados na Secção 14.2.3.1, a propósito dos parâmetros do modelo linear simples.

Para o parâmetro α , a definição do intervalo de confiança bilateral a $(1 - \gamma) \cdot 100\%$ decorre da primeira das expressões 14.24. Os limites deste intervalo são dados pela expressão seguinte:

$$A \pm t_{N-J-1}(\gamma/2) \cdot S \cdot \sqrt{1/N} \quad (14.25)$$

Para os parâmetros β_j ($j = 1, \dots, J$), os intervalos de confiança bilaterais a $(1 - \gamma) \cdot 100\%$ derivam das restantes expressões 14.24, vindo os seus limites dados por

$$B_j \pm t_{N-J-1}(\gamma/2) \cdot \sqrt{\text{Var}(B_j)} \quad (14.26)$$

Exemplo 14.8

Voltando ao Exemplo 14.7, calcule-se o intervalo de confiança a 95% para β_1 . Tal intervalo é definido do seguinte modo:

$$b_1 = 4.341$$

$$\text{Var}(B_1) = 0.300, \text{ ou seja } \sqrt{\text{Var}(B_1)} = \hat{\sigma}_{B_1} = 0.548;$$

$$t_{N-J-1}(\gamma/2) = t_7(0.025) = 2.365 \text{ (ver Tabela 5 do Anexo «Tabelas»)}.$$

Substituindo estes valores em 14.26, resulta:

$$4.341 \pm 2.365 \cdot 0.548,$$

pelo que o intervalo pretendido é

$$[3.045, 5.637].$$

Registe-se que, embora os intervalos assim definidos estejam correctamente especificados quando considerados individualmente, o nível de confiança para o conjunto dos intervalos definidos para α e β_j ($j = 1, \dots, J$) é, de facto, diferente do considerado (ver Secção 13.2.1).

14.3.3.2 TESTES DE HIPÓTESES

Os testes de hipóteses relativas aos parâmetros α (ou α') e β podem ser realizados recorrendo aos intervalos de confiança. Alternativamente, podem ser conduzidos recorrendo ao procedimento clássico.

Para α , a estrutura do teste, que decorre da primeira das expressões 14.24, é a seguinte:

$$H_0: \alpha = \alpha_0$$

$$H_1: \alpha \neq \alpha_0, \alpha > \alpha_0 \text{ ou } \alpha < \alpha_0$$

$$ET = \frac{A - \alpha_0}{S / \sqrt{N}}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim t_{N-J-1}.$$

Para α' , o teste tem a seguinte estrutura:

$$H_0: \alpha' = \alpha'_0$$

$$H_1: \alpha' \neq \alpha'_0, \alpha' > \alpha'_0 \text{ ou } \alpha' < \alpha'_0$$

$$ET = \frac{A' - \alpha'_0}{\sqrt{\text{Var}(A')}}$$

onde

$$A' = A - (\bar{X}_1 \cdot B_1 + \dots + \bar{X}_J \cdot B_J)$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim t_{N-J-1}.$$

A variância de A' , cujo estimador figura no denominador da estatística de teste, pode ser calculada, começando por considerar o caso em que $J = 2$. Dado que $\bar{X}_1$ e $\bar{X}_2$ são constantes e que $\text{Cov}(A, B_j) = 0$ ($j = 1, \dots, J$) vem

$$\begin{aligned} \text{Var}(A') &= \text{Var}[A - (\bar{X}_1 \cdot B_1 + \bar{X}_2 \cdot B_2)] \\ &= \text{Var}(A) + \text{Var}(\bar{X}_1 \cdot B_1 + \bar{X}_2 \cdot B_2). \end{aligned}$$

A segunda parcela pode ser desenvolvida, vindo

$$\text{Var}(\bar{X}_1 \cdot B_1 + \bar{X}_2 \cdot B_2) = \bar{X}_1^2 \cdot \text{Var}(B_1) + \bar{X}_2^2 \cdot \text{Var}(B_2) + 2 \cdot \bar{X}_1 \cdot \bar{X}_2 \cdot \text{Cov}(B_1, B_2).$$

O segundo membro desta expressão pode ser apresentado na forma matricial, vindo:

$$[\bar{X}_1, \bar{X}_2] \cdot \begin{bmatrix} \text{Var}(B_1) & \text{Cov}(B_2, B_1) \\ \text{Cov}(B_2, B_1) & \text{Var}(B_2) \end{bmatrix} \cdot \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \end{bmatrix} = \bar{X}^T \cdot [V(B)] \cdot \bar{X},$$

onde

$\bar{X}$: vector das médias das variáveis independentes

$\bar{X}^T$: $\bar{X}$ transposto

$[V(B)]$: matriz de variância-covariância dos estimadores B_1 e B_2 .

Seria fácil verificar que o resultado obtido para $J = 2$ é generalizável a qualquer $J > 2$, vindo então

$$\text{Var}(A') = \text{Var}(A) + \bar{X}^T \cdot [V(B)] \cdot \bar{X}.$$

Exemplo 14.9

Utilizando os dados do Exemplo 14.7, teste-se, ao nível de significância de 5%, se a ordenada na origem é igual ou diferente de zero.

$$H_0: \alpha' = 0$$

$$H_1: \alpha' \neq 0$$

$$ET = \frac{A'}{\sqrt{\hat{\text{Var}}(A')}}.$$

Cálculo do valor da estatística de teste:

$$\alpha' = a - \bar{x}_1 \cdot b_1 - \bar{x}_2 \cdot b_2 = 53.41 - 5.10 \cdot 4.341 - 7.65 \cdot 2.991 = 8.389$$

$$\begin{aligned} \text{Var}(A') &= \text{Var}(A) + \text{Var}(\bar{X}_1 \cdot B_1 + \bar{X}_2 \cdot B_2) = \\ &= \text{Var}(A) + \bar{X}_1^2 \cdot \text{Var}(B_1) + \bar{X}_2^2 \cdot \text{Var}(B_2) + 2 \cdot \bar{X}_1 \cdot \bar{X}_2 \cdot \text{Cov}(B_1, B_2) \\ &= 0.0983 + 5.10^2 \cdot 0.300 + 7.65^2 \cdot 0.133 + 2 \cdot 5.10 \cdot (-0.018) \\ &= 14.28 \end{aligned}$$

$$ET = \frac{8.389}{\sqrt{14.28}} = 2.22.$$

Como $ET = 2.22 < t_7(0.025) = 2.365$, a hipótese nula $H_0: \alpha' = 0$ não é rejeitada ao nível de significância de 5% (com um valor de prova de aproximadamente 6.2%).

Relativamente aos parâmetros β_j ($j = 1, \dots, J$), comece-se por testar a hipótese de que todos estes parâmetros são nulos contra a hipótese de que pelo menos um deles é diferente de zero.

Para realizar este teste pode recorrer-se à técnica de análise de variância, utilizando um procedimento análogo ao referido na Secção 14.2.3.2 (ver expressão 14.13), ou seja, decompondo a variação total (VT) nas componentes variação devida à regressão (VDR) e variação residual (VR):

$$\begin{aligned} \sum_n (Y_n - \bar{Y})^2 &= \sum_n \{[A + B_1 \cdot (X_{1n} - \bar{X}_1) + \dots + B_J \cdot (X_{Jn} - \bar{X}_J)] - \bar{Y}\}^2 + \\ &\quad \underbrace{\sum_n \{B_1 \cdot S_{X_1Y} + \dots + B_J \cdot S_{X_JY}\}}_{VDR} + \underbrace{\sum_n \{Y_n - [A + B_1 \cdot (X_{1n} - \bar{X}_1) + \dots + B_J \cdot (X_{Jn} - \bar{X}_J)]\}^2}_{VR = S_{YY} - (B_1 \cdot S_{X_1Y} + \dots + B_J \cdot S_{X_JY})}. \end{aligned} \quad (14.30)$$

Na Tabela 14.7 (tabela ANOVA referente à regressão linear múltipla) adopta-se esta decomposição.

Dela decorre a estrutura do teste ANOVA:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_J = 0$$

$$H_1: \text{Algum } \beta_j \neq 0 \quad (j = 1, \dots, J)$$

$$ET = \frac{DQMDR}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{J, N-J-1}.$$

Exemplo 14.10

Utilizando os dados do Exemplo 14.7, testem-se as hipóteses

$$H_0: \beta_1 = \beta_2 = \dots = \beta_J = 0$$

$$H_1: \text{algum } \beta_j \neq 0.$$

A tabela ANOVA correspondente apresenta-se na Tabela 14.8. Como

$$ET = \frac{70.15}{0.983} = 71.34 > F_{2,7}(\alpha = 0.05) = 4.74,$$

H_0 é rejeitada ao nível de significância de 5% (com um valor de prova quase nulo).

Tabela 14.8
Tabela ANOVA
referente aos dados
do Exemplo 14.7.

Fontes	Variações	GL	DQM
DR	140.3	2	70.15
R	6.9	7	0.983
T	147.2	9	

Quando, no contexto deste teste, a hipótese nula é rejeitada (tal como sucedeu no exemplo que acabou de ser apresentado), conclui-se que algum dos parâmetros β_j é diferente de zero. No entanto, fica-se sem a indicação de quais os parâmetros que estão nesta situação. Uma via para resolver esta questão consiste na realização de testes individuais aos parâmetros β_j .

Tabela 14.7. Tabela ANOVA para o modelo de regressão linear múltipla.

Fontes de variação	Variações (Somos de desvios quadráticos)	Graus de liberdade (Números de termos independentes)	Desvios quadráticos médios	Valores esperados
Devida à regressão (DR)	$VDR = B_1 \cdot S_{x_1r} + \dots + B_J \cdot S_{x_Jr}$ (Variação «explicada» pela regressão)	$GL_1 = J$	$DQMDR = VDR / GL_1$	$E[DQMDR] = \sigma^2 + [f(B_1, \dots, B_J)]^2$
Residual (R)	$VR = S_{yy} - VDR$ (Variação residual «não explicada»)	$GL_2 = N - J - 1$	$DQMR = VR / GL_2$	$E[DQMR] = \sigma^2$
Total (T)	$VT = S_{yy}$ (Variação total)	$GL = GL_1 + GL_2 = N - 1$		

Das expressões 14.24 relativas aos estimadores B_j ($j = 1, \dots, J$) (ver Secção 14.3.3) decorre a estrutura de tais testes individuais:

$$H_0: \beta_j = 0$$

$$H_1: \beta_j \neq 0, \beta_j > 0 \text{ ou } \beta_j < 0$$

$$ET = \frac{B_j}{\sqrt{\text{Var}(B_j)}}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim t_{N-J-1}$$

Exemplo 14.11

Utilizando ainda os dados do Exemplo 14.7, testem-se, ao nível de significância de 5%, as hipóteses

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

$$H_0: \beta_2 = 0$$

$$H_1: \beta_2 \neq 0$$

Dado que (ver cálculos do Exemplo 14.7) $b_1 = 4.34$, $\hat{\sigma}_{b_1} = 0.548$, $b_2 = 2.99$ e $\hat{\sigma}_{b_2} = 0.365$, resulta:

$$ET = \frac{b_1}{\sqrt{\text{Var}(B_1)}} = \frac{4.34}{0.548} = 7.92 > t_7(0.025) = 2.365$$

$\Rightarrow H_0: \beta_1 = 0$ é rejeitada ao nível de significância de 5% (com um valor de prova quase nulo) e

$$ET = \frac{b_2}{\sqrt{\text{Var}(B_2)}} = \frac{2.99}{0.365} = 8.19 > t_7(0.025) = 2.365$$

$\Rightarrow H_0: \beta_2 = 0$ também é rejeitada ao nível de significância de 5% (igualmente com um valor de prova praticamente nulo).

Note-se que, frequentemente, a partir do conhecimento das variáveis X_j e Y é possível definir, *a priori*, o sinal dos parâmetros β_j (no caso de estes não serem nulos). Nesta situação devem adoptar-se testes unilaterais.

O problema que surge na realização de testes seguindo esta via reside no facto de que, embora o nível de significância de cada teste esteja correctamente avaliado se ele for efectuado isoladamente, quando os testes são realizados em conjunto o nível de significância global é diferente daquele que foi especificado. Tal como se verá na Secção seguinte, a propósito do problema da selecção de regressores, esta dificuldade pode ser contornada recorrendo, de novo, à técnica de análise de variância.

14.3.4 SELECÇÃO DE REGRESSORES

Na análise de modelos de regressão linear múltipla, admitiu-se, até agora, que as variáveis independentes (também designadas por **regressores**) eram especificadas à partida. No entanto, na maioria das situações práticas, mesmo com um adequado conhecimento teórico sobre a natureza das relações causa-efeito entre diferentes variáveis em jogo, não se consegue especificar à partida, com segurança, qual o conjunto ideal de regressores que devem ser incluídos no modelo.

Muito mais realista é o cenário no qual existe uma multiplicidade de regressores potencialmente úteis na explicação do comportamento da variável dependente, havendo que seleccionar de entre eles quais os que são efectivamente merecedores de figurar no modelo. Nas secções seguintes discutir-se-ão diferentes métodos de selecção de regressores.

■ 14.3.4.1 MÉTODO EXAUSTIVO

O método exaustivo, conceptualmente muito simples, consiste em:

- Construir os modelos de regressão que combinem de todas as maneiras possíveis os regressores potenciais.
- Ordenar os modelos de regressão de acordo com um critério de qualidade (por exemplo, um critério de minimização do desvio quadrático médio residual, $DQMR = \hat{\sigma}^2$).
- Avaliar em detalhe um número restrito de modelos considerados melhores, de acordo com o critério fixado em (ii).

Relativamente a este método, é oportuno tecer dois comentários. O primeiro diz respeito ao facto de, apesar de se definir um critério de qualidade (no ponto (ii)), não se seleccionar necessariamente o modelo que melhor satisfaz esse critério (de outro modo, o ponto (iii) resumir-se-ia à selecção desse modelo). A razão de ser deste procedimento está associada à incapacidade de se definir um critério único que, em todas as circunstâncias, permita comparar com objectividade a qualidade de modelos de regressão alternativos.

O segundo comentário prende-se com as limitações do método que derivam do esforço associado à construção de todos os modelos de regressão possíveis. Se o número de regressores potenciais for J , o número de modelos alternativos que há que construir é $2^J - 1$. Por exemplo, para $J = 10$, o esforço computacional envolvido já será significativo, pois o número de modelos alternativos a construir é 1 023.

Reconhecida esta limitação, foram propostos métodos alternativos que, de alguma forma, constituem uma aproximação do método exaustivo. Na secção seguinte, apresentar-se-á a base conceptual de um desses métodos.

■ 14.3.4.2 MÉTODO PROGRESSIVO

O método progressivo (ou *forward*) envolve os seguintes passos:

- Ajustar tantos modelos de regressão linear simples quantos os regressores potenciais. De entre os regressores que, isoladamente, explicam uma proporção significativa da variação total da variável dependente, incluir no modelo aquele que explica a maior proporção.

Se nenhum dos regressores explicar uma proporção significativa da variação total, o método termina sem que se estabeleça qualquer modelo de regressão.

- Construir modelos de regressão linear dupla que associem, como variáveis independentes, o regressor seleccionado no passo (i) e cada um dos regressores potenciais ainda não incluídos. Registe-se que, neste processo, está envolvida a reestimação de parâmetros já calculados no passo anterior. De entre os regressores que, entrando no modelo, explicam uma proporção adicional significativa da variação total (adicional em relação àquela que era explicada no passo anterior), seleccionar aquele que explica a maior proporção e incluí-lo no modelo.

Se nenhum dos regressores potenciais ainda não incluídos no modelo, ao entrar nele, explicar uma proporção adicional significativa da variação total, o método termina. Neste caso, o modelo proposto é o modelo de regressão linear simples seleccionado no passo anterior.

- Prosseguir a tentativa de construção de modelos de ordem superior adoptando um procedimento idêntico ao descrito no passo anterior.

O método terminará quando

- nenhum dos regressores potenciais ainda não incluídos no modelo, ao entrar nele, explicar uma proporção adicional significativa da variação total, ou
- todos os regressores potenciais forem incluídos no modelo.

Exemplo 14.12

Considere-se o problema da selecção de regressores, admitindo que se dispõe de 20 observações de uma variável dependente (Y) e de três variáveis candidatas a figurar como regressores num modelo de regressão múltipla (X_1 , X_2 e X_3).

Passo (i)

Constroem-se os três modelos de regressão linear simples aqui denotados por $Y = Y(X_1)$ (Y função linear de X_1), $Y = Y(X_2)$ e $Y = Y(X_3)$.

Admita-se que se obtêm, para estes modelos, as tabelas ANOVA que se apresentam na Tabela 14.9.

O regressor que explica a maior proporção da variação total é X_2 . O teste ANOVA permite verificar, ao nível de significância de 5%, que, para o modelo $Y = Y(X_2)$, tal proporção é significativa (ou seja, permite rejeitar $H_0: \beta_2 = 0$):

$$\left[ET = \frac{110}{90/18} = 22.0 > F_{1,18}(0.05) = 4.41 \right] \Rightarrow H_0 \text{ rejeitada.}$$

Deste resultado decorre a inclusão da variável X_2 no modelo.

Passo (ii)

Constroem-se os dois modelos de regressão linear dupla $Y = Y(X_2, X_1)$ e $Y = Y(X_2, X_3)$.

Admita-se que se obtêm, para estes modelos, as tabelas ANOVA que se apresentam na Tabela 14.10.

Tabela 14.9
Tabelas ANOVA para os modelos de regressão linear simples (Exemplo 14.12).

Fontes			
Modelo $Y = Y(X_1)$:	Variações	GL	DQM
DR (X_1)	60	1	60
R	140	18	140 / 18
T	200	19	
Modelo $Y = Y(X_2)$:			
DR (X_2)	110	1	110
R	90	18	90 / 18
T	200	19	
Modelo $Y = Y(X_3)$:			
DR (X_3)	20	1	20
R	180	18	180 / 18
T	200	19	

Tabela 14.10
Tabelas ANOVA para os modelos de regressão linear dupla (Exemplo 14.12).

Fontes			
Modelo $Y = Y(X_2, X_1)$:	Variações	GL	DQM
DR (X_2, X_1)	120	2	120 / 2
R	80	17	80 / 17
T	200	19	
Modelo $Y = Y(X_2, X_3)$:			
DR (X_2, X_3)	135	2	135 / 2
R	65	17	65 / 17
T	200	19	

O regressor que explica uma proporção adicional maior da variação total é X_3 , pois a sua entrada no modelo faz subir a variação explicada pela regressão de 110 (que, como se pode ver na Tabela 14.9, é o valor de VDR quando só figura X_2 no modelo) para 135 (ver Tabela 14.10), enquanto que a subida associada a X_1 é apenas de 110 para 120.

Para testar se o contributo adicional de X_3 para a explicação da variação de Y é significativo, comece-se por alterar a tabela ANOVA correspondente ao modelo $Y = Y(X_2, X_3)$, como se indica na Tabela 14.11. A alteração tem a ver basicamente com a decomposição do termo $VDR(X_2, X_3)$ em duas parcelas:

$$VDR(X_2, X_3) = VDR(X_2) + VDR(X_3|X_2)$$

onde $VDR(X_2)$ representa a variação devida à regressão só com X_2 e $VDR(X_3|X_2)$ representa a variação devida à regressão atribuível à entrada de X_3 (dada a presença prévia de X_2).

O teste ANOVA a realizar tem a seguinte estrutura:

$$H_0: \beta_3 = 0$$

(note-se que β_3 representa o coeficiente de X_3 no modelo $Y = Y(X_2, X_3)$)

$$H_1: \beta_3 \neq 0$$

$$ET = \frac{DQMDR(X_3|X_2)}{DQMR}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim F_{1, n-3}$$

Para o exemplo que vem sendo analisado, o cálculo da estatística de teste conduz, ao nível de significância de 5%, à rejeição da hipótese nula, pois

$$ET = \frac{DQMDR(X_3|X_2)}{DQMR} = \frac{25}{65/17} = 6.54 > F_{1,17}(0.05) = 4.45.$$

Nestas condições, é incluído no modelo o regressor X_3 , que assim se junta ao regressor X_2 .

Passo (iii)

Constrói-se o modelo de regressão linear tripla $Y = Y(X_2, X_3, X_1)$.

Admita-se que se obtém, para este modelo, a tabela ANOVA que se apresenta na Tabela 14.12.

Tabela 14.11
Tabela ANOVA para o modelo $Y = Y(X_2, X_3)$, com identificação do contributo marginal do regressor que entra no modelo (X_3) (Exemplo 14.12).

Fontes	Variações	GL	DQM
$DR(X_2, X_3)$	135	2	135 / 2
$DR(X_2)$	(110)	(1)	
$DR(X_3 X_2)$	(25)	(1)	25
R	65	17	65 / 17
T	200	19	

Tabela 14.12
Tabela ANOVA para o modelo $Y = Y(X_2, X_3, X_1)$, com identificação do contributo marginal do regressor que entra no modelo (X_1) (Exemplo 14.12).

Fontes	Variações	GL	DQM
$DR(X_2, X_3, X_1)$	140	3	140 / 3
$DR(X_2, X_3)$	(135)	(2)	
$DR(X_1 X_2, X_3)$	(5)	(1)	5
R	60	16	60 / 16
T	200	19	

O teste ANOVA permite verificar, ao nível de significância de 5%, que, para o modelo $Y = Y(X_2, X_3, X_1)$, a proporção adicional da variação total que é explicada por X_1 não é significativa (ou seja, não permite rejeitar $H_0: \beta_1 = 0$):

$$ET = \frac{DQMDR(X_1|X_2, X_3)}{DQMR} = \frac{5}{60/16} = 1.33 < F_{1,16}(0.05) = 4.50 \Rightarrow H_0 \text{ não rejeitada.}$$

Deste resultado decorre a não-inclusão do regressor X_1 no modelo, terminando a aplicação do método com a especificação do modelo $Y = Y(X_2, X_3)$.

Em relação ao método progressivo, cuja base conceptual acaba de ser apresentada, devem ser tecidas algumas observações.

- Este método envolve um procedimento expedito que se destina a substituir o método exaustivo. Para o Exemplo 14.12 as combinações possíveis de regressores são sete:

$$(X_1), (X_2), (X_3), (X_1, X_2), (X_2, X_3), (X_1, X_3), (X_1, X_2, X_3).$$

Destas combinações houve apenas uma que não foi explorada na aplicação do método progressivo: (X_1, X_3) . Em situações como a considerada, envolvendo um número reduzido de regressores potenciais, a vantagem do método progressivo é questionável. Ela só se faz sentir quando o número de regressores potenciais for significativo.

- Tratando-se de um método expedito, no qual ficam por explorar algumas combinações de regressores potenciais, o método progressivo não garante que, no final, o grupo de regressores seleccionado seja efectivamente o melhor. No exemplo seguinte mostra-se porquê.

Exemplo 14.13

Numa determinada instalação fabril que envolve um processo químico, pretende-se estabelecer a relação entre o tempo de reacção (X_1), a temperatura (X_2) e o rendimento da instalação (Y). Para esse efeito, recolheram-se oito observações, a partir das quais se obtiveram os seguintes resultados:

$$\begin{aligned} s_{X_1 X_1} &= 30 & s_{X_1 X_2} &= 21 & s_{X_1 Y} &= 6 \\ & & s_{X_2 X_2} &= 20 & s_{X_2 Y} &= -17 \\ & & & & s_{YY} &= 94. \end{aligned}$$

Recorrendo ao método progressivo, procede-se seguidamente à selecção dos regressores.

Começam por construir-se os dois modelos de regressão linear simples $Y = Y(X_1)$ e $Y = Y(X_2)$, obtendo-se as tabelas ANOVA que se apresentam na Tabela 14.13.

Tabela 14.13
Tabelas ANOVA para os modelos de regressão linear simples (Exemplo 14.13).

Fontes	Variações	GL	DQM
Modelo $Y = Y(X_1)$:			
$DR(X_1)$	1.2	1	1.2
R	92.8	6	92.8 / 6
T	94.0	7	
Modelo $Y = Y(X_2)$:			
$DR(X_2)$	14.4	1	14.4
R	79.6	6	79.6 / 6
T	94.0	7	

O regressor que explica a maior proporção da variação total é X_2 . O teste ANOVA permite verificar, ao nível de significância de 5%, que, para o modelo $Y = Y(X_2)$, tal proporção não é significativa (ou seja, não permite rejeitar $H_0: \beta_2 = 0$):

$$\left[ET = \frac{14.4}{79.6/6} = 1.085 < F_{1,6}(0.05) = 5.99 \right] \Rightarrow H_0 \text{ não rejeitada.}$$

De acordo com as regras do método progressivo, nem a variável X_2 , nem, por maioria de razão, a variável X_1 , seriam seleccionadas, terminando o procedimento sem se ajustar qualquer modelo de regressão.

Se fosse aplicado o método exaustivo, faltaria considerar o modelo incluindo, simultaneamente, os dois regressores.

Na Tabela 14.14 apresenta-se a tabela ANOVA referente a este modelo.

O teste ANOVA permite verificar, ao nível de significância de 5%, que, para o modelo $Y = Y(X_1, X_2)$, a proporção da variação total que é explicada pela regressão é significativa (ou seja, permite rejeitar $H_0: \beta_1 = \beta_2 = 0$):

$$\left[ET = \frac{86.0/2}{8.0/5} = 26.88 > F_{2,5}(0.05) = 5.79 \right] \Rightarrow H_0 \text{ rejeitada.}$$

A aplicação do método exaustivo conduz assim ao ajustamento de um modelo de regressão linear dupla.

Tabela 14.14
Tabela ANOVA
para o modelo
de regressão
linear dupla
(Exemplo 14.13).

Fontes			
Modelo $Y = Y(X_1, X_2)$:	Variações	GL	DQM
DR (X_1, X_2)	86.0	2	86.0/2
R	8.0	5	8.0/5
T	94.0	7	

Este exemplo mostra como a associação de certos regressores pode ter um efeito muito significativo na explicação da variação total da variável dependente, mesmo quando cada um deles, tomado isoladamente, quase nada explica dessa variação.

Na Figura 14.8 apresenta-se uma situação em que nem a variável X_1 nem a variável X_2 , tomadas uma a uma, explicam uma proporção significativa da variação de Y .

No entanto, tal como se ilustra na Figura 14.9, Y relaciona-se de uma forma perfeitamente linear com as duas variáveis X_1 e X_2 tomadas em conjunto. Isto é, todas as observações de Y (representadas a branco na Figura 14.9) pertencem a um plano do tipo

$$Y = \alpha + \beta_1 \cdot (X_1 - \bar{X}_1) + \beta_2 \cdot (X_2 - \bar{X}_2).$$

Figura 14.8
Relações entre Y e X_1
e entre Y e X_2 .





Figura 14.9
Relação linear
perfeita entre
o par de variáveis
independentes
(X_1, X_2) e a variável
dependente Y .



■ 14.3.4.3 MÉTODO REGRESSIVO

Em alternativa ao método progressivo (ou *forward*) pode recorrer-se a um outro método que, tendo uma base conceptual semelhante, assenta num procedimento de alguma forma simétrico. Trata-se do método regressivo (ou *backward*), cuja ideia base é a seguinte:

- À partida, incluem-se no modelo todos os regressores potenciais.
- Posteriormente, vão-se retirando do modelo, um a um, regressores cuja presença não contribua para explicar uma proporção significativa da variação total da variável dependente (a avaliação da contribuição individual de cada regressor faz-se exactamente como no método progressivo, tratando cada regressor como se ele tivesse sido o último a entrar no modelo).
- Em cada momento, de todos os regressores cuja presença não contribua para explicar uma proporção significativa da variação total, retira-se aquele que menos contribua para a explicação desta variação.

■ 14.3.4.4 MÉTODOS DE REGRESSÃO PASSO A PASSO

Nas versões apresentadas dos métodos progressivo e regressivo, os mecanismos de inclusão ou exclusão de regressores têm um carácter definitivo. Na verdade, de acordo com os procedimentos descritos,

- um regressor que, no âmbito da aplicação do método progressivo, seja incluído no modelo, nunca mais o abandona e, simetricamente,
- um regressor que, no âmbito da aplicação do método regressivo, seja excluído do modelo, nunca mais volta a ser nele incorporado.

Existem outras versões dos métodos progressivo e regressivo — frequentemente designadas por métodos de **regressão passo a passo** (ou *stepwise regression*), nas quais, em cada passo, os regressores que tenham sido incluídos no modelo ou dele excluídos em passos anteriores são reexaminados. O objectivo do reexame é fácil de compreender:

- no âmbito da aplicação do método progressivo, pode suceder que um regressor que tenha sido incorporado no modelo num passo inicial se torne mais tarde supérfluo, como consequência da entrada de outros regressores, ou, simetricamente,
- no âmbito da aplicação do método regressivo, pode suceder que um regressor que tenha sido excluído do modelo num passo inicial se torne mais tarde útil, como consequência da saída de regressores que inicialmente se encontravam no modelo.

A adopção deste tipo de métodos conduz a um enviesamento (que na terminologia anglo-saxónica é apelidado de *stepwise bias*). De facto, como as variáveis são seleccionadas por forma a maximizar a proporção da variação total explicada pela regressão (ou seja, a maximizar o coeficiente de determinação, R^2), é natural que, no final, se sobrestime a capacidade preditiva dos regressores.

O maior perigo associado aos métodos automáticos de selecção de regressores consiste na sua utilização acrítica. É fundamental não esquecer que, ao construir um modelo de regressão, a inclusão de regressores tem de fazer sentido. Isto é, entre os regressores e a variável dependente têm de existir relações plausíveis de causa-efeito. Ora não há nenhum computador que consiga resolver esta questão e, por isso, um modelo sugerido por um método automático nada tem de definitivo, podendo o analista alterá-lo, se ajuizar que assim deve proceder.

14.3.5 COLINEARIDADE

O termo **colinearidade** utiliza-se para designar a existência de elevada correlação entre dois ou mais regressores.

Considerem-se dois quaisquer regressores potenciais, X_1 e X_2 , entre os quais se verifica uma elevada correlação. Neste caso,

- a proporção da variação total da variável dependente que é explicada por X_1 é semelhante àquela que é explicada por X_2 , e
- quando um dos regressores se encontra já no modelo de regressão, a inclusão do outro não acarreta, em geral, uma explicação adicional significativa da variação total da variável dependente.

Nestas condições, dado que a recolha, verificação e codificação dos dados relativos a uma qualquer variável consome tempo e recursos, ao definir o conjunto das variáveis candidatas a regressores não se deve investir na adopção de variáveis altamente correlacionadas.

A colinearidade acarreta dois tipos de problemas. O primeiro prende-se com a fase de estimação dos modelos de regressão e pode ser ilustrado considerando um modelo com duas variáveis independentes:

$$Y_n = \alpha + \beta_1 \cdot (X_{1n} - \bar{X}_1) + \beta_2 \cdot (X_{2n} - \bar{X}_2) + E_n. \quad (14.31)$$

Como se sabe (ver expressão 14.20), as estimativas $b_1 = \hat{\beta}_1$ e $b_2 = \hat{\beta}_2$ são obtidas resolvendo o sistema de equações

$$\begin{cases} b_1 \cdot s_{X_1 X_1} + b_2 \cdot s_{X_1 X_2} = s_{X_1 Y} \\ b_1 \cdot s_{X_2 X_1} + b_2 \cdot s_{X_2 X_2} = s_{X_2 Y} \end{cases}$$

No caso de X_1 e X_2 serem perfeitamente correlacionados, isto é, no caso de ser

$$X_2 = \gamma + \delta \cdot X_1,$$

é imediato verificar que as duas equações anteriores expressam a mesma relação e, portanto, o sistema é indeterminado. Nesta situação, resolvendo, por exemplo, a primeira equação, quaisquer valores de b_1 e b_2 que satisfaçam


$$b_2 = \frac{s_{X_1 Y}}{s_{X_1 X_2}} - b_1 \cdot \frac{s_{X_1 X_1}}{s_{X_1 X_2}}$$

são soluções do sistema.

Quando as variáveis X_1 e X_2 são altamente (mas não perfeitamente) correlacionadas, o sistema de equações acima representado admite uma solução única. No entanto, a sua resolução torna-se difícil devido à ocorrência de problemas de instabilidade numérica e conduz a estimadores de elevada variância. Dadas estas dificuldades, as aplicações informáticas dos métodos de selecção de regressores impedem que entre no modelo um regressor potencial que seja altamente correlacionado com outro já nele incluído.

O segundo tipo de problemas associados à colinearidade surge, potencialmente, na fase de previsão. Para exemplificar a sua natureza, considere-se, de novo, o modelo com dois regressores definido na expressão 14.31. Admita-se que o modelo é estimado com base num conjunto de observações que, no que respeita às variáveis X_1 e X_2 , se dispõem como se representa na Figura 14.10. Dado que tais observações são encaradas como constantes predeterminadas (não sendo necessariamente representativas da população conjunta das variáveis X_1 e X_2), pode haver interesse ou necessidade de prever o valor de Y num ponto do plano (X_1, X_2) que esteja completamente fora da região coberta pelas observações. Esta situação é ilustrada na Figura 14.10.

Figura 14.10
Dificuldades potenciais de previsão com origem na colinearidade entre X_1 e X_2 .



Uma vez que X_1 e X_2 são fortemente correlacionadas e, consequentemente, as estimativas obtidas para β_1 e β_2 são potencialmente de má qualidade, é perigoso efectuar extrapolações deste tipo. O que se deveria fazer neste caso seria tentar obter mais observações, de modo a alargar a região do plano (X_1, X_2) por elas coberto.

Se, alternativamente, as observações de X_1 e X_2 forem representativas da população conjunta destas variáveis, então não faz sentido efectuar extrapolações como a que se representa na figura anterior, uma vez que se admite que tal ponto nunca ocorreria. Neste caso, as interpolações realizadas na região do plano (X_1, X_2) coberta pelas observações não são afectadas de forma sensível pela colinearidade.

14.3.6 PREVISÕES EFECTUADAS COM BASE EM MODELOS DE REGRESSÃO LINEAR MÚLTIPLA

Para cada conjunto de novos valores das variáveis independentes X_j ($j = 1, \dots, J$), a melhor previsão de Y obtém-se através de

$$\hat{Y} = \hat{E}(Y) = A + B_1 \cdot (X_1 - \bar{X}_1) + \dots + B_J \cdot (X_J - \bar{X}_J).$$

O erro de previsão é dado pela diferença

$$\delta = Y - \hat{Y} = \left[\alpha + \beta_1 \cdot (X_1 - \bar{X}_1) + \dots + \beta_J \cdot (X_J - \bar{X}_J) + E \right] - \left[A + B_1 \cdot (X_1 - \bar{X}_1) + \dots + B_J \cdot (X_J - \bar{X}_J) \right].$$

A partir desta expressão, é imediato verificar que o valor esperado do erro de previsão, δ , é nulo. Uma vez que cada nova observação de Y é independente das observações anteriores (a partir das quais se estimou $\hat{Y}$) e, portanto, também independente de $\hat{Y}$, a variância de δ é dada por:

$$\text{Var}(\delta) = \text{Var}(Y) + \text{Var}(\hat{Y}).$$

Ora, tendo em conta que $\alpha, \beta_1, \dots, \beta_J, X_1, \dots, X_J, \bar{X}_1, \dots, \bar{X}_J$ são constantes, vem

$$\text{Var}(Y) = \text{Var}[\alpha + \beta_1 \cdot (X_1 - \bar{X}_1) + \dots + \beta_J \cdot (X_J - \bar{X}_J) + E] = \text{Var}(E) = \sigma^2.$$

Por outro lado,

$$\begin{aligned} \text{Var}(\hat{Y}) &= \text{Var}[A + B_1 \cdot (X_1 - \bar{X}_1) + \dots + B_J \cdot (X_J - \bar{X}_J)] \\ &= \text{Var}(A) + \text{Var}[B_1 \cdot (X_1 - \bar{X}_1) + \dots + B_J \cdot (X_J - \bar{X}_J)] \end{aligned} \quad (14.32)$$

dado que, para $j = 1, \dots, J$, $\text{Cov}(A, B_j) = 0$ e $(X_j - \bar{X}_j)$ é constante.

No segundo membro da expressão 14.32, a variância do estimador A é dada por

$$\text{Var}(A) = \text{Var}(\bar{Y}) = \text{Var}(Y) / N = \sigma^2 / N.$$

O termo $\text{Var}[B_1 \cdot (X_1 - \bar{X}_1) + \dots + B_J \cdot (X_J - \bar{X}_J)]$ pode ser desenvolvido adoptando um procedimento semelhante ao utilizado na Secção 14.3.3.2 para calcular $\text{Var}(A')$, obtendo-se

$$\text{Var}[B_1 \cdot (X_1 - \bar{X}_1) + \dots + B_J \cdot (X_J - \bar{X}_J)] = (\underline{X} - \bar{X})^T \cdot [V(B)] \cdot (\underline{X} - \bar{X})$$

onde

$(\underline{X} - \bar{X})$: vector das variáveis independentes (centradas nas respectivas médias);

$(\underline{X} - \bar{X})^T$: $(\underline{X} - \bar{X})$ transposto;

$[V(B)]$: matriz de variância-covariância dos estimadores $B_1, \dots, B_J$.

Retomando a expressão 14.32 e substituindo, obtém-se

$$\text{Var}(\hat{Y}) = \sigma^2 / N + \{(\underline{X} - \bar{X})^T \cdot [V(B)] \cdot (\underline{X} - \bar{X})\}.$$

Finalmente, a variância do erro de previsão vem

$$\text{Var}(\delta) = \text{Var}(Y) + \text{Var}(\hat{Y}) = (1 + 1/N) \cdot \sigma^2 + \{(\underline{X} - \bar{X})^T \cdot [V(B)] \cdot (\underline{X} - \bar{X})\}. \quad (14.33)$$

Note-se que a variância σ^2 pode ser estimada recorrendo à expressão 14.21 ou, o que é equivalente, à expressão do desvio quadrático médio residual (ver Tabela 14.7).

Admitindo como válida a hipótese da Normalidade dos erros, então tanto Y como $\hat{Y}$ e, portanto, o erro de previsão δ seguem distribuições Normais. Para cada conjunto de valores de $X_1, \dots, X_J$, o intervalo de previsão a $(1 - \gamma) \cdot 100\%$ vem assim dado por:

$$\hat{Y} \pm t_{N-J-1}(\gamma/2) \cdot \{(1 + 1/N) \cdot S^2 + (\underline{X} - \bar{X})^T \cdot [V(\hat{B})] \cdot (\underline{X} - \bar{X})\}^{1/2}. \quad (14.34)$$

Exemplo 14.14

Regresse-se ao Exemplo 14.7 e efectue-se a previsão de Y para $(X_1, X_2) = (6.1, 8.0)$.

Previsão pontual:

$$\begin{aligned} \hat{y} &= a + b_1 \cdot (x_1 - \bar{x}_1) + b_2 \cdot (x_2 - \bar{x}_2) \\ &= 53.41 + 4.34 \cdot (6.1 - 5.1) + 2.99 \cdot (8.0 - 7.65) = 58.8. \end{aligned}$$

Previsão por intervalo (a 95%):

Tendo em conta que

$$s^2 = \hat{\sigma}^2 = 0.983$$

$$\begin{aligned} (\underline{x} - \bar{x})^T \cdot [V(\hat{B})] \cdot (\underline{x} - \bar{x}) &= (x_1 - \bar{x}_1)^2 \cdot \hat{\text{Var}}(B_1) \\ &\quad + 2 \cdot (x_1 - \bar{x}_1) \cdot (x_2 - \bar{x}_2) \cdot \hat{\text{Cov}}(B_1, B_2) + (x_2 - \bar{x}_2)^2 \cdot \hat{\text{Var}}(B_2) \\ &= 1.0^2 \cdot 0.300 - 2 \cdot 1.0^2 \cdot 0.35 \cdot 0.018 + 0.35^2 \cdot 0.133 = 0.3 \end{aligned}$$

e

$$t_{N-J-1}(0.025) = t_7(0.025) = 2.365 \text{ (ver Tabela 5 do Anexo «Tabelas»),}$$

os limites do intervalo de previsão de Y a 95% para $X_1 = 6.1$ e $X_2 = 8.0$ vêm (ver expressão 14.34):

$$58.8 \pm 2.365 \cdot \sqrt{(1 + 1/10) \cdot 0.983 + 0.3} = 58.8 \pm 2.77.$$

O intervalo de previsão pretendido é então

$$[56.03, 61.57].$$

■ 14.3.7 INCORPORAÇÃO DE REGRESSORES QUALITATIVOS NUM MODELO DE REGRESSÃO: VARIÁVEIS MUDAS

As **variáveis mudas** (que, em inglês, se designam por *dummy variables*) são incorporadas nos modelos de regressão com o objectivo de representar o efeito de factores qualitativos. Para ilustrar o conceito de variável muda e o tipo de situações nas quais faz sentido a sua utilização, considere-se o exemplo que se apresenta em seguida.


Exemplo 14.15

Numa determinada empresa de artes gráficas existe uma secção dedicada ao fabrico de um tipo de cartões. Na Figura 14.11 representam-se, para essa secção, observações das variáveis

X : dimensões de diferentes encomendas de cartões

Y : custos de produção associados à satisfação das encomendas.

Figura 14.11
Regressão com uma variável muda
(Exemplo 14.15).



As observações foram classificadas em duas categorias:

- ♦ encomendas satisfeitas em regime normal
- ♦ encomendas satisfeitas com urgência.

Analisando a Figura 14.11, parece razoável que, neste caso, se adopte o modelo de regressão

$$\begin{aligned} Y_n &= \alpha + \beta \cdot (X_n - \bar{X}) + \gamma \cdot (Z_n - \bar{Z}) + E_n \\ &= \alpha' + \beta \cdot X_n + \gamma \cdot Z_n + E_n, \end{aligned} \quad (14.35)$$

em que Z_n representa uma **variável muda** que toma apenas os seguintes valores:

$$Z_n = \begin{cases} 0, & \text{se o regime for normal} \\ 1, & \text{se o regime for urgente.} \end{cases}$$

Esta variável serve então para incorporar no modelo de regressão o factor qualitativo «regime de satisfação de encomendas».

Registe-se que os valores atribuídos a Z_n são arbitrários. De facto, os valores 0 e 1 são habitualmente escolhidos por simplificarem a interpretação das parcelas e parâmetros do modelo. Neste exemplo, o parâmetro γ representa o valor esperado do custo adicional associado ao regime urgente.

Se um factor qualitativo tiver mais do que dois níveis, é incorrecto incluir no modelo de regressão uma só variável muda para o representar.

Exemplo 14.16

Voltando ao Exemplo 14.15, admita-se agora que existia um terceiro regime de satisfação de encomendas, com muita urgência. No modelo

$$Y_n = \alpha' + \beta \cdot X_n + \gamma \cdot Z_n + E_n,$$

as observações Z_n já têm valores correspondentes aos regimes normal (0) e urgente (1).

Qualquer valor que se atribua ao regime muito urgente imporá, *a priori*, uma relação entre os aumentos de custo correspondentes às mudanças de regime «normal → urgente» e «urgente → muito urgente». Por exemplo, se o valor adoptado para o regime muito urgente fosse $Z = 2$, o custo adicional introduzido por este regime relativamente ao urgente seria γ (ou seja, seria igual ao aumento de custo associado à mudança de regime «normal → urgente»).

Para representar adequadamente um factor com K níveis devem ser incluídas no modelo de regressão $K - 1$ variáveis mudas.

Exemplo 14.17

Retomando o Exemplo 14.16, os três regimes de satisfação de encomendas poderiam ser representados por $3 - 1 = 2$ variáveis mudas, designadamente por:

$$Z_1 = \begin{cases} 0, & \text{se o regime for normal} \\ 1, & \text{se o regime não for normal} \end{cases}$$

$$Z_2 = \begin{cases} 0, & \text{se o regime for urgente} \\ 1, & \text{se o regime não for urgente.} \end{cases}$$

O modelo de regressão seria então

$$Y_n = \alpha' + \beta \cdot X_n + \gamma_1 \cdot Z_{1n} + \gamma_2 \cdot Z_{2n} + E_n$$

podendo as observações de Z_1 e de Z_2 tomar os seguintes valores:

- ♦ regime normal: $Z_1 = 0, Z_2 = 1$
- ♦ regime urgente: $Z_1 = 1, Z_2 = 0$
- ♦ regime muito urgente: $Z_1 = 1, Z_2 = 1$.


Observe-se que, nestas condições, $(\gamma_1 - \gamma_2)$ representa o valor esperado do acréscimo do custo correspondente à mudança de regime «normal → urgente» e γ_2 equivale à mudança «urgente → muito urgente».

No modelo de regressão (com dois níveis) considerado no Exemplo 14.15,

$$Y_n = \alpha' + \beta \cdot X_n + \gamma \cdot Z_n + E_n,$$

admitiu-se que o coeficiente angular das duas rectas apresentadas na Figura 14.11 era idêntico (β). Ora, pode suceder que tal não se verifique. Uma forma alternativa de representar a situação em análise seria a de considerar dois modelos independentes: um para as observações com regime normal (com o coeficiente β_0) e outro para as observações com regime urgente (com o coeficiente β_1). Esta situação é ilustrada na Figura 14.12.

Figura 14.12
Modelos de regressão independentes
(Exemplo 14.15).



Para testar se a diferença entre β_0 e β_1 é significativa (na situação representada na Figura 14.12 interessaria verificar se $H_0: \beta_0 = \beta_1$ contra $H_1: \beta_0 < \beta_1$), atente-se a que (ver a segunda expressão 14.9)

$$\frac{B_0 - \beta_0}{\sigma_0 / \sqrt{S_{XX}^0}} \sim N(0, 1) \quad \text{e que} \quad \frac{B_1 - \beta_1}{\sigma_1 / \sqrt{S_{XX}^1}} \sim N(0, 1).$$

Se se admitir que $\sigma^2 = \sigma_0^2 = \sigma_1^2$ (hipótese que pode ser verificada recorrendo ao teste F), a variância σ^2 pode ser obtida recorrendo à expressão

$$S^2 = \hat{\sigma}_0^2 = \hat{\sigma}_1^2 = \frac{1}{N_0 + N_1 - 4} \cdot [(N_0 - 2) \cdot S_0^2 + (N_1 - 2) \cdot S_1^2],$$

onde

$$S_0^2 = \hat{\sigma}_0^2 = \frac{1}{N_0 - 2} \cdot \sum_n \hat{E}_{0n}^2 \quad \text{e} \quad S_1^2 = \hat{\sigma}_1^2 = \frac{1}{N_1 - 2} \cdot \sum_n \hat{E}_{1n}^2$$

(com N_0 e N_1 representando o número de observações no modelo correspondente).

Nestas condições, o teste teria a seguinte estrutura:

$$H_0: \beta_0 = \beta_1$$

$$H_1: \beta_0 < \beta_1$$

$$ET = \frac{B_1 - B_0}{S \cdot \sqrt{\frac{1}{S_{XX}^0} + \frac{1}{S_{XX}^1}}}$$

$$H_0 \text{ verdadeira} \Rightarrow ET \sim t_{N_0 + N_1 - 4}$$

14.3.8 REGRESSÃO LINEAR MÚLTIPLA E CORRELAÇÃO

Foi já anteriormente referido que a análise de correlação permite avaliar o grau de relacionamento linear entre variáveis. O modelo utilizado na análise de correlação múltipla é basicamente o mesmo que foi considerado na análise de regressão múltipla (ver expressão 14.19):

$$Y_n = \alpha + \sum_j \beta_j \cdot (X_{jn} - \bar{X}_j) + E_n$$

A diferença essencial entre a análise de regressão e a análise de correlação consiste no seguinte: enquanto na primeira se admite que os valores X_{jn} são constantes predeterminadas, na segunda considera-se que tais valores são observações aleatórias.

O coeficiente amostral de correlação múltipla entre Y e $X_1, \dots, X_J$ ($R_{YX_1X_2\dots X_J}$), pode ser definido das duas formas alternativas equivalentes que se enunciam em seguida:

- (i) Coeficiente amostral de correlação simples entre os valores observados da variável Y e os correspondentes valores estimados, ou seja, $\hat{Y} = A + B_1 \cdot (X_1 - \bar{X}_1) + \dots + B_J \cdot (X_J - \bar{X}_J)$:

$$R_{YX_1X_2\dots X_J} = R_{\hat{Y}\hat{Y}}$$

- (ii) Raiz quadrada do coeficiente de determinação múltipla ($R^2_{YX_1X_2\dots X_J}$), que, por sua vez, é dado por

$$R^2_{YX_1X_2\dots X_J} = \frac{VDR}{VT} \quad (14.36)$$

Numa ou na outra interpretação, o coeficiente amostral de correlação múltipla mede o grau de relacionamento linear de Y com o conjunto das variáveis $X_1, \dots, X_J$.

Para além de medir a correlação entre Y e o conjunto de todas as variáveis $X_1, \dots, X_J$, há frequentemente interesse em avaliar a correlação de Y com cada uma destas variáveis, tomadas individualmente. No entanto, quando estão em jogo diversas variáveis independentes, o coeficiente de correlação simples entre Y e cada um dos regressores constitui uma medida insuficiente do seu grau de relacionamento linear. O seguinte exemplo explica esta insuficiência.

Exemplo 14.18

Admita-se que, durante vários anos, o coeficiente de correlação entre o consumo nacional de vinho do Porto, Y , e o salário médio dos políticos portugueses, X_1 , se situou próximo do valor 0.9.

Tal facto não prova que os políticos sejam uns bebedores inveterados, que, quando dispõem de mais algum dinheiro, contribuem significativamente para o consumo nacional de vinho do Porto. Nem tão pouco sugere que, por outro lado, o aumento de vendas de vinho do Porto acarrete uma melhoria nos salários da generalidade dos políticos.

O que terá acontecido é que as duas variáveis caminharam juntas por influência de uma terceira: o rendimento *per capita*, X_2 . Só se fosse possível manter constantes os regressores que, tal como X_2 , influenciam simultaneamente Y e X_1 , é que a correlação entre estas variáveis passaria a fazer sentido. Nestas condições, certamente que o coeficiente de correlação entre Y e X_1 se anularia.

Na regressão múltipla consegue-se isolar o efeito de cada regressor X_j na variável dependente, sem que haja necessidade de manter constantes os valores dos restantes regressores. Tal efeito traduz-se no valor do correspondente coeficiente β_j .

Também no âmbito da correlação múltipla se consegue definir uma medida de correlação entre duas variáveis quaisquer quando se anulam os efeitos induzidos pelas restantes variáveis. Tal medida designa-se por **coeficiente de correlação parcial** e a sua expressão será seguidamente definida para o caso de três variáveis, X_1 , X_2 e X_3 .

Denotando os coeficientes de correlação simples por

$$R_{X_1X_2} = \frac{S_{X_1X_2}}{\sqrt{S_{X_1X_1} \cdot S_{X_2X_2}}}$$

$$R_{X_1X_3} = \frac{S_{X_1X_3}}{\sqrt{S_{X_1X_1} \cdot S_{X_3X_3}}}$$

$$R_{X_2X_3} = \frac{S_{X_2X_3}}{\sqrt{S_{X_2X_2} \cdot S_{X_3X_3}}}$$

os coeficientes de correlação parcial vêm definidos por

$$\begin{aligned} R_{X_1X_3|X_2} &= \frac{R_{X_1X_3} - R_{X_1X_2} \cdot R_{X_2X_3}}{\sqrt{(1 - R_{X_1X_2}^2) \cdot (1 - R_{X_2X_3}^2)}} \\ R_{X_1X_2|X_3} &= \frac{R_{X_1X_2} - R_{X_1X_3} \cdot R_{X_3X_2}}{\sqrt{(1 - R_{X_1X_3}^2) \cdot (1 - R_{X_3X_2}^2)}} \\ R_{X_2X_3|X_1} &= \frac{R_{X_2X_3} - R_{X_2X_1} \cdot R_{X_1X_3}}{\sqrt{(1 - R_{X_2X_1}^2) \cdot (1 - R_{X_1X_3}^2)}} \end{aligned} \quad (14.37)$$

(na notação aqui utilizada, $R_{X_2X_3|X_1}$ denota o coeficiente de correlação parcial entre X_2 e X_3 quando a variável X_1 é mantida constante).

14.4 REGRESSÃO NÃO-LINEAR

Até agora foram apenas contemplados modelos traduzindo relações lineares entre a variável dependente e a(s) variável(eis) independente(s). A técnica de análise de regressão será agora estendida ao tratamento de situações em que aquelas relações são não-lineares.

14.4.1 REGRESSÃO LINEAR SIMPLES COM TRANSFORMAÇÃO DE VARIÁVEIS

A técnica de regressão linear simples pode ser utilizada em **modelos não-lineares** com uma só variável independente, desde que tais modelos sejam convertíveis em modelos

lineares por aplicação de transformações às variáveis dependente ou independente. Considerar-se-ão seguidamente alguns exemplos cuja aplicação é relativamente frequente.

■ Modelo $Y_n = \alpha' + \frac{\beta}{X_n} + E_n$ (14.38)


Uma relação $Y_n = \alpha' + \beta/X_n$ (ver Figura 14.13), pode ser linearizada recorrendo à transformação inversa da variável independente, ou seja, definindo a nova variável

$$U_n = \frac{1}{X_n}.$$

O modelo linearizado, expressando a relação entre as variáveis Y e U , vem

$$Y_n = \alpha' + \beta \cdot U_n + E_n.$$

Figura 14.13
Relação $Y = \alpha' + \beta/X$.



■ Modelo exponencial: $Y_n = e^{\alpha' + \beta \cdot X_n} + E_n$ (14.39)


A linearização de uma relação $Y_n = e^{\alpha' + \beta \cdot X_n}$ (ver Figura 14.14) consegue-se através de uma transformação logarítmica da variável dependente, isto é, fazendo

$$Z_n = \ln(Y_n).$$

O modelo linearizado vem

$$Z_n = \alpha' + \beta \cdot X_n + E_n.$$

Figura 14.14
Relação $Y = e^{\alpha' + \beta \cdot X}$.




■ Modelo «curva S»: $Y_n = e^{\alpha' + \beta/X_n + E_n}$ (com $\alpha' > 0$ e $\beta < 0$) (14.40)

Uma relação $Y_n = e^{\alpha' + \beta/X_n}$ (com $\alpha' > 0$ e $\beta < 0$) (ver Figura 14.15) pode ser linearizada recorrendo simultaneamente à transformação inversa da variável independente e à transformação logarítmica da variável dependente:

$$U_n = \frac{1}{X_n}$$

$$Z_n = \ln(Y_n).$$

Figura 14.15
Relação $Y = e^{\alpha' + \beta/X}$.



O modelo linearizado vem

$$Z_n = \alpha' + \beta \cdot U_n + E_n.$$

Em relação aos modelos apresentados e, em geral, à aplicação da regressão linear simples após a transformação de variáveis, é oportuno incluir algumas observações.

- Os modelos linearizados foram apresentados na forma

$$Z_n = \alpha' + \beta \cdot X_n + E_n$$

e não na forma habitual

$$Z_n = \alpha + \beta \cdot (X_n - \bar{X}) + E_n.$$

Tal facto prende-se unicamente com a clareza e a comodidade da exposição. A conversão de um modelo no outro é trivial (como anteriormente já se verificou).

- Se os estimadores A e B dos parâmetros de regressão α e β forem calculados através das expressões 14.3 e 14.4 (ver Secção 14.2.2), eles só serão não-enviesados, consistentes e eficientes se, no modelo linearizado, os erros tiverem valor esperado nulo, variância constante e forem mutuamente independentes.

Note-se que as transformações não-lineares efectuadas sobre a variável dependente Y implicam que, se as condições acima mencionadas forem satisfeitas pelos erros do modelo linearizado, então não serão satisfeitas (pelo menos na globalidade) pelos erros do modelo original. A recíproca também é verdadeira, como é óbvio.

Exemplo 14.19

Considere-se o modelo

$$Y_n = e^{\alpha' + \beta \cdot X_n + E_n}.$$

Como se viu, a transformação $Z_n = \ln(Y_n)$ conduz ao modelo linearizado

$$Z_n = \alpha' + \beta \cdot X_n + E_n.$$

Admita-se que, neste modelo, os erros (E_n) seguem uma distribuição $N(0, \sigma^2)$ e, portanto, que as observações transformadas Z_n seguem distribuições $N(\alpha' + \beta \cdot X_n, \sigma^2)$.

Dado que as variáveis Z_n seguem distribuições Normais e que $Z_n = \ln(Y_n)$, então as variáveis Y_n seguem distribuições Lognormais com valor esperado e variância dados por (ver expressões 7.10):

$$\mu_{Y_n} = e^{(\alpha' + \beta \cdot X_n) + \sigma^2/2}$$


$$\sigma_{Y_n}^2 = e^{2[(\alpha' + \beta \cdot X_n) + \sigma^2]} - e^{2(\alpha' + \beta \cdot X_n) + \sigma^2}.$$

Calculando a razão entre a variância e o quadrado do valor esperado, obtém-se

$$\frac{\sigma_{Y_n}^2}{\mu_{Y_n}^2} = e^{\sigma^2} - 1 \quad \text{donde} \quad \frac{\sigma_{Y_n}}{\mu_{Y_n}} = \text{constante.}$$

Daqui se conclui que, quando a variância dos erros do modelo linearizado é constante, então o desvio padrão dos erros do modelo exponencial (que é igual ao desvio padrão das observações Y_n) é proporcional ao valor esperado destas observações. Este facto é ilustrado na Figura 14.16.

Figura 14.16
Banda $\mu_Y \pm \sigma_Y$ no modelo original e $\mu_Z \pm \sigma_Z$ no modelo linearizado (Exemplo 14.19).



- As previsões obtêm-se primeiro no modelo linearizado e, seguidamente, por aplicação das transformações apropriadas, são transportadas para o modelo original.

Exemplo 14.20

Na Tabela 14.15 apresentam-se as vendas registadas nos oito primeiros meses de comercialização de um produto que se admite ter um enorme potencial de vendas (muitíssimo superior aos níveis de venda actuais).


Pretende-se efectuar uma previsão por intervalo (a 90%) do valor das vendas para o mês 11.

Na Figura 14.17 representa-se graficamente a evolução desta variável com o tempo.

Tabela 14.15
Vendas nos primeiros oito meses (Exemplo 14.20).

Mês	Vendas [toneladas]
1	48.0
2	60.6
3	67.1
4	86.9
5	101.5
6	111.4
7	144.3
8	172.0

Figura 14.17
Evolução das vendas nos primeiros oito meses (Exemplo 14.20).



Tendo em conta esta figura e a referência ao elevado potencial das vendas, é razoável admitir um modelo exponencial do tipo

$$V_n = e^{\alpha + \beta(T_n - \bar{T}) + E_n}$$

onde a variável independente, T , representa o tempo (em meses) e a variável dependente, V , as vendas (em toneladas). Note-se que este modelo é equivalente ao que é dado pela expressão 14.39 (embora envolvendo o parâmetro α em vez de α').

Se o modelo exponencial traduzir adequadamente a relação entre T e V , então relação entre T e $Z = \ln(V)$ deverá ser linear. A representação gráfica desta relação na Figura 14.18 parece confirmar a linearidade desta relação.

Estimando o modelo linear


$$Z_n = \ln V_n = \alpha + \beta \cdot (T_n - \bar{T}) + E_n$$

com base nas observações (T_n, Z_n) ($n = 1, \dots, 8$) e, a partir deste modelo, prevendo o valor da variável Z para $T = 11$, obtém-se o seguinte intervalo de previsão a 90%: [5.553, 5.785].

Os limites do intervalo de previsão a 90% para as vendas correspondentes ao mês 11 obtêm-se aplicando aos limites do intervalo em Z a transformação inversa de $Z = \ln(V)$, ou seja, $V = e^Z$:

$$[e^{5.553}, e^{5.785}] \approx [258, 325] \text{ (toneladas).}$$

Figura 14.18
Linearização do modelo de evolução das vendas por transformação logarítmica da variável dependente (Exemplo 14.20).



14.4.2 REGRESSÃO LINEAR MÚLTIPLA COM TRANSFORMAÇÃO DE VARIÁVEIS

14.4.2.1 REGRESSÃO POLINOMIAL

Entre uma variável independente, X , e uma variável dependente, Y , pode existir uma relação polinomial de grau J . Tal relação pode ser representada por um modelo do tipo

$$Y_n = \alpha + \beta_1 \cdot (X_n - \bar{X}) + \beta_2 \cdot (X_n^2 - \bar{X}^2) + \dots + \beta_J \cdot (X_n^J - \bar{X}^J) + E_n, \quad (14.41)$$

onde

N : número de observações (X_n, Y_n)

$$\bar{X} = \frac{1}{N} \cdot \sum_n X_n$$

$$\bar{X}^2 = \frac{1}{N} \cdot \sum_n X_n^2$$

$$\dots$$

$$\bar{X}^J = \frac{1}{N} \cdot \sum_n X_n^J.$$

O modelo que se representa na expressão 14.41 designa-se por **modelo de regressão polinomial simples**.

Ora, este tipo de modelo pode ser convertido num modelo de regressão linear múltipla. Para isso bastará encarar cada potência de ordem j ($j = 1, \dots, J$) da mesma variável X como uma variável distinta, X_j . Tal é equivalente a substituir X_j^j por $(X_j)_n$ ou, mais simplesmente, por X_{jn} . Com esta substituição obtém-se o **modelo linearizado múltiplo** seguinte:

$$Y_n = \alpha + \beta_1 \cdot (X_{1n} - \bar{X}_1) + \beta_2 \cdot (X_{2n} - \bar{X}_2) + \dots + \beta_J \cdot (X_{Jn} - \bar{X}_J) + E_n. \quad (14.42)$$

Este modelo pode ser tratado recorrendo aos procedimentos aplicáveis à regressão linear múltipla, tal como foram descritos na Secção 14.3.

O problema da escolha do polinómio a ajustar às observações de Y e de X (ou se se preferir de Y e de $X_1, X_2, X_3, \dots$) é equivalente ao problema da selecção de regressores, já abordado anteriormente (ver secção 14.3.4).

Seguidamente, recorrendo a um exemplo, apresenta-se um procedimento baseado no método progressivo que permite seleccionar um polinómio ajustando sucessivamente polinómios de ordem crescente (1, 2, 3, ...) e parando quando a adição de mais um termo já não explique uma proporção significativa da variação total de Y .

Exemplo 14.21

Admita-se que, com base em 20 pares de observações (y_n, x_n) , se pretende ajustar uma relação polinomial entre as variáveis X e Y .

O procedimento inicia-se ajustando um modelo de regressão linear simples $Y = Y(X) = Y(X_1)$, para o qual se obteve a tabela ANOVA que se apresenta na Tabela 14.16.

O teste ANOVA correspondente (efectuado ao nível de significância de 5%), permite verificar que a proporção da variação total de Y que é explicada pela regressão em X é significativa (ou seja, permite rejeitar $H_0: \beta_1 = 0$):

$$\left[ET = \frac{99}{47/18} = 37.91 > F_{1,18}(0.05) = 4.41 \right] \Rightarrow H_0 \text{ rejeitada.}$$

Seguidamente ajusta-se um polinómio de segunda ordem, $Y = Y(X, X^2) = Y(X_1, X_2)$, com os resultados que se apresentam na Tabela 14.17.

Perante o resultado do teste ANOVA,

$$\left[ET = \frac{13}{25/17} = 8.84 > F_{1,17}(0.05) = 4.45 \right] \Rightarrow H_0 \text{ rejeitada,}$$

conclui-se, ao nível de significância de 5%, que a inclusão do termo de segunda ordem contribui significativamente para explicar a variação total de Y .

Tabela 14.16
Tabela ANOVA para o modelo de regressão linear simples $Y = Y(X)$ (Exemplo 14.21).

Fontes	Variações	GL	DQM
DR (X_2)	99	2	99
R	47	18	47 / 18
T	137	19	

Tabela 14.17
Tabela ANOVA para o modelo $Y = Y(X, X^2) = Y(X_1, X_2)$, com identificação do contributo marginal do termo de segunda ordem (Exemplo 14.21).

Fontes	Variações	GL	DQM
DR (X, X^2)	112	2	
DR (X)	(99)	(1)	
DR ($X^2 X$)	(99)	(1)	13
R	25	17	25 / 17
T	137	19	

Tabela 14.18
Tabela ANOVA para o modelo $Y = Y(X, X^2, X^3) = Y(X_1, X_2, X_3)$, com identificação do contributo marginal do termo de terceira ordem (Exemplo 14.21).

Fontes	Variações	GL	DQM
DR (X, X^2, X^3)	115	3	
DR (X, X^2)	(112)	(2)	
DR ($X^3 X, X^2$)	(3)	(1)	3
R	22	16	22 / 16
T	137	19	

O procedimento prossegue com a tentativa de ajuste de um polinómio de terceira ordem, $Y = Y(X, X^2, X^3) = Y(X_1, X_2, X_3)$. A tabela ANOVA correspondente a este modelo apresenta-se na Tabela 14.18.

Desta vez, o teste ANOVA revela que, ao nível de significância de 5%, a inclusão do termo de terceira ordem não contribui significativamente para explicar a variação total de Y . De facto,

$$\left[ET = \frac{3}{22/16} = 2.18 < F_{1,16}(0.05) = 4.49 \right] \Rightarrow H_0 \text{ não rejeitada.}$$

De acordo com este resultado, a relação entre X e Y é adequadamente descrita por um polinómio de segundo grau.


O procedimento básico que acabou de ser descrito pode ser refinado em duas áreas:

- Sempre que é acrescentado um termo ao polinómio, é oportuno verificar se algum daqueles que foram previamente incluídos merece ser desclassificado. Na essência, este refinamento corresponde à passagem do método progressivo ou regressivo para o método passo a passo.
- Embora, em geral, a regra de paragem seja segura, há, no entanto, circunstâncias nas quais pode conduzir a uma paragem precoce.

Exemplo 14.22

Ao ajustar um polinómio de grau um (isto é, uma recta) às observações representadas na Figura 14.19, chegar-se-ia à conclusão que o coeficiente angular β_1 não seria significativamente diferente de zero. De acordo com a regra de paragem considerada anteriormente, já não se ajustaria um polinómio de segundo grau (o que, de facto, se deveria fazer, pois o coeficiente de X^2 , β_2 , é positivo).

Figura 14.19
Ajuste de polinómios de graus 1 e 2 a um conjunto de dados (Exemplo 14.22).



Em geral, pode evitar-se uma paragem precoce por inspecção do diagrama (X, Y) . Alternativamente, a insuficiência de ajuste pode ser detectada se, por sistema, se verificar a existência de correlação positiva entre os desvios sucessivos das observações relativamente ao polinómio ajustado. Tal correlação positiva — que se manifestaria claramente no caso do polinómio de grau zero (ou um) considerado no exemplo anterior — é indicadora de que o grau do polinómio ajustado é insuficiente.

■ 14.4.2.2 INCLUSÃO DE PRODUTOS CRUZADOS

Como já se viu, a regressão linear múltipla assenta no modelo

$$Y_n = \alpha + \sum_j \beta_j \cdot (X_{jn} - \bar{X}_j) + E_n.$$


Neste modelo, presume-se que os diferentes regressores explicam a variação de Y de uma forma aditiva. Isto é, admite-se que os efeitos sobre a variável dependente Y que resultam de variações nos regressores se somam. No entanto, sucede frequentemente que entre alguns regressores existe interação. O exemplo seguinte ilustra este caso.

Exemplo 14.23

Regresse-se ao Exemplo 14.15 e admita-se agora que as observações relativas ao volume e ao custo de produção se apresentavam como na Figura 14.20 (que é idêntica à Figura 14.12).

Nesta situação, o regime de urgência parece reflectir-se não só no aumento do custo de produção (Y), mas também no aumento do coeficiente angular da relação entre este custo e o volume de produção (X).

Figura 14.20
Interação entre o
regime de produção
e o volume de
produção (Exemplo
14.23).



Anteriormente, na Secção 14.3.9, foi referida uma forma de modelar a relação entre X e Y numa a situação do tipo da que é ilustrada neste exemplo: considerar dois modelos de regressão independentes (um para o regime normal e outro para o regime urgente).

Um procedimento alternativo consiste em incluir na regressão termos que correspondam a produtos cruzados de dois (ou mais) regressores. No Exemplo 14.23, seria razoável considerar o modelo

$$Y_n = \alpha + \beta \cdot (X_n - \bar{X}) + \gamma \cdot (Z_n - \bar{Z}) + \delta \cdot (X_n - \bar{X}) \cdot (Z_n - \bar{Z}) + E_n,$$

no qual Z representa, como anteriormente, uma variável muda que expressa o regime de atendimento das encomendas (normal/urgente). Ao incluir um produto cruzado no modelo, quebra-se a sua linearidade. No entanto, tal linearidade pode ser recuperada, tratando o produto das duas variáveis como um novo regressor.

Uma vez assumida a transformação, o modelo é passível do tratamento habitual, recorrendo à técnica de regressão linear múltipla.

■ 14.4.3 REGRESSÃO SEM TRANSFORMAÇÃO DE VARIÁVEIS

Quando a linearização dos modelos de regressão por transformação de variáveis não for possível, procede-se à estimação directa dos parâmetros dos modelos não-lineares, recorrendo-se ainda ao método dos mínimos quadrados.

Para um modelo do tipo


$$Y_n = f(X_{1n}, X_{2n}, \dots, X_{jn}, \theta_1, \theta_2, \dots, \theta_k) + E_n,$$

a minimização do somatório

$$SEQ = \sum_n E_n^2 = \sum_n \left[Y_n - f(X_{1n}, X_{2n}, \dots, X_{jn}, \theta_1, \theta_2, \dots, \theta_k) \right]^2$$

é efectuada recorrendo a métodos numéricos de optimização de funções não-lineares. De entre tais métodos, merece uma referência, pela sua divulgação, o método de Marquardt (que se encontra disponível em alguns programas comerciais de estatística).

Como é evidente, por mais eficientes que os métodos de optimização de funções não-lineares sejam, o esforço computacional envolvido na estimação dos parâmetros é muito mais elevado do que no caso dos modelos de regressão linear.



- 14.1. O montante global dos seguros de vida efectuados pelas famílias de um determinado país depende do rendimento anual do agregado familiar. Na tabela seguinte apresentam-se os valores destas variáveis, expressas em unidades monetárias do país em causa, para um conjunto de 12 famílias considerado representativo da população.

Rendimento anual [1000 u.m.]	Capital seguro [1000 u.m.]
14	31
19	40
23	49
12	20
9	21
15	34
22	54
25	52
15	28
10	21
12	24
16	34

- (i) Estime a relação entre as duas variáveis.
(ii) Calcule a probabilidade de que uma família qualquer com um rendimento anual de 20 000 u.m. ter seguros de vida num montante que excede as 45 000 u.m.
- 14.2. Na tabela seguinte apresenta-se, para os últimos 9 anos, o volume de produção de trigo numa determinada região (em milhares de toneladas).

Ano (X)	1997	1998	1999	2000	2001	2002	2003	2004	2005
Vol. de produção (Y)	285	270	294	279	260	262	258	272	255

Com base nos valores inscritos na tabela, calcularam-se as seguintes estatísticas:

$$\begin{aligned}\bar{x} &= 2001 & \bar{y} &= 270.(5) \\ s_{xx} &= 60 & s_{yy} &= 1416.(2) & s_{xy} &= -203\end{aligned}$$

- (i) Estime e teste, ao nível de significância de 5%, a relação que define a evolução de produção de trigo em função do tempo.
(ii) Estime a probabilidade de o volume de produção em 2006 ser superior ao de 2005.
(iii) Estime a probabilidade de o volume de produção em 2007 ser superior ao de 2006.

- 14.3. No âmbito de uma auditoria internacional a uma Agência Governamental, tentou verificar-se a fiabilidade do Índice de Preços no Consumidor publicado pela Agência (o IPC oficial). Para o efeito, recalculou-se aquele índice seguindo uma metodologia considerada correcta. Na tabela seguinte apresentam-se os valores dos dois índices, o «correcto» e o oficial, para um período de seis anos.

IPC correcto (X)	IPC oficial (Y)
112.2	108.8
123.5	119.7
131.0	128.0
138.6	135.8
145.7	142.5
149.4	147.0

Com base nestes valores, calcularam-se as seguintes estatísticas:

$$\begin{aligned}\bar{x} &= 133.4 & \bar{y} &= 130.3 \\ s_{xx} &= 987.54 & s_{xy} &= 1012.12 & s_{yy} &= 1037.88\end{aligned}$$

Face a estes dados, estime, teste e interprete a relação entre os dois índices. Nos testes hipóteses que efectuar, adopte o nível de significância de 5%.

- 14.4. No âmbito de um estudo de tráfego efectuado para apoiar o projecto de um túnel rodoviário, registaram-se, em 20 ocasiões diferentes, os valores observados das duas variáveis seguintes:

X: densidade do tráfego, expressa em número de veículos por quilómetro
Y: velocidade média dos veículos, expressa em km/hora.

A partir das medições efectuadas, foram calculadas as seguintes estatísticas:

$$\begin{aligned}\bar{x} &= 60 & \bar{y} &= 25 \\ s_{xx} &= 5000 & s_{xy} &= -1500 & s_{yy} &= 630.\end{aligned}$$

- (i) Determine a recta de regressão que permite prever a velocidade a partir da densidade. Verifique (com $\alpha = 5\%$) se o coeficiente angular da recta é significativo.
(ii) Admitindo que a densidade de tráfego é de 70 veículos por quilómetro, defina o intervalo de previsão a 95% para a velocidade média.
(iii) Estime o nível ao qual deve ser controlada a densidade de tráfego, por forma a maximizar o volume (V) de tráfego através do túnel (com $V = X \cdot Y$ veículos por hora). Qual o valor do desvio padrão do estimador da densidade óptima?

- 14.5. Uma companhia de aviação efectua a manutenção preventiva de um determinado instrumento dos aviões do tipo AA após cada 25 horas de voo dos aparelhos. Foi, no entanto, sugerido que a desregulação dos instrumentos em causa dependeria mais do tempo que decorre entre manutenções sucessivas do que do número de horas de voo.

Para examinar a validade desta sugestão, efectuaram-se, para os aviões do tipo AA, 20 observações das variáveis seguintes:

- X_1 : n.º de horas de voo desde a última operação de manutenção até à verificação do instrumento
 X_2 : n.º de dias decorridos desde a última operação de manutenção até à verificação do instrumento
 Y : medida de desregulação do instrumento.

A partir dos resultados obtidos foram calculadas as seguintes estatísticas:

$$\bar{x}_1 = 12 \quad \bar{x}_2 = 10 \quad \bar{y} = 2 \quad s_{x_1 x_1} = 1500$$

$$s_{x_1 x_2} = 500 \quad s_{x_2 x_1} = 300 \quad s_{x_1 y} = 120 \quad s_{x_2 y} = 60 \quad s_{yy} = 30.$$

- (i) Analise os resultados e verifique se as manutenções devem ser programadas de acordo com X_1 , de acordo com X_2 ou de acordo com as duas variáveis.
(ii) Admita que, por razões de segurança, a medida de desregulação do instrumento em causa não deve ultrapassar o valor 5.0. Viajaria tranquilo nesta companhia de aviação se soubesse que a nova política de manutenção consistia em regular o aparelho logo que decorressem 15 dias desde a intervenção anterior?

- 14.6. Para estudar os efeitos exercidos pela temperatura de reacção (T) e pela presença de um determinado catalisador no rendimento (R) de um processo químico, efectuou-se uma experiência cujos resultados se incluem na tabela seguinte.

Presença do catalisador	Temperatura [°C]	Rendimento [%]
não	20	70
não	22	71
não	26	80
não	29	82
sim	21	72
sim	23	78
sim	27	88
sim	28	89

Modele a relação entre o rendimento do processo e os dois factores analisados (temperatura de reacção e ausência-presença do catalisador).

Na realização de testes de significância, admita que, pela natureza da reacção envolvida,

- o rendimento não pode baixar com o aumento da temperatura, e
- a presença do catalisador não pode contribuir para a diminuição do efeito da temperatura sobre o rendimento.

- 14.7. Na tabela seguinte apresentam-se as vendas trimestrais (VV) de um produto que foi lançado no primeiro trimestre (trimestre $t = 1$).

Trimestre (t)	Volume de vendas (VV)
1	1 206
2	11 356
3	36 888
4	39 636
5	53 887
6	77 806
7	91 627
8	80 147
9	89 646
10	101 677

Efectue previsões das vendas para o trimestre 11, calculando o intervalo de previsão a 95%.

- 14.8. O preço de um veículo usado é função de diversos factores, entre os quais figuram os seguintes: o modelo do veículo em causa, o preço do veículo novo, a idade do veículo usado, o seu estado de conservação e a relação procura/oferta no mercado de veículos em segunda mão.

Considerando apenas o caso de veículos devidamente conservados e supondo que o factor procura/oferta do mercado em segunda mão não varia significativamente, o preço de um veículo usado de determinado modelo pode ser explicado através de uma relação do tipo

$$p = \frac{PVU}{PVN} = f(I)$$


onde

- PVU : preço do veículo usado
 PVN : preço do veículo novo
 I : idade do veículo usado.

Na tabela seguinte apresentam-se valores de p e I para veículos de um determinado modelo, que se supõem obtidos nas condições acima enunciadas.

I [anos]	1	2	3	4	5	6	7	8	9
$p = PVU / PVN$	0.843	0.753	0.580	0.520	0.452	0.414	0.346	0.264	0.241

- (i) Começando por representar graficamente os dados apresentados, defina a função que melhor traduz a relação entre p e I .
(ii) Calcule a probabilidade de p ultrapassar o valor 0.65, para um veículo que, tendo 3 anos de idade, esteja nas condições definidas anteriormente.



■ Tabela 1. Funções de Probabilidade de Distribuições Binomiais $B(N, p)$

Os valores tabelados correspondem às probabilidades

$$p(y) = \binom{N}{y} \cdot p^y \cdot q^{N-y},$$

para diferentes combinações de N e P .

$N = 2$											
$y \downarrow$	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	$\leftarrow p$
0	.9025	.8100	.7225	.6400	.5625	.4900	.4225	.3600	.3025	.2500	2
1	.0950	.1800	.2550	.3200	.3750	.4200	.4550	.4800	.4950	.5000	1
2	.0025	.0100	.0225	.0400	.0625	.0900	.1225	.1600	.2025	.2500	0
$p \rightarrow$	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	$y \uparrow$

$N = 3$											
$y \downarrow$	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	$\leftarrow p$
0	.8574	.7290	.6141	.5120	.4219	.3430	.2746	.2160	.1664	.1250	3
1	.1354	.2430	.3251	.3840	.4219	.4410	.4436	.4320	.4084	.3750	2
2	.0071	.0270	.0574	.0960	.1406	.1890	.2389	.2880	.3341	.3750	1
3	.0001	.0010	.0034	.0080	.0156	.0270	.0429	.0640	.0911	.1250	0
$p \rightarrow$	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	$y \uparrow$

$N = 4$											
$y \downarrow$	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	$\leftarrow p$
0	.8145	.6561	.5220	.4096	.3164	.2401	.1785	.1296	.0915	.0625	4
1	.1715	.2916	.3685	.4096	.4219	.4116	.3845	.3456	.2995	.2500	3
2	.0135	.0486	.0975	.1536	.2109	.2646	.3105	.3456	.3675	.3750	2
3	.0005	.0036	.0115	.0256	.0469	.0756	.1115	.1536	.2005	.2500	1
4	.0000	.0001	.0005	.0016	.0039	.0081	.0150	.0256	.0410	.0625	0
$p \rightarrow$	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	$y \uparrow$

$N = 5$											
$y \downarrow$	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	$\leftarrow p$
0	.7738	.5905	.4437	.3277	.2373	.1681	.1160	.0778	.0503	.0313	5
1	.2036	.3281	.3951	.4096	.3955	.3602	.3124	.2592	.2059	.1563	4
2	.0214	.0729	.1382	.2048	.2637	.3087	.3364	.3456	.3369	.3125	3
3	.0011	.0081	.0244	.0512	.0879	.1323	.1811	.2304	.2757	.3125	2
4	.0000	.0005	.0022	.0064	.0146	.0284	.0488	.0768	.1128	.1563	1
5	.0000	.0000	.0001	.0003	.0010	.0024	.0053	.0102	.0185	.0313	0
$p \rightarrow$	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	$y \uparrow$

N = 6

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.7351	.5314	.3771	.2621	.1781	.1176	.0754	.0467	.0277	.0156	6
1	.3231	.3543	.3993	.3932	.3560	.3025	.2437	.1866	.1359	.0938	5
2	.0305	.0984	.1762	.2458	.2966	.3241	.3280	.3110	.2780	.2344	4
3	.0021	.0146	.0415	.0819	.1318	.1852	.2355	.2765	.3032	.3125	3
4	.0001	.0012	.0055	.0154	.0330	.0595	.0951	.1382	.1861	.2344	2
5	.0000	.0001	.0004	.0015	.0044	.0102	.0205	.0369	.0609	.0938	1
6	.0000	.0000	.0000	.0001	.0002	.0007	.0018	.0041	.0083	.0156	0
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 7

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.6983	.4783	.3206	.2097	.1335	.0824	.0490	.0280	.0152	.0078	7
1	.2573	.3720	.3960	.3670	.3115	.2471	.1848	.1306	.0872	.0547	6
2	.0406	.1240	.2097	.2753	.3115	.3177	.2985	.2613	.2140	.1641	5
3	.0036	.0230	.0617	.1147	.1730	.2269	.2679	.2903	.2918	.2734	4
4	.0002	.0026	.0109	.0287	.0577	.0972	.1442	.1935	.2388	.2734	3
5	.0000	.0002	.0012	.0043	.0115	.0250	.0466	.0774	.1172	.1641	2
6	.0000	.0000	.0001	.0004	.0013	.0036	.0084	.0172	.0320	.0547	1
7	.0000	.0000	.0000	.0000	.0001	.0002	.0006	.0016	.0037	.0078	0
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 8

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.6634	.4305	.2725	.1678	.1001	.0576	.1319	.0168	.0084	.0039	8
1	.2793	.3826	.3847	.3355	.2670	.1977	.1373	.0896	.0548	.0313	7
2	.0515	.1488	.2376	.2936	.3115	.2965	.2587	.2090	.1569	.1094	6
3	.0054	.0331	.0839	.1468	.2076	.2541	.2786	.2787	.2568	.2188	5
4	.0004	.0046	.0185	.0459	.0865	.1361	.1875	.2322	.2627	.2734	4
5	.0000	.0004	.0026	.0092	.0231	.0467	.0808	.1239	.1719	.2188	3
6	.0000	.0000	.0002	.0011	.0038	.0100	.0217	.0413	.0703	.1094	2
7	.0000	.0000	.0000	.0001	.0004	.0012	.0033	.0079	.0164	.0313	1
8	.0000	.0000	.0000	.0000	.0000	.0001	.0002	.0007	.0017	.0039	0
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 9

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.6302	.3874	.2316	.1342	.0751	.0404	.0207	.0101	.0046	.0020	9
1	.2985	.3874	.3679	.3020	.2253	.1556	.1004	.0605	.0339	.0176	8
2	.0629	.1722	.2597	.3020	.3003	.2668	.2162	.1612	.1110	.0703	7
3	.0077	.0446	.1069	.1762	.2336	.2668	.2716	.2508	.2119	.1641	6
4	.0006	.0074	.0283	.0661	.1168	.1715	.2194	.2508	.2600	.2461	5
5	.0000	.0008	.0050	.0165	.0389	.0735	.1181	.1672	.2128	.2461	4
6	.0000	.0001	.0006	.0028	.0087	.0210	.0424	.0743	.1160	.1641	3
7	.0000	.0000	.0000	.0003	.0012	.0039	.0098	.0212	.0407	.0703	2
8	.0000	.0000	.0000	.0000	.0001	.0004	.0013	.0035	.0083	.0176	1
9	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0003	.0008	.0020	0
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 10

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.5987	.3487	.1969	.1074	.0563	.0282	.0135	.0060	.0025	.0010	10
1	.3151	.3874	.3474	.2684	.1877	.1211	.0725	.0403	.0207	.0098	9
2	.0746	.1937	.2759	.3020	.2816	.2335	.1757	.1209	.0763	.0439	8
3	.0105	.0574	.1298	.2013	.2503	.2668	.2522	.2150	.1665	.1172	7
4	.0010	.0112	.0401	.0881	.1460	.2001	.2377	.2508	.2384	.2051	6
5	.0001	.0015	.0085	.0264	.0584	.1029	.1536	.2007	.2340	.2461	5
6	.0000	.0001	.0012	.0055	.0162	.0368	.0689	.1115	.1596	.2051	4
7	.0000	.0000	.0001	.0008	.0031	.0090	.0212	.0425	.0746	.1172	3
8	.0000	.0000	.0000	.0001	.0004	.0014	.0043	.0106	.0229	.0439	2
9	.0000	.0000	.0000	.0000	.0000	.0001	.0005	.0016	.0042	.0098	1
10	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0003	.0010	0
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 12

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.5404	.2824	.1422	.0687	.0317	.0138	.0057	.0022	.0008	.0002	12
1	.3413	.3766	.3012	.2062	.1267	.0712	.0368	.0174	.0075	.0029	11
2	.0988	.2301	.2924	.2835	.2323	.1678	.1088	.0639	.0339	.0161	10
3	.0173	.0852	.1720	.2362	.2581	.2397	.1954	.1419	.0923	.0537	9
4	.0021	.0213	.0683	.1329	.1936	.2311	.2367	.2128	.1700	.1208	8
5	.0002	.0038	.0193	.0532	.1032	.1585	.2039	.2270	.2225	.1934	7
6	.0000	.0005	.0040	.0155	.0401	.0792	.1281	.1766	.2124	.2256	6
7	.0000	.0000	.0006	.0033	.0115	.0291	.0591	.1009	.1489	.1934	5
8	.0000	.0000	.0001	.0005	.0024	.0078	.0199	.0420	.0762	.1208	4
9	.0000	.0000	.0000	.0001	.0004	.0015	.0048	.0125	.0277	.0537	3
10	.0000	.0000	.0000	.0000	.0000	.0002	.0008	.0025	.0068	.0161	2
11	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0003	.0010	.0029	1
12	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0003	.0002	0
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 14

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.4877	.2288	.1028	.0440	.0178	.0068	.0024	.0008	.0002	.0001	14
1	.3593	.3559	.2339	.1539	.0832	.0407	.0181	.0073	.0027	.0009	13
2	.1229	.2570	.2912	.2501	.1802	.1134	.0634	.0317	.0141	.0056	12
3	.0259	.1142	.2056	.2501	.2402	.1943	.1366	.0845	.0462	.0222	11
4	.0037	.0349	.0998	.1720	.2202	.2290	.2022	.1549	.1040	.0611	10
5	.0004	.0078	.0352	.0860	.1468	.1963	.2178	.2066	.1701	.1222	9
6	.0000	.0013	.0093	.0322	.0734	.1262	.1759	.2066	.2088	.1833	8
7	.0000	.0002	.0019	.0092	.0280	.0618	.1082	.1574	.1952	.2095	7
8	.0000	.0000	.0003	.0020	.0082	.0232	.0510	.0918	.1398	.1833	6
9	.0000	.0000	.0000	.0003	.0018	.0066	.0183	.0408	.0762	.1222	5
10	.0000	.0000	.0000	.0000	.0003	.0014	.0049	.0136	.0312	.0611	4
11	.0000	.0000	.0000	.0000	.0000	.0002	.0010	.0033	.0093	.0222	3
12	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0005	.0019	.0056	2
13	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0002	.0009	1
14	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	0
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 16

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.4401	.1853	.0743	.0281	.0100	.0033	.0010	.0003	.0001	.0000	16
1	.3706	.3294	.2097	.1126	.0535	.0228	.0087	.0030	.0009	.0002	15
2	.1463	.2745	.2775	.2111	.1336	.0732	.0353	.0150	.0056	.0018	14
3	.0359	.1423	.2285	.2463	.2079	.1465	.0888	.0468	.0215	.0085	13
4	.0061	.0514	.1311	.2001	.2252	.2040	.1553	.1014	.0572	.0278	12
5	.0008	.0137	.0555	.1201	.1802	.2099	.2008	.1623	.1123	.0667	11
6	.0001	.0028	.0180	.0550	.1101	.1649	.1982	.1983	.1684	.1222	10
7	.0000	.0004	.0045	.0197	.0524	.1010	.1524	.1889	.1969	.1746	9
8	.0000	.0001	.0009	.0055	.0197	.0487	.0923	.1417	.1812	.1964	8
9	.0000	.0000	.0001	.0012	.0058	.0185	.0442	.0840	.1318	.1746	7
10	.0000	.0000	.0000	.0002	.0014	.0056	.0167	.0392	.0755	.1222	6
11	.0000	.0000	.0000	.0000	.0002	.0013	.0049	.0142	.0337	.0667	5
12	.0000	.0000	.0000	.0000	.0000	.0002	.0011	.0040	.0115	.0278	4
13	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0008	.0029	.0085	3
14	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0005	.0018	2
15	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0002	1
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 18

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.3972	.1501	.0536	.0180	.0056	.0016	.0004	.0001	.0000	.0000	18
1	.3763	.3002	.1704	.0811	.0338	.0126	.0042	.0012	.0003	.0001	17
2	.1683	.2835	.2556	.1723	.0958	.0458	.0190	.0069	.0022	.0006	16
3	.0473	.1680	.2406	.2297	.1704	.1046	.0547	.0246	.0095	.0031	15
4	.0093	.0700	.1592	.2153	.2130	.1681	.1104	.0614	.0291	.0117	14
5	.0014	.0218	.0787	.1507	.1988	.2017	.1664	.1146	.0666	.0327	13
6	.0002	.0052	.0301	.0816	.1436	.1873	.1941	.1655	.1181	.0708	12
7	.0000	.0010	.0091	.0350	.0820	.1376	.1792	.1892	.1657	.1214	11
8	.0000	.0002	.0022	.0120	.0376	.0811	.1327	.1734	.1864	.1669	10
9	.0000	.0000	.0004	.0033	.0139	.0386	.0794	.1284	.1694	.1855	9
10	.0000	.0000	.0001	.0008	.0042	.0149	.0385	.0771	.1248	.1669	8
11	.0000	.0000	.0000	.0001	.0010	.0046	.0151	.0374	.0742	.1214	7
12	.0000	.0000	.0000	.0000	.0002	.0012	.0047	.0145	.0354	.0708	6
13	.0000	.0000	.0000	.0000	.0000	.0002	.0012	.0045	.0134	.0327	5
14	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0011	.0039	.0117	4
15	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0009	.0031	3
16	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0006	2
17	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	1
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 20

y ↓	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.3585	.1216	.0388	.0115	.0032	.0008	.0002	.0000	.0000	.0000	20
1	.3774	.2702	.1368	.0576	.0211	.0068	.0020	.0005	.0001	.0000	19
2	.1887	.2852	.2293	.1369	.0669	.0278	.0100	.0031	.0008	.0002	18
3	.0596	.1901	.2428	.2054	.1339	.0716	.0323	.0123	.0040	.0011	17
4	.0133	.0898	.1821	.2182	.1897	.1304	.0738	.0350	.0139	.0046	16
5	.0022	.0319	.1028	.1746	.2023	.1789	.1272	.0746	.0365	.0148	15
6	.0003	.0089	.0454	.1091	.1686	.1916	.1712	.1244	.0746	.0370	14
7	.0000	.0020	.0160	.0545	.1124	.1643	.1844	.1659	.1221	.0739	13
8	.0000	.0004	.0046	.0222	.0609	.1144	.1614	.1797	.1623	.1201	12
9	.0000	.0001	.0011	.0074	.0271	.0654	.1158	.1597	.1771	.1602	11
10	.0000	.0000	.0002	.0020	.0099	.0308	.0686	.1171	.1593	.1762	10
11	.0000	.0000	.0000	.0005	.0030	.0120	.0336	.0710	.1185	.1602	9
12	.0000	.0000	.0000	.0001	.0008	.0039	.0136	.0355	.0727	.1201	8
13	.0000	.0000	.0000	.0000	.0002	.0010	.0045	.0146	.0366	.0739	7
14	.0000	.0000	.0000	.0000	.0000	.0002	.0012	.0049	.0150	.0370	6
15	.0000	.0000	.0000	.0000	.0000	.0000	.0003	.0013	.0049	.0148	5
16	.0000	.0000	.0000	.0000	.0000	.0000	.0003	.0013	.0046	.0148	4
17	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0011	.0111	3
18	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0002	2
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 50

y →	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.0769	.0052	.0003	.0000	.0000	.0000	.0000	.0000	.0000	.0000	50
1	.2025	.0286	.0026	.0002	.0000	.0000	.0000	.0000	.0000	.0000	49
2	.2611	.0779	.0113	.0011	.0001	.0000	.0000	.0000	.0000	.0000	48
3	.2199	.1386	.0319	.0044	.0004	.0000	.0000	.0000	.0000	.0000	47
4	.1360	.1809	.0661	.0128	.0016	.0001	.0000	.0000	.0000	.0000	46
5	.0658	.1849	.1072	.0295	.0049	.0006	.0000	.0000	.0000	.0000	45
6	.0260	.1541	.1419	.0554	.0123	.0018	.0002	.0000	.0000	.0000	44
7	.0086	.1076	.1575	.0870	.0259	.0048	.0006	.0000	.0000	.0000	43
8	.0024	.0643	.1493	.1169	.0463	.0110	.0017	.0002	.0000	.0000	42
9	.0006	.0333	.1230	.1364	.0721	.0220	.0042	.0005	.0000	.0000	41
10	.0001	.0152	.0890	.1398	.0985	.0386	.0093	.0014	.0001	.0001	40
11	.0000	.0061	.0571	.1271	.1194	.0602	.0182	.0035	.0004	.0000	39
12	.0000	.0022	.0328	.1033	.1294	.0838	.0319	.0076	.0011	.0001	38
13	.0000	.0007	.0169	.0755	.1261	.1050	.0502	.0147	.0027	.0003	37
14	.0000	.0002	.0079	.0499	.1110	.1189	.0714	.0260	.0059	.0008	36
15	.0000	.0001	.0033	.0299	.0888	.1223	.0923	.0415	.0116	.0020	35
16	.0000	.0000	.0013	.0164	.0648	.1147	.1088	.0606	.0207	.0044	34
17	.0000	.0000	.0005	.0082	.0432	.0983	.1171	.0808	.0339	.0089	33
18	.0000	.0000	.0001	.0037	.0264	.0772	.1156	.0987	.0508	.0160	32
19	.0000	.0000	.0000	.0016	.0148	.0558	.1048	.1109	.0700	.0270	31
20	.0000	.0000	.0000	.0006	.0077	.0370	.0875	.1146	.0888	.0419	30
21	.0000	.0000	.0000	.0002	.0036	.0227	.0673	.1091	.1038	.0598	29
22	.0000	.0000	.0000	.0001	.0016	.0128	.0478	.0959	.1119	.0788	28
23	.0000	.0000	.0000	.0000	.0006	.0067	.0313	.0778	.1115	.0960	27
24	.0000	.0000	.0000	.0000	.0002	.0032	.0190	.0584	.1026	.1080	26
25	.0000	.0000	.0000	.0000	.0001	.0014	.0106	.0405	.0873	.1123	25
26	.0000	.0000	.0000	.0000	.0000	.0006	.0055	.0259	.0687	.1080	24
27	.0000	.0000	.0000	.0000	.0000	.0002	.0026	.0154	.0500	.0960	23
28	.0000	.0000	.0000	.0000	.0000	.0001	.0012	.0084	.0336	.0788	22
29	.0000	.0000	.0000	.0000	.0000	.0000	.0005	.0043	.0208	.0598	21
30	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0020	.0119	.0419	20
31	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0009	.0063	.0270	19
32	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0003	.0031	.0160	18
33	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0014	.0087	17
34	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0006	.0044	16
35	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0020	15
36	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0008	14
37	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0003	13
38	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	12
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

N = 100

y →	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
0	.0059	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	100
1	.0312	.0003	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	99
2	.0812	.0016	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	98
3	.1396	.0059	.0001	.0000	.0000	.0000	.0000	.0000	.0000	.0000	97
4	.1781	.0159	.0003	.0000	.0000	.0000	.0000	.0000	.0000	.0000	96
5	.1800	.0339	.0011	.0000	.0000	.0000	.0000	.0000	.0000	.0000	95
6	.1500	.0596	.0031	.0001	.0000	.0000	.0000	.0000	.0000	.0000	94
7	.1060	.0889	.0075	.0002	.0000	.0000	.0000	.0000	.0000	.0000	93
8	.0649	.1148	.0153	.0006	.0000	.0000	.0000	.0000	.0000	.0000	92
9	.0349	.1304	.0276	.0015	.0000	.0000	.0000	.0000	.0000	.0000	91
10	.0167	.1319	.0444	.0034	.0001	.0000	.0000	.0000	.0000	.0000	90
11	.0072	.1199	.0640	.0069	.0003	.0000	.0000	.0000	.0000	.0000	89
12	.0028	.0988	.0838	.0128	.0006	.0000	.0000	.0000	.0000	.0000	88
13	.0010	.0743	.1001	.0216	.0014	.0000	.0000	.0000	.0000	.0000	87
14	.0003	.0513	.1098	.0335	.0030	.0001	.0000	.0000	.0000	.0000	86
15	.0001	.0327	.1111	.0481	.0057	.0002	.0000	.0000	.0000	.0000	85
16	.0000	.0193	.1041	.0638	.0100	.0006	.0000	.0000	.0000	.0000	84
17	.0000	.0106	.0908	.0789	.0165	.0012	.0000	.0000	.0000	.0000	83
18	.0000	.0054	.0739	.0909	.0254	.0024	.0001	.0000	.0000	.0000	82
19	.0000	.0026	.0563	.0981	.0365	.0044	.0002	.0000	.0000	.0000	81
20	.0000	.0012	.0402	.0993	.0493	.0076	.0004	.0000	.0000	.0000	80
21	.0000	.0005	.0270	.0946	.0626	.0124	.0009	.0000	.0000	.0000	79
22	.0000	.0002	.0171	.0849	.0749	.0190	.0017	.0001	.0000	.0000	78
23	.0000	.0001	.0103	.0720	.0847	.0277	.0032	.0001	.0000	.0000	77
24	.0000	.0000	.0058	.0577	.0906	.0380	.0055	.0003	.0000	.0000	76
25	.0000	.0000	.0031	.0439	.0918	.0496	.0090	.0006	.0000	.0000	75
26	.0000	.0000	.0016	.0316	.0883	.0613	.0140	.0012	.0000	.0000	74
27	.0000	.0000	.0008	.0217	.0806	.0207	.0207	.0022	.0001	.0000	73
28	.0000	.0000	.0004	.0141	.0701	.0804	.0290	.0038	.0002	.0000	72
29	.0000	.0000	.0002	.0088	.0580	.0856	.0388	.0063	.0004	.0000	71
30	.0000	.0000	.0001	.0052	.0458	.0868	.0494	.0100	.0008	.0000	70
31	.0000	.0000	.0000	.0029	.0344	.0840	.0601	.0151	.0014	.0001	69
32	.0000	.0000	.0000	.0016	.0248	.0776	.0698	.0217	.0025	.0001	68
33	.0000	.0000	.0000	.0008	.0170	.0685	.0774	.0297	.0043	.0002	67
34	.0000	.0000	.0000	.0004	.0112	.0579	.0821	.0391	.0069	.0005	66
35	.0000	.0000	.0000	.0002	.0070	.0468	.0834	.0491	.0106	.0009	65
36	.0000	.0000	.0000	.0001	.0042	.0362	.0811	.0591	.0157	.0016	64
37	.0000	.0000	.0000	.0000	.0024	.0268	.0755	.0682	.0222	.0027	63
38	.0000	.0000	.0000	.0000	.0013	.0191	.0674	.0754	.0301	.0045	62
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

l...

N = 100

y →	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50	← p
39	.0000	.0000	.0000	.0000	.0007	.0130	.0577	.0799	.0391	.0071	61
40	.0000	.0000	.0000	.0000	.0004	.0085	.0474	.0812	.0488	.0108	60
41	.0000	.0000	.0000	.0000	.0002	.0053	.0373	.0792	.0584	.0159	59
42	.0000	.0000	.0000	.0000	.0001	.0032	.0282	.0742	.0672	.0223	58
43	.0000	.0000	.0000	.0000	.0000	.0019	.0205	.0667	.0741	.0301	57
44	.0000	.0000	.0000	.0000	.0000	.0010	.0143	.0576	.0786	.0390	56
45	.0000	.0000	.0000	.0000	.0000	.0005	.0096	.0478	.0800	.0485	55
46	.0000	.0000	.0000	.0000	.0000	.0003	.0062	.0381	.0782	.0580	54
47	.0000	.0000	.0000	.0000	.0000	.0001	.0038	.0292	.0736	.0666	53
48	.0000	.0000	.0000	.0000	.0000	.0001	.0023	.0215	.0665	.0735	52
49	.0000	.0000	.0000	.0000	.0000	.0000	.0013	.0152	.0577	.0780	51
50	.0000	.0000	.0000	.0000	.0000	.0000	.0007	.0103	.0482	.0796	50
51	.0000	.0000	.0000	.0000	.0000	.0000	.0004	.0068	.0368	.0780	49
52	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0042	.0298	.0735	48
53	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0026	.0221	.0666	47
54	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0015	.0157	.0580	46
55	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0008	.0108	.0485	45
56	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0004	.0071	.0390	44
57	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0045	.0301	43
58	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0027	.0223	42
59	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0016	.0159	41
60	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0009	.0108	40
61	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0005	.0071	39
62	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0002	.0045	38
63	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0027	37
64	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	.0016	36
65	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0009	35
66	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0005	34
67	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0002	33
68	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	32
69	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0000	.0001	31
p →	0.95	0.90	0.85	0.80	0.75	0.70	0.65	0.60	0.55	0.50	y ↑

■ Tabela 2. Funções de Distribuição para Distribuições de Poisson (λ)

Os valores tabelados correspondem às probabilidades acumuladas

$$F(y) = \sum_{u=0}^y e^{-\lambda} \cdot \lambda^u / u!$$

para diferentes valores do parâmetro λ .

		λ									
$y \downarrow$		0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
0	0.9048	0.8187	0.7408	0.6703	0.6065	0.5488	0.4966	0.4493	0.4066	0.3679	
1	0.9953	0.9825	0.9631	0.9384	0.9098	0.8781	0.8442	0.8088	0.7725	0.7358	
2	0.9998	0.9989	0.9964	0.9921	0.9856	0.9769	0.9659	0.9526	0.9371	0.9197	
3	1.0000	0.9999	0.9997	0.9992	0.9982	0.9966	0.9942	0.9909	0.9865	0.9810	
4	1.0000	1.0000	1.0000	0.9999	0.9998	0.9996	0.9992	0.9986	0.9977	0.9963	
5	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9998	0.9997	0.9994	
6	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	

		λ									
$y \downarrow$		1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	2.0
0	0.3329	0.3012	0.2725	0.2466	0.2231	0.2019	0.1827	0.1653	0.1496	0.1353	
1	0.6990	0.6626	0.6268	0.5918	0.5578	0.5249	0.4932	0.4628	0.4337	0.4060	
2	0.9004	0.8795	0.8571	0.8335	0.8088	0.7834	0.7572	0.7306	0.7037	0.6767	
3	0.9743	0.9662	0.9569	0.9463	0.9344	0.9212	0.9068	0.8913	0.8747	0.8571	
4	0.9946	0.9923	0.9893	0.9857	0.9814	0.9763	0.9704	0.9636	0.9559	0.9473	
5	0.9990	0.9985	0.9978	0.9968	0.9955	0.9940	0.9920	0.9896	0.9868	0.9834	
6	0.9999	0.9997	0.9996	0.9994	0.9991	0.9987	0.9981	0.9974	0.9966	0.9955	
7	1.0000	1.0000	0.9999	0.9999	0.9998	0.9997	0.9996	0.9994	0.9992	0.9989	
8	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9999	0.9998	0.9998	

		λ									
$y \downarrow$		2.1	2.2	2.3	2.4	2.5	2.6	2.7	2.8	2.9	3.0
0	0.1225	0.1108	0.1003	0.0907	0.0821	0.0743	0.0672	0.0608	0.0550	0.0498	
1	0.3796	0.3546	0.3309	0.3084	0.2873	0.2674	0.2487	0.2311	0.2146	0.1991	
2	0.6496	0.6227	0.5960	0.5697	0.5438	0.5184	0.4936	0.4695	0.4460	0.4232	
3	0.8386	0.8194	0.7993	0.7787	0.7576	0.7360	0.7141	0.6919	0.6696	0.6472	
4	0.9397	0.9275	0.9162	0.9041	0.8912	0.8774	0.8629	0.8477	0.8318	0.8153	
5	0.9796	0.9751	0.9700	0.9643	0.9580	0.9510	0.9433	0.9349	0.9258	0.9161	
6	0.9941	0.9925	0.9906	0.9884	0.9858	0.9828	0.9794	0.9756	0.9713	0.9665	
7	0.9985	0.9980	0.9974	0.9967	0.9958	0.9947	0.9934	0.9919	0.9901	0.9881	
8	0.9997	0.9995	0.9994	0.9991	0.9989	0.9985	0.9981	0.9976	0.9969	0.9962	
9	0.9999	0.9999	0.9999	0.9998	0.9997	0.9996	0.9995	0.9993	0.9991	0.9989	
10	1.0000	1.0000	1.0000	1.0000	0.9999	0.9999	0.9999	0.9998	0.9998	0.9997	
11	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9999	


		λ									
$y \downarrow$		3.1	3.2	3.3	3.4	3.5	3.6	3.7	3.8	3.9	4.0
0	0.0450	0.0408	0.0369	0.0334	0.0302	0.0273	0.0247	0.0224	0.0202	0.0183	
1	0.1847	0.1712	0.1586	0.1468	0.1359	0.1257	0.1162	0.1074	0.0992	0.0916	
2	0.4012	0.3799	0.3594	0.3397	0.3208	0.3027	0.2854	0.2689	0.2531	0.2381	
3	0.6248	0.6025	0.5803	0.5584	0.5366	0.5152	0.4942	0.4732	0.4532	0.4335	
4	0.7982	0.7982	0.7806	0.7442	0.7254	0.7064	0.6872	0.6678	0.6484	0.6288	
5	0.9057	0.8946	0.8829	0.8705	0.8576	0.8441	0.8301	0.8156	0.8006	0.7851	
6	0.9612	0.9554	0.9490	0.9421	0.9347	0.9267	0.9182	0.9091	0.8995	0.8893	
7	0.9858	0.9832	0.9802	0.9769	0.9733	0.9692	0.9648	0.9599	0.9546	0.9489	
8	0.9953	0.9943	0.9931	0.9917	0.9901	0.9883	0.9863	0.9840	0.9815	0.9786	
9	0.9986	0.9982	0.9978	0.9973	0.9967	0.9960	0.9952	0.9942	0.9931	0.9919	
10	0.9996	0.9995	0.9994	0.9992	0.9990	0.9987	0.9984	0.9981	0.9977	0.9972	
11	0.9999	0.9999	0.9998	0.9998	0.9997	0.9996	0.9995	0.9994	0.9993	0.9991	
12	1.0000	1.0000	1.0000	0.9999	0.9999	0.9999	0.9999	0.9998	0.9998	0.9997	
13	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9999	

		λ									
$y \downarrow$		4.1	4.2	4.3	4.4	4.5	4.6	4.7	4.8	4.9	5.0
0	0.0166	0.0150	0.0136	0.0123	0.0111	0.0101	0.0091	0.0082	0.0071	0.0067	
1	0.0845	0.0780	0.0719	0.0663	0.0611	0.0563	0.0518	0.0477	0.0439	0.0404	
2	0.2238	0.2102	0.1974	0.1851	0.1736	0.1626	0.1536	0.1425	0.1333	0.1247	
3	0.4142	0.3954	0.3772	0.3594	0.3423	0.3257	0.3097	0.2942	0.2793	0.2650	
4	0.6093	0.5898	0.5704	0.5512	0.5321	0.5132	0.4946	0.4763	0.4582	0.4405	
5	0.7693	0.7531	0.7367	0.7199	0.7029	0.6858	0.6684	0.6510	0.6335	0.6160	
6	0.8786	0.8675	0.8558	0.8436	0.8311	0.8180	0.8046	0.7908	0.7767	0.7622	
7	0.9427	0.9361	0.9290	0.9214	0.9134	0.9049	0.8960	0.8867	0.8769	0.8666	
8	0.9755	0.9721	0.9683	0.9642	0.9597	0.9549	0.9497	0.9442	0.9382	0.9319	
9	0.9905	0.9889	0.9871	0.9851	0.9829	0.9805	0.9778	0.9749	0.9717	0.9682	
10	0.9966	0.9959	0.9952	0.9943	0.9933	0.9922	0.9910	0.9896	0.9880	0.9863	
11	0.9989	0.9986	0.9983	0.9980	0.9976	0.9971	0.9966	0.9960	0.9953	0.9945	
12	0.9997	0.9996	0.9995	0.9993	0.9992	0.9990	0.9988	0.9986	0.9983	0.9980	
13	0.9999	0.9999	0.9998	0.9998	0.9997	0.9997	0.9996	0.9995	0.9994	0.9993	
14	1.0000	1.0000	1.0000	0.9999	0.9999	0.9999	0.9999	0.9999	0.9998	0.9998	
15	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9999	0.9999	

	λ									
$y \downarrow$	5.5	6.0	6.5	7.0	7.5	8.0	8.5	9.0	9.5	10.0
0	0.0041	0.0025	0.0015	0.0009	0.0006	0.0003	0.0002	0.0001	0.0001	0.0000
1	0.0266	0.0174	0.0113	0.0073	0.0047	0.0030	0.0019	0.0012	0.0008	0.0005
2	0.0884	0.0620	0.0430	0.0296	0.0203	0.0138	0.0093	0.0062	0.0042	0.0028
3	0.2017	0.1512	0.1118	0.0818	0.0591	0.0424	0.0301	0.0212	0.0149	0.0103
4	0.3575	0.2851	0.2237	0.1730	0.1321	0.0996	0.0744	0.0550	0.0403	0.0293
5	0.5289	0.4457	0.3690	0.3007	0.2414	0.1912	0.1496	0.1157	0.0885	0.0671
6	0.6860	0.6063	0.5265	0.4497	0.3782	0.3134	0.2562	0.2068	0.1649	0.1301
7	0.8095	0.7440	0.6728	0.5987	0.5246	0.4530	0.3856	0.3239	0.2687	0.2202
8	0.8944	0.8472	0.7916	0.7291	0.6620	0.5925	0.5231	0.4557	0.3918	0.3328
9	0.9462	0.9161	0.8774	0.8305	0.7764	0.7166	0.6530	0.5874	0.5218	0.4579
10	0.9747	0.9574	0.9332	0.9015	0.8622	0.8159	0.7634	0.7060	0.6453	0.5830
11	0.9890	0.9799	0.9661	0.9467	0.9208	0.8881	0.8487	0.8030	0.7520	0.6968
12	0.9955	0.9912	0.9840	0.9730	0.9573	0.9362	0.9091	0.8758	0.8364	0.7916
13	0.9983	0.9964	0.9929	0.9872	0.9784	0.9658	0.9486	0.9261	0.8981	0.8645
14	0.9994	0.9986	0.9970	0.9943	0.9897	0.9827	0.9726	0.9585	0.9400	0.9165
15	0.9998	0.9995	0.9988	0.9976	0.9954	0.9918	0.9862	0.9780	0.9665	0.9513
16	0.9999	0.9998	0.9996	0.9990	0.9980	0.9963	0.9934	0.9889	0.9823	0.9730
17	1.0000	0.9999	0.9998	0.9996	0.9992	0.9984	0.9970	0.9947	0.9911	0.9857
18	1.0000	1.0000	0.9999	0.9999	0.9997	0.9993	0.9987	0.9976	0.9957	0.9928
19	1.0000	1.0000	1.0000	1.0000	0.9999	0.9997	0.9995	0.9989	0.9980	0.9965
20	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9998	0.9996	0.9991	0.9984
21	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9998	0.9996	0.9993
22	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9999	0.9999	0.9997
23	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.9999	0.9999	0.9999

■ Tabela 3. Probabilidades Associadas à Cauda Direita da Distribuição Normal Padronizada


Os valores tabelados correspondem à área α assinalada na Figura: $P\{Z \geq z(\alpha)\} = \alpha$.



$Z(\alpha) = a + b$										
$a \downarrow$	$b \rightarrow$									
	0.0	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.4960	0.4920	0.4880	0.4840	0.4801	0.4761	0.4721	0.4681	0.4641
0.1	0.4602	0.4562	0.4522	0.4483	0.4443	0.4404	0.4364	0.4325	0.4286	0.4247
0.2	0.4207	0.4168	0.4129	0.4090	0.4052	0.4013	0.3974	0.3936	0.3897	0.3859
0.3	0.3821	0.3783	0.3745	0.3707	0.3669	0.3632	0.3594	0.3557	0.3520	0.3483
0.4	0.3446	0.3409	0.3372	0.3336	0.3300	0.3264	0.3228	0.3192	0.3156	0.3121
0.5	0.3085	0.3050	0.3015	0.2981	0.2946	0.2912	0.2877	0.2843	0.2810	0.2776
0.6	0.2743	0.2709	0.2676	0.2643	0.2611	0.2578	0.2546	0.2514	0.2483	0.2451
0.7	0.2420	0.2389	0.2358	0.2327	0.2296	0.2266	0.2236	0.2206	0.2177	0.2148
0.8	0.2119	0.2090	0.2061	0.2033	0.2005	0.1977	0.1949	0.1921	0.1894	0.1867
0.9	0.1841	0.1814	0.1788	0.1762	0.1736	0.1711	0.1685	0.1660	0.1635	0.1611
1.0	0.1587	0.1562	0.1539	0.1515	0.1492	0.1469	0.1446	0.1423	0.1401	0.1379
1.1	0.1357	0.1335	0.1314	0.1292	0.1271	0.1251	0.1230	0.1210	0.1190	0.1170
1.2	0.1151	0.1131	0.1112	0.1093	0.1075	0.1056	0.1038	0.1020	0.1003	0.0985
1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823
1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
1.6	0.0548	0.0537	0.0526	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
2.1	0.0179	0.0174	0.0170	0.0166	0.0162	0.0158	0.0154	0.0150	0.0146	0.0143
2.2	0.0139	0.0136	0.0132	0.0129	0.0125	0.0122	0.0119	0.0116	0.0113	0.0110
2.3	0.0107	0.0104	0.0102	0.0099	0.0096	0.0094	0.0091	0.0089	0.0087	0.0084
2.4	0.0082	0.0080	0.0078	0.0075	0.0073	0.0071	0.0069	0.0068	0.0066	0.0064
2.5	0.0062	0.0060	0.0059	0.0057	0.0055	0.0054	0.0052	0.0051	0.0049	0.0048
2.6	0.0047	0.0045	0.0044	0.0043	0.0041	0.0040	0.0039	0.0038	0.0037	0.0036
2.7	0.0035	0.0034	0.0033	0.0032	0.0031	0.0030	0.0029	0.0028	0.0027	0.0026
2.8	0.0026	0.0025	0.0024	0.0023	0.0023	0.0022	0.0021	0.0021	0.0020	0.0019
2.9	0.0019	0.0018	0.0017	0.0017	0.0016	0.0016	0.0015	0.0015	0.0014	0.0014
3.0	0.00135	0.00131	0.00126	0.00122	0.00118	0.00114	0.00111	0.00107	0.00104	0.00100

■ Tabela 4. Valores Críticos de Distribuições χ^2_{GL}


Na tabela registam-se os valores $\chi^2_{GL}(\alpha)$ tais que $\alpha = \int_{\chi^2_{GL}(\alpha)}^{\infty} f(u) \cdot du$.



GL ↓	α												
	0.995	0.990	0.975	0.950	0.900	0.750	0.500	0.250	0.100	0.050	0.025	0.010	0.005
1	0.000	0.000	0.001	0.004	0.015	0.102	0.455	1.323	2.71	3.84	5.02	6.63	7.88
2	0.010	0.020	0.050	0.103	0.211	0.575	1.386	2.77	4.61	5.99	7.38	9.21	10.60
3	0.072	0.115	0.216	0.352	0.584	1.213	2.37	4.11	6.25	7.81	9.35	11.34	12.84
4	0.207	0.297	0.484	0.711	1.064	1.923	3.36	5.39	7.78	9.49	11.14	13.28	14.86
5	0.412	0.554	0.831	1.145	1.61	2.67	4.35	6.63	9.24	11.07	12.83	15.09	16.75
6	0.676	0.872	1.24	1.64	2.20	3.45	5.35	7.84	10.64	12.59	14.45	16.81	18.55
7	0.989	1.24	1.69	2.17	2.83	4.25	6.35	9.04	12.02	14.07	16.01	18.48	20.28
8	1.34	1.65	2.18	2.73	3.49	5.07	7.34	10.22	13.36	15.51	17.53	20.09	21.96
9	1.73	2.09	2.70	3.33	4.17	5.90	8.34	11.39	14.68	16.92	19.02	21.67	23.59
10	2.16	2.56	3.25	3.94	4.87	6.74	9.34	12.55	15.99	18.31	20.48	23.21	25.19
11	2.60	3.05	3.82	4.57	5.58	7.58	10.34	13.70	17.28	19.68	21.92	24.73	26.76
12	3.07	3.57	4.40	5.23	6.30	8.44	11.34	14.85	18.55	21.03	23.34	26.22	28.30
13	3.57	4.11	5.01	5.89	7.04	9.30	12.34	15.98	19.81	22.36	24.74	27.69	29.82
14	4.07	4.66	5.63	6.57	7.79	10.17	13.34	17.12	21.06	23.68	26.12	29.14	31.32
15	4.60	5.23	6.26	7.26	8.55	11.04	14.34	18.25	22.31	25.00	27.49	30.58	32.80
16	5.14	5.81	6.91	7.96	9.31	11.91	15.34	19.37	23.54	26.30	28.85	32.00	34.27
17	5.70	6.41	7.56	8.67	10.09	12.79	16.34	20.49	24.77	27.59	30.19	33.41	35.72
18	6.26	7.01	8.23	9.39	10.86	13.68	17.34	21.60	25.99	28.87	31.53	34.81	37.16
19	6.84	7.63	8.91	10.12	11.65	14.56	18.34	22.72	27.20	30.14	32.85	36.19	38.58
20	7.43	8.26	9.59	10.85	12.44	15.45	19.34	23.83	28.41	31.41	34.17	37.57	40.00
21	8.03	8.90	10.28	11.59	13.24	16.34	20.34	24.93	29.62	32.67	35.48	38.93	41.40
22	8.64	9.54	10.98	12.34	14.04	17.24	21.34	26.04	30.81	33.92	36.78	40.29	42.80
23	9.26	10.20	11.69	13.09	14.85	18.14	22.34	27.14	32.01	35.17	38.08	41.64	44.18
24	9.89	10.86	12.40	13.85	15.66	19.04	23.34	28.24	33.20	36.42	39.36	42.98	45.56
25	10.52	11.52	13.12	14.61	16.47	19.94	24.34	29.34	34.38	37.65	40.65	44.31	46.93
26	11.16	12.20	13.84	15.38	17.29	20.84	25.34	30.43	35.56	38.89	41.92	45.64	48.29
27	11.81	12.88	14.57	16.15	18.11	21.75	26.34	31.53	36.74	40.11	43.19	46.96	49.64
28	12.46	13.56	15.31	16.93	18.94	22.65	27.34	32.62	37.92	41.34	44.46	48.28	50.99
29	13.12	14.26	16.05	17.71	19.77	23.57	28.34	33.71	39.09	42.56	45.72	49.59	52.34
30	13.79	14.95	16.79	18.49	20.60	24.48	29.34	34.80	40.26	43.77	46.98	50.89	53.67
40	20.71	22.16	24.43	26.51	29.05	33.66	39.34	45.62	51.81	55.76	59.34	63.69	66.77
50	27.99	29.71	32.36	34.76	37.69	42.94	49.33	56.33	63.17	67.50	71.42	76.15	79.49
60	35.53	37.48	40.48	43.19	46.46	52.29	59.33	66.98	74.40	79.08	83.30	88.38	91.95
70	43.28	45.44	48.76	51.74	55.33	61.70	69.33	77.58	85.53	90.53	95.02	100.4	104.2
80	51.17	53.54	57.15	60.39	64.28	71.14	79.33	88.13	96.58	101.8	106.6	112.3	116.3
90	59.20	61.75	65.65	69.13	73.29	80.62	89.33	98.65	107.5	113.1	118.1	124.1	128.3
100	67.33	70.06	74.22	77.93	82.36	90.13	99.33	109.1	118.5	124.3	129.5	135.8	140.1

■ Tabela 5. Probabilidades Associadas à Cauda Direita de Distribuições t_{GL}


Na tabela registam-se os valores $t_{GL}(\alpha)$ tais que $\alpha = \int_{t_{GL}(\alpha)}^{\infty} f(u) \cdot du$.



	α								
GL 1	0.25	0.20	0.15	0.10	0.05	0.025	0.010	0.005	0.0005
1	1.000	1.376	1.963	3.078	6.314	12.706	31.821	63.657	636.619
2	.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	31.598
3	.765	.978	1.250	1.638	2.353	3.182	4.541	5.841	12.941
4	.741	.941	1.190	1.533	2.132	2.776	3.747	4.604	8.610
5	.727	.920	1.156	1.476	2.015	2.571	3.365	4.032	6.859
6	.718	.906	1.134	1.440	1.943	2.447	3.143	3.707	5.959
7	.711	.896	1.119	1.415	1.895	2.365	2.998	3.499	5.405
8	.706	.889	1.108	1.397	1.860	2.306	2.896	3.355	5.041
9	.703	.883	1.100	1.383	1.833	2.262	2.821	3.250	4.781
10	.700	.879	1.093	1.372	1.812	2.228	2.764	3.169	4.587
11	.697	.876	1.088	1.363	1.796	2.201	2.718	3.106	4.457
12	.695	.873	1.083	1.356	1.782	2.179	2.681	3.055	4.318
13	.694	.870	1.079	1.350	1.771	2.160	2.650	3.012	4.221
14	.692	.868	1.076	1.345	1.761	2.145	2.624	2.977	4.140
15	.691	.866	1.074	1.341	1.753	2.131	2.602	2.947	4.073
16	.690	.865	1.071	1.337	1.746	2.120	2.583	2.921	4.015
17	.689	.863	1.069	1.333	1.740	2.110	2.567	2.898	3.965
18	.688	.862	1.067	1.330	1.734	2.101	2.552	2.878	3.922
19	.688	.861	1.066	1.328	1.729	2.093	2.539	2.861	3.883
20	.687	.860	1.064	1.325	1.725	2.086	2.528	2.845	3.850
21	.686	.859	1.063	1.323	1.721	2.080	2.518	2.831	3.819
22	.686	.858	1.061	1.321	1.717	2.074	2.508	2.819	3.792
23	.685	.858	1.060	1.319	1.714	2.069	2.500	2.807	3.767
24	.685	.857	1.059	1.318	1.711	2.064	2.492	2.797	3.745
25	.684	.856	1.058	1.316	1.708	2.060	2.485	2.487	3.725
26	.684	.856	1.058	1.315	1.706	2.056	2.479	2.779	3.707
27	.684	.855	1.057	1.314	1.703	2.052	2.473	2.771	3.690
28	.683	.855	1.056	1.314	1.701	2.048	2.467	2.763	3.674
29	.683	.854	1.055	1.311	1.699	2.045	2.462	2.756	3.659
30	.683	.854	1.055	1.310	1.697	2.042	2.457	2.750	3.646
40	.681	.851	1.050	1.303	1.684	2.021	2.423	2.704	3.551
60	.679	.848	1.046	1.296	1.671	2.000	2.390	2.660	3.460
120	.677	.845	1.041	1.289	1.658	1.980	2.358	2.617	3.373
∞	.674	.842	1.036	1.282	1.645	1.960	2.326	2.576	3.291

■ Tabela 6. Probabilidades Associadas à Cauda Direita de Distribuições F_{GL_1, GL_2}

Na tabela registam-se os valores $F_{GL_1, GL_2}(\alpha)$ tais que $\alpha = \int_{F_{GL_1, GL_2}(\alpha)}^{\infty} f(u) \cdot d u$.



$\alpha = 10\%$	$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
1	39.9	49.5	53.6	55.8	57.2	58.2	58.9	59.4	59.9	60.2	60.5	60.7	61.1	61.3	61.6	61.7	62.1	62.3	62.5	62.7	63.0	63.1	63.2	
2	8.53	9.00	9.16	9.24	9.29	9.33	9.35	9.37	9.38	9.39	9.40	9.41	9.42	9.43	9.44	9.44	9.45	9.46	9.47	9.47	9.48	9.48	9.49	
3	5.54	5.46	5.39	5.34	5.31	5.28	5.27	5.25	5.24	5.23	5.22	5.22	5.20	5.20	5.19	5.18	5.17	5.17	5.16	5.15	5.14	5.14	5.14	
4	4.54	4.32	4.19	4.11	4.05	4.01	3.98	3.95	3.94	3.92	3.91	3.90	3.88	3.86	3.85	3.84	3.83	3.82	3.80	3.78	3.77	3.77	3.77	
5	4.06	3.78	3.62	3.52	3.45	3.40	3.37	3.34	3.32	3.30	3.28	3.27	3.25	3.23	3.22	3.21	3.19	3.17	3.16	3.15	3.13	3.12	3.12	
6	3.78	3.46	3.29	3.18	3.11	3.05	3.01	2.98	2.96	2.94	2.92	2.90	2.88	2.86	2.85	2.84	2.81	2.80	2.78	2.77	2.75	2.74	2.73	
7	3.59	3.26	3.07	2.96	2.88	2.83	2.78	2.75	2.72	2.70	2.68	2.67	2.64	2.62	2.61	2.59	2.57	2.56	2.54	2.52	2.50	2.49	2.48	
8	3.46	3.11	2.92	2.81	2.73	2.67	2.62	2.59	2.56	2.54	2.52	2.50	2.48	2.45	2.44	2.42	2.40	2.38	2.36	2.35	2.32	2.31	2.31	
9	3.36	3.01	2.81	2.69	2.61	2.55	2.51	2.47	2.44	2.42	2.40	2.38	2.35	2.33	2.31	2.30	2.27	2.25	2.23	2.22	2.19	2.18	2.17	
10	3.29	2.92	2.73	2.61	2.52	2.46	2.41	2.38	2.35	2.32	2.30	2.28	2.26	2.23	2.22	2.20	2.17	2.16	2.13	2.12	2.09	2.08	2.07	
11	3.23	2.86	2.66	2.54	2.45	2.39	2.34	2.30	2.27	2.25	2.23	2.21	2.18	2.16	2.14	2.12	2.10	2.08	2.05	2.04	2.01	1.99	1.99	
12	3.18	2.81	2.61	2.48	2.39	2.33	2.28	2.24	2.21	2.19	2.17	2.15	2.12	2.09	2.08	2.06	2.03	2.01	1.99	1.97	1.94	1.93	1.92	
13	3.14	2.76	2.56	2.43	2.35	2.28	2.23	2.20	2.16	2.14	2.12	2.10	2.07	2.04	2.02	2.01	1.98	1.96	1.93	1.92	1.88	1.87	1.86	
14	3.10	2.73	2.52	2.39	2.31	2.24	2.19	2.15	2.12	2.10	2.07	2.05	2.02	2.00	1.98	1.96	1.93	1.91	1.89	1.87	1.83	1.82	1.82	
15	3.07	2.70	2.49	2.36	2.27	2.21	2.16	2.12	2.09	2.06	2.04	2.02	1.99	1.96	1.94	1.92	1.89	1.87	1.85	1.83	1.79	1.78	1.77	
16	3.05	2.67	2.46	2.33	2.24	2.16	2.13	2.09	2.06	2.03	2.01	1.99	1.95	1.93	1.91	1.89	1.86	1.84	1.81	1.79	1.76	1.74	1.74	
17	3.03	2.64	2.44	2.31	2.22	2.15	2.10	2.06	2.03	2.00	1.98	1.96	1.93	1.90	1.88	1.86	1.83	1.81	1.78	1.76	1.73	1.71	1.71	
18	3.01	2.62	2.42	2.29	2.20	2.13	2.08	2.04	2.00	1.98	1.95	1.93	1.90	1.87	1.85	1.84	1.80	1.78	1.75	1.74	1.70	1.68	1.68	
19	2.99	2.61	2.40	2.27	2.18	2.11	2.06	2.02	1.98	1.96	1.93	1.91	1.88	1.85	1.83	1.81	1.78	1.76	1.73	1.71	1.67	1.66	1.65	
20	2.97	2.59	2.38	2.25	2.16	2.09	2.04	2.00	1.96	1.94	1.91	1.89	1.86	1.83	1.81	1.79	1.76	1.74	1.71	1.69	1.65	1.64	1.63	
21	2.96	2.57	2.36	2.23	2.14	2.08	2.02	1.98	1.95	1.92	1.90	1.87	1.84	1.81	1.79	1.78	1.74	1.72	1.69	1.67	1.63	1.62	1.61	
22	2.95	2.56	2.35	2.22	2.13	2.06	2.01	1.97	1.93	1.90	1.88	1.86	1.83	1.80	1.78	1.76	1.73	1.70	1.67	1.65	1.61	1.60	1.59	
23	2.94	2.55	2.34	2.21	2.11	2.05	1.99	1.95	1.92	1.89	1.87	1.84	1.81	1.78	1.76	1.74	1.71	1.69	1.66	1.64	1.59	1.58	1.57	
24	2.93	2.54	2.33	2.19	2.10	2.04	1.98	1.94	1.91	1.88	1.85	1.83	1.80	1.77	1.75	1.73	1.70	1.67	1.64	1.62	1.56	1.56	1.56	
25	2.92	2.53	2.32	2.18	2.09	2.02	1.97	1.93	1.89	1.87	1.84	1.82	1.79	1.76	1.74	1.72	1.68	1.66	1.63	1.61	1.56	1.55	1.54	
26	2.91	2.52	2.31	2.17	2.08	2.01	1.96	1.92	1.88	1.86	1.83	1.81	1.77	1.75	1.72	1.71	1.67	1.65	1.61	1.59	1.55	1.54	1.53	
27	2.90	2.51	2.30	2.17	2.07	2.00	1.95	1.91	1.87	1.85	1.82	1.80	1.76	1.74	1.71	1.70	1.66	1.64	1.60	1.58	1.54	1.52	1.52	
28	2.89	2.50	2.29	2.16	2.06	2.00	1.94	1.90	1.87	1.84	1.81	1.79	1.75	1.73	1.70	1.69	1.65	1.63	1.59	1.57	1.53	1.51	1.50	
29	2.89	2.50	2.28	2.15	2.06	1.99	1.93	1.89	1.86	1.83	1.80	1.78	1.75	1.72	1.69	1.68	1.64	1.62	1.58	1.56	1.52	1.50	1.49	
30	2.88	2.49	2.28	2.14	2.05	1.98	1.93	1.88	1.85	1.82	1.79	1.77	1.74	1.71	1.69	1.67	1.63	1.61	1.57	1.55	1.51	1.49	1.48	

$GL_1 \uparrow$

GL_1 : Número de graus de liberdade do numerador.
 GL_2 : Número de graus de liberdade do denominador.

$\alpha = 10\%$ (conclusão)

$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
32	2.87	2.48	2.26	2.13	2.04	1.97	1.91	1.87	1.83	1.81	1.78	1.76	1.72	1.69	1.67	1.65	1.62	1.59	1.56	1.53	1.49	1.47	1.46
34	2.86	2.47	2.25	2.12	2.02	1.96	1.90	1.86	1.82	1.79	1.77	1.75	1.71	1.68	1.66	1.64	1.60	1.58	1.54	1.52	1.47	1.46	1.45
36	2.85	2.46	2.24	2.11	2.01	1.94	1.89	1.85	1.81	1.78	1.76	1.73	1.70	1.67	1.65	1.63	1.59	1.56	1.53	1.51	1.46	1.44	1.43
38	2.84	2.45	2.23	2.10	2.01	1.94	1.88	1.84	1.80	1.77	1.75	1.72	1.59	1.66	1.63	1.61	1.58	1.55	1.52	1.49	1.45	1.43	1.42
40	2.84	2.44	2.23	2.09	2.00	1.93	1.87	1.83	1.79	1.76	1.74	1.71	1.68	1.65	1.62	1.61	1.57	1.54	1.51	1.48	1.43	1.42	1.41
42	2.83	2.43	2.22	2.08	1.99	1.92	1.86	1.82	1.78	1.75	1.73	1.71	1.67	1.64	1.62	1.60	1.56	1.53	1.50	1.47	1.42	1.40	1.40
44	2.82	2.43	2.21	2.08	1.98	1.91	1.86	1.81	1.78	1.75	1.72	1.70	1.66	1.63	1.61	1.59	1.55	1.52	1.49	1.46	1.41	1.39	1.39
46	2.82	2.42	2.21	2.07	1.98	1.91	1.85	1.81	1.77	1.74	1.71	1.69	1.65	1.63	1.60	1.58	1.54	1.52	1.48	1.46	1.40	1.39	1.38
48	2.81	2.42	2.20	2.07	1.97	1.90	1.85	1.80	1.77	1.73	1.71	1.69	1.65	1.62	1.59	1.57	1.54	1.51	2.47	1.45	1.40	1.38	1.37
50	2.81	2.41	2.20	2.06	1.97	1.90	1.84	1.80	1.76	1.73	1.70	1.68	1.64	1.61	1.59	1.57	1.53	1.50	1.46	1.44	1.39	1.37	1.36
60	2.79	2.39	2.18	2.04	1.95	1.87	1.82	1.77	1.74	1.71	1.68	1.66	1.62	1.59	1.56	1.54	1.50	1.48	1.44	1.41	1.36	1.34	1.33
70	2.78	2.38	2.16	2.03	1.93	1.86	1.80	1.76	1.72	1.69	1.66	1.64	1.60	1.57	1.55	1.53	1.49	1.46	1.42	1.39	1.34	1.31	1.30
80	2.77	2.37	2.15	2.02	1.92	1.85	1.79	1.75	1.71	1.68	1.65	1.63	1.59	1.56	1.53	1.51	1.47	1.44	1.40	1.38	1.32	1.30	1.28
90	2.76	2.36	2.15	2.01	1.91	1.84	1.78	1.74	1.70	1.67	1.64	1.62	1.58	1.55	1.52	1.50	1.46	1.43	1.39	1.35	1.30	1.28	1.27
100	2.76	2.36	2.14	2.00	1.91	1.83	1.78	1.73	1.69	1.66	1.64	1.61	1.57	1.54	1.52	1.49	1.45	1.42	1.38	1.35	1.29	1.27	1.26
125	2.75	2.35	2.13	1.99	1.89	1.82	1.77	1.72	1.68	1.65	1.62	1.60	1.56	1.53	1.50	1.46	1.44	1.41	1.36	1.34	1.27	1.25	1.23
150	2.74	2.34	2.12	1.98	1.89	1.81	1.76	1.71	1.67	1.64	1.61	1.59	1.55	1.52	1.49	1.47	1.43	1.40	1.35	1.33	1.26	1.23	1.22
200	2.73	2.33	2.11	1.97	1.88	1.80	1.75	1.70	1.66	1.63	1.60	1.58	1.54	1.51	1.48	1.46	1.41	1.38	1.34	1.31	1.24	1.21	1.20
300	2.72	2.32	2.10	1.96	1.87	1.79	1.74	1.69	1.65	1.62	1.59	1.57	1.53	1.49	1.47	1.45	1.40	1.37	1.32	1.29	1.22	1.19	1.18
500	2.72	2.31	2.09	1.96	1.86	1.79	1.73	1.68	1.64	1.61	1.58	1.56	1.52	1.49	1.46	1.44	1.39	1.36	1.31	1.28	1.21	1.18	1.16

GL_1 : Número de graus de liberdade do numerador.
 GL_2 : Número de graus de liberdade do denominador.

$\alpha = 5.0\%$

$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
1	161	200	216	225	230	234	237	239	241	242	243	244	245	246	247	248	249	250	251	252	253	253	254
2	18.5	19.0	19.2	19.2	19.3	19.3	19.4	19.4	19.4	19.4	19.4	19.4	19.4	19.4	19.4	19.4	19.5	19.5	19.5	19.5	19.5	19.5	19.5
3	10.1	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.76	8.74	8.71	8.69	8.67	8.66	8.63	8.62	8.59	8.58	8.55	8.54	8.54
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.94	5.91	5.87	5.84	5.82	5.80	5.77	5.75	5.72	5.70	5.66	5.65	5.65
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.70	4.68	4.64	4.60	4.58	4.56	4.52	4.50	4.46	4.44	4.41	4.39	4.39
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.03	4.00	3.96	3.92	3.90	3.87	3.83	3.81	3.77	3.75	3.71	3.70	3.69
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.60	3.57	3.53	3.49	3.47	3.44	3.40	3.38	3.34	3.32	3.27	3.26	3.25
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.31	3.28	3.24	3.20	3.17	3.15	3.11	3.08	3.04	3.02	2.97	2.96	2.95
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.10	3.07	3.03	2.99	2.96	2.94	2.89	2.86	2.83	2.80	2.76	2.74	2.73
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.94	2.91	2.86	2.83	2.80	2.77	2.73	2.70	2.66	2.64	2.59	2.57	2.56
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.82	2.79	2.74	2.70	2.67	2.65	2.60	2.57	2.53	2.51	2.46	2.44	2.43
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.72	2.69	2.64	2.60	2.57	2.54	2.50	2.47	2.43	2.40	2.35	2.33	2.32
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.63	2.60	2.55	2.51	2.48	2.46	2.41	2.38	2.34	2.31	2.26	2.24	2.23
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.57	2.53	2.48	2.44	2.41	2.39	2.34	2.31	2.27	2.24	2.19	2.17	2.16
15	4.54	3.68	3.29	3.05	2.90	2.79	2.71	2.64	2.59	2.54	2.51	2.48	2.42	2.38	2.35	2.33	2.28	2.25	2.20	2.18	2.12	2.10	2.10
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.46	2.42	2.37	2.33	2.30	2.28	2.23	2.19	2.15	2.12	2.07	2.05	2.04
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.41	2.38	2.33	2.29	2.26	2.23	2.18	2.15	2.10	2.08	2.02	2.00	1.99
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.37	2.34	2.29	2.25	2.22	2.19	2.14	2.11	2.06	2.04	1.98	1.96	1.95
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42	2.38	2.34	2.31	2.26	2.21	2.18	2.16	2.11	2.07	2.03	2.00	1.94	1.92	1.91
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.31	2.28	2.22	2.18	2.15	2.12	2.07	2.04	1.99	1.97	1.91	1.89	1.88
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37	2.32	2.28	2.25	2.20	2.16	2.12	2.10	2.05	2.01	1.96	1.94	1.88	1.86	1.84
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34	2.30	2.26	2.23	2.17	2.13	2.10	2.07	2.02	1.98	1.94	1.91	1.85	1.83	1.82
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32	2.27	2.24	2.20	2.15	2.11	2.08	2.05	2.00	1.96	1.91	1.88	1.82	1.80	1.79
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30	2.25	2.22	2.18	2.13	2.09	2.05	2.03	1.97	1.94	1.89	1.86	1.80	1.78	1.77
25	4.24	3.39	2.99	2.75	2.60	2.49	2.40	2.34	2.28	2.24	2.20	2.16	2.11	2.07	2.04	2.01	1.96	1.92	1.87	1.84	1.78	1.76	1.75
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.27	2.22	2.18	2.15	2.09	2.05	2.02	1.99	1.94	1.90	1.85	1.82	1.76	1.74	1.73
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.25	2.20	2.17	2.13	2.08	2.04	2.00	1.97	1.92	1.88	1.84	1.81	1.74	1.72	1.71
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.24	2.19	2.15	2.12	2.06	2.02	1.99	1.96	1.91	1.87	1.82	1.79	1.73	1.70	1.69
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.28	2.22	2.18	2.14	2.10	2.05	2.01	1.97	1.94	1.89	1.85	1.81	1.77	1.71	1.69	1.67
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	2.13	2.09	2.04	1.99	1.96	1.93	1.88	1.84	1.79	1.76	1.70	1.67	1.66

$GL_1 \uparrow$

GL_1 : Número de graus de liberdade do numerador.

GL_2 : Número de graus de liberdade do denominador.

$\alpha = 5.0\%$ (conclusão)

$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
32	4.15	3.29	2.90	2.67	2.51	2.40	2.31	2.24	2.19	2.14	2.10	2.07	2.01	1.97	1.94	1.91	1.85	1.82	1.77	1.74	1.67	1.64	1.63
34	4.13	3.28	2.88	2.65	2.49	2.38	2.29	2.23	2.17	2.12	2.08	2.05	1.99	1.95	1.92	1.89	1.83	1.80	1.75	1.71	1.65	1.62	1.61
36	4.11	3.26	2.87	2.63	2.48	2.36	2.28	2.21	2.15	2.11	2.07	2.03	1.98	1.93	1.90	1.87	1.81	1.78	1.73	1.69	1.62	1.60	1.59
38	4.10	3.24	2.85	2.62	2.46	2.35	2.26	2.19	2.14	2.09	2.05	2.02	1.96	1.92	1.88	1.85	1.80	1.76	1.71	1.68	1.61	1.58	1.57
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	2.04	2.00	1.95	1.90	1.87	1.84	1.78	1.74	1.69	1.66	1.59	1.56	1.55
42	4.07	3.22	2.83	2.59	2.44	2.32	2.24	2.17	2.11	2.06	2.03	1.99	1.94	1.89	1.86	1.83	1.77	1.73	1.68	1.65	1.57	1.55	1.53
44	4.06	3.21	2.82	2.58	2.43	2.31	2.23	2.16	2.10	2.05	2.01	1.98	1.92	1.88	1.84	1.81	1.76	1.72	1.67	1.63	1.56	1.53	1.52
46	4.05	3.20	2.81	2.57	2.42	2.30	2.22	2.15	2.09	2.04	2.00	1.97	1.91	1.87	1.83	1.80	1.75	1.71	1.65	1.62	1.55	1.52	1.51
48	4.04	3.19	2.80	2.57	2.41	2.29	2.21	2.14	2.08	2.03	1.99	1.96	1.90	1.86	1.82	1.79	1.74	1.70	1.64	1.61	1.54	1.51	1.49
50	4.03	3.18	2.79	2.56	2.40	2.29	2.20	2.13	2.07	2.03	1.99	1.95	1.89	1.85	1.81	1.78	1.73	1.69	1.63	1.60	1.52	1.50	1.48
60	4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	2.04	1.99	1.95	1.92	1.86	1.82	1.78	1.75	1.69	1.65	1.59	1.56	1.48	1.45	1.44
70	3.93	3.13	2.74	2.50	2.35	2.23	2.14	2.07	2.02	1.97	1.93	1.89	1.84	1.79	1.75	1.72	1.66	1.62	1.57	1.53	1.45	1.42	1.40
80	3.96	3.11	2.72	2.49	2.33	2.21	2.13	2.06	2.00	1.95	1.91	1.88	1.82	1.77	1.73	1.70	1.64	1.60	1.54	1.51	1.43	1.39	1.38
90	3.95	3.10	2.71	2.47	2.32	2.20	2.11	2.04	1.99	1.94	1.90	1.86	1.80	1.76	1.72	1.69	1.63	1.59	1.53	1.49	1.41	1.38	1.36
100	3.94	3.09	2.70	2.45	2.31	2.19	2.10	2.03	1.97	1.93	1.89	1.85	1.79	1.75	1.71	1.68	1.62	1.57	1.52	1.48	1.39	1.36	1.34
125	3.92	3.07	2.68	2.44	2.29	2.17	2.08	2.01	1.96	1.91	1.87	1.83	1.77	1.73	1.69	1.66	1.59	1.55	1.49	1.45	1.36	1.33	1.31
150	3.90	3.06	2.66	2.43	2.27	2.16	2.07	2.00	1.94	1.89	1.85	1.82	1.76	1.71	1.67	1.64	1.58	1.54	1.48	1.44	1.34	1.31	1.29
200	3.89	3.04	2.65	2.42	2.26	2.14	2.06	1.98	1.93	1.88	1.84	1.80	1.74	1.69	1.66	1.62	1.56	1.52	1.46	1.41	1.32	1.28	1.26
300	3.87	3.03	2.63	2.40	2.24	2.13	2.04	1.97	1.91	1.86	1.82	1.78	1.72	1.68	1.64	1.61	1.54	1.50	1.43	1.39	1.30	1.26	1.23
500	3.86	3.01	2.62	2.39	2.23	2.12	2.03	1.96	1.90	1.85	1.81	1.77	1.71	1.66	1.62	1.59	1.53	1.48	1.42	1.38	1.28	1.23	1.21

$GL_1 \uparrow$

GL_1 : Número de graus de liberdade do numerador.

GL_2 : Número de graus de liberdade do denominador.

$\alpha = 2,5\%$

$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
1	548	800	864	900	922	937	948	957	963	969	973	977	983	987	990	993	998	1001	1006	1008	1013	1015	1016
2	38.5	39.0	39.2	39.2	39.3	39.3	39.4	39.4	39.4	39.4	39.4	39.4	39.4	39.4	39.4	39.4	39.5	39.5	39.5	39.5	39.5	39.5	39.5
3	17.4	16.0	15.4	15.1	14.9	14.7	14.6	14.5	14.5	14.4	14.4	14.3	14.3	14.2	14.2	14.2	14.1	14.1	14.0	14.0	14.0	13.9	13.9
4	12.2	10.6	9.98	9.60	9.36	9.20	9.07	8.98	8.90	8.84	8.79	8.75	8.68	8.63	8.59	8.56	8.50	8.46	8.41	8.38	8.32	8.30	8.29
5	10.0	8.43	7.76	7.39	7.15	6.98	6.85	6.76	6.68	6.62	6.57	6.52	6.46	6.40	6.36	6.33	6.27	6.23	6.18	6.14	6.08	6.06	6.05
6	8.81	7.26	6.60	6.23	5.99	5.82	5.70	5.60	5.52	5.46	5.41	5.37	5.30	5.24	5.20	5.17	5.11	5.07	5.01	4.98	4.92	4.89	4.88
7	8.07	6.54	5.89	5.52	5.29	5.12	4.99	4.90	4.82	4.76	4.71	4.67	4.60	4.54	4.50	4.47	4.40	4.36	4.31	4.28	4.21	4.19	4.18
8	7.57	6.06	5.42	5.05	4.82	4.65	4.53	4.43	4.36	4.30	4.24	4.20	4.13	4.08	4.03	4.00	3.94	3.89	3.84	3.81	3.74	3.72	3.70
9	7.21	5.71	5.08	4.72	4.48	4.32	4.20	4.10	4.03	3.96	3.91	3.87	3.80	3.74	3.70	3.67	3.60	3.56	3.51	3.47	3.40	3.38	3.37
10	6.94	5.46	4.83	4.47	4.24	4.07	3.95	3.85	3.78	3.72	3.66	3.62	3.55	3.50	3.45	3.42	3.35	3.31	3.26	3.22	3.15	3.13	3.12
11	6.72	5.26	4.63	4.28	4.04	3.88	3.76	3.66	3.59	3.53	3.47	3.43	3.36	3.30	3.26	3.23	3.16	3.12	3.06	3.03	2.96	2.93	2.92
12	6.55	5.10	4.47	4.12	3.89	3.73	3.61	3.51	3.44	3.37	3.32	3.28	3.21	3.15	3.11	3.07	3.01	2.96	2.91	2.87	2.80	2.78	2.76
13	6.41	4.97	4.35	4.00	3.77	3.60	3.48	3.39	3.31	3.25	3.20	3.15	3.08	3.03	2.98	2.95	2.88	2.84	2.78	2.74	2.67	2.65	2.63
14	6.30	4.86	4.24	3.89	3.66	3.50	3.38	3.29	3.21	3.15	3.09	3.05	2.98	2.92	2.88	2.84	2.78	2.73	2.67	2.64	2.56	2.54	2.53
15	6.20	4.77	4.15	3.80	3.58	3.41	3.29	3.20	3.12	3.06	3.01	2.96	2.89	2.84	2.79	2.76	2.69	2.64	2.59	2.55	2.47	2.45	2.44
16	6.12	4.69	4.08	3.73	3.50	3.34	3.22	3.12	3.05	2.99	2.93	2.89	2.82	2.76	2.72	2.68	2.61	2.57	2.51	2.47	2.40	2.37	2.36
17	6.04	4.62	4.01	3.66	3.44	3.28	3.16	3.06	2.98	2.92	2.87	2.82	2.75	2.70	2.65	2.62	2.55	2.50	2.44	2.41	2.33	2.30	2.29
18	5.98	4.56	3.95	3.61	3.38	3.22	3.10	3.01	2.93	2.87	2.81	2.77	2.70	2.64	2.60	2.56	2.49	2.44	2.38	2.35	2.27	2.24	2.23
19	5.92	4.51	3.90	3.56	3.33	3.17	3.05	2.96	2.88	2.82	2.76	2.72	2.65	2.59	2.55	2.51	2.44	2.39	2.33	2.30	2.22	2.19	2.18
20	5.87	4.46	3.86	3.51	3.29	3.13	3.01	2.91	2.84	2.77	2.72	2.68	2.60	2.55	2.50	2.46	2.40	2.35	2.29	2.25	2.17	2.14	2.13
21	5.83	4.42	3.82	3.48	3.25	3.09	2.97	2.87	2.80	2.73	2.68	2.64	2.56	2.51	2.46	2.42	2.36	2.31	2.25	2.21	2.13	2.10	2.09
22	5.79	4.38	3.78	3.44	3.22	3.05	2.93	2.84	2.76	2.70	2.65	2.60	2.53	2.47	2.43	2.39	2.32	2.27	2.21	2.17	2.09	2.06	2.05
23	5.75	4.35	3.75	3.41	3.18	3.02	2.90	2.81	2.73	2.67	2.62	2.57	2.50	2.44	2.39	2.36	2.29	2.24	2.18	2.14	2.06	2.03	2.01
24	5.72	4.38	3.72	3.38	3.15	2.99	2.87	2.73	2.70	2.64	2.59	2.54	2.47	2.41	2.36	2.33	2.26	2.21	2.15	2.11	2.02	2.00	1.98
25	5.69	4.29	3.69	3.35	3.13	2.97	2.85	2.75	2.68	2.61	2.56	2.51	2.44	2.38	2.34	2.30	2.23	2.18	2.12	2.08	2.00	1.97	1.95
26	5.66	4.27	3.67	3.33	3.10	2.94	2.82	2.73	2.65	2.59	2.54	2.49	2.42	2.36	2.31	2.28	2.21	2.16	2.09	2.05	1.97	1.94	1.92
27	5.63	4.24	3.65	3.31	3.08	2.92	2.80	2.71	2.63	2.57	2.51	2.47	2.39	2.34	2.29	2.25	2.18	2.13	2.07	2.03	1.94	1.91	1.90
28	5.61	4.22	3.63	3.29	3.06	2.90	2.78	2.69	2.61	2.55	2.49	2.45	2.37	2.32	2.27	2.23	2.16	2.11	2.05	2.01	1.92	1.89	1.88
29	5.59	4.20	3.61	3.27	3.04	2.88	2.76	2.67	2.59	2.53	2.48	2.43	2.36	2.30	2.25	2.21	2.14	2.09	2.03	1.99	1.90	1.87	1.86
30	5.57	4.18	3.59	3.25	3.03	2.87	2.75	2.65	2.57	2.51	2.46	2.41	2.34	2.28	2.23	2.20	2.12	2.07	2.01	1.97	1.88	1.85	1.84

 $GL_1 \uparrow$ GL_1 : Número de graus de liberdade do numerador. GL_2 : Número de graus de liberdade do denominador. $\alpha = 2.5\%$ (conclusão)

$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
32	5.53	4.15	3.56	3.22	3.00	2.84	2.71	2.62	2.54	2.48	2.43	2.38	2.31	2.25	2.20	2.16	2.09	2.04	1.98	1.93	1.85	1.82	1.80
34	5.50	4.12	3.53	3.19	2.97	2.81	2.69	2.59	2.52	2.45	2.40	2.35	2.28	2.22	2.17	2.13	2.06	2.01	1.95	1.90	1.82	1.78	1.77
36	5.47	4.09	3.50	3.17	2.94	2.78	2.66	2.57	2.49	2.43	2.37	2.33	2.25	2.20	2.15	2.11	2.04	1.99	1.92	1.88	1.79	1.76	1.74
38	5.45	4.07	3.48	3.15	2.92	2.76	2.64	2.55	2.47	2.41	2.35	2.31	2.23	2.17	2.13	2.09	2.01	1.96	1.90	1.85	1.76	1.73	1.71
40	5.42	4.05	3.46	3.13	2.90	2.74	2.62	2.53	2.45	2.39	2.33	2.29	2.21	2.15	2.11	2.07	1.99	1.94	1.88	1.83	1.74	1.71	1.69
42	5.40	4.03	3.45	3.11	2.89	2.73	2.61	2.51	2.43	2.37	2.32	2.27	2.20	2.14	2.09	2.05	1.98	1.92	1.86	1.81	1.72	1.69	1.67
44	5.39	4.02	3.43	3.09	2.87	2.71	2.59	2.50	2.42	2.36	2.30	2.26	2.18	2.12	2.07	2.03	1.96	1.91	1.84	1.80	1.70	1.67	1.65
46	5.37	4.00	3.42	3.08	2.86	2.70	2.58	2.48	2.41	2.34	2.29	2.24	2.17	2.11	2.06	2.02	1.94	1.89	1.82	1.78	1.69	1.65	1.63
48	5.35	3.99	3.40	3.07	2.84	2.69	2.56	2.47	2.39	2.33	2.27	2.23	2.15	2.09	2.05	2.01	1.93	1.88	1.81	1.77	1.67	1.64	1.62
50	5.34	3.97	3.39	3.05	2.83	2.67	2.55	2.46	2.38	2.32	2.26	2.22	2.14	2.08	2.03	1.99	1.92	1.87	1.80	1.75	1.66	1.62	1.60
60	5.29	3.93	3.34	3.01	2.79	2.63	2.51	2.41	2.33	2.27	2.22	2.17	2.09	2.03	1.98	1.94	1.87	1.82	1.74	1.70	1.60	1.56	1.54
70	5.25	3.89	3.31	2.97	2.75	2.59	2.47	2.38	2.30	2.24	2.18	2.14	2.06	2.00	1.95	1.91	1.83	1.78	1.71	1.66	1.56	1.52	1.50
80	5.22	3.86	3.28	2.95	2.73	2.57	2.45	2.35	2.28	2.21	2.16	2.11	2.03	1.97	1.92	1.88	1.81	1.75	1.68	1.63	1.53	1.49	1.47
90	5.20	3.84	3.26	2.93	2.71	2.55	2.43	2.34	2.26	2.19	2.14	2.09	2.02	1.95	1.91	1.86	1.79	1.73	1.66	1.61	1.50	1.46	1.44
100	5.18	3.83	3.25	2.92	2.70	2.54	2.42	2.32	2.24	2.18	2.12	2.08	2.00	1.94	1.89	1.85	1.77	1.71	1.64	1.59	1.48	1.44	1.42
125	5.15	3.80	3.22	2.89	2.67	2.51	2.39	2.30	2.22	2.15	2.10	2.05	1.97	1.91	1.86	1.82	1.74	1.68	1.61	1.56	1.45	1.40	1.38
150	5.13	3.78	3.20	2.87	2.65	2.49	2.37	2.28	2.20	2.13	2.08	2.03	1.95	1.89	1.84	1.80	1.72	1.67	1.59	1.54	1.42	1.38	1.35
200	5.10	3.76	3.18	2.85	2.63	2.47	2.35	2.26	2.18	2.11	2.06	2.01	1.93	1.87	1.82	1.78	1.70	1.64	1.56	1.51	1.39	1.35	1.32
300	5.07	3.73	3.16	2.83	2.61	2.45	2.33	2.23	2.16	2.09	2.04	1.99	1.91	1.85	1.80	1.75	1.67	1.62	1.54	1.48	1.36	1.31	1.28
500	5.05	3.72	3.14	2.81	2.59	2.43	2.31	2.22	2.14	2.07	2.02	1.97	1.89	1.83	1.78	1.74	1.65	1.60	1.52	1.46	1.34	1.28	1.25

 $GL_1 \uparrow$ GL_1 : Número de graus de liberdade do numerador. GL_2 : Número de graus de liberdade do denominador.

$\alpha = 1.0\%$

$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
1	4052	5000	5403	5625	5764	5859	5928	5981	6022	6056	6083	6166	6143	6170	6192	6209	6240	6261	6287	6303	6334	6345	6350
2	98.5	99.0	99.2	99.2	99.3	99.3	99.4	99.4	99.4	99.4	99.4	99.4	99.4	99.4	99.4	99.4	99.5	99.5	99.5	99.5	99.5	99.5	99.5
3	34.1	30.8	29.5	28.7	28.2	27.9	27.7	27.5	27.3	27.2	27.1	26.9	26.8	26.8	26.7	26.6	26.5	26.4	26.4	26.2	26.2	26.2	26.2
4	21.2	18.0	16.7	16.0	15.5	15.2	15.0	14.8	14.7	14.5	14.5	14.4	14.2	14.2	14.1	14.0	13.9	13.8	13.7	13.7	13.6	13.5	13.5
5	16.3	13.3	12.1	11.4	11.0	10.7	10.5	10.3	10.2	10.1	9.96	9.89	9.77	9.68	9.61	9.55	9.45	9.38	9.29	9.24	9.13	9.09	9.08
6	13.7	10.9	9.78	9.15	8.75	8.47	8.26	8.10	7.98	7.87	7.79	7.72	7.60	7.52	7.45	7.40	7.30	7.23	7.14	7.09	6.99	6.95	6.93
7	12.2	9.55	8.45	7.85	7.46	7.19	6.99	6.84	6.72	6.62	6.54	6.47	6.36	6.28	6.21	6.16	6.06	5.99	5.91	5.86	5.75	5.72	5.70
8	11.3	8.65	7.59	7.01	6.63	6.37	6.18	6.03	5.91	5.81	5.73	5.67	5.56	5.48	5.41	5.36	5.26	5.20	5.12	5.07	4.96	4.93	4.91
9	10.6	8.02	6.99	6.42	6.06	5.80	5.61	5.47	5.35	5.26	5.18	5.11	5.01	4.92	4.86	4.81	4.71	4.65	4.57	4.52	4.41	4.38	4.36
10	10.0	7.56	6.55	5.99	5.64	5.39	5.20	5.06	4.94	4.85	4.77	4.71	4.60	4.52	4.46	4.41	4.31	4.25	4.17	4.12	4.01	3.98	3.96
11	9.65	7.21	6.22	5.67	5.32	5.07	4.89	4.74	4.63	4.54	4.46	4.40	4.29	4.21	4.15	4.10	4.01	3.94	3.86	3.81	3.71	3.67	3.66
12	9.33	6.93	5.95	5.41	5.06	4.82	4.64	4.50	4.39	4.30	4.22	4.16	4.05	3.97	3.91	3.86	3.76	3.70	3.62	3.57	3.47	3.43	3.41
13	9.07	6.70	5.74	5.21	4.86	4.62	4.44	4.30	4.19	4.10	4.02	3.96	3.86	3.78	3.72	3.66	3.57	3.51	3.43	3.38	3.27	3.24	3.22
14	8.88	6.51	5.56	5.04	4.69	4.46	4.28	4.14	4.03	3.94	3.86	3.80	3.70	3.62	3.56	3.51	3.41	3.35	3.27	3.22	3.11	3.08	3.06
15	8.68	6.36	5.42	4.89	4.56	4.32	4.14	4.00	3.89	3.80	3.73	3.67	3.56	3.49	3.42	3.37	3.28	3.21	3.13	3.08	2.98	2.94	2.92
16	8.53	6.23	5.29	4.77	4.44	4.20	4.03	3.89	3.78	3.69	3.62	3.55	3.45	3.37	3.31	3.26	3.16	3.10	3.02	2.97	2.86	2.83	2.81
17	8.40	6.11	5.19	4.67	4.34	4.10	3.93	3.79	3.68	3.59	3.52	3.46	3.35	3.27	3.21	3.16	3.07	3.00	2.92	2.87	2.76	2.73	2.71
18	8.29	6.01	5.09	4.58	4.25	4.01	3.84	3.71	3.60	3.51	3.43	3.37	3.27	3.19	3.13	3.08	2.98	2.92	2.84	2.78	2.68	2.64	2.62
19	8.18	5.93	5.01	4.50	4.17	3.94	3.77	3.63	3.52	3.43	3.36	3.30	3.19	3.12	3.05	3.00	2.91	2.84	2.76	2.71	2.60	2.57	2.55
20	8.10	5.85	4.94	4.43	4.10	3.87	3.70	3.56	3.46	3.37	3.29	3.23	3.13	3.05	2.99	2.94	2.84	2.78	2.69	2.64	2.54	2.50	2.48
21	8.02	5.78	4.87	4.37	4.04	3.81	3.64	3.51	3.40	3.31	3.24	3.17	3.07	2.99	2.93	2.88	2.79	2.72	2.64	2.58	2.48	2.44	2.42
22	7.95	5.72	4.82	4.31	3.99	3.76	3.59	3.45	3.35	3.26	3.18	3.12	3.02	2.94	2.88	2.83	2.73	2.67	2.58	2.53	2.42	2.38	2.36
23	7.88	5.66	4.76	4.26	3.94	3.71	3.54	3.41	3.30	3.21	3.14	3.07	2.97	2.89	2.83	2.78	2.69	2.62	2.54	2.48	2.37	2.34	2.32
24	7.82	5.61	4.72	4.22	3.90	3.67	3.50	3.36	3.26	3.17	3.09	3.03	2.93	2.85	2.79	2.74	2.64	2.58	2.49	2.44	2.33	2.29	2.27
25	7.77	5.57	4.68	4.18	3.85	3.63	3.46	3.32	3.22	3.13	3.06	2.99	2.89	2.81	2.75	2.70	2.60	2.54	2.45	2.40	2.29	2.25	2.23
26	7.72	5.53	4.64	4.14	3.82	3.59	3.42	3.29	3.18	3.09	3.02	2.96	2.86	2.78	2.72	2.66	2.57	2.50	2.42	2.36	2.25	2.21	2.19
27	7.68	5.49	4.60	4.11	3.78	3.56	3.39	3.26	3.15	3.06	2.99	2.93	2.82	2.75	2.68	2.63	2.54	2.47	2.38	2.33	2.22	2.18	2.16
28	7.64	5.45	4.57	4.07	3.75	3.53	3.36	3.23	3.12	3.03	2.96	2.90	2.79	2.72	2.65	2.60	2.51	2.44	2.35	2.30	2.19	2.15	2.13
29	7.60	5.42	4.54	4.04	3.73	3.50	3.33	3.20	3.09	3.00	2.93	2.87	2.77	2.69	2.63	2.57	2.48	2.41	2.33	2.27	2.16	2.12	2.10
30	7.56	5.39	4.51	4.02	3.70	3.47	3.30	3.17	3.07	2.98	2.91	2.84	2.74	2.66	2.60	2.55	2.45	2.39	2.30	2.25	2.13	2.09	2.07

$GL_1 \uparrow$

GL_1 : Número de graus de liberdade do numerador.

GL_2 : Número de graus de liberdade do denominador.

$\alpha = 1.0\%$ (conclusão)

$GL_1 \rightarrow$	1	2	3	4	5	6	7	8	9	10	11	12	14	16	18	20	25	30	40	50	100	150	200
32	7.50	5.34	4.46	3.97	3.65	3.43	3.26	3.13	3.02	2.93	2.86	2.80	2.70	2.62	2.55	2.50	2.41	2.34	2.25	2.20	2.08	2.04	2.02
34	7.44	5.29	4.42	3.93	3.61	3.39	3.22	3.09	2.98	2.89	2.82	2.76	2.66	2.58	2.51	2.46	2.37	2.30	2.21	2.16	2.04	2.00	1.98
36	7.40	5.25	4.38	3.89	3.57	3.35	3.18	3.05	2.95	2.86	2.79	2.72	2.62	2.54	2.48	2.43	2.33	2.26	2.18	2.12	2.00	1.96	1.94
38	7.35	5.21	4.34	3.86	3.54	3.32	3.15	3.02	2.92	2.83	2.75	2.69	2.59	2.51	2.45	2.40	2.30	2.23	2.14	2.09	1.97	1.93	1.90
40	7.31	5.18	4.31	3.83	3.51	3.29	3.12	2.99	2.89	2.80	2.73	2.66	2.56	2.48	2.42	2.37	2.27	2.20	2.11	2.06	1.94	1.90	1.87
42	7.28	5.15	4.29	3.80	3.49	3.27	3.10	2.97	2.86	2.78	2.70	2.64	2.54	2.46	2.40	2.34	2.25	2.18	2.09	2.03	1.91	1.87	1.85
44	7.25	5.12	4.26	3.78	3.47	3.24	3.08	2.95	2.84	2.75	2.68	2.62	2.52	2.44	2.37	2.32	2.22	2.15	2.07	2.01	1.89	1.84	1.82
46	7.22	5.10	4.24	3.76	3.44	3.22	3.06	2.93	2.82	2.73	2.66	2.60	2.50	2.42	2.35	2.30	2.20	2.13	2.04	1.99	1.86	1.82	1.80
48	7.19	5.08	4.22	3.74	3.43	3.20	3.04	2.91	2.80	2.71	2.64	2.58	2.48	2.40	2.33	2.28	2.18	2.12	2.02	1.97	1.84	1.80	1.78
50	7.17	5.06	4.20	3.72	3.41	3.19	3.02	2.89	2.78	2.70	2.63	2.56	2.46	2.38	2.32	2.27	2.17	2.10	2.01	1.95	1.82	1.78	1.76
60	7.08	4.98	4.13	3.65	3.34	3.12	2.95	2.82	2.72	2.63	2.56	2.50	2.39	2.31	2.25	2.20	2.10	2.03	1.94	1.88	1.75	1.70	1.68
70	7.01	4.92	4.07	3.60	3.29	3.07	2.91	2.78	2.67	2.59	2.51	2.45	2.35	2.27	2.20	2.15	2.05	1.98	1.89	1.83	1.70	1.65	1.62
80	6.96	4.88	4.04	3.56	3.26	3.04	2.87	2.74	2.64	2.55	2.48	2.42	2.31	2.23	2.17	2.12	2.01	1.94	1.85	1.79	1.65	1.61	1.58
90	6.93	4.85	4.01	3.53	3.23	3.01	2.84	2.72	2.61	2.52	2.45	2.39	2.29	2.21	2.14	2.09	1.99	1.92	1.82	1.76	1.62	1.57	1.55
100	6.90	4.82	3.98	3.51	3.21	2.99	2.82	2.69	2.59	2.50	2.43	2.37	2.27	2.19	2.12	2.07	1.97	1.89	1.80	1.74	1.60	1.55	1.52
125	6.84	4.78	3.94	3.47	3.17	2.95	2.79	2.66	2.55	2.47	2.39	2.33	2.23	2.15	2.08	2.03	1.93	1.85	1.76	1.69	1.55	1.50	1.47
150	6.81	4.75	3.91	3.45	3.14	2.92	2.76	2.63	2.53	2.44	2.37	2.31	2.20	2.12	2.06	2.00	1.90	1.83	1.73	1.66	1.52	1.46	1.43
200	6.76	4.71	3.88	3.41	3.11	2.89	2.73	2.60	2.50	2.41	2.34	2.27	2.17	2.09	2.03	1.97	1.87	1.79	1.69	1.63	1.48	1.42	1.39
300	6.72	4.68	3.85	3.38	3.08	2.86	2.70	2.57	2.47	2.38	2.31	2.24	2.14	2.06	1.99	1.94	1.84	1.76	1.66	1.59	1.44	1.38	1.35
500	6.69	4.65	3.82	3.36	3.05	2.84	2.68	2.55	2.44	2.36	2.28	2.22	2.12	2.04	1.97	1.92	1.81	1.74	1.63	1.57	1.41	1.34	1.31

$GL_1 \uparrow$

GL_1 : Número de graus de liberdade do numerador.

GL_2 : Número de graus de liberdade do denominador.

■ Tabela 7. Números Aleatórios
(Números Equiprováveis e Independentes)

763150	012500	268350	506190
953420	812760	662160	409727
593300	630770	242972	239033
286353	914160	099318	622683
988830	149510	031520	439362
764530	786380	791930	759796
094360	564940	436650	248557
033133	623908	282163	686200
177601	876335	976523	001004
174845	114146	912337	869647
982380	147550	022450	027192
977660	755040	735890	694344
509928	357516	040141	956246
145280	498150	844850	232013
561216	169780	832765	141247
562990	803448	293316	701351
898469	084015	915136	077920
302670	670452	424765	831062
615680	724927	306799	633872
555500	452902	635654	102276
795780	485981	030700	048505
321660	190030	033538	156660
912302	112453	184951	744661
590550	275959	967646	661861
087721	123271	973327	290726
880407	811897	626287	538190
472764	198036	435293	189969
852574	962055	345073	763754
981980	720749	158506	218626
924460	484617	793570	707400
568145	500370	296667	390319
163689	579768	607137	507758
732938	914246	287825	707558
853590	680640	768100	720916
824546	775398	288290	970700

■ Tabela 8. Valores Críticos da Distribuição da Estatística D
(Kolmogorov-Smirnov, Uma Amostra)

Valores críticos da distribuição da estatística $D = \sup_x |S(x) - F_0(x)|$ para amostras de dimensão N e níveis de significância α .

N	α					N	α				
	0.20	0.10	0.05	0.02	0.01		0.20	0.10	0.05	0.02	0.01
1	0.900	0.950	0.975	0.990	0.995	21	0.226	0.259	0.287	0.321	0.344
2	0.684	0.776	0.842	0.900	0.929	22	0.221	0.253	0.281	0.314	0.337
3	0.565	0.636	0.708	0.785	0.829	23	0.216	0.247	0.275	0.307	0.330
4	0.493	0.565	0.624	0.689	0.734	24	0.212	0.242	0.269	0.301	0.323
5	0.447	0.509	0.563	0.627	0.669	25	0.208	0.238	0.264	0.295	0.317
6	0.410	0.468	0.519	0.577	0.617	26	0.204	0.233	0.259	0.290	0.311
7	0.381	0.436	0.483	0.538	0.576	27	0.200	0.229	0.254	0.284	0.305
8	0.358	0.410	0.454	0.407	0.542	28	0.197	0.225	0.250	0.279	0.300
9	0.339	0.387	0.430	0.480	0.513	29	0.193	0.221	0.246	0.275	0.295
10	0.323	0.369	0.409	0.457	0.489	30	0.190	0.218	0.242	0.270	0.290
11	0.308	0.352	0.391	0.437	0.468	31	0.187	0.214	0.238	0.266	0.285
12	0.296	0.338	0.375	0.419	0.449	32	0.184	0.211	0.234	0.262	0.181
13	0.285	0.325	0.361	0.404	0.432	33	0.182	0.208	0.231	0.258	0.277
14	0.275	0.314	0.349	0.390	0.418	34	0.179	0.205	0.227	0.254	0.273
15	0.266	0.304	0.338	0.377	0.404	35	0.177	0.202	0.224	0.251	0.269
16	0.258	0.295	0.327	0.366	0.392	36	0.174	0.199	0.221	0.247	0.265
17	0.250	0.286	0.318	0.355	0.381	37	0.172	0.196	0.218	0.244	0.262
18	0.244	0.279	0.309	0.346	0.371	38	0.170	0.194	0.215	0.241	0.258
19	0.237	0.271	0.301	0.337	0.361	39	0.168	0.191	0.213	0.238	0.255
20	0.232	0.265	0.294	0.329	0.352	40	0.165	0.189	0.210	0.235	0.252

Para $N > 40$ os valores críticos de D podem ser aproximados pelas seguintes expressões:

α				
0.20	0.10	0.05	0.02	0.01
1.07	1.22	1.36	1.52	1.63
$\sqrt{N}$	$\sqrt{N}$	$\sqrt{N}$	$\sqrt{N}$	$\sqrt{N}$

Adaptado de L. H. Miller [1956], "Table of Percentage Points of Kolmogorov Statistics", *Journal of the American Statistical Association*, Vol. 51, pp. 111-121.

■ Tabela 9. Valores Críticos da Distribuição da Estatística D
(Lilliefors, Populações Normais)

Valores críticos da distribuição da estatística $D = \sup_x |S(x) - F_0(x)|$ para populações Normais e parâmetros estimados a partir de amostras de dimensão N .

Dimensão da amostra N	Nível de significância (α)				
	0.20	0.15	0.10	0.05	0.01
4	0.300	0.319	0.352	0.381	0.417
5	0.285	0.299	0.315	0.337	0.405
6	0.265	0.277	0.294	0.319	0.364
7	0.217	0.253	0.276	0.300	0.348
8	0.233	0.244	0.261	0.285	0.331
9	0.223	0.233	0.249	0.271	0.311
10	0.215	0.224	0.239	0.258	0.294
11	0.206	0.217	0.230	0.249	0.284
12	0.199	0.212	0.223	0.242	0.275
13	0.190	0.202	0.214	0.234	0.268
14	0.183	0.194	0.207	0.227	0.261
15	0.177	0.187	0.201	0.220	0.257
16	0.173	0.182	0.195	0.213	0.250
17	0.169	0.177	0.189	0.206	0.245
18	0.166	0.173	0.184	0.200	0.239
19	0.163	0.169	0.179	0.195	0.235
20	0.160	0.166	0.174	0.190	0.231
25	0.149	0.153	0.165	0.180	0.203
30	0.131	0.136	0.144	0.161	0.187
>30	$\frac{0.730}{\sqrt{N}}$	$\frac{0.768}{\sqrt{N}}$	$\frac{0.805}{\sqrt{N}}$	$\frac{0.886}{\sqrt{N}}$	$\frac{1.031}{\sqrt{N}}$

■ Tabela 10. Distribuição da Estatística $N_A \cdot N_B \cdot D'$
(Teste de Kolmogorov-Smirnov, Duas Amostras)

Os valores P referem-se à probabilidade na cauda direita da distribuição da estatística $N_A \cdot N_B \cdot D'$ (com $D' = \max |S_A(x) - S_B(x)|$), para amostras com dimensões N_A e N_B (satisfazendo $2 \leq N_A \leq N_B \leq 12$ e $N_A + N_B \leq 16$) de duas populações A e B .

Em testes unilaterais deverá considerar-se $P/2$ (os valores de D' assim calculados serão correctos se P for pequeno).

N_A	N_B	$N_A \cdot N_B \cdot D$	P	N_A	N_B	$N_A \cdot N_B \cdot D'$	P	N_A	N_B	$N_A \cdot N_B \cdot D'$	P
2	2	4	0.333	3	6	18	0.02	4	5	20	0.016
2	3	6	0.200			15	0.09			16	0.079
2	4	8	0.133			12	0.33			15	0.143
2	5	10	0.095	3	7	21	0.01	4	6	24	0.100
		8	0.286			18	0.06			20	0.048
2	6	12	0.071			15	0.16			18	0.095
		10	0.214	3	8	24	0.01			16	0.181
2	7	14	0.056			21	0.04	4	7	28	0.006
		12	0.167			18	0.12			24	0.030
2	8	16	0.044	3	9	27	0.00			21	0.067
		14	0.133			24	0.03			20	0.121
2	9	18	0.036			21	0.09	4	8	32	0.004
		16	0.109			18	0.23			28	0.020
2	10	20	0.030	3	10	30	0.00			24	0.085
		18	0.091			27	0.02			20	0.222
		16	0.182			24	0.07	4	9	36	0.003
2	11	22	0.026			21	0.14			32	0.014
		20	0.077	3	11	33	0.00			28	0.042
		18	0.154			30	0.02			27	0.062
2	12	24	0.022			27	0.05			24	0.115
		22	0.066			24	0.11	4	10	40	0.002
		20	0.132	3	12	36	0.00			36	0.010
3	3	9	0.100			33	0.01			32	0.030
3	4	12	0.057			30	0.04			30	0.046
		9	0.229			27	0.08			28	0.084
3	5	15	0.036			24	0.18			26	0.126
		12	0.143	4	4	16	0.02				
						12	0.22				

/...

N_A	N_B	$N_A \cdot N_B \cdot D'$	P	N_A	N_B	$N_A \cdot N_B \cdot D$	P	N_A	N_B	$N_A \cdot N_B \cdot D'$	P
4	11	44	0.001	5	10	50	0.001	6	10	60	0.000
		40	0.007			45	0.004			54	0.002
		36	0.022			40	0.019			50	0.004
		33	0.035			35	0.061			48	0.009
		32	0.063			30	0.166			44	0.019
		29	0.098	5	11	55	0.000			42	0.031
		28	0.144			50	0.003			40	0.042
4	12	48	0.001			45	0.010			38	0.066
		44	0.005			44	0.014			36	0.092
		40	0.016			40	0.029			34	0.125
		36	0.048			39	0.044	7	7	49	0.001
		32	0.112			35	0.074			42	0.008
5	5	25	0.008			34	0.106			35	0.053
		20	0.079	6	6	36	0.002			28	0.212
		15	0.357			30	0.026	7	8	56	0.000
5	6	30	0.004			24	0.143			49	0.002
		25	0.026	6	7	42	0.001			48	0.005
		24	0.048			36	0.008			42	0.013
		20	0.108			35	0.015			41	0.024
5	7	35	0.003			30	0.038			40	0.033
		30	0.015			29	0.068			35	0.056
		28	0.030			28	0.091			34	0.087
		25	0.066			24	0.147			33	0.118
		23	0.116	6	8	48	0.001	7	9	63	0.000
5	8	40	0.002			42	0.005			56	0.001
		35	0.009			40	0.009			54	0.003
		32	0.020			36	0.023			49	0.008
		30	0.042			34	0.043			47	0.015
		27	0.079			32	0.061			45	0.021
		25	0.126			30	0.093			42	0.034
5	9	45	0.001			28	0.139			40	0.055
		40	0.006	6	9	54	0.000			38	0.079
		36	0.014			48	0.003			36	0.098
		35	0.028			45	0.006			35	0.127
		31	0.056			42	0.014	8	8	64	0.000
		30	0.086			39	0.028			56	0.002
		27	0.119			36	0.061			48	0.019
						33	0.095			40	0.087
						30	0.176			32	0.283

Valores críticos da distribuição da estatística $N_A \cdot N_B \cdot D'$ para amostras com dimensões tais que $9 \leq N_A = N_B \leq 20$ (os valores de α indicados para testes unilaterais são aproximados).

Dimensão da amostra	Nível de significância (α) (teste bilateral)					
	$N_A = N_B$	0.20	0.10	0.05	0.02	0.01
9	45	54	54	63	63	63
10	50	60	70	70	80	80
11	66	66	77	88	88	88
12	72	72	84	96	96	96
13	78	91	91	104	117	117
14	84	98	112	112	126	126
15	90	105	120	135	135	135
16	112	112	128	144	160	160
17	119	136	136	153	170	170
18	126	144	162	180	180	180
19	133	152	171	190	190	190
20	140	160	180	200	220	220
	0.10	0.05	0.025	0.01	0.005	
Nível de significância (α) (teste unilateral)						

Para amostras cujas dimensões não estão contempladas nos quadros anteriores, os valores críticos da distribuição da estatística D' podem ser aproximados através das expressões seguintes (com $N = N_A + N_B$):

Nível de significância (α) (teste bilateral)				
0.20	0.10	0.05	0.02	0.01
$1.07 \cdot \sqrt{N / N_A \cdot N_B}$	$1.22 \cdot \sqrt{N / N_A \cdot N_B}$	$1.36 \cdot \sqrt{N / N_A \cdot N_B}$	$1.52 \cdot \sqrt{N / N_A \cdot N_B}$	$1.63 \cdot \sqrt{N / N_A \cdot N_B}$
0.10	0.05	0.025	0.01	0.005
Nível de significância (α) (teste unilateral)				

■ Tabela 11. Distribuição da Estatística T (Teste de Wilcoxon)

Os valores P referem-se à probabilidade de, para amostras com dimensão N , a estatística T tomar valores inferiores ou iguais a t_e (cauda esquerda) ou, alternativamente, tomar valores superiores ou iguais a t_d (cauda direita).

N	t_e	P	t_d	N	t_e	P	t_d	N	t_e	P	t_d
2	0	0.250	3	7	0	0.008	29	9	0	0.002	45
	1	0.500	2		1	0.016	27		1	0.004	44
3	0	0.125	6		2	0.023	26		2	0.006	43
	1	0.250	5		3	0.039	25		3	0.010	42
	2	0.375	4		4	0.055	24		4	0.014	41
	3	0.625	3		5	0.078	23		5	0.020	40
4	0	0.062	10		6	0.109	22		6	0.027	39
	1	0.125	9		7	0.148	21		7	0.037	38
	2	0.188	8		8	0.188	20		8	0.049	37
	3	0.312	7		9	0.234	19		9	0.064	36
	4	0.438	6		10	0.289	18		10	0.082	35
	5	0.562	5		11	0.344	17		11	0.102	34
5	0	0.031	15		12	0.406	16		12	0.125	33
	1	0.062	14		13	0.469	15		13	0.150	32
	2	0.094	13		14	0.531	14		14	0.180	31
	3	0.156	12	8	0	0.004	36		15	0.213	30
	4	0.219	11		1	0.008	35		16	0.248	29
	5	0.312	10		2	0.012	34		17	0.285	28
	6	0.406	9		3	0.020	33		18	0.326	27
	7	0.500	8		4	0.027	32		19	0.367	26
6	0	0.016	21		5	0.039	31		20	0.410	25
	1	0.031	20		6	0.055	30		21	0.455	24
	2	0.047	19		7	0.074	29		22	0.500	23
	3	0.078	18		8	0.098	28	10	0	0.001	55
	4	0.109	17		9	0.125	27		1	0.002	54
	5	0.156	16		10	0.156	26		2	0.003	53
	6	0.219	15		11	0.191	25		3	0.005	52
	7	0.281	14		12	0.230	24		4	0.007	51
	8	0.344	13		13	0.273	23		5	0.010	50
	9	0.422	12		14	0.320	22		6	0.014	49
10	0.500	11			15	0.371	21		7	0.019	48
					16	0.422	20		8	0.024	47
					17	0.473	19		9	0.032	46
					18	0.527	18		10	0.042	45

.../

/...

N	t_e	P	t_d	N	t_e	P	t_d	N	t_e	P	t_d
10	11	0.053	44	12	0	0.000	78	13	11	0.007	80
	12	0.065	43		1	0.000	77		12	0.009	79
	13	0.080	42		2	0.001	76		13	0.011	78
	14	0.097	41		3	0.001	75		14	0.013	77
	15	0.116	40		4	0.002	74		15	0.016	76
	16	0.138	39		5	0.002	73		16	0.020	75
	17	0.161	38		6	0.003	72		17	0.024	74
	18	0.188	37		7	0.005	71		18	0.029	73
	19	0.216	36		8	0.006	70		19	0.034	72
	20	0.246	35		9	0.008	69		20	0.040	71
	21	0.278	34		10	0.010	68		21	0.047	70
	22	0.312	33		11	0.013	67		22	0.055	69
	23	0.348	32		12	0.017	66		23	0.064	68
	24	0.385	31		13	0.021	65		24	0.073	67
	25	0.423	30		14	0.026	64		25	0.084	66
	26	0.461	29		15	0.032	63		26	0.095	65
	27	0.500	28		16	0.039	62		27	0.108	64
11	0	0.000	66		17	0.046	61		28	0.122	63
	1	0.001	65		18	0.055	60		29	0.137	62
	2	0.001	64		19	0.065	59		30	0.153	61
	3	0.002	63		20	0.076	58		31	0.170	60
	4	0.003	62		21	0.088	57		32	0.188	59
	5	0.005	61		22	0.102	56		33	0.207	58
	6	0.007	60		23	0.117	55		34	0.227	57
	7	0.009	59		24	0.133	54		35	0.249	56
	8	0.012	58		25	0.151	53		36	0.271	55
	9	0.016	57		26	0.170	52		37	0.294	54
	10	0.021	56		27	0.190	51		38	0.318	53
	11	0.027	55		28	0.212	50		39	0.342	52
	12	0.034	54		29	0.235	49		40	0.368	51
	13	0.042	53		30	0.259	48		41	0.393	50
	14	0.051	52		31	0.285	47		42	0.420	49
	15	0.062	51		32	0.311	46		43	0.446	48
	16	0.074	50		33	0.339	45		44	0.473	47
	17	0.087	49		34	0.367	44		45	0.500	46
	18	0.103	48		35	0.396	43	14	0	0.000	105
	19	0.120	47		36	0.425	42		1	0.000	104
	20	0.139	46		37	0.455	41		2	0.000	103
	21	0.160	45		38	0.485	40		3	0.000	102
	22	0.183	44		39	0.515	39		4	0.000	101
	23	0.207	43	13	0	0.000	91		5	0.001	100
	24	0.232	42		1	0.000	90		6	0.001	99
	25	0.260	41		2	0.000	89		7	0.001	98
	26	0.289	40		3	0.001	88		8	0.002	97
	27	0.319	39		4	0.001	87		9	0.002	96
	28	0.350	38		5	0.001	86		10	0.003	95
	29	0.382	37		6	0.002	85		11	0.003	94
	30	0.416	36		7	0.002	84		12	0.004	93
	31	0.449	35		8	0.003	83		13	0.005	92
	32	0.483	34		9	0.004	82		14	0.007	91
	33	0.517	33		10	0.005	81		15	0.008	90

.../

Adaptado de H. L. Harter e D. B. Owen, eds., [1970], *Select Tables in Mathematical Statistics*, Vol. I and 2, Table II, Markan Publishing Company, Chicago. Por cortesia do Institute of Mathematical Statistics, Hayward, Califórnia, USA.

/...

N	t_e	P	t_d	N	t_e	P	t_d	N	t_e	P	t_d
14	16	0.010	89	15	0	0.000	120	15	31	0.053	89
	17	0.012	88		1	0.000	119		32	0.060	88
	18	0.015	87		2	0.000	118		33	0.068	87
	19	0.018	86		3	0.000	117		34	0.076	86
	20	0.021	85		4	0.000	116		35	0.084	85
	21	0.025	84		5	0.000	115		36	0.084	84
	22	0.029	83		6	0.000	114		37	0.104	83
	23	0.034	82		7	0.001	113		38	0.115	82
	24	0.039	81		8	0.001	112		39	0.126	81
	25	0.045	80		9	0.001	111		40	0.138	80
	26	0.052	79		10	0.001	110		41	0.151	79
	27	0.059	78		11	0.002	109		42	0.165	78
	28	0.068	77		12	0.002	108		43	0.180	77
	29	0.077	76		13	0.003	107		44	0.195	76
	30	0.086	75		14	0.003	106		45	0.211	75
	31	0.097	74		15	0.004	105		46	0.227	74
	32	0.108	73		16	0.005	104		47	0.244	73
	33	0.121	72		17	0.006	103		48	0.262	72
	34	0.134	71		18	0.008	102		49	0.281	71
	35	0.148	70		19	0.009	101		50	0.300	70
	36	0.163	69		20	0.011	100		51	0.319	69
	37	0.179	68		21	0.013	99		52	0.339	68
	38	0.196	67		22	0.015	98		53	0.360	67
	39	0.213	66		23	0.018	97		54	0.381	66
	40	0.232	65		24	0.021	96		55	0.402	65
	41	0.251	64		25	0.024	95		56	0.423	64
	42	0.271	63		26	0.028	94		57	0.445	63
	43	0.292	62		27	0.032	93		58	0.467	62
	44	0.313	61		28	0.036	92		59	0.489	61
	45	0.335	60		29	0.042	91		60	0.511	60
	46	0.357	58		30	0.047	90				
	47	0.380	58								
	48	0.404	57								
	49	0.428	56								
	50	0.452	55								
	51	0.476	54								
	52	0.500	53								

■ Tabela 12. Distribuição da Estatística W
(Teste de Mann-Whitney-Wilcoxon)

Os valores P referem-se à probabilidade de, para amostras de dimensões N_A e N_B (com $N_B \leq N_A \leq 10$), a estatística W tomar valores menores ou iguais a w_e (cauda esquerda) ou, alternativamente, tomar valores maiores ou iguais a w_d (cauda direita).

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 1$				$N_B = 2$				$N_B = 2$			
1	1	0.500	2	2	3	0.167	7	8	3	0.022	19
2	1	0.333	3		4	0.333	6		4	0.044	18
	2	0.667	2		5	0.667	5		5	0.089	17
3	1	0.250	4	3	3	0.100	9		6	0.133	16
	2	0.500	3		4	0.200	8		7	0.200	15
4	1	0.200	5		5	0.400	7		8	0.267	14
	2	0.400	4		6	0.600	6		9	0.356	13
	3	0.600	3	4	3	0.067	11		10	0.444	17
	1	0.167	6		4	0.133	10		11	0.556	11
	2	0.333	5		5	0.267	9	9	3	0.018	21
	3	0.500	4		6	0.400	8		4	0.036	20
6	1	0.143	7		7	0.600	7		5	0.073	19
	2	0.286	6	5	3	0.048	13		6	0.109	18
	3	0.429	5		4	0.095	12		7	0.164	17
	4	0.571	4		5	0.190	11		8	0.218	16
7	1	0.125	8		6	0.286	10		9	0.291	15
	2	0.250	7		7	0.429	9		10	0.364	14
	3	0.375	6		8	0.571	8		11	0.455	13
	4	0.500	5	6	3	0.036	15		12	0.545	12
8	1	0.111	9		4	0.071	14	10	3	0.015	23
	2	0.222	8		5	0.143	13		4	0.030	22
	3	0.333	7		6	0.214	12		5	0.061	21
	4	0.444	6		7	0.321	11		6	0.091	20
	5	0.556	5		8	0.429	10		7	0.136	19
9	1	0.100	10		9	0.571	9		8	0.182	18
	2	0.200	9	7	3	0.028	17		9	0.242	17
	3	0.300	8		4	0.056	16		10	0.303	16
		0.400	7		5	0.111	15		11	0.379	15
	5	0.500	6		6	0.167	14		12	0.455	14
10	1	0.091	11		7	0.250	13		13	0.545	13
	2	0.182	10		8	0.333	12				
	3	0.273	9		9	0.444	11				
	4	0.364	8		10	0.556	10				
	5	0.455	7								
	6	0.545	6								

/...

Adaptado de *A Nonparametric Introduction to Statistics*, Kraft/van Eeden, pp. 199-217, © 1968. Publicação autorizada por Prentice-Hall Inc., Upper Saddle River, NJ.

/...

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 3$				$N_B = 3$				$N_B = 4$			
3	6	0.050	15	8	6	0.006	30	4	10	0.014	26
	7	0.100	14		7	0.012	29		11	0.029	25
	8	0.200	13		8	0.024	28		12	0.057	24
	9	0.350	12		9	0.042	27		13	0.100	23
4	10	0.500	11	10	0.067	26	10	0.171	22		
	6	0.029	18	11	0.097	25	15	0.243	21		
	7	0.057	17	12	0.139	24	16	0.343	20		
	8	0.114	16	13	0.188	23	17	0.443	19		
5	9	0.200	15	14	0.248	22	18	0.557	18		
	10	0.314	14	15	0.315	21	5	10	0.008	30	
	11	0.429	13	16	0.388	20	11	0.016	29		
	12	0.571	12	17	0.461	19	12	0.032	28		
6	6	0.018	21	18	0.539	18	13	0.056	27		
	7	0.036	20	9	6	0.005	33	14	0.095	26	
	8	0.071	19		7	0.009	32	15	0.143	25	
	9	0.125	18		8	0.018	31	16	0.206	24	
10	0.196	17	9		0.032	30	17	0.278	23		
7	11	0.286	16	10	0.050	29	18	0.365	22		
	12	0.393	15	11	0.073	28	19	0.452	21		
	13	0.500	14	12	0.105	27	20	0.548	20		
	6	0.012	24	13	0.141	26	6	10	0.005	34	
8	7	0.024	23	14	0.186	25	11	0.010	33		
	8	0.048	22	15	0.241	24	12	0.019	32		
	9	0.083	21	16	0.300	23	13	0.033	31		
	10	0.131	20	17	0.364	22	14	0.057	30		
9	11	0.190	19	18	0.432	21	15	0.086	29		
	12	0.274	18	19	0.500	20	16	0.129	28		
	13	0.357	17	10	6	0.003	36	17	0.176	27	
	14	0.452	16		7	0.007	35	18	0.238	26	
15	0.548	15	8		0.014	34	19	0.305	25		
6	0.008	27	9		0.024	33	20	0.381	24		
10	7	0.017	26	10	0.038	32	21	0.457	23		
	8	0.033	25	11	0.056	31	22	0.543	22		
	9	0.058	24	12	0.080	30					
	10	0.092	23	13	0.108	29					
11	11	0.133	22	14	0.143	28					
	12	0.192	21	15	0.185	27					
	13	0.258	20	16	0.234	26					
	14	0.333	19	17	0.287	25					
12	15	0.417	18	18	0.346	24					
	16	0.500	17	19	0.406	23					
	20	0.469	22								
	21	0.531	21								

/...

/...

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 4$				$N_B = 4$				$N_B = 5$			
7	10	0.003	38	9	10	0.001	46	5	15	0.004	40
	11	0.006	37		11	0.003	45		16	0.008	39
	12	0.012	36		12	0.006	44		17	0.016	38
	13	0.021	35		13	0.010	43		18	0.028	37
	14	0.036	34		14	0.017	42		19	0.048	36
	15	0.055	33		15	0.025	41		20	0.075	35
	16	0.082	32		16	0.038	40		21	0.111	34
	17	0.115	31		17	0.053	39		22	0.155	33
	18	0.158	30		18	0.074	38		23	0.210	32
	19	0.206	29		19	0.099	37		24	0.274	31
	20	0.264	28		20	0.130	36		25	0.345	30
	21	0.324	27		21	0.165	35		26	0.421	29
8	22	0.394	26	22	0.207	34	6	27	0.500	28	
	23	0.464	25	23	0.252	33		15	0.002	45	
	24	0.536	24	24	0.302	32		16	0.004	44	
	10	0.002	42	25	0.355	31		17	0.009	43	
	11	0.004	41	26	0.413	30		18	0.015	42	
	12	0.008	40	27	0.470	29		19	0.026	41	
	13	0.014	39	28	0.530	28		20	0.041	40	
	14	0.024	38	10	10	0.001		50	21	0.063	39
	15	0.036	37		11	0.002		49	22	0.089	38
	16	0.055	36		12	0.004		48	23	0.123	37
	17	0.077	35		13	0.007		47	24	0.165	36
	18	0.107	34		14	0.012		46	25	0.214	35
19	0.141	33	15		0.018	45	26	0.268	34		
20	0.184	32	16		0.027	44	27	0.331	33		
21	0.230	31	17		0.038	43	28	0.396	32		
22	0.285	30	18		0.053	42	29	0.465	31		
23	0.341	29	19		0.071	41	30	0.535	30		
24	0.404	28	20		0.094	40					
25	0.467	27	21		0.120	39					
26	0.533	26	22	0.152	38						
			23	0.187	37						
			24	0.227	36						
			25	0.270	35						
			26	0.318	34						
			27	0.367	33						
			28	0.420	32						
			29	0.473	31						
			30	0.527	30						

/...

I...

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 5$				$N_B = 5$				$N_B = 6$			
7	15	0.001	50	9	15	0.000	60	6	21	0.001	57
	16	0.003	49		16	0.001	59		22	0.002	56
	17	0.005	48		17	0.002	58		23	0.004	55
	18	0.009	47		18	0.003	57		24	0.008	54
	19	0.015	46		19	0.006	56		25	0.013	53
	20	0.024	45		20	0.009	55		26	0.021	52
	21	0.037	44		21	0.014	54		27	0.032	51
	22	0.053	43		22	0.021	53		28	0.047	50
	23	0.074	42		23	0.030	52		29	0.066	49
	24	0.101	41		24	0.041	51		30	0.090	48
	25	0.134	40		25	0.056	50		31	0.120	47
	26	0.172	39		26	0.073	49		32	0.155	46
	27	0.216	38		27	0.095	48		33	0.197	45
	28	0.265	37		28	0.120	47		34	0.242	44
	29	0.319	36		29	0.149	46		35	0.294	43
	30	0.378	35		30	0.182	45		36	0.350	42
	31	0.438	34		31	0.219	44		37	0.409	41
	32	0.500	33		32	0.259	43		38	0.469	40
8	15	0.001	55		33	0.303	42		39	0.531	39
	16	0.002	54		34	0.350	41	7	21	0.001	63
	17	0.003	53		35	0.399	40		22	0.001	62
	18	0.005	52		36	0.449	39		23	0.002	61
	19	0.009	51		37	0.500	38		24	0.004	60
	20	0.015	50	10	15	0.000	65		25	0.007	59
	21	0.023	49		16	0.001	64		26	0.011	58
	22	0.033	48		17	0.001	63		27	0.017	57
	23	0.047	47		18	0.002	62		28	0.026	56
	24	0.064	46		19	0.004	61		29	0.037	55
	25	0.085	45		20	0.006	60		30	0.051	54
	26	0.111	44		21	0.010	59		31	0.069	53
	27	0.142	43		22	0.014	58		32	0.090	52
	28	0.177	42		23	0.020	57		33	0.117	51
	29	0.218	41		24	0.028	56		34	0.147	50
	30	0.262	40		25	0.038	55		35	0.183	49
	31	0.311	39		26	0.050	54		36	0.223	48
	32	0.362	38		27	0.065	53		37	0.267	47
	33	0.416	37		28	0.082	52		38	0.314	46
	34	0.472	36		29	0.103	51		39	0.365	45
	35	0.528	35		30	0.127	50		40	0.418	44
					31	0.155	49		41	0.473	43
					32	0.185	48		42	0.527	42
					33	0.220	47				
					34	0.257	46				
					35	0.297	45				
					36	0.339	44				
					37	0.384	43				
					38	0.430	42				
					39	0.477	41				
					40	0.523	40				

I...

I...

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 6$				$N_B = 6$				$N_B = 7$			
8	21	0.000	69	9	41	0.228	55	7	28	0.000	77
	22	0.001	68		42	0.264	54		29	0.001	76
	23	0.001	67		43	0.303	53		30	0.001	75
	24	0.002	66		44	0.344	52		31	0.002	74
	25	0.004	65		45	0.388	51		32	0.003	73
	26	0.006	64		46	0.432	50		33	0.006	72
	27	0.010	63		47	0.477	49		34	0.009	71
	28	0.015	62		48	0.523	48		35	0.013	70
	29	0.021	61	10	21	0.000	81		36	0.019	69
	30	0.030	60		22	0.000	80		37	0.027	68
	31	0.041	59		23	0.000	79		38	0.036	67
	32	0.054	58		24	0.001	78		39	0.049	66
	33	0.071	57		25	0.001	77		40	0.064	65
	34	0.091	56		26	0.002	76		41	0.082	64
	35	0.114	55		27	0.004	75		42	0.104	63
	36	0.141	54		28	0.005	74		43	0.130	62
	37	0.172	53		29	0.008	73		44	0.159	61
	38	0.207	52		30	0.011	72		45	0.191	60
	39	0.245	51		31	0.016	71		46	0.228	59
	40	0.286	50		32	0.021	70		47	0.267	58
	41	0.331	49		33	0.028	69		48	0.310	57
	42	0.377	48		34	0.036	68		49	0.355	56
	43	0.426	47		35	0.047	67		50	0.402	55
	44	0.475	46		36	0.059	66		51	0.451	54
	45	0.525	45		37	0.074	65		52	0.500	53
9	21	0.000	75		38	0.090	64	8	28	0.000	84
	22	0.000	74		39	0.110	63		29	0.000	83
	23	0.001	73		40	0.132	62		30	0.001	82
	24	0.001	72		41	0.157	61		31	0.001	81
	25	0.002	71		42	0.184	60		32	0.002	80
	26	0.004	70		43	0.214	59		33	0.003	79
	27	0.006	69		44	0.246	58		34	0.005	78
	28	0.009	68		45	0.281	57		35	0.007	77
	29	0.013	67		46	0.318	56		36	0.010	76
	30	0.018	66		47	0.356	55		37	0.014	75
	31	0.025	65		48	0.396	54		38	0.020	74
	32	0.033	64		49	0.437	53		39	0.027	73
	33	0.044	63		50	0.479	52		40	0.036	72
	34	0.057	62		51	0.521	51		41	0.047	71
	35	0.072	61						42	0.060	70
	36	0.091	60						43	0.076	69
	37	0.112	59						44	0.095	68
	38	0.136	58						45	0.116	67
	39	0.164	57						46	0.140	66
	40	0.194	56						47	0.168	65

I...

I...

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 7$				$N_B = 7$				$N_B = 8$			
8	48	0.198	64	10	28	0.000	98	8	36	0.000	100
	49	0.232	63		29	0.000	97		37	0.000	99
	50	0.268	62		30	0.000	96		38	0.000	98
	51	0.306	61		31	0.000	95		39	0.001	97
	52	0.347	60		32	0.001	94		40	0.001	96
	53	0.389	59		33	0.001	93		41	0.001	95
	54	0.433	58		34	0.002	92		42	0.002	94
	55	0.478	57		35	0.002	91		43	0.003	93
	56	0.522	56		36	0.003	90		44	0.005	92
9	28	0.000	91		37	0.005	89		45	0.007	91
	29	0.000	90		38	0.007	88		46	0.010	90
	30	0.000	89		39	0.009	87		47	0.014	89
	31	0.001	88		40	0.012	86		48	0.019	88
	32	0.001	87		41	0.017	85		49	0.025	87
	33	0.002	86		42	0.022	84		50	0.032	86
	34	0.003	85		43	0.028	83		51	0.041	85
	35	0.004	84		44	0.035	82		52	0.052	84
	36	0.006	83		45	0.044	81		53	0.065	83
	37	0.008	82		46	0.054	80		54	0.080	82
	38	0.011	81		47	0.067	79		55	0.097	81
	39	0.016	80		48	0.081	78		56	0.117	80
	40	0.021	79		49	0.097	77		57	0.139	79
	41	0.027	78		50	0.115	76		58	0.164	78
	42	0.036	77		51	0.135	75		59	0.191	77
	43	0.045	76		52	0.157	74		60	0.221	76
	44	0.057	75		53	0.182	73		61	0.253	75
	45	0.071	74		54	0.209	72		62	0.287	74
	46	0.087	73		55	0.237	71		63	0.323	73
	47	0.105	72		56	0.268	70		64	0.360	72
	48	0.126	71		57	0.300	69		65	0.399	71
	49	0.150	70		58	0.335	68		66	0.439	70
	50	0.176	69		59	0.370	67		67	0.480	69
	51	0.204	68		60	0.406	66		68	0.520	68
	52	0.235	67		61	0.443	65	9	36	0.000	108
	53	0.268	66		62	0.481	64		37	0.000	107
	54	0.303	65		63	0.519	63		38	0.000	106
	55	0.340	64						39	0.000	105
	56	0.379	63						40	0.000	104
	57	0.419	62						41	0.001	103
	58	0.459	61						42	0.001	102
	59	0.500	60						43	0.002	101

I...

I...

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 8$				$N_B = 8$				$N_B = 9$			
9	44	0.003	100	10	36	0.000	116	9	45	0.000	126
	45	0.004	99		37	0.000	115		46	0.000	125
	46	0.006	98		38	0.000	114		47	0.000	124
	47	0.008	97		39	0.000	113		48	0.000	123
	48	0.010	96		40	0.000	112		49	0.000	122
	49	0.014	95		41	0.000	111		50	0.000	121
	50	0.018	94		42	0.001	110		51	0.001	120
	51	0.023	93		43	0.001	109		52	0.001	119
	52	0.030	92		44	0.002	108		53	0.001	118
	53	0.037	91		45	0.002	107		54	0.002	117
	54	0.046	90		46	0.003	106		55	0.003	116
	55	0.057	89		47	0.004	105		56	0.004	115
	56	0.069	88		48	0.006	104		57	0.005	114
	57	0.084	87		49	0.008	103		58	0.007	113
	58	0.100	86		50	0.010	102		59	0.009	112
	59	0.118	85		51	0.013	101		60	0.012	111
	60	0.138	84		52	0.017	100		61	0.016	110
	61	0.161	83		53	0.022	99		62	0.020	109
	62	0.185	82		54	0.027	98		63	0.025	108
	63	0.212	81		55	0.034	97		64	0.031	107
	64	0.240	80		56	0.042	96		65	0.039	106
	65	0.271	79		57	0.051	95		66	0.047	105
	66	0.303	78		58	0.061	94		67	0.057	104
	67	0.336	77		59	0.073	93		68	0.068	103
	68	0.371	76		60	0.086	92		69	0.081	102
	69	0.407	75		61	0.102	91		70	0.095	101
	70	0.444	74		62	0.118	90		71	0.111	100
	71	0.481	73		63	0.137	89		72	0.129	99
	72	0.519	72		64	0.158	88		73	0.149	98
					65	0.180	87		74	0.170	97
					66	0.204	86		75	0.193	96
					67	0.230	85		76	0.218	95
					68	0.257	84		77	0.245	94
					69	0.286	83		78	0.273	93
					70	0.317	82		79	0.302	92
					71	0.348	81		80	0.333	91
					72	0.381	80		81	0.365	90
					73	0.414	79		82	0.398	89
					74	0.448	78		83	0.432	88
					75	0.483	77		84	0.466	87
					76	0.517	76		85	0.500	86

I...

N_A	w_e	P	w_d	N_A	w_e	P	w_d	N_A	w_e	P	w_d
$N_B = 9$				$N_B = 9$				$N_B = 10$			
10	45	0.000	135	10	78	0.178	102	10	73	0.007	137
	46	0.000	134		79	0.200	101		74	0.009	136
	47	0.000	133		80	0.223	100		75	0.012	135
	48	0.000	132		81	0.248	99		76	0.014	134
	49	0.000	131		82	0.274	98		77	0.018	133
	50	0.000	130		83	0.302	97		78	0.022	132
	51	0.000	129		84	0.330	96		79	0.026	131
	52	0.000	128		85	0.360	95		80	0.032	130
	53	0.001	127		86	0.390	94		81	0.038	129
	54	0.001	126		87	0.421	93		82	0.045	128
	55	0.001	125		88	0.452	92		83	0.053	127
	56	0.002	124		89	0.484	91		84	0.062	126
	57	0.003	123		90	0.516	90		85	0.072	125
	58	0.004	122						86	0.083	124
	59	0.005	121						87	0.095	123
	60	0.007	120						88	0.109	122
	61	0.009	119						89	0.124	121
	62	0.011	118						90	0.140	120
	63	0.014	117	10	55	0.000	155		91	0.157	119
	64	0.017	116		56	0.000	154		92	0.176	118
	65	0.022	115		57	0.000	153		93	0.197	117
	66	0.027	114		58	0.000	152		94	0.218	116
	67	0.033	113		59	0.000	151		95	0.241	115
	68	0.039	112		60	0.000	150		96	0.264	114
	69	0.047	111		61	0.000	149		97	0.289	113
	70	0.056	110		62	0.000	148		98	0.315	112
	71	0.067	109		63	0.000	147		99	0.342	111
	72	0.078	108		64	0.001	146		100	0.370	110
	73	0.091	107		65	0.001	145		101	0.398	109
	74	0.106	106		66	0.001	144		102	0.427	108
	75	0.121	105		67	0.001	143		103	0.456	107
	76	0.139	104		68	0.002	142		104	0.485	106
	77	0.158	103		69	0.003	141		105	0.515	105
					70	0.003	140				
					71	0.004	139				
					72	0.006	138				

Os valores P referem-se à probabilidade de, em amostras com dimensões N_A e N_B , a estatística R tomar valores menores ou iguais a r_e (cauda esquerda) ou, alternativamente, tomar valores maiores ou iguais a r_r (cauda direita).

P: probabilidade na cauda esquerda															
N_B	N_A	r_e	P	N_B	N_A	r_e	P	N_B	N_A	r_e	P	N_B	N_A	r_e	P
2	2	2	0.333	2	18	2	0.011	3	14	2	0.003	4	10	2	0.002
2	3	2	0.200			3	0.105			3	0.025			3	0.014
		3	0.500			4	0.284			4	0.101			4	0.068
2	4	2	0.133	3	3	2	0.100			5	0.350			5	0.203
		3	0.400			3	0.300	3	15	2	0.002			6	0.419
2	5	2	0.095	3	4	2	0.057			3	0.022	4	11	2	0.001
		3	0.333			3	0.200			4	0.091			3	0.011
2	6	2	0.071	3	5	2	0.036			5	0.331			4	0.055
		3	0.286			3	0.143	3	16	2	0.002			5	0.176
2	7	2	0.056			4	0.429			3	0.020			6	0.374
		3	0.250	3	6	2	0.024			4	0.082	4	12	2	0.001
2	8	2	0.044			3	0.107			5	0.314			3	0.009
		3	0.222			4	0.345	3	17	2	0.002			4	0.045
2	9	2	0.036	3	7	2	0.017			3	0.018			5	0.154
		3	0.200			3	0.083			4	0.074			6	0.335
		4	0.491			4	0.283			5	0.298	4	13	2	0.001
2	10	2	0.030	3	8	2	0.012	4	4	2	0.029			3	0.007
		3	0.182			3	0.067			3	0.114			4	0.037
		4	0.455			4	0.236			4	0.371			5	0.136
2	11	2	0.026	3	9	2	0.009	4	5	2	0.016			6	0.302
		3	0.167			3	0.055			3	0.071	4	14	2	0.001
		4	0.423			4	0.200			4	0.262			3	0.006
2	12	2	0.022			5	0.491			5	0.500			4	0.031
		3	0.154	3	10	2	0.007	4	6	2	0.010			5	0.121
		4	0.396			3	0.045			3	0.048			6	0.274
2	13	2	0.019			4	0.171			4	0.190	4	15	2	0.001
		3	0.143			5	0.455			5	0.405			3	0.005
		4	0.371	3	11	2	0.005	4	7	2	0.006			4	0.027
2	14	2	0.017			3	0.038			3	0.033			5	0.108
		3	0.133			4	0.148			4	0.142			6	0.249
		4	0.350			5	0.423			5	0.333	4	16	2	0.000
2	15	2	0.015	3	12	2	0.004	4	8	2	0.004			3	0.004
		3	0.125			3	0.033			3	0.024			4	0.023
		4	0.331			4	0.130			4	0.109			5	0.097
2	16	2	0.013			5	0.396			5	0.279			6	0.227
		3	0.118	3	13	2	0.004	4	9	2	0.003	5	5	2	0.008
		4	0.314			3	0.029			3	0.018			3	0.040
2	17	2	0.012			4	0.114			4	0.085			4	0.167
		3	0.111			5	0.371			5	0.236			5	0.357
		4	0.298							6	0.471				

Adaptado de F. S. Swed e C. Eisenhart [1943], "Tables for Testing Randomness of Grouping in a Sequence of Alternatives", *Annals of Mathematical Statistics*, Vol. 14, pp. 66-87.

/...

P: probabilidade na cauda esquerda

N_B	N_A	r_e	P	N_B	N_A	r_e	P	N_B	N_A	r_e	P	N_B	N_A	r_e	P
5	6	2	0.004	5	14	2	0.000	6	11	2	0.000	7	9	2	0.000
	3		0.024		3		0.002		3		0.001		3		0.001
	4		0.110		4		0.011		4		0.009		4		0.010
	5		0.262		5		0.044		5		0.036		5		0.035
5	7	2	0.003		6		0.125		6		0.108		6		0.108
	3		0.015		7		0.299		7		0.242		7		0.231
	4		0.076		8		0.496		8		0.436		8		0.427
	5		0.197	5	15	2	0.000	6	12	2	0.000	7	10	2	0.000
	6		0.424		3		0.001		3		0.001		3		0.001
5	8	2	0.002		4		0.009		4		0.007		4		0.006
	3		0.010		5		0.037		5		0.028		5		0.024
	4		0.054		6		0.108		6		0.087		6		0.080
	5		0.152		7		0.272		7		0.205		7		0.182
	6		0.347		8		0.460		8		0.383		8		0.355
5	9	2	0.001	6	6	2	0.002	6	13	2	0.000	7	11	2	0.000
	3		0.007		3		0.013		3		0.001		3		0.001
	4		0.039		4		0.067		4		0.005		4		0.004
	5		0.119		5		0.175		5		0.022		5		0.018
	6		0.287		6		0.392		6		0.070		6		0.060
5	10	2	0.001	6	7	2	0.001		7		0.176		7		0.145
	3		0.005		3		0.008		8		0.338		8		0.296
	4		0.029		4		0.043	6	14	2	0.000		9		0.484
	5		0.095		5		0.121		3		0.001	7	12	2	0.000
	6		0.239		6		0.296		4		0.004		3		0.000
	7		0.455		7		0.500		5		0.017		4		0.003
5	11	2	0.000	6	8	2	0.001		6		0.058		5		0.013
	3		0.004		3		0.005		7		0.151		6		0.046
	4		0.022		4		0.028		8		0.299		7		0.117
	5		0.077		5		0.086	7	7	2	0.001		8		0.247
	6		0.201		6		0.226		3		0.004		9		0.428
	7		0.407		7		0.413		4		0.025	7	13	2	0.000
5	12	2	0.000	6	9	2	0.000		5		0.078		3		0.000
	3		0.003		3		0.003		6		0.209		4		0.002
	4		0.017		4		0.019		7		0.383		5		0.010
	5		0.063		5		0.063	7	8	2	0.000		6		0.035
	6		0.170		6		0.175		3		0.002		7		0.095
	7		0.365		7		0.343		4		0.015		8		0.208
5	13	2	0.000	6	10	2	0.000		5		0.051		9		0.378
	3		0.002		3		0.002		6		0.149	8	8	2	0.000
	4		0.013		4		0.013		7		0.296		3		0.001
	5		0.053		5		0.047						4		0.009
	6		0.145		6		0.137						5		0.032
	7		0.330		7		0.287						6		0.100
					8		0.497						8		0.405

.../

/...

P: probabilidade na cauda esquerda

N_B	N_A	r_e	P	N_B	N_A	r_e	P	N_B	N_A	r_e	P	N_B	N_A	r_e	P
8	9	2	0.000	9	9	2	0.000	10	10	2	0.000	11	11	2	0.000
	3		0.001		3		0.000		3		0.000		3		0.000
	4		0.005		4		0.003		4		0.001		4		0.000
	5		0.020		5		0.012		5		0.004		5		0.002
	6		0.069		6		0.044		6		0.019		6		0.007
	7		0.157		7		0.109		7		0.051		7		0.023
	8		0.319		8		0.238		8		0.128		8		0.063
	9		0.500		9		0.399		9		0.242		9		0.135
8	10	2	0.000	9	10	2	0.000		10		0.414		10		0.260
	3		0.000		3		0.000	10	11	2	0.000		11		0.410
	4		0.003		4		0.002		3		0.000	11	12	2	0.000
	5		0.013		5		0.008		4		0.001		3		0.000
	6		0.048		6		0.029		5		0.003		4		0.000
	7		0.117		7		0.077		6		0.012		5		0.001
	8		0.251		8		0.179		7		0.035		6		0.005
	9		0.419		9		0.319		8		0.092		7		0.015
8	11	2	0.000	9	11	2	0.000		9		0.185		8		0.044
	3		0.000		3		0.000		10		0.335		9		0.099
	4		0.002		4		0.001		11		0.500		10		0.202
	5		0.009		5		0.005	10	12	2	0.000		11		0.335
	6		0.034		6		0.020		3		0.000	12	12	2	0.000
	7		0.088		7		0.055		4		0.000		3		0.000
	8		0.199		8		0.135		5		0.002		4		0.000
	9		0.352		9		0.255		6		0.008		5		0.001
8	12	2	0.000		10		0.430		7		0.024		6		0.003
	3		0.000	9	12	2	0.000		8		0.067		7		0.009
	4		0.001		3		0.000		9		0.142		8		0.030
	5		0.006		4		0.001		10		0.271		9		0.070
	6		0.025		5		0.003		11		0.425		10		0.150
	7		0.067		6		0.014						11		0.263
	8		0.159		7		0.040						12		0.421
	9		0.297		8		0.103								
	10		0.480		9		0.205								
					10		0.362								

/...

P: probabilidade na cauda direita															
N_B	N_A	r_d	P	N_B	N_A	r_d	P	N_B	N_A	r_d	P	N_B	N_A	r_d	P
2	2	4	0.333	4	10	9	0.126	5	14	11	0.111	7	7	14	0.001
2	3	5	0.100			8	0.294			10	0.234			13	0.004
		4	0.500	4	11	9	0.154	5	15	11	0.129			12	0.025
2	4	5	0.200			8	0.330			10	0.258			11	0.078
2	5	5	0.286	4	12	9	0.181	6	6	12	0.002			10	0.209
2	6	5	0.357			8	0.363			11	0.013			9	0.383
2	7	5	0.417	4	13	9	0.208			10	0.067	7	8	15	0.000
2	8	5	0.467			8	0.393			9	0.175			14	0.002
3	3	6	0.100	4	14	9	0.234			8	0.392			13	0.012
		5	0.300			8	0.421	6	7	13	0.001			12	0.051
3	4	7	0.029	4	15	9	0.258			12	0.008			11	0.133
		6	0.200			8	0.446			11	0.034			10	0.296
		5	0.457	4	16	9	0.282			10	0.121			9	0.486
3	5	7	0.071			8	0.470			9	0.267	7	9	15	0.001
		6	0.286	5	5	10	0.008			8	0.500			14	0.006
3	6	7	0.119			9	0.040	6	8	13	0.002			13	0.025
		6	0.357			8	0.167			12	0.016			12	0.084
3	7	7	0.167			7	0.357			11	0.063			11	0.194
		6	0.417	5	6	11	0.002			10	0.179			10	0.378
3	8	7	0.212			10	0.024			9	0.354	7	10	15	0.002
		6	0.467			9	0.089	6	9	13	0.006			14	0.010
3	9	7	0.255			8	0.262			12	0.028			13	0.043
3	10	7	0.294			7	0.478			11	0.098			12	0.121
3	11	7	0.330	5	7	11	0.008			10	0.238			11	0.257
3	12	7	0.363			10	0.045			9	0.434			10	0.451
3	13	7	0.393			9	0.146	6	10	13	0.010	7	11	15	0.004
3	14	7	0.421			8	0.348			12	0.042			14	0.017
3	15	7	0.446	5	8	11	0.016			11	0.136			13	0.064
3	16	7	0.470			10	0.071			10	0.294			12	0.160
3	17	7	0.491			9	0.207	6	11	13	0.017			11	0.318
4	4	8	0.029			8	0.424			12	0.058	7	12	15	0.007
		7	0.114	5	9	11	0.028			11	0.176			14	0.025
		6	0.371			10	0.098			10	0.346			13	0.089
4	5	9	0.008			9	0.266	6	12	13	0.025			12	0.199
		8	0.071			8	0.490			12	0.075			11	0.376
		7	0.214	5	10	11	0.042			11	0.217	7	13	15	0.010
		6	0.500			10	0.126			10	0.395			14	0.034
4	6	9	0.024			9	0.322	6	13	13	0.034			13	0.116
		8	0.119	5	11	11	0.058			12	0.092			12	0.238
		7	0.310			10	0.154			11	0.257			11	0.430
4	7	9	0.045			9	0.374			10	0.439	8	8	16	0.000
		8	0.167	5	12	11	0.075	6	14	13	0.044			15	0.001
		7	0.394			10	0.181			12	0.111			14	0.009
4	8	9	0.071			9	0.421			11	0.295			13	0.032
		8	0.212	5	13	11	0.092			10	0.480			12	0.100
		7	0.467			10	0.208							11	0.214
4	9	9	0.098			9	0.465							10	0.405
		8	0.255												

.../

/...

P: probabilidade na cauda direita															
N_B	N_A	r_d	P	N_B	N_A	r_d	P	N_B	N_A	r_d	P	N_B	N_A	r_d	P
8	9	17	0.000	9	9	18	0.000	10	10	20	0.000	11	11	22	0.000
		16	0.001			17	0.000			19	0.000			21	0.000
		15	0.004			16	0.003			18	0.000			20	0.000
		14	0.020			15	0.012			17	0.001			19	0.002
		13	0.061			14	0.044			16	0.004			18	0.007
		12	0.157			13	0.109			17	0.019			17	0.023
		11	0.298			12	0.238			16	0.051			16	0.063
		10	0.500			11	0.399			15	0.128			15	0.135
8	10	17	0.000	9	10	19	0.000			14	0.242			14	0.260
		16	0.002			18	0.000			13	0.414			13	0.410
		15	0.010			17	0.001	10	11	21	0.000	11	12	23	0.000
		14	0.036			16	0.008			20	0.000			22	0.000
		13	0.097			15	0.026			19	0.000			21	0.000
		12	0.218			14	0.077			18	0.003			20	0.001
		11	0.379			13	0.166			17	0.010			19	0.004
8	11	17	0.001			12	0.319			16	0.035			18	0.015
		16	0.004			11	0.490			15	0.085			17	0.041
		15	0.018	9	11	19	0.000			14	0.185			16	0.099
		14	0.057			18	0.001			13	0.320			15	0.191
		13	0.138			17	0.003			12	0.500			14	0.335
		12	0.278			16	0.015	10	12	21	0.000			13	0.493
		11	0.453			15	0.045			20	0.000	12	12	24	0.000
8	12	17	0.001			14	0.115			19	0.001			23	0.000
		16	0.007			13	0.227			18	0.006			22	0.000
		15	0.029			12	0.395			17	0.020			21	0.001
		14	0.080							16	0.056			20	0.003
		13	0.183							15	0.125			19	0.009
		12	0.137							14	0.245			18	0.030
										13	0.395			17	0.070
														16	0.150
														15	0.263
														14	0.421

■ Tabela 14. Distribuição da Estatística V
(Teste das Sequências Ascendentes e Descendentes)

Os valores P_e e P_d referem-se às probabilidades de, em amostras com dimensão N , a estatística V tomar, respectivamente, valores menores ou iguais a v_e (cauda esquerda) ou valores maiores ou iguais a v_d (cauda direita).

N	v_e	P_e	v_d	P_d	N	v_e	P_e	v_d	P_d
3	1	0.3333	2	0.6667	13	1	0.0000		
4			3	0.4167		2	0.0000		
	1	0.0833	2	0.9167		3	0.0001	12	0.0072
5	1	0.0167	4	0.2667		4	0.0026	11	0.0568
	2	0.2500	3	0.7500		5	0.0213	10	0.2058
6	1	0.0028				6	0.0964	9	0.4587
	2	0.0861	5	0.1694		7	0.2749	8	0.7251
	3	0.4139	4	0.5861	14	1	0.0000		
7	1	0.0004	6	0.1079		2	0.0000		
	2	0.0250	5	0.4417		3	0.0000		
	3	0.1909	4	0.8091		4	0.0007	13	0.0046
8	1	0.0000				5	0.0079	12	0.0391
	2	0.0063	7	0.0687		6	0.0441	11	0.1536
	3	0.0749	6	0.3250		7	0.1534	10	0.3722
	4	0.3124	5	0.6876		8	0.3633	9	0.6367
9	1	0.0000			15	1	0.0000		
	2	0.0014				2	0.0000		
	3	0.0257	8	0.0437		3	0.0000		
	4	0.1500	7	0.2347		4	0.0002		
	5	0.4347	6	0.5653		5	0.0027	14	0.0029
10	1	0.0000				6	0.0186	13	0.0267
	2	0.0003	9	0.0278		7	0.0782	12	0.1134
	3	0.0079	8	0.1671		8	0.2216	11	0.2970
	4	0.0633	7	0.4524		9	0.4520	10	0.5480
	5	0.2427	6	0.7573	16	1	0.0000		
11	1	0.0000				2	0.0000		
	2	0.0001				3	0.0000		
	3	0.0022	10	0.0177		4	0.0001	15	0.0019
	4	0.0239	9	0.1177		5	0.0009	14	0.0182
	5	0.1196	8	0.3540		6	0.0072	13	0.0828
	6	0.3438	7	0.6562		7	0.0367	12	0.2335
12	1	0.0000				8	0.1238	11	0.4631
	2	0.0000				9	0.2975	10	0.7025
	3	0.0005							
	4	0.0082	11	0.0113					
	5	0.0529	10	0.0821					
	6	0.1918	9	0.2720					
	7	0.4453	8	0.5547					

/...

N	v_e	P_e	v_d	P_d	N	v_e	P_e	v_d	P_d
17	1	0.0000			21	1	0.0000		
	2	0.0000				2	0.0000		
	3	0.0000				3	0.0000		
	4	0.0000				4	0.0000		
	5	0.0003	16	0.0012		5	0.0000		
	6	0.0026	15	0.0123		6	0.0000		
	7	0.0160	14	0.0600		7	0.0003	20	0.0002
	8	0.0638	13	0.1812		8	0.0023	19	0.0025
	9	0.1799	12	0.3850		9	0.0117	18	0.0154
	10	0.3770	11	0.6230		10	0.0431	17	0.0591
18	1	0.0000				11	0.1202	16	0.1602
	2	0.0000				12	0.2622	15	0.3293
	3	0.0000				13	0.4603	14	0.5397
	4	0.0000			22	1	0.0000		
	5	0.0001				2	0.0000		
	6	0.0009	17	0.0008		3	0.0000		
	7	0.0065	16	0.0083		4	0.0000		
	8	0.0306	15	0.0431		5	0.0000		
	9	0.1006	14	0.1389		6	0.0000	21	0.0001
	10	0.2443	13	0.3152		7	0.0001	20	0.0017
	11	0.4568	12	0.5432		8	0.0009	19	0.0108
19	1	0.0000				9	0.0050	18	0.0437
	2	0.0000				10	0.0213	17	0.1251
	3	0.0000				11	0.0674	16	0.2714
	4	0.0000				12	0.1661	15	0.4688
	5	0.0000	18	0.0005		13	0.3276	14	0.6724
	6	0.0003	17	0.0056	23	1	0.0000		
	7	0.0025	16	0.0308		2	0.0000		
	8	0.0137	15	0.1055		3	0.0000		
	9	0.0523	14	0.2546		4	0.0000		
	10	0.1467	13	0.4663		5	0.0000		
	11	0.3144	12	0.6856		6	0.0000		
20	1	0.0000				7	0.0000	22	0.0001
	2	0.0000				8	0.0003	21	0.0011
	3	0.0000				9	0.0021	20	0.0076
	4	0.0000				10	0.0099	19	0.0321
	5	0.0000				11	0.0356	18	0.0968
	6	0.0001	19	0.0003		12	0.0988	17	0.2211
	7	0.0009	18	0.0038		13	0.2188	16	0.4020
	8	0.0058	17	0.0218		14	0.3953	15	0.6047
	9	0.0255	16	0.0793					
	10	0.0821	15	0.2031					
	11	0.2012	14	0.3945					
	12	0.3873	13	0.6127					

.../

I...

N	v_e	P_e	v_d	P_d	N	v_e	P_e	v_d	P_d
24	1	0.0000			25	1	0.0000		
	2	0.0000				2	0.0000		
	3	0.0000				3	0.0000		
	4	0.0000				4	0.0000		
	5	0.0000				5	0.0000		
	6	0.0000				6	0.0000		
	7	0.0000				7	0.0000	24	0.0000
	8	0.0001	23	0.0000		8	0.0000	23	0.0005
	9	0.0008	22	0.0007		9	0.0003	22	0.0037
	10	0.0044	21	0.0053		10	0.0018	21	0.0170
	11	0.0177	20	0.0235		11	0.0084	20	0.0564
	12	0.0554	19	0.0742		12	0.0294	19	0.1423
	13	0.1374	18	0.1783		13	0.0815	18	0.2852
	14	0.2768	17	0.3405		14	0.1827	17	0.4708
	15	0.4631	16	0.5369		15	0.3384	16	0.6616

■ Tabela 15. Valores Críticos da Distribuição do Coeficiente de Correlação Ordinal de Spearman

Valores críticos da distribuição da estatística R_s para amostras de dimensão N e níveis de significância α .

N	α			
	0.05	0.025	0.01	0.005
5	0.900	—	—	—
6	0.829	0.886	0.943	—
7	0.714	0.786	0.893	—
8	0.643	0.738	0.833	0.881
9	0.600	0.683	0.783	0.833
10	0.564	0.648	0.745	0.794
11	0.523	0.623	0.736	0.818
12	0.497	0.591	0.703	0.780
13	0.475	0.566	0.673	0.745
14	0.457	0.545	0.646	0.716
15	0.441	0.525	0.623	0.689
16	0.425	0.507	0.601	0.666
17	0.412	0.490	0.582	0.645
18	0.399	0.476	0.564	0.625
19	0.388	0.462	0.549	0.608
20	0.377	0.450	0.534	0.591
21	0.368	0.438	0.521	0.576
22	0.359	0.428	0.508	0.562
23	0.351	0.418	0.496	0.549
24	0.343	0.409	0.485	0.537
25	0.336	0.400	0.475	0.526
26	0.329	0.392	0.465	0.515
27	0.323	0.385	0.456	0.505
28	0.317	0.377	0.448	0.496
29	0.311	0.370	0.440	0.487
30	0.305	0.364	0.432	0.478

Adaptado de E. G. Olds [1938], "Distribution of Sums of Squares of Rank Differences for Small Samples", *Annals of Mathematical Statistics*, Vol. 9.

■ Tabela 16. Factor $q_{N, GL}(\alpha)$ (Para o Cálculo de Intervalos de Confiança pelo Método de Tukey)


Valores críticos da distribuição da estatística $q_{N, GL}$ para níveis de significância $\alpha = 0.05$ e $\alpha = 0.01$, em que N representa ou o número de grupos, ou o número de linhas, ou o número de colunas, ou, ainda, o número de linhas vezes o número de colunas, e GL representa o número de graus de liberdade.

GL	α	N											
		2	3	4	5	6	7	8	9	10	11	12	
2	0.05	6.08	8.33	9.80	10.9	11.7	12.4	13.0	13.5	14.0	14.4	14.7	
	0.01	14.0	19.0	22.3	24.7	26.6	28.2	29.5	30.7	31.7	32.6	33.4	
3	0.05	4.50	5.91	6.82	7.50	8.04	8.48	8.85	9.18	9.46	9.72	9.95	
	0.01	8.26	10.6	12.2	13.3	14.2	15.0	15.6	16.2	16.7	17.1	17.5	
4	0.05	3.93	5.04	5.76	6.29	6.71	7.05	7.35	7.60	7.83	8.03	8.21	
	0.01	6.51	8.12	9.17	9.96	10.6	11.1	11.5	11.9	12.3	12.6	12.8	
5	0.05	3.64	4.60	5.22	5.67	6.03	6.33	6.58	6.80	6.99	7.17	7.32	
	0.01	5.70	6.97	7.80	8.42	8.91	9.32	9.67	9.97	10.2	10.5	10.7	
6	0.05	3.46	4.34	4.90	5.30	5.63	5.90	6.12	6.32	6.49	6.65	6.79	
	0.01	5.70	6.97	7.80	8.42	8.91	9.32	9.67	9.97	10.2	10.5	10.7	
7	0.05	3.34	4.16	4.68	5.06	5.36	5.61	5.82	6.00	6.16	6.30	6.43	
	0.01	4.95	5.92	6.54	7.01	7.37	7.68	7.94	8.17	8.37	8.55	8.71	
8	0.05	3.26	4.04	4.53	4.89	5.17	5.40	5.60	5.77	5.92	6.05	6.18	
	0.01	4.74	5.63	6.20	6.63	6.96	7.24	7.47	7.68	7.87	8.03	8.18	
9	0.05	3.20	3.95	4.41	4.76	5.02	5.24	5.43	5.59	5.74	5.87	5.98	
	0.01	4.60	5.43	5.96	6.35	6.66	6.91	7.13	7.32	7.49	7.65	7.78	
10	0.05	3.15	3.88	4.33	4.65	4.91	5.12	5.30	5.46	5.60	5.72	5.83	
	0.01	4.48	5.27	5.77	6.14	6.43	6.67	6.87	7.05	7.21	7.36	7.48	
11	0.05	3.11	3.82	4.26	4.57	4.82	5.03	5.20	5.35	5.49	5.61	5.71	
	0.01	4.39	5.14	5.62	5.97	6.25	6.48	6.67	6.84	6.99	7.13	7.25	
12	0.05	3.08	3.77	4.20	4.51	4.75	4.95	5.12	5.27	5.39	5.51	5.61	
	0.01	4.32	5.04	5.50	5.84	6.10	6.32	6.51	6.67	6.81	6.94	7.06	
13	0.05	3.06	3.73	4.15	4.45	4.69	4.88	5.05	5.19	5.32	5.43	5.53	
	0.01	4.26	4.96	5.40	5.73	5.98	6.19	6.37	6.53	6.67	6.79	6.90	
14	0.05	3.03	3.70	4.11	4.41	4.64	4.83	4.99	5.13	5.25	5.36	5.46	
	0.01	4.21	4.89	5.32	5.63	5.88	6.08	6.26	6.41	6.54	6.66	6.77	
15	0.05	3.01	3.67	4.08	4.37	4.59	4.78	4.94	5.08	5.20	5.31	5.40	
	0.01	4.17	4.83	5.25	5.56	5.80	5.99	6.16	6.31	6.44	6.55	6.66	
16	0.05	3.00	3.65	4.05	4.33	4.56	4.74	4.90	5.03	5.15	5.26	5.35	
	0.01	4.13	4.78	5.19	5.49	5.72	5.92	6.08	6.22	6.35	6.46	6.56	
17	0.05	2.98	3.63	4.02	4.30	4.52	4.70	4.86	4.99	5.11	5.21	5.31	
	0.01	4.10	4.74	5.14	5.43	5.66	5.85	6.01	6.15	6.27	6.38	6.48	


/...

GL	α	N											
		2	3	4	5	6	7	8	9	10	11	12	
18	0.05	2.97	3.61	4.00	4.28	4.49	4.67	4.82	4.96	5.07	5.17	5.27	
	0.01	4.07	4.70	5.09	5.38	5.60	5.79	5.94	6.08	6.20	6.31	6.41	
19	0.05	2.96	3.59	3.98	4.25	4.47	4.65	4.79	4.92	5.04	5.14	5.23	
	0.01	4.05	4.67	5.05	5.33	5.55	5.73	5.89	6.02	6.14	6.25	6.34	
20	0.05	2.95	3.58	3.96	4.23	4.45	4.62	4.77	4.90	5.01	5.11	5.20	
	0.01	4.02	4.64	5.02	5.29	5.51	5.69	5.84	5.97	6.09	6.19	6.29	
24	0.05	2.92	3.53	3.90	4.17	4.37	4.54	4.68	4.81	4.92	5.01	5.10	
	0.01	3.96	4.54	4.91	5.17	5.37	5.54	5.69	5.81	5.92	6.02	6.11	
30	0.05	2.89	3.49	3.85	4.10	4.30	4.46	4.60	4.72	4.82	4.92	5.00	
	0.01	3.89	4.45	4.80	5.05	5.24	5.40	5.54	5.65	5.76	5.85	5.93	
40	0.05	2.86	3.44	3.79	4.04	4.23	4.39	4.52	4.63	4.73	4.82	4.90	
	0.01	3.82	4.37	4.70	4.93	5.11	5.27	5.39	5.50	5.60	5.69	5.77	
60	0.05	2.83	3.40	3.74	3.98	4.16	4.31	4.44	4.55	4.65	4.73	4.81	
	0.01	3.76	4.28	4.60	4.82	4.99	5.13	5.25	5.36	5.45	5.53	5.60	
120	0.05	2.80	3.36	3.68	3.92	4.10	4.24	4.36	4.47	4.56	4.64	4.71	
	0.01	3.70	4.20	4.50	4.71	4.87	5.01	5.12	5.21	5.30	5.38	5.44	
∞	0.05	2.77	3.31	3.63	3.86	4.03	4.17	4.29	4.39	4.47	4.55	4.62	
	0.01	3.64	4.12	4.40	4.60	4.76	4.88	4.99	5.08	5.16	5.23	5.29	

GL	α	N							
		13	14	15	16	17	18	19	20
2	0.05	15.1	15.4	15.7	15.9	16.1	16.4	16.6	16.8
	0.01	34.1	34.8	35.4	36.0	36.5	37.0	37.5	37.9
3	0.05	10.2	10.3	10.5	10.7	10.8	11.0	11.1	11.2
	0.01	17.9	18.2	18.5	18.8	19.1	19.3	19.5	19.8
4	0.05	8.37	8.52	8.66	8.79	8.91	9.03	9.13	9.23
	0.01	13.1	13.3	13.5	13.7	13.9	14.1	14.2	14.4
5	0.05	7.47	7.60	7.72	7.83	7.93	8.03	8.12	8.21
	0.01	10.9	11.1	11.2	11.4	11.6	11.7	11.8	11.9
6	0.05	6.92	7.03	7.14	7.24	7.34	7.43	7.51	7.59
	0.01	9.65	9.81	9.95	10.1	10.2	10.3	10.4	10.5
7	0.05	6.55	6.66	6.76	6.85	6.94	7.02	7.10	7.17
	0.01	8.86	9.00	9.12	9.24	9.35	9.46	9.55	9.65
8	0.05	6.29	6.39	6.48	6.57	6.65	6.73	6.80	6.87
	0.01	8.31	8.44	8.55	8.66	8.76	8.85	8.94	9.03
9	0.05	6.09	6.19	6.28	6.36	6.44	6.51	6.58	6.64
	0.01	7.91	8.03	8.13	8.23	8.32	8.41	8.49	8.57
10	0.05	5.93	6.03	6.11	6.19	6.27	6.34	6.40	6.47
	0.01	7.60	7.71	7.81	7.91	7.99	8.07	8.15	8.22
11	0.05	5.81	5.90	5.98	6.06	6.13	6.20	6.27	6.33
	0.01	7.36	7.46	7.56	7.65	7.73	7.81	7.88	7.95
12	0.05	5.71	5.80	5.88	5.95	6.02	6.09	6.15	6.21
	0.01	7.17	7.26	7.36	7.44	7.52	7.59	7.66	7.73
13	0.05	5.63	5.71	5.79	5.86	5.93	5.99	6.05	6.11
	0.01	7.01	7.10	7.19	7.27	7.34	7.42	7.48	7.55
14	0.05	5.55	5.64	5.71	5.79	5.85	5.91	5.97	6.03
	0.01	6.87	6.96	7.05	7.12	7.20	7.27	7.33	7.39
15	0.05	5.49	5.57	5.65	5.72	5.78	5.85	5.90	5.96
	0.01	6.76	6.84	6.93	7.00	7.07	7.14	7.20	7.26
16	0.05	5.44	5.52	5.59	5.66	5.73	5.79	5.84	5.90
	0.01	6.66	6.74	6.82	6.90	6.97	7.03	7.09	7.15
17	0.05	5.39	5.47	5.54	5.61	5.67	5.73	5.79	5.84
	0.01	6.57	6.66	6.73	6.80	6.87	6.94	7.00	7.05
18	0.05	5.35	5.43	5.50	5.57	5.63	5.69	5.74	5.79
	0.01	6.50	6.58	6.65	6.72	6.79	6.85	6.91	6.96
19	0.05	5.31	5.39	5.46	5.53	5.59	5.65	5.70	5.75
	0.01	6.43	6.51	6.58	6.65	6.72	6.78	6.84	6.89
20	0.05	5.28	5.36	5.43	5.49	5.55	5.61	5.66	5.71
	0.01	6.37	6.45	6.52	6.59	6.65	6.71	6.76	6.82
24	0.05	5.18	5.26	5.32	5.38	5.44	5.49	5.55	5.59
	0.01	6.19	6.26	6.33	6.39	6.45	6.51	6.56	6.61
30	0.05	5.08	5.15	5.21	5.27	5.33	5.38	5.43	5.47
	0.01	6.01	6.08	6.14	6.20	6.26	6.31	6.36	6.41
40	0.05	4.98	5.04	5.11	5.16	5.22	5.27	5.31	5.36
	0.01	5.84	5.90	5.96	6.02	6.07	6.12	6.17	6.21
60	0.05	4.88	4.94	5.00	5.06	5.11	5.15	5.20	5.24
	0.01	5.67	5.73	5.79	5.84	5.89	5.93	5.98	6.02
120	0.05	4.78	4.84	4.90	4.95	5.00	5.04	5.09	5.13
	0.01	5.51	5.56	5.61	5.66	5.71	5.75	5.79	5.83
∞	0.05	4.68	4.74	4.80	4.85	4.89	4.93	4.97	5.01
	0.01	5.35	5.40	5.45	5.49	5.54	5.57	5.61	5.65



1. Belz, M. H. (1972), 'Statistical Methods for the Process Industries', MacMillan, Londres.
2. Daniel, W. W. e J. C. Terrell (1976), 'Business Statistics: Basic Concepts and Methodology', Houghton Mifflin, Boston.
3. Fishman, G. S. (1978), 'Principles of Discrete Event Simulation', John Wiley & Sons, Nova Iorque.
4. Gibbons, J. D. (1976), 'Nonparametric Methods for Quantitative Analysis', Holt, Rinehart and Winston, Nova Iorque.
5. Kendall, M. G. e A. Stuart (1963), 'The Advanced Theory of Statistics, Vol. 1, Distribution Theory', (2.ª edição), Hafner Publishing Company, Nova Iorque.
6. Kendall, M. G. e A. Stuart (1961), 'The Advanced Theory of Statistics, Vol. 2, Inference and Relationship', Hafner Publishing Company, Nova Iorque.
7. Kendall, M. G. e A. Stuart (1966), 'The Advanced Theory of Statistics, Vol. 3, Design and Analysis, and Time Series', Hafner Publishing Company, Nova Iorque.
8. Kenney, J. F. e E. S. Keeping (1954), 'Mathematics of Statistics. Part One' (3.ª edição), D. Van Nostrand Company, Princeton, Nova Jersey.
9. Kleinbaum, D. G., Lawrence L. Kupper e Keith E. Muller (1978), 'Applied Regression Analysis and Other Multivariable Methods', PWS-Kent Publishing Company, Boston.
10. Law, A. M. e Associates (2007), 'Simulation Modeling & Analysis' (4.ª edição), McGraw-Hill, Nova Iorque.
11. Montgomery, D. C. (2005), 'Design and Analysis of Experiments' (6.ª edição), John Wiley & Sons, Nova Iorque.
12. Mood, A. M., F. A. Graybill e D. C. Boes (1974), 'Introduction to the Theory of Statistics' (3.ª edição), McGraw-Hill, Singapura.
13. Murteira, B. J. (1990), 'Probabilidades e Estatística', Vols. I e II, (2.ª edição revista), McGraw-Hill, Lisboa.
14. Murteira, B. J. (1993), 'Análise Exploratória de Dados – Estatística Descritiva', McGraw-Hill, Lisboa.
15. Neter, J., W. Wasserman e G. A. Whitmore (1988), 'Applied Statistics' (3.ª edição), Allyn and Bacon, Boston.
16. Reis, E., P. Melo, R. Andrade e T. Calapez (1996), 'Estatística Aplicada', Edições Sílabo, Lisboa.
17. Ross, S. M. (1987), 'Introduction to Probability and Statistics for Engineers and Scientists', John Wiley & Sons, Nova Iorque.
18. Scheffé, H. (1999), 'The Analysis of Variance', John Wiley & Sons, Nova Iorque.
19. Siegel, S. e N. J. Castellan (1988), 'Nonparametric Statistics for the Behavioural Sciences' (2.ª edição), McGraw-Hill, Nova Iorque.
20. Wonnacott T. H. e R. J. Wonnacott (1990), 'Introductory Statistics' (5.ª edição), John Wiley & Sons, Nova Iorque.



Índice Remissivo

A

- Acontecimento(s)
 - certo 51
 - composto 51
 - impossível 51
 - independentes 58-59
 - simples 51
- Aleatoriedade 263, 287
- Amostra(s) 2-4
 - aleatória 168, 287
 - aleatória simples 168
 - geração 176-182, 186
 - bivariada 34
 - dimensionamento 230
 - emparelhadas 253, 286
 - equilibradas 311
 - univariada 11
- Amostragem,
 - aleatória 167-170
 - com reposição 168
 - não-probabilística 5
 - por conveniência 5
 - subjectiva 5
 - probabilística 4-5
 - sem reposição 168-169, 172
- Amplitude (da amostra) 26
- Amplitude interquartis 26, 83
- Análise combinatória 52
 - arranjos 63
 - combinações 63
 - permutações 63
- Análise de variância (ANOVA),
 - com dois factores, efeitos fixos (duas ou mais observações por célula) 316-324
 - com efeitos aditivos 316
 - com interacção 317
 - estimação dos parâmetros 318

- tabela ANOVA 326
- testes ANOVA 327
- com dois factores, efeitos variáveis (duas ou mais observações por célula) 324-327
 - estimação das variâncias 325, 327
 - intervalos de confiança 324
 - tabela ANOVA 326
 - testes ANOVA 325, 327
- com dois factores, efeitos fixos e variáveis (uma observação por célula) 327-331
 - intervalos de confiança 331
 - tabelas ANOVA 329-330
 - testes ANOVA 328
- com um factor, efeitos fixos 303-312
 - estimação dos parâmetros 336
 - intervalos de confiança,
 - (método de Tukey) 310-311
 - (método de Scheffé) 311-312
 - tabela ANOVA 308
 - teste ANOVA 307, 342
 - variação dentro dos grupos 306
 - variação entre grupos 306
 - variação total 306
- com um factor, efeitos variáveis 312-315
 - estimação da variância dos efeitos 315-316
 - tabela ANOVA 314
 - teste ANOVA 315
- Árvore de resultados 50
- Associação,
 - directa 291-292
 - inversa 291-292

B

- Bayes (teorema) 60-62
- Bernoulli (experiências) 119
- Box-Muller (método) 182, 186

C

- Célula mediana 21-22
- Célula modal 23-24
- Classificação cruzada (de dados) 316
- Coefficiente de assimetria,
 - amostral 32
 - populacional 85
- Correlação 103, 106
 - coeficiente de correlação,
 - amostral 40-41, 360
 - ordinal de Spearman 492
 - parcial 540
 - populacional 104-105, 114-115, 360
 - coeficiente de correlação múltipla 384
- Coefficiente de determinação, 43, 361
 - corrigido 44
 - múltipla 385
- Coefficiente de kurtose,
 - amostral 33
 - populacional 85
- Colinearidade 378
- Complementaridade (de acontecimentos) 51
- Conjunto vazio 51
- Correcção de Sheppard 28, 32
- Covariância,
 - amostral 40
 - como valor esperado 107-108
 - populacional 103-104, 109-110

D

- Dados,
 - contínuos 11
 - discretos 10
 - primários 6
 - qualitativos 9-11, 35
 - quantitativos 10-12, 36
 - secundários 6
- Desvio absoluto médio,
 - amostral 26-27
 - populacional 82
- Desvio cúbico médio,
 - amostral 31
 - populacional 85
- Desvio médio (ver Desvio absoluto médio)
- Desvio padrão,
 - amostral 29
 - populacional 83
- Desvio quadrático médio amostral 27
 - valor esperado, 141, 208-209
- Diagrama circular 11
- Diagrama de barras 11, 35, 70
- Diagrama de barras sobrepostas 35-36
- Diagrama de Venn 50

- Diagrama do tipo caixa 34
- Diagrama (x, y) 36
- Distribuição Binomial 119-121
 - aproximação pela distribuição de Poisson 138
 - valor esperado e variância 121, 130
- Distribuição Binomial Negativa 122-123
 - valor esperado e variância 123, 131-132
- Distribuição condicional 99
- Distribuição conjunta de probabilidade 95
- Distribuição da média amostral 171-173
- Distribuição de Cauchy 84
- Distribuição de frequências 12
- Distribuição de Gauss (ver Distribuição Normal)
- Distribuição de Poisson 126-129
 - forma funcional 127, 135-136
 - relação com as distribuições Binomial e Hipergeométrica 128-129, 138
 - valor esperado e variância 128, 137
- Distribuição do Qui-Quadrado 152-154, 265, 273
 - comparação com a distribuição Normal 155
 - valor esperado e variância 153
- Distribuição dos dados amostrais (ver Distribuição de frequências)
- Distribuição empírica (ver Distribuição de frequências)
- Distribuição Exponencial Negativa 143-144
 - valor esperado e variância 144, 158
- Distribuição F 156-157
 - valor esperado e variância 157
- Distribuição Geométrica 122
- Distribuição Hipergeométrica 123-126
 - relação com a distribuição Binomial 125-126
 - valor esperado e variância 125, 133-134
- Distribuição Lognormal 150-151
 - mediana e moda 151
 - valor esperado e variância 150, 162
- Distribuição marginal 98-99
- Distribuição Normal 145-150
 - aproximação da Distribuição do Qui-Quadrado 176
 - combinação linear de variáveis Normais 148
 - padronizada (ou reduzida) 146
 - parâmetros 145
 - função de distribuição 145
 - função densidade de probabilidade 145, 159
 - kurtose 146
 - relação com a distribuição Binomial 149
 - transformação linear de uma variável Normal 146-147, 161
 - valor esperado e variância 144, 160
- Distribuição por amostragem 170-171
- Distribuição t de Student 154-155, 293
 - valor esperado e variância 156
- Distribuição Uniforme 141-143
 - valor esperado e variância 143

E

- Enviesamento,
 - de selecção 5
 - de um estimador (ver Estimador) *stepwise* 377
- Erro(s) de previsão (em modelos de regressão) 357, 379
- Erro do tipo I (ver Teste de hipóteses)
- Erro do tipo II (ver Teste de hipóteses)
- Erro padrão 171
- Erro quadrático médio 193
- Escala,
 - absoluta 9-11
 - de intervalo 9-11
 - nominal 9-11
 - ordinal 9-11
- Espaço amostral 50
- Estatística(s) 19-33
 - de dispersão 26-33
 - de localização 19-26
 - representação gráfica 34
- Estatística de teste (ver Teste de hipóteses)
- Estatística descritiva 1, 9
- Estimação por intervalo (ver Intervalos de confiança)
- Estimador(es),
 - consistência 194
 - eficiência 191-193
 - eficiência relativa 193
 - enviesamento 190
 - LVM (método linear com variância mínima) 202-205
 - Mom (método dos momentos) 195-197
 - MQ (método dos mínimos quadrados) 205-206, 362
 - MV (método de máxima verosimilhança) 197-202
 - pontual 190
 - robustez 195
 - selecção 289
 - suficiência 195
- Estimativa(s) de parâmetros 190
- Experiência aleatória 50

F

- Factor de correcção da variância (populações finitas) 172
- Frequência absoluta 12
- Frequência relativa 12
 - acumulada 15
- Função condicional de densidade de probabilidade 100-101
- Função condicional de probabilidade 100-101
- Função conjunta de densidade de probabilidade 96-98, 104
- Função conjunta de probabilidade 96, 295
- Função de distribuição,
 - variável contínua 76
 - variável discreta 70
- Função de distribuição da amostra 268
- Função de distribuição empírica (ver Função de distribuição da amostra)

- Função de probabilidade 69
- Função de probabilidade acumulada (ver Função de distribuição)
- Função densidade de probabilidade 71-76
- Função Gama 152
- Função geradora de momentos 85, 92, 158, 160
- Função marginal de densidade de probabilidade 99
- Função marginal de probabilidade 98-99, 295
- Função de verosimilhança 198, 201

G

- Gauss, Carl F. 145
- Gosset, W. S. 154
- Graus de liberdade 152, 154, 156

H

- Hipótese alternativa 238
- Hipótese nula 238
- Histograma de frequências 13
 - com células de amplitude variável 13-14
 - número de células (de igual amplitude) 17
- Homogeneidade da variância 331, 334

I

- Independência 101-102
 - entre duas variáveis 295
- Inferência estatística 1, 8, 189
- Intervalo interquartis 26
- Intersecção (de acontecimentos) 58
- Intervalo(s) de confiança,
 - amplitude 215-216
 - conceito 213-216
 - da proporção Binomial 220
 - definição conjunta (ANOVA),
 - método de Scheffé 311-312
 - método de Tukey 310-312, 324, 331
 - limites de confiança 214
 - para a diferença entre proporções Binomiais 229-230
 - para a diferença entre valores esperados 225-229
 - para a razão entre variâncias de populações Normais 223-225
 - para a variância de uma população Normal 222-223
 - para o valor esperado 214, 217-220
 - para os parâmetros de regressão 352-354, 366-367
 - unilateral 217
- Interacção (ANOVA) 317, 321-322
- Intervalo de previsão (regressão) 358, 380, 388-389

K

- Kolmogorov, A. 267
- Kurtose 32, 146

L

Lilliefors, H. 270

M

Marquardt (método) 393

Matriz de variância-covariância 350, 363

Média,

amostral 19, 190

distribuição 173-175

valor esperado 171

variância 171-172, 183-184

populacional (ver Valor esperado)

Média geométrica 21, 44

Média harmónica 21, 45

Média pesada 20

Mediana,

amostral 21-22

populacional 80, 274

variância 192

Métodos de estimação pontual (ver Estimador)

Métodos de estimação por intervalo (ver Intervalos de confiança)

Moda,

amostral 23-24

populacional 80-81

Momentos,

amostrais,

centrados 29-30

ordinários 29-30

de variáveis transformadas 106-107

populacionais,

centrados 84

como valores esperados 86

ordinários 84

Monte Carlo (técnica) 176-182

Métodos congruênciais lineares 178, 185

N

Números pseudo-aleatórios 178, 185

O

Observações (ver Amostras)

P

Parâmetros populacionais 79-85, 170, 189

de dispersão 82-83

de localização 79-82

Percentil 26

Poisson, S. D. 126

Polígono de frequências 13

acumuladas 13

População(ões) 2-4

conjuntas 3

finita 3

infinita 3

Produto(s) cruzado(s) 39-40, 392

Proporção Binomial 220

Probabilidade,

a priori 62

a posteriori 62

condicional 56-58

definição axiomática 55

definição clássica 52

definição frequencista 54

definição geométrica 53

definição subjectiva 54

teoria (da) 47

Q

Quartil 26

R

Regressão linear múltipla,

colinearidade 378-379

com variáveis mudas 381-384

correlação (comparação) 384-385

estimação dos parâmetros 362-365

estimador da variância dos erros 363

hipóteses subjacentes 361

intervalos de confiança 366-367

matriz de variância-covariância 363

modelo 361

previsões 379-381

intervalo de previsão 380

selecção de regressores,

método exaustivo 372

método progressivo (ou *forward*) 372-377

método regressivo (ou *backward*) 377

métodos passo a passo (*stepwise*) 377-378

tabela ANOVA 370

testes de hipóteses 367-371

Regressão linear simples,

correlação (comparação) 360-361

estimação dos parâmetros 351-352

estimador da variância dos erros 351

hipóteses subjacentes 347-349

intervalos de confiança 352-354

matriz de variância-covariância 350

modelo 347

previsões 357-359

intervalo de previsão 358

recta estimada 350

tabela ANOVA 356

testes de hipóteses 354-357

Regressão não-linear,

múltipla com transformação de variáveis 389-392

polinomial 389-391

produtos cruzados 392

sem transformação de variáveis 393

simples com transformação de variáveis 385-389

intervalo de previsão 388-389

modelo com inversão da variável independente 386

modelo «curva S» 387

modelo exponencial 386

Regressão 371

Reunião (de acontecimentos) 51

S

Semente 178

Simulação 176

Snedecor, G. 156

Smirnov, N. 267

Sturges (regra) 17

T

Tabela de contingência 294

Tabela de frequências 11, 13

Tabela de informação cruzada 35

Teorema do limite central 173-175

Teoria de concepção de experiências 335

Teste(s) de hipóteses,

à diferença entre proporções Binomiais 257

à diferença entre valores esperados (testes Z e t),

amostras emparelhadas 253-256

amostras independentes 252-253

à proporção Binomial 256-257

à razão entre variâncias de populações Normais (teste F) 250-251

à variância de uma população Normal (teste do Qui-Quadrado) 250

ao valor esperado (testes Z e t) 351, 274, 278

bilateral 238

da correlação ordinal de Spearman 263, 291-294

das sequências 263, 288-289

das sequências ascendentes e descendentes 263, 289-291

de Bartlett 334-335

de Kolmogorov-Smirnov 263

duas amostras 274-275

uma amostra 267-271

de Kruskal-Wallis 332-334

de Man-Whitney-Wilcoxon 281-285, 298

de Wilcoxon 263

duas amostras emparelhadas 286-287, 297

uma amostra 279-281

do Qui-Quadrado (ajuste) 263

duas amostras 271-273

uma amostra 262-267

do Qui-Quadrado (associação) 263, 294-296

do sinal 263

duas amostras emparelhadas 286-287

uma amostra 276-279

erro do tipo I 240, 243

erro do tipo II 243-247

estatística de teste 239

inconclusivo 240

não-paramétricos 261

de aleatoriedade 263, 288-291

de associação 263, 291-296

de localização 263, 276-287

de qualidade de ajuste 263-276

nível de significância 240

paramétricos 261

de dispersão 249-251

de localização 249, 251-257

potência 243, 246-247, 285

procedimento básico 237

região de rejeição 240

regra de decisão 240

relação com intervalos de confiança 247-249

unilateral 238

valor crítico da estatística de teste 240

valor de prova 242

valor P (ver valor de prova)

V

Variável(eis) aleatória(s),

combinação linear,

valor esperado 108-110

variância 109-110

contínua 69

função de distribuição 76-77

função densidade de probabilidade 73-76

definição 67-69

discreta 69

função de distribuição 69-70

função de probabilidade 69-70

independentes 101-102

qualitativa 69

quantitativa 69

Valor esperado,

de variáveis contínuas 79

de variáveis discretas 79

de variáveis transformadas 86-90, 108-113

Variância,

amostral 28, 191

de variáveis contínuas 83

de variáveis discretas 83

de variáveis transformadas 86-90, 108-113

Variável dicotómica 279

Variável muda 381

Variáveis transformadas,

a partir de duas variáveis 106-107

a partir de uma variável 86-87

Y

Yates (correção) 296