

Cap. 2

Estatística Descritiva

AMG, LGRRF, AFL, JFO (v12 – 2023)

baseado em:

Estatística,

Rui Campos Guimarães

José A. Sarsfield Cabral

Tópicos

- **Introdução**
- **Tipos de Dados e Escalas**
- **Caracterização e Representação de Dados Categóricos**
- **Caracterização e Representação de Dados Quantitativos**
- **Caracterização e Representação de Dados Bivariados**
- **Anexos**


Introdução

Cap. 2 - 3

Tipos de Dados e Escalas

Exemplos

- Classif. de pessoas pela cor do cabelo: preto, castanho, branco, loiro, ...
- Classificação dos consumidores de bens de primeira necessidade pelo género: feminino ou masculino
- Classificações obtidas pelos alunos num teste de Estatística: mau, medíocre, suficiente, bom ou muito bom
- Classificação dos clientes segundo o volume de encomendas que colocam: clientes A (muito importantes), B (importantes) e C (pouco importantes)
- Temperaturas registadas, em °C, às 8 horas de dias sucessivos (note-se que não faz sentido dizer que em dias consecutivos a temperatura duplicou, p.e. passou de 5°C para 10°C, ... porquê?)
- Peso de pessoas, expressos em kg
- Volumes de investimento, expressos em milhares de euros
- Resultados de 150 lançamentos de um dado



Caracterização e Representação de Dados Categóricos

Caracterização de amostras univariadas

Amostra univariada

Quando cada um dos dados que a integram mede, numa escala qualquer, apenas um atributo

Dados categóricos (ou qualitativos) – distribuem-se por um conjunto de diferentes classes ou categorias

- representação tabular ou gráfica da distribuição de frequências (ou empírica ou dos dados amostrais)

Dados quantitativos – dados discretos ou contínuos

- representação tabular ou gráfica da distribuição de frequências
- cálculo de estatísticas (ou medidas) amostrais
- representação gráfica de estatísticas

Caracterização e Representação de Dados Quantitativos

Representação de dados quantitativos contínuos

Peso (em gramas) do conteúdo de 100 garrafas

Como representar este conjunto de dados?


302.25	299.20	300.24	297.72	301.10	299.70	302.17	297.47
298.35	303.76	298.65	299.38	301.11	298.86	298.61	304.22
300.36	299.19	300.86	299.83	299.68	299.75	301.99	302.85
302.52	300.12	301.81	297.99	298.49	299.60	299.26	302.45
299.23	298.73	303.07	299.07	303.66	302.10	298.35	302.83
297.83	299.75	299.55	298.76	299.95	299.76	299.13	299.07
301.85	299.83	300.52	298.98	298.72	303.49	298.00	305.13
300.73	300.14	298.34	299.07	298.56	301.05	302.39	297.84
299.62	299.12	298.11	299.48	299.70	301.35	298.85	300.20
302.45	302.04	300.83	298.94	298.34	299.70	298.36	301.59
298.07	298.29	303.91	298.16	297.59	300.96	299.08	300.02
299.57	300.84	299.18	301.33	297.87	301.63	300.48	299.16
298.23	302.00	300.86	299.80				

Criar **classes** (também denominadas categorias ou células) e contar ...


Tabela de frequências (relativas)

k	Limites	$f'_k(\%)$	$fa'_k(\%)$
1	[297, 0 ⁺ ; 298, 0]	8	8
2	[298, 0 ⁺ ; 299, 0]	21	29
3	[299, 0 ⁺ ; 300, 0]	28	57
4	[300, 0 ⁺ ; 301, 0]	15	72
5	[301, 0 ⁺ ; 302, 0]	11	83
6	[302, 0 ⁺ ; 303, 0]	10	93
7	[303, 0 ⁺ ; 304, 0]	5	98
8	[304, 0 ⁺ ; 305, 0]	1	99
9	[305, 0 ⁺ ; 306, 0]	1	100
Total		100	100

Histograma de freq. relativas



Polígono de frequências relativas



Polígono de freq. relativas acum.






Tabela de frequências (relativas)

k	Limites	$f'_k(\%)$.	$fa'_k(\%)$.
1	$[297, 0^+; 298, 0]$	8	8
2	$[298, 0^+; 299, 0]$	21	29
3	$[299, 0^+; 300, 0]$	28	57
4	$[300, 0^+; 301, 0]$	15	72
5	$[301, 0^+; 302, 0]$	11	83
6	$[302, 0^+; 303, 0]$	10	93
7	$[303, 0^+; 304, 0]$	5	98
8	$[304, 0^+; 305, 0]$	1	99
9	$[305, 0^+; 306, 0]$	1	100
Total		100	100


Histograma de freq. relativas



Polígono de frequências relativas




Polígono de freq. relativas acum.



Classes de amplitude variável

- adequadas a distribuições de frequência com concentrações elevadas em alguns valores
- permitem homogeneizar o número de elementos em cada classe
- altura de cada barra do histograma (h) é proporcional à frequência por unidade de amplitude da classe

Rendimentos colectáveis (contos)			Frequências relativas (%)
0 +	–	1500	0,6
1500 +	–	3000	10,2
3000 +	–	4500	13,4
4500 +	–	7500	29,3
7500 +	–	15000	36,4
15000 +	–	30000	10,1
Total			100,0




Exemplo (classe 15000⁺– 30000): $h = \frac{10.1}{\frac{30000 - 15000}{1500}} = \frac{10.1}{10} = 1.01$

Unidade de amplitude: 1500 (= amplitude da célula de menor amplitude)


Cap. 2 - 21

Estatísticas de localização

- Pretendem indicar onde se concentram os dados de uma distribuição de frequências ou histograma
 → **tendência central** ou **valor central**
- Principais estatísticas de localização: **Média, Mediana e Moda**



Moda=Mediana=Média



Moda

Mediana

Média

- Vector de dados $(x_1, x_2, \dots, x_N)$ ordenados por ordem crescente (ou decrescente), a **mediana amostral** (Med) vem


- ## Propriedade da mediana amostral

A mediana é o valor que minimiza a soma dos desvios absolutos:

$$\min \sum_{n=1}^N |x_n - C| \Rightarrow C = \text{Med}$$


Comparação entre média, mediana e moda

Histograma simétrico



Moda=Mediana=Média

Histograma assimétrico à direita





Moda
Mediana
Média

Histograma simétrico: $\bar{x} = Med = Mod$

Histograma assimétrico unimodal à direita: $\bar{x} > Med > Mod$ *



* Trata-se de uma regra prática que nem sempre se verifica (ver detalhes em <http://www.amstat.org/publications/jse/v13n2/vonhippel.html>)

Que medida de localização utilizar?



(Darrell Huff, "How to Lie with Statistics", Penguin Books, 1973)

Que medida de localização utilizar?



(Darrell Huff, "How to Lie with Statistics", Penguin Books, 1973)

Moda: não é muito útil para dados contínuos não-agrupados (pode haver mais do que uma moda ou mesmo nenhuma)

Mediana: pouco afectada por valores extremos (utilizada como medida quando se pretende caracterizar por exemplo o rendimento da população)

Média: de longe a medida de localização mais utilizada, embora seja afectada por valores extremos (popularidade: por ser afectada por todos os valores e propriedades matemáticas atractivas para a inferência estatística)

Estat. de dispersão – Desvio (absoluto) médio

- Média dos desvios absolutos dos dados em relação à média

Dados não agrupados:
$$DAM = \frac{1}{N} \sum_{n=1}^N |x_n - \bar{x}|$$

Dados discretos agrupados:
$$DAM = \sum_{k=1}^K f_k \cdot |x_k - \bar{x}|$$

Dados contínuos agrupados:
$$DAM = \sum_{k=1}^K f_k \cdot |M_k - \bar{x}|$$

Notas

- f_k : frequência relativa, M_k : o ponto central da classe k
- Dados agrupados apenas permitem cálculo aproximado, porquê?
- Porquê desvio absoluto?

Estat. de dispersão – Desvio quadrático médio

- Média dos quadrados dos desvios dos dados em relação à média
- Dá maior peso a desvios maiores (devido ao quadrado)

Dados não agrupados:
$$DQM = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^2$$

Dados discretos agrupados:
$$DQM = \sum_{k=1}^K f_k \cdot (x_k - \bar{x})^2$$

Dados contínuos agrupados:
$$DQM = \sum_{k=1}^K f_k \cdot (M_k - \bar{x})^2$$

Notas

- Preferível ao DAM (maior facilidade de manipulação matemática)
- Utilização do valor central da classe em dados agrupados leva à sobreavaliação sistemática do DQM $\Rightarrow$ **Correcção de Sheppard**

Correcção de Sheppard

- Tomar o ponto médio da classe M_k , no caso de dados contínuos agrupados, é um procedimento já adoptado no cálculo da média amostral e do desvio absoluto médio.
- No cálculo da média e da mediana não se introduz qualquer erro sistemático, pois os desvios introduzidos por pontos abaixo do ponto médio M_k tendem a ser compensados por desvios de sinal contrário introduzidos por pontos acima de M_k , isto é, se nuns casos se subavalia noutros sobreavalia-se.
- No cálculo do DQM , ao elevar-se ao quadrado os desvios, tende-se a sobreavaliar sistematicamente o DQM .
- Para histogramas unimodais, com classes de igual amplitude Δ , com a classe modal relativamente afastada dos valores extremos dos dados e com classes progressivamente decrescentes nas caudas (histograma em forma de sino), este efeito pode ser minorado pela introdução de um termo negativo no cálculo do DQM – a correcção de Sheppard (para o desvio quadrático médio):


$$DQM = \sum_{k=1}^K f_k (M_k - \bar{x})^2 - \frac{\Delta^2}{12}$$

Cap. 2 - 36

Estat. de dispersão – Quartis e Percentis

Quartis (Q_1 , Q_2 , Q_3)

Dividem um conjunto **ordenado** de dados em 4 segmentos com igual número de elementos



Cálculo dos quartis (livro recomendado)

Vector de dados $(x_1, x_2, \dots, x_N)$ ordenados por ordem crescente (ou decrescente), a posição do 1º e 3º quartil vem

$$pos(Q_1) = \frac{N+1}{4} \quad pos(Q_2) = \frac{2(N+1)}{4} \quad pos(Q_3) = \frac{3(N+1)}{4}$$

- Se $pos(Q_i)$ é um número inteiro então $Q_i = x_{pos(Q_i)}$
- Senão Q_i é igual à média entre os dois valores correspondentes às posições mais próximas $(Q_i = (x_{\lfloor pos(Q_i) \rfloor} + x_{\lceil pos(Q_i) \rceil})/2)$

Outras estatísticas – Momentos amostrais

Momentos ordinários (m'_i), ou em relação à origem, de ordem i

Dados não agrupados:
$$m'_i = \frac{1}{N} \sum_{n=1}^N (x_n)^i \quad (i = 1, 2, \dots)$$

Dados discretos agrupados:
$$m'_i = \sum_{k=1}^K f_k (x_k)^i \quad (i = 1, 2, \dots)$$


Dados contínuos agrupados:
$$m'_i = \sum_{k=1}^K f_k (M_k)^i \quad (i = 1, 2, \dots)$$

- A média amostral corresponde ao momento ordinário de primeira ordem:

$$m'_1 = \bar{x}$$


Porquê momentos de ordem superior a dois?

⇒ A média e o desvio padrão (ou a variância) não são suficientes para distinguir distribuições




Representação gráfica de estatísticas

Diagrama do tipo caixa





Histograma e diagrama do tipo caixa



- Não existe uma forma única para o diagrama do tipo caixa
- A forma apresentada é a forma básica do diagrama do tipo caixa
- Formas mais elaboradas permitem identificar potenciais valores extremos atípicos (*outliers*)

Interpretação de diagramas do tipo caixa

- a caixa central inclui 50% dos dados (os 50% centrais)
- os “bigodes” mostram a amplitude dos dados
- a simetria é indicada pela caixa central, “bigodes” e valor médio
- comparação entre diferentes grupos → construção de diagramas do tipo caixa lado a lado (ver caracterização de amostras bivariadas)



Como lidar com valores extremos (*outliers*)?

Duas alternativas:

(a) Utilizar medidas resistentes

Medidas resistentes: pouco sensíveis a valores extremos atípicos (baseadas em ordenações – quartis, mediana, *trimean*, *trimmean*, ...)

Notas:

- *trimean*: $TM = (Q1 + 2Q2 + Q3)/4$
- o *trimmean* é uma função do *Excel* que calcula a média ignorando uma percentagem dos valores mais extremos

Medidas não resistentes: são sensíveis a valores extremos atípicos (consideram sempre todos os valores – média, DQM, variância, ...)

(b) Eliminar *outliers*

- 1 Identificar possíveis valores extremos atípicos
- 2 Verificar cada um dos valores extremos atípicos (erro de medida?)
- 3 Corrigir ou Eliminar valores extremos atípicos confirmados
- 4 Calcular as estatísticas amostrais pretendidas

Caracterização e Representação de Dados Bivariados

Caracterização e Representação de Dados Bivariados

Amostra bivariada

Amostra constituída por **pares ordenados** de dados (medem-se 2 atributos diferentes do mesmo objecto)

- Para além da análise univariada a cada um dos atributos ...
- Pretende-se também **analisar as interacções** entre os dois atributos

Dados qualitativos:

- Tabela de informação cruzada
- Diagramas de barras sobrepostas



Dados quantitativos:

- Diagrama (x , y)
- Coeficientes de correlação e de determinação

Dados mistos:

- Um dos atributos é quantitativo e o outro é qualitativo

Dados qualitativos – Diagr. de barras sobrepostas



Nota o diagrama da direita também é conhecido como diagrama mosaico

Dados qualitativos – Paradoxo de Simpson

Business School

	Admit	Deny
Male	480 = 80%	120 = 20%
Female	180 = 90%	20 = 10%

Law School

	Admit	Deny
Male	10 = 10%	90 = 90%
Female	100 = 33%	200 = 67%

Dados qualitativos – Paradoxo de Simpson

Business School

	Admit	Deny
Male	480 = 80%	120 = 20%
Female	180 = 90%	20 = 10%

Law School

	Admit	Deny
Male	10 = 10%	90 = 90%
Female	100 = 33%	200 = 67%

- Aparentemente a taxa de admissão de mulheres é mais alta quer na Business school quer na Law school


Law School	Admit	Deny
Male	10 = 10%	90 = 90%
Female	100 = 33%	200 = 67%

Business and Law Schools		
	Admit	Deny
Male	490 = 70%	210 = 30%
Female	280 = 56%	220 = 44%


Ajuste de uma relação linear $\rightarrow$ MMQ (cont.)

Tipo de relações


Relação linear com declive positivo



Relação linear com declive negativo




Relação não linear (quadrática)




Observações

- Recta passa sempre pelo ponto $(\bar{x}, \bar{y})$, sejam quais forem os dados
- Desde que os x_n não sejam todos iguais, $s_{XX} > 0$, o sinal do declive da recta (b) será definido pelo termo $s_{XY} = \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$
- Perigoso fazer extrapolações para fora da gama de valores dos dados
- MMQ pode também ser utilizado para ajustar relações não lineares


$$r_{XY} = 1$$




$$0 < r_{XY} < 1$$



$$r_{XY} = -1$$



$$r_{XY} = 0$$



- $$S_{YY} = \sum_{n=1}^N (y_n - \bar{y})^2 = \sum_{n=1}^N [(y_n - \hat{y}_n) + (\hat{y}_n - \bar{y})]^2 = \underbrace{\sum_{n=1}^N e_n^2}_{\text{Não expl.}} + \underbrace{b^2 \sum_{n=1}^N (x_n - \bar{x})^2}_{\text{Explicada}}$$

- $$\frac{b^2 \sum_{n=1}^N (x_n - \bar{x})^2}{\sum_{n=1}^N (y_n - \bar{y})^2} = \frac{\left(\frac{s_{XY}}{s_{XX}}\right)^2 \cdot s_{XX}}{s_{YY}} = \frac{s_{XY}^2}{s_{XX} \cdot s_{YY}} = r_{XY}^2 = 1 - \frac{\sum_{n=1}^N e_n^2}{s_{YY}}$$

$$r_{XY}^2 \text{ (corrigido)} = 1 - \frac{\sum_{i=1}^N (e_n)^2 / N - 2}{s_{XY} / N - 1}$$

- Atributo qualitativo caracteriza o grupo
 - Cálculo de estatísticas dentro de cada grupo
 - Diagramas do tipo caixa para cada grupo, colocados lado a lado e alinhados para facilitar a comparação
- ⇒ Procurar **diferenças de dispersão** (variação) entre os vários grupos, **alterações nas médias** de cada grupo e **outliers** (valores extremos atípicos)



Anexos

Level of Measurement	Properties	Examples	Descriptive statistics	Graphs
Nominal / Categorical	Discrete Arbitrary (no order)	Dichotomous Yes / No Gender Types / Categories Colour shape	Frequencies Percentage Mode	Bar Pie
Ordinal / Rank	Ordered categories Ranks	Ranking of favourites Academic grades	Frequencies Mode Median Percentiles	Bar Pie Stem&leaf
Interval	Equal distances between values Discrete (e.g., Likert scale) Continuous (e.g., deg. F)	Discrete - Thoughts, behaviours, feelings, etc. on a Likert scale Continuous - Deg. C or F	Frequencies (if discrete) Mode (if discrete) Median Mean SD Skewness Kurtosis	Bar (if discrete) Pie (if discrete) Stem & Leaf Boxplot Histogram (if continuous)
Ratio	Continuous Meaningful 0 allows ratio statements (e.g., A is twice as large as B)	Age Weight VO_2 max Deg. Kelvin	Mean SD Skewness Kurtosis	Histogram Boxplot Stem & Leaf (may need to round leaves)

adapted from http://www.wilderdom.com/research/Summary_Levels_Measurement.html
(James Neil, 2009)

Statistic	Nominal	Ordinal	Interval	Ratio
Mode	Yes	Yes	Yes	Yes
Median	No	Yes	Yes	Yes
Range, Min, Max	No	Yes	Yes	Yes
Mean	No	No	Yes	Yes
SD	No	No	Yes	Yes

Graph	Nominal	Ordinal	Interval	Ratio
Bar / Pie	Yes	Yes	If discrete	No
Stem & Leaf	No	Yes	Yes	Yes
Boxplot	No	Yes	Yes	Yes
Histogram	No	No	If continuous	Yes

- Estatística Descritiva (v12 - 2023) Cap. 2 - 70

Exemplo

The following data give the yearly numbers of law enforcement officers killed in the United States over 10 years:

164, 165, 157, 164, 152, 147, 148, 131, 147, 155

Find the sample variance of the number killed in these years.

Exemplo

The following data give the yearly numbers of law enforcement officers killed in the United States over 10 years:

164, 165, 157, 164, 152, 147, 148, 131, 147, 155

Find the sample variance of the number killed in these years.

To make the computation easier: $y_i = x_i - 150$

x_i	164	165	157	164	152	147	148	131	147	155
y_i	14	15	7	14	2	-3	-2	-19	-3	5
y_i^2	196	225	49	196	4	9	4	361	9	25

$$\bar{y} = \frac{1}{10} \cdot \sum_{i=1}^5 y_i = \frac{14 + 15 + 7 + 14 + 2 - 3 - 2 - 19 - 3 + 5}{10} = \frac{30}{10} = 3.0$$

$$\sum_{i=1}^5 y_i^2 = 196 + 225 + 49 + 196 + 4 + 9 + 4 + 361 + 9 + 25 = 1078$$

$$\sum_{i=1}^N y_i^2 - N \cdot \bar{y}^2 = 1078 - 10 \times 3^2 = 988 \quad s^2 = \frac{988}{9} \approx 109.78$$

Nota: $x_i - \bar{x} = x_i - \bar{x} - C + C = (x_i - C) - (\bar{x} - C) = y_i - \bar{y}$

Exemplo

The following table gives the U.S. per capita consumption of whole milk (x) and low-fat milk (y) in three different years. Find the sample correlation coefficient of the given data.

	Per capita consumption (gallons)		
	1980	1982	1984
Whole milk (x)	17.1	14.7	12.8
Low-fat milk (y)	10.6	11.5	13.2

Exemplo

The following table gives the U.S. per capita consumption of whole milk (x) and low-fat milk (y) in three different years. Find the sample correlation coefficient of the given data.

	Per capita consumption (gallons)		
	1980	1982	1984
Whole milk (x)	17.1	14.7	12.8
Low-fat milk (y)	10.6	11.5	13.2

To make the computation easier, let us first subtract 12.8 from each of the x values and 10.6 from each of the y values.

$$\bar{x}' = \frac{4.3 + 1.9 + 0}{3} = 2.0667$$

$$\bar{y}' = \frac{0 + 0.9 + 2.6}{3} = 1.1667$$

$$\sum_{i=1}^3 x_i y_i = 0 + 1.9 \times 0.9 + 0 = 1.71$$

	i		
	1	2	3
x'_i	4.3	1.9	0
y'_i	0	0.9	2.6

$$\sum_{i=1}^3 x_i'^2 = 4.3^2 + 1.9^2 + 0 = 22.10$$

$$\sum_{i=1}^3 y_i'^2 = 0 + 0.9^2 + 2.6^2 = 7.57$$

$$r = \frac{1.71 - 3 \times 2.0667 \times 1.1667}{\sqrt{[22.10 - 3 \times 2.0667^2] \cdot [7.57 - 3 \times 1.1667^2]}} = -0.97$$

Resultados de aprendizagem

- Distinguir os diferentes tipos de escalas em que dados podem ser expressos
- Classificar e sintetizar manualmente pequenos conjuntos de dados amostrais
- Calcular, manualmente ou com recurso a calculadoras, estatísticas de pequenos conjuntos de dados amostrais
- Utilizar folhas de cálculo e software estatístico para classificar e sintetizar dados amostrais (representação tabular e gráfica, cálculo de estatísticas)
- Distinguir os vários tipos de estatísticas: de localização, de dispersão, de forma e de associação
- Interpretar correctamente representações tabulares e gráficas de dados amostrais, assim como os resultados de estatísticas